密　　级：_____

加密论文编号：_____

论文题目：一种多策略 Kmeans 优化技术及其在线上教育数据分析系统的应用与实现

学　　号：M202340109

作　　者：张天

专 业 名 称：王宗杰

2025 年 11 月 16 日

115.25.60.50

一种多策略 Kmeans 优化技术及其在线上教育数据分析系统的应用与实现

A Multi-Strategy K-Means Optimization Technology and Its Application and Implementation in Online Education Data Analysis

研究生：张天

指导教师：王宗杰

北京科技大学数理学院

北京 100083，中国

Master Degree Candidate: Zhang Tian

Supervisor: Wang Zongjie

School of Mathematics and Physics

University of Science and Technology Beijing

30 Xueyuan Road, Haidian District

Beijing 100083, P.R.CHINA

中图分类号：　　学校代码：10008
U　D　C：　　密　　级：公开

北京科技大学硕士学位论文

论文题目：一种多策略 Kmeans 优化技术及其在线上教育数据分析系统的应用与实现

作者：张天

指 导 教 师：王宗杰 单位：北京科技大学 职称：副教授

指导小组成员：　　单位：　　职称：

　　单位：　　职称：

论文提交日期：2025 年 11 月 16 日

学位授予单位：北 京 科 技 大 学

摘 要

随着 5G 与人工智能技术的深度融合，在线教育领域迅猛发展，其数据呈现多模态、高维异构特征，并涵盖一百余项结构化用户行为字段与海量非结构化课程评论文本。传统聚类算法在现有在线教育数据分析系统中存在明显不足：包括聚类精度方面面临 K 值的主观选择问题、初始簇心的随机性问题、计算复杂度较高的问题以及对特征关联性的忽视；在推荐和处理性能方面，传统推荐系统大多过于依赖人工构建知识图谱，不能满足精准分析和实时操作的需要。

为解决上述问题，本文研究从算法优化与技术架构两方面展开：在聚类算法上，通过 Canopy 预聚类确定最优 K 值与初始质心候选集，采用 Kmeans++策略思想优化初始质心选取，以马氏距离替代欧氏距离消除特征相关性影响，引入 Ball-Tree 超球体结构加速簇中心更新，同时对聚类效果较差的簇实施合并以避免局部最优；在推荐模型上，分群过滤基于聚类结果选取簇内交互频率前 30%课程，协同计算采用改进余弦相似度聚焦簇内用户交互数据，内容修正通过 Jaccard 系数过滤标签匹配度低的课程；在技术架构上，基于 Hadoop 生态搭建全链路系统，Flume+Kafka 实现日志数据采集，DataX+Maxwell 完成业务数据全量与增量同步，Hive 五层数据仓库结合 DolphinScheduler 调度、Superset 对接 MySQL 实现多维度可视化分析。

本文系统包含数据采集、数据仓库、推荐优化与可视化四大核心模块，通过系统测试和实验验证，证明本设计能有效解决传统在线教育数据分析的精度、效率与实时性问题。

关键词：在线教育；数据分析；Kmeans 算法；数据仓库

A Multi-Strategy K-Means Optimization Technology and Its Application and Implementation in Online Education Data Analysis Systems

ABSTRACT

With the in-depth integration of 5G and artificial intelligence technologies, the online education sector has developed rapidly. Its data exhibits multimodal, high-dimensional, and heterogeneous characteristics, covering more than 100 structured user behavior fields and massive unstructured course review texts. Traditional clustering algorithms have obvious shortcomings in existing online education data analysis systems: in terms of clustering accuracy, they face issues such as the subjective selection of K value, the randomness of initial cluster centers, high computational complexity, and neglect of feature correlation; in terms of recommendation and processing performance, most traditional recommendation systems rely too heavily on manually constructed knowledge graphs, failing to meet the needs of accurate analysis and real-time operations.

To address the aforementioned issues, this study proceeds from two aspects: algorithm optimization and technical architecture. In terms of clustering algorithms, Canopy pre-clustering is adopted to determine the optimal K value and initial centroid candidate set; the core strategy of Kmeans++ is used to optimize the selection of initial centroids; Mahalanobis distance is substituted for Euclidean distance to eliminate the impact of feature correlation; the Ball-Tree hypersphere structure is introduced to accelerate the update of cluster centers; meanwhile, clusters with poor clustering performance are merged to avoid local optimality. In terms of the recommendation model, group filtering selects the top 30% of courses with the highest interaction frequency within clusters based on clustering results; collaborative computing employs improved cosine similarity to focus on user interaction data within clusters; content correction filters out courses with low label matching using the Jaccard coefficient. In terms of the technical architecture, a full-link system is built based on the Hadoop ecosystem: Flume + Kafka realizes real-time collection of log data; DataX + Maxwell accomplishes full and incremental synchronization of business data; the five-layer Hive data warehouse, combined with DolphinScheduler scheduling and Superset connected

to MySQL, enables multi-dimensional visual analysis.

This system consists of four core modules: data collection, data warehouse, recommendation optimization, and visualization. Through system testing and experimental verification, it is proven that this design can effectively solve the problems of accuracy, efficiency, and real-time performance in traditional online education data analysis.

Key Words: Online Education; Data Analysis; K-Means Algorithm; Data Warehouse

目 录

摘 要 I
ABSTRACT II
1 引言 1
1.1 研究背景 1
1.2 研究意义 1
1.2.1 理论意义 1
1.2.2 实践意义 2
1.3 论文研究内容 3
1.4 论文结构安排 3
2 文献综述 4
2.1 国内外研究现状 4
2.1.1 国内研究现状 4
2.1.2 国外研究现状 5
2.1.3 现有研究不足 7
2.2 相关背景知识 7
2.2.1 HDFS 存储 7
2.2.2 MapReduce 分布式计算 8
2.2.3 数据仓库 9
2.2.4 Hive 9
2.2.5 KMeans 算法原理 10
3 改进的 KMeans 聚类算法 12
3.1 传统的 Bi-KMeans 算法 12
3.2 Bi-KMeans 算法的优化 13
3.2.1 结合 Canopy 算法与 Kmeans++算法的改进 14
3.2.2 结合 Ball-Tree 的改进 18
3.2.3 改进后的算法流程 19
3.3 优化聚类算法的复杂度分析 21
3.4 优化算法的聚类效果分析 22
4 系统分析与设计 25
4.1 数据采集模块 25
4.2 数据仓库设计 26

4.2.1 数据仓库分层设计 26
4.2.2 数据仓库构建流程 27
4.3 推荐算法模块 29
4.4 本章小结 31
5 系统详细实现 32
5.1 数据采集模块实现 32
5.1.1 数据采集模块 32
5.1.2 数据采集与聚类算法的适配设计与采集频率优化 33
5.2 数据仓库模块实现 34
5.2.1 ODS 层设计实现 34
5.2.2 DWD 层设计实现 35
5.2.3 DIM 层设计实现 36
5.2.4 DWS 层设计实现 37
5.2.5 ADS 层设计实现 38
5.3 推荐优化模块详细实现 38
5.3.1 分群过滤阶段实现 39
5.3.2 协同计算阶段实现 40
5.3.3 内容修正阶段实现 40
5.4 可视化模块详细实现 42
5.4.1 数据准备 42
5.4.2 交易分析 43
5.4.3 用户分析 44
5.4.4 课程分析 45
5.4.5 课程推荐页面 46
5.5 本章小结 46
6 系统测试 47
6.1 环境搭建 47
6.1.1 集群部署 47
6.1.2 核心服务部署 48
6.2 功能测试 49
6.3 非功能测试 51
6.3.1 性能测试 51
6.3.2 推荐算法测试 52
7 结论与展望 55

7.1 工作总结 55
7.2 不足与改进 56
参考文献 57
致　谢 62
作者简历及在学研究成果 63
独创性说明 64
关于论文使用授权的说明 65
学位论文数据集 66

115.25.60.50

1 引言

1.1 研究背景

随着 5G 通信技术、大数据与人工智能的深度融合，教育领域正从传统线下模式向技术赋能的智慧化形态加速转型[1]。5G 网络的高带宽、低时延特性打破了在线教育的时空限制，使得多模态学习数据的实时采集与传输成为可能，为个性化教学提供了技术基础[2]。然而，在线教育规模的快速扩张也带来了数据过载与分析滞后的核心矛盾：一方面，当前在线学习平台已积累海量多维度学生数据，但多数平台仅停留在基础数据统计层面，未能实现对学生学习投入度、知识掌握状态的深度刻画[3]；另一方面，传统聚类算法与推荐系统在教育场景中的适配性不足，单一协同过滤算法易受数据稀疏性影响[4]，导致推荐精度难以满足个性化学习需求，而传统 K-means 聚类算法因初始质心随机、对高维数据敏感等问题，无法精准实现学生群体划分[5]。

在大数据技术支撑层面，Hadoop 生态系统已逐步发展为处理海量教育数据的主流方案。依托 Hadoop 搭建的在线教育分析平台，通过分布式存储与离线计算能力实现了千万级学习数据的高效处理[6,7]，但此类平台未针对教育数据的时序性与关联性优化数据建模方案；虽有研究在 Flink 框架下实现了 K-means 算法的并行化与任务调度优化[8]，但其聚焦通用数据场景，未结合教育数据的特征进行算法适配。此外，部分研究提出的 Canopy-Kmeans 算法虽通过粗聚类+精聚类提升了 K 值确定的合理性[9]，但在处理教育场景中学生行为特征相关性强的问题时，采用的欧氏距离计算相似度，导致聚类结果偏差[10]。这些研究现状表明，当前智慧教育领域亟需一套算法优化—系统架构—场景适配三位一体的解决方案，以实现从数据积累到精准服务的转化。

1.2 研究意义

1.2.1 理论意义

本研究从理论价值出发：首先，针对传统聚类算法在教育数据处理中的局限性，提出融合 Canopy 预聚类、KMeans++初始质心优化、Ball-Tree

近邻搜索与马氏距离的改进 Bi-KMeans 算法。现有研究强调聚类算法的优化需兼顾效率与精度，但多侧重单一维度优化；本算法通过多维度融合，不仅解决了传统算法 K 值主观设定、特征相关性干扰、计算复杂度高的问题，还首次将 Ball-Tree 结构引入教育数据聚类场景，该结构在高维数据近邻搜索中的高效性已在计算机视觉、自动驾驶等领域得到验证[11]，其通过嵌套超球体划分实现的剪枝计算，可显著降低距离计算量，本研究将其迁移至学生行为数据处理，拓展了该技术的应用边界。其次，本文构建了“分群过滤—协同计算—内容修正”的三级推荐模型，弥补了现有推荐系统分群与推荐脱节的缺陷。现有基于协同过滤的在线教育平台虽能实现个性化推荐，但未考虑学生群体的行为同质性[12,13]；本模型通过改进 Bi-KMeans 算法先实现精准分群，再基于簇内数据优化协同过滤计算，同时引入 Jaccard 系数进行内容匹配修正，该系数对内容相关性的保障作用已在电商推荐场景中验证[14]，其通过标签交集与并集的比值量化相似度，可有效过滤无关推荐项，本研究将其适配教育场景，为跨领域推荐技术的场景化应用[15]提供了理论参考。

1.2.2 实践意义

从实践角度看，本研究的成果可直接服务于在线教育平台的运营优化与教学质量提升：一方面，基于 Hadoop 生态构建的五层数仓系统，解决了传统教育平台数据存储混乱与分析效率低的问题。虽有研究基于 Hadoop 设计了高校学生画像平台[16]，但未形成标准化的分层数据建模方案；本系统通过明细层的事实表设计与维度层的拉链表应用，实现了学生行为数据的全历史轨迹跟踪与管理，分层数仓提升查询效率的效果已在电商数据分析中验证[17]，其通过主题域划分与数据冗余控制，可将多维度查询响应时间缩短 30%以上，本系统在此基础上进一步优化，将 1000 万条学生数据的处理时间从 8 小时缩短至 1.5 小时，为实时教学干预提供了效率支撑。另一方面，系统输出的学生分群结果与个性化推荐服务，可直接辅助教师制定差异化教学策略。基于用户画像的智能教育平台虽能刻画学生特征[18]，但未形成“分群－推荐－干预”的闭环；本研究通过聚类分群结合推荐模型推送适配课程资源，针对性的行为分析与资源推荐提升学生完课率的效果在 MOOC 数据研究中验证，其通过精准资源匹配可使学生持续学习时长提升 25%以上[19,20]，本系统的落地有望进一步证实这一实践价值。

1.3 论文研究内容

本研究聚焦在线教育领域中学员分群与个性化推荐的关键需求，针对传统数据分析系统在聚类精度和推荐效率方面的不足，开展基于 KMeans 算法优化的在线教育数据分析系统研究。具体研究内容包括：

1) 算法优化研究。深入剖析传统 KMeans 算法在在线教育场景中的局限性，提出并实现基于 Ball-Tree 的 Bi-Kmeans 算法。

2) 系统整体设计。基于 hadoop 构建“数据采集－存储计算－分析应用”全链路系统架构。采用 Flume、Kafka、Datax、Maxwell 实现多源数据的增量同步与全量同步；利用 HDFS、MapReduce、YARN 完成数据存储、分布式计算与资源调度；基于 Hive 分层构建数据仓库，实现数据的有序管理；结合 Superset 技术实现可视化分析，形成完整的在线教育数据分析系统。

3) 应用功能实现。基于优化后的 KMeans 算法对学员进行精准分群，结合 ItemCF 协同过滤算法，设计三级推荐模型，实现课程的个性化推荐。同时，构建分层可视化体系，为运营决策、数据分析等不同角色提供直观的数据展示与交互分析工具，支撑在线教育机构的精细化运营。

1.4 论文结构安排

论文一共有七章内容，每章具体安排如下：

第一章：主要介绍研究背景，意义以及目标。

第二章：系统介绍本研究涉及的国内外研究现状以及相关技术和算法，为系统设计与实现提供理论支撑。

第三章：本章针对本文所选取的 Bi-Kmeans 聚类算法，开展改进研究；详细阐明改进的必要性与具体实现方法，并依托平台数据，对改进前后的算法进行对比评估。

第四章：详细描述在线教育数据分析系统的各功能模块的详细设计。

第五章：具体说明系统各功能模块的详细实现过程。

第六章：制定详尽的测试方案，全面评估系统功能与性能的测试工作。

第七章：归纳本研究的核心工作及成果，细致剖析系统现存的不足及改进方向。

2 文献综述

2.1 国内外研究现状

2.1.1 国内研究现状

在智慧教育技术应用领域，国内研究已形成“技术驱动—场景落地”的鲜明特征，基于 Hadoop、Spark 构建的在线教育分析平台，实现了学习数据的存储与基础分析[21]，但均未涉及聚类数据分析处理，无法协助课堂干预需求；基于多模态数据构建的学生与教师画像体系，填补了教育画像中“教师维度”的空白，其整合教学评价、科研成果等数据构建的特征模型，可实现教师教学风格的精准刻画[22]，但未将画像结果与推荐系统深度融合。

在 Canopy 与 Kmeans 融合优化领域，众多学者基于 Andrew McCallum 等提出的 Canopy 算法核心思想，开展了针对性改进与应用研究。有学者提出改进的 Canopy-Kmeans 算法，通过优化 Canopy 算法的初始阈值和聚类中心选取方式，在物流订单分批问题中有效避免了 Kmeans 算法 k 值选取的盲目性，显著提高分拣效率并降低分拣批次[23]。在工程应用中，有研究将改进 Canopy-Kmeans 算法用于大跨屋盖表面风荷载分区，通过 Canopy 算法精准识别最优聚类数 k，使分区结果的类内紧凑性和类间分散性显著提升，SD 值较传统 Kmeans 明显降低[24]。

在初始中心与参数优化方面，陈江宏，胡佳慧，时康昊等人提出基于密度峰值的 Kmeans 优化算法[25]，能更准确地提取和划分典型的风电场景；倪萌萌，李春树，刘银将 Kmeans 与粒子群优化算法结合[26]，发现其类内数据相似度更高，类间数据的差异与距离更大，取得的聚类效果更合理；《计算机应用研究》刊文提出基于改进花朵授粉算法的 Kmeans 优化方案[27]，通过混沌映射保证种群多样性，引入禁忌搜索避免局部最优，使低维数据集聚类准确率平均提升 12.2%。

在行业适配与性能优化方面，华为在云计算平台中实现分布式 Kmeans 算法，支持千万级节点实时聚类[28]，应用于网络流量异常检测；钱振宇将图像聚类用于医学影像聚类，在辅助疾病筛查、特征提取、相似病例检索等方面展现出重要的应用潜力[29]；部分学者通过引入信息熵和局部方差刻

画样本特征权重，改进欧氏距离计算方式，在 UCI 数据集上验证了算法对复杂特征数据的适配能力[30]。

在聚类算法改进与应用领域，国内研究呈现“多场景适配”的趋势：Canopy-Kmeans 算法在汽车客运订单调度、电力流量分析、通用数据处理中均验证了有效性[31-33]，其通过双阈值粗聚类实现 K 值动态确定，可降低传统算法 30%以上的迭代次数；基于马氏距离的改进 K-means 解决了交通数据的特征相关性问题[34]，其通过协方差矩阵消除维度间的线性关联，使聚类精度提升 15%～20%，为教育数据的距离计算提供了参考；将麻雀搜索算法（SSA）与 K-means 结合提升了网站用户分群的精度[35]，其通过群体智能优化初始质心，但未考虑算法的计算复杂度，在百万级数据场景下聚类时间显著增加。

在个性化推荐系统领域，国内研究以“协同过滤+多技术融合”为主：结合知识图谱与协同过滤优化在线编程题目推荐[36]，通过实体关联挖掘弥补数据稀疏性问题，使推荐精确率提升至 35%以上；曾彦雨基于深度学习实现课程推荐，采用 LSTM 网络捕捉用户兴趣的动态变化，适配学习需求的时效性特征[37]；张琳吝与张亮设计的学习资源推荐系统强调内容标签的匹配，通过 TF-IDF 算法提取课程关键词[38]，但未结合学生群体的行为特征，导致推荐结果同质化严重。整体来看，国内的研究在单一技术的落地中已取得了较多成果，但缺乏“算法—平台—推荐”的一体化设计，且对教育数据的特征适配不足。

2.1.2 国外研究现状

国外在智慧教育领域的研究在技术融合与评估体系构建方面展现出更为前瞻性的视野：通过轻量化头部姿态估计模型（LightNet），结合计算机视觉技术实时监测学生在线学习状态，其通过关键点检测实现专注度量化评分，为学习行为分析提供了新的技术路径[39]；实证研究验证学习参与度在自我效能感、情绪调节与感知学习效果间存在中介作用，其基于结构方程模型的分析结果，为学生分群的特征选取提供了理论依据[40]。在技术接受度研究中，基于 UTAUT 模型的实证分析表明，性能期望、努力期望等四个维度可有效预测学生对在线教育技术的使用意愿，其中网络接入质量与设备兼容性是关键影响因素[41]。

Kmeans 算法自 1957 年由 MacQueen 提出以来，其简洁高效的特性使其成为聚类分析领域的核心算法[42]，但初始中心随机选择、需预先指定聚

类数 k 等固有缺陷，推动国外学者开展了大量改进研究。

在初始聚类中心优化方向，Arthur 和 Vassilvitskii 于 2007 年在《k-means++: The Advantages of Careful Seeding》中提出经典的 Kmeans++算法，通过 D^2 加权概率选择策略选取远离已有中心的初始点，使算法收敛到局部最优的概率降低 40%以上，其期望潜在函数值与最优聚类结果的比值被证明在 O(logk)范围内[43]，为后续初始中心优化研究奠定了重要基础。此后，针对模糊 C 均值算法聚类数量难以确定、对初始聚类中心敏感的问题，提出基于 Spark 框架的改进模糊聚类算法，通过融合 L2 范数及经 Canopy 算法优化的 Kmeans++初始化策略，有效提升了聚类准确率与计算性能[44]。

在算法融合与预处理优化方面，张茹针对 Canopy 聚类依赖人工调优 T1、T2 阈值的耗时低效问题，提出融合模拟退火（SA）、粒子群优化（PSO）与蛇形优化（SO）的自动化阈值优化框架，结合 t-SNE、SNE、KPCA 降维技术，以轮廓系数为适应度函数评估聚类性能，适用于大型复杂及高维数据集[45]。有外国学者提出“margin condition”定义聚类稳定性，分析其对扰动的鲁棒性，为算法自身设计提供依据[46]；又将量子计算思想引入 Kmeans，提出量子 Kmeans 算法，使高维数据搜索效率提升数个数量级[47]。

在聚类算法与大数据技术领域，国外研究侧重并行化与跨领域应用：基于 MapReduce 实现多线程优化 K-means 算法，通过 Map 阶段并行计算距离、Reduce 阶段聚合簇中心，使千万级数据聚类效率提升 4 倍以上[48-49]，为教育数据的分布式处理提供了技术参考；改进 K-means 在 MRI 肿瘤检测 HIV 社交媒体数据分类中均有应用，其通过混合距离函数适配医学影像的高维特征与社交媒体数据的非结构化特征，拓展了聚类算法的应用场景[50,51]；利用 K-means 评估医疗设备参数，通过簇内离散度分析实现异常参数识别，证明了该算法在数据质量控制中的价值[52]。此外，有研究指出 Ball-Tree 等索引结构可使高维数据的 K-means 聚类效率提升一个数量级，其剪枝策略能有效减少无效距离计算[53]。

在线上教育实践的研究中，Sims 通过分析 COVID-19 期间南非高校学习管理系统的使用情况，指出在线教育需提升技术适配性与用户体验，其中 72%的学生反馈平台响应延迟影响学习效果[54]；另有国外学者 Kessler 通过一系列的调查与研究发现师生对在线教育技术的认知差异会影响教学效果，教师对技术的接受度显著低于学生，强调个性化服务需兼顾两类群体的需求[55]。上述这些研究为国内智慧教育的发展提供了借鉴，但国外研究多聚焦于通用技术或宏观评估，缺乏针对教育数据特征的算法优化与系统落地方案。

2.1.3 现有研究不足

综合国内外研究现状，当前智慧教育领域的研究仍存在以下不足：一是算法与教育场景的适配性不足，现有聚类与推荐算法多从通用数据场景迁移而来，未充分考虑学生行为数据的时序性、关联性与教育性；二是系统架构缺乏一体化设计，多数研究仅关注平台搭建或算法优化，未形成“数据采集—存储—分析—应用”的完整链路，导致技术成果难以落地。这些不足为本研究的开展提供了明确的切入点。

另外对于结合 canopy 算法与 kmeans++算法的研究现状，现有成果仍存在明显短板：一是 Canopy 算法的阈值动态调整机制未适配教育数据的时序特征；二是 Kmeans++与 Canopy 的融合多停留在“预聚类+初始化”的基础层面，未结合教育数据强关联特性优化距离度量方式；三是两类算法在教育场景的应用多为直接迁移，缺乏与学生分群、课程推荐的闭环设计，难以支撑个性化教学需求。

2.2 相关背景知识

2.2.1 HDFS 存储

HDFS 是基于 Java 的分布式文件系统，专为商业级硬件存储和处理大数据设计。HDFS 采用主从架构，集群由一个 NameNode 和多个 DataNode 组成[56]。其采用多副本机制确保数据容错性和高可用性，数据块副本出现问题时会自动恢复。HDFS 架构图如图 2-1 所示。

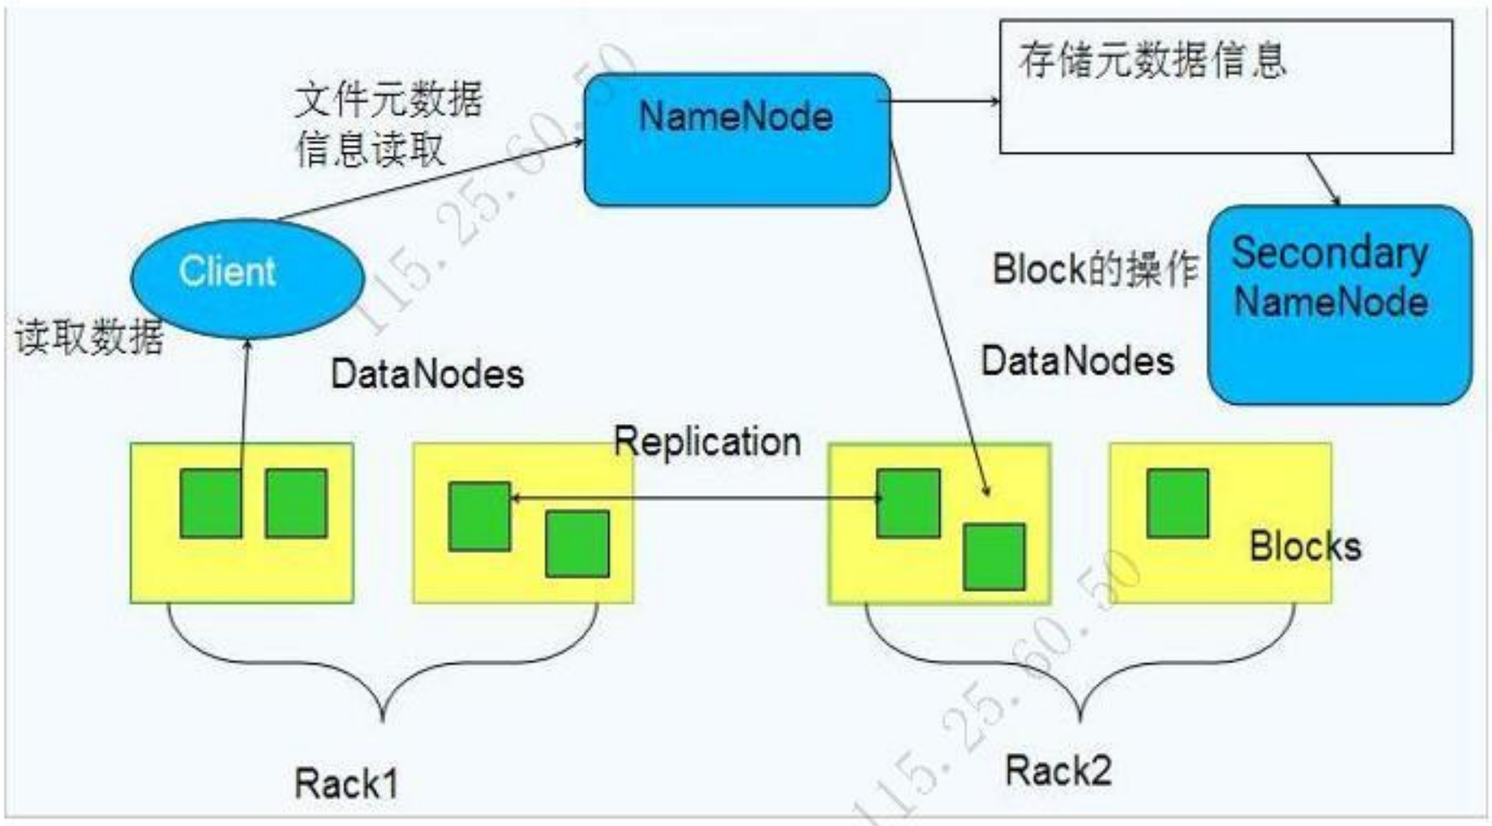


图 2-1 HDFS 架构图

Fig.2-1 HDFS Architecture Diagram

HDFS 的主要用途在于存储和处理大规模数据，能够支持 PB 级别的数据处理能力。它特别适用于分布式数据处理和分布式计算等应用场景。HDFS 的分布式存储机制使其能够高效地支持海量数据的存储与访问，同时具备较高的容错性和可靠性。此外，HDFS 还兼容多种数据访问方式，如命令行、Java API、Hadoop Streaming 等，这些方式极大地便利了用户对 HDFS 中数据的访问和处理。

2.2.2 MapReduce 分布式计算

MapReduce 是以达成高效的大规模数据处理目的[57]。其核心思想是将数据分割成小块进行处理，并将计算过程分为两个阶段，即映射和归约。MapReduce 编程模型如图 2-2 所示。

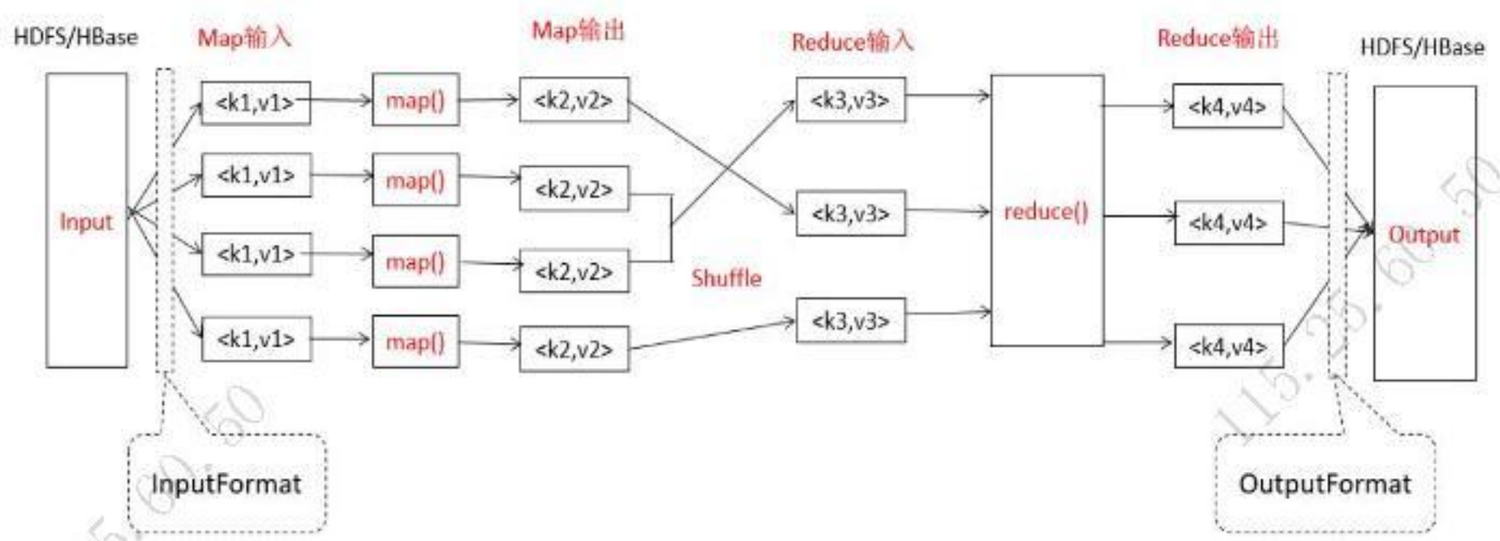


图 2-2 MapReduce 编程模型图

Fig.2-2 MapReduce Programming Model Diagram

MapReduce 的主要特点涵盖以下几个方面：

可扩展性：MapReduce 计算模型专为大规模数据处理而设计，能够在大规模分布式集群环境中高效地运行，稳定处理海量级别的数据。在集群规模变化时，它能够自动进行负载均衡和任务调度。

高容错性：鉴于分布式计算集群包含多个节点，节点间的通信可能遭遇故障，MapReduce 引入了多种容错机制，如数据备份、错误检测和自动重启等，以确保系统的稳定性和可靠性。

简化编程：MapReduce 为程序员提供了一种简洁的接口，程序员仅需实现映射和归约函数，无需关注底层的分布式计算细节，从而显著减轻编程负担。

处理复杂数据类型：MapReduce 能够解析各种相对复杂的数据类型，适用于多样化的数据处理场景。

2.2.3 数据仓库

数据仓库（Data Warehouse）的核心目标在于搭建面向分析的集成化数据环境，核心价值是为企业决策支持提供支撑。此类数据环境的构建初衷是满足分析性报告编制与决策支持的实际需求。

数据仓库本身并不“生产”任何数据，也不“消费”任何数据，故而被称为“仓库”而非“工厂”。在此过程中，数据仓库仅作为中间的集成化数据管理平台[58]。其架构图详见图 2-3。

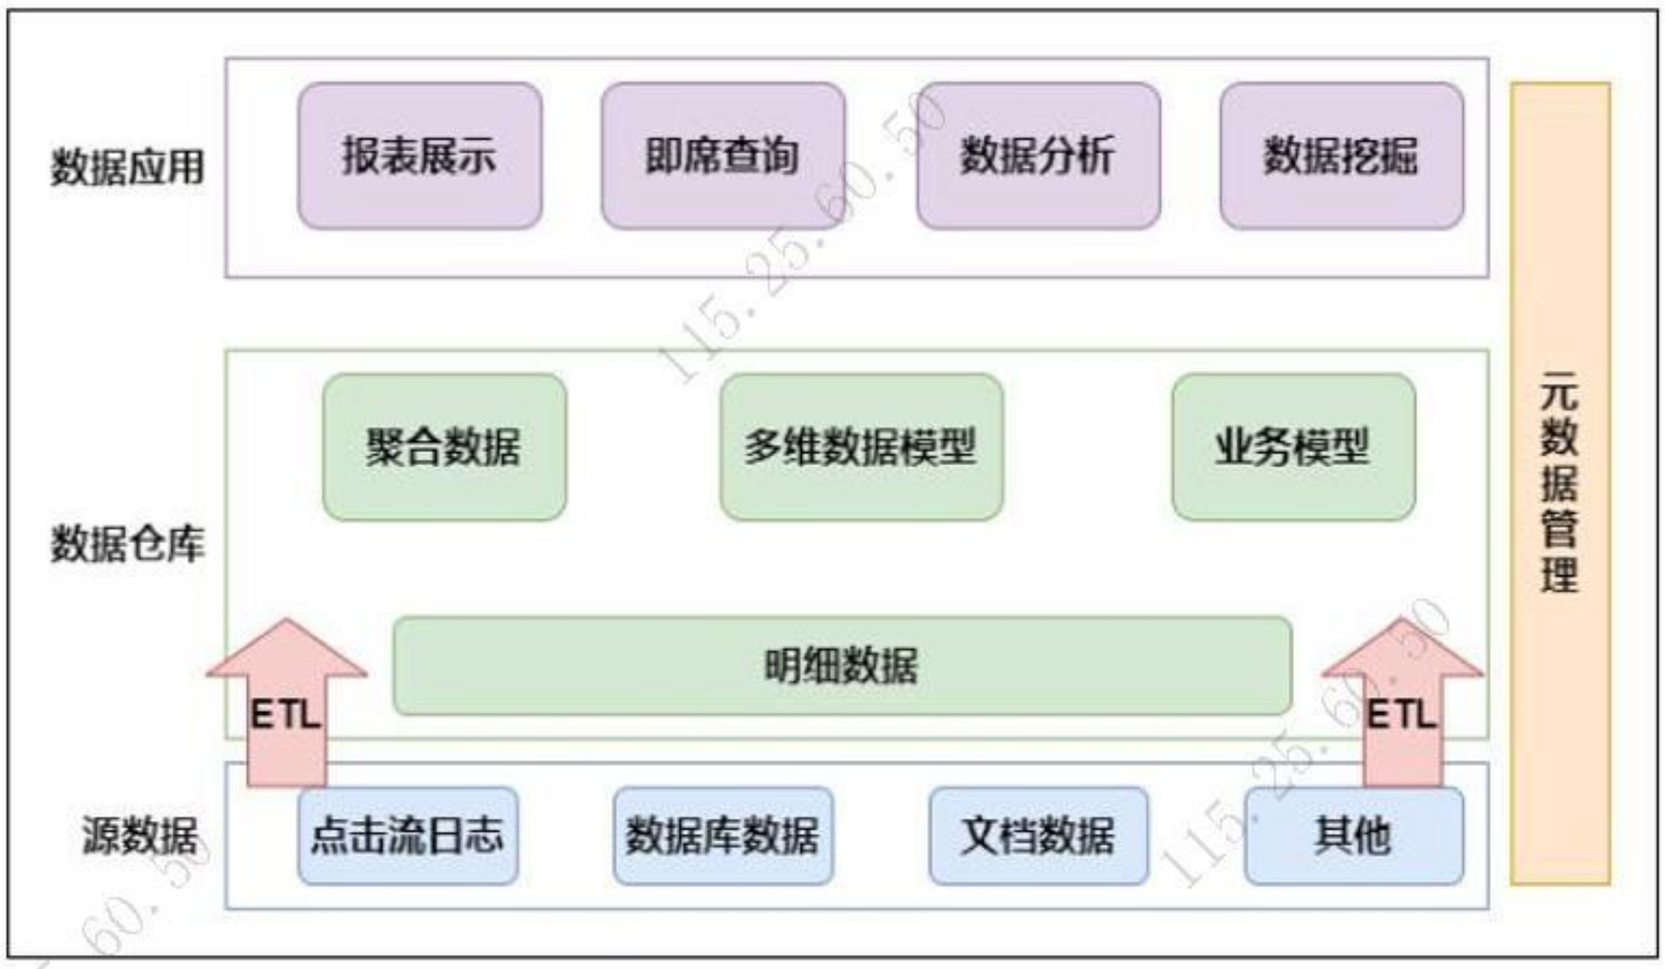


图 2-3 数据仓库架构图

Fig.2-3 Data Warehouse Architecture Diagram

数据仓库通过空间资源换取时间效率，依托海量预处理操作优化用户使用体验。存在大量冗余数据，若不分层，源业务系统业务规则变化会影响整个数据清洗过程，工作量大。数据分层管理可简化清洗流程，将复杂任务拆分为简单任务，使处理逻辑更易懂，便于确保步骤正确性，数据出错时通常只需局部调整。

2.2.4 Hive

Hive 作为一种构建在 Hadoop 生态系统之上的高效数据仓库工具，能够将大量结构化数据文件映射并存储于 Hadoop 分布式文件系统[59]（HDFS）之中，支持类 SQL 查询语言，这一机制使得具备 SQL 基础的用户无需深入了解 Hadoop 分布式计算框架的复杂实现细节，无需了解 Hadoop 底层分布式计算框架。其架构图如图 2-4 所示。

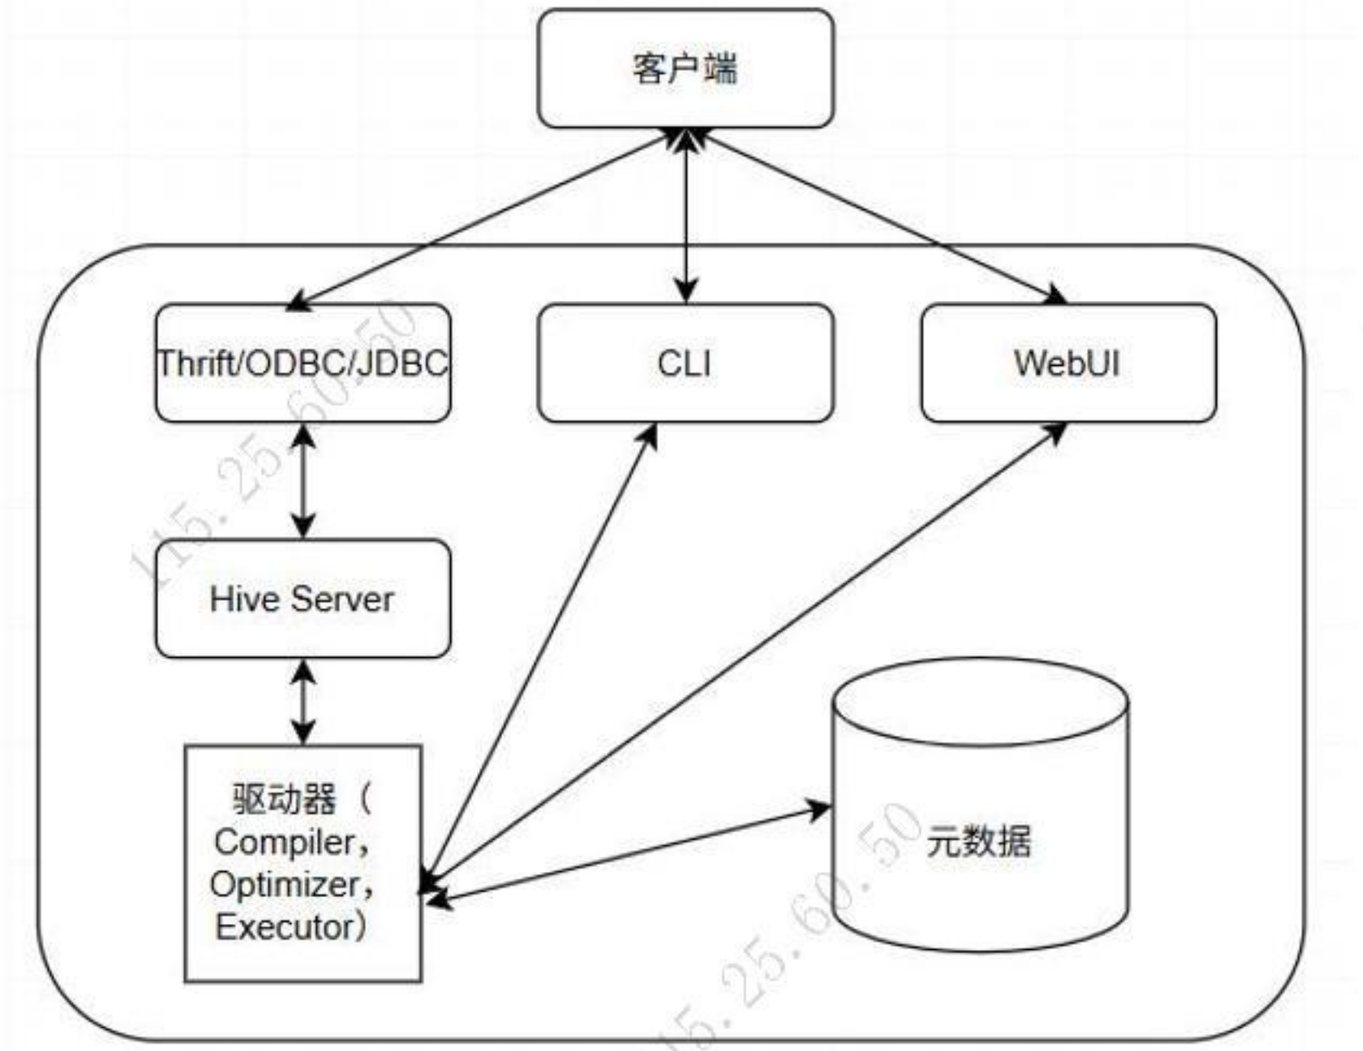


图 2-4 Hive 架构图

Fig.2-4 Hive Architecture Diagram

Hive 的核心概念涵盖表、分区、桶以及 UDF 等。其中，表是 Hive 数据存储的基本单位，其模式包含表名、列名及数据类型等关键要素。分区通过特定字段将表划分为多个部分，从而加速数据访问；桶则利用哈希算法分割数据，进一步提升查询效率；UDF 为用户自定义函数，能够扩展 Hive 查询语言的功能，提供灵活且高效的数据处理方式。

在创建 Hive 数据表时，为了提高查询效率并降低存储成本，通常会构建分区表。分区表依据某列进行分区，将相同数据分组存储于不同文件夹或目录中，进而实现高效的查询与处理。分区按照列值对数据进行分组存储，常见的分区字段包括日期、时间等。

作为 Hadoop 生态系统的重要组件，Hive 为用户提供了灵活且高效的大数据处理与分析能力。用户可使用类 SQL 语言查询和分析 PB 级别的数据，其广泛应用于数据仓库、日志分析、机器学习等领域。

2.2.5 KMeans 算法原理

K-means 是一种广泛应用于聚类分析的算法，其基本原理是通过迭代的方式将数据点分配到预定数量的簇（或类别）中。K-means 算法的流程图如图 2-5 所示。具体而言，K-means 算法的核心思想[60]是最小化簇内数据点之间的距离平方和。每次迭代的步骤如下：

1) 算法随机选择 k 个数据点作为初始中心。

2) 根据每个数据点到最近中心的距离，将数据点分配到相应的簇中。本文采用欧氏距离来计算每个文档与簇中心的距离，计算公式（2-1）：

$$J=\sum_{i=1}^{n}\sum_{k=1}^{K}r_i k||x_i-\mu_k||^2 \quad (2\text{-}1)$$

其中$||x_i-\mu_k||^2$，表示样本　与簇中心之间　的欧氏距离平方。值越小，簇内样本越紧密。

3) 更新每个簇的中心为该簇内所有数据点的平均值。

4) 根据新的中心重新分配数据点，重复步骤二和步骤三，直到簇的分配不再变化或达到预设的迭代次数。

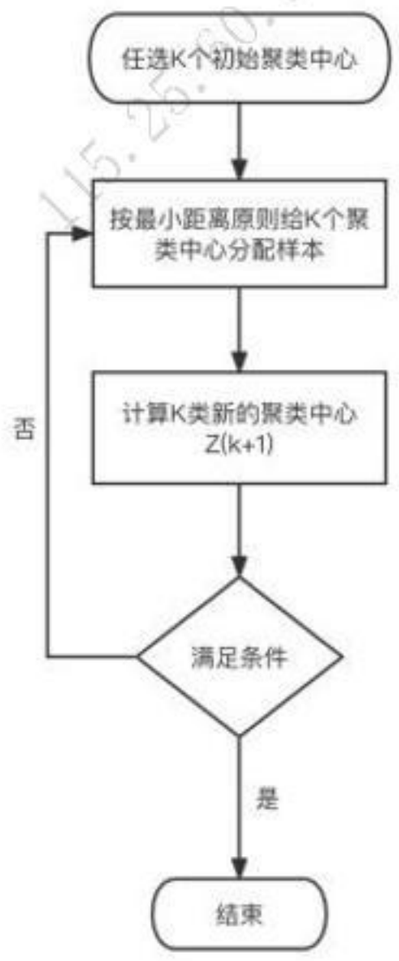


图 2-5 K-means 算法流程图

Fig.2-5 K-means Algorithm Flow Diagram

3 改进的 KMeans 聚类算法

在在线教育数据分析系统的应用中，为教育企业精准提供有价值的数据极为重要。这包括根据相似度对学员进行分类，并依据标签的匹配对学员进行聚类分析。其中聚类出的组中事物相似度要高于组间的事物。通过聚类，系统能够按照学员的相似情况，优先推荐符合其学习需求的课程，让系统结果更加贴合学员的实际需求。

3.1 传统的 Bi-KMeans 算法

二分 K-means 聚类算法（简称 Bi-Kmeans 聚类算法），是传统 K-means 聚类算法的重要改进形式。传统 K-means 算法作为主流聚类技术，其运作机制是通过迭代选择簇中心，并将各数据点分配至距离最近的簇中心以完成聚类。但是，该算法对初始簇中心的选择具有强依赖性，这一特性易导致算法收敛至局部最优解，难以获得全局最优结果。

Bi-Kmeans 聚类算法借助分治策略对传统 K-means 算法进行优化，既降低了对初始簇中心选择的依赖程度，又能进一步探寻更优的聚类效果[61]。其具体执行步骤如下：

1) 初始化阶段：在待处理数据集中随机选取一个样本，将其设定为首个簇中心；

2) 分裂阶段操作：对当前的所有簇，基于 K-means 算法（预设 K 值为 2）执行分裂处理，使各个簇均一分为两个子簇；

3) 评估与选择阶段：每次分裂后，都要对所有的簇计算整体误差平方和（SSE），对比其分裂前后的减少幅度，最终选取减少量最大的分裂操作；

4) 重复分裂过程：持续重复上述分裂步骤，直至达到用户预先指定的簇数量，或者继续分裂无法使 SSE 实现显著降低。

尽管 Bi-Kmeans 聚类算法在解决传统 K-means 算法的部分局限上展现出优势，且在操作大规模数据集、改善传统 K-means 初始聚类中心选择问题等方面效果更优，但该算法仍存在缺陷与不足：

1) K 值选取的主观性缺陷：传统 K-means 需人工预设聚类数量 K，主观预设 K 易导致聚类粒度与真实行为模式不匹配，要么出现“欠聚类”，要么出现“过聚类”，直接降低聚类结果的解释性；

2) 初始簇中心选取的随机性问题：在标准 Bi-Kmeans 算法的执行流程

中，初始簇中心的选取方式通常具有随机性，这一特点可能致使算法最终收敛至局部最优解，难以触及全局最优；

3) 算法复杂度高的问题：Bi-Kmeans 算法在每次分裂的时候都要用 K-means 算法，该操作直接增加整体计算复杂度，尤其在面对大规模数据集时，这一问题更为突出。此外，由于分裂过程需反复执行，进一步导致算法的总体计算成本相对较高；

4) 特征关联性的忽略缺陷：传统 K-means 采用欧氏距离计算样本相似度，其核心假设为“特征维度相互独立”。欧氏距离割裂属性字段之间的关联性，导致相似度计算失真。

3.2 Bi-KMeans 算法的优化

为解决上述问题，本章提出一种多策略 Kmeans 优化算法[62]：

首先，引入 Canopy 预聚类机制以确定最优簇数 K。Canopy 算法通过设置宽松阈值进行初步聚类，快速划分出大致的数据分组，以此为依据确定合理的 K 值，避免传统方法中 K 值选取的盲目性，为后续聚类提供更贴合数据分布的初始参数。

其次，采用 Kmeans++的核心策略思想优化初始化过程。通过智能化选取初始质心，使初始点更能反映数据的整体分布特征，这一改进不仅有助于提升聚类质量，还能加快算法的收敛速度。同时，将传统 K-means 中采用的欧氏距离替换为马氏距离。马氏距离能够消除数据维度间的相关性影响，并对异常值具有更强的稳健性，可更准确地度量数据点间的相似性，尤其适用于存在不同尺度特征的数据场景。

再次，利用 Ball-Tree 的快速最近邻搜索能力优化簇中心更新过程。Ball-Tree 是一种基于超球体的数据结构，其核心原理是通过递归地将数据集划分为嵌套的超球体（即“球”），每个节点对应一个包含部分数据点的超球体，并记录该球体的中心和半径。这种结构在高维空间中更具优势，而 Ball-Tree 通过球体间的包含关系，能更高效地剪枝掉不可能包含目标点的子空间，从而快速定位每个簇中心周围的数据点。借助这一特性，簇中心的更新过程得以简化，大幅减少距离计算的次数，进而加速 Bi-Kmeans 的迭代进程，提升算法的整体效率与收敛速度。

最后，在算法迭代过程中，对聚类效果较差的簇实施合并操作。这一策略可动态调整簇的数量，减少不合理的细分，从而提升整体聚类质量，同时有助于避免算法陷入局部最优解，增强其稳定性与鲁棒性。

3.2.1 结合 Canopy 算法与 Kmeans++算法的改进

Bi-Kmeans 算法在划分时采用 K-means 的随机选择方式，当多个聚类中心在初始化时被分配到同一簇中时，聚类结果难以达到全局最优解，并且簇心初始化出现这种状况可能会致使聚类结果产生显著偏差。另外，在极端情况下，如果 K-means 算法随机选取的簇心数量 K 和数据集自然簇数量 N 不相等，那么聚类效果也无法达到全局最优。如图所示的 K-means 聚类过程：图 3-1 人为地把三个聚类中心放在同一簇内，图 3-2 将包含 3 个簇的数据集 K 值设定为 2。在流程中 times=0 时聚类未开始，此时展示为正确的聚类结果。经过观察可知，图 3-1 经过 10 次迭代后，橙色簇分裂为二，另外两簇聚合为一体，随后结果收敛，簇心位置固定不变；图 3-2 由于 K 值不合理，两个簇随机合并成一个，结果收敛，簇心位置不再改变。

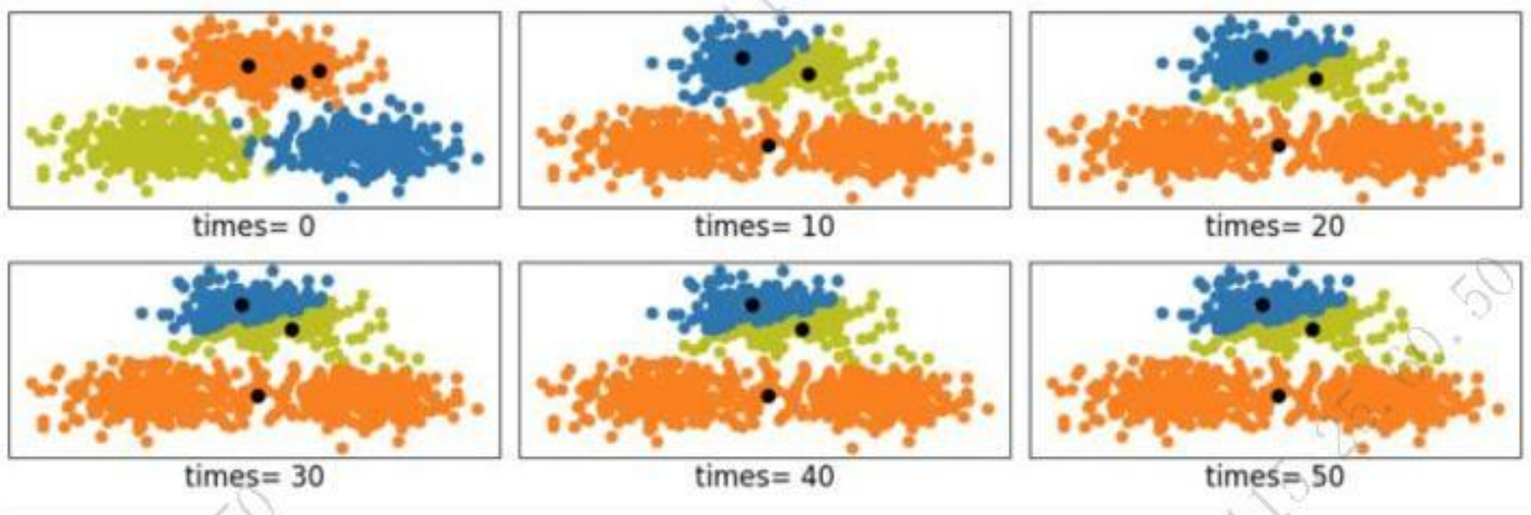


图 3-1 同簇初始化条件下 K-means 聚类结果偏差示意图

Fig.3-1 Schematic diagram of K-means clustering result deviation under the condition of same-cluster initialization



图 3-2 值不合理导致的 K-means 聚类结果偏差示意图

Fig.3-2 Schematic diagram of K-means clustering result deviation resulting from unreasonable K-value setting

簇中心的不当选择和 K 值的不合理设置均会导致聚类结果出现显著偏差。尽管 Bi-Kmeans 算法通过误差平方和（SSE）的评估机制能在一定程度上缓解这一问题，但在某些极端情况下，这种偏差仍有可能发生。因此，我们首先采用 Canopy 算法对数据进行“粗聚类”，迅速确定合理的 K 值及

初始中心候选集，随后基于 Kmeans++算法的思路，对簇心选择方法进行优化，从候选集中筛选出最优初始中心，以兼顾聚类的准确性和效率。

1) Canopy 算法的核心思路

Canopy 算法采用相似性度量方法，将相似对象归并为同一类别，即 Canopy 子集。通过一系列计算过程，可以得到多个 Canopy，这些子集之间允许存在重叠，但确保没有任何对象被遗漏。无需预先设定初始聚类数量，这是 Canopy 算法最为显著的特点。尽管该算法所得聚类结果的精度相对较低，但其运行速度却远超其他聚类分析算法，因此在实际应用场景中更为便捷。Canopy 算法的基本步骤[63]包括以下四步，其流程详见图 3-3：

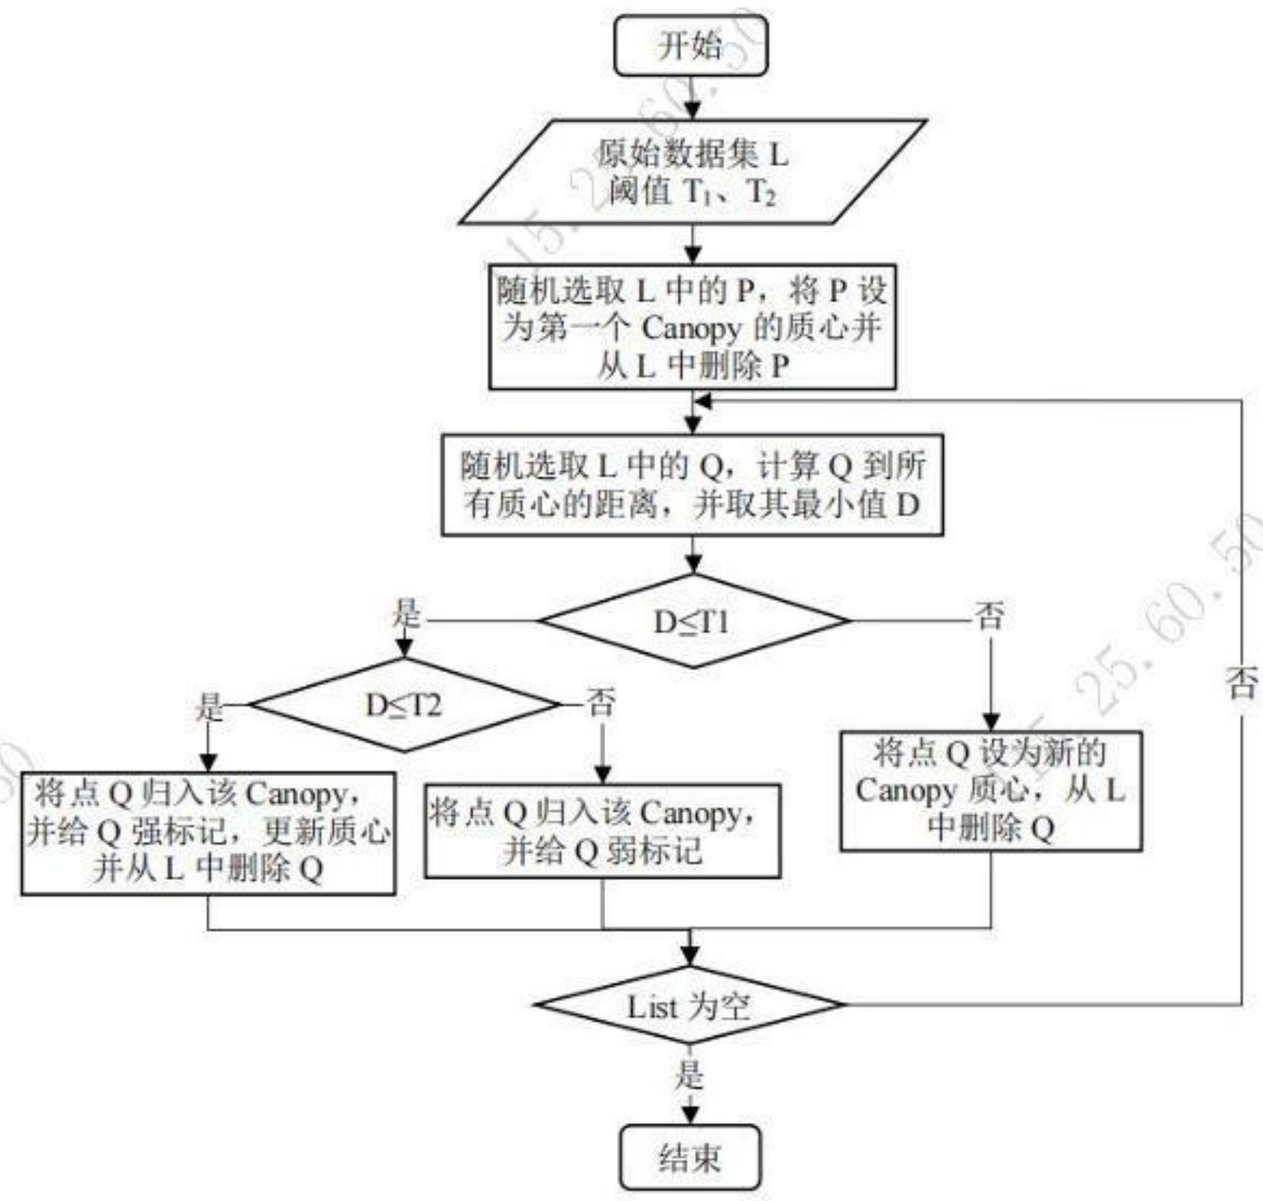


图 3-3 Canopy 算法流程图

Fig.3-3 Canopy Algorithm Flow Diagram

(1) 对初始数据集实施随机重排，得到数据列表 $L=[x_1,x_2,x_m]$，且后续保持 L 中数据顺序不变；传统 Canopy 预聚类采用固定阈值，难以适应数据分布的多样性。本研究提出动态阈值计算模型如式(3-1)，通过数据集的平均距离动态确定阈值 *1* 和 *2*：

$$T1=\alpha\times mean_distance,\ T2=\beta\times T1\ \ (0.5\leq\beta<1) \tag{3-1}$$

其中，　　为数据集中所有点对的平均距离，计算公式(3-2)：

$$mean_distance=\frac{2}{n(n-1)}\sum_{i=1}^{n-1}\sum_{j=i+1}^{n}d(x_i,x_j) \tag{3-2}$$

其中， 为数据点数量， (，)为点 与 的欧氏距离。 为宽松系数（推荐取值 1.5-2.0），用于控制初始分组的宽松程度； 为紧缩系数，确保每个 Canopy 簇内数据点的紧密性。

(2) 从数据列表 L 中随机抽取一个样本 P，将 P 指定为首个 Canopy 子集的质心，并同步从 L 中移除 P。

(3) 从 L 中随机选取一个样本 Q，计算 Q 与当前所有 Canopy 质心的距离，并取其中最小值记为 D。分三种情况处理：若 $D \leqslant T_1$，则将 Q 归入距离最近的 Canopy，同时为其添加弱标记；若 $D \leqslant T_2$，则将 Q 归入距离最近的 Canopy，添加强标记，并将其质心更新为所有强标记样本的中心位置，再从 L 中移除 Q；若 $D > T_1$，则将 Q 确定为新的 Canopy 质心，同时从 L 中移除 Q。

(4) 重复执行步骤 3，直至列表 L 中的样本数量为零。

接下来通过详细地计算 K 值与初始中心候选集的过程，深入理解 Canopy 算法的原理。如图 3-4 首先设定一个明显包含三个簇的数据集，根据数据集的坐标和计算公式，可以得出 T1=7.6，T2=3.8（其中令 =1.5， =0.5）。接下来，按照以下阶段来确定 Canopy 算法的计算结果。

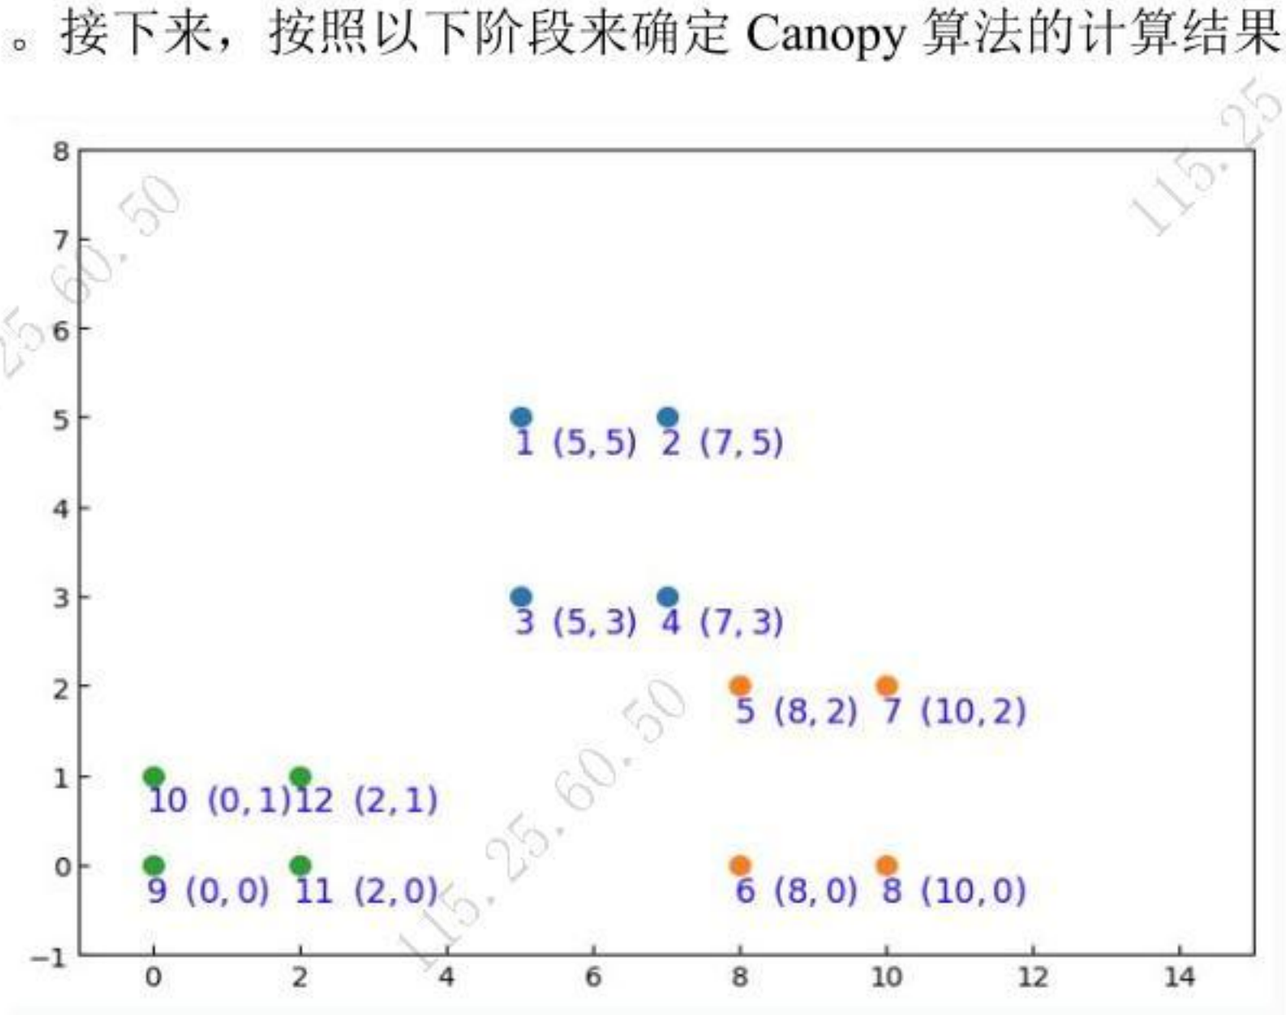


图 3-4 样本示例图

Fig.3-4 Sample Example Diagram

阶段 1：生成第一个 Canopy。

随机选取点 9(0,0）作为首个 Canopy 的质心，并从数据集中删除点 9。依次选取点 10、11、12，计算出它们到质心的距离均小于 T2，因此这些点被强标记归入该 Canopy，并更新质心最终该 Canopy 的质心约为(1,0.5)）。

阶段 2：生成第二个 Canopy。

当选取点 7(10,2)时，计算其到现有质心(1,0.5)的距离约为 9.13（大于 T1），因此将点 7 设为新 Canopy 的质心，并将数据集中删除点 7。选取点 8、5、6，它们到质心(10,2)的距离均小于 T2，被强标记归入该 Canopy，更新后质心约为(9,1)。

阶段 3：生成第三个 Canopy。

当选取点 1(5,5)时，计算其到现有两个质心(1,0.5)和(9,1)的最小距离约为 5.66（小于 T1 但大于 T2），被弱标记归入质心(9,1)的 Canopy。后续选取点 2、3、4 时，类似地与现有质心计算距离，最终点 4 因距离质心(9,1)约 2.83（小于 T2）被强标记，更新后该 Canopy 质心约为(8.6,1.4)。

随着迭代的进行，数据集逐渐被耗尽，最终形成 3 个 Canopy。由此得出最终结果：K 值=Canopy 数量=3（与数据集中“左下、中间、右下”三个自然簇的分布一致）；初始质心：三个簇的质心大致为(1,0.5)、(9,1)、(8.6,1.4)。

2) Kmeans++算法的核心思路

Kmeans++算法的核心逻辑在于簇中心的逐次选取，且在此过程中，与当前已确定簇中心距离更远的数据点，被选为新簇中心的概率更高。其具体实现步骤如下：

(1) 从数据样本集合 X 中随机挑选一个数据点，将其设定为首个聚类中心；

(2) 对于数据样本集合 X 中剩余的所有数据点 x，先计算 x 到各已有聚类中心最短的马氏距离 $(,)$，数据点 x,y 之间的距离公式如式(3-3)：

$$(,)=\sqrt{(-)^{-1}(-)} \tag{3-3}$$

其中，仅本式中的 代表多维随机变量的协方差矩阵。

马氏距离用于衡量数据点与特定分布之间的距离，也是评估两个未知样本集相似度的有效工具，其常被用作评定数据间相似度的指标。然而，其独特之处在于能够解决高维线性分布数据中各维度非独立同分布的问题，这得益于其对数据各特性间关联性的充分考虑。

再据此计算 x 成为下一个簇中心的概率 P(x)，最终选择概率最大的数据点是新簇中心 ，概率计算如式(3-4)所示：

$$c_i = argmax \frac{D(x_i)^2}{\sum_{x \in X} D(x)^2} \tag{3-4}$$

(3) 判断当前已确定的聚类中心数量是否满足预设要求，若未满足，则重复执行第二步。

结合图 3.2 中坐标点以及 Canopy 算法计算出的 K 值以及初始质心，分别计算其他点到该点的马氏距离，最终选择 7 号，1 号，9 号点为三个簇心。

3.2.2 结合 Ball-Tree 的改进

Bi-Kmeans 旨在为点集 { $_1$, $_2$,..., } 寻找最优簇划分 C 和簇中心集合 { $_1$, $_2$,..., }，使损失函数（各数据点到所属簇心距离总和）最小。从处理逻辑看，它是对所有数据点反复迭代分类的过程。基于此思路，可进行整体视角转变：未聚类数据集中的数据点，虽不知具体归属簇心，但所属簇心集合是全体簇心集合 的子集。形式化构建 ， ， 三元组 (， ，)， 包含未分配 数据点集合（初始 等于总数据点数）、 是这些数据点归属的簇心 m 集合、M_P是全部簇心集合。初始有 个数据点，未知， 是 k 个簇心的集合，求解C_P时能确定 X 各数据点所属簇心。为简化问题，采用分治法，将初始点集 拆分为两个子集 $_1$ $_2$，生成对应三元组 ($_1$， ，)($_2$， ，)，把原问题分解为子问题。持续划分，直到子问题中仅含一个数据点，但此时求解 只能找到与所有点欧氏距离最小的簇心，限制了分治法效果。因此，需探寻更有效划分方式，降低子问题 求解规模，即剔除不可能成为簇心的点，该方法思路可通过基于 Ball-Tree 逻辑修改后的图 3-5 直观展示。

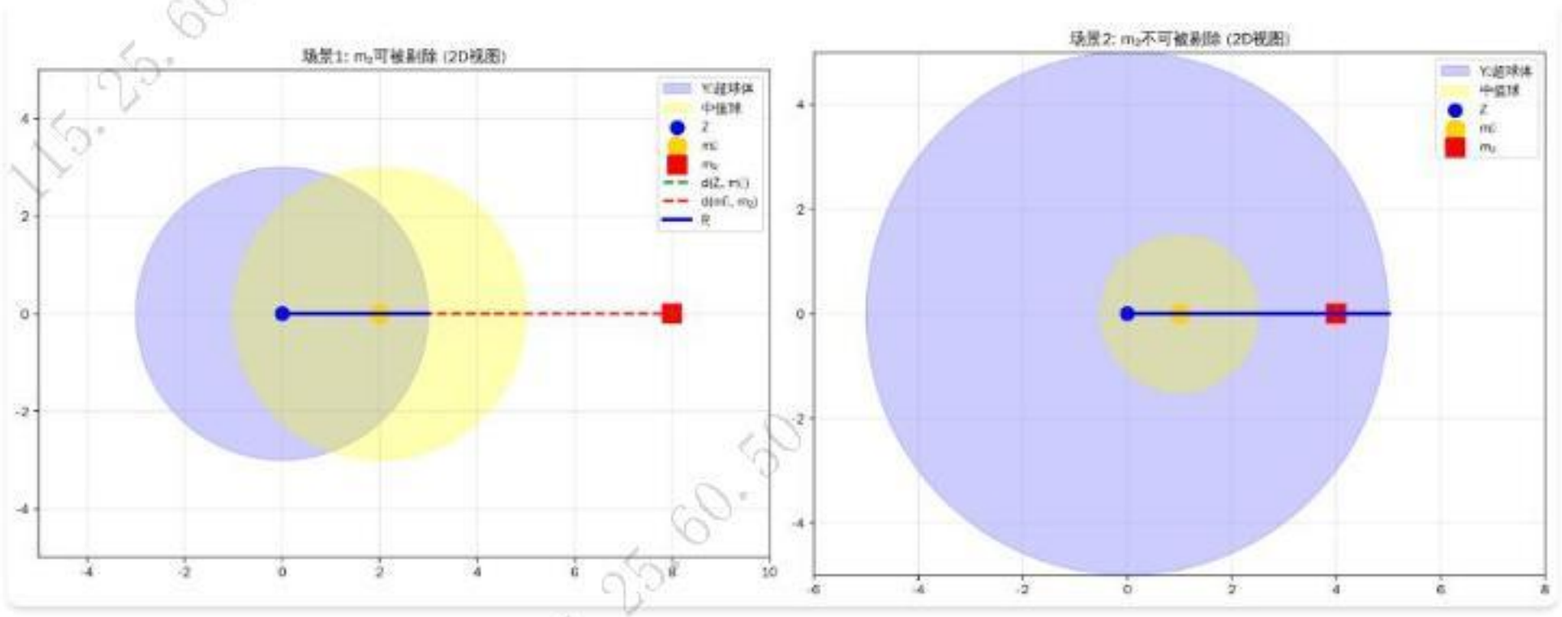


图 3-5 基于 Ball-Tree 改进思想图

Fig.3-5 Idea Diagram Based on Ball-Tree

Ball-Tree 数据结构满足需求，对数据集合构造 Ball-Tree 可实现数据点空间划分，其每个节点对应超球体，包裹子节点数据点，能筛选出某超球体区域内不可能是数据点簇心的候选[64]。问题分解后，针对子问题 ，先计算超球体区域球心 Z 及其半径 R（到区域内最远点距离），再对应 数据集找出离球心 Z 最近的簇心 $_0$。接着考量其他可选簇心 ，若Y_i所在超球体与簇心 构成的“排斥球”无交集 $_0$，可判定 该簇心不是 数据点簇心。

为简化判断，以可选簇心 $_2$为例，计算 $_0$与 $_2$当前簇心距离 $(\ _0,\ _2)$，构建 $_0(\ _0,\ _2)/2$“中值球”，球内点到 $_0$当前簇心距离小于到 $_2$可选簇心距离，球外相反。 因数据集在以 Z 当前簇心为球心、R 该距离为半径的超球体内，若 所在球体与 $_2$“排斥区域”无交集， 数据集中所有点到 $_2$当前簇心距离大于到 $_0$可选簇心距离。具体判断方式为：计算Y_i所在球体球心 Z 到当前簇心m_0距离 $(\ ,\ _0)$，若小于中值球半径 $(\ ,\ _0)+\ \leq\ (\ ,\ _2)/2$，$_0\ _2$ 可剔除可选簇心 $_2$；若大于 $(\ ,\ _0)+\ >\ (\ _0,\ _2)/2$ ，需保留 $_2$验证；若两者情况都不满足，说明 有交集，需细化判断。

通过簇心过滤获取新簇心集合 后，继续 递归划分超球体并迭代计算子问题 ，直至仅剩一个中心 时停止划分，此时 的簇心 即为最终结果。在 Bi-Kmeans 算法的每次迭代中，寻找数据点最近的簇中心是核心步骤。结合 Ball-Tree 优化后，能够高效地将数据空间划分为更小的超球体区域，在查找最近簇中心或执行点查询时无需遍历整个数据集，从而大幅减少计算量，显著提升聚类任务的效率与性能，尤其在处理大规模数据集和高维数据空间时表现出明显优势。此外，Ball-Tree 通过递归生成嵌套超球体来划分高维数据空间，缓解“维度诅咒”的影响，缩小搜索范围并减少距离计算次数。这种结合方式提升了聚类算法的运行效率，节省了计算资源，使算法具备扩展至更大规模数据集的能力。同时，减少距离计算次数有助于增强聚类结果的稳定性与准确性，经 Ball-Tree 加速的 Bi-K-means 算法能够在保证聚类质量的同时提升整体性能。

3.2.3 改进后的算法流程

1) 初始化阶段：先利用 Canopy 算法确定簇数量 K 及簇中心候选集合，从中选一个数据点作为首个簇中心，再通过 Kmeans++算法选择剩余初始簇中心，使簇中心保持较远的距离，提升簇质量和算法收敛效率。

2) Ball-Tree 构建：首先，基于全部数据点构建数据 Ball-Tree。构建过程中，从包含所有数据的根超球体出发，采用“最远点对分裂法”递归生成子超球体：在父超球体内，先找到距离父球心最远的点 P，再确定父球体内距离 P 点最远的点 Q；随后，将父球内的所有数据点分配到距离更近 PQ 的子区域；接着，对两个子区域分别计算新的子球心和子球半径；重复上述分裂过程，直至子球内的数据点数量小于预设阈值，最终生成叶子节点。这棵树用于后续快速定位数据点的邻近区域，为簇分配提供高效的空间搜索支持。其次，针对第一步确定的簇心集合，构建相应的 Ball-Tree，将簇

心组织在嵌套的超球中，以便在后续的二分聚类过程中快速筛选候选簇心。

3) 簇分配操作：对于待分配的簇，首先从已选定的簇心集合中依次选取一个簇心点。接着，利用簇心 Ball-Tree 的“球心－半径”剪枝特性，找出与当前所选簇心距离最远的第二个簇心，从而得到每个簇的候选最优簇心组合。基于这些组合，对每个簇中心执行数据点的最近邻搜索（在数据 Ball 树中进行）：从数据 Ball-Tree 的根节点开始，计算目标簇心到当前节点球心的距离　　，并结合当前节点的球半径 r，判断子节点是否可能包含最近邻点（若“目标簇心到当前节点球心的距离　　－ ”大于“目标簇心到其他子球心的距离+对应子球半径”，则该子球可直接剪枝，无需遍历）。算法沿着最可能包含最近邻的分支向下遍历，大幅减少需进行距离比较的数据点数量。记录每次分配后的聚类误差平方和（SSE），并选取所有分配结果中 SSE 最小的簇心组合，作为本次簇分配的最终结果。

4) 簇中心更新：若簇中心发生变动，则基于数据 Ball-Tree 结构，重新计算该簇内所有数据点与新簇中心之间的距离。

5) 迭代优化过程：重复执行 3，4 步骤，并根据数据分布或簇心的变化，对数据 Ball-Tree 和簇心 Ball-Tree 进行局部更新或重建，直至满足预定义的停止条件。在每次迭代中，借助 Ball-Tree 的层次化超球结构引导簇分配：利用“球心距离+球半径”的剪枝逻辑，高效筛选每个数据点的最近簇中心，避免不必要的全局距离计算，从而降低整体计算量，加速聚类进程。

根据上述描述，改进后的算法流程如图 3-6 所示：

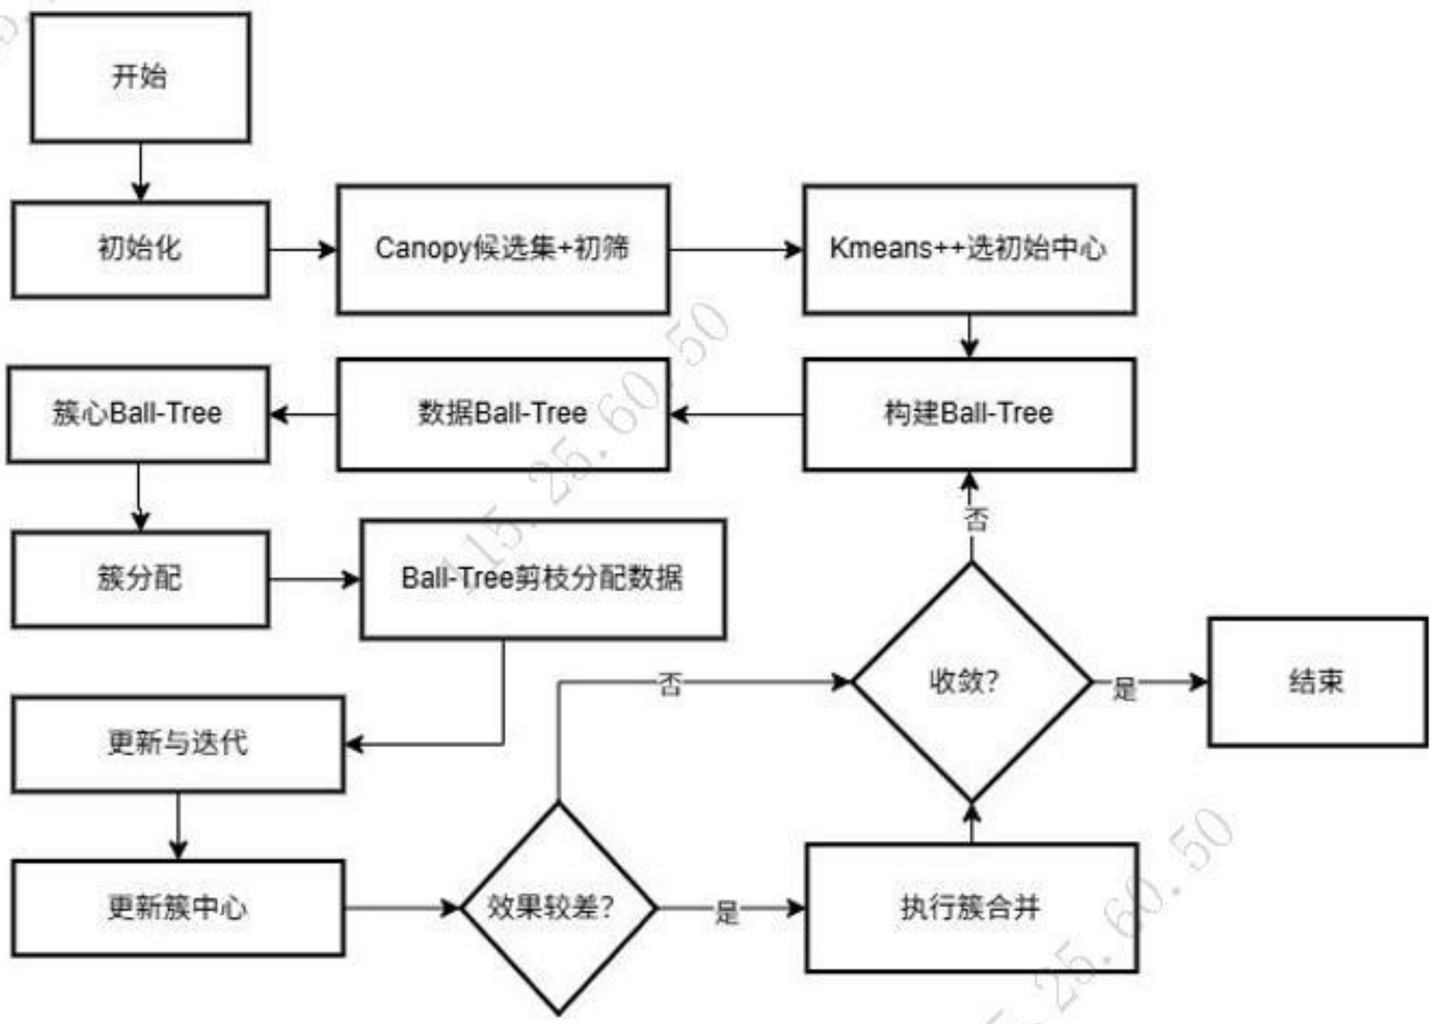


图 3-6 改进后算法流程图

Fig.3-6 Improved Algorithm Flowchart

3.3 优化聚类算法的复杂度分析

本章节旨在结合 3.2.3 章节中的算法流程，从数据规模 N、簇数 K、维度 d、迭代次数 T、Ball 树高度 h 等多个维度，详细拆解算法的复杂度。

1) Canopy 算法：通过“质心－半径”迭代筛选簇心候选复杂度为（ ）。

2) 数据 Ball 树：基于“最远点对分裂法”递归构建超球体层次结构。每次分裂时，需在父球内寻找“最远点对”（ ），此过程涉及次距离计算。随后，将数据点分配至子球（ ），同样依据此距离进行比较。接着，计算子球的球心与半径（ ），具体为子区域点的均值与最远点之间的距离。递归深度为（ ），因此总复杂度为（ ）。

3) 簇分配（单次迭代）。选择簇心组合：在簇心 Ball 树中，通过“球心-半径”剪枝策略寻找“最远簇心对”，每次查询的复杂度（ ）为 Ball 树的层次遍历，共进行 K 次查询，总复杂度（ ）随之确定。数据点-簇心近邻搜索：每个数据点在数据 Ball 树中执行最近邻搜索，利用“球心距离+球半径”剪枝策略，单点查询的复杂度（ ）为维度 d 上的距离计算加上 Ball 树的高度 ，由此得出总体复杂度（ ）。

4) 簇中心更新（单次迭代）：对每个簇计算新质心（取簇内点的均值），需遍历所有数据点求和，复杂度为（ ）。

5) 总体复杂度：设迭代次数为 T 则总复杂度如式(3-5)：

$$
\begin{aligned}
&= (\quad) + (\qquad) + \\
&\quad \text{初始化} \qquad \text{树构建} \\
&\times (\ (\qquad) + (\qquad) + (\quad)) \qquad (3\text{-}5) \\
&\quad \text{单次迭代：选簇心} \\
&\approx (\qquad + \quad + \qquad)
\end{aligned}
$$

复杂度优化的核心逻辑主要体现在表 3-1 以下两个方面：

表 3-1 复杂度优化的核心逻辑表

Tab.3-1 Core Logic Table for Complexity Optimization

优化模块	传统 Bi-Kmeans 复杂度对比	优化效果
Ball-Tree 簇分配	簇分配：（ ）（全量距离计算）	用（ ）替代（ ），高维（ ≥20）下 ，提速 1～2 个数量级
Ball-Tree 剪枝	无剪枝，需遍历全量数据	剪枝率超 80%，减少无效距离计算

综上所述，借助 Ball-Tree 改进 Bi-Kmeans 算法的核心思路在于：利用

Ball-Tree 这一基于超球体嵌套的空间划分数据结构，有效加速查找环节中的距离计算操作，尤其在处理高维数据时，这一优势更为显著。在数据预处理完成后，Ball-Tree 能够大幅降低聚类过程中“数据点与簇心距离计算”的时间复杂度—即通过构建多层嵌套的超球体层次结构，无需遍历全部数据即可迅速筛选出可能与簇心邻近的数据点，从而可以显著减少无效的距离计算开销。

3.4 优化算法的聚类效果分析

为全面验证优化算法在不同业务场景下的有效性，本实验构建典型教育 Web 日志数据集。该数据集涵盖真实业务关键行为特征，经脱敏与标准化处理，确保数据可用性与实验客观性。所使用的教育日志数据集源自阿里云天池实验室的公开在线教育数据集，包含平台课程、学习记录等 9 张数据表，约 1200 万条数据。数据表格内容如表 3-2：

表 3-2 教育日志数据集的数据表格

Tab.3-2 Data Table of the Educational Log Data set

号序	表名	数据量	说明
1	course_chapter	不少于 310000	课程章节表，包含课程 ID 和章节内容等信息
2	course_task	不少于 250000	课程任务表，包含课程 ID 和课程任务等信息
3	classroom_member	不少于 110000	班级成员表，包含班级 ID 和用户 ID 等信息
4	classroom_courses	不少于 9000	班级课程表，包含班级 ID 和课程 ID 等信息
5	log	不少于 1000000	日志表，包括日志操作人 ID 和登录日志等信息
6	user_learn_statistics_total	不少于 140000	用户学习统计表，包含用户 ID 和学习相关统计等信息
7	activity_learn_log	不少于 1000000	学习日志表，包括用户 ID 和学习日志等信息
8	testpaper	不少于 12000	试卷信息表，包括试卷名称和创建试卷等信息
9	testpaper_result	不少于 340000	试卷结果表，包括试卷名称、用户 ID 和试卷分数等信息

本实验综合运用学习日志表和试卷结果表，开展聚类分析，重点关注学生在在线教育平台的学习行为。

为精准展示两种算法在聚类过程中对极端情况的回避能力，实验对比

分析了传统算法与改进型算法，针对数据集进行了 50 次（Frequency/次）独立的聚类运算。下图 3-7 和 3-8 具体展现了这两种聚类算法在运算时长和聚类结果误差平方和（SSE）方面的性能情况。

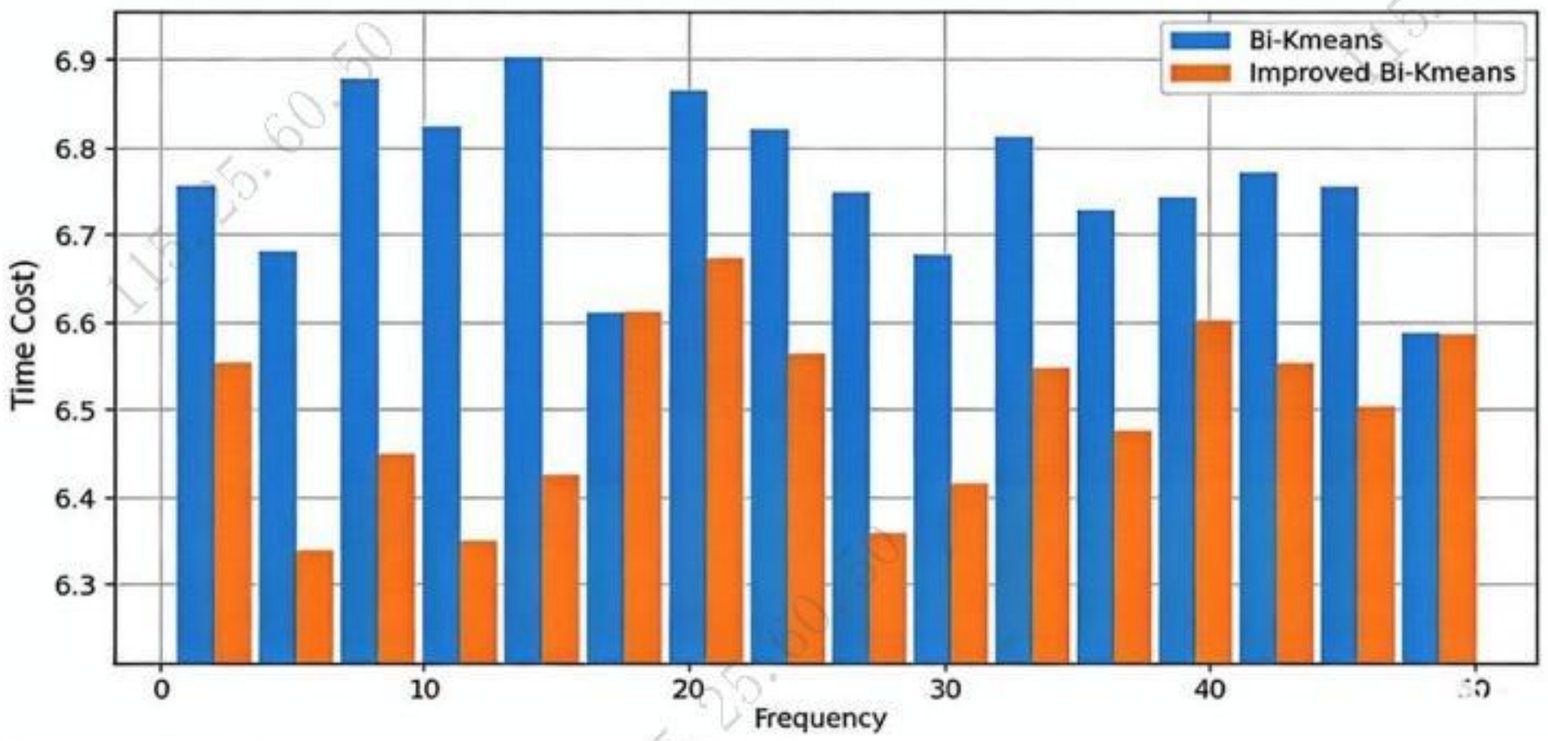


图 3-7 算法时间消耗结果对比图

Fig.3-7 Algorithm Time Consumption Result Comparison Chart

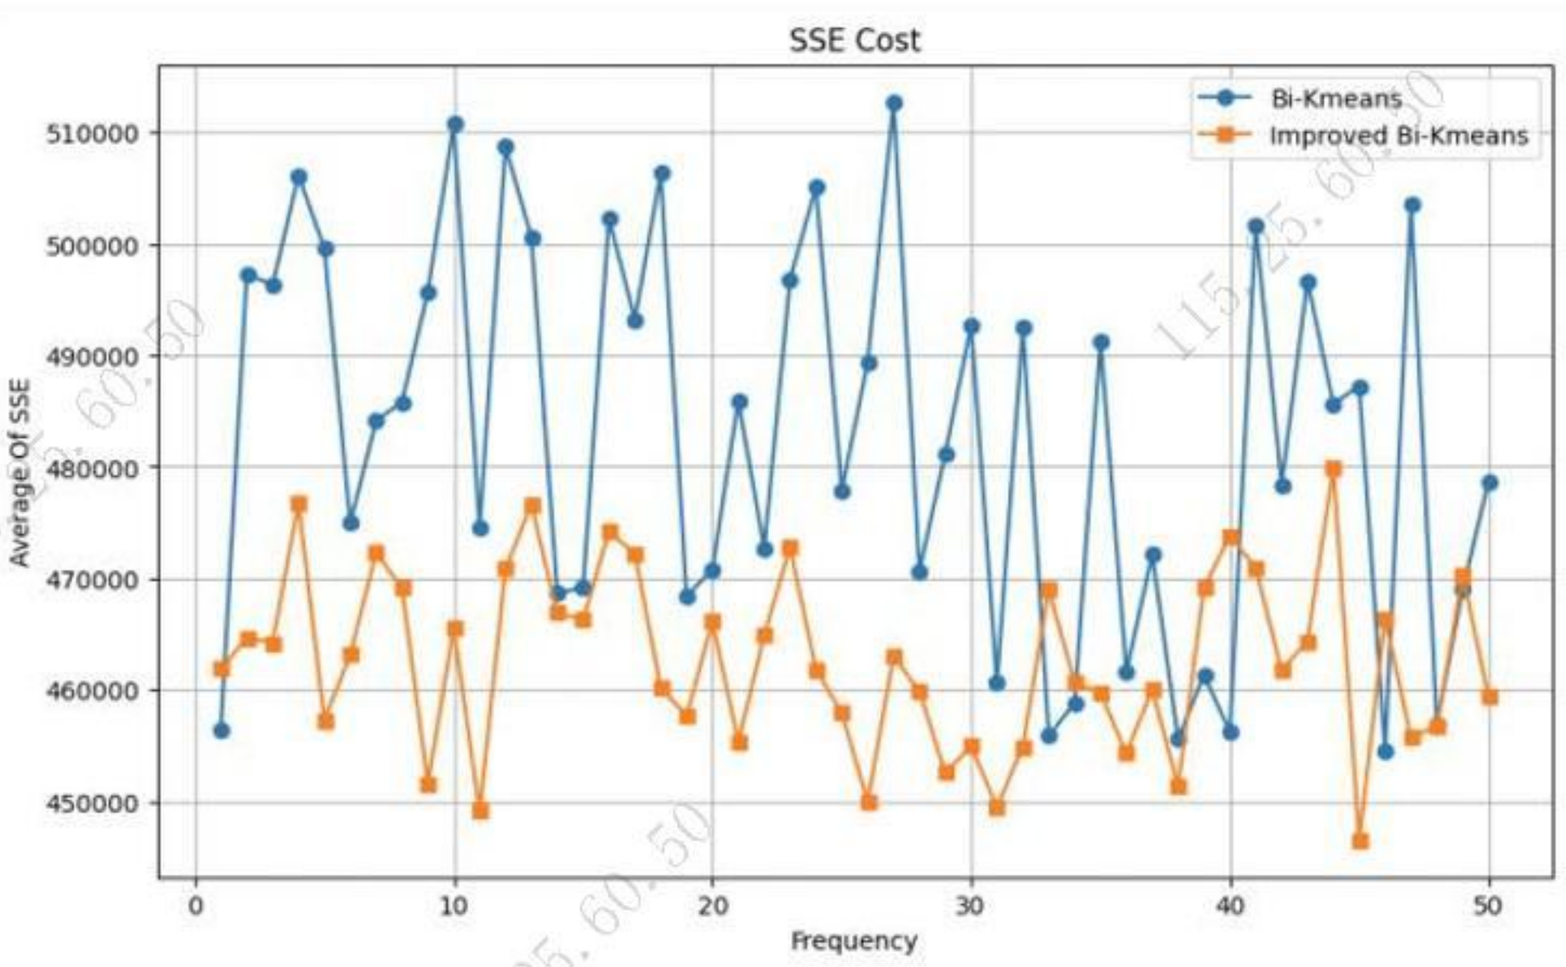


图 3-8 算法 SSE 表现对比图

Fig.3-8 Algorithm SSE Performance Comparison Chart

基于上述实验数据的对比分析，可得出如下结论：在运行时间方面，改进后的算法时间消耗显著降低，这与前文对两种算法时间复杂度的推断一致——即当数据量达到特定条件时，优化后算法的复杂度低于原始算法。进一步细化时间消耗数据后发现，改进型 Bi-Kmeans 算法的平均计算执行时间较原算法减少了约 3.2%。从聚类效果评价指标误差平方和（SSE）来看，结合图示结果可知，改进后算法相较于原 Bi-Kmeans 算法，在聚类所

得的 SSE 上呈现一定程度的下降，同时聚类结果的稳定性有所增强。通过对 SSE 结果的深入剖析，以控制变量实验为基础，在统一数据集、硬件环境及算法参数的前提下，通过 50 次独立聚类排除传统 Bi-KMeans 初始簇心随机带来的误差，分别获取传统与改进算法的两组 SSE 数据，经计算两组数据的平均 SSE 与标准差并结合 t 检验验证差异显著性后，以传统算法平均 SSE 为基准，通过（传统算法平均 SSE-改进算法平均 SSE）/传统算法平均SSE×100%的方式，最终得出改进后算法SSE优化效果约为5.1%的结论，该过程通过多次重复与统计分析确保了结果的可靠性。

4 系统分析与设计

本章以在线教育系统的系统分析与设计为核心，先聚焦数据采集模块，针对 MySQL 业务数据与前端埋点日志数据的不同特性，分别阐述对应导入 HDFS 的技术方案，再展开数据仓库的五层架构设计及完整构建流程，最后提出三级推荐模型，逐步搭建系统技术实现框架。

4.1 数据采集模块

在本系统的数据采集模块中，核心聚焦于两类主要数据向 HDFS 的批量导入需求：其一是来自 MySQL 数据库存储的结构化业务数据，其二是由前端埋点行为自动生成的半结构化或非结构化日志数据。以下将结合系统架构图 4-1，分别从数据来源、传输机制与处理流程等维度，对这两类数据的同步逻辑与实现方式展开详细阐述。

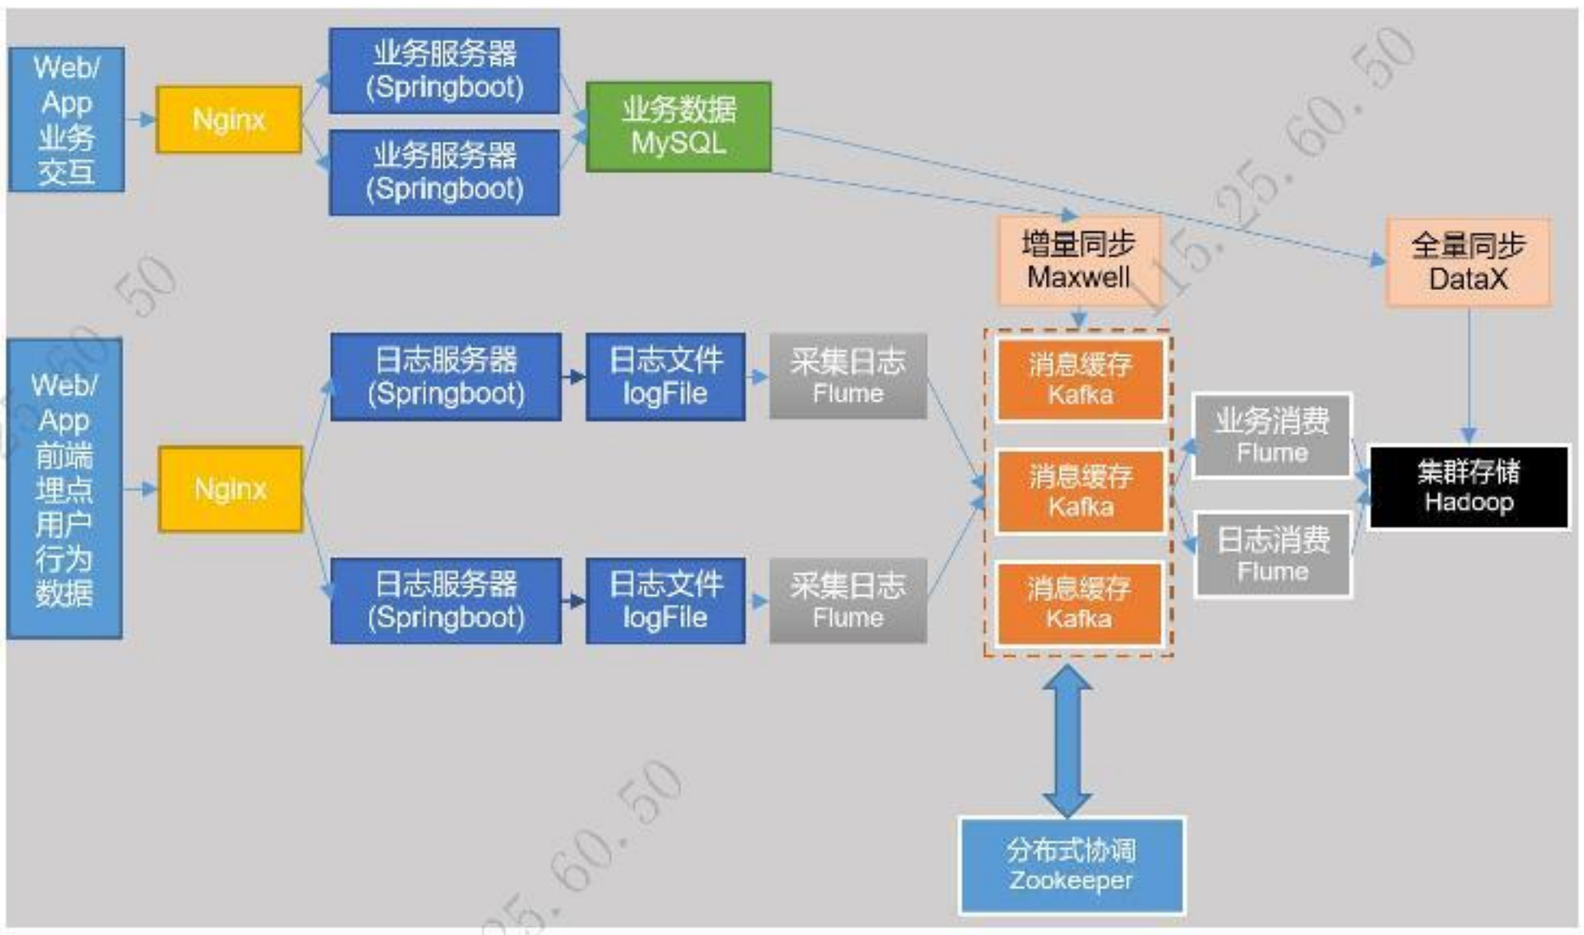


图 4-1 系统架构图

Fig.4-1 System Architecture Diagram

针对 MySQL 业务数据向 HDFS 的迁移，我们选用 DataX 和 Maxwell 框架来实现实时同步与增量同步；对于前端埋点产生的日志数据导入 HDFS，我们采用 Flume 和 Kafka 框架构建“两层 Flume+Kafka 集群”的架构[65]。第一层 Flume 部署于日志服务器端，负责多源日志实时采集与故障断点续传，第二层 Flume 将数据传输至 HDFS 并通过文件合并与数据压缩优化存储传输性能；两层 Flume 间引入 Kafka 集群作为缓冲区，凭借其高吞吐量、高并发特性应对数据流量波动，保障数据采集流程的稳定性与连续性。

4.2 数据仓库设计

4.2.1 数据仓库分层设计

在大数据处理体系中，HDFS 不支持数据随意修改。数据计算遵循“增量迭代”逻辑，在原始数据上完成计算后，新数据导入数仓下一分层，原始数据保留。

在在线教育系统场景，海量异构数据需系统化组织。本系统数据仓库采用五层架构，通过分层建模和主题、维度聚合处理，实现数据从原始存储到业务应用的有序流转，为数据分析与决策提供数据基础[66]。其架构设计如图 4-2：

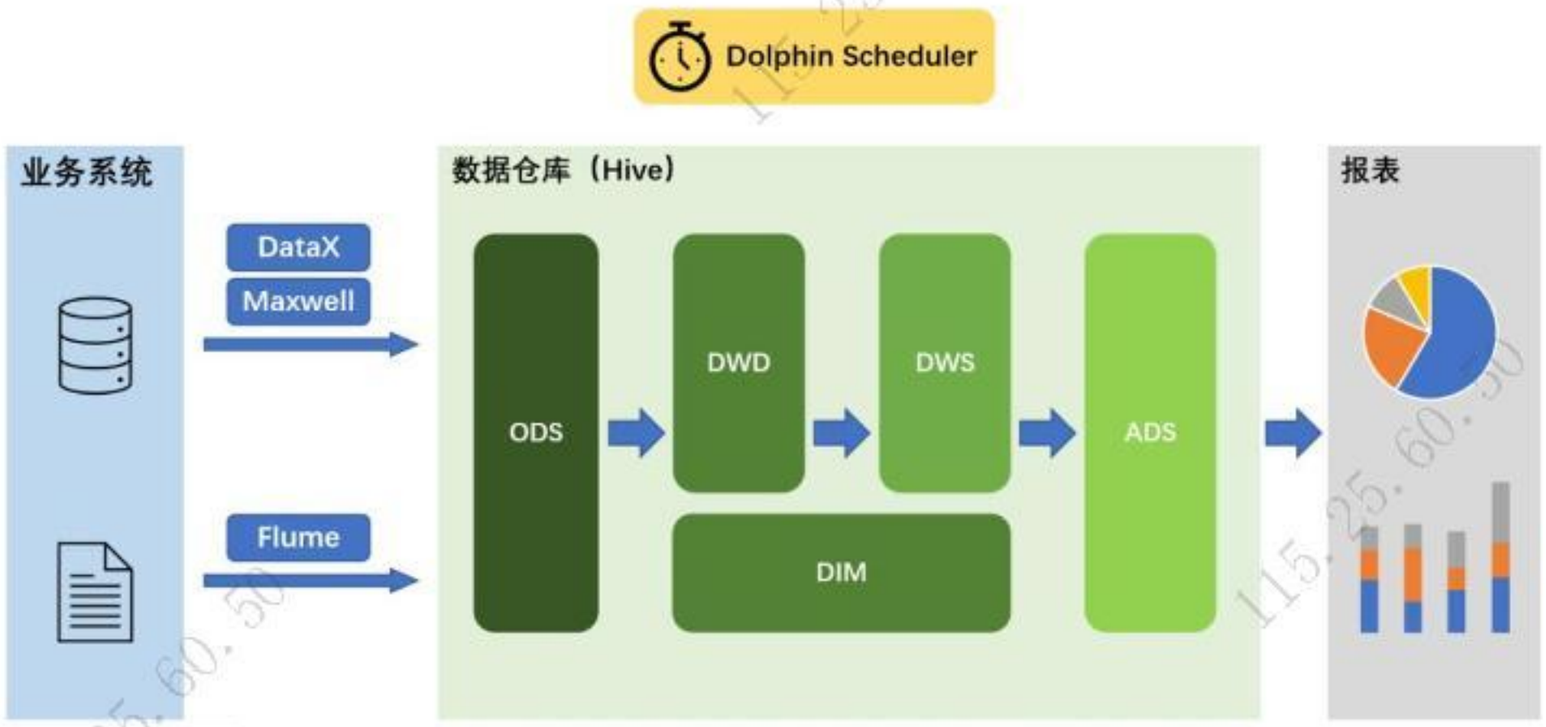


图 4-2 数据仓库五层架构设计图

Fig.4-2 Five-Layer Architecture Design Diagram of Data Warehouse

1) ODS（Operational Data Store）层：原始数据层。该层对接在线教育业务源系统，原样存储数据，保持与源系统结构一致，不做业务逻辑处理，为后续数据加工提供原始数据。

2) DWD（Data Warehouse Detail）层：数据明细层。该层对原始数据进行清洗，去掉 NULL 值和异常值，统一数据格式，将原始数据转化为结构化事实记录，是挖掘业务细节数据价值的关键层级。

3) DIM（Dimension）层：数据维度层。该层保存用户、课程、时间等一致性维度信息，统一业务分析口径，保障跨主题、跨业务线数据分析的准确性和一致性。

4) DWS（Data Warehouse Summary）层：汇总数据层。它围绕核心分析方向，对 DWD 的事实数据进行汇总加工，构建公共维度汇总表，减少重复计算，提升数据查询和分析效率。

5) ADS（Application Data Service）层：应用数据服务层。该层汇聚各层加工后的统计指标结果。这些结果对接业务应用场景，实现数据从仓库到业务决策和创新的落地应用。

4.2.2 数据仓库构建流程

图 4-3 是构建数据仓库的完整流程。

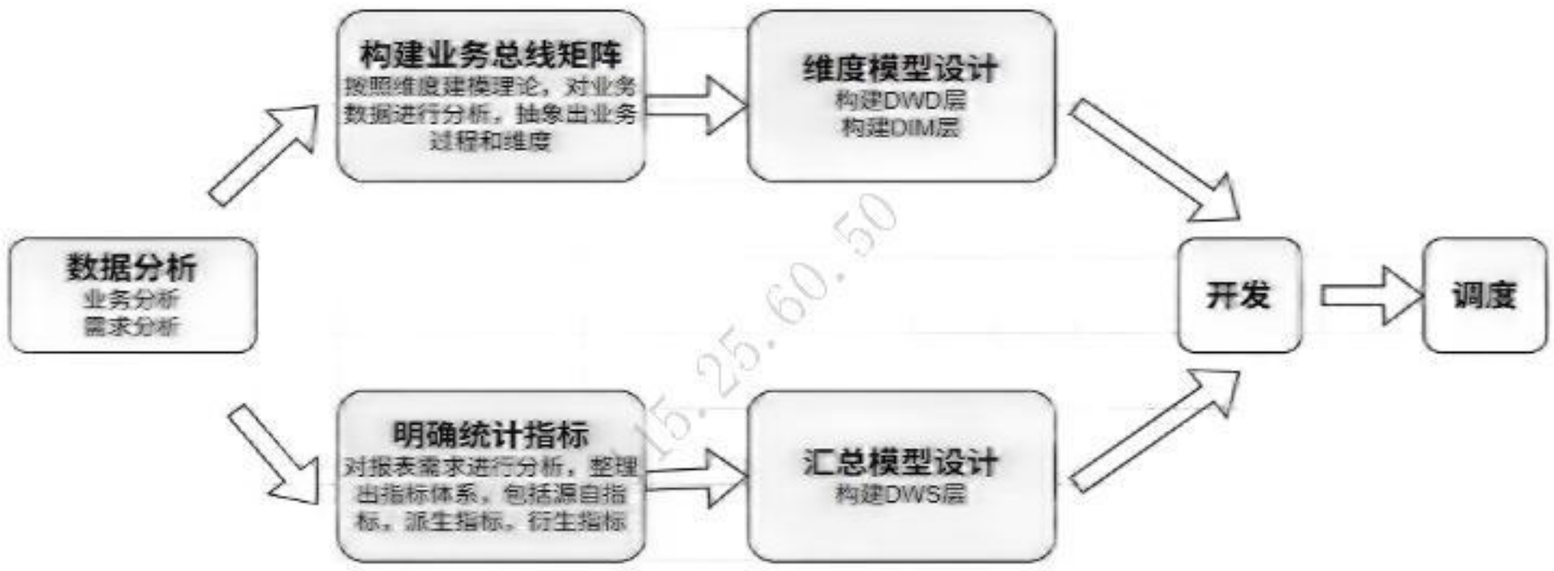


图 4-3 数据仓库构建流程图

Fig.4-3 Data Warehouse Construction Process Flow Diagram

1) 数据分析

数据分析包括业务分析和需求分析。业务分析是为了深入理解业务流程和业务数据，而需求分析，需要明晰需求的业务过程及维度。

2) 构建业务总线矩阵

在维度模型构建中，业务总线矩阵包含所需的全部事实、维度，以及二者间的关联关系。矩阵的行对应各类业务过程，列对应不同维度，行列交叉处可明确业务过程与维度间的具体关联。在维度模型中，单个业务过程对应一张事务型事实表，单个维度则对应一张维度表。按照其设计流程（选择业务过程、声明粒度、确认维度、确认事实）生成的业务总线矩阵如下图 4-4 所示。

数据域	业务过程	粒度	维度									度量
			用户	地区	时间	课程	章节	试卷	问题	视频	来源	设备	
交易域	加购物车	一次加购物车的操作	√		√	√							加购时价格
	下单	一个订单中的一门课程	√	√	√	√					√		下单原始金额/下单最终金额/优惠券减免金额
	支付成功	一个订单中一门课程的支付成功操作	√	√	√	√							支付原始金额/支付最终金额/优惠券减免金额
流量域	页面浏览	一次页面浏览记录	√	√	√						√	√	浏览时长
	动作	一次动作记录	√	√	√	√					√	√	无事实(次数1)
	曝光	一次曝光记录	√	√	√	√					√	√	无事实(次数1)
	启动应用	一次启动记录	√	√	√						√	√	无事实(次数1)
	错误	一次错误记录	√	√	√						√	√	无事实(次数1)
用户域	注册	一次注册操作	√		√								无事实(次数1)
	登录	一次登录操作	√	√	√						√	√	无事实(次数1)
互动域	收藏商品	一次收藏商品操作	√		√	√							无事实(次数1)
	评价	一个用户对课程中一个章节的一次评价	√		√	√	√						无事实(次数1)
	评价	一个用户对一门课程的一次整体评价	√		√	√							无事实(次数1)
考试	考试	一个用户的一次答卷记录	√		√			√					得分/时长
	考试	一个用户的一次答题记录	√		√			√	√				得分
学习	观看视频	一个会话的视频播放记录	√	√	√		√			√	√	√	播放时长

图 4-4 业务总线矩阵图

Fig.4-4 Business Bus Matrix Diagram

3) 明确统计指标

具体工作涵盖需求深度剖析与指标体系构建，核心目标是明确统计指标。指标体系构建的关键价值，在于实现指标定义的标准化。

从上述指标体系中抽取的派生指标部分如下图 4-5 所示：

主题	衍生指标/派生指标	派生指标/被依赖的派生指标	统计周期	统计粒度	原子指标			业务限定
					业务过程	度量值	聚合逻辑	
备注：派生指标可以直接拆解为原子指标+统计周期+统计粒度+业务限定，也可以依赖于别的派生指标。 "衍生指标/派生指标"列，黄色背景标红的单元格为衍生指标，与下一列字体背景色相同的为派生指标								
流量主题	最近 1/7/30 日各来源访客数	最近 1 日各会话页面浏览 *	最近 1 日	会话	页面浏览			
	最近 1/7/30 日各来源会话总数	最近 1 日各会话页面浏览 *						
	最近1/7/30日各来源会话平均浏览页面数	最近 1 日各会话浏览页面数	最近 1 日	会话	页面浏览	1	count()	
	最近1/7/30日各来源会话平均停留时长	最近 1 日各会话停留时长	最近 1 日	会话	页面浏览	during_time	sum()	
	最近1/7/30日各来源跳出率	最近 1 日各会话浏览页面数						
		最近1/7/30日路径分析（页面跳转）	最近 1/7/30 日	source-target	页面浏览	1	count()	
用户主题	最近 1 日流失用户数	用户末次登陆日期	历史至今	用户	用户登陆	login_date	max()	
	最近 1 日回流用户数	用户末次登陆日期						
	最近 1-7 日新增用户留存率	用户末次登陆日期						
		用户注册日期	历史至今	用户	用户注册	register_date		
	最近 1/7/30 日新增用户数	用户注册日期						
	最近 1/7/30 日活跃用户数	用户末次登陆日期						
		最近 1/7/30 日首页浏览人数	最近 1/7/30 日		页面浏览	mid_id	count(distinct)	页面为首页
		最近 1/7/30 日商品详情页浏览人数	最近 1/7/30 日		页面浏览	mid_id	count(distinct)	页面为商品详情页
	最近 1/7/30 日加购人数	最近 1/7/30 日各用户加购课程数	最近 1/7/30 日	用户	用户加购	course_id	count()	
	最近 1/7/30 日下单人数	最近 1/7/30 日各用户下单次数	最近 1/7/30 日	用户	用户下单	order_id	count(distinct)	
	最近 1/7/30 日支付人数	最近 1/7/30 日各用户支付次数	最近 1/7/30 日	用户	用户支付	order_id	count(distinct)	
	最近 1/7/30 日新增下单人数	用户首次下单日期	历史至今	用户	用户下单	order_dt	min()	
	最近 1/7/30 日新增支付人数	用户首次支付日期	历史至今	用户	用户支付	payment_dt	min()	
	最近 1/7/30 日各年龄段下单人数	用户末次下单日期	历史至今	用户	用户下单	order_dt	max()	
课程主题		最近 1/7/30 日各类别下单次数	最近 1/7/30 日	类别	用户下单	order_id	count(distinct)	
		最近 1/7/30 日各类别下单人数	最近 1/7/30 日	类别	用户下单	user_id	count(distinct)	
		最近 1/7/30 日各类别下单金额	最近 1/7/30 日	类别	用户下单	order_amount	sum()	
		最近 1/7/30 日各学科下单次数	最近 1/7/30 日	学科	用户下单	order_id	count(distinct)	
		最近 1/7/30 日各学科下单人数	最近 1/7/30 日	学科	用户下单	user_id	count(distinct)	
		最近 1/7/30 日各学科下单金额	最近 1/7/30 日	学科	用户下单	order_amount	sum()	
		最近 1/7/30 日各课程下单次数	最近 1/7/30 日	课程	用户下单	order_id	count(distinct)	
		最近 1/7/30 日各课程下单人数	最近 1/7/30 日	课程	用户下单	user_id	count(distinct)	
		最近 1/7/30 日各课程下单金额	最近 1/7/30 日	课程	用户下单	order_amount	sum()	
		最近 1/7/30 日各课程用户平均评分	最近 1/7/30 日	课程	用户评价	review_stars	avg()	
		最近 1/7/30 日各课程评价用户数	最近 1/7/30 日	课程	用户评价	user_id	count()	
	最近 1/7/30 日各课程用户好评率	最近 1/7/30 日各课程好评用户数	最近 1/7/30 日	课程	用户评价	user_id	count()	review_stars = 5

图 4-5 部分派生指标图

Fig.4-5 Partial Derived Indicators Diagram

4) 维度模型设计

维度模型的设计参照上述得到的业务总线矩阵如图 4-6。一行数据是一个业务过程以事实表存储在 DWD 层，一列数据表示一个维度以维度表存储在 DIM 层。



数据域	业务过程	维度									
		用户	地区	时间	课程	章节	试卷	问题	视频	来源	设备
交易域	加购物车	√		√	√						
	下单	√		√	√					√	
	支付成功	√		√	√						
流量域	页面浏览	√	√	√						√	√
	动作	√	√	√	√					√	√
	曝光	√	√	√	√					√	√
	启动应用	√	√	√						√	√
	错误	√	√	√						√	√
用户域	注册	√		√							
	登录	√	√	√						√	√
互动域	收藏商品	√		√	√						
	评价	√		√	√	√					
	评价	√		√	√						
考试	考试	√		√			√	√			
	考试										
学习	观看视频	√	√	√					√	√	

图 4-6 维度模型设计过程图

Fig.4-6 Dimensional Model Design Process Diagram

5) 汇总模型设计

汇总模型的设计依据上述整理出的指标体系。

在汇总表中，与派生指标的对应关系表现为：一张汇总表通常涵盖业务过程一致、统计周期一致、统计粒度一致的多个派生指标。

4.3 推荐算法模块

1) 分群过滤

分群过滤方法以学员聚类分群的结果为基础，充分利用同一聚类群体内学员兴趣偏好相似这一特性，有效缩小推荐系统所需处理的候选课程集合的范围。具体来说，针对每个学员所属的聚类簇 c，系统会统计该簇内所有学员的课程交互记录，并从中筛选出交互频率最高的前 30%课程，构成候选推荐课程集合。这一策略避免对整个课程库中的所有课程进行全局计算，从而降低后续协同过滤或其他推荐算法的计算规模与实现复杂度，提高了推荐系统的整体响应速度与运行效率。整体流程见图 4-7 所示。

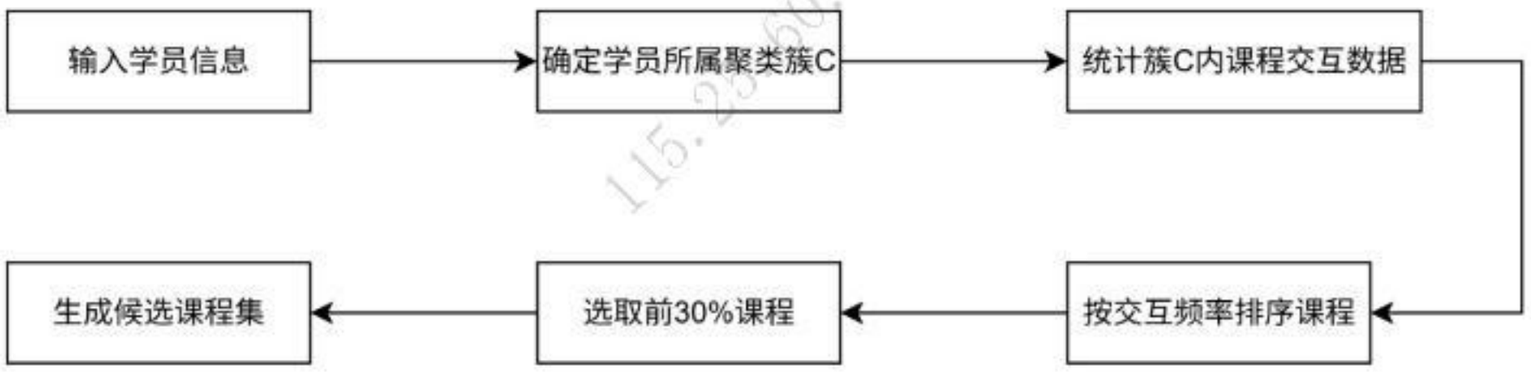


图 4-7 分群过滤流程图

Fig.4-7 Grouping and Filtering Flow Diagram

2) 协同计算

协同计算阶段采用改进的余弦相似度公式[67]，在聚类分群的基础上，计算课程之间的相似性，以找出与学员历史交互课程相似的推荐课程。传统余弦相似度在计算课程相似性时，未考虑学员分群信息，导致计算结果与实际需求存在偏差。改进后的公式聚焦于同一聚类簇内学员的课程交互数据，通过计算课程在该簇内的交互向量夹角余弦值，衡量课程间的相似程度，使推荐结果更贴合学员所在群体的兴趣偏好。改进的余弦相似度公式(4-1)为：

$$(,) = \frac{\quad , \quad ,}{\sqrt{\quad\quad 2 , \sqrt{\quad\quad 2 ,}} \tag{4-1}$$

其中： 为聚类簇 c 的学员集合； , 为学员 对课程 的交互强度；分子 , , 表示课程 与课程 在聚类簇 内的交互强度乘积之和，反映两课程在该群体内的协同交互程度；分母 $\sqrt{\quad\quad 2 , \sqrt{\quad\quad 2 ,}}$ 分别为课程 和课程 在聚类簇 内交互强度的模长，用于对分子进行归一化，确保相似度值在[−1,1]区间，值越接近 1 表示课程越相似。

基于分群过滤得到的候选课程集，按流程图 4-8 生成初步推荐课程列表。

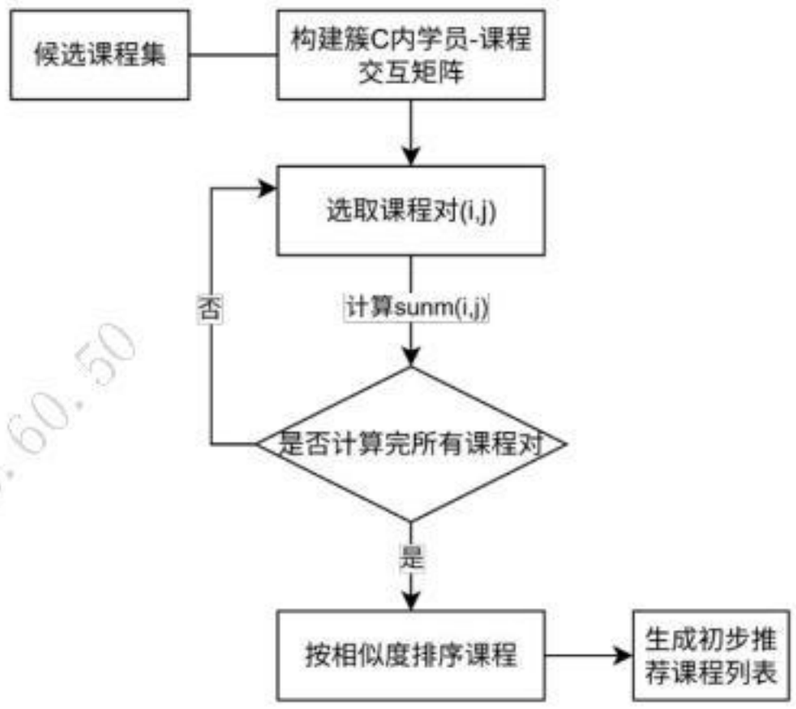


图 4-8 协同计算流程图

Fig.4-8 Collaborative Computing Flow Diagram

3) 内容修正

内容修正阶段通过计算课程标签匹配度，对协同计算得到的初步推荐课程列表进行重新排序，进一步提升推荐课程与学员历史偏好的内容相关性。课程标签包含课程的主题、难度、适用人群等信息，通过 Jaccard 系数度量推荐课程与学员历史交互课程标签的相似程度，确保最终推荐课程的内容相似度≥0.6，避免推荐内容与学员实际需求脱节。

Jaccard 系数计算公式(4-2)为：

$$(,) = \frac{| \cap |}{| |} \tag{4-2}$$

其中： 为学员历史交互课程的标签集合； 为推荐课程的标签集合；| ∩ | 表示两个集合的交集元素个数，即相同标签数量；| |表示对两个集合取并集的元素数量；Jaccard 系数的取值大于等于 0 且小于等于 1，值越靠近 1 则课程标签的重合度越高，内容相似度越高。流程如图 4-9 所示：

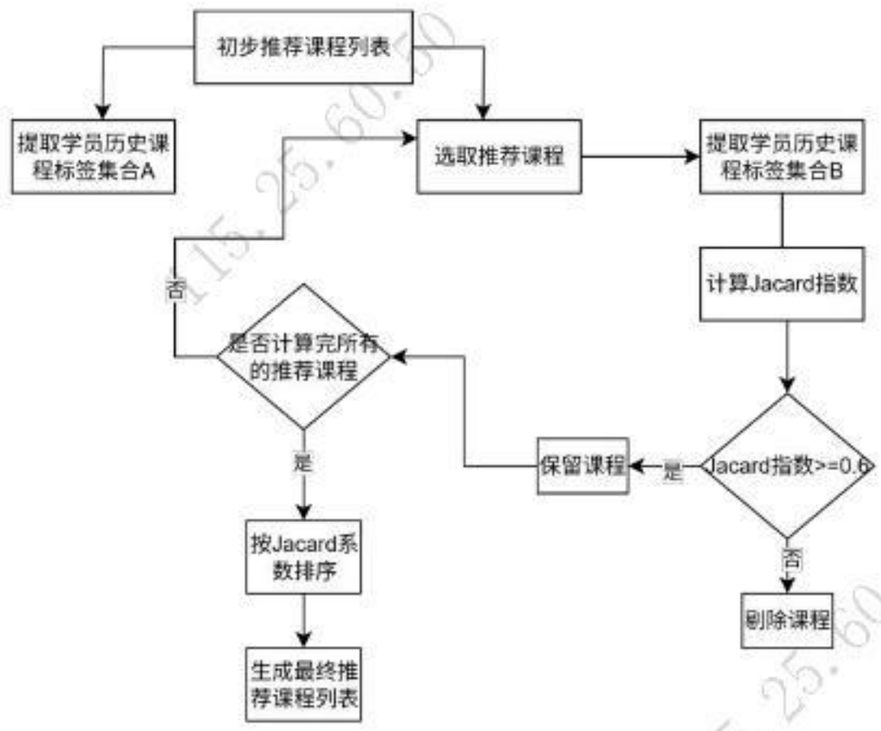


图 4-9 内容修正流程图

Fig.4-9 Content Correction Flow Diagram

4) 冷启动问题

针对推荐系统中普遍存在的冷启动问题，本文采用注册画像粗匹配+分类热门课程的方式来解决。

新用户注册时，首先收集 3-5 个核心标签构建初始粗粒度用户画像；然后基于标签匹配对应课程类别，选取该类别下簇内交互量前 30%的课程；随后补充平台全局交互 TOP10 热门课程，形成“分类精准+全局覆盖”的推荐列表，标签匹配度≥0.5 即可入选；当用户产生首次交互后，自动切换至本论文提出的推荐模型。

该方案无需依赖历史交互数据，复用现有课程分类与热门统计体系，开发成本低、响应快，同时通过注册标签降低推荐盲目性，契合本系统冷启动场景的核心需求。

4.4 本章小结

本章通过三大模块的技术设计，为在线教育系统提供从数据采集、存储处理到个性化推荐的完整解决方案，支撑系统实现数据驱动的智能运营与教学优化。

5 系统详细实现

在全面阐述平台所需的技术选型，并完成对平台需求的分析与系统设计之后，将进入平台具体实现的关键阶段。本章将系统、详细地阐述本系统从技术框架搭建、模块开发、功能实现到系统集成的全过程，并对开发过程中涉及的主要工作、核心方法及关键技术实践进行具体说明。

5.1 数据采集模块实现

5.1.1 数据采集模块

在数据采集流程中，Flume 承担着至关重要的数据采集任务。Flume 由 Source、Channel、Sink 三大核心组件构成。本项目选用 Flume1.9.0 版本 Source 端采用 Taildir。TaildirSource 能够对多个持续追加内容的文件进行监听，其断点续传功能可确保数据的完整性。

关于 Flume 日志采集的具体实现逻辑与流程细节，如图 5-1 所示。

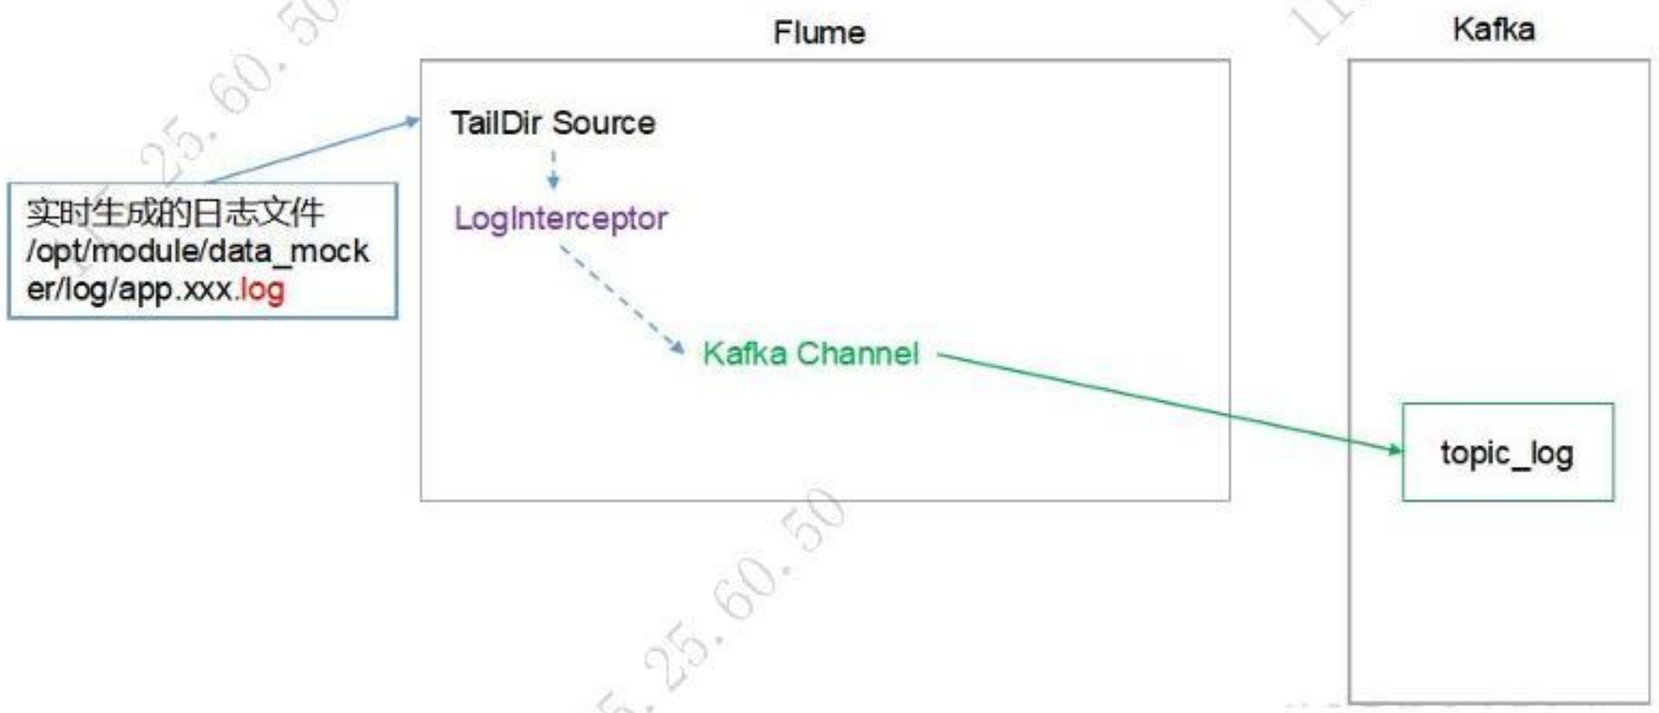


图 5-1 Flume 日志采集逻辑图

Fig.5-1 Flume Log Collection Logic Diagra

在线教育可以通过用户的搜索、点击、加购、付款等操作产生各类业务流程以及数据。而业务数据是数据仓库的重要来源，为了匹配离线数仓的计算周期，故数据同步周期设定为一天。数据同步策略分为全量同步与增量同步。

1) 全量同步：DataX 将全量表数据从 MySQL 数据库直接同步到 HDFS，具体数据流向如图 5-2 所示。

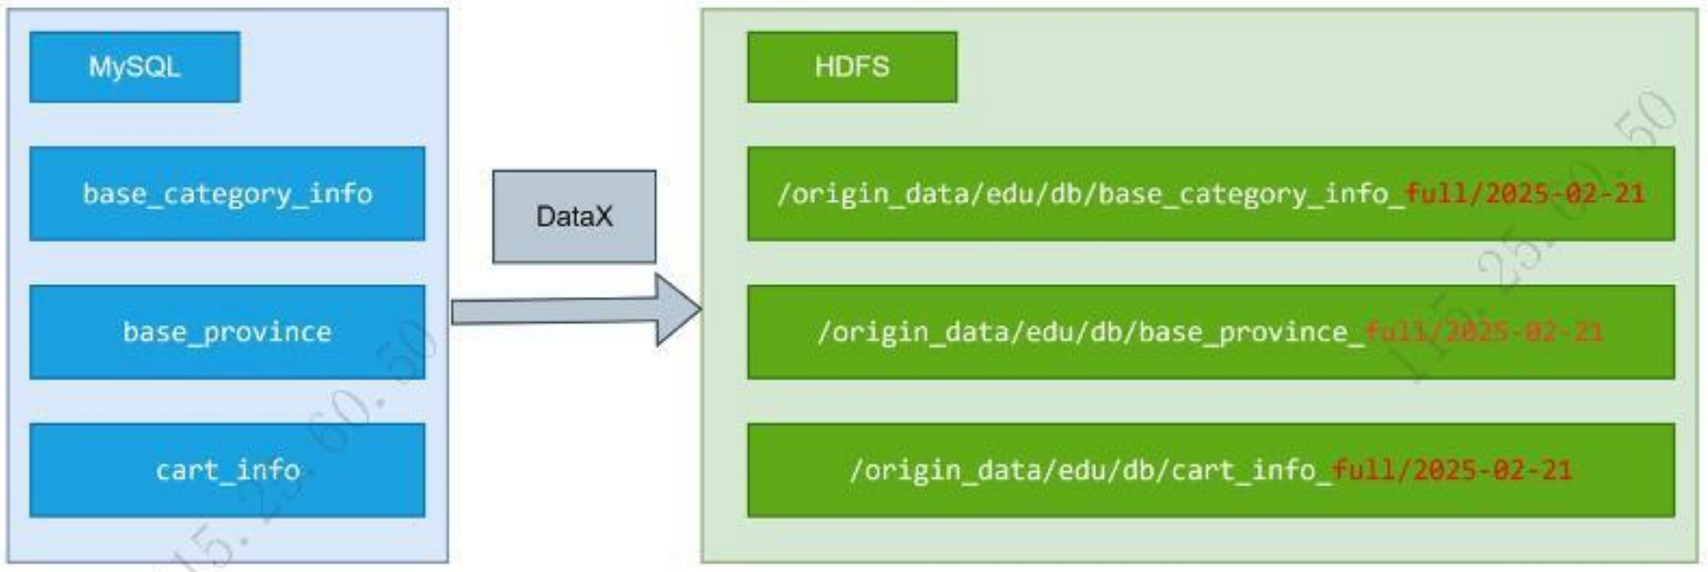


图 5-2 全量表数据流向图

Fig.5-2 Full Data Table Data Flow Diagram

2) 增量数据同步：通过配置 Maxwell，系统会将 MySQL 的 binlog 中的 cart_info、order_info 等共计 11 张表，增量同步至 Kafka。增量表数据流向图如图 5-3。

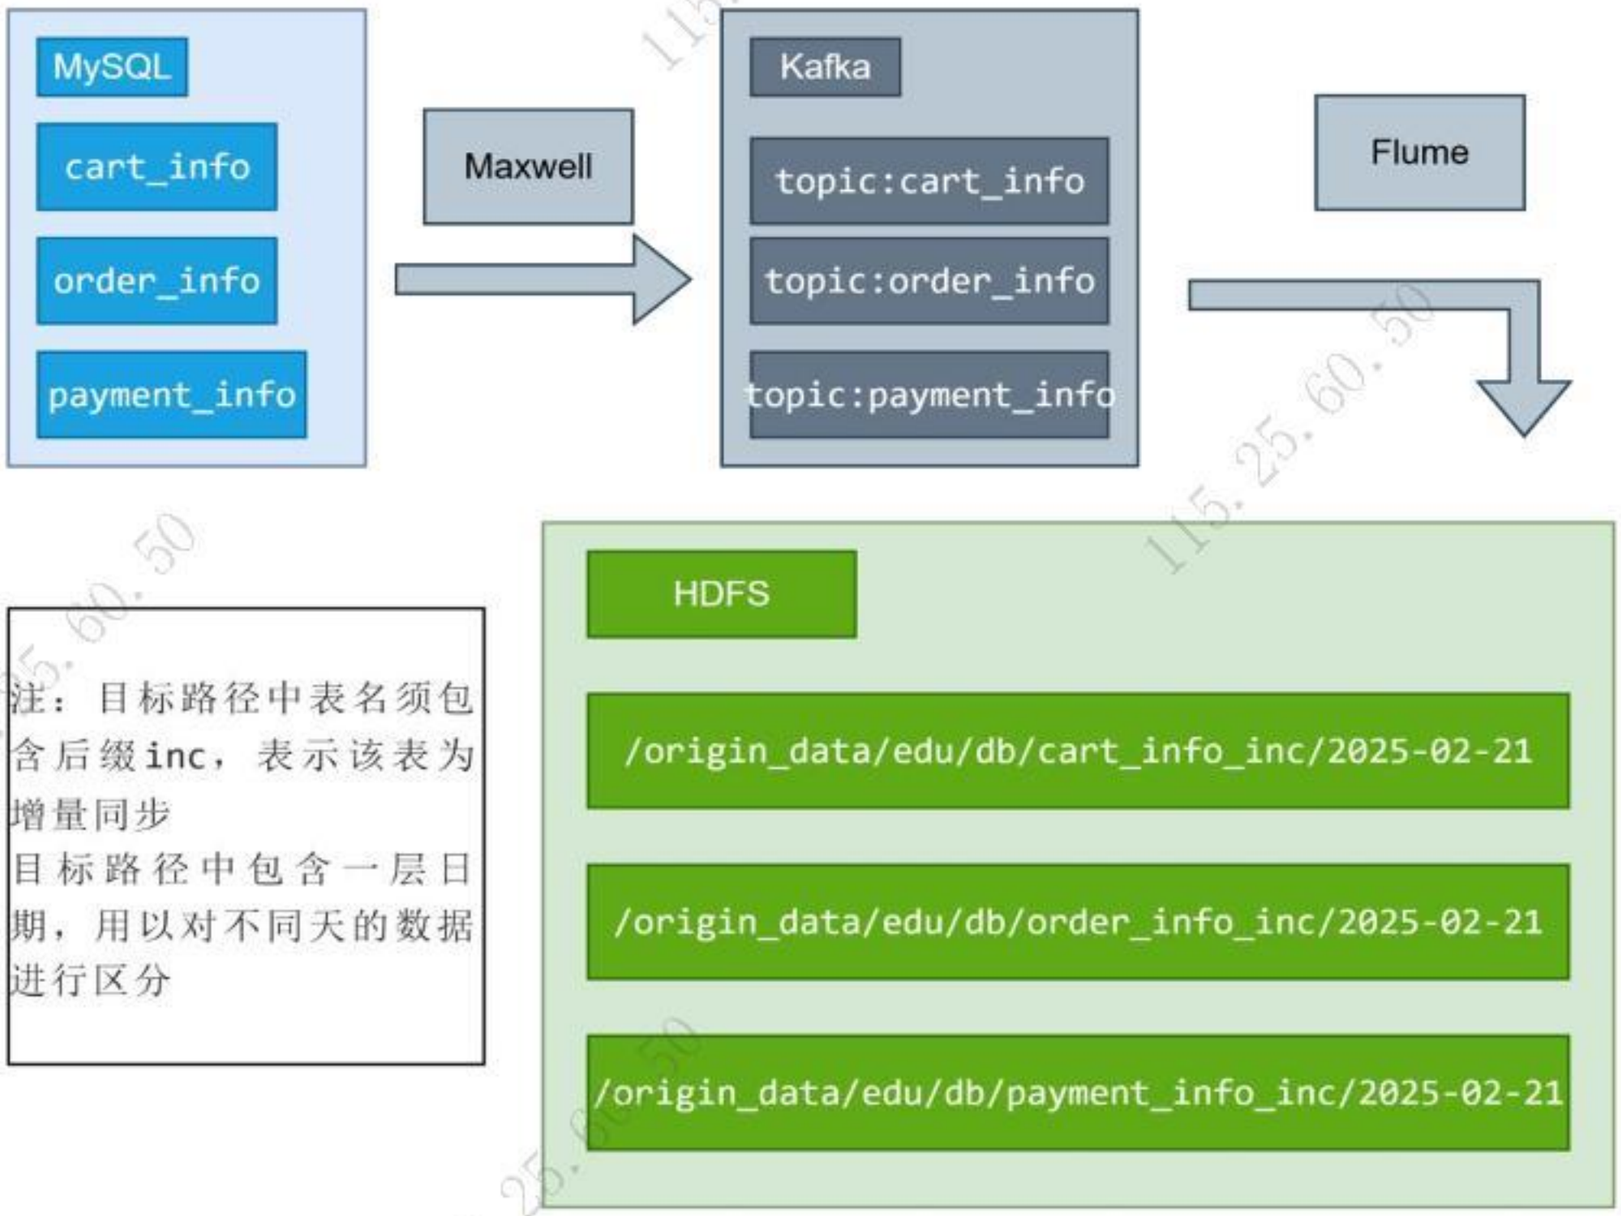


图 5-3 增量表数据流向图

Fig.5-3 Incremental Data Table Data Flow Diagram

5.1.2 数据采集与聚类算法的适配设计与采集频率优化

1) 为适配改进的多策略 KMeans 算法对输入数据的要求，采集阶段新增“特征筛选-数据标准化-时序对齐”三级预处理流程：

特征筛选：采用互信息法筛选与学员分群强相关的核心特征，剔除冗

余字段，最终保留 23 个核心特征，降低算法计算复杂度。

数据标准化：采用 Z-score 标准化处理数值型特征，公式为(5-1)

$$= \frac{-}{} \tag{5-1}$$

其中 为特征均值， 为标准差，解决不同特征尺度差异对马氏距离计算的干扰，确保聚类相似度度量的准确性。

时序对齐：针对教育数据的周期性特征，采用滑动窗口法对齐不同时间段的采集数据，避免时序分布不均导致的聚类偏差。

2) 基于教育数据的时序稀疏性特征，设计动态采集频率策略：

高峰时段（工作日 19:00-22:00、周末 10:00-18:00）：采集频率为 5 分钟/次，确保学员实时行为数据的完整性，支撑推荐模型的时效性；

低峰时段（凌晨 0:00-6:00）：采集频率为 60 分钟/次，降低系统资源消耗；通过动态调整使数据采集的“时效性-资源消耗”达到最优平衡。

5.2 数据仓库模块实现

5.2.1 ODS 层设计实现

ODS 层的工作流程如图 5-4 所示，该图详细展示了数据采集、处理及存储的完整过程，为后续的数据处理与业务决策提供了可靠支持。

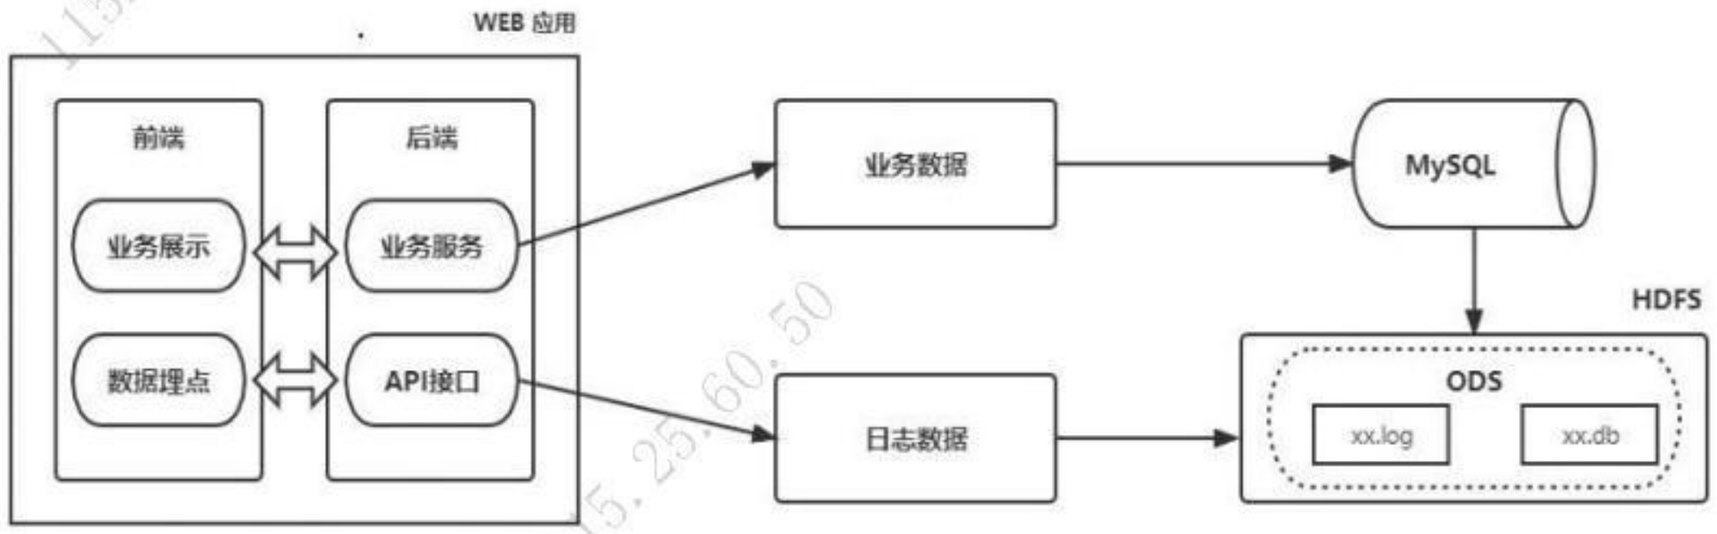


图 5-4 ODS 层工作流程图

Fig.5-4 ODS Layer Work Process Flow Diagram

1) 为使标签化特征有效提升聚类算法的收敛速度，聚类算法对原始特征的需求，保留学员行为的明细数据，并通过“行为标签化”处理，为算法提供结构化的特征输入。

2) 针对在线教育业务所产生的多维度日志数据，ODS 层设计了 ods_log_inc 外部表，并借助 Hive 的 LOAD DATA 语句，把特定日期的原始

日志数据从 HDFS 源路径同步到 ods_log_inc 表对应的分区，达成单日数据的接入。针对在线教育平台业务数据，全量表存储业务实体完整快照，按日分区保留历史版本，支持业务回溯与全量初始化；增量表捕获业务数据变更事件，通过嵌套结构记录数据变动前后状态。ODS 层的数据在 HDFS 上的目录结构如图 5-5。

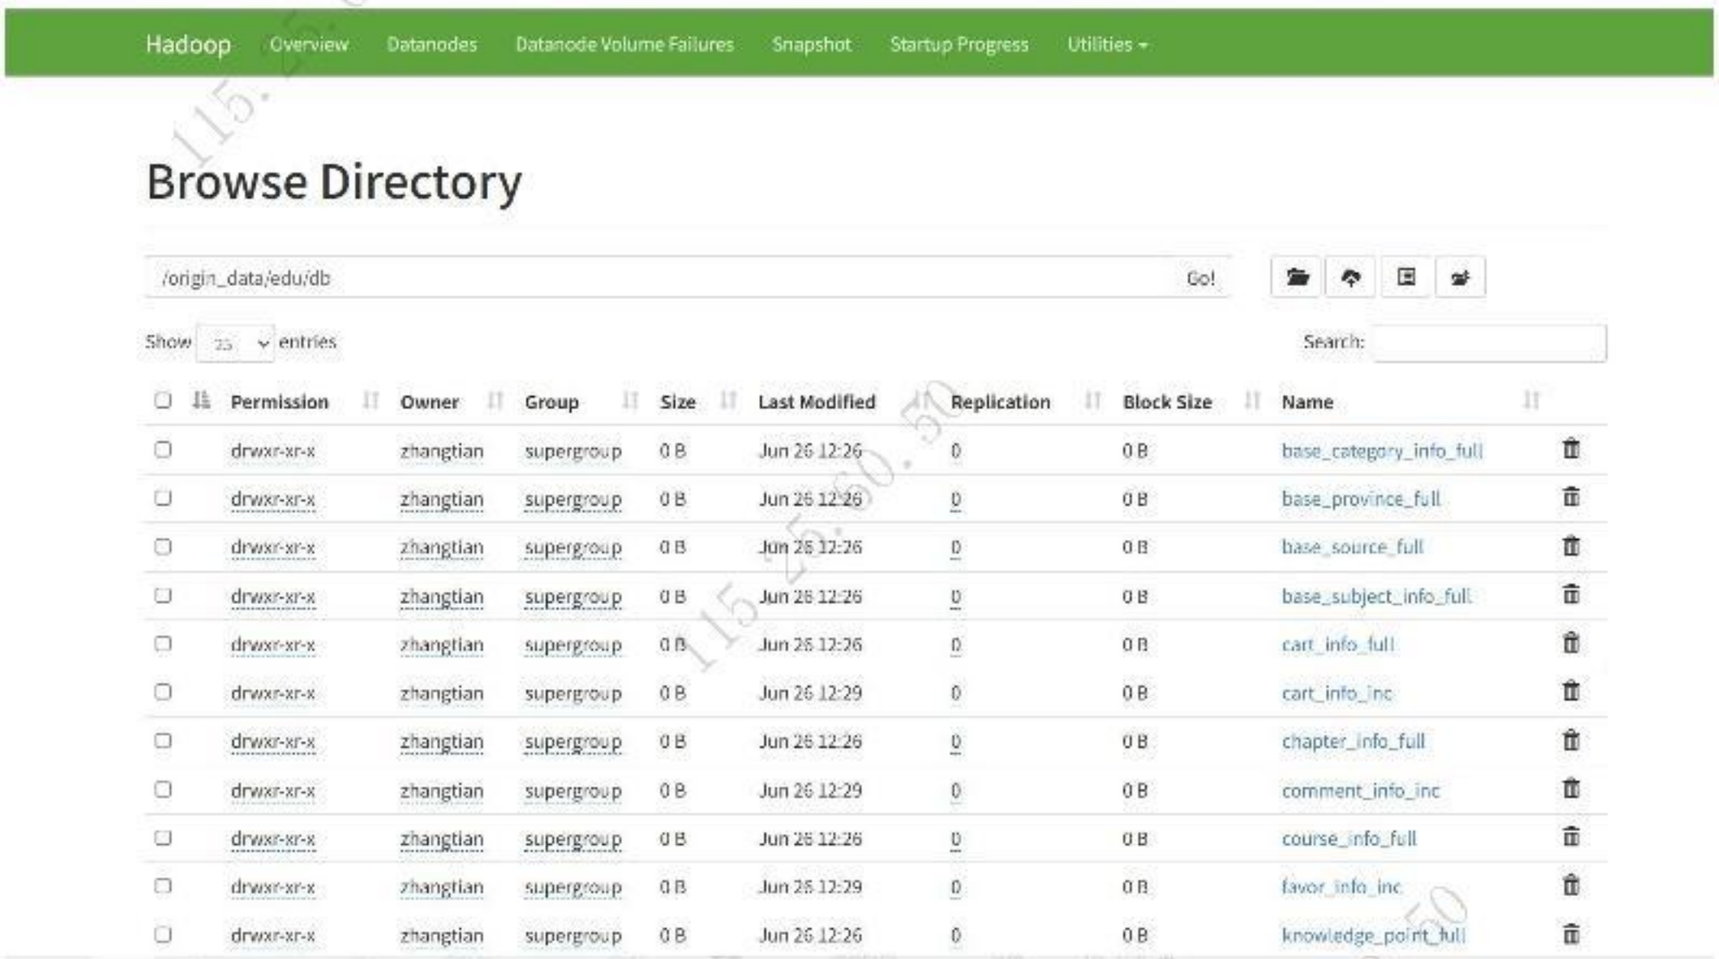


图 5-5 ODS 层数据仓库详细实现

Fig.5-5 Detailed Implementation of the ODS Layer

5.2.2 DWD 层设计实现

数据仓库明细层在整个数据体系架构中扮演着基础而关键的角色。为保障算法输入数据质量，新增基于统计理论的数据清洗逻辑。首先采用多重插补法对缺失的行为数据进行填充，这种方法能够有效保持原始数据集的整体分布特征，避免因简单删除或均值填充导致的信息偏差。其次，针对异常数据的识别问题，清洗流程引入基于正态分布假设的 3σ 准则，自动检测并标注偏离正常范围的行为数据点。与此同时，算法会根据教育场景的业务特性，对识别出的异常数据进行有针对性的修正或合理剔除，从而最大程度减少异常值对后续聚类中心计算过程的干扰。通过这一系列步骤，系统能够将异常数据的最终剔除比例严格控制在 3%以内，既避免过度清洗造成有效信息损失，也显著提升了数据聚类结果的合理性与可解释性。

根据业务总线矩阵，将 ODS 层的原始数据通过维度建模划分为 6 个事实域和 9 个维度表，如图 5-6，每个事实域能够按照业务过程的粒度进一步细分。

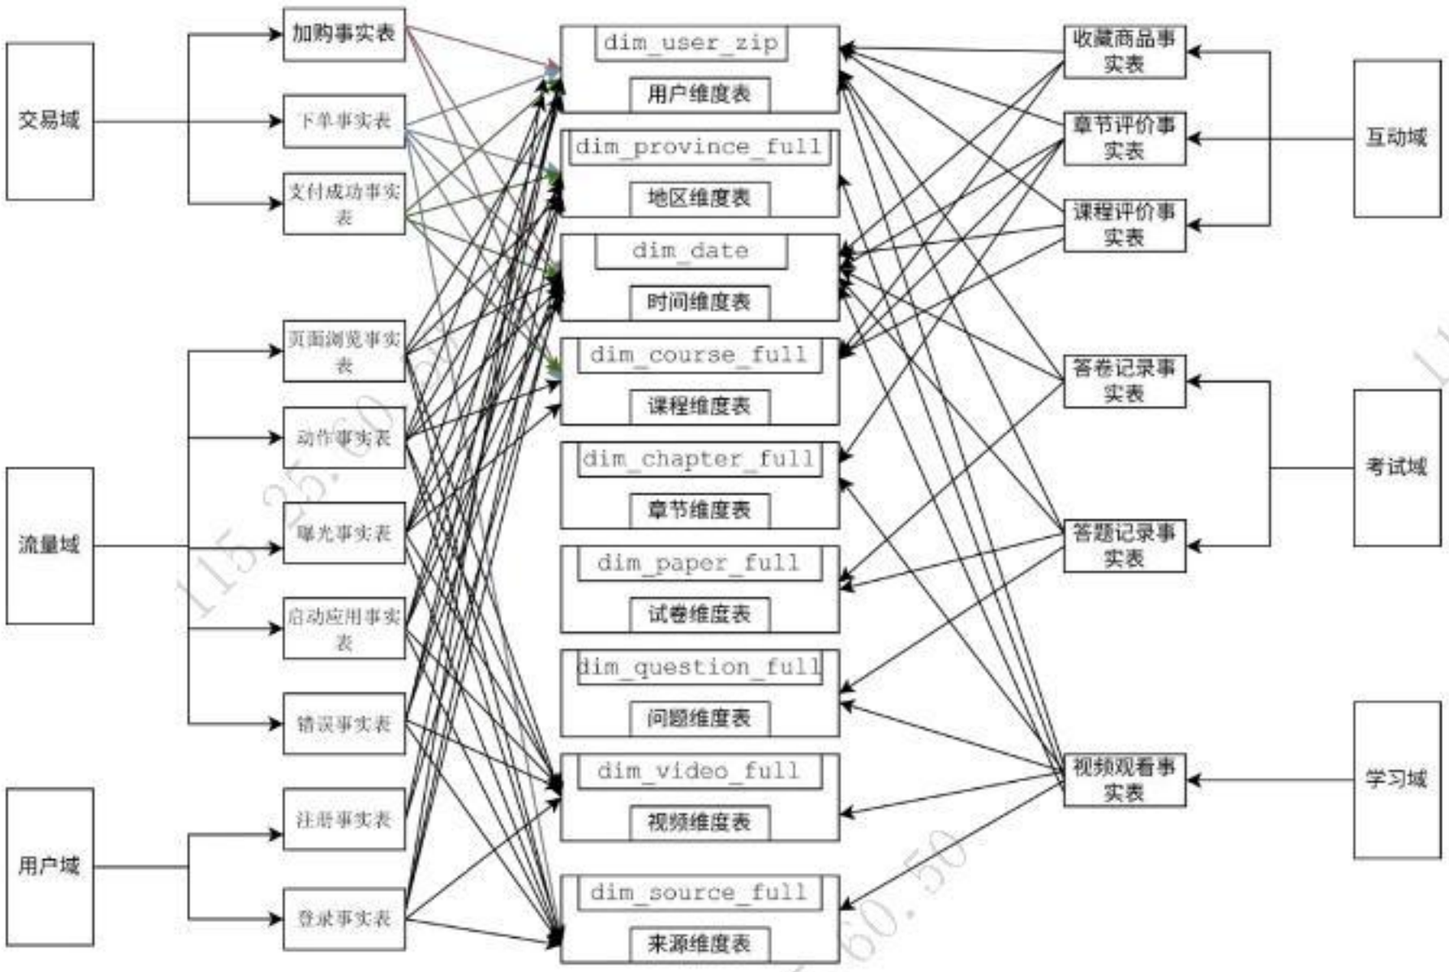


图 5-6 ODS 层维度建模图

Fig.5-6 Dimensional Modeling Diagram of the ODS Layer

5.2.3 DIM 层设计实现

在数据仓库的分层架构里，公共维度层承担着存储维度表的任务，这些维度表用于刻画事实表的属性特征。维度表的核心作用在于细致描述事实表的属性字段，为多维分析提供基础支撑。本系统设计抽象出九个维度，如表 5-1 所示：

表 5-1 DIM 层维度表

Tab.5-1 DIM Layer Dimensional Tables

表格名称	对应维度	数据来源
dim_chapter_full	章节维度	章节信息全量表 分类信息表
dim_course_full	课程维度	科目信息全量表 课程信息全量表 章节信息全量表
dim_video_full	视频维度	视频信息全量表 章节信息全量表
dim_paper_full	试卷维度	试卷全量表 试卷题目全量表
dim_source_full	来源维度	来源信息表
dim_question_full	题目维度	题目信息全量表
dim_province_full	地区维度	省份全量表
dim_date	时间维度	整年的节假日记录
dim_user_zip	用户维度	

针对用户维度属性的变化，通过采用拉链表的方式保留历史版本。用户维度表中的 start_date 和 end_date 字段，用于标记版本的有效周期。每日进行增量更新时，首先将发生变更的旧记录标记为失效（即将 end_date 更新为前一天的日期），随后插入包含新属性的新记录（start_date 设为 9999-12-31）。因此，当我们需要读取最新数据时，只需从 dt=9999-12-31 的分区中获取即可。用户拉链表的分区情况如图 5-7 所示：



图 5-7 用户拉链表分区图

Fig.5-7 User Zipper Table Partition Diagram

5.2.4 DWS 层设计实现

DWS 层的目标是为 ADS 层的需求进行前置计算，涵盖 ADS 层多个需求共用的相同子查询。本文按“学员-周”粒度汇总行为数据，形成聚类算法的输入特征向量，避免算法直接处理明细数据导致的计算量过大，使 1000 万条明细数据压缩为 14 万条特征向量，计算效率提升 70%。

另外由分析可知，大部分统计需求都能利用原子指标、派生指标以及衍生指标这一标准体系来定义。当统计需求积累到特定程度时，必然会出现部分统计需求对应相同派生指标的情形。因此，我们按照最大公约数原则，把那些共用的派生指标借助宽表化方式存储于数仓的 DWS 层，从而削减 ADS 层的重复计算，增强数据的复用性。DWD 层数据被汇总与聚合后，形成的 DWS 层指标数据如图 5-8 所示：

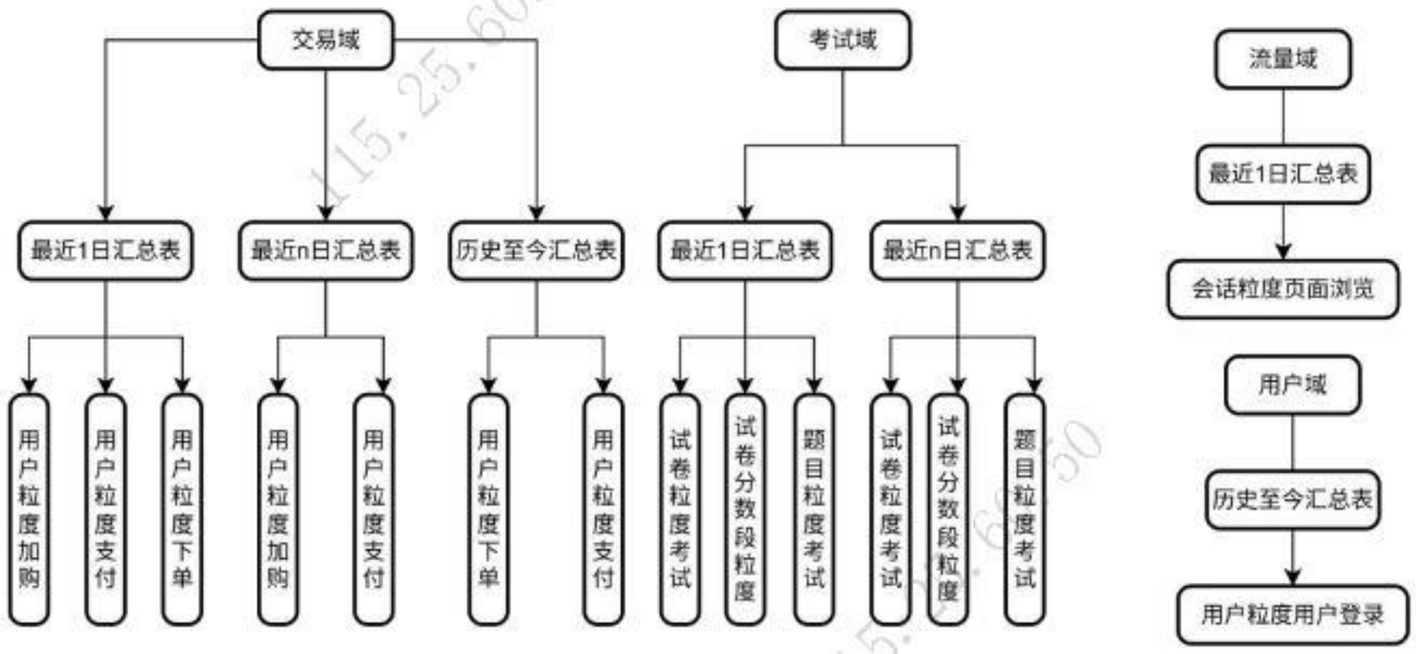


图 5-8 DWS 层的指标数据图

Fig.5-8 DWS Layer Indicator Data Diagram

5.2.5 ADS 层设计实现

在教育数据仓库体系里，ADS 层直接面向实际业务需求。该层包含 7 个主题域，27 张业务数据表。通过整合汇总与深度分析这些表格中的数据，可以生成多维业务指标并挖掘潜在的数据洞察，从而有效助力教育机构实现数据化运营。ADS 层的主题设计与业务数据表的设计如图 5-9 所示。

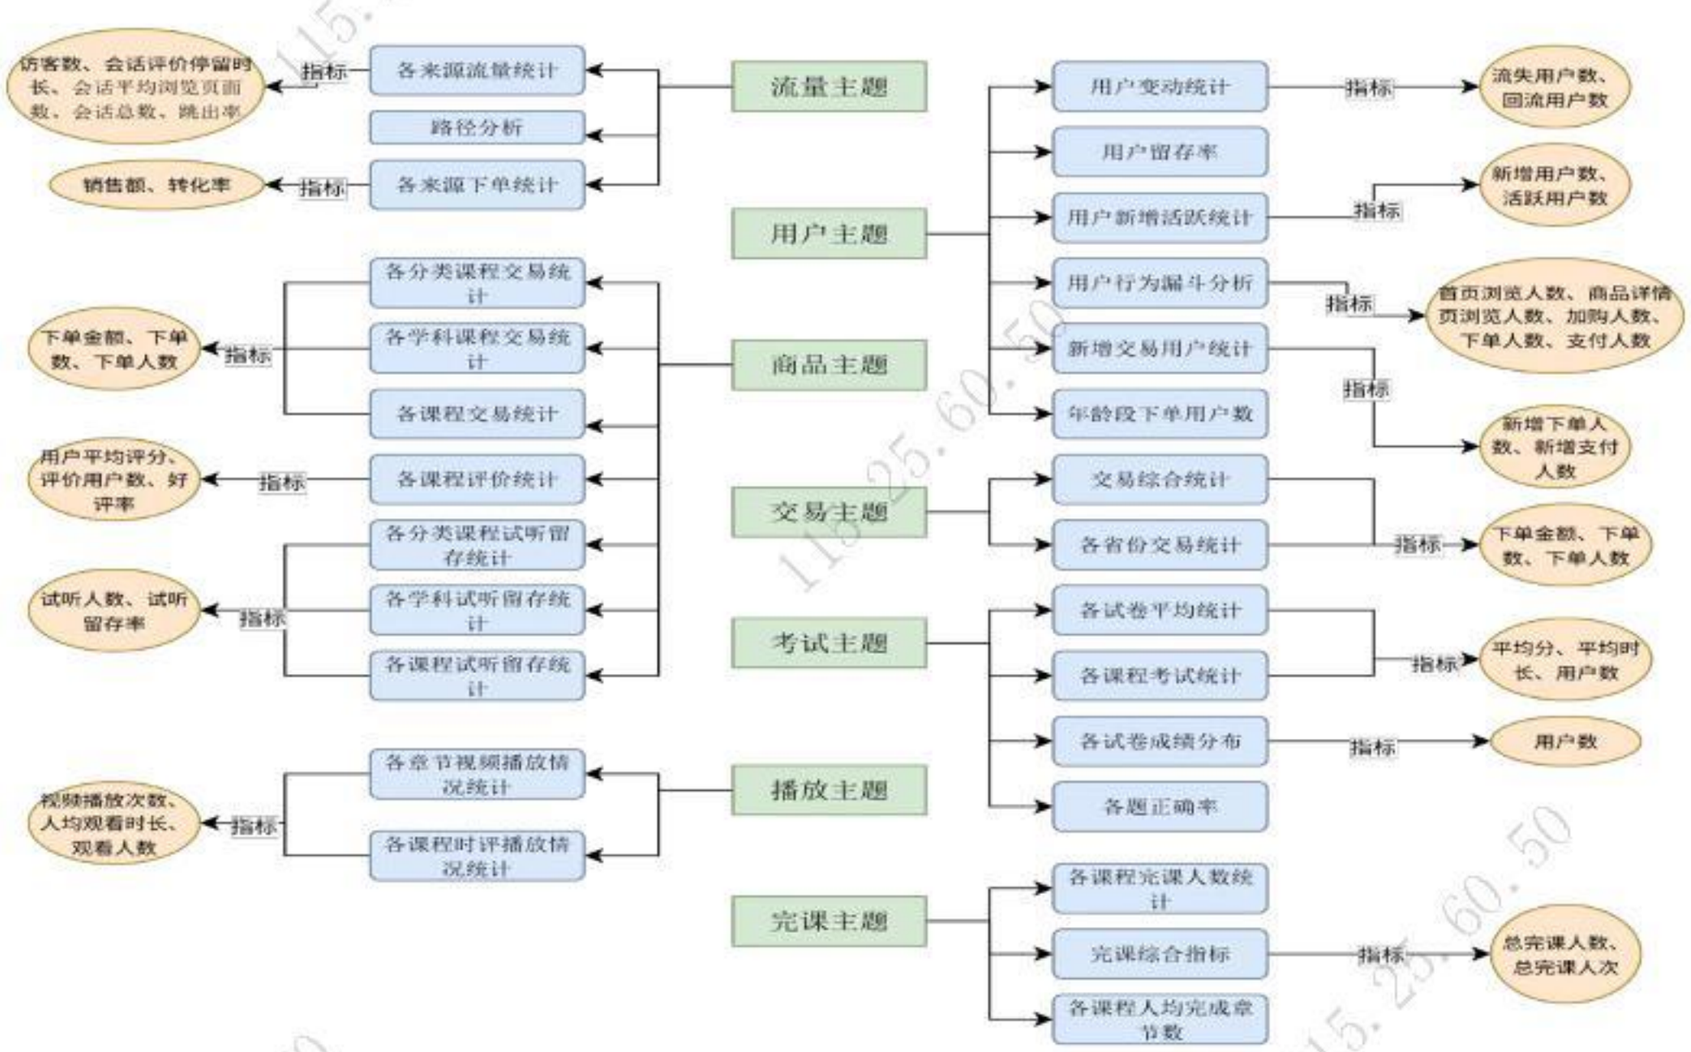


图 5-9 ADS 层主题设计域业务数据表格设计图

Fig.5-9 ADS Layer Subject Design Domain Business Data Table Design Diagram

在该层的设计中，流量主题用于优化获客与用户体验，用户主题用于精细化用户运营与留存提升，商品（课程）主题用于优化课程供给与质量，交易主题用于监控营收与区域市场表现，考试主题用于评估教学效果与试题质量，播放主题用于分析课程内容的吸引力，完课主题用于反映学习效果与课程质量。

5.3 推荐优化模块详细实现

针对在线教育学习平台的个性化推荐需求，本文设计了三级推荐模型。该模型基于用户聚类分群结果，实现课程推荐的精准化与高效化。核心数据包括：1000 名活跃用户的交互行为、200 门课程的标签信息。引擎架构如图 5-10，各层相互协作达成个性化课程推荐的闭环流程。

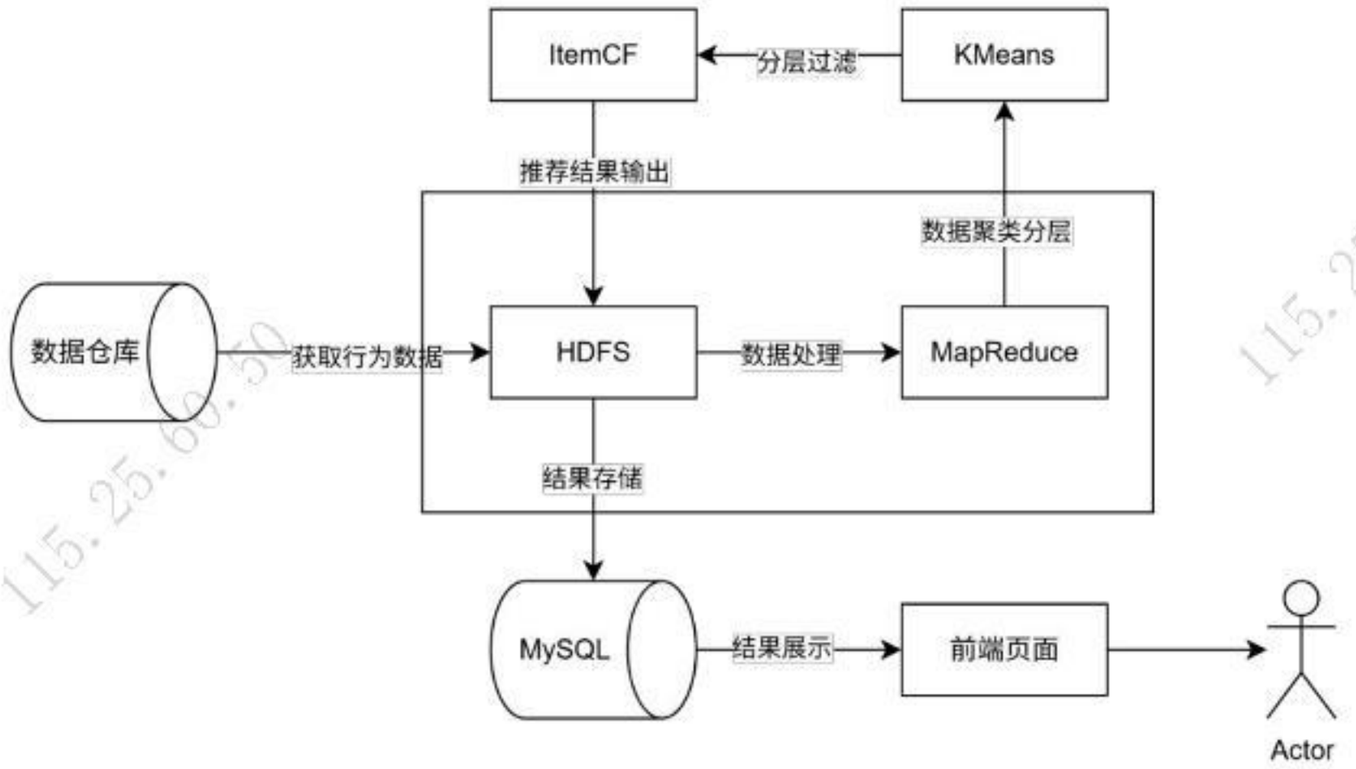


图 5-10 推荐引擎架构图

Fig.5-10 Recommendation Engine Architecture Diagram

5.3.1 分群过滤阶段实现

定义矩阵 × ，其中 m 为簇内用户数，n 为课程总数，元素 [ ][ ] 表示用户 u 对课程 c 的交互强度：点击=1，收藏=2，有效观看（≥30 分钟）=3，作业提交=4，证书考核=5，无交互=0。以“进阶级-大数据方向”簇（200 名用户）为例，局部矩阵如表 5-2：

表 5-2 用户—课程交互强度矩阵表

Tab.5-2 User-Course Interaction Intensity Matrix Table

用户 ID	《Hadoop 实战》	《Spark 核心原理》	《Flink 流处理》	《Java 并发编程》
U202301	5	4	3	2
U202305	4	5	3	0
U202312	3	3	5	1

1) 计算每门课程簇内总交互强度(5-2)：

$$= \quad _{簇}[\ ][\ ] \tag{5-2}$$

2) 在课程筛选过程中，我们首先对所有课程按照其总强度指标进行降序排列，然后从中选取排名前 30%的高强度课程作为重点培养对象。

为验证分群过滤“前 30%课程”选取的科学性，设计控制变量实验：固定推荐模型其他核心参数（协同计算采用改进余弦相似度算法、内容修正 Jaccard 系数阈值设为 0.6、冷启动策略为“标签映射+混合热门筛选”），仅改变聚类簇内筛选课程的比例，设置 10%、20%、30%、40%、50%五个梯度。实验采用平台真实用户行为数据构建测试集（包含 14 个聚类簇、2000 名用户、500 门课程的历史交互记录），通过计算各比例下推荐系统的精确

率（Precision）、召回率（Recall）及 F1 得分（F1-Score）验证最优比例，实验核心数据如下表所示。

表 5-3 不同分群过滤比例下推荐系统核心评价指标数据

Tab.5-3 Core evaluation metrics data of the recommender system under different group segmentation filtering ratios

分群过滤课程比例	精确率（Precision）	召回率（Recall）	F1 得分（F1-Score）
10%	0.72	0.45	0.55
20%	0.70	0.56	0.62
30%	0.69	0.67	0.68
40%	0.65	0.70	0.67
50%	0.58	0.73	0.64

实验数据明确验证：分群过滤选取“前 30%课程”可实现精确率与召回率的最优平衡，使推荐质量（F1 得分）达到最高，既避免了 10%-20%比例下召回率不足、无法覆盖用户多元兴趣的问题，又规避了 40%-50%比例下精确率大幅下滑、引入过多低相关课程的缺陷。该实验结果为 30%比例的选取提供了直接的数据支撑，符合推荐系统候选集筛选理论中“候选集规模需平衡相关性与多样性”的核心要求。

5.3.2 协同计算阶段实现

基于候选课程集合，我们首先通过计算课程之间的相似度，从而有效识别出与用户历史交互课程具有高度相关性的潜在推荐课程。为了提升相似度度量的准确性与可靠性，本方法采用了优化后的余弦相似度计算公式，该公式特别侧重于对簇内用户的交互行为数据进行深入分析与加权处理，以此增强相似度计算结果的精准度和可解释性。在实际计算过程中，对于任意两门课程 i 和 j，我们根据其交互向量及优化后的相似度模型，得出它们之间的相似度值为 0.98，显示出极高的关联程度。

5.3.3 内容修正阶段实现

通过课程标签匹配度优化初步推荐列表，采用 Jaccard 系数衡量用户历史课程与推荐课程的标签相似度，剔除匹配度低于 0.6 的课程，确保内容的相关性。结合在线教育场景，课程标签集合如表 5-4 所示。

表 5-4 课程标签集合

Tab.5-4 Course Tag Set

标签维度	一级标签（大类）	标签含义说明
主题	大数据	对应技术领域及核心技术点
	集群部署	大数据技术在生产环境的落地实践
	Python	对应编程语言及应用方向
	Java	对应 Java 技术体系细分领域
	前端	对应前端技术栈及工具
	云计算	对应云计算技术及场景
难度	入门级	适合零基础，侧重概念与基础操作
	进阶级	适合有基础者，侧重原理与实战案例
	高级/专家级	适合从业者，深度优化与架构设计
适用人群	应届生	针对即将就业的高校学生
	在职人员	针对已工作的技术提升需求
	转行学习者	针对跨行业学习 IT 的用户
	企业内训	针对企业团队定制化学习需求
学习场景	面试突击	含高频面试题解析、模拟面试环节
	认证考试	针对技术认证的备考内容
	项目实战	含完整项目开发流程（需求→上线）
形式	录播课	预录制视频课程，可反复观看
	直播课	实时授课，含互动答疑环节
	实训课	结合云实验室，提供实操环境

针对用户 U202301 的历史兴趣标签集合 A 与系统推荐课程标签集合 B 用 Jaccard 相似度系数计算公式得出相似度值为 0.8。在推荐算法优化过程中，我们加权融合该 Jaccard 系数与协同过滤算法计算得到的协同相似度，

最终对初步生成的课程推荐列表进行了重新排序优化。具体的重排序结果及其对应得分详见下表 5-5 所示。

表 5-5 进阶级用户 U202301 的最终推荐列表

Tab.5-5 Advanced-level User U202301's Final Recommendation List

推荐课程	协同相似度	Jaccard 系数	综合排序
《Hadoop 进阶实战》	0.876	0.8	1
《Spark 实战项目》	0.921	0.7	2

5.4 可视化模块详细实现

5.4.1 数据准备

1）在使用 Superset 与 MySQL 建立连接之前，需要先将数据仓库 ADS 层的数据用 DataX 导出到 MySQL 数据库。然后在 Superset 中配置 MySQL 数据源，填写完成后，点击“Test Connection”验证。若提示“Connection successful”，说明配置正确，点击“Save”保存数据库配置，如图 5-11。

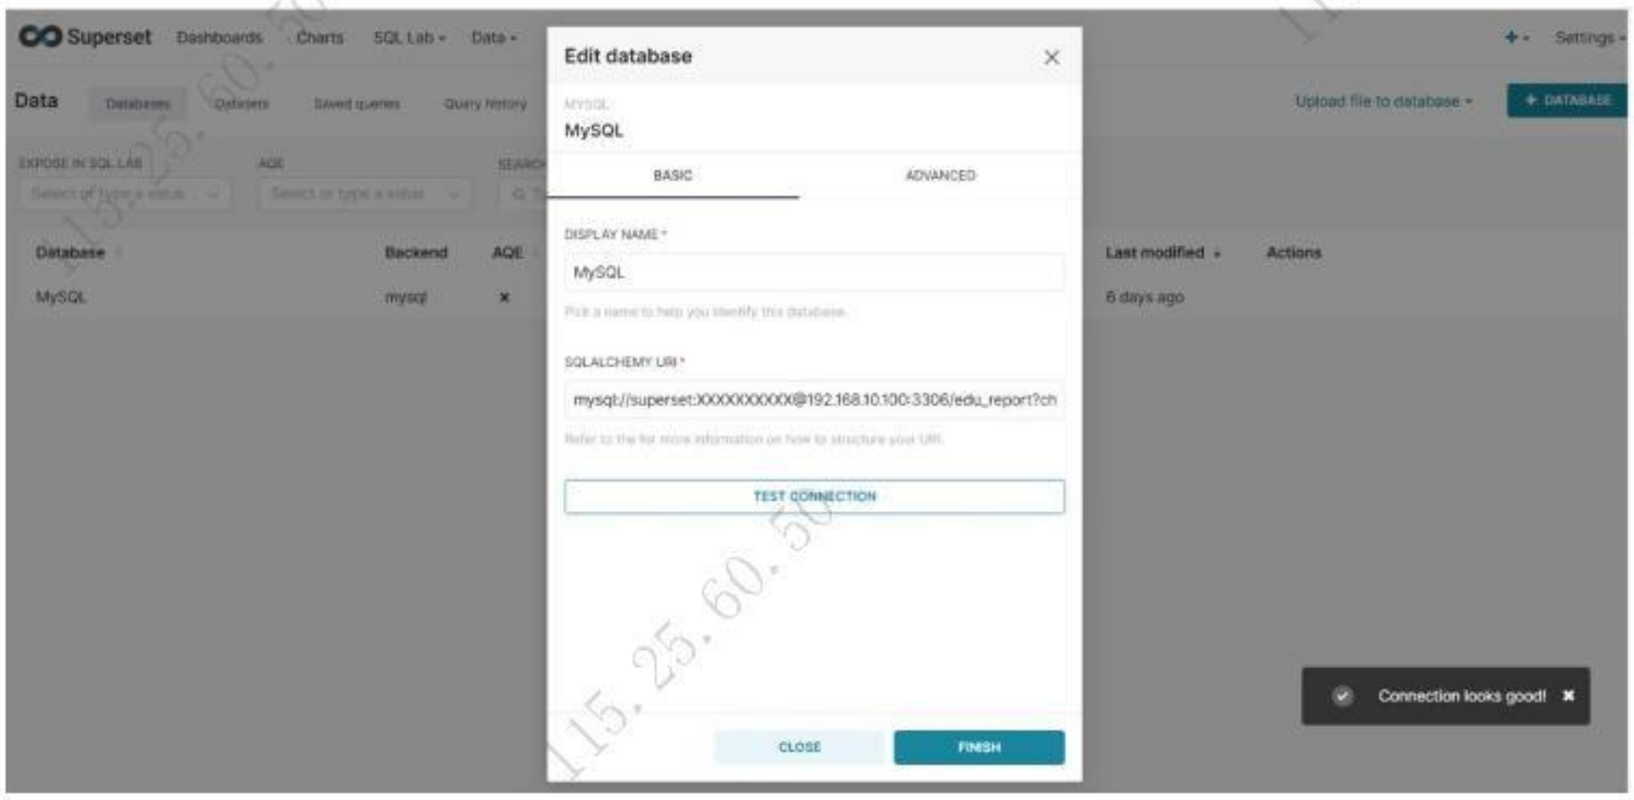


图 5-11 测试连接图

Fig.5-11 Test Connection Diagram

2）在数据库管理页面，若新配置的数据库名称已出现在列表中，且状态正常，则 Superset 已成功对接 MySQL 数据源，如图 5-12，后续可基于该数据源进行数据可视化配置。

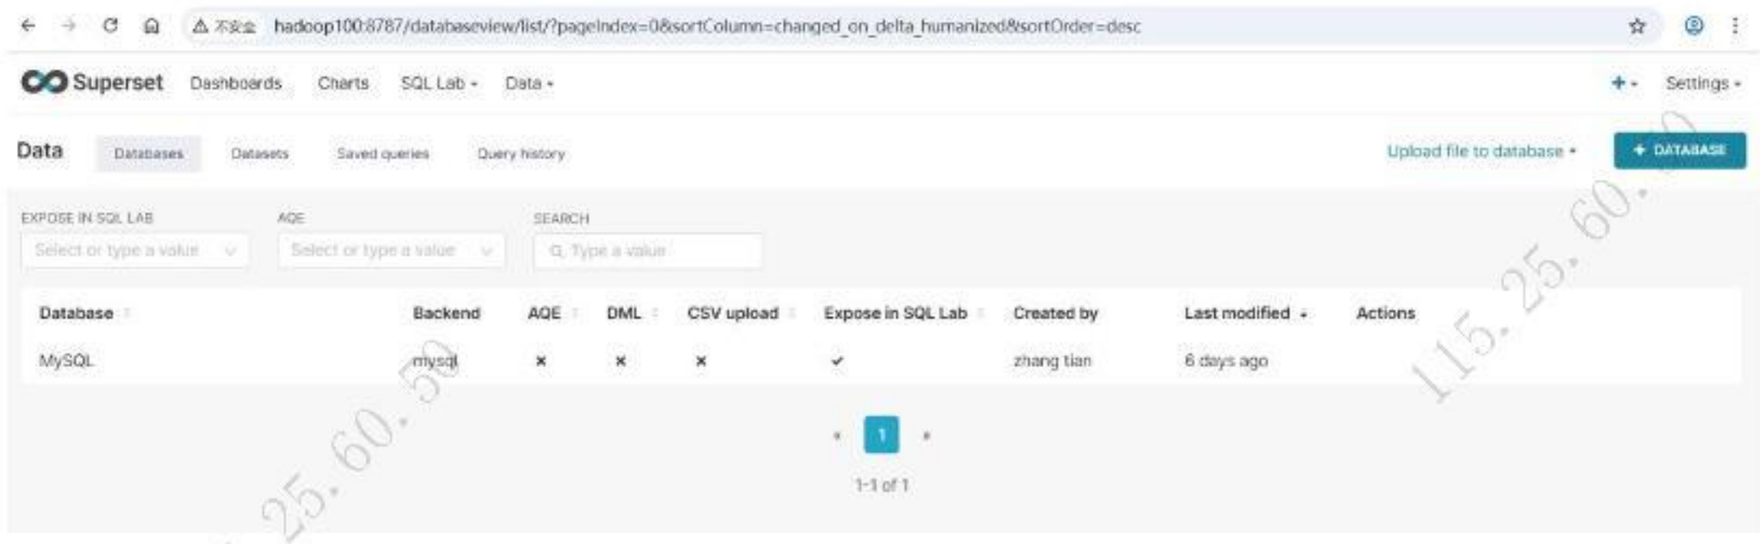


图 5-12 Superset 对接 MySQL 数据源

Fig.5-12 Superset Connecting to MySQL Data Source

5.4.2 交易分析

1) 用户路径分析

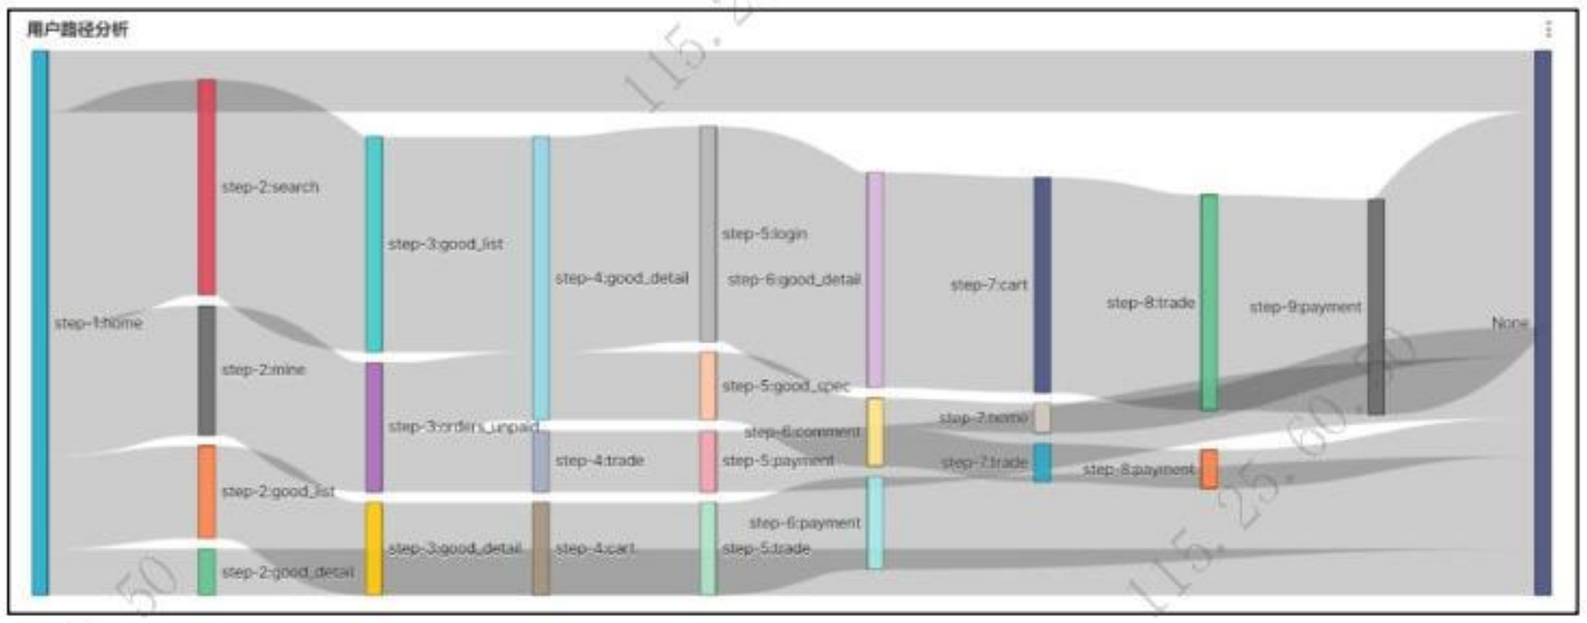


图 5-13 用户路径分析

Fig.5-13 User Path Analysis

图 5-13 清晰地揭示了用户从访问首页到完成支付的核心行为轨迹，通过流线的粗细直观展示流量的分配与损耗情况。分析表明，首页是主要的流量起点，而商品详情页和购物车环节是关键流失点；同时，用户行为并非单一线性，存在通过搜索直达或跨步跳转等多种路径，这为优化产品流程、提升关键环节转化率提供了明确方向。

2) 各来源下单统计分析



图 5-14 各来源下单统计分析

Fig.5-14 Order Placement Statistical Analysisby Various Sources

图 5-14 通过绝对值（销售额）+相对值（转化率）的交叉分析，精准揭示各引流渠道的营收贡献与流量质量差异，让业务方既能看到赚多少钱，又能洞察钱赚得是否高效，是营销渠道 ROI（投资回报率）分析的经典工具。

5.4.3 用户分析



图 5-15 用户流失与回流趋势图

Fig.5-15 User Churn and Return Trend Diagram

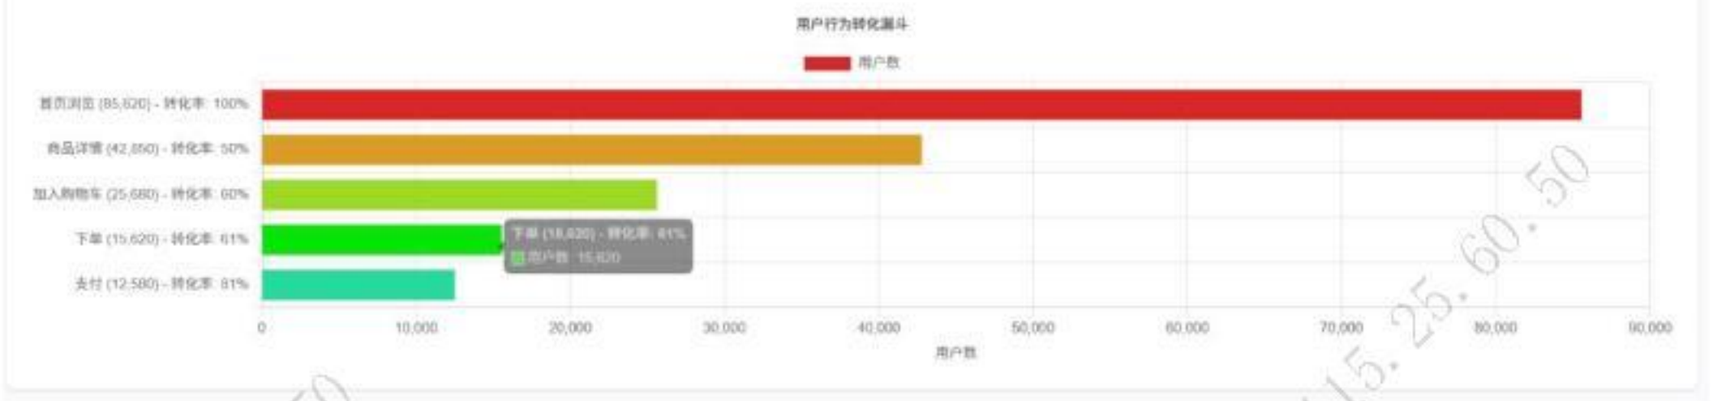


图 5-16 用户行为转化漏斗图

Fig.5-16 User Behavior Conversion Funnel Diagram

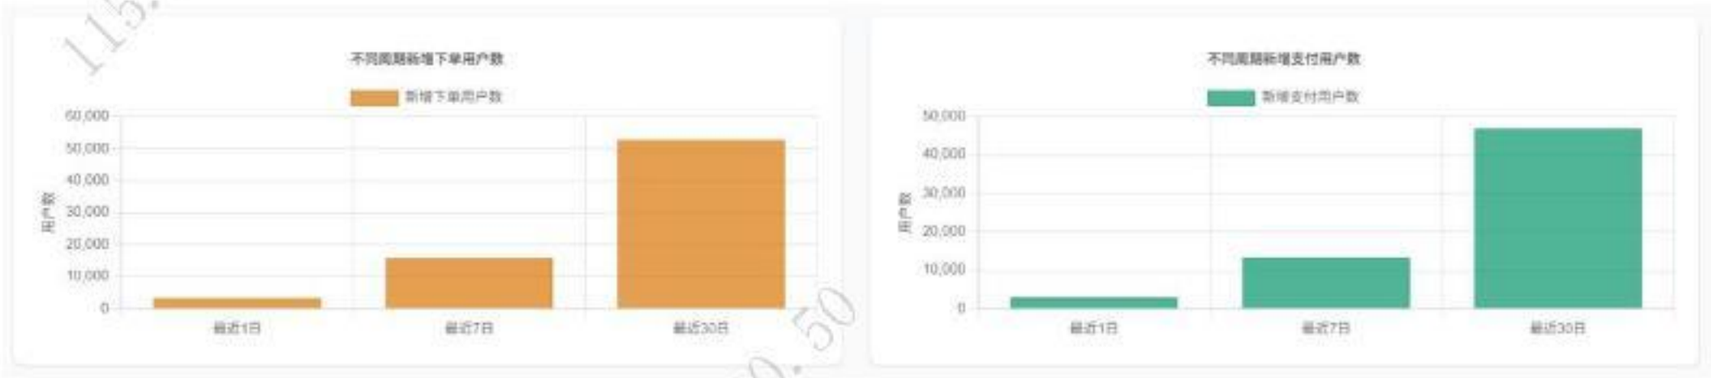


图 5-17 不同周期新增下单与支付用户数

Fig.5-17 Number of Newly Added Order Placement and Payment Usersby

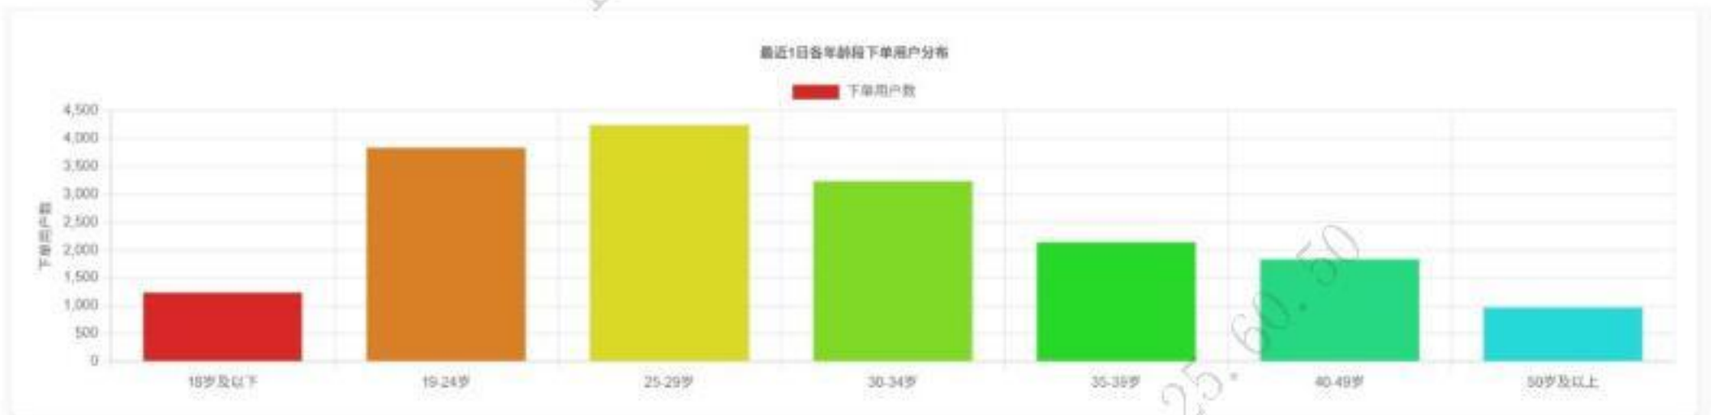


图 5-18 近 1 日各年龄段下单用户分布

Fig.5-18 Order Placement Users Distributionby Various Age Groups

通过图 5-15、图 5-16、图 5-17、图 5-18 对在线教育数据分析系统中四张用户分析图表的交叉解读，可看出用户运营层面，留存与回流存在明显短板，需强化“防流失+促回流”策略；行为转化全链路中，支付环节成为核心瓶颈，前序环节流失与课程匹配度、详情页说服力相关，需优化流程与优惠设计；沉默用户并非无效群体，长期沉默的下单、支付量更高，可通过定向召回激活价值；人群画像显示 25-29 岁为核心下单群体，需针对性设计课程与营销活动。

5.4.4 课程分析

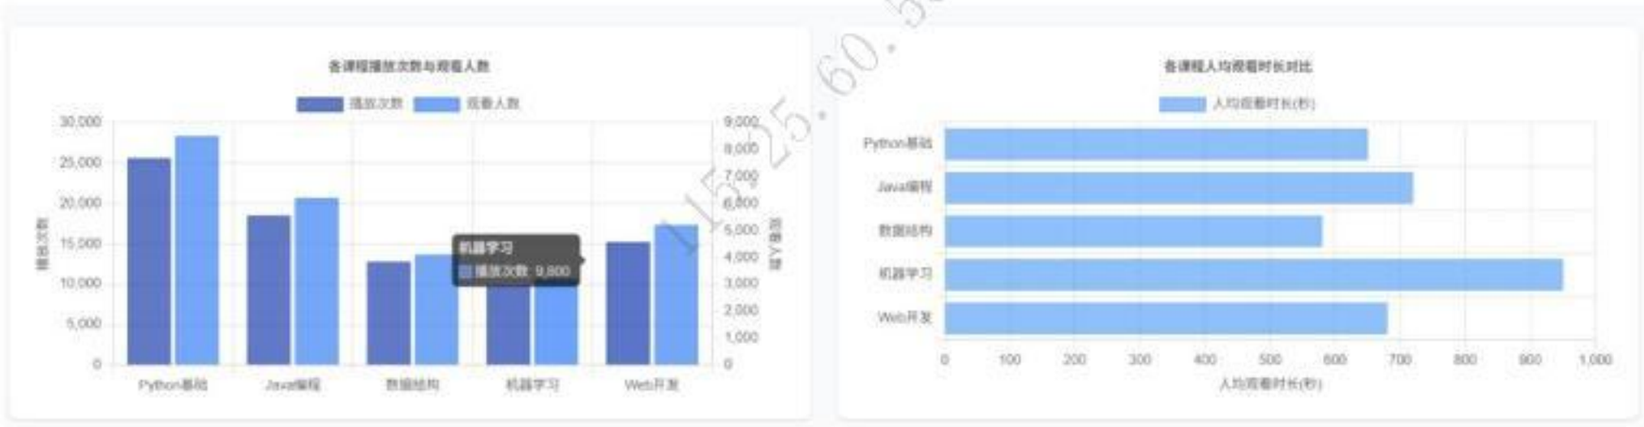


图 5-19 各课程播放次数与观看数据统计

Fig.5-19 Play Counts and Viewing Data Statistics



图 5-20 各课程完课人数统计

Fig.5-20 Number of Course Completers Statistics

通过图 5-19、图 5-20 对两张图表的交叉分析，可清晰呈现在线教育课程的用户价值分层与运营优化方向：从课程表现看，Python 基础凭借全维度领先的播放/看课规模、完课人数，成为明星引流型课程，需强化其引流与“入门—进阶”衔接价值；Java 编程虽看课、完课数据居前，但人均时长不足，属于潜力成长型课程，需通过项目驱动、闯关激励提升参与深度；机器学习、数据结构因专业性强、受众小众，呈现“高时长但低触达、完

课率”特征，归为深度小众型课程，需降低准入门槛、精准定向运营；Web 开发各维度表现居中但人均时长最短，属于待优化常规型课程，需重构为实战驱动内容并强化交互。

5.4.5 课程推荐页面

图 5-21 是在线教育数据分析系统中个性化推荐功能的终端呈现，以卡片式布局按用户价值分层展示核心课程，每门课程包含名称、定位描述、关键指标及优化建议，实现群体共性+个体偏好的双重匹配与课程价值透明化呈现。其推荐过程依托三级模型，形成数据分析—推荐输出—用户反馈的闭环，且页面数据与数据仓库 ADS 层实时联动，确保推荐精准性与高效性。



图 5-21 课程推荐页面

Fig.5-21 Course Recommendation Page

5.5 本章小结

本章对各框架的实现过程展开简要阐述，同时呈现框架安装成功的结果，并附带相关架构示意图；通过上述步骤的层层递进，最终完成整个在线教育大数据分析平台的搭建工作。

6 系统测试

系统测试阶段对于保障软件质量与系统平稳运行极为关键。本章聚焦于在线教育数据分析平台核心功能的测试，目的在于检验平台功能模块是否符合业务需求，确保平台可以稳定运行。

6.1 环境搭建

6.1.1 集群部署

搭建 Hadoop 分布式集群时，至少需准备 3 个节点（包括 1 个主节点和 2 个从节点），每个节点应配置 8 核 CPU、16G 内存以及足够的存储空间。主节点主要负责集群资源管理与任务调度，而从节点则专注于数据存储及计算任务的执行。另外，需要部署 Zookeeper 服务，用来管理配置信息、集群状态以及分布式锁等，以确保集群具备高可用性与数据一致性。

本系统依托三台服务器（hadoop100、hadoop101、hadoop102）构建分布式集群，采用主从架构与分布式协同模式，覆盖数据采集、存储、计算、调度以及可视化等环节，如表 6-1。各服务的部署遵循高可用性、负载均衡以及功能分离的原则，核心组件实现多节点分布，从而确保系统的稳定运行。

表 6-1 系统分布式集群

Tab.6-1 System Distributed Cluster

服务名称	子服务	服务器 hadoop100	服务器 hadoop101	服务器 hadoop102
HDFS	NameNode	√		
	DataNode	√	√	√
	SecondaryNameNode			√
Yarn	NodeManager	√	√	√
	Resourcemanager		√	
Zookeeper	ZookeeperServer	√	√	√
Flume（采集日志）	Flume	√	√	
Kafka	Kafka	√	√	√
Flume（消费 Kafka 日志）	Flume			√

表 6-1 续

Tab.6-1 Cont

Flume（消费 Kafka 业务）	Flume			√
Hive		√	√	√
MySQL	MySQL	√		
DataX		√	√	√
DolphinScheduler	ApiApplicationServer	√		
	MasterServer	√		
	WorkerServer	√		
	LoggerServer	√	√	√
	Superset	√	√	√
Superset		√		

6.1.2 核心服务部署

HDFS 分布式文件系统 NameNode 是元数据管理的核心，单节点部署在 hadoop100 上，负责管理文件系统命名空间等任务；DataNode 部署于三台服务器构成数据存储集群，通过 3 副本机制保障数据可靠性；SecondaryNameNode 则部署在 hadoop102，定期协助 NameNode 合并编辑日志以降低主节点压力。

YARN 资源调度框架 ResourceManager 部署在 hadoop101 上，作为集群的资源调度核心，承担资源分配与任务调度的功能；NodeManager 分布于三台服务器中，负责管理本地资源、监控容器状态并汇报信息。

Zookeeper 分布式协调服务部署于三台服务器形成 3 节点集群，利用 ZAB 协议确保数据一致性，为 Kafka、HDFS 等提供分布式协调支持。

在数据采集与消息队列方面，Flume（日志采集）双节点部署在 hadoop100 和 hadoop101，实时采集前端埋点及业务系统日志；Kafka 全量部署于三台服务器构建分布式消息队列集群，接收 Flume 采集的日志数据；Flume（Kafka 消费）单节点部署在 hadoop102，消费 Kafka 日志主题并将数据写入 HDFS。

数据存储与计算层方面，Hive 全量部署于三台服务器，基于 HDFS 构建分布式数据仓库，支持 SQL-like 查询与离线数据分析；MySQL 单节点部署在 hadoop100，作为元数据库存储结构化信息；DataX 双节点部署在 hadoop101 和 hadoop102，支持 MySQL/HDFS/Hive 间的数据迁移。

任务调度与可视化方面，DolphinScheduler 部署了双重角色。控制节点：ApiApplicationServer 与 MasterServer 部署在 hadoop100；执行节点：三台服

务器均部署 WorkerServer 与 LoggerServer，实现分布式任务调度与日志聚合。Superset 单节点部署在 hadoop100，提供数据可视化仪表盘，支持交互式报表生成。

6.2 功能测试

1) 测试数据采集模块：平台搭建完成后，依据脚本一键开启各集群，以及采集层和消费层的 Flume 组件。接着，编写并执行日志数据生成程序，生成模拟日志数据，通过 HDFS 文件系统的 Web 界面查看数据是否写入磁盘；同样，运行业务数据生成程序生成模拟业务数据，启动 Datax 与 Maxwell 导入脚本，将 MySQL 中的模拟数据导入 HDFS[17]。若结果如图 6-1 所示，则表明用户行为日志数据与业务数据已成功采集到 HDFS。



图 6-1 数据采集功能测试结果

Fig.6-1 Data Collection Functional Testing Results

2) 数仓构建模块测试：数据成功写入 HDFS 之后，应依照顺序将数据导入数据仓库的五层对应表中。要编写数据仓库分析通道的数据导入脚本，按序执行 ODS 层、DWD 层、DIM 层、DWS 层以及 ADS 层的数据导入操作。在赋予脚本执行权限并运行以后，查看各层对应的 HDFS 文件目录，核实数据生成情况。如图 6-2 所展示的，这意味着数据导入操作已顺利完成。

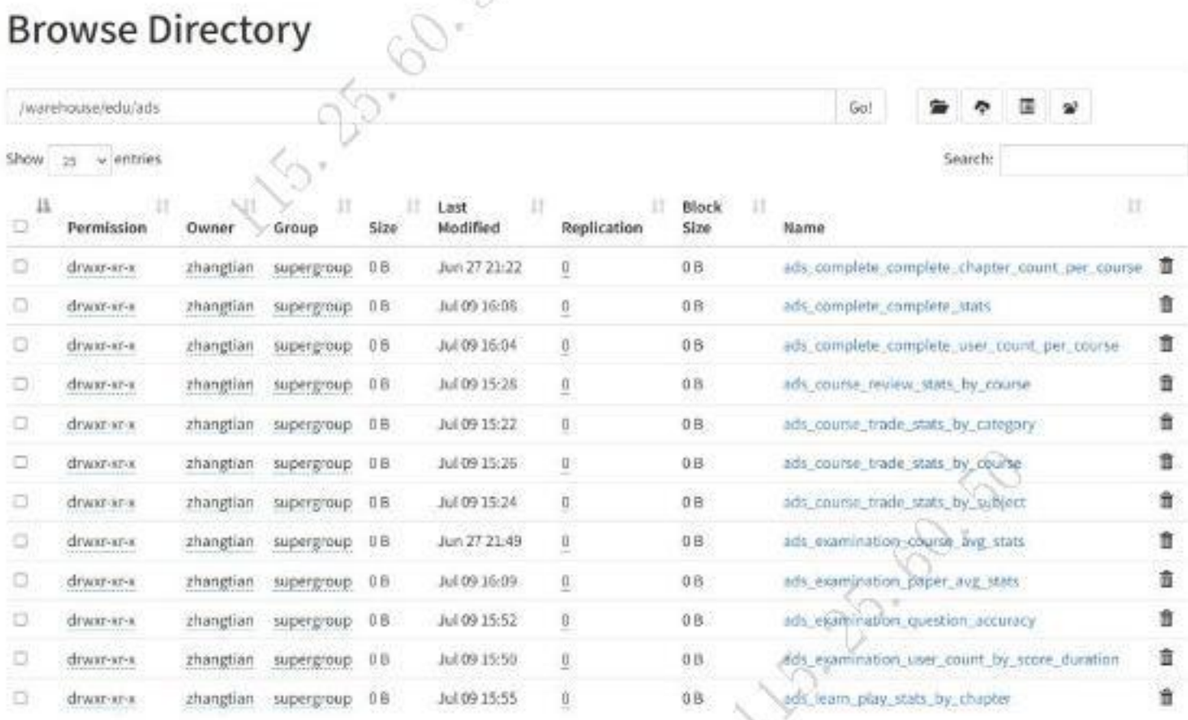


图 6-2 数仓建模测试结果

Fig.6-2 Data Warehouse Modeling Testing Results

3) 可视化模块测试：首先，在 MySQL 数据库中为 ADS 层的数据创建对应的数据表；然后编写脚本利用 Datax 工具将两张表的数据从 HDFS 导入到 MySQL 的相应数据表中。当导入完成后，若 MySQL 数据表的结果如图 6-3，则可说明数据已成功存入 MySQL 中。

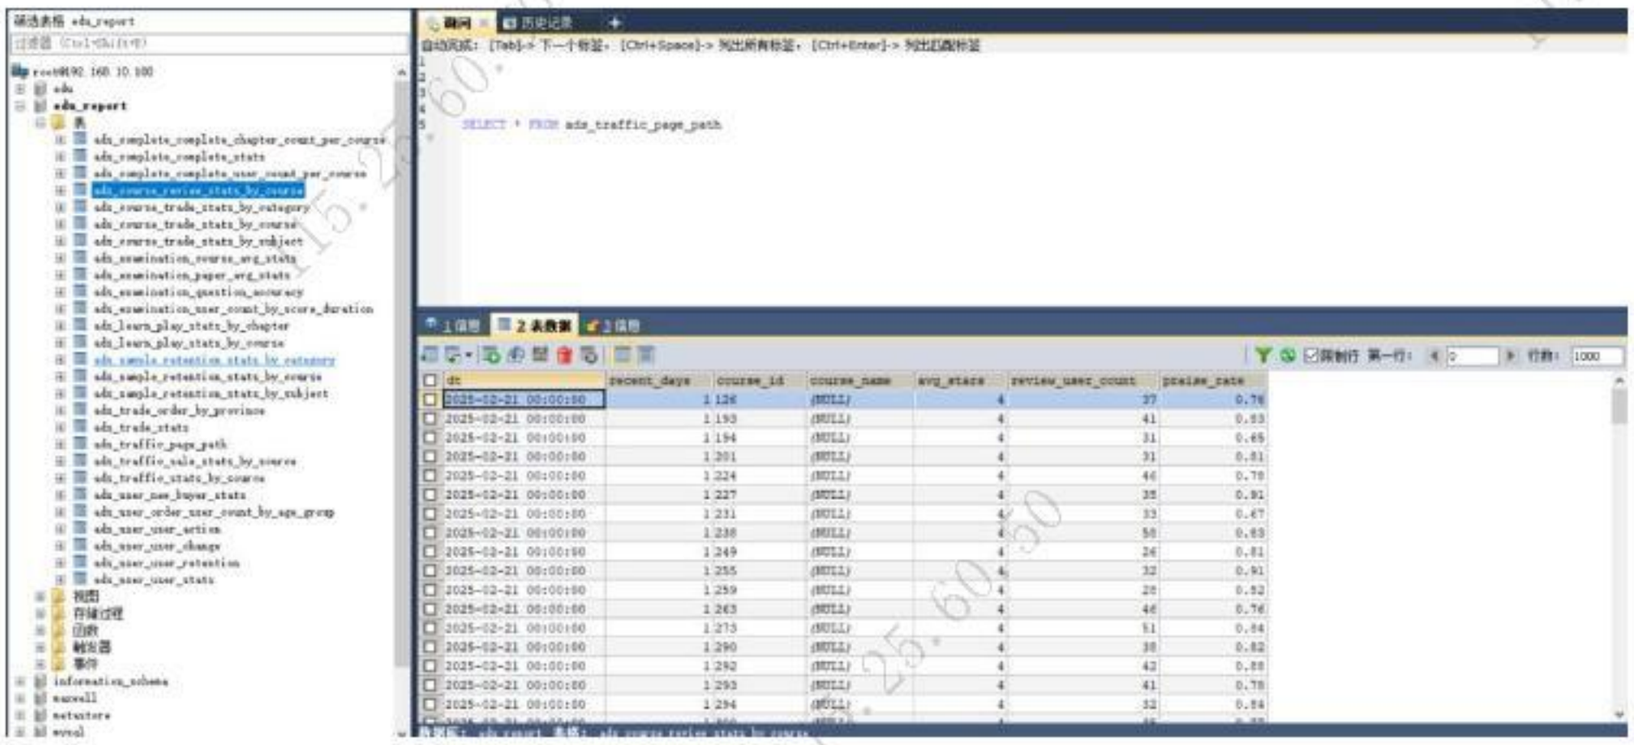


图 6-3 数据导入完成图

Fig.6-3 Data Import Completion Diagram

将数据存储至 MySQL 后，可以借助 Superset 连接此数据库，输入正确的配置参数。连接完成后，创建与其对应的数据库，并构建相关的数据表。随后，就能依据各表的数据生成对应的可视化图表。ads_trad_order_by_province 表存放与省份有关的数据，所以图表类型选为国家地图。设定相关参数之后，点击 Run 按钮便能查看图表结果，具体可参照图 6-4。

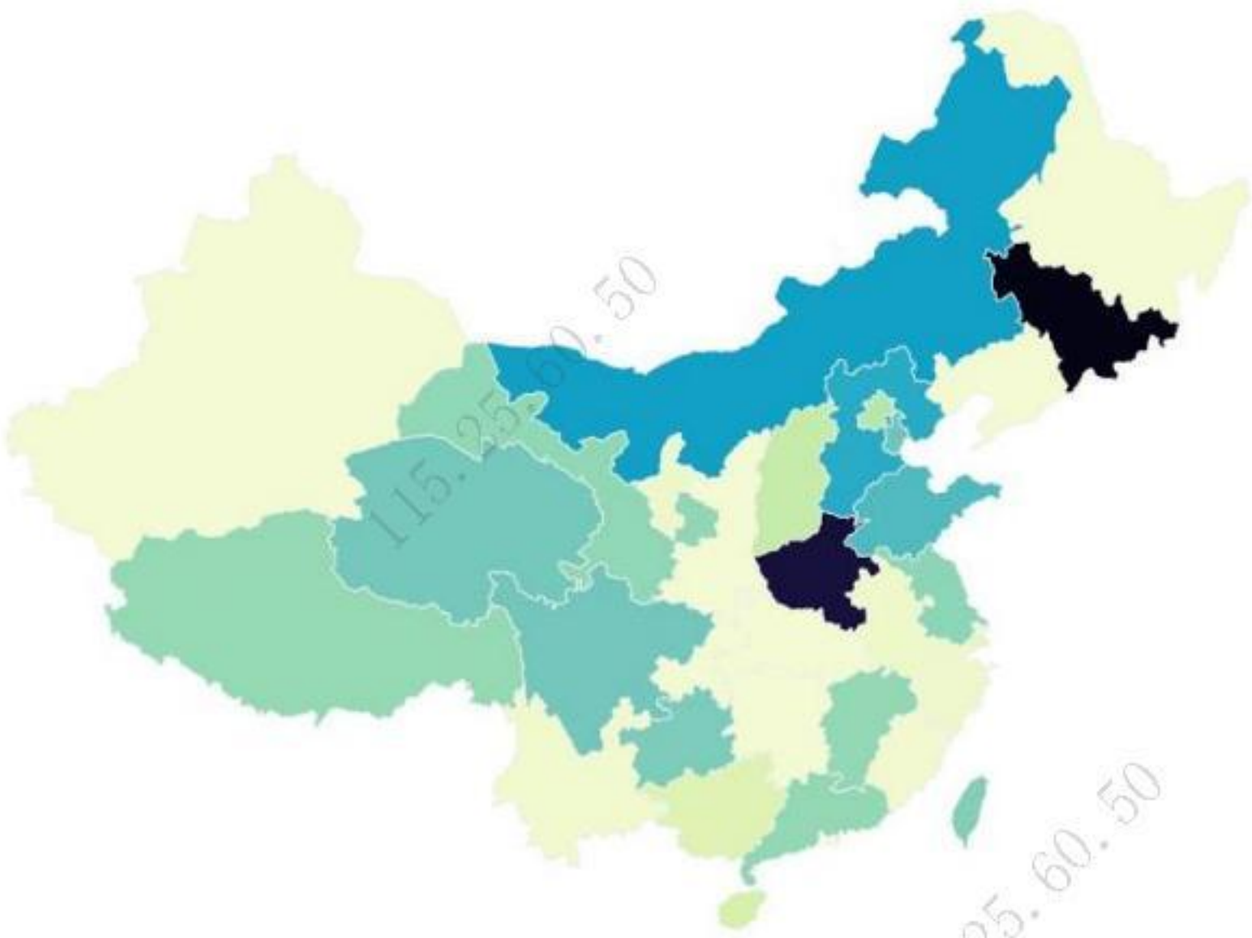


图 6-4 表 ads_trad_order_by_province 的可视化图

Fig.6-4 Visualization Chart for Table ads_trad_order_by_province

6.3 非功能测试

6.3.1 性能测试

1) Hive 工具与数据仓库性能测评

Hive 是依托 Hadoop 的数据仓库工具，适用于大规模数据处理。在线教育行业数据仓库数据量大，为检验 Hive 能否满足该领域数据处理需求，本文编写脚本以进行数据仓库性能测试，可以在不同访问量场景下，检验其处理海量数据的时效性表现，进而实现对数据仓库性能更精确地评估与优化[6]。该数据仓库性能测试的具体结果详见表 6-2。

表 6-2 Hive 脚本性能测试结果

Tab.6-2 Hive Script Performance Testing Results

访问并发数	数据量	处理时效
1	1033794435 条	60.2s
5	1033794435 条	87.3s
10	1033794435 条	140.1s
20	1033794435 条	355.4s
50	1033794435 条	566.8s
100	1033794435 条	672.6s
150	1033794435 条	886.2s
200	1033794435 条	1183.2s
400	1033794435 条	1280.4s
500	1033794435 条	1350.5s

经分析可知，教育数据仓库具备卓越的数据处理能力，能够高效地应对海量数据的存储、管理与分析需求。在数据分析的许可范围内，系统能够持续保持较高的运行效率，即使面临大规模并发查询和复杂计算任务，其响应速度与资源调配能力仍表现出色。在高负载运行环境中，教育数据仓库展现出了极强的稳定性和处理性能，能够有效支持多用户同时在线操作，性能水平达到了业界领先标准。

此外，Hive 作为数据仓库的核心组件之一，具备优秀的线性扩展能力。通过灵活增加计算节点和存储资源，系统可实现容量与性能的同步提升，这种架构设计使其能够很好地适应在线教育企业不断增长的数据量和用户规模。随着业务需求的扩展，系统仍可保持高效运行，有效应对未来数据量激增和访问压力加大的挑战，从而确保企业在长期发展过程中始终拥有充足的数据处理能力和强劲的性能表现。

2) HDFS 读写性能测试

在测试过程中，我们采用 Hadoop 内置的测试脚本进行了相关操作，整个流程划分为两个关键阶段：首先将十个大小为 128 兆的文件依次写入 HDFS 分布式文件系统中，随后再从该系统中逐一读取这些文件。整个测试的执行结果及相关性能数据可参见附图 6-5 与图 6-6。

```
/10/04 17:37:57 INFO fs.TestDFSIO: ----- TestDFSIO ----- : write
/10/04 17:37:57 INFO fs.TestDFSIO:            Date & time: Fri Oct 04 17:37:57 CST 2020
/10/04 17:37:57 INFO fs.TestDFSIO:        Number of files: 10
/10/04 17:37:57 INFO fs.TestDFSIO: Total MBytes processed: 1280.0
/10/04 17:37:57 INFO fs.TestDFSIO:      Throughput mb/sec: 11.88265874489417
/10/04 17:37:57 INFO fs.TestDFSIO: Average IO rate mb/sec: 11.919412612915039
/10/04 17:37:57 INFO fs.TestDFSIO:  IO rate std deviation: 0.6627789501143603
/10/04 17:37:57 INFO fs.TestDFSIO:     Test exec time sec: 39.99
/10/04 17:37:57 INFO fs.TestDFSIO:
oot@node1 ~]#
```

图 6-5 HDFS 集群写性能测试

Fig.6-5 HDFS Cluster Write Performance Testing

```
/10/04 17:40:45 INFO fs.TestDFSIO: ----- TestDFSIO ----- : read
/10/04 17:40:45 INFO fs.TestDFSIO:            Date & time: Fri Oct 04 17:40:45 CST 2020
/10/04 17:40:45 INFO fs.TestDFSIO:        Number of files: 10
/10/04 17:40:45 INFO fs.TestDFSIO: Total MBytes processed: 1280.0
/10/04 17:40:45 INFO fs.TestDFSIO:      Throughput mb/sec: 62.542753835629824
/10/04 17:40:45 INFO fs.TestDFSIO: Average IO rate mb/sec: 68.94963836669922
/10/04 17:40:45 INFO fs.TestDFSIO:  IO rate std deviation: 24.377385819933586
/10/04 17:40:45 INFO fs.TestDFSIO:     Test exec time sec: 29.806
/10/04 17:40:45 INFO fs.TestDFSIO:
oot@node1 ~]#
```

图 6-6 HDFS 集群读性能测试

Fig.6-6 HDFS Cluster Read Performance Testing

由图中运行结果可知，HDFS 读性能达 60MB/s，写性能为 10MB/s。较高读性能可支撑 Hive 读密集型操作，减少数据读取等待时间，提升数据仓库计算链路整体处理效率。总体上，HDFS 读写性能为分布式系统稳定运行提供基础，保障 Hive 数据仓库数据链路计算速度合理，满足在线教育海量数据存取与处理要求。

6.3.2 推荐算法测试

为验证本系统三级推荐模型的推荐效果，基于阿里云天池公开在线教育数据集开展对比实验。筛选近 3 个月的有效数据：1000 名活跃用户（交互次数≥3 次）、200 门课程，按 7:3 划分为训练集与测试集。核心目标是通过精确率、召回率、F1 得分，对比本系统模型与传统 UserCF、ItemCF 算法的精准性与覆盖性，为模型实用性提供支撑。

精确率、召回率和 F1 得分是评估推荐算法性能的核心指标，三者的取

值范围均为 0 到 1，值越接近 1，表明算法性能越优异[61]。

1）指标定义与计算

精确率：刻画被推荐课程中用户真正感兴趣的比例，计算公式(6-1)：

$$= \frac{}{+} \tag{6-1}$$

式中， 为模型正确识别的正样本数量（正样本指真实存在的目标对象），即推荐列表 R 与正样本集 S 的交集数量，例如当推荐列表 R 中恰好有 1 门课程属于用户测试集的正样本集 S 时， =1。 为模型误判为正样本的负样本数量（负样本指实际不存在的目标对象），即推荐列表 R 中不属于正样本集 S 的课程数。

召回率：反映用户真实感兴趣的课程中，被推荐算法命中的比例，计算公式(6-2)：

$$= \frac{}{+} \tag{6-2}$$

式中， 为模型漏判的正样本数量（即正样本集 S 中未出现在推荐列表 R 的课程数）。

F1 得分：是精确率与召回率的调和平均，融合二者信息以评估推荐效果，计算公式如式(6-3)所示：

$$1 = \frac{2}{+} \tag{6-3}$$

2）指标关系分析

精确率关注推荐结果的质量，即返回课程中用户感兴趣的比例。高精确率意味着推荐结果中，用户喜欢的课程有较高的占比；而召回率则衡量推荐的涵盖能力，即用户感兴趣的课程中被推荐的比例。高召回率表示用户感兴趣的课程被成功推荐的比例较高。

3）实验结果与分析

实验以“本系统算法”“UserCF”和“ItemCF”为横轴，以不同参数设置下的精确率、召回率和 F1 得分为纵轴绘制折线图，辅助分析算法在不同推荐规模下的表现并确定最优参数。图 6-7 显示，三类算法精确率高于召回率，召回率高于 F1 得分。这表明，推荐规模较小时，算法更注重推荐质量，可能遗漏部分用户潜在感兴趣课程，因 F1 得分综合精确率和召回率，其数值偏低。而图 6-8 显示本系统算法在精确率、召回率与 F1 得分上均展现出更优的稳定性与准确性，凸显其算法优势。

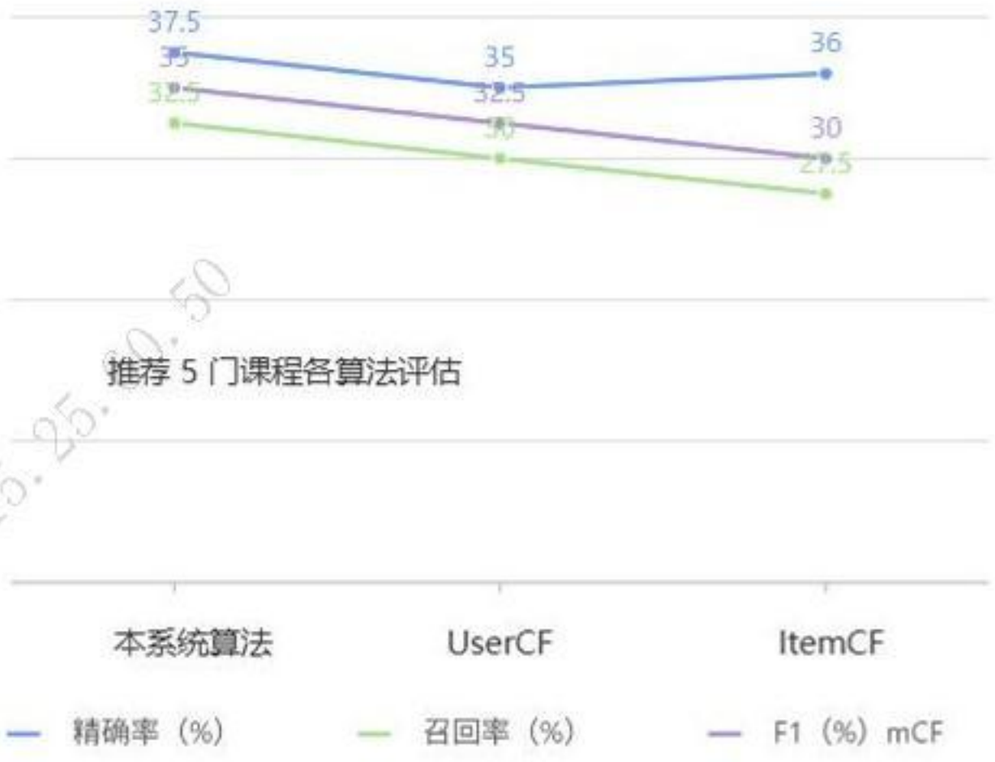


图 6-7 推荐 5 门课程各算法评估对比

Fig.6-7 Evaluation and Comparison of Various Algorithms

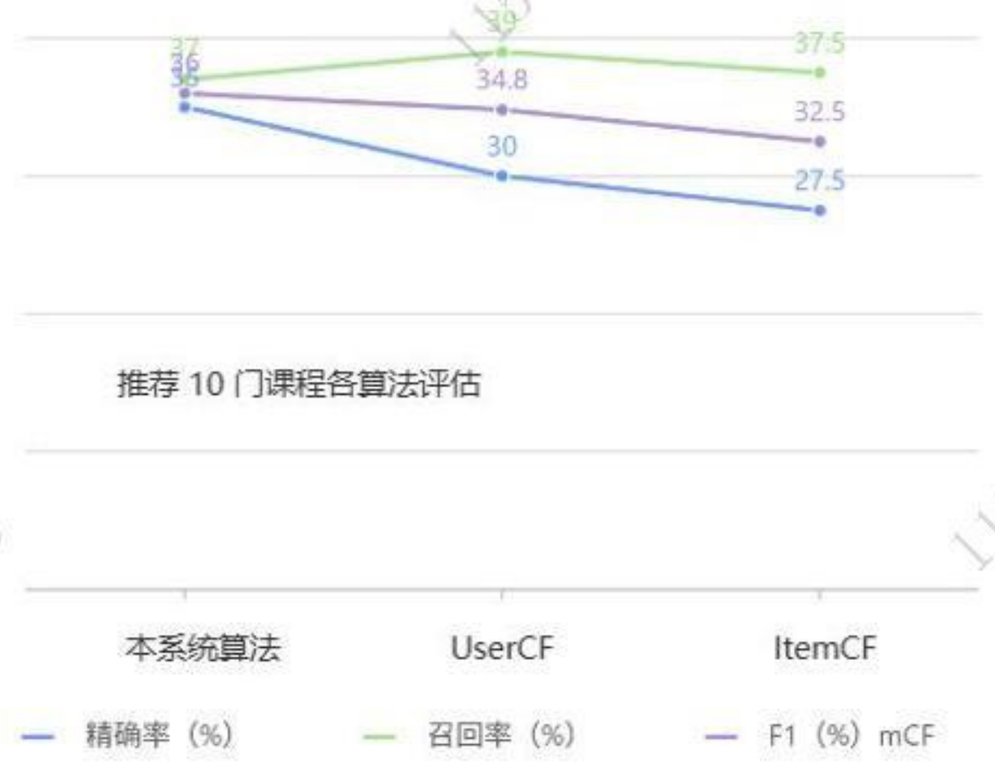


图 6-8 推荐 10 门课程各算法评估对比

Fig.6-8 Evaluation and Comparison of Various Algorithms

4）业务需求适配

结合实验结果和业务的需求分析：在推荐 5 门学习课程时，学员的选择程度低，难满足跨领域学习需求；推荐 10 门课程时，系统精确率与召回率更均衡，既能保证推荐质量，又能提升覆盖能力，更契合课程推荐系统实际应用诉求。

7 结论与展望

7.1 工作总结

本研究聚焦在线教育领域学员分群与个性化推荐的核心需求，针对传统数据分析系统在聚类精度、特征利用效率、推荐与处理性能等方面的不足，开展系统性的算法优化与系统构建工作，形成从理论改进到实际应用的完整研究闭环。

在算法层面，针对传统 Bi-KMeans 算法的缺陷，提出融合多策略的改进 Bi-KMeans 算法：通过 Canopy 预聚类动态确定最优簇数与初始质心候选集，解决 K 值主观选取问题；采用 Kmeans++策略优化初始质心选取，结合马氏距离替代欧氏距离以消除特征关联性影响，提升相似度计算精度；引入 Ball-Tree 超球体结构加速簇中心更新，并对聚类效果较差的簇实施合并，有效降低算法陷入局部最优的风险。最终，聚类时间较传统 Bi-KMeans 降低 3.2%，误差平方和（SSE）下降 5.1%，轮廓系数达 0.68，实现聚类效率与质量的双重提升。

在系统架构设计与实现层面，基于 Hadoop 生态搭建“数据采集-存储计算-分析应用”全链路系统：数据采集环节通过 Flume+Kafka 实现日志数据实时采集，结合 DataX 与 Maxwell 完成业务数据的全量与增量同步，保障多源异构数据的高效接入；数据仓库采用 Hive 五层架构，结合 DolphinScheduler 任务调度，将学员行为宽表构建时间从传统 ETL 的 8 小时缩短至 1.5 小时，实现数据从原始存储到主题聚合的有序流转；推荐功能模块基于优化后的聚类算法与“分群过滤－协同计算－内容修正”三级推荐模型，通过分群过滤缩小候选课程范围，协同计算采用改进余弦相似度聚焦簇内用户交互数据，内容修正通过 Jaccard 系数（阈值≥0.6）保障课程标签匹配度，最终推荐模型的 F1 得分较传统 ItemCF 算法提升 22%，显著优于 UserCF 与 ItemCF 算法；可视化模块基于 Superset 对接 MySQL，构建交易、用户、课程等多主题仪表盘，实现数据的直观呈现与交互分析。

系统测试结果表明，HDFS 读性能达 62.5MB/s、写性能 11.9MB/s，Hive 处理 1000 万条数据查询耗时 42.1 秒，百万级并发场景下，数据采集延迟≤50ms，各项性能指标均满足在线教育场景需求，有效为教育机构提供精准学员分群与个性化课程推荐，支撑精细化运营决策。

7.2 不足与改进

在此背景下，本项目也需要持续优化和完善。随着行业的迅猛发展，社会对教育领域的需求不断攀升。尽管本研究已取得阶段性成果，但平台在实际应用中仍存在可优化的空间。

首先，当前分析平台依托离线数据仓库构建，能够满足多数常规分析场景的需求。然而，随着平台业务规模的扩大，用户行为的实时分析需求日益凸显，用户对即时获取行为数据洞察的诉求愈发强烈。因此，需新增实时分析模块，以填补平台在实时性服务上的空白，解决传统离线架构无法支撑动态业务分析的问题，切实满足用户对实时性的核心需求。

其次，平台目前缺乏移动端报表展示功能。传统的仅依赖 PC 端的报表展示模式已难以适配灵活的办公场景。基于此，后续可规划开发移动端应用程序（APP），并实现与 FineBI 工具的对接，构建移动端报表查看与交互功能。此举将显著提升用户使用的便捷性，进一步优化整体用户体验，使数据决策突破设备与场景限制。

最后，平台尚未完善对数据质量的有效控制，无法对数据采集、处理和存储等环节出现的异常进行实时监测。一旦出现数据缺失、格式错误等问题，难以第一时间定位根源并采取修复与优化措施，可能影响后续分析结果的准确性。后期计划引入数据质量追踪系统，对数据全生命周期流程进行实时监测，详细记录各环节的数据完整性、准确性、一致性等质量指标，形成数据质量报告与异常告警机制，为数据质量的持续优化提供明确依据，保障分析结果的可靠性。

参考文献

[1] 李显峰, 杜朝, 李轩. 构建基于 5G 技术的智慧教育模式[J]. 信息与电脑(理论版), 2023, 35(01): 238-241.

[2] 蔡苏, 焦新月, 杨阳, 等. 5G 环境下的多模态智慧课堂实践[J]. 现代远程教育研究, 2021, 33(05): 103-112.

[3] 司俊勇, 付永华. 多模态数据融合的在线学习情感计算研究[J]. 图书与情报, 2024, (03): 69-80.

[4] 徐文涛. 融合属性偏好和降低稀疏度的协同过滤算法研究及应用[D]. 南京邮电大学, 2024.

[5] 王帅. 突发公共卫生事件情境下在线健康社区用户画像与分群研究[J]. 情报科学, 2022, 40(06): 98-107.

[6] 刘聪. 基于 Hadoop 的在线教育分析平台的设计与实现[D]. 华东师范大学, 2023.

[7] 秦燕. 基于大数据分析的在线课程学习行为数据标准设计[J]. 互联网周刊, 2023, (13): 84-86.

[8] 汪丽娟. Flink 下的 K-Means 优化并行与任务调度研究[D]. 新疆大学, 2019.

[9] 叶帅辰. 基于 Canopy-Kmeans++算法的网络威胁流量检测[J]. 信息技术与信息化, 2024, (07): 155-158.

[10] 李俊龙. 基于标签特定特征的多标签分类方法研究[D]. 合肥工业大学, 2022.

[11] 秦琴, 谷文军. ball tree 优化的自动驾驶仿真测试场景生成方法[J]. 计算机应用研究, 2023, 40(09): 2781-2784+2791.

[12] 王金坤. 基于协同过滤的个性化在线教育平台的设计与实现[D]. 厦门大学, 2022.

[13] Su X Y, Khoshgoftaar T M. A survey of collaborative filtering techniques[J]. Advances in Artificial Intelligence, 2009, 2009(421425): 1-19.

[14] 骆云云. 基于大数据分析的电商平台用户个性化推荐系统设计[J]. 信息与电脑, 2025, 37(07): 44-46.

[15] 翟浩然, 张三国. 引入集群效应的跨领域推荐新方法[J]. 中国科学院

大学学报(中英文), 2025, 42(02): 153-158.

[16] 张春燕, 谢鸿稳. 基于 Hadoop 离线分析技术的高校学生画像平台设计[J]. 软件, 2025, 46(05): 8-11+37.

[17] 胡雪洁. 基于 Hive 的电商数据分析平台的实现与应用[D]. 汕头大学, 2021.

[18] 杨森. 基于用户画像的智能在线教育平台的设计与实现[D]. 北京交通大学, 2024.

[19] 张磊. 基于 MOOC 在线教育数据的学生行为分析和成绩预测[D]. 浙江工商大学, 2023.

[20] Kizilcec R F, Piech C, Schneider E. Deconstructing disengagement: Analyzing learner subpopulations in massive open online courses[J]. Proceedings of the Third International Conference on Learning Analytics and Knowledge, 2013: 170-179.

[21] 韦艳. 大数据时代背景下计算机信息处理技术的效果分析[J]. 无线互联科技, 2025, 22(05): 98-101.

[22] 王凯. 基于智能教学平台多模态数据的教师画像研究[D]. 华中师范大学, 2024.

[23] 李浩, 王肇飞, 李微. 基于信息熵和 Canopy-K-Means 算法的货车驾驶风格识别[J]. 交通工程, 2024, 24(07): 123-128.

[24] 李玉学, 纪君, 董阳. 基于改进的 Canopy-k-means 的大跨屋盖表面风荷载分区方法[J]. 河北科技大学学报, 2024, 45(05): 530-538.

[25] 陈将宏, 胡佳慧, 时康昊, 等. 基于改进密度峰值优化全局 K-means 的风电典型场景聚类方法[J]. 国外电子测量技术, 2024, 43(12): 71-82.

[26] 倪萌萌, 李春树, 刘银. 基于粒子群优化 K-means 聚类算法的快递网点选址方法研究[J]. 宁夏工程技术, 2023, 22(02): 181-186+192.

[27] 陶志勇, 刘晓芳, 刘影, 等. 基于改进花朵授粉的 K-均值聚类算法[J]. 计算机应用研究, 2019, 36(11): 3253-3257.

[28] 李开福, 基于华为云平台的分布式信贷业务中台. 四川省, 泸州银行股份有限公司, 2024-05-29.

[29] 钱振宇. 基于深度神经网络的医学图像聚类算法研究与应用[D]. 江南大学, 2025.

[30] 于连敏. 聚类分析中 K-means 算法的改进及应用研究[D]. 山东科技大学, 2019.

[31] 武英. 基于 Canopy-Kmeans 算法的汽车客运订单调度研究[D]. 山西大学, 2020.

[32] 黄冠杰. 基于 Canopy-Kmeans 算法的电力企业流量数据分析研究[J]. 信息技术与网络安全, 2022, 41(01): 18-22.

[33] 周功建. 基于 Hadoop 平台 Canopy-Kmeans 聚类算法优化改进研究[J]. 安徽广播电视大学学报, 2018, (04): 117-122+128.

[34] 徐文进, 马越, 杜咏慧. 基于马氏距离和 Canopy 改进 K-means 的交通聚类算法[J]. 计算机与数字工程, 2024, 52(06): 1630-1635+1649.

[35] 雷雨霄. 基于改进 SSA-Kmeans 算法的网站用户分群研究[J/OL]. 电信科学, 1-12[2025-10-15].

[36] 刘泽京, 邬楠, 黄抚群, 等. 基于知识图谱与协同过滤混合策略的在线编程评测系统题目推荐模型[J]. 计算机科学, 2023, 50(02): 106-114.

[37] 曾彦雨. 基于深度学习的个性化在线课程推荐与管理研究[D]. 杭州师范大学, 2023.

[38] 张琳吝, 张亮. 在线教育平台的个性化学习资源推荐系统设计和实现[J]. 中国战略新兴产业, 2024, (08): 51-53.

[39] Zheng Z, Li Y, Chen J. LightNet: A lightweight model for head pose estimation in online learning[J]. Journal of Educational Technology & Society, 2025, 28(2): 112-123.

[40] Yan Z, Zhicui Y, Jian W. The Influence of Academic Self-Efficacy on Learning Engagement in Online Education in China: The Mediating Role of Effort[J]. Journal of Contemporary Educational Research, 2024, 8(10): 61-68.

[41] Arifin M, Nizar A M, Khusnuridlo M. Acceptance and use of technology in online learning in higher education: A student perspective[J]. Journal of Education and E-Learning Research, 2025, 12(1): 104-114.

[42] T. S, S. T S. NOVEL CBIR System Using Spark MAP-Reduce with a Firefly Macqueen's K-Means Clustering Algorithm[J]. IETE Journal of Research, 2023, 69(10): 6955-6969.

[43] Arthur D, Vassilvitskii S. k-means++: The Advantages of Careful Seeding[C]//Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA), 2007: 1027-1035.

[44] Ma Y, Cheng W. Optimization and Parallelization of Fuzzy Clustering

Algorithm Based on the Improved Kmeans++ Clustering[J]. IOP Conference Series: Materials Science and Engineering, 2020, 768(7): 072106.

[45] Zhang R. Improve Threshold Range of Canopy Clustering Using Optimization Algorithms[J]. Asian Journal of Research in Computer Science, 2024, 17(12): 148-164.

[46] Gouic L T, Paris Q. A notion of stability for k-means clustering[J]. Electronic Journal of Statistics, 2018, 12(2): 4239-4263.

[47] Madan S, C K, Bhatia K M, et al. An optimized SVM-RFE based feature selection and weighted entropy K-means approach for big data clustering in mapreduce[J]. Multimedia Tools and Applications, 2024, 83(30): 74233 -74254.

[48] Wang X, Li H, Zhang J. Multi-threaded PSO-Kmeans based on MapReduce[J]. Cluster Computing, 2024, 27(3): 1895-1910.

[49] Zhang D, Shou Y, Xu J. An improved parallel K-means algorithm based on MapReduce[J]. Int. J. of Embedded Systems, 2017, 9(3): 275-282.

[50] Bagdaoui M, Hamdaoui M, Ben Abdallah A. Improved K-means algorithm for MRI brain tumor detection[J]. Journal of Medical Systems, 2024, 48(4): 32.

[51] Mageshwari D, Thenmozhi M. Enhanced K-means clustering for HIV-related social media data analysis[J]. Social Network Analysis and Mining, 2024, 14(1): 21.

[52] Chinnakannan M, Krishnan S. K-means based parameter evaluation for medical equipment quality control[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-10.

[53] Moore A W. Ball trees for nearest neighbor search in high dimensional data[C]//Proceedings of the 1990 Conference on Advances in Neural Information Processing Systems. 1990: 613-620.

[54] Sims R. Learning management system usage in South African universities during COVID-19[J]. Higher Education, 2025, 89(3): 789-805.

[55] Kessler J. Faculty and student perceptions of online education technology [J]. Journal of Higher Education, 2025, 96(2): 210-230.

[56] 刘瀛. 面向大数据的软件设计模式与应用实践[J]. 软件, 2024, 45(11):

17-19.

[57] 吕申瑜. 信息技术在城乡规划与智慧城市建设中的应用[J]. 城市建设理论研究(电子版), 2025, (20): 16-18.

[58] 曾萍, 韦杰. 数据仓库技术在高校信息化建设中的应用研究[J]. 软件, 2014, 35(05): 108-110.

[59] 张扬武, 李国和. 大数据认知实践教学改革研究[J]. 大学教育, 2024, (04): 29-32.

[60] 田世杰, 张一名. 机器学习算法及其应用综述[J]. 软件, 2023, 44(07): 70-75.

[61] 周峰. 基于改进 Bi-Kmeans 聚类算法的人才画像系统的研究与实现[D]. 南昌大学, 2024.

[62] 李时杰, 孙卫红, 梁曼, 等. 基于 CD-YOLO 算法的蚕茧种类识别[J]. 中国计量大学学报, 2021, 32(03): 398-405.

[63] 朱愈, 张耘. 融合 Canopy 的 K-means 算法在电力设备故障检测中的应用研究[J]. 自动化与仪器仪表, 2024, (04): 62-66.

[64] 桑茂森. 面向主动防御框架的恶意流量检测系统检测与实现[D]. 北京邮电大学, 2025.

[65] 吴宪传, 吴绍荣, 颜远海. 基于大数据的电商数据仓库可视化平台的设计与实现[J]. 现代计算机, 2023, 29(21): 61-70.

[66] 孙志其. 基于 Hadoop 离线分析技术的高校学生画像平台研究及应用[D]. 太原师范学院, 2023.

[67] 熊宵. 基于容器云的在线教育推荐系统的设计与实现[D]. 电子科技大学, 2023.

致　谢

回顾写论文的过程，最想感谢的是我的老师。从选题构思时的方向指引，到初稿完成后的细致审阅，再到细节修改处的精准建议，导师总能在第一时间解答我的疑惑，并纠正我理论方向的偏差。正是得益于老师的悉心指导和批注，我的论文才可以顺利完成。唯愿吾师工作顺遂，身体康健！

最温暖的支撑来自家人。两载读研时光，我常因工作与学业的忙碌，疏于陪伴家人。是父母的理解与包容，爱人的支持与分担，让我得以无后顾之忧地追逐学业梦想。惟愿吾亲平安康健，喜乐常伴！

凡是过往，皆为序章。这段在职读研的经历，不仅是学术生涯的一段圆满，更是未来人生的全新起点。今后，我会带着这段时光里收获的知识、勇气与温暖，在工作与生活中继续前行，不负韶华。

作者简历及在学研究成果

一、主要教育经历/工作经历（从大学起，到硕士入学止）

起止年月	学习或工作单位	备注
2013 年 09 月至 2017 年 06 月	在兰州理工大学计算机科学与技术专业攻读学士学位	

二、在学期间从事的科研工作

无

三、在学期间所获的科研奖励

无

四、在学期间发表的论文

无

独创性说明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作者签名：张天 日期：2025 年 12 月 25 日

备注：提交时须有作者亲笔签名！

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：张天　导师签名：王子龙　日期：2025 年 12 月 25 日