密　　级：_____

加密论文编号：_____

论文题目：金融产品推荐系统的实现与可视化分析

学　　号：M202340085

研　究　生：李东瀚

专 业 名 称：软件工程

2025 年 12 月 20 日

115.25.60.50

金融产品推荐系统的实现与可视化分析

Implementation and Visual Analysis of Financial Product Recommendation System

研究生：李东瀚

指导教师：王昭顺

北京科技大学数理学院

北京 100083，中国

Master Degree Candidate：Donghan Li

Supervisor：Zhaoshun Wang

School of Mathematics And Physics

University of Science and Technology Beijing

30 Xueyuan Road，Haidian District

Beijing 100083，P.R.CHINA

115.25.60.50

中图分类号：　　学校代码：10008
U　D　C：　　密　　级：公开

北京科技大学硕士学位论文

论文题目：金融产品推荐系统的实现与可视化分析

作者：李东瀚

指 导 教 师：王昭顺　单位：北京科技大学　职称：教授

指导小组成员：　　单位：　　职称：

　　单位：　　职称：

论文提交日期：2025 年 12 月 20 日

学位授予单位：北 京 科 技 大 学

115.25.60.50

摘 要

随着金融行业数字化转型的持续推进，金融产品推荐系统在提升客户服务质量、增强用户黏性和促进交叉销售等方面具有重要作用。然而，由于金融数据具有高维度、稀疏性、动态变化等特征，传统推荐算法如协同过滤和关联规则挖掘在实际应用中往往面临准确率低、实时性差、可解释性弱等问题。针对这些挑战，本文本文提出一种融合多源结构化特征的混合推荐模型，该模型集成关联规则挖掘、用户画像构建与深度学习排序技术，显著提升了推荐的精度和实用性。

具体而言，本文首先采用改进的 Apriori 算法——基于 FP 树的频繁项集挖掘方法，高效识别金融产品之间的关联关系，生成高质量的产品组合规则。其次，利用 C4.5 决策树算法对用户进行多维度分群，构建包含价值、行为、风险、潜力四类特征的动态用户画像体系，将客户划分为 8 种类型，实现精准客群识别。最后，引入 FiBiNET 模型进行多目标 CTR 预估，通过 SENET 结构动态学习特征重要性，并结合双线性特征交互机制增强模型表达能力，最终实现对候选产品列表的智能排序。

实验部分基于真实金融场景脱敏数据，涵盖银保与财产险等多类产品交易记录。结果表明，本文提出的融合模型在 AUC 和排序损失等指标上显著优于基线方法，其中 CTR 提升 27.6%，转化率提高 34.2%，高价值客户留存率提升 14%。此外，本文设计并实现了一套基于 ELK 技术栈的可视化分析系统，具备实时日志采集、分布式存储与高效检索能力，支持推荐结果的多维度可视化展示与交互分析，有效提升了系统的可解释性与运维效率。具备较强的实际应用价值，为金融科技领域的智能推荐系统提供了完整的解决方案与实践参考。

关键词：金融产品推荐；关联规则；决策树；点击率预估；可视化系统

Implementation and Visual Analysis of Financial Product Recommendation System

ABSTRACT

With the continuous advancement of digital transformation in the financial industry, financial product recommendation systems play a crucial role in enhancing customer service quality, strengthening user loyalty, and promoting cross-selling. However, due to the characteristics of financial data, such as high dimensionality, sparsity, and dynamic changes, traditional recommendation algorithms, such as collaborative filtering and association rule mining, often encounter issues of low accuracy, poor real-time performance, and weak interpretability in practical applications. To address these challenges, this paper proposes a hybrid recommendation model that integrates multi-source structured features. This model combines association rule mining, user persona construction, and deep learning ranking techniques, significantly improving the accuracy and practicality of recommendations.

Specifically, this paper first employs an improved Apriori algorithm, a frequent itemset mining method based on FP trees, to efficiently identify the association relationships between financial products and generate high-quality product combination rules. Secondly, it utilizes the C4.5 decision tree algorithm to perform multi-dimensional clustering on users, constructs a dynamic user portrait system encompassing four types of features: value, behavior, risk, and potential, and divides customers into eight types to achieve precise customer group identification. Finally, the FiBiNET model is introduced for multi-objective CTR prediction. The SENET structure dynamically learns feature importance and combines a bilinear feature interaction mechanism to enhance the model's expressive power, ultimately achieving intelligent sorting of candidate product lists.

The experimental part is based on desensitized data from real financial scenarios, covering transaction records of various types of products such as bancassurance and property insurance. The results show that the fusion model proposed in this paper significantly outperforms the baseline method in terms of

AUC and ranking loss, with a 27.6% increase in CTR, a 34.2% increase in conversion rate, and a 14% increase in high-value customer retention rate. In addition, this paper designs and implements a visual analysis system based on the ELK technology stack, which possesses real-time log collection, distributed storage, and efficient retrieval capabilities. It supports multi-dimensional visual display and interactive analysis of recommendation results, effectively enhancing the interpretability and operational efficiency of the system. It has strong practical application value and provides a complete solution and practical reference for intelligent recommendation systems in the field of financial technology.

Key Words: Financial product recommendation; Association rule;decision tree;Click-through rate estimation;visualization system

目 录

摘 要 I
ABSTRACT II
1 绪论 1
1.1 研究背景 1
1.2 研究意义 2
1.2.1 学术价值 3
1.2.2 应用价值 4
1.3 研究内容 5
1.4 论文结构安排 7
2 关键技术概述 8
2.1 关联原则算法 8
2.1.1 Apriori 算法的简介 8
2.1.2 Apriori 算法的构建流程及概念 9
2.1.3 Apriori 算法的应用 10
2.2 CTR 点击率预估算法 11
2.2.1 CTR 点击率预估算法的简介 11
2.2.2 CTR 点击率预估算法的关键组件 12
2.3 独热编码技术 13
2.3.1 独热编码技术简介 13
2.3.2 技术原理与数学模型 13
2.4 决策树算法 14
2.4.1 决策树算法的简介与构建 14
2.4.2 决策树算法的剪枝技术 15
2.5 本章小结 17
3 需求分析 18
3.1 系统需求概述 18
3.2 系统功能需求 19
3.2.1 关联原则算法的隐性需求挖掘模块需求 19
3.2.2 基于决策树算法的用户画像模块需求 20
3.2.3 融合 FiBiNET 的多目标 CTR 预估模块需求 21
3.3 系统管理需求 22

3.3.1 客户端.....22
3.3.2 日志实时采集.....23
3.3.3 长文本处理.....24
3.3.4 实验数据管理.....25
4 系统功能模块设计与实现.....27
4.1 系统功能模块设计.....27
4.2 基于关联原则算法的隐性需求挖掘模块.....28
4.2.1 Apriori 与 FP-Apriori 算法流程概述.....28
4.2.2 基于 FP-Apriori 算法的产品频繁集构建.....29
4.3 基于决策树算法的用户画像模块.....33
4.3.1 用户分群分析与设计.....33
4.3.2 用户画像的构建.....34
4.4 融合 FIBINET 的多目标 CTR 预估模块.....39
4.4.1 特征提取与加强.....39
4.4.2 预估模块的实现.....41
4.5 本章小结.....43
5 系统管理功能的设计与实现.....45
5.1 客户端.....45
5.2 日志实时采集模块设计与实现.....46
5.3 长文本处理模块设计与实现.....52
5.4 分布式数据库设计与搭建.....55
5.5 本章小结.....58
6 系统测试.....59
6.1 实验环境.....59
6.2 功能测试.....59
6.3 接口测试.....64
6.3.1 测试方案.....64
6.3.2 测试结果.....65
6.4 性能测试.....65
6.4.1 评价指标.....66
6.4.2 数据准备.....67
6.4.3 结果与分析.....68
6.5 本章小结.....70
7 结论与展望.....71

7.1 结论 71
7.2 创新点 71
7.3 展望 72
参考文献 75
致　谢 80
作者简历及在学研究成果 81
独创性说明 82
关于论文使用授权的说明 83
学位论文数据集 84

1 绪论

本章引言将围绕金融产品推荐系统的研究背景与意义，结合国内外研究现状，对主要的研究内容及本文文章结构进行系统性阐述。

1.1 研究背景

在数字化浪潮席卷全球的当下，金融行业正经历着深刻变革，这一变革在我国“十四五”规划的宏伟蓝图中得到了清晰映照与有力指引。在国家“十四五”规划期间，我国开启全面建设特色社会主义现代化的新目标，在金融领域进行信息化建设成为推动经济高质量发展、提升金融服务效能、防范金融风险的关键环节、重要抓手。而银行业与保险业作为金融体系的重要支柱，其信息化进程也备受关注。在《金融标准化“十四五”发展规划》中明确指出，要进一步拓展升级保险市场标准，稳步推进完善金融科技标准的建设，系统性完善金融数据要素标准等[1] 。

随着金融科技的快速发展和数字化金融服务的普及，金融产品种类日益丰富，用户在面对存款、理财、保险、基金、信贷等众多金融产品时，普遍面临“选择困难”的问题。另一方面，金融机构也希望通过更精准的产品推荐，提升用户转化率、增强客户黏性，并实现交叉销售与向上销售。在此背景下，智能金融产品推荐系统逐渐成为连接用户与金融机构的重要桥梁，其研究与实施具有重要的理论价值与现实意义。

目前国外金融业金融产品推荐算法的研究现状，正从传统模型快速向深度学习等更复杂的范式演进，核心驱动力是处理金融数据特有的时间敏感性、用户决策精准化及化解冷启动问题。涌现出一批较为经典的算法，如多臂老虎机(MAB)、汤普森采样等具有代表性的推荐算法。

传统的推荐系统多基于协同过滤、内容过滤或混合推荐方法，在电商、视频、新闻等领域已取得显著成效[1]-[3] 。然而，金融产品具有高价值、高风险、强监管、长周期等特殊性，其推荐过程不仅需考虑用户偏好，还需兼顾风险匹配度、合规性、实时市场变化等多维因素。此外，金融数据通常具有高度敏感、稀疏、异构等特点，也加大了推荐系统构建的难度。

目前，国内多数金融机构仍依赖规则引擎或简单逻辑进行产品推送，缺乏真正的个性化与智能化能力。尤其在面对多源异构数据如用户行为数据、资产数据、风险测评数据、市场数据等时，系统往往难以实现深度融合与动

态推理，导致推荐效果不佳、用户满意度低，甚至引发合规风险。

关联原则算法、点击率预估等算法作为推荐算法的重要理论基础之一，旨在挖掘数据中各项事务之间的关联关系。在金融产品推荐场景中，它能够发现不同金融产品之间的潜在联系，以及客户购买行为之间的相关性。例如，通过关联原则算法分析发现，购买了某款股票型基金的客户，往往有较大概率同时关注或购买相关的保险、理财产品。然而，传统的关联原则算法在应用于金融产品推荐时，受限于金融数据的高维度、稀疏性以及动态变化性等特点，存在推荐准确率不高、时效性差、难以适应复杂多变的金融市场环境等问题。面对政策驱动的数字化转型和数据驱动的业务模式创新的双重挑战下，金融产品推荐算法其发展呈现出从基础统计分析向智能化、场景化、系统化、叠加化应用的转变。

因此通过合理设计金融产品推荐系统并引入算法模块，提高推荐的精准性和时效性，为了更好地满足客户个性化的金融需求，并助力金融机构在日益竞争激烈的市场中脱颖而出；[1] 借助可视化分析，将复杂的推荐结果和算法性能以直观易懂的方式呈现给金融从业者和客户，从而提升在决策中的透明度和科学性，进而促进金融业的可持续发展。

1.2 研究意义

推荐系统作为信息过滤的关键技术，自 20 世纪 90 年代以来已发展出多种经典方法，如基于用户的协同过滤、基于物品的协同过滤、矩阵分解等。近年来，随着深度学习技术的兴起，神经协同过滤、图神经网络、序列推荐模型等逐渐成为研究热点[4] 。

在金融领域，推荐系统的应用仍处于起步阶段，但已引起广泛关注。现有研究主要集中在以下几个方面：

（1）基于传统方法的金融推荐：早期研究多采用逻辑回归、决策树等机器学习方法，结合用户画像与产品特征进行匹配。这类方法虽可解释性强，但特征工程复杂，且难以捕捉非线性关系与动态变化。

（2）基于深度学习的推荐模型：近年来，部分研究尝试将深度学习引入金融推荐中，如使用 DNN 处理用户行为序列，或利用注意力机制捕捉关键特征。然而，这些方法往往忽略金融产品之间的关联性与用户决策的时序依赖性。

（3）基于图模型的推荐方法：图神经网络能够自然地表征用户与产品、产品与产品之间的复杂关系，已在社交推荐、电商推荐中表现出色。在金融

场景中，图结构可用于构建用户-产品交互图、产品关联图等，但相关研究仍较少，尤其是在多关系、动态图建模方面尚存空白。

（4）可解释性与合规性：金融推荐系统不仅需保证推荐准确性，还需具备良好的可解释性，以满足监管要求与用户信任。现有方法多依赖事后解释，缺乏融入模型本身的可解释机制[5] 。

总体而言，当前金融产品推荐系统在数据融合、动态推理、可解释性等方面仍存在明显不足，亟需引入更先进的建模方法与系统架构，以应对金融场景下的特殊挑战。

1.2.1 学术价值

传统 Apriori 关联推荐算法需多次扫描数据集，计算复杂度高，难以适应金融场景的实时性需求。通过压缩存储和扫描优化，并引入预处理模块，可显著提升效率，但其内存消耗仍制约大规模金融数据的应用，使得算法存在一定的局限性，部分场景使用受限，例如虽然可以通过算法推断出随车行李险和人身意外险两种产品存在某种关联关系，但将产品不分人群特征，盲目推销，明显会降低成功率，不同用户群体的购买意愿与其关联产品集的关系依旧模糊。

对于推荐算法中协同过滤算法依赖用户历史行为数据，存在冷启动问题，如果是新用户或新产品缺乏交互记录[4] ，此时算法的性能出现波动，且难以解释推荐逻辑，也是我们常说的“黑箱效应”。基于产品属性与用户特征的推荐算法虽可解释性强，但仅依赖产品属性匹配，无法挖掘隐性关联，如某用户在购买基金 A 后，其实也可能存在偏好保险 B 的跨品类规律。

目前金融产品推荐系统的算法需求多建立在深刻的业务理解基础上，需要同时满足精准性、可解释性、实时性和合规性等多重目标[2] 。精准性要求算法能够准确捕捉用户偏好和产品特性，提供高度个性化的推荐结果，具体体现在点击率、转化率等核心指标上的显著提升。可解释性在金融领域尤为重要，算法不仅要给出推荐结果，还需要提供清晰的推荐理由，包括基于哪些特征、符合哪些规则等，以满足监管要求和用户信任需求。

实时性需求体现在两个层面：一是模型更新实时性，要求系统能够快速适应用户行为变化和市场动态；二是推理实时性，推荐接口需要在毫秒级别返回结果，确保用户体验。合规性需求要求算法符合金融监管规定，避免推荐不合适的产品，特别是风险等级不匹配的产品，同时需要建立完善的审计追踪机制。

算法架构需要支持多目标优化，不仅要考虑短期转化指标，还要关注用户长期价值、风险控制和平台生态健康。模块化设计使得各个算法组件能够独立演进和优化，同时保持系统的整体性和协调性。扩展性需求要求算法框架能够方便地集成新的数据源、特征和模型，适应业务快速发展变化。

传统关联规则算法在金融场景中的局限性较多，耦合性不高，存在高维稀疏性、动态时序性、规则冗余性等诸多问题，在理论上完善金融产品推荐算法研究体系，在实践中帮助金融机构提高推荐准确性、增加用户满意度与忠诚度，提升业务绩效，为助推金融科技稳步向前提供坚实基础。

改进关联规则算法以适配金融数据特征，适应复杂的生产环境使其得到更好的应用，具有一定学术价值[6] 。

1.2.2 应用价值

我国的金融行业相较建国初期已经有了非常大的发展，但是我国金融行业仍然存在信息化程度不高等问题，在国家新的一轮十四五规划中，国家金融管理局对银行保险行业的发展提出了新的要求、做出新的规划，于 2022 年 5 月，银保监会面向保险业等金融企业下发《保险业标准化“十四五”规划》，在规划中要求，以 2025 年为期，要进一步完善金融保险业标准化的工作机制，完善并确立效用突出、覆盖全面、结构清晰的金融保险行业标准体系。以大型国有保险公司为例，目前国内保险深度（保费/GDP）约 3.9%，保险密度、人均保费约 3327 元，仍低于 7%深度、约 700 美元密度的全球平均水平[7] 。在实际的销售场景中由于购买保险的人群多集中于线下，而在线下的推荐场景中又多依赖于销售人员，目前保险行业在推荐产品的时候依旧延用传统的产品推荐方式，由此可见在信息化，智能化的今天作为产品销售为王的行业，实现产品推荐优化算法的实现与可视化分析，嵌入生产系统具有现实意义。

研究可通过数据压缩、分布式计算等技术进一步优化，为高频交易数据的实时处理提供支持。此外如图 1-1，金融推荐需平衡规则质量与业务价值：传统指标支持度、置信度无法直接映射业务目标，需通过特征扩充和特征叠加等手段，比如引入提升度 Lift 等指标筛选有效规则，避免“虚假关联”如高置信度但低提升度的规则误导推荐策略，结合传统模型还可延伸至风险管理、客户分群等领域[8] 。

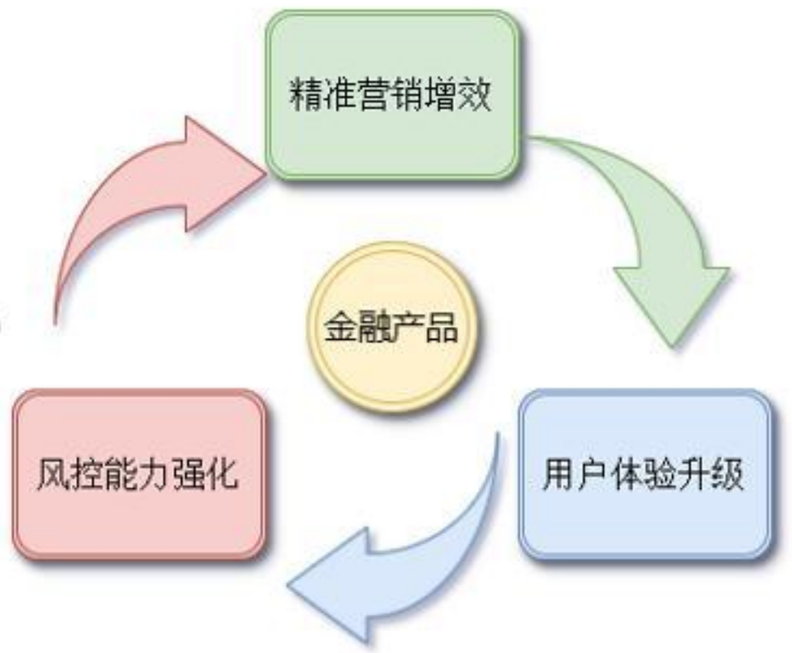


图 1-1 算法应用价值

Fig.1-2 The application value of algorithms

精准营销增效：通过可视化系统展示产品关联网络，帮助业务人员识别高价值规则，如“购买养老基金的客户常配置终身寿险”，制定组合营销策略，预计可提升交叉销售转化率 15%-20%。基于用户画像年龄、健康数据等生成个性化保险方案。据用户风险评级和收益目标推荐金融产品。

风控能力强化：嵌入风险匹配度约束，避免违规推荐，如向保守型用户推荐股票型基金，降低监管投诉率。金融场景用户行为低频，需结合算法特性，应对数据稀疏性等问题带来的影响[9] 。

用户体验升级：实时交互的可视化界面如关联动态看板可增强用户参与感，提升服务满意度。

帮助金融机构实现精准交叉销售，提升客户粘性，研究的推进，可以为金融科技稳步向前打下坚实基础。

1.3 研究内容

本文围绕金融产品推荐系统中“精准推荐与可解释服务”的核心需求，开展了基于多模态特征融合的推荐算法设计与可视化分析系统研究，聚焦于两个关键技术方向：高可扩展的混合推荐算法框架构建与面向实时场景的可视化分析系统的设计与实现，整体研究内容框架重点解决以下两个问题[10]-[11] ：

研究内容一：如何构建支持多源异构数据融合与高可解释性的混合推荐算法架构

在金融机构普遍面临的“海量用户行为数据+稀疏交易反馈”的业务背景下，金融产品推荐场景面临数据维度高、特征稀疏、用户行为低频、监管可解释性要求强等多重挑战。传统推荐算法如协同过滤、矩阵分解等存在冷启

动明显、忽略产品关联性、推荐逻辑不透明等问题，难以支撑高合规要求的金融产品智能化推荐。

为此，本文在典型推荐系统基础架构上，设计并实现了一种融合关联规则、用户画像与深度学习排序的混合推荐模型。该系统在继承经典推荐流程中用户特征提取、产品检索与排序等基础模块的基础上，针对金融数据高稀疏和强时序的特点，进行了特征重构与算法整合，以适配多目标学习与实时推理的工程需要。同时，扩展了基于关联规则的产品频繁项集挖掘模块和决策树用户分群模块，支持产品组合挖掘与用户群体细分，为排序模型提供可解释的结构化特征[12] 。

为应对高维稀疏特征下的模型表达与效率瓶颈，本文提出“频繁模式挖掘 + 用户画像 + 深度排序”的三阶段推荐架构，将产品协同关系与用户静态属性分别进行结构化提取，通过特征交叉层与 FiBiNET 网络进行高阶特征交互与重要性加权，最终输出融合业务规则与隐式偏好的推荐结果列表。该架构在保持推荐精度显著提升的同时，增强模型的可解释性与业务适配性，特别适用于保险、理财等强合规性金融产品的推荐场景[13] 。

研究内容二：如何实现推荐过程的可视化分析与系统行为的多维度追溯

在混合推荐架构下，系统需处理用户实时行为、产品属性、关联规则、画像标签等多源数据流，并应对推荐结果可解释、模型迭代可追溯、运营决策可干预等实际运营需求。传统推荐系统缺乏对推荐逻辑和用户反馈的透明化展示与交互分析机制，难以支持业务人员理解模型决策、定位推送偏差与优化推送策略。

本文设计并开发了一套基于 ELK 技术栈的可视化分析平台，实现对推荐全链路的实时监控、多维检索与交互分析[14] 。该系统将用户点击、购买、曝光等行为日志实时采集至 Elasticsearch 集群，通过 Kibana 进行多维度可视化展示；同时构建推荐追溯模块，支持基于用户 ID、产品 ID、会话 ID 等关键字段快速检索单次推荐所触发的规则、特征与模型得分细节。在此基础上，引入决策路径可视化组件，将 C4.5 用户分群树、Apriori 关联产品集以图结构进行渲染，并支持业务人员沿特定路径下钻分析群体偏好与产品组合效应[15] 。

实际应用表明，该可视化系统可在秒级时间内响应复杂查询请求，输出用户推荐决策的可解释报告与传播路径图，显著提升运营团队的决策效率与模型审计能力。系统特别适用于交叉销售效果分析、高风险产品推送监控、用户群体偏好迁移追踪等业务场景，为推荐策略迭代与产品运营优化提供数据支持和可视化能力支撑。

1.4 论文结构安排

本论文共分为七章：

第一章介绍了本文的研究背景及研究意义，并阐述了研究的学术价值和应用价值，对实验所面临的问题做出初步的简述。

第二章介绍了文章所引用和借鉴学习的相关文献，并站在时代的发展和政策需求的角度，回首关联原则及相关推荐算法发展的过去与当前国内外算法研究的进展，着重分析了 Apriori 算法、CTR 点击率预估算法、独热编码、决策树算法、可视化系统架构等算法及技术手段在研究中的应用与发展前景，为进一步推动研究提供核心支撑。

第三章通过对系统的需求分析，梳理系统所需的功能需求和管理需求，为接下来的系统设计与实现提供支撑。

第四章设计金融产品推荐系统的功能模块,架构设计思路为自上而下的设计思路，可分为表示层、服务层、数据访问层、数据存储层主要包括数据处理、算法计算和推荐服务三个核心维度。

第五章设计金融产品推荐系统的系统管理模块，通过设计数据库，并针对算法的可持久化，可追溯性配套、可实施性设计相关配套模块，确保算法在生产环境中的稳定运行。并构建可视化系统，进行可视化分析，本文依托 ELK 分布式日志采集技术和分布式数据库支持实时搜索、数据可视化和分析。

第六章系统测试工作。通过对系统的测试工作，证明该系统能满足为用户推荐心仪产品的功能与性能需求，系统功能和算法性能测试结果均符合预期。

第七章介绍了研究的结论与展望，本章系统性总结在实验中的发现与存在的局限性，为以后的研究理清思路提出可能，对算法在金融领域中的发展趋势进行思考和展望。

2 关键技术概述

关于推荐系统的研究，最早可以追溯至 1992 年，由 Goldberg 等人提出的 Tapestry 系统，在该系统中研究者首次引入了有关协同过滤的概念。Resnick 和 Varian 在 1997 年正式定义了推荐系统的概念，将其描述为“利用用户对物品的评价预测用户对其他物品喜好程度”的系统[16] 。

进入 21 世纪后，推荐系统研究经历了三个主要发展阶段：

传统算法阶段(2000-2009)：以协同过滤、基于内容的推荐和混合推荐为主，Netflix Prize 竞赛(2006-2009)推动了矩阵分解等技术的快速发展。

深度学习阶段(2010-2017)：深度神经网络开始应用于推荐系统，解决了传统方法在特征提取和非线性关系建模方面的局限。

非线性关系建模、多模态与强化学习阶段(2018 至今)：推荐系统开始整合多模态数据，并引入强化学习实现动态优化。

比如加州大学伯克利分校相关研究对高效频繁项集挖掘相关研究，改进的 FP-Growth 算法被用于处理金融交易流数据，提升实时性。也有剑桥大学团队提出将 Apriori 算法与神经网络结合，识别高频交叉销售组合（如信用卡+旅行保险）的关联规则与深度学习融合的尝试。对于稀疏数据处理针对金融场景低频交易问题，提出了加权关联规则（Weighted Association Rules），通过用户价值权重调整规则重要性[17] -[18] 。

2.1 关联原则算法

2.1.1 Apriori 算法的简介

关联规则挖掘是数据挖掘领域中的重要研究方向，其核心目标是从事务型数据中发现项集之间有趣的关联或相关关系。该技术源于超市购物篮分析的需求，通过发现商品之间的购买关联关系，为商品陈列、促销策略制定提供数据支持。随着技术的发展，关联规则挖掘已广泛应用于金融、医疗、教育等多个领域，成为智能推荐系统的重要技术基础。关联原则算法在国外部分国家被广泛应用于产品推荐如，最初提出关联规则的动机是针对购物篮分析(Market Basket Analysis)问题提出的[19] 。假设分店经理想更多的了解顾客的购物习惯。而关联规则的经典案例——啤酒与尿布，则是发生在美国沃尔玛连锁超市的真实案例：将尿布与啤酒这两种表面风马牛不相及的商品摆在

一起，却明显增加了这两种不相关商品的销售总量。原来，美国的妇女通常在家照顾孩子，所以她们经常会嘱咐丈夫在下班回家的路上为孩子买尿布，而丈夫在买尿布的同时又会顺手购买自己爱喝的啤酒。

2.1.2 Apriori 算法的构建流程及概念

Apriori 算法是第一个关联规则挖掘算法，Apriori 算法也是最经典应用最广泛的算法如图 2-1。它的核心思路是利用逐层搜索的迭代方法找出数据库中项集的关系，以形成规则，其过程由类矩阵运算连接和利用剪枝去掉那些没必要的中间结果两部分组成。该算法中项集的概念即为项的集合。包含 K 个项的集合为 k 项集。项集出现的频率是包含项集的事务数，称为项集的频率。如果某项集满足最小支持度，则称它为频繁项集。具体实现时，算法需要多次扫描数据库。在算法进行第一次扫描时，对各个项的支持度进行统计，而后生成频繁项集。在后续每次扫描中，都会基于前一次的结果生成候选项集，然后扫描数据库计算这些候选项集的支持度，最终确定频繁项集。在生成关联规则阶段，从频繁项集中提取所有可能的规则，并计算其置信度，选择满足最小置信度阈值的规则作为最终输出。

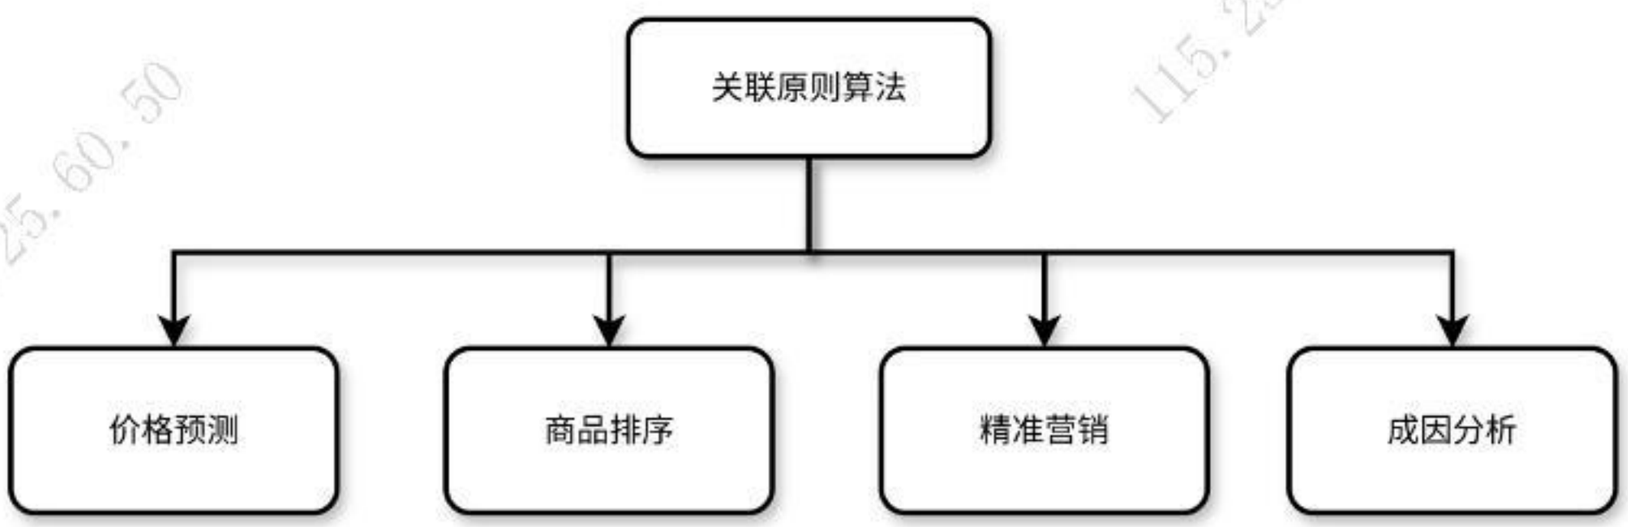


图 2-1 应用场景

Fig.2-2 Application scenarios

假设有 1000 条交易记录，其中有 100 条交易同时包含啤酒和尿布，假设有 100 条交易中有 30 条交易中包含了啤酒，其中有 10 条交易同时购买了尿布，计算支持度和置信度。

$$support(x,y) = P(xy) = \frac{number(XY)}{num(AllSamples)} \tag{2-1}$$

支持度可以表示为:支持度 (啤酒,尿布) = (啤酒和尿布同时出现的次数) / (总的交易记录数)，支持度=100/1000=0.1。

$$confidence(x \Rightarrow y) = P(y|x) = \frac{P(xy)}{P(x)} \tag{2-2}$$

置信度可以表示为:置信度 (啤酒 > 尿布) = (啤酒和尿布同时出现的次数) / (啤酒出现的次数)，置信度=10/30=0.33，通过计算支持度和置信度，可以得出结论:购买尿布的顾客中，有 10%的顾客也购买了啤酒，并且购买啤酒的顾客中有 33%的顾客也购买了尿布。

对于提升度可以表示为支持度和置信度二者的商。我们在做商品推荐或者风控策略的时候，重点考虑的是提升度，因为提升度代表的是 A 的出现，对 B 的出现概率提升的程度。对于以上例子啤酒的出现，提高了尿不湿的概率。

频繁项集：就是支持度大于等于最小支持度阈值的项集，所以小于最小值支持度的项目就是非频繁项集，而大于等于最小支持度的的项集就是频繁项集，项集可以是单个商品，也可以是组合如图 2-2。

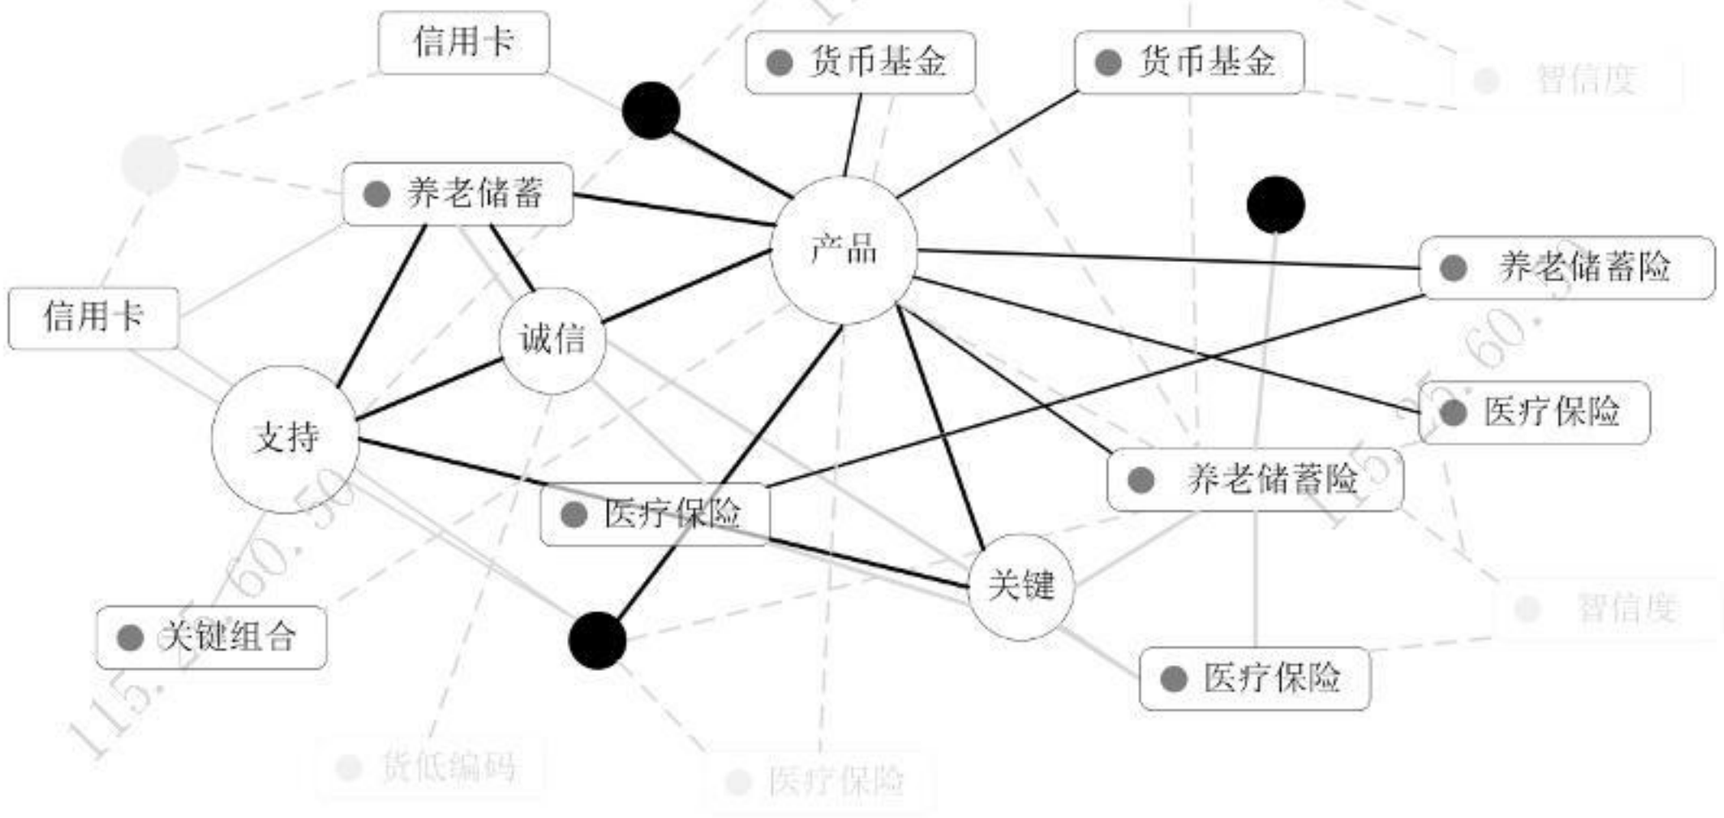


图 2-3 产品频繁集

Fig.2-2 frequent product releases

2.1.3 Apriori 算法的应用

在金融产品推荐场景中，关联规则挖掘具有重要价值。通过分析客户的交易数据，可以发现不同金融产品之间的关联关系，如购买了某款理财产品的客户很可能需要特定的保险产品，或者持有信用卡的客户对消费贷产品有较高需求。这些关联规则可以为交叉销售、精准营销提供数据支持。

然而，金融数据的特点给关联规则挖掘带来了特殊挑战。首先，金融交易数据具有高维稀疏特性，客户购买的产品数量有限，导致项集支持度普遍较低。其次，金融产品种类繁多，且更新迭代速度快，需要算法能够快速适应数据变化。此外，金融领域的关联规则需要具备良好的可解释性，以满足

监管要求和客户信任需求。

现实生产场景中关联规则挖掘技术在金融产品推荐中具有重要价值，但需要根据金融数据特点和业务需求进行适当的算法改进和参数优化，才能发挥最大效用。例如某商业银行应用改进的Apriori算法分析客户产品持有数据，发现了“信用卡+货币基金+消费贷”的强关联模式，支持度达到0.15，置信度为0.43，提升度为2.8。基于这一发现，银行优化了产品推荐策略，在信用卡申请流程中增加相关产品推荐，使交叉销售成功率提升了18%。另一个保险公司通过关联规则分析发现，购买车险的客户中有35%会在半年内购买人身意外险，据此制定了精准的营销时机策略，显著提高了营销转化率[10]-[11],[20]。

2.2 CTR 点击率预估算法

2.2.1 CTR 点击率预估算法的简介

点击率预估（Click-Through Rate Prediction）是在线推荐系统的核心组件，其本质是一个二分类问题，旨在预测用户对特定项目点击概率。在金融产品推荐场景中，CTR 预估转化为预测用户对特定金融产品产生兴趣的概率，这对提高转化率和用户满意度至关重要。

CTR 预估技术的发展经历了从传统统计方法到深度学习的重要演进。早期主要使用逻辑回归（LR）和梯度提升树（GBDT）等模型。2010 年，Rendle 提出的因子分解机（FM）通过隐向量内积建模特征交互，成为 CTR 预估的重要里程碑。

2016 年，Google 提出 Wide & Deep 模型，开创了深度学习在 CTR 预估中的应用。模型 wide 部分记忆低频特征模式，deep 部分泛化未知特征组合。随后出现的 DeepFM、NFM、AFM 等模型不断改进特征交互方式。

2017 年提出的 xDeepFM 引入压缩交互网络（CIN），显式地学习向量级特征交互。同年出现的 PNN（Product-based Neural Network）通过内积或外积操作增强特征交互。

FiBiNET 于 2019 年由新浪微博团队提出，通过 SENet 机制动态学习特征重要性，并结合双线性交互细化特征交互方式，在多个公开数据集上取得 state-of-the-art 效果。其在金融场景的适应性主要体现在：1、动态特征权重适应金融数据分布变化；2、双线性交互更好捕捉金融特征间复杂关系；3、模型可解释性满足金融监管要求[21]。

2.2.2 CTR 点击率预估算法的关键组件

CTR 数据的特征一般可以分为三大类：用户的特征、广告的特征和上下文特征。用户的特征包括用户性别、年龄、职业、教育水平等等；创意的特征包括广告的行业(旅游、电商，……)、标签等等；上下文的特征包括广告的位置、用户使用的设备、浏览器、时间、地点等。这些特征有一部分是连续的值，比如年龄；而更多的特征是 Category(类别)的特征，比如性别为两类的男女，职业可以是销售、产品经理、……[22] 。

CTR 预估的数学形式化定义为：给定特征向量 x，预测用户点击的概率 p = P(y=1|x)，其中 y∈{0,1}表示点击行为。传统逻辑回归模型使用 sigmoid 函数建模：p = 1/(1+exp(-w　x))，其中 w 为模型参数。然而，这种线性模型无法捕捉特征间复杂的非线性关系。

FiBiNET（Feature Importance and Bilinear feature Interaction NETwork）模型是 CTR 预估领域的重要突破，其核心创新在于动态特征重要性学习和细粒度特征交互建模。模型结构包含三个关键组件：

$$logloss = \sum_{i=1}^{N}\left[-y_i \log ctr\,(x_i) - (1-y_i)\log(1-ctr(x_i))\right] \quad (2\text{-}3)$$

其中 y 是真实的值(0/1)，而 ctr(x)是模型预测的点击率。

可以认为 FiBiNET 是在 wide & deep 模型的基础上对它的 wide 部分进行了一些创新的改进，或者直接视为 FNN 的一个变体。主要的创新点在于：在传统的 embedding stage 加入了一个 SENET 层对 embedding 特征升级为新的一种 embedding，得到与特征重要性（Feature Importance）相关的信息，将 SENet 输出和双线性交互输出拼接后，输入到多层全连接网络中，不使用传统的 inner product 或 Hadamard product 方法，而是选择了结合二者的一种新的 bilinear interaction 方法来获得特征之间的联系。最终通过 sigmoid 函数输出预测概率针对金融场景的特殊需求。

FiBiNET 有以下特性可供系统提升改进，可解释性要求：金融监管要求推荐决策可解释。FiBiNET 通过特征重要性权重提供一定可解释性，还可结合多种事后解释方法。同时设计规则引擎，确保推荐结果符合监管政策。多模态特征处理：金融数据包含结构化数据、文本数据（产品描述）、时序数据（交易记录）等多模态信息。

FiBiNET 模型通过其动态特征重要性学习和细粒度特征交互能力，能够有效适应金融推荐场景的复杂需求，在提升推荐效果的同时满足风险控制和可解释性要求。

2.3 独热编码技术

2.3.1 独热编码技术简介

特征编码技术的发展经历了从简单统计方法到深度学习表示的演进过程。早期主要依赖人工特征工程和统计编码方法。2003 年提出的均值编码开启了目标导向编码的新思路。2010 年左右，随着推荐系统的发展，矩阵分解技术中的潜在因子概念为嵌入编码奠定了基础。2013 年 Word2Vec 的成功证明了分布式表示的强大能力，推动了嵌入技术在各个领域的应用。2016 年，Google 提出的 Wide & Deep 模型将嵌入编码广泛应用于推荐系统，展示了深度学习表示的优势。随后出现的 Field-aware Factorization Machines 进一步细化了特征交互的编码方式。在金融领域的发展中，特征编码还需要考虑数据安全和隐私保护的要求。联邦学习中的加密编码、差分隐私等技术逐渐被引入，形成了适合金融场景的编码方案[23] 。

2.3.2 技术原理与数学模型

特征编码是机器学习流程中的关键预处理环节，其主要作用是将原始数据转化为适合算法处理的数值格式。在金融推荐场景下，通常需对以下类型特征进行编码：类别型（例如产品种类与用户职业）、数值型（如资产规模与交易金额）、时序型（例如最近交易时间）以及多值型（例如用户历史购买记录）。

标签编码（Label Encoding）是一种广泛用于类别特征的编码方法，它将每个类别映射为一个整数。例如，对于包含“健康型”、“债券型”、“理财型”、“存款型”、“风险型”等取值的金融产品特征，可依次编码从 0 到 4。该方法能够快速将非数值类别转换为数值形式，便于模型处理，具有实现简便和内存占用少的优点。在如树模型这类不依赖特征间距离度量的算法中，标签编码效果良好。然而，在涉及欧氏距离计算的模型（如线性模型或聚类算法）中，其局限性显著：原本语义上等距的类别（如“健康型”与“债券型”），在编码后对应的数值（0 与 1）之间的距离可能并不一致，从而引入偏差。

独热编码（One-Hot Encoding）是另一种处理类别特征的常用方法，能够有效缓解上述问题。仍以金融产品为例，五个类别可分别表示为：[1,0,0,0,0]、[0,1,0,0,0]、[0,0,1,0,0]、[0,0,0,1,0]和[0,0,0,0,1]。这样做确保了任

意两个类别之间的欧氏距离均保持一致，从而实现对类别特征的无偏编码。然而，该方法的缺点在于会显著扩展特征维度——类别取值数量即为新增的特征数，因此不适用于类别取值极多的场景，以避免维度灾难。

在深度学习领域，嵌入编码（Embedding Encoding）提供了一种更为高效的替代方案。该方法通过神经网络中的嵌入层，将类别变量映射为低维稠密向量。嵌入向量的维度可由人工设定，从而有效规避了独热编码引起的高维稀疏问题，特别适用于处理包含大量类别取值的特征。

此外，在金融应用中还存在一些特定的编码需求，例如对数值特征进行分桶编码：将连续变量（如年龄）划分为若干离散区间，如“[20,30)”、“[30,40)”等，以更好地捕捉其非线性影响。

2.4 决策树算法

2.4.1 决策树算法的简介与构建

决策树是一种监督学习的分类算法，目的是学习出一颗决策树，该树中间节点是数据特征，叶子节点是类别，实际分类时根据树的结构，一步一步根据当前数据特征取值选择进入哪一颗子树，直到走到叶子节点，叶子节点的类别就是此决策树对此数据的学习结果。其本质就是通过递归地将数据集分割成更小的子集，最终形成一个树形模型，用于预测新数据的输出。图 2-3 就是一颗简单的决策树：

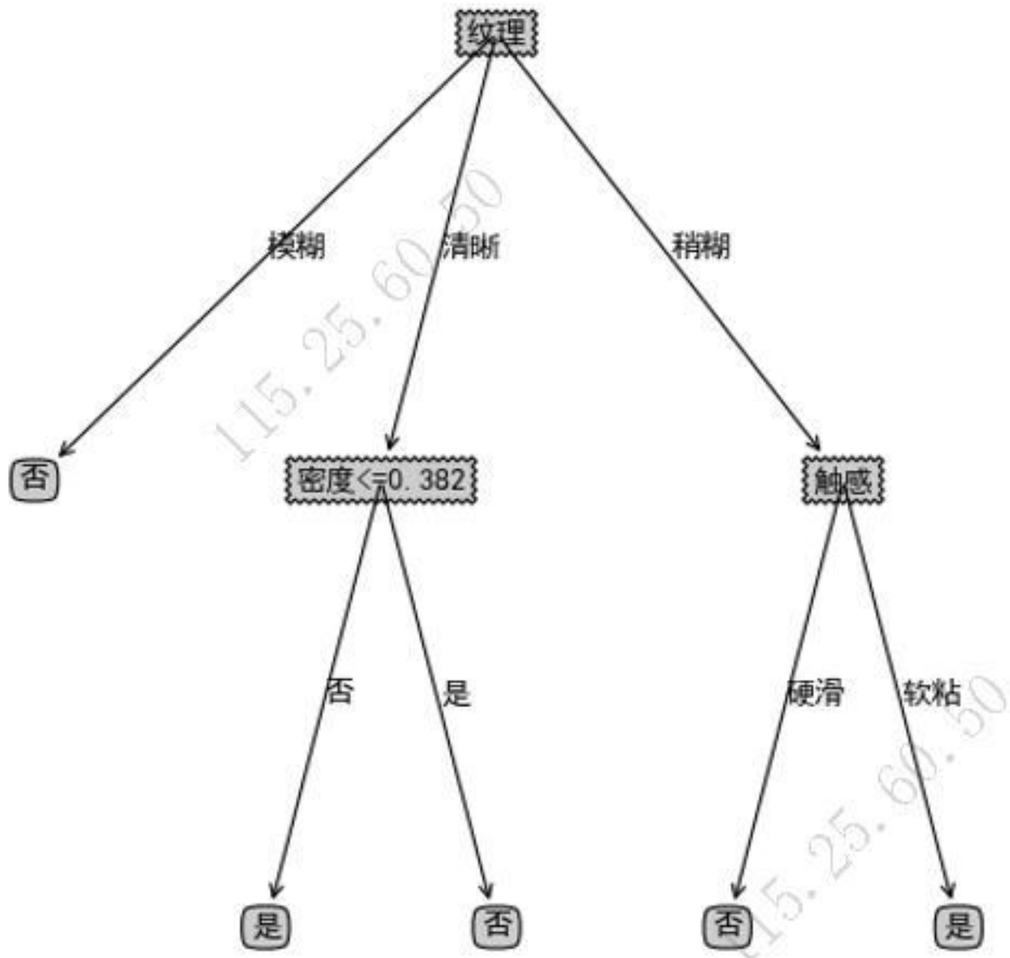


图 2-4 决策树树状结构图

Fig.2-3 Decision tree structure

此决策树用来判断一个具有纹理，触感，密度的西瓜是否是“好瓜”。当有这样一个西瓜，纹理清晰，密度为 0.333，触感硬滑，那么要你判断是否是一个“好瓜”，这时如果通过决策树来判断，显然可以一直顺着纹理->清晰->密度<=0.382->否，即此瓜不是“好瓜”，一次决策就这样完成了。正因为决策树决策很方便，并且准确率也较高，所以常常被用来做分类器，也是“机器学习十大算法”之一 C4.5 的基本思想。

通过构建多个深度不同的决策树来形成一个森林，每棵树都是在随机选取的训练集上独立训练出来的，并且在分裂节点时也会随机选择特征子集。集成学习通过增加模型的多样性，有效地提升了模型的泛化能力。具体来说，通过结合多个决策树的预测，可以降低模型对特定样本的敏感性，减少波动，从而使得模型在新的、未见过的数据上表现得更好。在集成学习中，即使是高方差的弱模型（如决策树）也能达到低方差的强模型的效果。这种方法可以平衡模型在训练集上的过拟合现象，使得模型在未知数据上具有更好的预测能力。

2.4.2 决策树算法的剪枝技术

预剪枝的核心思想是在决策树完全展开前提前终止其生长，其实现途径包括为模型训练设定多种约束条件，例如：限制树的最大深度；设定节点继续分裂所需的最小样本数；或当信息增益等指标低于特定阈值时停止分裂。通过这类方式，可以有效控制模型复杂度。后剪枝一般指的是建立完决策树后进行剪枝操作，首先构建决策树，让它成长到最大深度，然后开始移除那些对最终决策不产生重要影响的叶节点。常见的后剪枝技术包括成本复杂度剪枝

成本复杂度剪枝是一种常用的后剪枝方法，它通过引入通常表示为 α 的“复杂度参数”来平衡树的大小和模型的拟合度。具体步骤如下：首先计算每个节点的错误率在树的每个节点计算错误分类的代价。并计算每个节点的“净增益”，通过将节点的错误率与树的复杂度，如将树的深度或节点数结合起来进行计算。之后选择合适的 α，通过交叉验证或其他方法选择一个最优的 α 值。

剪枝则是对于每个内部节点，如果移除该节点及其所有子节点并将其替换为叶节点能减少复杂度调整后的总错误率，则执行这一剪枝操作。

设树 T 的叶节点个数为|T|，t 是树 T 的叶节点，则决策树学习的损失函

数一般如公式（2-4）所示。

$$C_\alpha(T) = \sum_{t=1}^{|T|} N_t H_t(T) + \alpha|T| \tag{2-4}$$

其中经验熵如公式（2-5）

$$H_t(T) = \sum_k \frac{N_{tk}}{N_t} \log \frac{N_{tk}}{N_t} \tag{2-5}$$

在损失函数中，将右端的第 1 项记作公式（2-6）

$$C(T) = \sum_{t=1}^{|T|} N_t H_t(T) = -\sum_{t=1}^{|T|} \sum_{k=1}^{K} N_{tk} \log \frac{N_{tk}}{N_t} \tag{2-6}$$

于是得出结果如公式（2-7）

$$C_\alpha(T) = C(T) + \alpha|T \tag{2-7}$$

式（2-7）中，表示模型对训练数据的拟合损失，表示模型复杂度，参数控制两者之间的影响。较大的促使选择较简单的模型（树），较小的促使选择较复杂的模型（树）。意味着只考虑对训练数据的拟合程度，不考虑模型的复杂度。

剪枝就是当确定时，选择损失较小的模型，即损失较小的子树， 越大，树越小。在训练数据集和测试数据集不同时，最优模型的复杂度就越低，但是在训练数据集和测试数据集一致时，损失较小的模型可以不剪枝。可以看出，剪枝本质上是通过调整信息度量（或信息增益比），在拟合训练数据时引入对模型复杂度的正则化约束，从而在拟合损失与模型复杂度之间取得平衡。在实际系统中，剪枝有助于筛选出预测准确率更高的模型。式（2-4）或（2-7）所定义损失函数的最小化，等价于进行正则化后的极大似然估计。因此基于该损失函数的剪枝过程，即为一种正则化极大似然估计下的模型选择方法。优点首先是简单易理解，决策树的结构类似于人类的决策过程，具有很好的可解释性。可以通过树状图直观地展示决策过程和规则，易于理解和解释。其次是能处理非线性关系：决策树能够处理线性和非线性关系，不要求数据线性可分。通过分裂节点，决策树可以捕捉复杂的模式和关系。

最后是可以自动特征选择，决策树可以自动进行特征选择，重要特征会被优先分裂，提高了模型的性能和效率。

2.5 本章小结

本章系统性地综述了金融产品推荐系统所依托的四项关键技术：关联规则挖掘、CTR 预估、特征编码与决策树，并深入探讨了各项技术在金融这一特定领域中的应用特性、面临的挑战及相应的优化方向。各项技术并非彼此

孤立，而是构成了一个有机整体，特征编码是处理原始数据的基础，关联规则与决策树分别从产品侧和用户侧提供可解释的规律洞察，而 FiBiNET 模型则负责融合多源信息进行精准的端到端排序预测。它们共同奠定了本文所提出的混合推荐模型的理论与技术基础。如何将这些技术有效地融合，以应对金融推荐场景中的复杂挑战，将是接下来研究内容的核心所在。

3 需求分析

传统的 Apriori 及相关算法因为效率低下很少用在大规模数据挖掘中，且金融场景用户行为低频所导致的数据稀疏性会导致算法缺少使用场景，加之用户的特征来源诸多且混杂，导致用户画像模糊定位不清晰、分析量过大，故希望通过引入 FP-apriori 算法、基于 FIBINET 的点击率预估算法和决策树算法构成混合模型，提高算法效率。基于关联原则生成频繁集，确定是否命中相关产品，由决策树生成用户画像，为不同用户分群，最终由 FIBINET-CTR 算法作为连接二者的纽带实现多目标排序。研究目标在于解决以下存在的问题。第一数据稀疏性：平均用户购买产品数<5。第二特征异构：结构化数据与非结构化日志并存。第三目标冲突：精准性与多样性难以兼顾。多模态的金融产品推荐算法模块旨在为系统提供一个实现精准推荐的平台，通过开发推荐功能模块达到推荐效果 **Error! Reference source not found.**。文章基于系统这一设计，聚焦于多模态的金融产品推荐算法的研究、构建与实现。

3.1 系统需求概述

金融产品购买决策是一个复杂的多层次过程，其决策机制远比普通消费品更为严谨和复杂。其需求认知、信息搜集、方案评估、购买决策和购后评价。每个阶段都受到用户特征、产品属性和环境因素的三重影响。在需求认知阶段，金融需求可分为显性需求和隐性需求。显性需求由特定生命周期事件触发，如购房产生的贷款需求、子女教育带来的教育金储备需求等；隐性需求则源于用户的财富增值、风险保障等深层动机，用户自身可能未能明确意识[24] 。本研究通过决策树用户画像模块，能够有效识别用户的潜在需求状态，如通过分析用户交易行为、资产变动和生命周期阶段，预测其可能产生的金融需求。

信息搜集阶段呈现出线上线下多渠道特征。线上渠道包括金融平台 APP、第三方评测网站等，线下渠道则包括客户经理咨询、亲友推荐等。在这个过程中，用户面临信息过载与可信度甄别的双重挑战[26] 。本系统的推荐模块通过提供经过算法筛选的个性化产品列表，有效降低了用户的信息筛选成本。

方案评估是决策过程的核心环节。金融用户采用多维度评估体系，按重要性排序包括：风险与安全性（首要考虑因素）、收益性、流动性、合规与

适配性、成本与费用、便捷性等。本系统的 FiBiNET 多目标排序模型正是对这一评估体系的数学化模拟，通过综合计算用户风险偏好、产品风险等级、历史收益率、流动性指标等特征，输出符合用户价值偏见的产品序列。

购买决策阶段常受到决策环境的影响，包括市场波动、销售服务体验、购买流程便捷性等。购后评价则决定了用户的满意度和忠诚度，正面评价会强化用户信任，负面评价可能导致客户流失。系统通过 ELK 日志分析模块实时监控用户购后行为，为服务质量改进提供数据支持，用例图如图 3-1 所示。

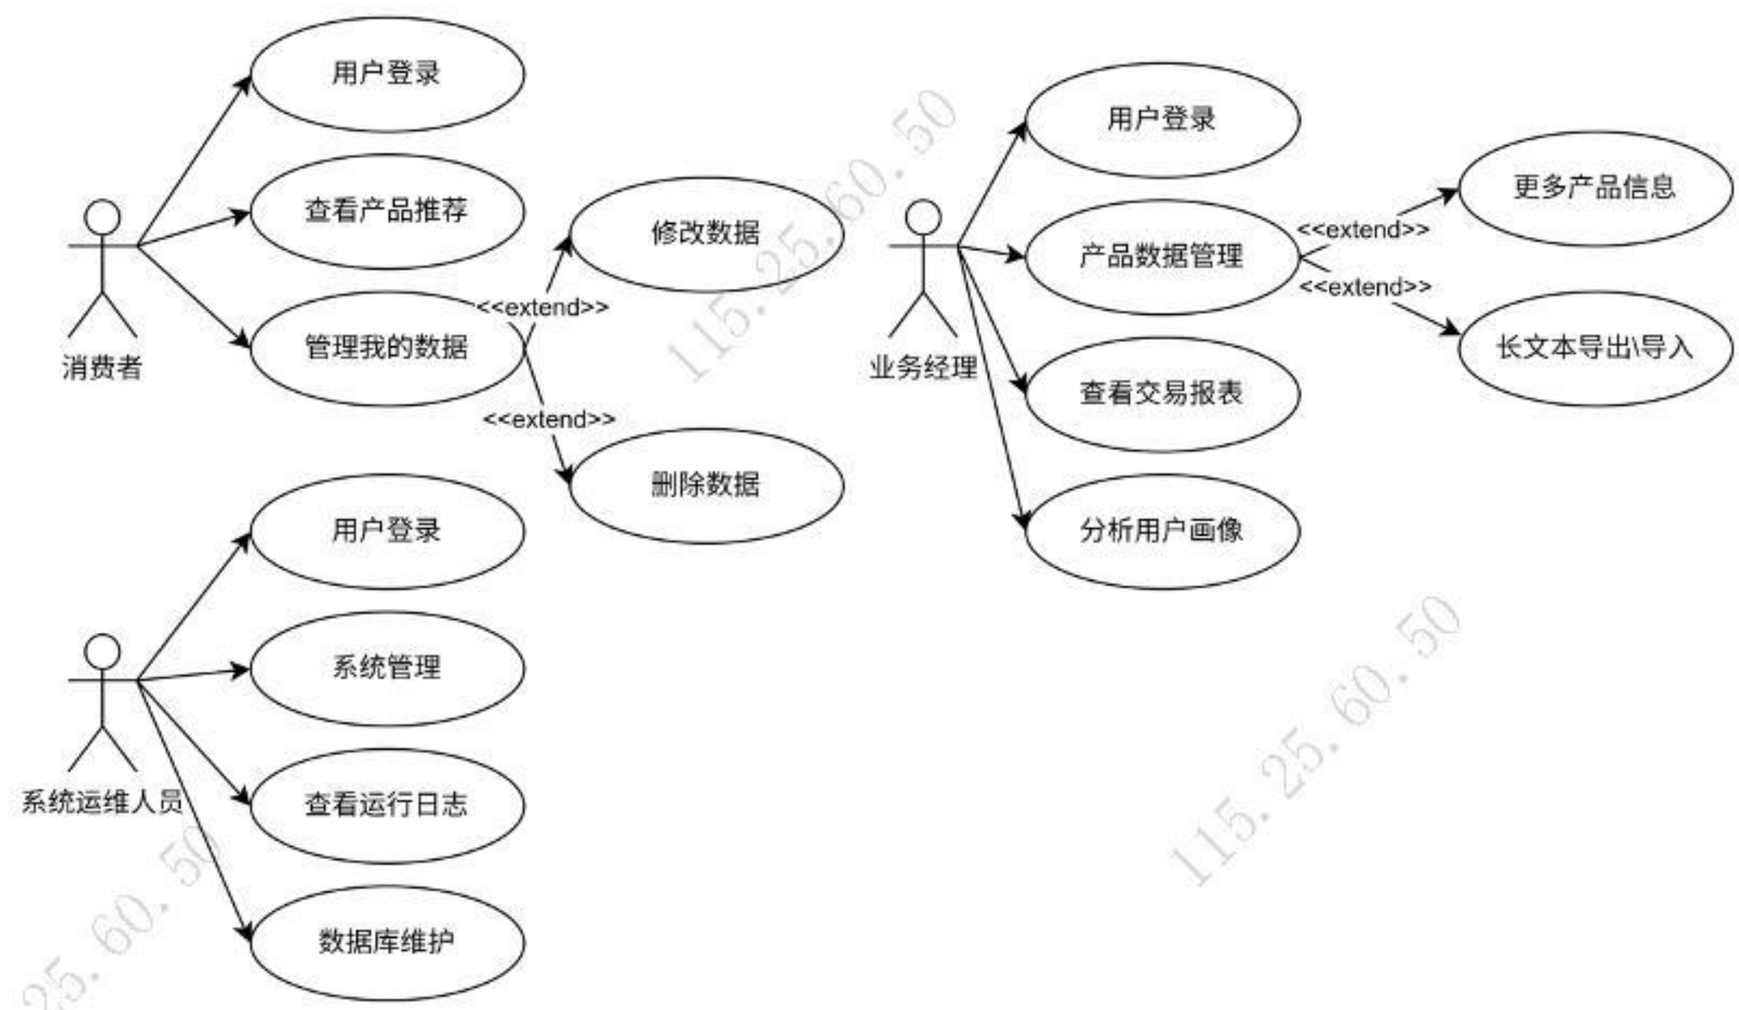


图 3-1 系统用例图

Fig.3-1 System Use Case

3.2 系统功能需求

3.2.1 关联原则算法的隐性需求挖掘模块需求

用户首先在登录界面登录账号后，进入产品浏览界面，系统根据用户购买和持有产品历史数据 **Error! Reference source not found.**，对关联产品生成产品频繁集，并存储管理数据。通过关联原则算法可以有效挖掘产品之间的隐性需求，探索用户与产品之间的不同组合，流程见图 3-2[27] 。

表 3-1 关联原则算法的隐性需求挖掘模块说明表

Tab.3-1 Explanation table for implicit demand mining module of association rule algorithm

主要参与者	购买产品用户
概述	为用户生成分群画像
前置条件	用户账户已创建，存在用户基本信息、产品购买和持有历史等数据
事件流	1、用户登录账号 2、点击产品列表按钮 3、系统调用 FP-Apriori 算法，调用数据库查询接口，查询用户数据，扫描产品表 4、生成关联产品频繁集合 5、存储数据，在数据库表中记录关联产品名称，唯一 id， 6、生成运行日志
后置流程	生成用户分群画像
其他说明	关联产品集合的生成依赖于历史购买和当下持有产品数据

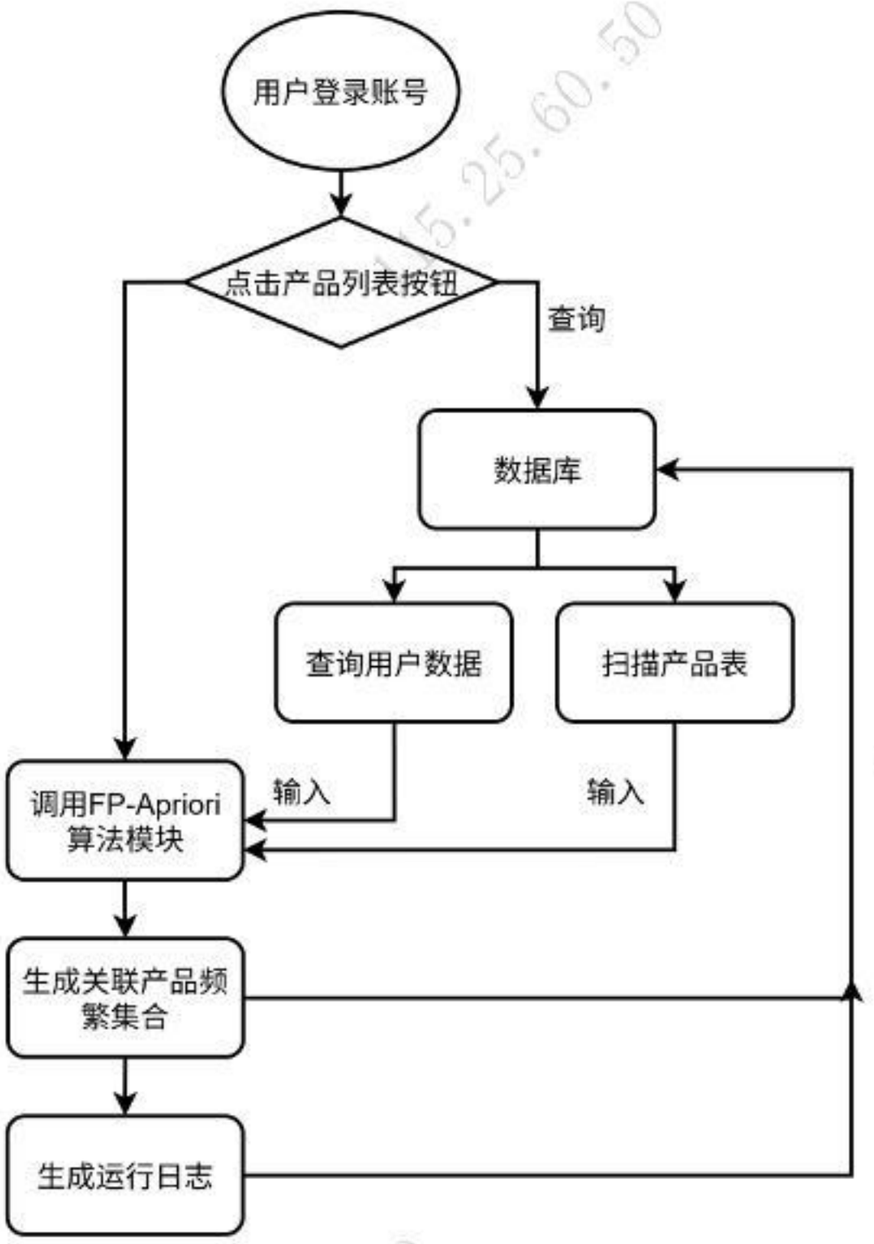


图 3-2 关联原则算法的隐性需求挖掘模块流程图

Fig.3-2 The process of implicit demand mining module in the association rule algorithm

3.2.2 基于决策树算法的用户画像模块需求

用户基础信息包括年龄、产品持有数量、产品购买历史、资产数量等，信息量大、分析难，通过决策树构建用户画像，实现用户分群，可以为分析用户需求提供有效抓手，并且作为点击率预估的前置流程，可以有效减少点击率预估模块的数据输入和特征数量，可以有效提升系统性能，流程见图 3-3。

表 3-2 决策树算法的用户画像模块说明表

Tab.3-2 Description table of user personas module for decision tree algorithm

主要参与者	购买产品用户
概述	为用户生成分群画像
前置条件	用户账户已创建，存在用户基本信息相关数据
事件流	1、检查用户是否登录账号 2、调用查询接口，查询用户基础信息和相关数据 3、调用 C4.5 决策树算法模块，输入用户数据 5、生成用户分群画像 6、调用修改接口，修改用户分群画像信息
后置流程	调用点击率预估模块
其他说明	用户的分群画像主要分为八种类型

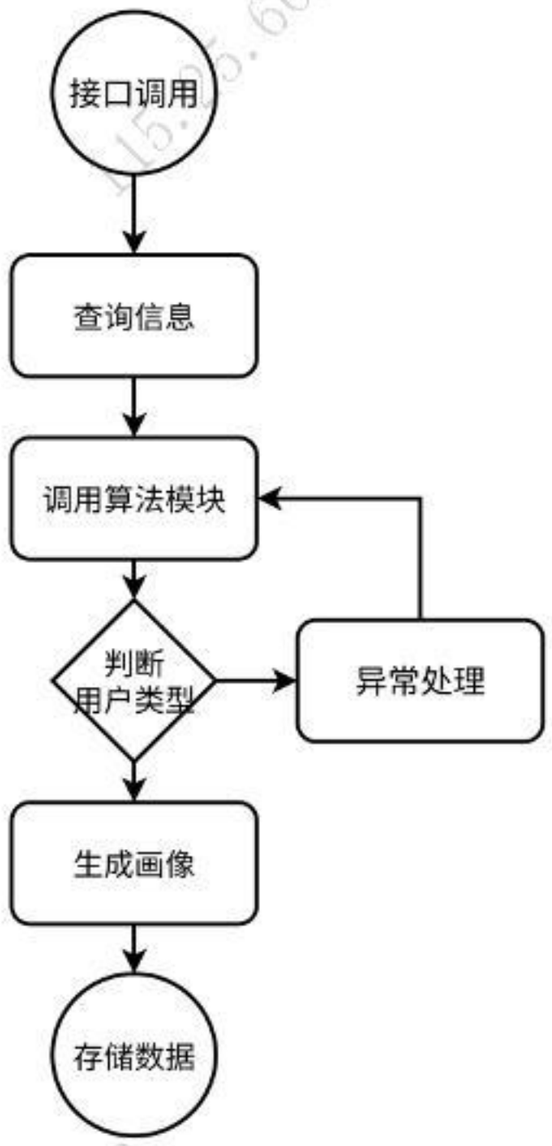


图 3-3 决策树算法的用户画像模块流程图

Fig.3-3 The user persona module process of the decision tree algorithm

3.2.3 融合 FiBiNET 的多目标 CTR 预估模块需求

在生成产品频繁集后和用户分群画像后，我们掌握了用户可能存在的潜在产品需求，但关联产品集合和用户的潜在购买需求之间仍然缺少联通的桥梁，此时需要设计点击预估模块，模拟用户购买意愿，连接用户需求和产品列表，提高产品推荐的契合度。点击预估模块的前置流程首先检查账号是否登录，其次查询产品关联集，和用户画像等数据，最后调用点击率预估算法，

评估用户购买意愿，为产品列表排序，最后输出根据产品预估概率排序的产品集合排序，返回集合给调用产品列表展示接口，展示产品流程见图 3-4。

表 3-3 融合 FiBiNET 的多目标 CTR 预估模块说明

Tab.3-3 Description of the multi-objective CTR prediction module integrated with FiBiNET

主要参与者	购买产品用户
概述	为用户生成推荐产品列表
前置条件	用户账户已创建，关联产品列表和用户分群画像已生成
事件流	1、检查用户是否登录账号 2、查询关联产品集合，输入 3、调用点击率预估算法 4、根据预估概率为产品集合排序
后置流程	调用产品列表展示接口，展示产品

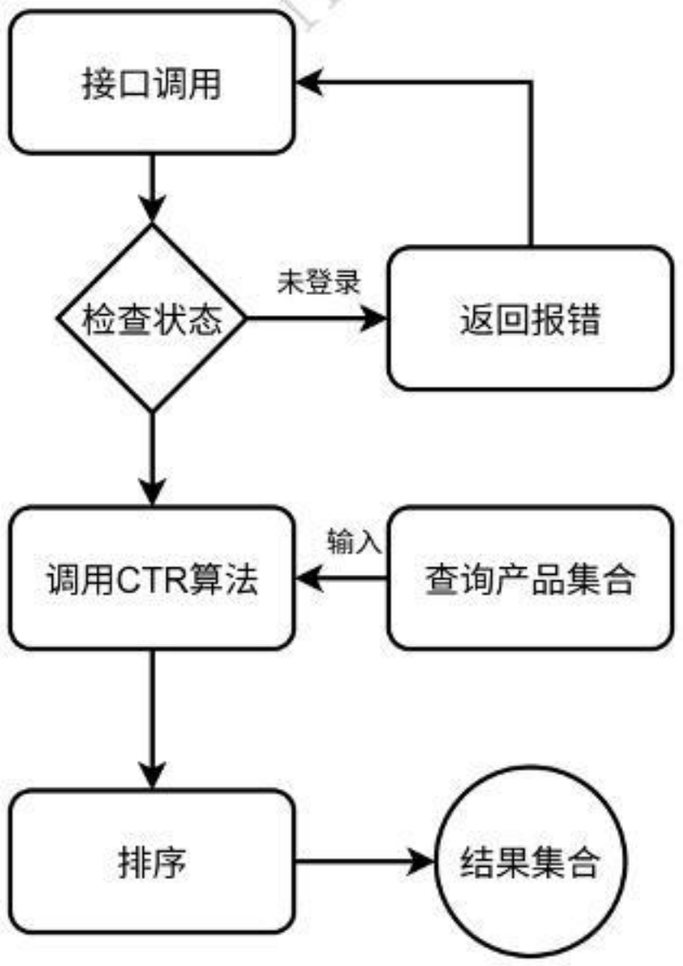


图 3-4 融合 FiBiNET 的多目标 CTR 预估流程图

Fig.3-4 Multi-objective CTR prediction process integrating FiBiNET

3.3 系统管理需求

3.3.1 客户端

客户端是用户与系统交互的首要入口，核心职责是呈现数据操作交互界面与发起操作指令，为用户提供可视化操作环境。其核心功能涵盖数据上传、数据更新、数据删除、数据交易及操作日志展示五大模块。操作完成后，客

户端将统一调用 Web 服务端接口，实现与区块链及存储层的联动，客户端整体架构如图所示。

在拥有相应权限的前提下，用户可通过填写并提交上传表单发起数据上传操作。上传表单包含两部分内容：

元数据部分：含数据标题、上传人、上传时间、所属分类、关键字、数据摘要等结构化信息；

数据内容部分：采用动态容器结构，支持上传图表、文本、图像等多种格式的非结构化数据，以满足不同实验数据的表达需求。

用户可在“我的数据”模块中对已有数据发起更新。更新界面支持用户修改数据内容或补充元数据，客户端处理流程与数据上传类似：用户提交更新内容后，界面将实时展示数据更新进度及历史版本信息，方便后续核查工作。

删除界面支持对已有数据执行逻辑删除操作，用户操作前需完成确认步骤。删除后的数据将在前端标记为“已删除”，同时触发后端对该记录的链上状态变更，保障记录的完整性。

客户端交易模块为用户间提供数据有偿共享机制，用户可进行以下操作：设置数据价格、用途声明等信息；将产品设为“待购买”状态；浏览其他用户发布的数据并发起交易请求；查看交易历史与记录。交易完成后，用户可在个人空间内查看所购数据的基本信息。

本系统客户端基于 React 框架开发，提供用户操作数据与追溯数据全流程的图形化操作界面，核心功能模块包括：

数据管理界面：包含了数据上传、修改以及数据详情页面。用户填写上传表单并提交内容，上传后可以查看数据详情页面并可以对数据进行修改，详情页中也包含了数据最后一次操作对应的产品交易 ID。

用户在系统首页登录账号，系统应依据角色不通实行不同的权限管理。

具体而言，销售人员将被赋予管理员权限，享有全面的资源访问权限，用的界面将根据其角色需求进行差异化设计。

通过上述界面，用户可直观操作平台功能。

3.3.2 日志实时采集

日志实时采集方面，系统需要处理日均百万级的用户请求，峰值 QPS 达到 5 万以上，推荐接口响应时间 P99 不超过 500 毫秒。关键组件需要实现冗

余部署。系统应具备弹性伸缩能力，能够根据负载动态调整计算资源。系统的安全性需求尤为关键，需要符合金融行业监管要求，比如金融管理局对反洗钱，反诈骗的监管需求。同时所有操作都需要记录审计日志，支持操作追溯和安全审计。同时通过该系统，系统运维人员可以便捷的维护系统，追溯异常。

表 3-4 日志实时采集需求说明

Tab.3-4 Real-time log collection requirement specification

主要参与者	管理用户
概述	提供实验日志解析、展示和查找功能。
前置条件	用户账户已创建，推荐产品列表已生成
事件流	1、用户通过点击系统工具栏进入系统的日志管理页面 2、日志管理页面显示所有已存储的日志文件的列表,按用户名、存储路径和操作排列展示 3、点击上传按钮，可以上传本地日志文件 4、提供可视化仪表盘实时监控系统运行状态 5、可点击查询，对页面中的具体日志进行查询、展示详细内容
后置流程	无

可扩展性方面，系统架构需要支持水平扩展，能够通过增加节点提升处理能力。各模块之间采用松耦合设计，支持独立升级和扩展。系统还应提供标准化的接口，便于与外部系统集成和新功能扩展。

3.3.3 长文本处理

在金融产品推荐系统中，批处理作业需要在指定时间窗口内完成，长文本处理模块承担着关键的数据预处理功能，负责处理来自多源的大规模文本数据。这些数据包括 Excel/CSV 格式的金融产品信息、用户行为日志、产品描述文档以及用户画像文本，还比如部分生产场景如分析保险产品的团单购买场景、关联投保人场景时可能涉及到几百甚至上千人的用户数输入等。于是对于长文本的处理和拆解变得尤为重要。随着业务量的增长，每日需要处理的文件数量可达数万份，总数据量达到 TB 级别。传统的数据处理方法已无法满足高效、稳定处理的需求，因此需要设计一个能够处理海量文本数据的专业化模块。

表 3-5 长文本处理需求说明

Tab.3-5 Long text processing requirement specification

主要参与者	管理用户、购买产品用户
概述	解析 Excel 等格式长文本文件
前置条件	用户账户已登录
事件流	1、点击批量导入界面，选择团单导入按钮/关联受益人按钮 2、选择 excel 表格解析按钮，开始解析工作 3、点击解析情况按钮，查看解析详情 4、点击团单查询/关联受益人查询查询 excel 表格解析结果是否复合预期
后置流程	调用列表展示接口，展示详情

3.3.4 实验数据管理

随着互联网业务的快速发展，数据量呈现爆炸式增长，传统的单机 MySQL 数据库在处理大规模数据存储和高并发访问时面临着性能瓶颈。依托于 OceanBase 数据库实现 MySQL 分布式架构搭建，可以有效的解决这些问题，通过将数据分散存储在多个节点上，提高数据库的读写性能、可扩展性和容错能力，其架构如图 3-5。MySQL 分布式架构的核心思想是将数据分散存储在多个节点上，通过网络连接实现数据的共享和协同处理。其主要优势在于提高了数据库的可扩展性和容错能力。当数据量不断增长或访问并发度提高时，可以通过添加节点来扩展系统的处理能力。同时，多个节点之间的数据备份和复制机制可以保证系统在部分节点故障时仍能正常运行。在生产环境中经常出现总公司数据库与分公司数据库更新不一致、不及时，导致数据失去时效性，在搭建分布式数据库设计存储表结构的同时需要处理总库与分库的冲突的问题，提高可靠性。

OceanBase架构图：

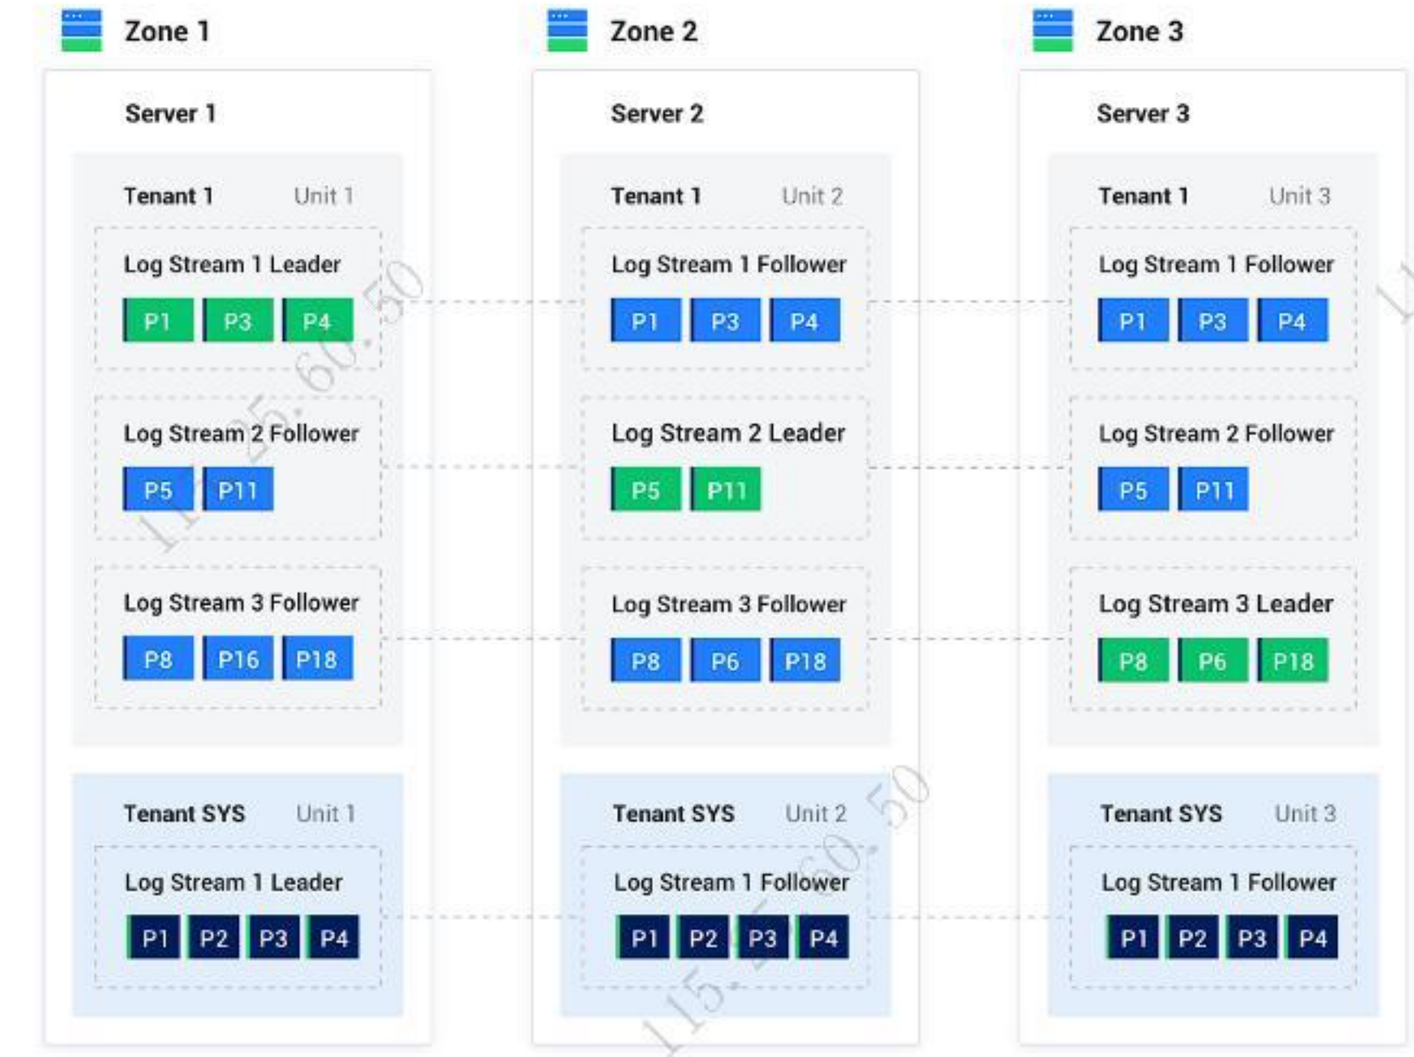


图 3-5 分布式数据库示意图

Fig.3-5 Schematic diagram of distributed database

分布式各个核心组件联系如下。

客户端：向分布式架构发送数据库请求，包括读请求和写请求。

路由节点：负责接收客户端请求，并根据请求类型和数据分布规则将请求转发到相应的节点上。

主节点：负责处理写请求，并将数据同步到从节点和分片节点。

从节点：复制主节点的数据，主要用于处理读请求，以减轻主节点的负载。

分片节点：存储部分数据，通过数据分片将数据分散存储在多个节点上，提高数据处理效率。

副本节点：为分片节点提供数据备份，保证数据的可用性和容错性。

4 系统功能模块设计与实现

4.1 系统功能模块设计

金融产品推荐系统采用分层架构设计,架构设计思路为自上而下的设计思路，可分为表示层、服务层、数据访问层、数据存储层。金融产品推荐系统架构图如图 4-1 所示。

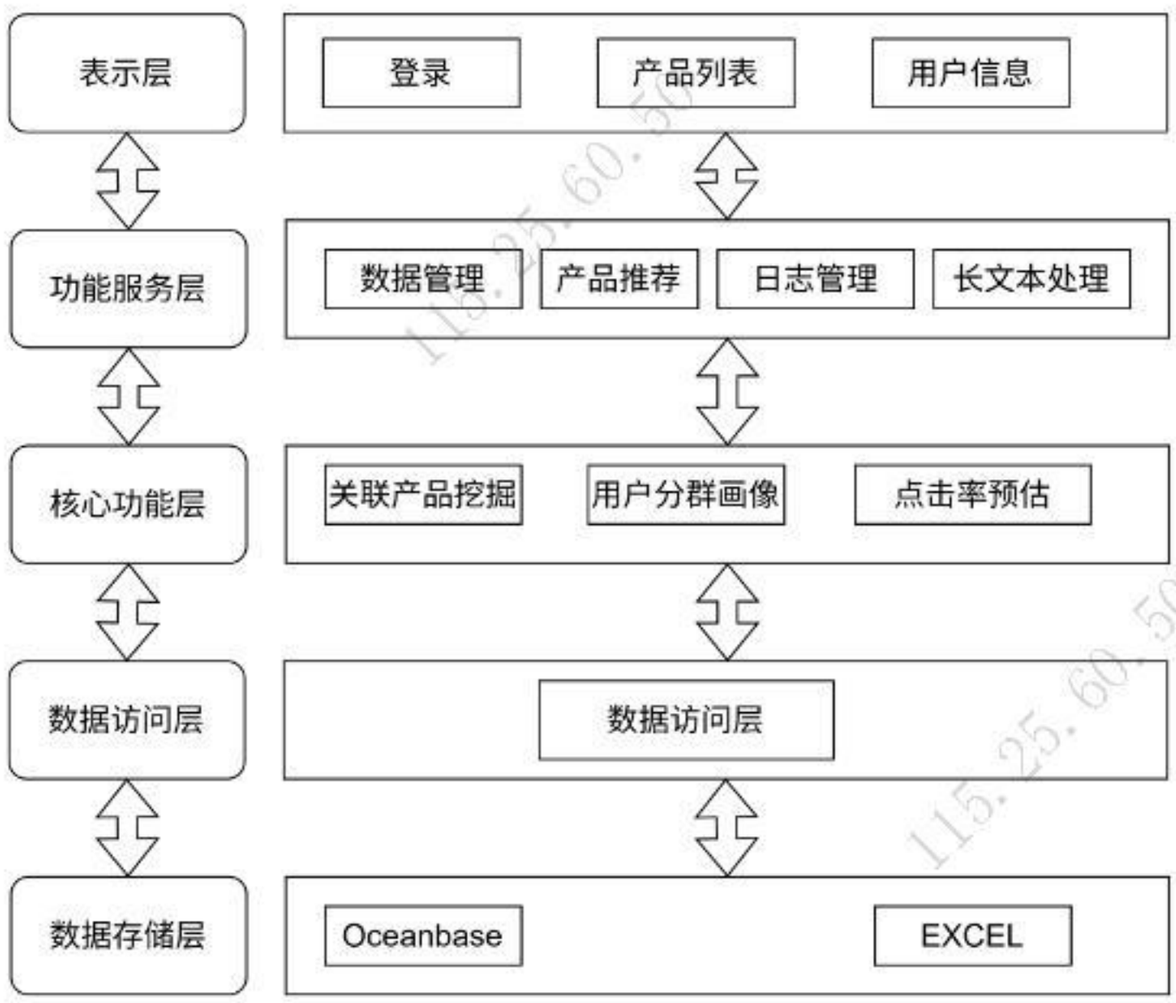


图 4-1 金融产品推荐系统架构图

Fig.4-1 Financial product recommendation system architecture

金融产品推荐系统的功能性需求主要包括数据处理、算法计算和推荐服务三个核心维度。在数据处理方面，系统需要具备大规模异构数据采集能力，支持每日 TB 级别的用户行为数据、产品信息和交易记录的实时接入与批处理。数据预处理功能要求实现多源数据的清洗、转换和标准化，特别是对金融领域特有的数值型特征进行规范化处理。特征工程模块需要支持基于关联规则的特征提取、用户画像标签计算和实时特征生成，为后续推荐算法提供高质量输入特征。

算法计算层面，系统需要集成多种推荐算法，包括基于 FiBiNET 的深度学习模型和基于用户画像的内容推荐算法。算法模块应支持在线学习和实时更新，能够根据用户反馈动态调整模型参数。推荐引擎需要实现多策略融合机制，根据不同场景和用户群体自动选择最优推荐策略，并支持 A/B 测试框架进行算法效果验证。算法模块数据流如图 4-2 所示。

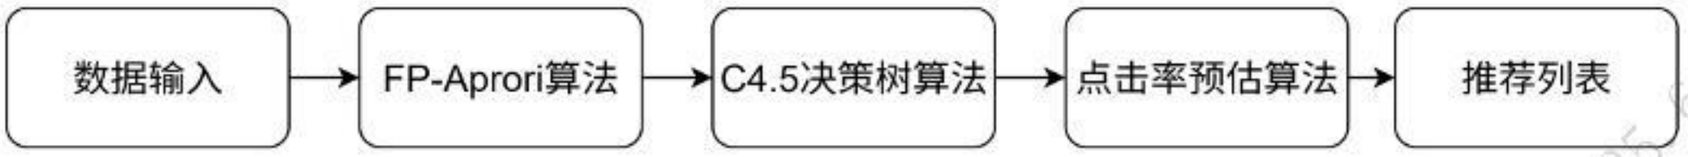


图 4-2 金融产品推荐算法模块流程图

Fig.4-2 Financial product recommendation algorithm module process

在服务层面，系统需要提供高可用的推荐接口，支持每秒万级的并发请求，响应时间保持在 200 毫秒以内。个性化推荐服务需要根据用户实时行为动态调整推荐结果，保证推荐的及时性和准确性。系统还应提供推荐效果监控和数据分析功能，支持业务人员查看推荐效果报表和用户行为分析。

4.2 基于关联原则算法的隐性需求挖掘模块

4.2.1 Apriori 与 FP-Apriori 算法流程概述

基于对销售人员与客户和产品销售数据进行关联分析，可以识别出冷门但高价值的“冷门热点”资源和相关度高经常会“打包”进入客户购物车的畅销组合，优化策略。

经典 Apriori 算法在处理大规模、高维数据时，存在频繁项集膨胀、候选集过多、计算代价大等问题，关联规则质量和生成效率有 待提高。算法核心思想是逐层搜索（Breadth-First），基于先验性质：频繁项集的子集必频繁

关键步骤：

1、扫描事务数据库，生成频繁 1-项集 L1

2、通过 Lk 生成候选 Ck+1 连接和剪枝

3、计算 Ck+1 的支持度，筛选出 Lk+1

4、重复直至无新频繁项集

缺点：多次扫描数据库，I/O 开销大；候选集数量指数级增长

本实验准备采用基于 FP 树的 Apriori 改良算法，FP－growth 改进算法从频繁项集的生成方式入手进行优化，算法的核心思想是分治策略，构建 FP 树压缩数据。通过构建 FP 树、分支搜索策略来避免产生过多的候选集，扫描数据库的次数分别由 Apriori 算法的 8 次降为 2 次和 1 次。其基本原理是若一个集合的子集不是频繁项集，那么该集合也不可能是频繁项集。基于此，该算法可以通过检查小集合而去掉大部分不合格的大集合如图 4-3。

关键步骤：

1、扫描数据库产品及相关表，生成频繁 1-项集并按支持度降序排序

2、构建 FP 树：根节点空置，按事务顺序插入路径

3、从条件模式基生成条件 FP 树，递归挖掘频繁项集

优点：仅需 2 次数据库扫描，无候选集生成

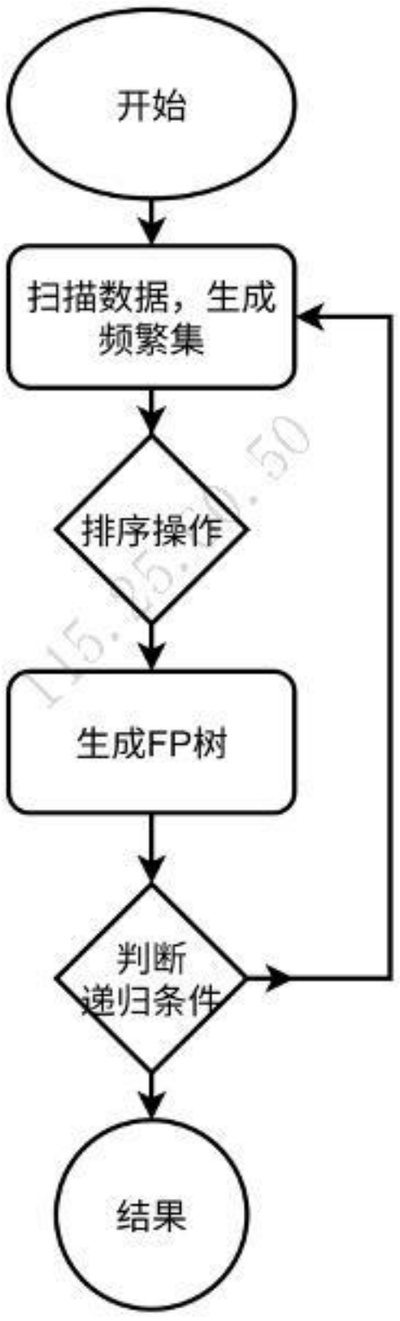


图 4-3 构造频繁集流程图

Fig.4-3 Process of constructing frequent sets

4.2.2 基于 FP-Apriori 算法的产品频繁集构建

在流程的最开始通过规则挖掘请求接口提交一个异步任务，根据指定参数在目标数据集上执行关联规则挖掘。其操作流程如下所述步骤一和步骤二，在此过程中可以调用状态查询接口和处理结果获取接口获取处理状态和处理结果，如果处理已经完成，提供规则结果分页查询接口，从数据库表中查询关联产品集合列表，利用规则导出接口支持规则导出操作。

关联原则算法的隐性需求挖掘模块具体接口及参数如表 4-1。

表 4-1 模块主要接口表

Tab.4-1 Main interface table of module

接口描述	方法	接口名称	主要功能
规则挖掘请求接口	POST	/v1/product/generateAssociationRules	提交一个异步任务，根据指定参数在目标数据集上执行关联规则挖掘。
处理状态查询接口	GET	/v1/product/status/{taskId}	查询处理任务状态
处理结果获取接口	GET	/v1/product/result/{taskId}	获取处理完成的结构化结果
规则结果分页查询接	POST	/v1/product/queryRules	根据多种条件对已挖掘出的关联规则进行筛选和分页查询。
实时规则匹配接口	POST	/v1/product/matchRulesForUser	给定一个用户 ID 或一个产品集合，实时返回匹配的、已启用的关联规则。
规则导出接口	POST	/v1/product/exportRules	将规则库中的规则以文件形式导出

具体实现流程中为保证实验数据高质量、准确，首先需要在数据的读取前对产品进行标准化操作，合并同义产品如“理财 A”、“理财 A 2025 版”和“理财产品 A”，统一命名为“理财产品 A”，为了避免同义产品影响，需要先将数据中同一类型产品进行合并，统一名称。计算产品支持度，过滤其中支持度小于 5%的低支持度产品。第二步，为更方便操作，降低操作难度，将每一个客户视为一个事务，并把产品列表转化为项集：T001 = {团体意外险（2025 版），随车行李险（A 版），货币基金（C 型）}，最后生成布尔矩阵如表 4-2[29] 。

表 4-2 产品频繁集布尔矩阵表

Tab.4-2 Product frequent set Boolean matrix table

事务 ID	团体意外险（2025 版）	随车行李险（A 版）	货币基金（C 型）	...
001	1	1	1	...
002	0	1	0	...
003	1	0	0	...
004	1	0	1	...
...	...	...	...	...

接口执行流程

步骤一：将数据输入到事务数据库 D 中，为算法设置最小支持度阈值，最小支持度阈值为 min_sup=0.05min_sup=0.05（5%），首次扫描数据库时，统计所有单项的支持度，筛选支持度≥min_sup 的频繁 1-项集 L1，之后开始构建 FP 树，按支持度降序重排事务项集，如 T001 = {随车行李险（A 版），

货币基金（C 型），团体意外险（2025 版）}插入 FP 树，对于路径相同的项集计数+1，对于不同路径创建新的节点如图 4-4。

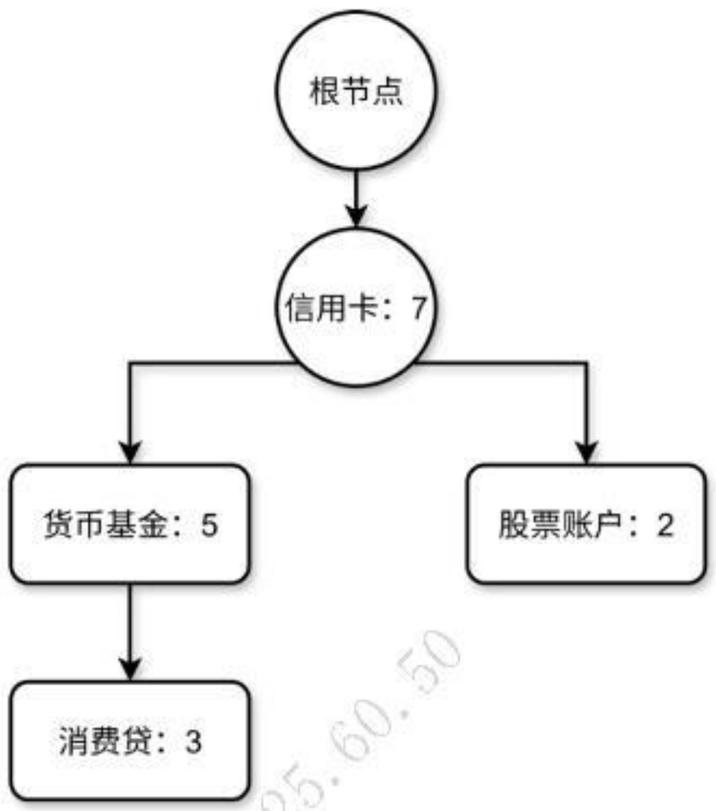


图 4-4 FP 树插入节点示意图

Fig.4-4 Schematic diagram of tree node insertion

步骤二：

对 FP-Tree 中的每个元素项，找出其对应的条件模式基。条件模式基是指以该元素项结尾的所有前缀路径。自底向上遍历（从最低频项开始）如图 4-5，对每一项的所有前缀路径生成条件模式基，如项养老储蓄险的条件模式基：

路径 1：养老储蓄险 3 → 混合型风险投资（C 型）3（来自事务 001,005,009）

路径 2：养老储蓄险 1 → 大病险 1（来自事务 012）

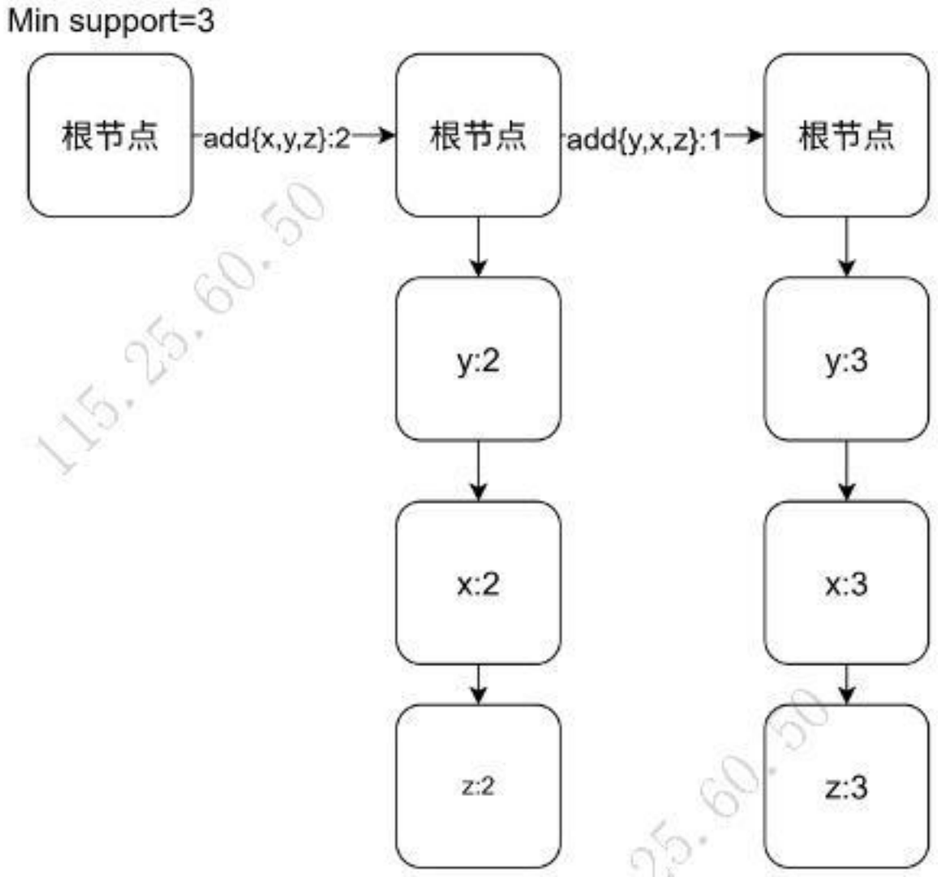


图 4-5 FP 树的创建过程图

Fig.4-5 Diagram of the creation process of FP tree

根据条件模式基建立子 FP 树，删除支持度 ＜min_sup 的节点，递归挖掘直至树为空，将条件 FP 树的频繁项与当前项组合，生成频繁项集，消费贷的条件 FP 树中{信用卡, 货币基金}频繁→ 输出频繁项集{信用卡, 货币基金, 消费贷}。

输出高频项集（部分）如表 4-3：

表 4-3 频繁项集支持度和来源算法表

Tab.4-3 Frequent itemset support and source algorithm table

频繁项集	支持度	来源算法
{信用卡, 货币基金}	0.152	FP-Apriori
{房屋财产险, 车险}	0.048	FP-Apriori
{随车行李险（A 型）, 人身意外险（单人）, 长期理财（B 型 2025）}	0.031	FP-Apriori

其中比较重要的计算参数如支持读，表示项集在所有事务中出现的频率，support（x）=count（x）/D，在 1000 笔交易中，“信用卡+货币基金”出现的次数 150 次，support=150/1000=0.15。置信度，购买 X 后购买 Y 的条件概率，confidence（X->Y）=support（X U Y）/support（X），support（信用卡，货币基金）=0.15。提升度，lift>1 则代表正相关，具有挖掘价值，lift=1 则代表产品较为独立，lift<1 则代表负相关。

其实根据关联原则算法初步计算出的结果，在不考虑用户定位和用户购买意愿的情况下，已经可以给出诸如以下几种初步的业务决策建议，例如在销售中采用交叉销售：对信用卡客户推送货币基金（43.4%转化率预期）。在监管环节进行风险控制：发现“短期理财产品 B 型+车险（单人）”组合支持度 0.02 但置信度达 65%，需要加入监控清单。在产品设计时，可以关注“养老储蓄+医疗保险”组合，组合的提升度为 2.1，可以尝试设计捆绑产品进行试点销售，观察实际的销售情况。

但策略的具体适用人群依旧模糊，需要利用已掌握的用户数据对用户进行分群处理，构建用户画像，进一步将产品与用户链接在一起。

4.3 基于决策树算法的用户画像模块

4.3.1 用户分群分析与设计

在金融产品营销中，精准客户分群是提升营销效率的关键。本方案基于

C4.5 决策树算法，并结合销售场景中可能存在的用户人群，将客户分为 8 类：重要价值客户：高价值、高忠诚度。重要保持客户：高价值但忠诚度下降。重要挽留客户：高价值但有流失风险。重要发展客户：高潜力但当前价值不足。一般价值客户：中等价值稳定客户。一般保持客户：中等价值但活跃度下降。一般挽留客户：中等价值有流失风险。一般发展客户：中等潜力待开发客户如图 4-6。

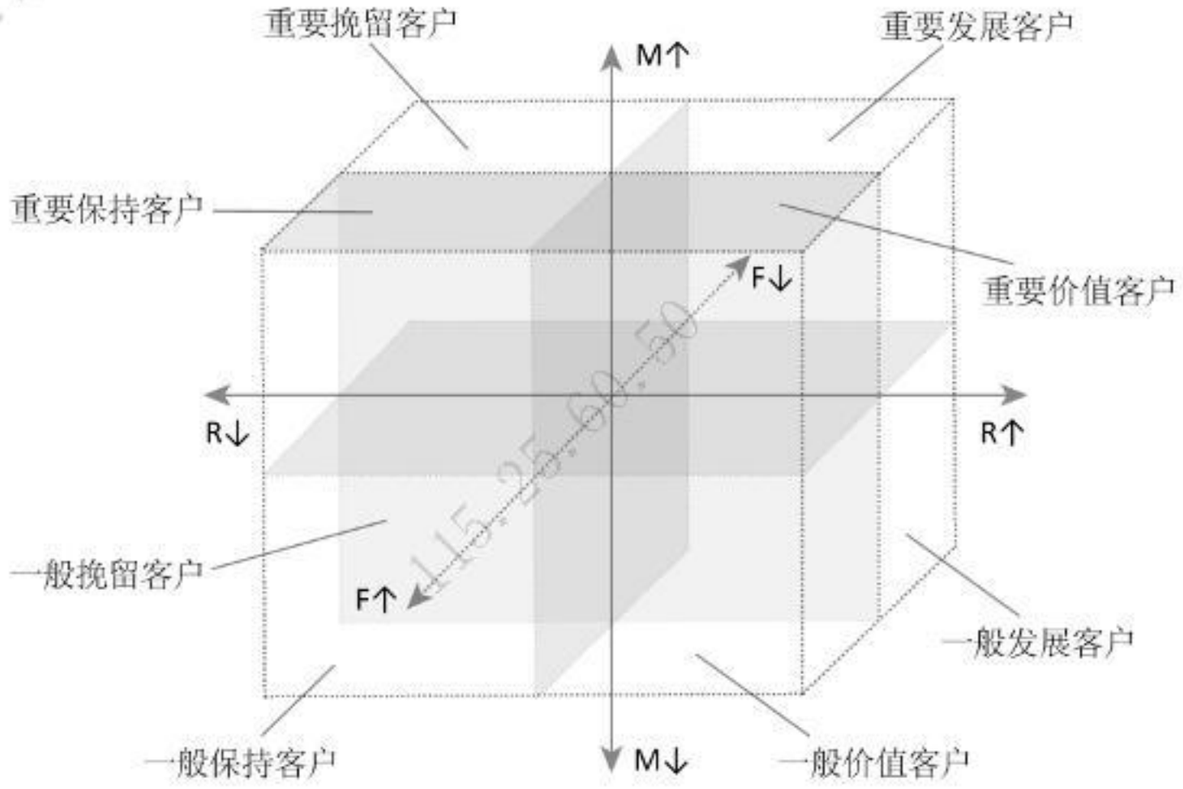


图 4-6 用户分群画像三维坐标轴示意图

Fig.4-6 Three-dimensional coordinates of user segmentation personas

基于 C4.5 决策树算法构建的用户画像体系，将金融用户群体划分为八个典型类别，每个类别具有鲜明的需求特征和行为模式。这种精细化分群为理解用户需求提供了结构化框架如图 4-7。

重要价值客户群体通常具有高资产规模、高活跃度和高忠诚度特征。他们的核心需求已从单一产品收益转向全面的资产配置、财富传承和税务规划。这类用户期望获得高度个性化、专属化的服务，对投资建议的专业性和及时性要求极高。针对该群体，平台应提供专属投资顾问服务，推荐组合投资方案，并优先提供私募、信托等高端产品。

重要保持客户虽然具有高价值特征，但活跃度呈现下降趋势。其需求特点是重新发现平台价值，恢复使用信心。这类用户可能因体验不佳或需求未满足而流失风险较高。平台需要通过个性化唤醒策略，如提供专属产品收益率上浮、免费增值服务体验等，重建用户 engagement。

重要挽留客户具有高价值但已显示明显流失迹象。他们的需求可能是问题解决或更好的替代方案。这类用户需要立即的关怀和问题解决，平台应触发预警机制，安排客户经理主动回访，深入了解流失原因并提供针对性解决方案[24] 。

重要发展客户当前价值不高但成长潜力巨大。他们的需求特征是金融启

蒙、小额试水和长期信任建立。这类用户需要低门槛、体验型产品和服务，平台应提供教育性内容和简单明了的产品推荐，培养其理财习惯和平台忠诚度。

一般价值客户和一般保持客户构成了平台用户基础，需求相对稳定，追求稳健、省心和性价比。一般挽留客户和一般发展客户则价值较低且活跃度不高，需要基于投入产出比优化服务策略。

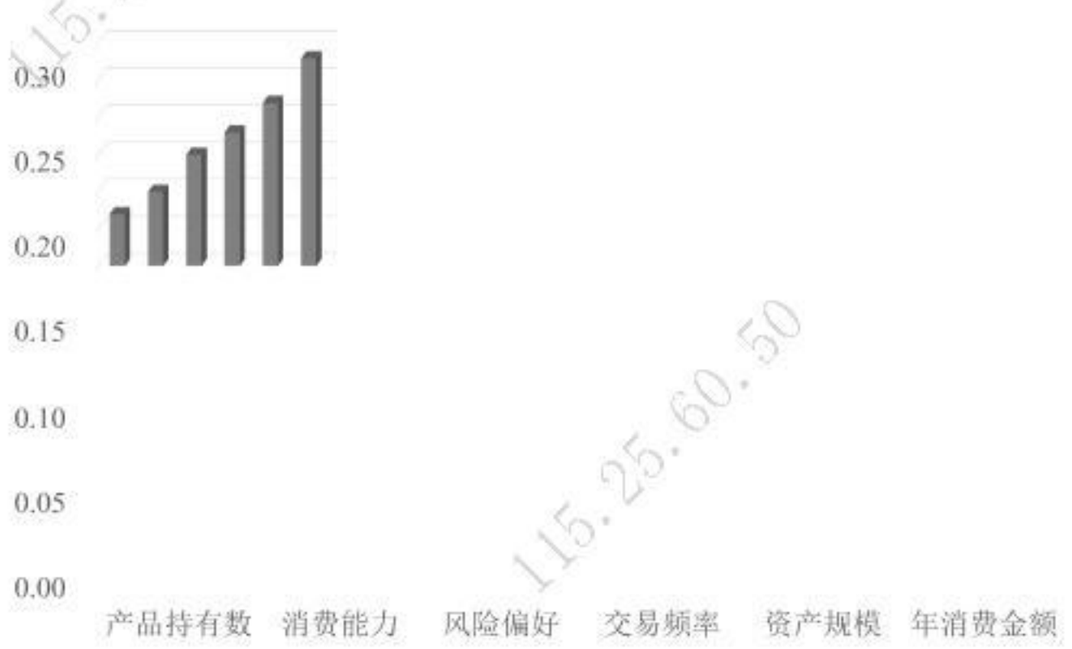


图 4-7 用户分群画像柱状图

Fig.4-7 Bar chart of user segmentation personas

4.3.2 用户画像的构建

不同的决策树算法，决策方式和构建方式存在差异，ID3 使用信息增益，C4.5 利用信息增益率，CART 则是依托 gini 系数进行构建。C4.5 算法核心原理 C4.5 基于信息增益比进行特征选择，[30] 解决了 ID3 算法的两大缺陷：偏向取值多的特征，不能处理连续值。本模块的主要接口如表 4-4 所示。

表 4-4 模块主要接口表

Tab.4-4 Module main interface table

接口名称	方法	路径	主要功能
用户画像模型训练接口	POST	/v1/user_grouping/trainUserProfileModel	提交一个异步任务，根据指定的特征数据和用户标签，训练或更新 C4.5 决策树画像模型。
处理状态查询接口	GET	/v1/user_grouping/status/{taskId}	查询处理任务状态
处理结果获取接口	GET	v1/user_grouping/result/{taskId}	获取处理完成的结构化结果
单个用户画像实时预测接口	POST	/v1/user_grouping/predictUserProfile	为单个用户实时计算其画像标签如“重

接口名称	方法	路径	主要功能
			要价值客户”及对应的决策路径。
批量用户画像预测接口	POST	/v1/user_grouping/batchPredictUserProfile	为一个批次用户，批量生成画像标签
用户画像标签体系管理接口	POST	/v1/user_grouping/updateProfileLabelSystem	更新或配置标签体系及其业务含义

在构建决策树前，需要针对用户的基本特征进行预处理，分析用户的不同特征类型并保留其中的核心特征，如包含年消费金额和资产规模的价值特征，包括交易频率和产品持有数在内的行为特征，包括风险偏好和投资杠杆率的风险特征，包括收入增长率和消费能力的潜力特征，并对变量进行离散化处理，如表 4-5 所示[31] -[32] 。

表 4-5 决策树算法基础信息分析表

Tab.4-5 Basic information analysis table of decision tree algorithm

特征类别	特征名称	数据类型	计算逻辑
价值特征	年消费金额	连续型	过去 12 个月产品消费总额
	资产规模	连续型	存款+理财+投资总金额
行为特征	交易频率	连续型	月均交易次数
	产品持有数	离散型	持有金融产品数量
风险特征	风险偏好	离散型	高(3)/中(2)/低(1)
	投资杠杆率	连续型	负债/资产比例
潜力特征	收入增长率	连续型	年收入变化率
	消费能力	离散型	高(3)/中(2)/低(1)

以调用用户画像模型训练接口计算数据库中 15 名用户交易频率的条件熵为例，其中用户 9 名用户推荐关联产品推荐成功，6 名用户推荐关联产品推荐失败，由于推荐成功和发展失败并非同一类，需要进行分裂。为选择分裂特征，需要计算各特征的信息增益。为计算信息增益，先计算经验熵和条件熵。

$$H_1(D) = -\left(\frac{9}{15}\log_2\frac{9}{15} + \frac{6}{15}\log_2\frac{6}{15}\right) = 0.9710$$

其中高频率交易、中频率交易、低频率交易的权重分别为：W1=5÷15=0.3、W2=5÷15=0.3、W3=5÷15=0.3，结果见表 4-6。

表 4-6 用户交易历史数据表

Tab.4-6 User transaction history data table

		数量	关联产品推荐成功	推荐失败
交易频率	高	5	4	1
	中	5	2	3
	低	5	3	2

并且计算高交易频率的信息熵为 0.8879，中等的信息熵为 0.9710，低交易频率的信息熵为 0.9710。具体过程见公式（4-1）至（4-7）：

$$H(A_1^1) = -\left(\frac{4}{5}\log_2\frac{4}{5} + \frac{1}{5}\log_2\frac{1}{5}\right) = 0.8879 \tag{4-1}$$

$$H(A_2^1) = -\left(\frac{2}{5}\log_2\frac{2}{5} + \frac{3}{5}\log_2\frac{3}{5}\right) = 0.9710 \tag{4-2}$$

$$H(A_2^1) = -\left(\frac{2}{5}\log_2\frac{2}{5} + \frac{3}{5}\log_2\frac{3}{5}\right) = 0.9710 \tag{4-3}$$

计算交易频率的条件熵和信息增益：

$$H(D|A^1) = w_1 H(A_1^1) + w_2 H(A_2^1) + w_3 H(A_3^1) = 0.8879 \tag{4-4}$$

$$G(D,A_1) = H(D) - H(D,A^1) = 0.9710 - 0.8879 = 0.0831 \tag{4-5}$$

年龄的分裂信息和年龄特征的信息增益比：

$$H_{split}(D) = -\left(\frac{5}{15}\log_2\frac{5}{15} + \frac{5}{15}\log_2\frac{5}{15} + \frac{5}{15}\log_2\frac{5}{15}\right) = 1.5850 \tag{4-6}$$

$$G_r(D,A) = \frac{G(D,A)}{H_1(D)} = \frac{0.0831}{1.5850} = 0.0524 \tag{4-7}$$

类似可以计算其它特征的参数，并得出年消费金额的信息增益比最高，其属性有年消费金额大于五万、年消费金额小于五万。对于该节点的分类。“年消费金额大于五万”属性中，类别最多的为“推荐成功”，该属性归类为“推荐成功”；“年消费金额小于五万”属性中，类别最多的为“推荐失败”，该属性归类为“推荐失败”。在判断是否进行分裂时，如果该节点下的属性不属同一类，如同时存在“推荐成功”和“推荐失败”两种情况，则需要进行继续分裂，重复上述流程就算各个参数，直到无法继续分裂，此时的所有节点均无需再进一步分裂，属于单一类别，分裂结束。此时可以调用处理状态查询接口和处理结果查询接口查询处理状态和处理结果[33] 。

数据集采用数据库中存储的 20,000 条客户记录，特征选择的选择阶段，最终保留 6 个核心特征并存储，可通过用户画像标签体系管理接口进行管理，其中特征按重要性排名[34] ：年消费金额(0.28)>资产规模(0.22)>交易频率(0.18)>风险偏好(0.15)>消费能力(0.10)>产品持有数(0.07)。对于决策树剪枝优

化则采用悲观错误剪枝法(PEP)。

在构建完成后，根据已有信息，对于年消费大于五万的用户，并且消费能力高，持有产品数量大于五的用户，其用户分群为重要价值客户，持有产品数量小于五的归类于重要保持客户，对于风险偏好分群的用户，风险偏好为低的分别分成一般保持客户和一般挽留客户，对于交易风险明显偏高的用户，则为一般发展用户，诸如此类，对用户进行分群处理，利用关键特征组合将客户分为八种类型，客户类型和关键特征组合详见见表 4-7[27] 。

表 4-7 用户分层类型分析表

Tab.4-7 User segmentation type analysis table

客户类型	关键特征组合
重要价值客户	年消费>5 万 & 消费能力高 & 持有产品≥5
重要保持客户	年消费>5 万 & 消费能力高 & 持有产品<5
重要挽留客户	年消费>5 万 & 消费能力低 & 交易频率≤2
重要发展客户	年消费≤5 万 & 资产>20 万
一般价值客户	年消费>5 万 & 消费能力低 & 交易频率>2
一般保持客户	年消费≤5 万 & 资产≤20 万 & 风险偏好低 & 交易频率>3
一般挽留客户	年消费≤5 万 & 资产≤20 万 & 风险偏好低 & 交易频率≤3
一般发展客户	年消费≤5 万 & 资产≤20 万 & 风险偏好高

对于已经一年以上未购买的客户，定义为流失客户，由此可分析得出重要挽留、一般挽留类型的客户的流失风险最高，如表 4-8 所示，重要价值、一般价值类型用户流失风险最低。

表 4-8 用户画像及流失风险分析表

Tab.4-8 User Persona and Churn Risk Analysis Table

客户类型	占比	平均资产	流失风险
重要价值客户	8.2%	￥1,250,000	2.1%
重要保持客户	12.5%	￥980,000	18.7%
重要挽留客户	6.3%	￥850,000	45.2%
重要发展客户	9.8%	￥550,000	12.5%
一般价值客户	15.7%	￥320,000	8.9%
一般保持客户	20.1%	￥180,000	25.3%
一般挽留客户	18.5%	￥150,000	62.4%
一般发展客户	8.9%	￥210,000	28.7%



客户类型分布分析

客户类型	占比	平均资产	流失风险
重要价值客户	8.2%	￥1,250,000	2.1%
重要保持客户	12.5%	￥980,000	18.7%
重要挽留客户	6.3%	￥850,000	**45.2%**
重要发展客户	9.8%	￥550,000	12.5%
一般价值客户	15.7%	￥320,000	8.9%
一般保持客户	20.1%	￥180,000	25.3%
一般挽留客户	18.5%	￥150,000	**62.4%**
一般发展客户	8.9%	￥210,000	28.7%

注：流失风险低于10%为低风险，10%-30%为中风险，高于30%为高风险

图 4-8 客户类型分布图

Fig.4-8 Customer type distribution chart

其实此时，基于用户的分群，对于不同客户的用户画像，可以调用单个用户画像实时预测接口查询其分群标签，并且已经可以有针对性的提出营销策略，比如对于重要价值客户画像，其流失率低，资产消费能力均偏高的特点，可以提供专属财富管家服务，并为其优先推荐私募、信托等高端产品、定制化税务规划服务，客户类型分布图如图 4-8。

对于重要挽留、一般挽留类型的客户的高流失风险客户，其资产、消费能力、购买频率一般不高等特点，可以设置预警触发机制[35]，为高风险客户实时触发客户经理预警，提供挽留策略，安排客户经理主动回访，提供专属产品收益率上浮 0.5%，免费增值服务体验包。为中风险客户生成每日批量推送预警名单，匹配产品过程中根据用户分群画像降低风险产品的权值，增加中长期捆绑型消费产品，降低流失风险。为低风险客户提供月度流失值检查，长期动态监控[36]。

基于 C4.5 决策树的金融客户分群系统，通过以下创新点实现精准画像：

1. 动态特征体系：结合价值、行为、风险、潜力四维特征
2. 可解释分群规则：清晰的分群决策路径
3. 画像-策略联动：每个分群匹配专属营销策略
4. 持续优化机制：动态特征更新和模型迭代

该系统通过预先设计的决策树算法，不仅实现客户分类准确率，更关键的是可以推荐与其画像相匹配的产品[37]，提升高价值客户留存率，显著提升分析管理效能。虽然在模拟用户购买意愿和对关联产品排序方面缺少抓手，但为为结合产品特性，进一步挖掘客户群体购买行为与关联产品的深层逻辑，实现更精准的个性化服务提供更多可能。

4.4 融合 FiBiNET 的多目标 CTR 预估模块

4.4.1 特征提取与加强

可以认为 FiBiNET 是在 wide & deep 模型的基础上对它的 wide 部分进行了一些创新的改进，或者直接视为 FNN 的一个变体。主要的创新点在于：

在传统的 embedding stage 加入了一个 SENET 层对 embedding 特征升级为新的一种 embedding，得到与特征重要性 Feature Importance 相关的信息；不使用传统的 inner product 或 Hadamard product 方法，而是选择了结合二者的一种新的 bilinear interaction 方法来获得特征之间的联系；不同的特征对目标任务有不同的重要性。例如，当我们预测一个人的购买意愿时，特征消费能力比特征资产更重要。考虑到这一点，融合 FiBiNET 的多目标 CTR 预估模型引入了一个压缩激励网络 SENET 来动态学习特征的权重。此外，特征交互是点击率预测领域的一个关键挑战，许多相关工作都采用 Hadamard 积和内积等简单的方法来计算特征交互。融合 FiBiNET 的多目标 CTR 预估模型提出了一种新的细粒度方法来计算特征与双线性函数的相互作用。

其中 SENET 部分可以对特征间的依赖关系进行一定的提取。SENET 一共分为三个部分：Squeeze，Excitation 和 Re-Weight，按照顺序执行后从原始的 embedding 特征向量 E 得到加权后的 V。采用基于双塔模型改进的方法，分别生成用户与物品的向量表示。在传统深度学习模型中，每个离散特征通常对应一个独立的 Embedding 层，用于将其转换为嵌入向量；而连续特征一般直接输入，不作处理。为实现离散属性与连续属性具有相同维度的向量表示，本章引入全连接层，将连续数值转换为与离散特征向量维度一致的连续特征向量。最终，在传统双塔模型中，用户与物品经过特征提取后得到的隐向量会通过内积运算，以预测用户对物品的购买意愿。[38]-[40] 。

如果直接从双塔模型的 Embedding 层中取出用户和产品属性对应的向量进行拼接作为用户和物品的整体向量，则两个向量的内积无法体现出用户对产品的购买意愿，因为在双塔模型中，Embedding 层还要经过若干全连接层才能得到用户和产品的最终向量表示。如果将双塔模型中的若干全连接层去掉，Embedding 层向量确实可以体现用户对产品的评分。但由于网络架构只有一个 Embedding 层，特征提取方式显得过于单薄，因此需要一种特征加强的方式，这种特征加强方式要求只能对应每个 属性向量单独进行特征加强，不同属性之间的向量不能交互，否则最终得到的向量不再是每个属 性对应的向量。对此，本章将改进后的 SENet+模块引入双塔模型。SENet+特征加强

模块首次应 用于 FiBiNet++点击率预估模型，负责重要特征的学习。本章对 SENet+模块做了部分改进，并将用户的分群画像，代替部分特征，最为参考数据，减少计算量，改进后的 SENet+模块如图 4-9 所示[29] ：

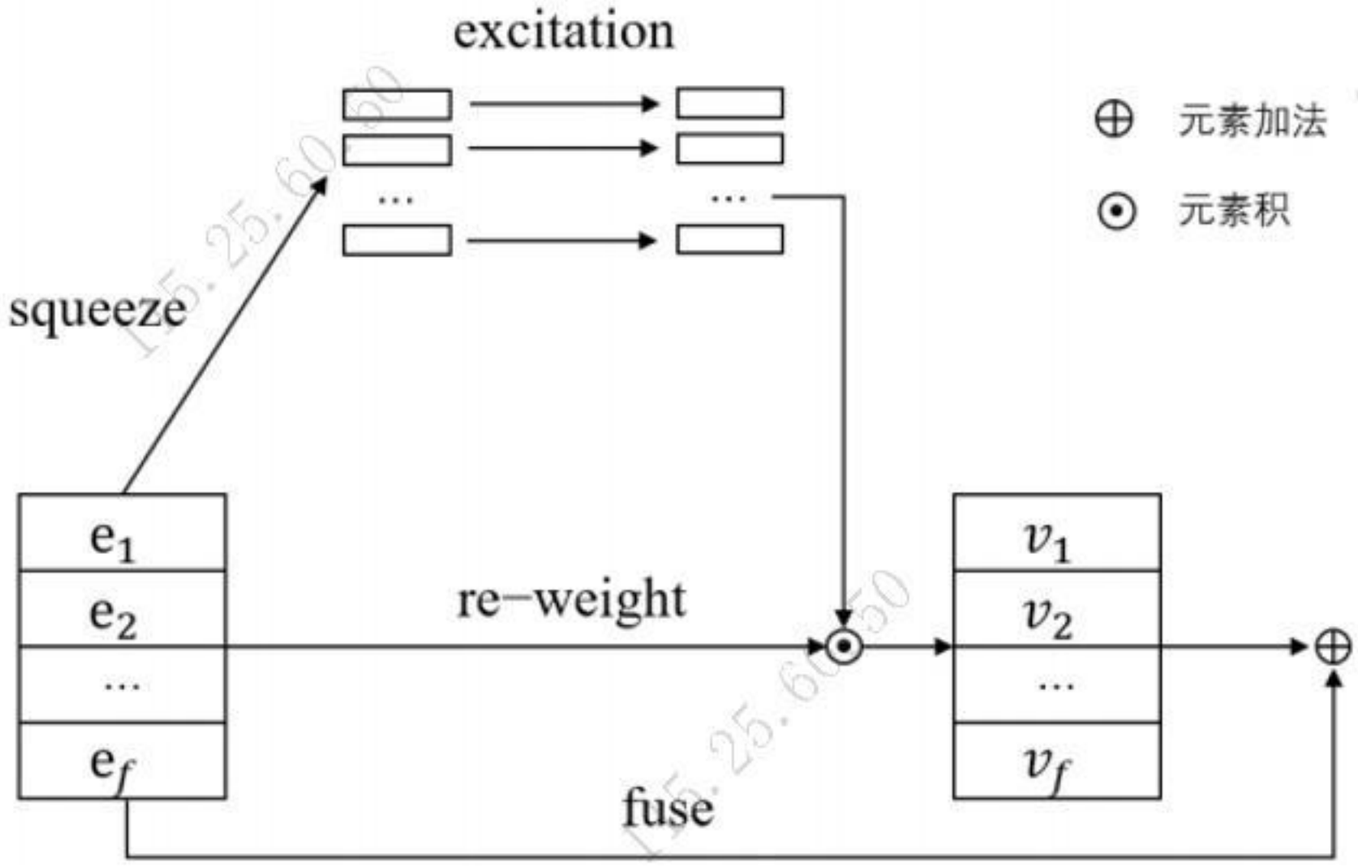


图 4-9 改进后的 SENet 模块

Fig.4-9 Improved SENet module

SENet+模块接收 Embedding 层和全连接层输出的特征向量，通过一系列计算得到每个向量对应的权重，在将权重和对应的向量相乘，再与原来的向量相加得到最终加强后的特征向量。具体来说，SENet+包含了四个步骤，分别是第一步挤压、第二步激励、第三步配重和第四步融和。改进后的 SENet+模块是对第三部分做出的改进。

在初始的 SENet+模块中，提取各特征向量内部各组子向量的均值与最大值之后，模块不仅会将每个特征向量内全部子向量的均值与最大值拼接为对应的池化向量，还会进一步将所有特征向量对应的池化向量拼接为一个整体，作为全连接层的输入，进而计算每个特征向量的比特级权重。然而，由于本章需要利用向量生成模型提取各属性的独立特征表示，因此需避免不同特征向量之间发生信息交互。针对这一问题，本章对原始 SENet+模块中的激励（excitation）操作作出改进，提出一种新的比特级权重计算方式：所有特征向量生成的池化向量不再整体拼接，而是分别输入全连接层，以独立生成各自的权重向量。该为每个特征向量单独计算比特级权重的步骤，即为激励操作。具体计算过程见公式（4-8）。

$$\begin{aligned} z_i &= concat\left[z_{i,1}^{avg}, z_{i,2}^{avg}, \ldots, z_{i,g}^{avg}, z_{i,1}^{\max}, z_{i,2}^{\max}, \ldots, z_{i,g}^{\max}\right] \in \mathbb{R}^{1\times 2g} \\ a_i &= \sigma_2(\sigma_1(z_i W_1)W_2) \in \mathbb{R}^{1\times d} \end{aligned} \tag{4-8}$$

为体现“用户向量与产品向量的内积反映用户购买意愿”这一设计理念，本章所采用的向量生成模型采用了双塔结构。在此基础上，将离散特征转换

层及全连接层输出的特征向量输入改进后的 SENet+模块，以增强特征表示能力。因此，本章在经典双塔模型的基础上，使用改进的 SENet+模块替换原有的全连接层。最终，Embedding 层与改进 SENet+模块的输出即分别为用户和产品的最终特征向量如图 4-10。

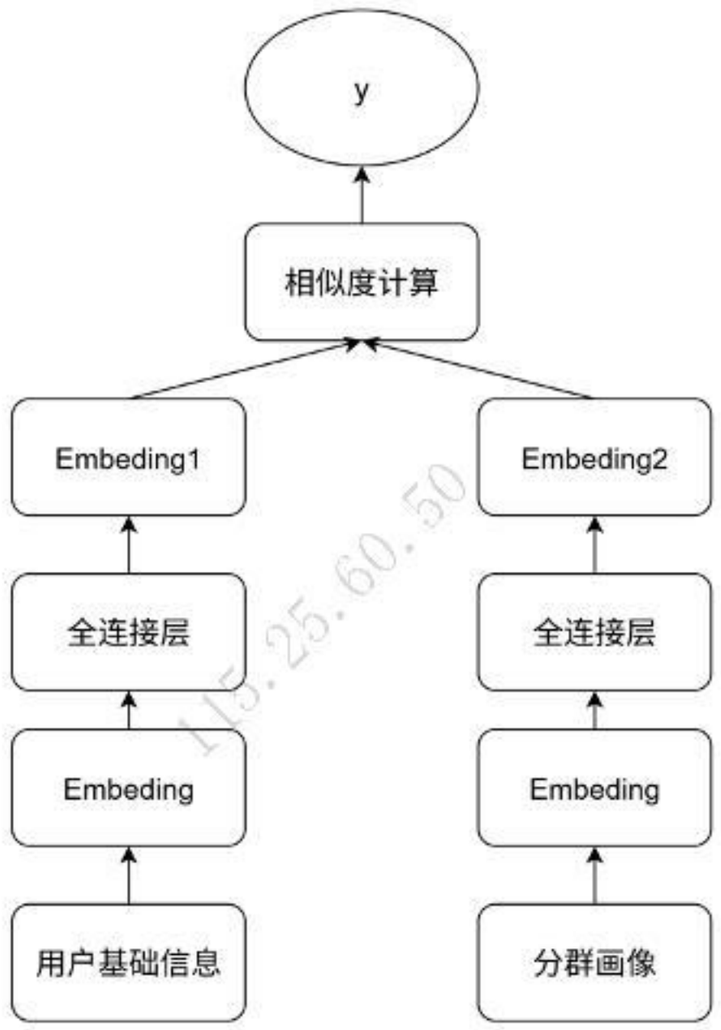


图 4-10 改进的 SENet 模型

Fig.4-10 Improved SENet model

4.4.2 预估模块的实现

表 4-9 模块主要接口表

Tab.4-9 Main interface table of the module

接口名称	方法	路径	主要功能
多目标模型训练接口	POST	/v1/ctr/trainFiBiNETModel	提交一个异步任务，使用训练数据训练或更新 FiBiNET 多目标预估模型
处理状态查询接口	GET	/v1/ctr/status/{taskId}	查询处理任务状态
处理结果获取接口	GET	v1/ctr/result/{taskId}	获取处理完成的结构化结果
实时点击率预估接口	POST	/v1/ctr/predictCTR	推荐系统在生成候选产品后，调用此接口进行精排
批量预估接口	POST	/v1/ctr/batchPredict	运营人员需要评估一批潜在的用户-产品组合的吸引力，用于策划营销活动
模型性能评估	POST	/v1/ctr/evaluateModel	在指定的测试数据集上评估模型

接口名称	方法	路径	主要功能
接口			的性能指标

模块主要接口表如表 4-9，特征融合层中传统的特征交叉方式广泛采用了内积(fm，ffm 等)和哈达玛积(AFM，NFM 等)。而这两种方式在稀疏数据上很难有效对特征交叉进行建模。Bilinear-Interaction Layer 部分结合内积和哈达玛积并引入一个额外的参数矩阵W_{ij}来学习特征交叉。多目标模型训练接口调用 FiBiNET 多目标预估算法，具体执行流程具体步骤如下：

（1）所有特征组进行两两交叉时共享一个参数矩阵W_{ij}，额外参数量为 k×k；

（2）每个特征组维护一个参数矩阵W_{ij}，额外参数量为 f×k×k 如图 4-11；

（3）式（4-9），每对交互特征 p_{ij} 都有一个参数矩阵W_{ij}，额外参数量为 f×(f-1)/2×f×f。

$$p = v \times W_{ij} \times u \tag{4-9}$$

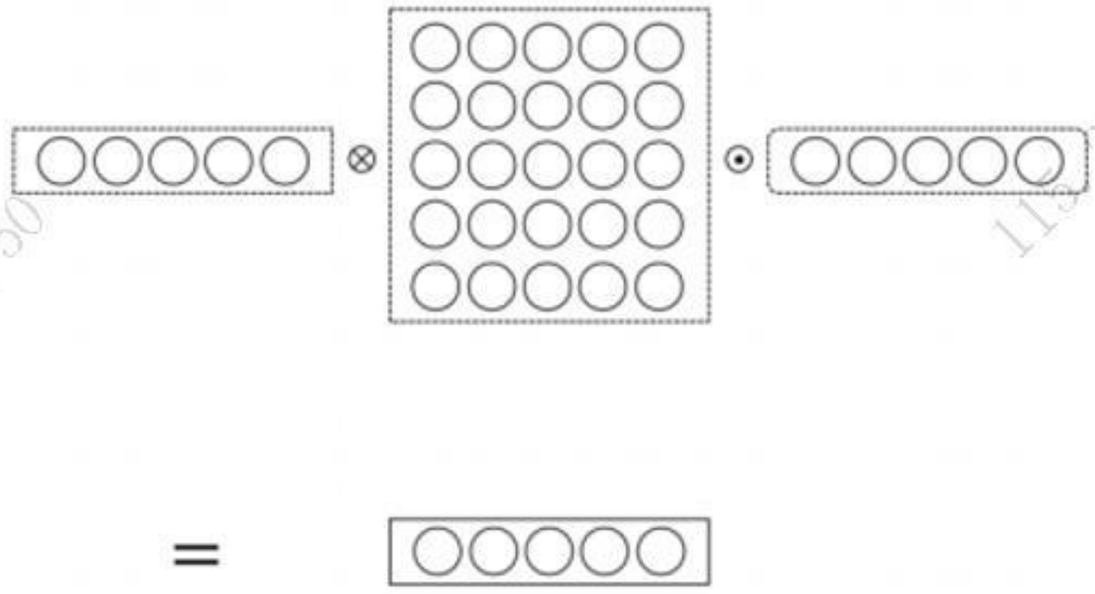


图 4-11 特征交叉图

Fig.4-11 Feature Crossing Graph

（4）经过 bilinear 函数的转换得到一个包含特征之间的关联的向量 p 和 q 在 combination 层把（1）和（2）的输出 p 和 q 简单的连接为式

$$c = [p,q] = [c_1,c_2,...,c_{2n}],\ c \in R^{2n \times k} \tag{4-10}$$

（5）最后把 c 送到多层全连接的神经网络结构，也就是我们通常说的 DNN，得到最终的输出。送入点击率预估模块得到最终的用户点击概率 P 计算公式见公式（4-11），算法流程图如图 4-12。

$$a^{(0)} = [c_1,c_2,...,c_{2n}],\ a^{(l)} = \sigma(W^{(l)}a^{(l-1)} + b^{(l)}) \tag{4-11}$$

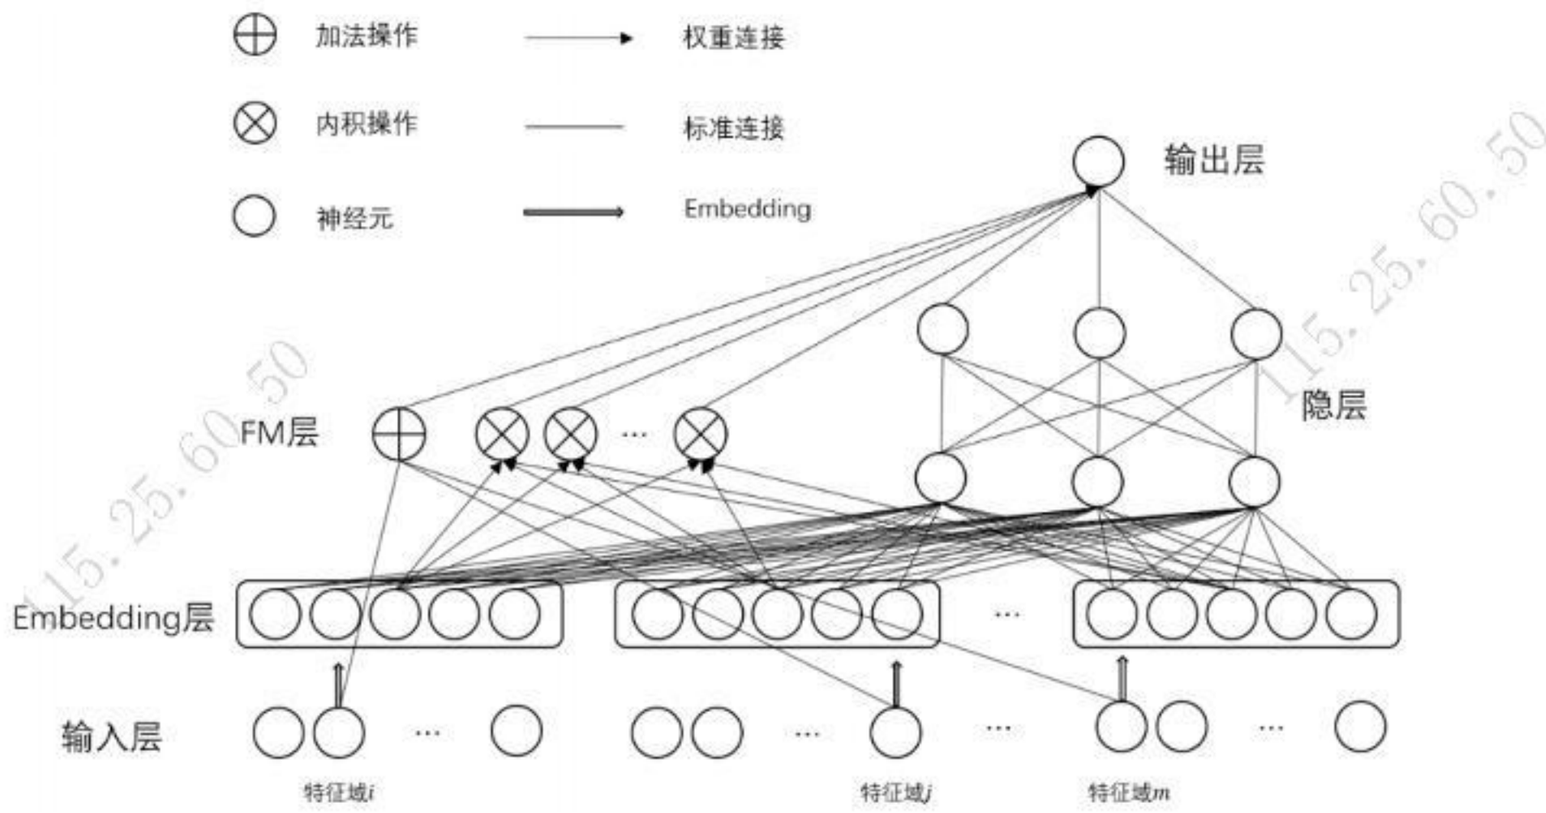


图 4-12 FiBiNET 算法结构图

Fig.4-12 FiBiNET algorithm structure diagram

（6）根据得到的点击概率 P 对产品频繁集产品重新排序，得到最终推荐列表，为用户推送[41] 。

4.5 本章小结

系统推荐生成流程，采用实时推理与批量计算相结合的方式。当用户访问系统时，实时推荐引擎首先获取并更新用户实时行为数据，结合用户画像和上下文信息，生成初步的候选产品集。候选集生成阶段综合考虑多种策略：基于协同过滤的相似产品推荐、基于关联规则的配套产品推荐、基于用户画像的个性化推荐。

接下来，系统使用 FiBiNET 深度学习模型对候选产品进行精排。模型综合考虑用户特征、产品特征、上下文特征和交互特征，为每个候选产品计算点击率预估分数。精排阶段还融入了业务规则和风控策略，确保推荐结果符合金融监管要求和业务目标。

最终，系统对精排结果进行多样性调整和曝光控制，避免推荐结果过于单一，同时考虑产品之间的平衡性。推荐结果通过 API 接口返回给前端应用，同时记录推荐日志用于后续效果分析和模型优化。

5 系统管理功能的设计与实现

本章基于以上各部分的研究，吸取部分金融公司的研发经验，并根据如保险、银行行业中用户的常见需求，对算法所依托的可视化系统进行设计与开发，包括如分布式存储，大文本处理，实时日志采集等技术模块的可视化系统如图 5-1，保障了在实际生产场景中高效的金融产品推荐，提升了金融产品推荐算法的实时性与便捷性[42] 。

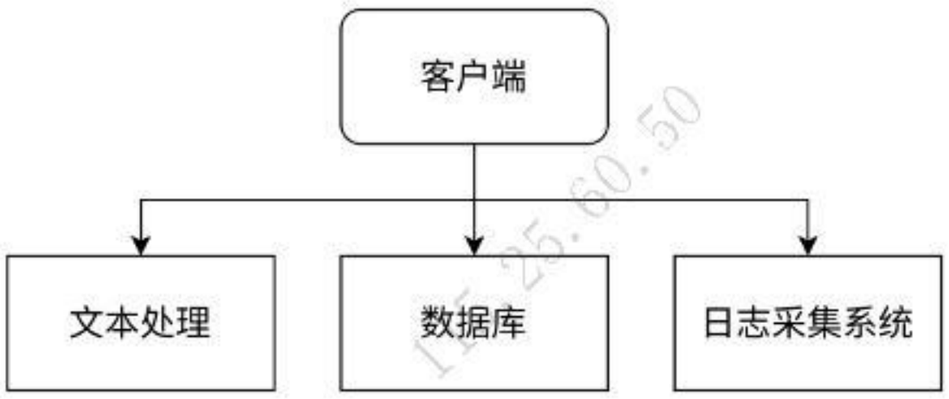


图 5-1 系统管理模块图

Fig.5-1 System management module

5.1 客户端

客户端是用户与系统交互的首要入口，核心职责是呈现数据操作交互界面与发起操作指令，为用户提供可视化操作环境。其核心功能涵盖数据上传、数据更新、数据删除、数据交易及操作日志展示五大模块。操作完成后，客户端将统一调用 Web 服务端接口，实现与区块链及存储层的联动[43] 。

（1）用户登录认证接口（userLogin）

功能描述：处理用户登录请求，验证用户名/密码，返回认证令牌和用户基本信息。调用场景：用户打开管理系统登录界面，输入凭证进行登录。

（2）权限验证接口（checkUserPermissions）

功能描述：验证用户对特定功能或资源的访问权限。调用场景：用户访问管理界面不同模块时的权限检查[44] 。

（3）产品列表查询接口（getProductList）

功能描述：分页查询产品列表，支持多条件筛选和排序。调用场景：产品经理查看和管理所有金融产品。

（4）产品详情获取接口（getProductDetail）

功能描述：获取指定产品的详细信息。调用场景：点击产品列表中的某

个产品，查看详情。

（5）产品创建/编辑接口（saveProductInfo）

功能描述：创建新产品或更新现有产品信息。调用场景：产品经理添加新产品或修改产品信息。

（6）日志查询接口（getProductOperationLogs）

功能描述：查询日志，用于定位和追踪。调用场景：点击查看日志界面详细信息。

5.2 日志实时采集模块设计与实现

日志实时采集模块主要依托 ELK 开源日志监控平台实现，组件组成如图 5-2。ELK（Elasticsearch, Logstash, Kibana）是一个目前主流的开源日志监控平台。其由三个主要组件组成的[45] -[46] ：

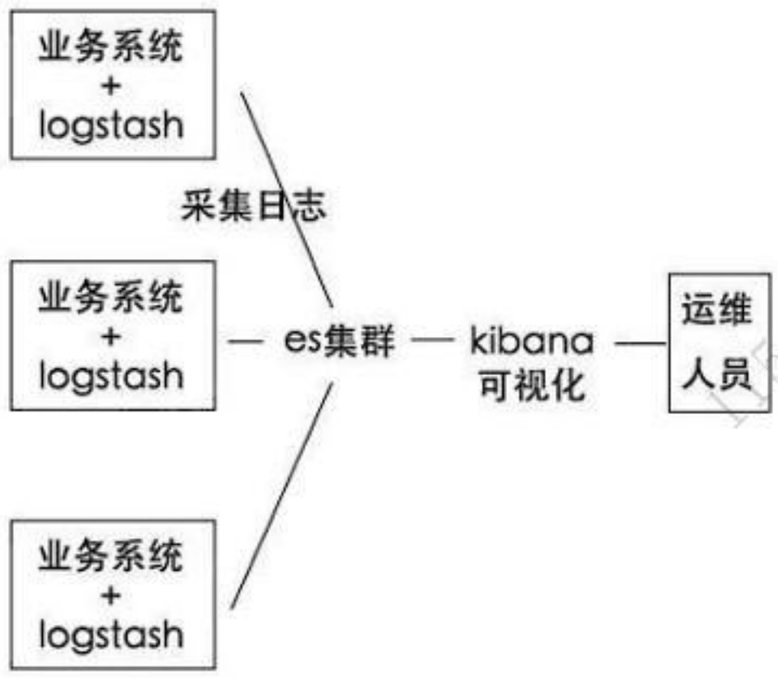


图 5-2 ELK（Elasticsearch, Logstash, Kibana）组件组成图

Fig.5-2 Composition diagram of ELK (Elasticsearch, Logstash, Kibana) components

Elasticsearch：是一个开源的分布式搜索和分析引擎，可以用于全文检索、结构化检索和分析，它构建在 Lucene 搜索引擎库之上，是当前使用较为广泛的开源搜索引擎之一[47] 。

默认情况下，Elasticsearch 集群中每个节点都有成为主节点的资格，也都存储数据，还可以提供查询服务如图 5-3。

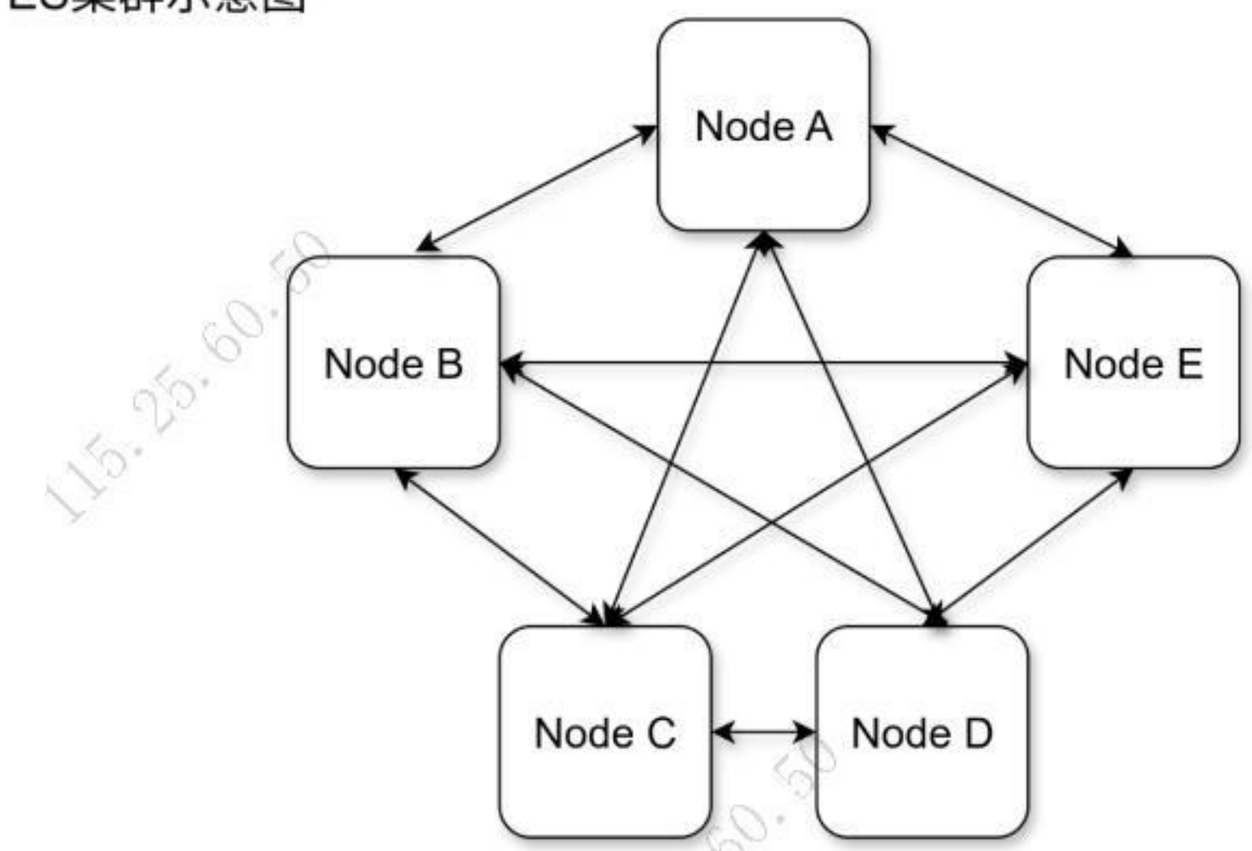


图 5-3 ES 集群示意图

Fig.5-3 Schematic diagram of ES cluster

在集群部署中 Node A 为当前集群 master,表 5-1 为配置表。

表 5-1 ES 配置表

Tab.5-1 ES configuration table

主机	IP	角色
docker	192.168.67.10	Elasticsearch_head
主机 B	192.168.67.31	Elasticsearch
主机 C	192.168.67.32	Elasticsearch
主机 D	192.168.67.33	logstash
主机 E	192.168.67.34	kibana

```
[root@elk1 ~]# yum install -y elasticsearch-7.6.1-x86_64.rpm
Loaded plugins: langpacks, product-id, search-disabled-repos, subscription-
              : manager
This system is not registered with an entitlement server. You can use subscriptio
n-manager to register.
Examining elasticsearch-7.6.1-x86_64.rpm: elasticsearch-7.6.1-1.x86_64
Marking elasticsearch-7.6.1-x86_64.rpm to be installed
Resolving Dependencies
--> Running transaction check
---> Package elasticsearch.x86_64 0:7.6.1-1 will be installed
--> Finished Dependency Resolution

Dependencies Resolved

================================================================================
 Package           Arch       Version      Repository                       Size
================================================================================
Installing:
 elasticsearch     x86_64     7.6.1-1      /elasticsearch-7.6.1-x86_64     475 M
```

图 5-4 Elasticsearch 安装

Fig.5-4 Elasticsearch installation

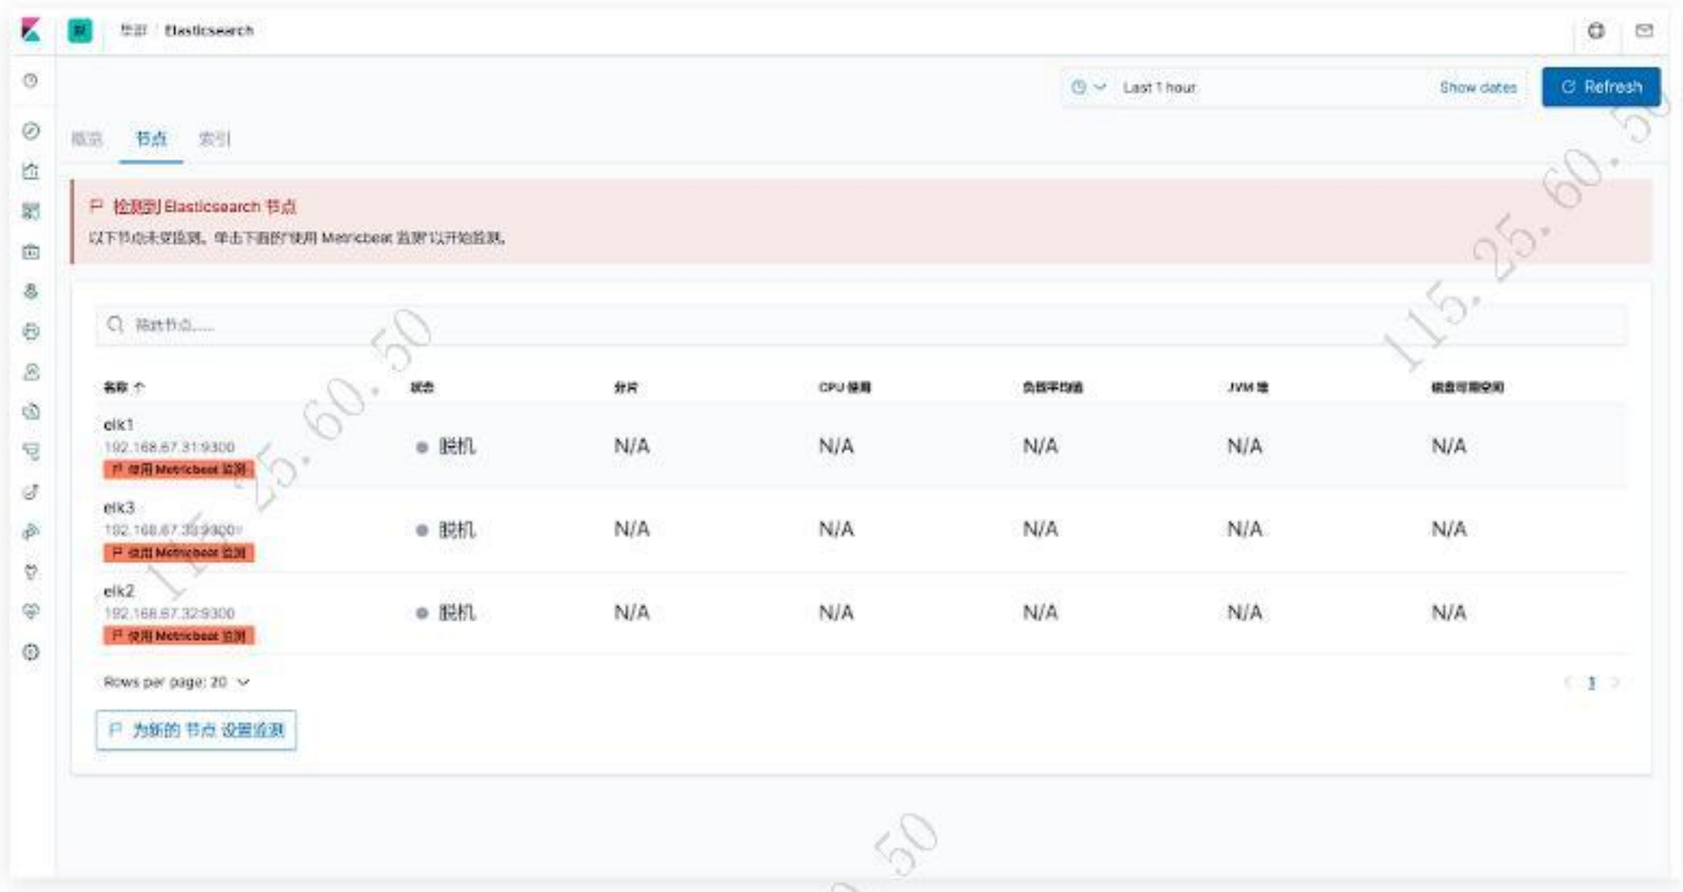


图 5-5 Elasticsearch 集成安装

Fig.5-5 Elasticsearch integrated installation

通过可视化界面验证节点已经成功部署如图 5-4 和图 5-5。

Logstash：用于收集、处理和转发日志数据的数据处理管道。Logstash 可以从不同的日志源（如文件、应用程序日志、数据库等）中收集日志数据，流程如图 5-6，并对其进行过滤、解析和转换，然后将其发送到 Elasticsearch 中进行存储和索引。

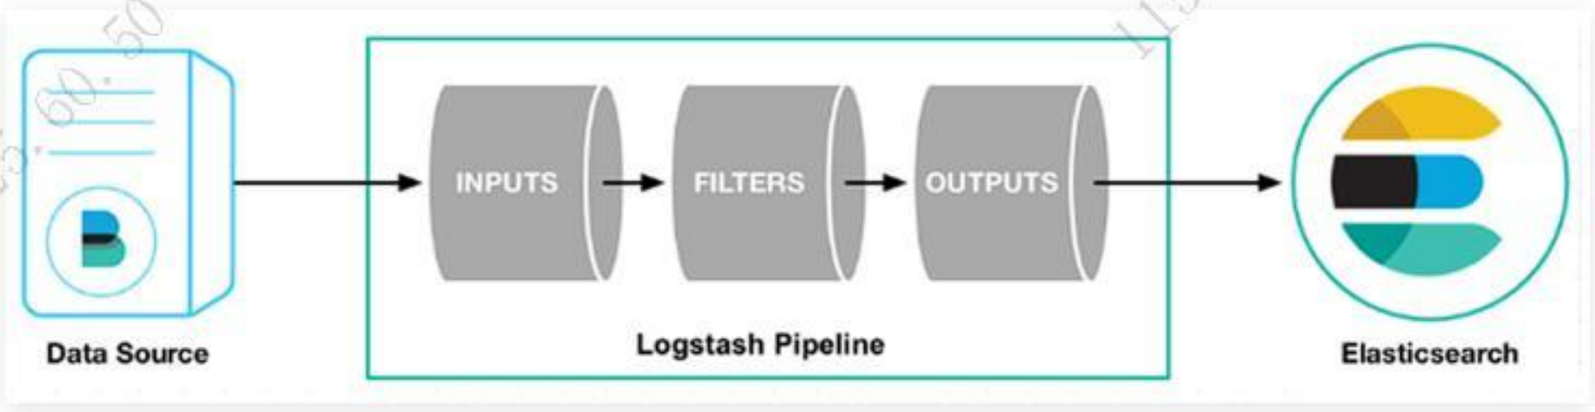


图 5-6 Logstash 关键流程图

Fig.5-6 Key process flowchart of Logstash

通过 Logstash 实现同时从多个来源采集数据，转换数据后将数据发送到“存储库”中。拥有高达 200 多个插件供扩展使用，安装过程如图 5-7。

```
[root@elk4 ~]# yum install -y jdk-11.0.15_linux-x64_bin.rpm
Loaded plugins: langpacks, product-id, search-disabled-repos, subscription-manager
This system is not registered with an entitlement server. You can use subscription-manager to register.
Examining jdk-11.0.15_linux-x64_bin.rpm: 2000:jdk-11-11.0.15-ga.x86_64
Marking jdk-11.0.15_linux-x64_bin.rpm to be installed
Resolving Dependencies
--> Running transaction check
---> Package jdk-11.x86_64 2000:11.0.15-ga will be installed
--> Finished Dependency Resolution

Dependencies Resolved

================================================================================
 Package                 Arch                 Version                 Repository                 Size
================================================================================
Installing:
 jdk-11                  x86_64               2000:11.0.15-ga         /jdk-11.0.15_linux-x64_bin 269 M

Transaction Summary
================================================================================
Install  1 Package

Total size: 269 M
Installed size: 269 M
Downloading packages:
Running transaction check
Running transaction test
Transaction test succeeded
Running transaction
  Installing : 2000:jdk-11-11.0.15-ga.x86_64                               1/1
  Verifying  : 2000:jdk-11-11.0.15-ga.x86_64                               1/1

Installed:
  jdk-11.x86_64 2000:11.0.15-ga

Complete!
```

图 5-7 Logstash 安装

Fig.5-7 Logstash installation

使用 ip 地址 192.168.67.33 安装部署 logstash，如图 5-8 所示。

```
[root@elk4 ~]# yum install -y logstash-7.6.1.rpm
Loaded plugins: langpacks, product-id, search-disabled-repos, subscription-manager
This system is not registered with an entitlement server. You can use subscription-manager to register.
Examining logstash-7.6.1.rpm: 1:logstash-7.6.1-1.noarch
Marking logstash-7.6.1.rpm to be installed
Resolving Dependencies
--> Running transaction check
---> Package logstash.noarch 1:7.6.1-1 will be installed
--> Finished Dependency Resolution

Dependencies Resolved

================================================================================
 Package                 Arch                 Version                 Repository                 Size
================================================================================
Installing:
 logstash                noarch               1:7.6.1-1               /logstash-7.6.1            291 M

Transaction Summary
================================================================================
Install  1 Package

Total size: 291 M
Installed size: 291 M
Downloading packages:
Running transaction check
Running transaction test
Transaction test succeeded
Running transaction
  Installing : 1:logstash-7.6.1-1.noarch                                   1/1
Using provided startup.options file: /etc/logstash/startup.options
Java HotSpot(TM) 64-Bit Server VM warning: Option UseConcMarkSweepGC was deprecated in version 9.0 and will likely be removed in a future release.
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by com.headius.backport9.modules.Modules to method sun.nio.ch.NativeThread.signal(long)
WARNING: Please consider reporting this to the maintainers of com.headius.backport9.modules.Modules
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access operations
WARNING: All illegal access operations will be denied in a future release
/usr/share/logstash/vendor/bundle/jruby/2.5.0/gems/pleaserun-0.0.30/lib/pleaserun/platform/base.rb:112: warning: constant ::Fixnum is deprecated
Successfully created system startup script for Logstash
  Verifying  : 1:logstash-7.6.1-1.noarch                                   1/1

Installed:
  logstash.noarch 1:7.6.1-1

Complete!
```

图 5-8 Logstash 部署

Fig.5-8 Logstash deployment

Kibana：一个用于可视化和分析存储在 Elasticsearch 中的日志数据的用户界面。Kibana 提供了一个直观且功能强大的仪表盘，可以根据特定需求创建各种图表、表格和地图，并进行实时数据可视化和监控如图 5-9 所示。

通过 Kibana 拥有精选的时序性 UI，搭载了一批经典功能：柱状图、线状图、饼图、旭日图，等等，对您 Elasticsearch 中的数据执行时间序列分析。



图 5-9 Kibana 组件操作界面图

Fig.5-9 Kibana component operation interface diagram

通过新建指标，定制数据可视化指标，生成网站访问量。并将创建的可视化添加到仪表板中如图 5-10 和图 5-11 所示。



图 5-10 流量指标

Fig.5-10 traffic metrics

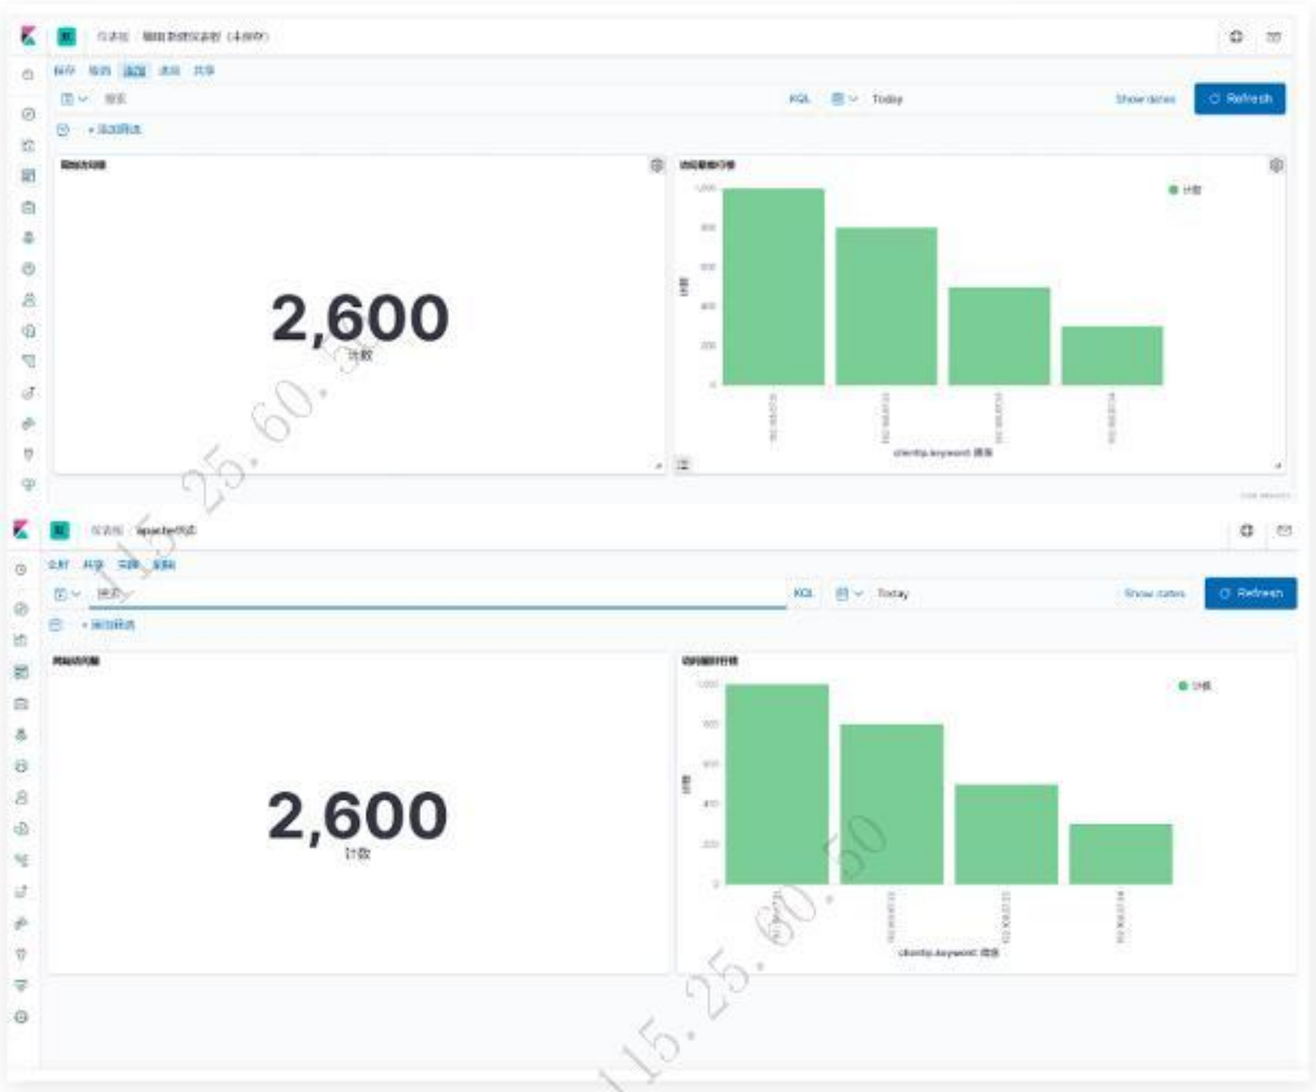


图 5-11 可视化仪表盘

Fig.5-11 Visual dashboard

除此之外，ELK 系统还支持以下功能和扩展，如 Metricbeat：搜集系统、进程和文件系统级别的 CPU 和内存使用情况等数据。通过从操作系统和服务收集指标，帮助您监控服务器及其托管的服务。

Heartbeat 心跳监测不管测试同一台主机上的服务，还是要测试开放网络上的服务，Heartbeat 都能轻松生成运行时间数据和响应时间数据 Heartbeat 能够通过 ICMP、TCP 和 HTTP 进行 ping 检测，同时也支持 TLS，认证和代理，您可以借助简易的 DNS 解析，监控负载均衡服务器背后的所有主机，安装系统环境如图 5-12 所示[48] 。



图 5-12 全流程可视化仪表盘

Fig.5-12 Full-process visual dashboard

基于 ELK 平台可以实现对数据的监控与收集，为后期分析实验数据，对实验数据进行统计学分析提供了基础。呈现出后台日志实时抓取并初步分析的效果，如图 5-13 所示。

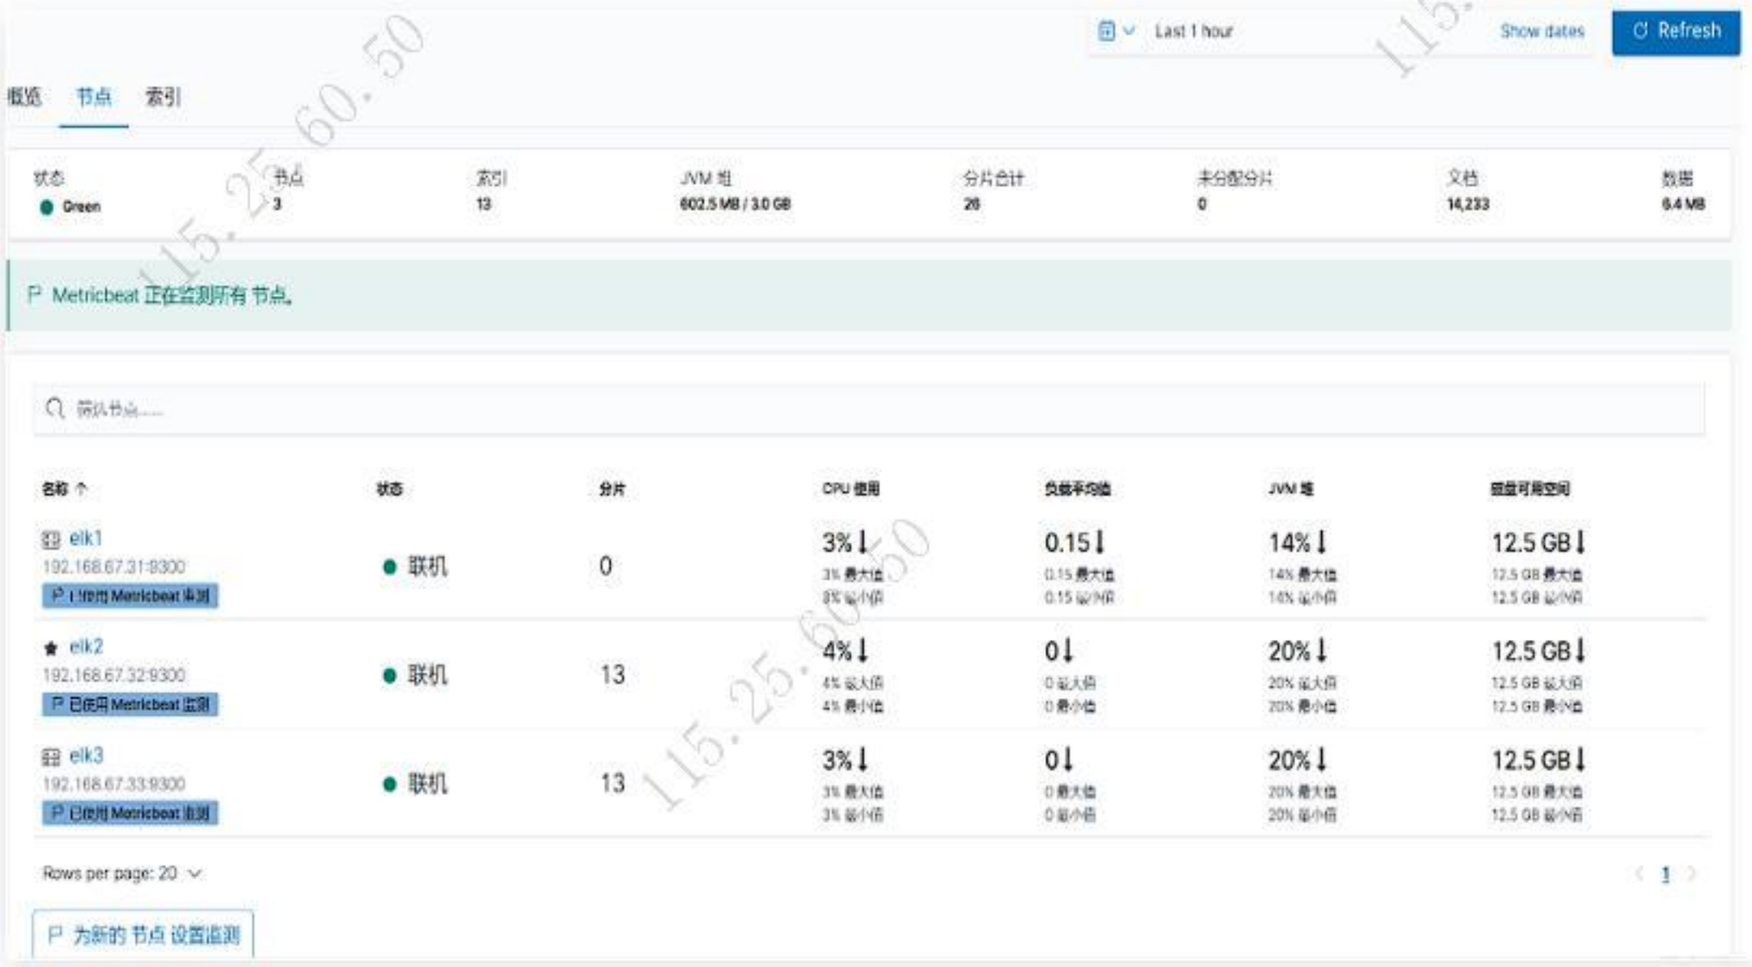


图 5-13 监控平台

Fig.5-13 monitoring platform

5.3 长文本处理模块设计与实现

在金融产品推荐系统中，长文本处理模块承担着关键的数据预处理功能，负责处理来自多源的大规模文本数据。这些数据包括 Excel/CSV 格式的金融产品信息、用户行为日志、产品描述文档以及用户画像文本，还比如部分生产场景如分析保险产品的团单购买场景、关联投保人场景时可能涉及到几百甚至上千人的用户数输入等。于是对于长文本的处理和拆解变得尤为重要。随着业务量的增长，每日需要处理的文件数量可达数万份，总数据量达到 TB 级别。传统的数据处理方法已无法满足高效、稳定处理的需求，因此需要设计一个能够处理海量文本数据的专业化模块。

长文本处理模块采用分层架构设计，主要包括文件接收与验证层、分布式存储层、流式处理引擎、文本解析层、结构化数据处理层以及监控管理层。这种分层设计使得系统具有良好的可扩展性和可维护性，各层之间通过标准接口进行通信，降低了系统耦合度[49] 。

具体接口如表 5-2 所示。

表 5-2 接口表

Tab.5-2 interface table

接口名称	方法	路径	主要功能
文件上传接口	POST	/v1/text-processing/upload	上传长文本文件进行异步处理
处理状态查询接口	GET	/v1/text-processing/status/{taskId}	查询处理任务状态
处理结果获取接口	GET	v1/text-processing/result/{taskId}	获取处理完成的结构化结果
批量文件提交接口	POST	/v1/text-processing/batch-upload	批量提交多个文件进行处理
处理中断与重试接口	POST	/v1/text-processing/retry/{taskId}	中断或重新执行失败任务
文件处理历史查询接口	GET	/v1/text-processing/history	查询用户或系统的处理历史记录

处理模块采用流式处理模式调用 Vercel AI SDK 处理架构，其提核心组件包括流式文本生成函数 streamText()，流消费处理器 consumeStream()，提供根据文件大小自动选择不同的处理策略。对于小于 100MB 的文件，采用直接内存处理方式，保证处理效率；对于 100MB 至 2GB 的中等文件，采用分块加载方式，平衡内存使用和处理性能；对于超过 2GB 的大文件，则采用完全的流式处理，避免内存溢出风险，处理模式如图 5-14 所示。

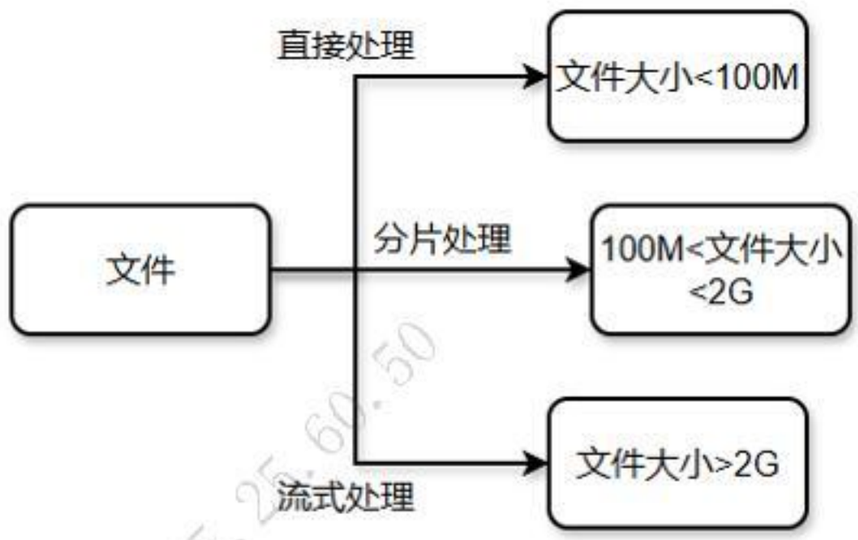


图 5-14 处理模块处理模式示意图

Fig.5-14 Processing module processing mode

中等文件处理的任务拆分与底层数据结构设计，首要步骤是任务拆分，其底层依赖于数据结构的合理设计。常见的方式是将长文本按字节偏移量或语义段落进行划分。以固定字节数（如 1024 字节）为单位拆分时，需要记录每个子任务的起始和结束偏移量，通过自定义的任务描述结构体实现，结构体中包含任务 ID、文本偏移范围、处理状态等字段。大文件的流式处理，避免大文件一次性加载到内存并使用对象池技术减少频繁创建对象的开销，上

文中的 ELK 栈在此过程中可以负责日志收集和分析，包括处理吞吐量、资源使用率、错误率和处理延迟等关键指标和可视化监控界面，实时展示系统运行状态[50]，帮助运维人员快速定位和解决问题。

在数据结构层面，使用双向链表或数组存储这些子任务描述信息。双向链表便于动态插入和删除任务，适合在运行时根据负载动态调整任务分配；数组则具有高效的随机访问特性，适合预先确定任务数量的场景。操作系统通过内存映射技术，将长文本文件映射到内存地址空间，线程可以直接访问映射后的内存区域，避免频繁的磁盘 I/O 操作，提升数据读取效率。对于线程池中的线程处于空闲状态的情况，会尝试从任务队列中获取子任务。这一过程涉及操作系统的线程同步机制，线程通过互斥锁锁定任务队列，防止多个线程同时访问导致数据竞争。如果任务队列为空，线程会通过条件变量进入等待状态，释放 CPU 资源；当有新任务加入队列时，操作系统会唤醒等待的线程，使其继续执行任务[42]。

模块的处理流程大致如下客户端通过 HTTP 协议上传文件，之后由服务端验证文件类型是否为可处理类型等，检查文件大小限制，文件大小是否超过 2GB，验证文件内容的基本结构，如标题行，生成唯一文件标识符，批次处理号，用于后续追踪，流程如图 5-15 所示。

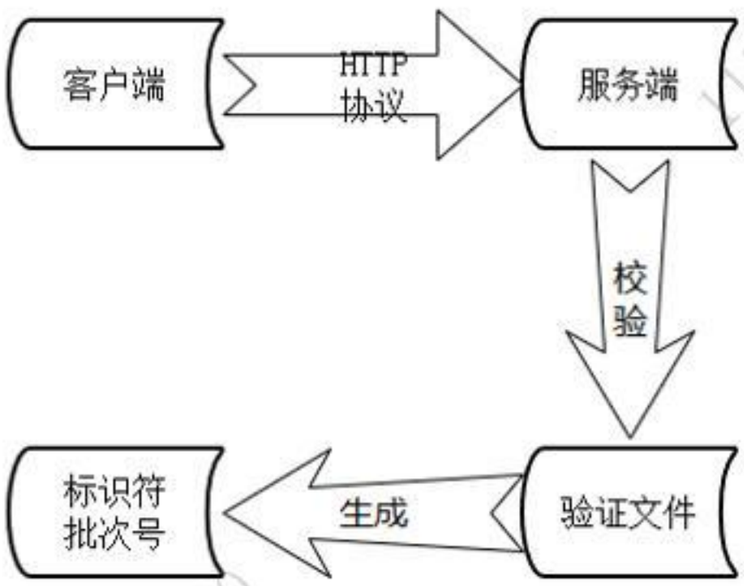


图 5-15 模块的处理流程图

Fig.5-15 Module processing

长文本处理方案其底层技术逻辑紧密依赖于操作系统的进程与线程管理、内存管理、资源调度和同步机制。通过合理利用这些底层技术，实现任务的高效拆分、并行处理、数据同步和结果合并，从而大幅提升长文本处理的性能和效率。在实际应用中，根据具体的业务场景和系统资源进行优化和调整，可以充分发挥多线程和高并发技术的优势。该模块的成功实施为金融推荐系统提供了稳定可靠的数据支撑，使得后续的关联规则挖掘、用户画像构建和推荐算法计算能够基于高质量的数据进行。时序图如图 5-16：

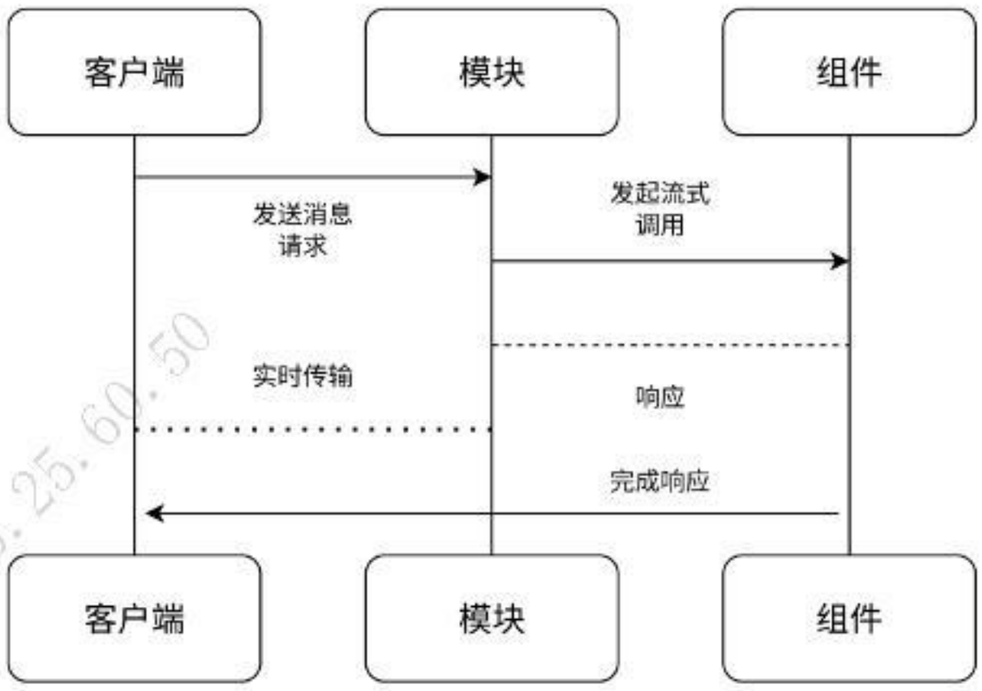


图 5-16 模块的处理时序图

Fig.5-16 Processing sequence diagram of module

5.4 分布式数据库设计与搭建

数据库的连接与部署过程如图 5-17 和图 5-18 所示：

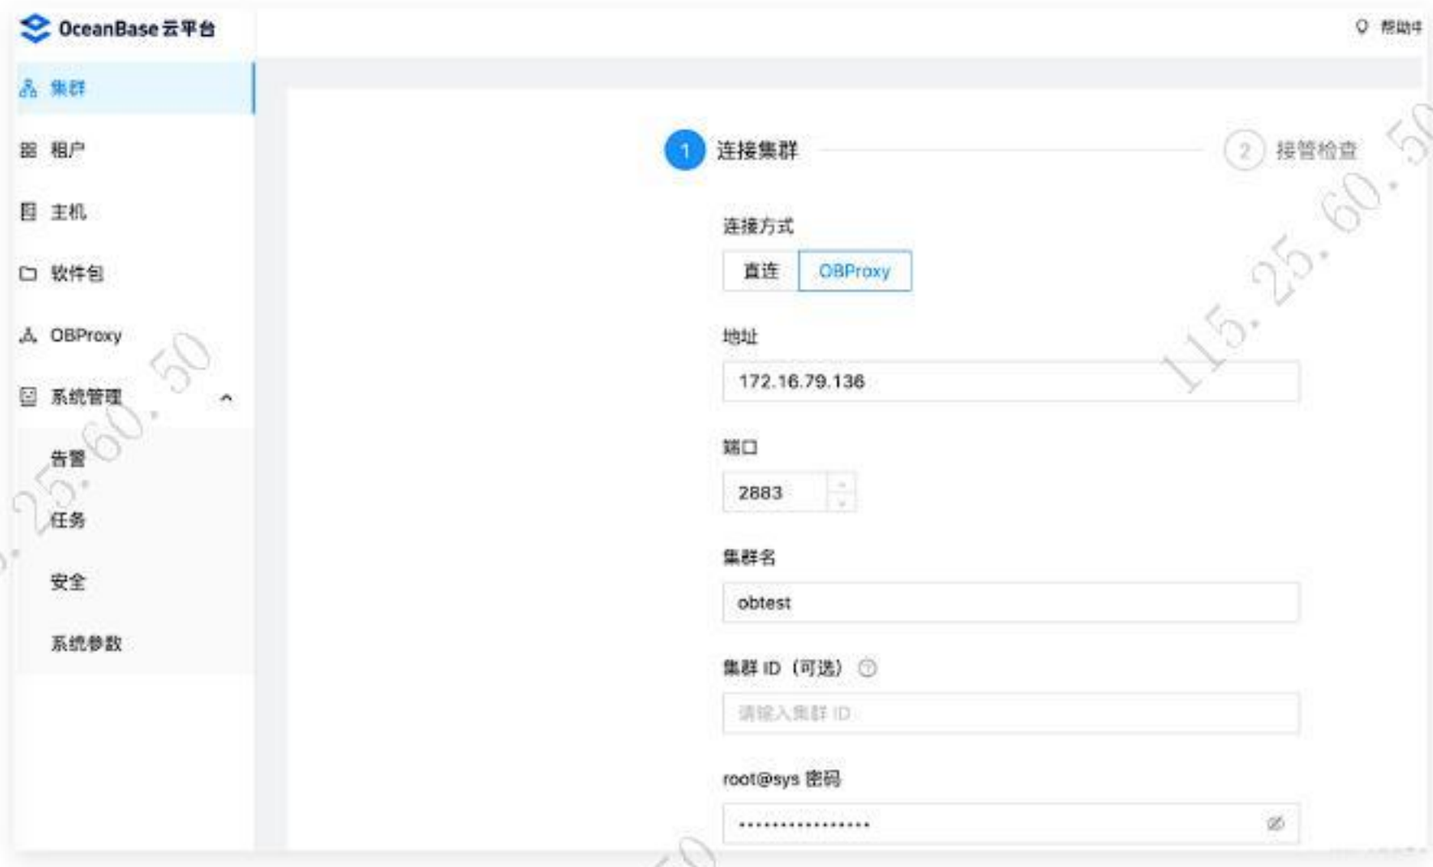


图 5-17 数据库的连接

Fig.5-17 Database connection



图 5-18 数据库的部署

Fig.5-18 Deployment of database

数据分片采用范围分片，根据数据的分片键的取值范围将数据分配到不同的节点上。例如，将用户 ID 在 1-1000 的用户数据存储在节点 1，将用户 ID 在 1001-2000 的用户数据存储在节点 2。范围分片的优点是便于数据的范围查询[51]-[52]。

数据分片后可以通过中间件 MyCat（一个开源的 MySQL 分布式中间件，支持数据分片、读写分离、负载均衡等功能）来实现跨分片查询。中间件会将跨分片查询拆分成多个子查询，分别发送到不同的分片节点上执行，然后将结果合并返回给客户端。并通过以下策略解决主从复制延迟问题。一、优化主节点的性能，减少写操作的时间。二、增加从节点的资源，提高从节点的处理能力。三、采用并行复制技术，提高从节点的复制效率[53]-[55]。策略如图 5-19 所示。

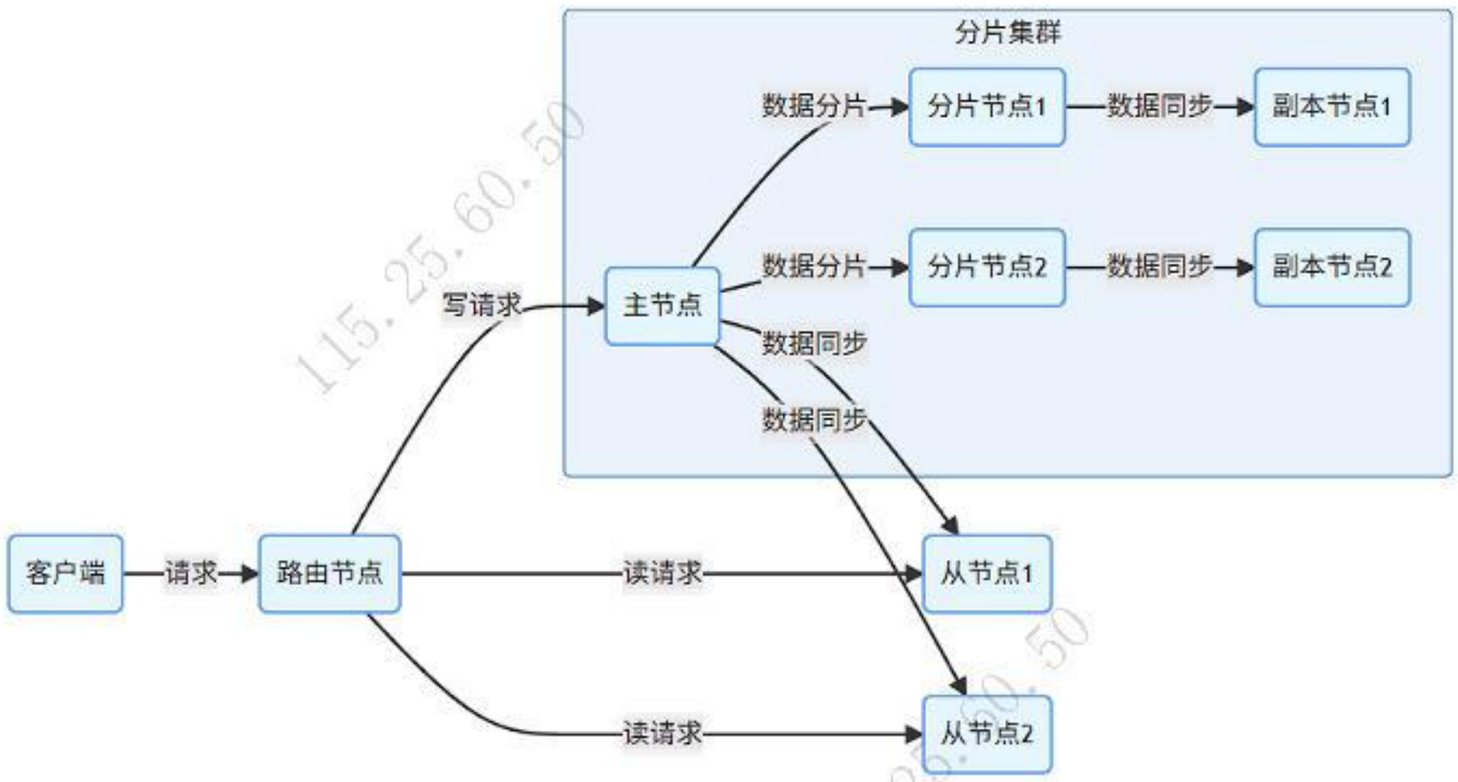


图 5-19 分布式数据库策略示意图

Fig.5-19 Schematic diagram of distributed database strategy

由于涉及数据库表较多，因此对几个重要的表进行介绍，具体内容如如表 5-3。

表 5-3 数据库表

Tab.5-3 database table

应用	数据库表名	表描述
用户基础特征	user_base_feature	用户基础特征表
用户分群画像	user_grouping	用户分群画像表
产品高频集	product_high_frequency	产品高频集表

用户基础特征表用于记录用户的基础特征，如用户唯一标识、用户年龄、年龄分组（加工特征，如：‘25-34’）、总资产规模（元）、资产分级（加工特征，如：‘100 万-500 万’）等，定义并储存了用户的基本信息。用户分群画像表用于记录用户的分群画像，以用户唯一标识与用户基础特征表关联，其主要字段有用户分群标签（如：重要价值客户）、风险偏好（1:低, 2:中, 3:高）、消费能力（1:低, 2:中, 3:高）、流失风险评分、忠诚度评分等。产品高频集表主要用于记录产品高频集，用于记录产品筛选的高频集，记录支持度、置信度、提升度等信息，主要存储字段见表 5-4[56] 、5-5、5-6。

表 5-4 产品频繁项集表

Tab.5-4 Product frequent itemset table

表名	字段名	字段简述
product_high_frequency (产品频繁项集表)	user_id	用户唯一标识
	antecedent	规则前提，包含的产品 ID 列表
	consequent	规则结果，被推荐的产品 ID 列表
	support	支持度，规则出现的频率
	confidence	置信度，前提出现后结果出现的概率
	lift	提升度，衡量规则的有效性（>1 为正相关）
	created_time	规则创建时间
	last_updated_time	规则最后更新时间

表 5-5 用户分群画像表

Tab.5-5 User segmentation portrait table

表名	字段名	字段简述
user_grouping (用户分群画像表)	user_id	用户唯一标识
	cluster_label	用户分群标签（如：重要价值客户）
	risk_preference	风险偏好（1:低, 2:中, 3:高）
	consumption_ability	消费能力（1:低, 2:中, 3:高）
	churn_risk_score	流失风险评分（越高越可能流失）
	loyalty_score	忠诚度评分
	model_version	生成此画像的模型版本号
	last_calculated_time	画像最后计算更新时间

表 5-6 用户基础特征表

Tab.5-6 User basic feature tablee

表名	字段名	字段简述
user_base_feature (用户基础特征表)	user_id	用户唯一标识
	age	用户年龄
	age_group	年龄分组（加工特征，如：'25-34'）
	total_assets	总资产规模（元）
	asset_band	资产分级(加工特征，如：'100 万-500 万'）
	number_of_held_products	当前持有产品总数
	avg_transaction_frequency	近 180 天日均交易次数
	last_transaction_date	最近一次交易日期
	features_updated_time	特征最后更新时间

5.5 本章小结

本章主要基于前文提出的理论并结合现阶段前沿软开技术实现了金融产品推荐算法的可视化系统，在考虑系统实时性和获取用户数据复杂性的同时通过设计分布式数据库的方式，解决了可能存在的分库与总库可能出现的冲突与时延问题，系统实现了日志实时监控采集，长文本处理，分布式存储等核心模块。沿系统架构，模块功能，数据库设计的顺序逐步介绍。

6 系统测试

6.1 实验环境

产品推荐系统依赖的硬件实验环境如表 6-1。

表 6-1 系统硬件依赖表

Tab.6-1 System hardware dependency table

序号	硬件类型	版本
1	处理器	14th Gen Intel(R) Core(TM) i9-14900HX 5.8GHz
2	内存	32G DDR5 6000MHz
3	网卡	Intel(R) Wi-Fi 6E AX211 160MHz
4	硬盘存储	2T SSD

产品推荐系统依赖的软件实验环境如表 6-2。

表 6-2 系统软件依赖表

Tab.6-1 System software dependency table

序号	软件	版本	说明
1	Java	18	后端编程软件
2	Oceanbase	4.3.5	后端数据库
3	Node.js	14.19.2	前段编程
4	Nginx	1.18.0	反向代理
5	MongoDB	7.0	文档存储容器

6.2 功能测试



图 6-1 登录界面

Fig.6-1 Login screen

在登录界面如图 6-1 所示，输入手机号获取验证码，即可完成登录。之后通过用户实现点击产品浏览，并实现产品购买的功能流程。

用户一为重要挽留客户其购买产品历史，关联产品表，用户分群画像，推荐产品列表如表 6-3。

表 6-3 客户一基本信息表

Tab.6-3 Basic information table of customer 1

属性类别	属性名称	属性值
基本信息	客户 ID	CUST_2024_8R7X
	年龄	52
	年龄分组	45-55
价值特征	年消费金额	￥186,000
	资产规模	￥1,250,000
	资产分级	100 万-500 万
行为特征	交易频率	1.2 次/月
	最近一次交易日期	2025-08
	产品持有数	8
风险特征	风险偏好	低 (1)
	投资杠杆率	0.15
潜力特征	消费能力	低 (1)
	收入增长率	-0.05
系统画像	客户分群标签	重要挽留客户
	流失风险评分	低
	忠诚度评分	高

产品名称	公告时间	年结算利率%	日结算利率%
福富有余终身寿险（万能型）	2025年08月	2.5	0.006766
福富有余终身寿险（万能型）	2025年08月	2.5	0.006766
福富有余终身寿险（万能型，B款）	2025年08月	2.5	0.006766
金管家终身寿险（万能型，钻石版）	2025年08月	3	0.008099
金管家终身寿险（万能型，钻石增强版）(2022年11月29日及以前生...	2025年08月	3	0.008099
金管家终身寿险（万能型，钻石增强版）(2022年11月30日及以后生...	2025年08月	3	0.008099
金管家终身寿险（万能型，2023版）	2025年08月	2.8	0.007567
金管家终身寿险（万能型，祥瑞版）	2025年08月	2.8	0.007567

图 6-2 客户一部分购买历史

Fig.6-2 Part of the customer's purchase history

产品名称	公告时间	年结算利率%	日结算利率%
金管家终身寿险（万能型，钻石版）	2025年08月	3	0.008099
金管家终身寿险（万能型，祥瑞版）	2025年08月	2.8	0.007567
财富一号两全保险（万能型，D款）	2025年08月	2.5	0.006766
财富一号两全保险F款（万能型，至尊版）(2019年12月26日及以前生...	2025年08月	3	0.008099
金管家年金保险（万能型，B款）	2025年08月	2.5	0.006766
金管家年金保险（万能型，C款）	2025年08月	3.5	0.009426
金管家养老年金保险（万能型，赢家版）	2025年08月	3	0.008099
节节高终身寿险（万能型，尊享版）(2022年11月29日及以前生效的...	2025年08月	3	0.008099
财富一号养老年金保险（万能型，F款）(2017年07月31日及以前生效...	2025年08月	3	0.008099
金葵花终身寿险（万能型）(2022年11月29日及以前生效的保单)	2025年08月	3	0.008099
金管家终身寿险（万能型，钻石增强版）(2022年11月30日及以后生...	2025年08月	3	0.008099
华夏禧企业补充团体养老年金保险（万能型，B款）	2025年08月	2.5	0.006765

图 6-3 客户一关联产品列表

Fig.6-3 List of related products for customer one



图 6-4 客户一推荐产品列表

Fig.6-4 List of recommended products by customer 1

用户二为一般价值客户其购买产品历史，关联产品表，用户分群画像，推荐产品列表如表 6-4。

表 6-4 客户二基本信息表

Tab.6-4 Basic information table of customer 2

属性类别	属性名称	属性值
基本信息	客户 ID	CUST_2023_5T3Y
	年龄	38
	年龄分组	35-44
价值特征	年消费金额	￥68,000
	资产规模	￥380,000
	资产分级	30 万-100 万
行为特征	交易频率	5.5 次/月
	最近一次交易日期	2025-08
	产品持有数	5
风险特征	风险偏好	中 (2)
	投资杠杆率	0.35
潜力特征	消费能力	中 (2)
	收入增长率	0.08
系统画像	客户分群标签	一般价值客户
	流失风险评分	低
	忠诚度评分	高

产品名称	公告时间	年结算利率%	日结算利率%
聚宝盆团体年金保险（万能型）	2025年08月	2.5	0.006765
聚宝盆团体年金保险（万能型）	2025年07月	2.5	0.006765
聚宝盆团体年金保险（万能型）	2025年06月	2.5	0.006765
聚宝盆团体年金保险（万能型）	2025年05月	2.5	0.006765
聚宝盆团体年金保险（万能型）	2025年04月	2.5	0.006765

图 6-5 客户二部分产品购买历史

Fig.6-5 Purchase history of two parts of products by customers

产品名称	公告时间	医疗赔付比例%
常青树重大保险A型	2025年08月	3
常青树重大保险A型	2025年07月	3
常青树重大保险B型	2025年06月	3
常青树重大保险C型	2025年06月	3

图 6-6 客户二部分关联产品列表

Fig.6-6 List of related products for customer segment 2



图 6-7 客户二推荐产品列表

Fig.6-7 List of recommended products by Customer 2

6.3 接口测试

6.3.1 测试方案

测试方案分为单一接口测试和接口压测两个部分。接口测试利用Postman测试工具，测试各个接口是否满足需求，性能压测主要测试算法在生产环境中的稳定性和安全性是否符合系统需求[27] 。

在分布式客户端-服务器系统中，测试是从服务器跨所有客户机完成的。压力服务器的作用是向所有压力客户端分发一组压力测试，并跟踪客户端的状态。客户端与服务器联系后，服务器添加客户端名称，并开始发送数据进行测试。

同时，客户端机器发送与服务器连接的信号或心跳。如果服务器没有从客户端机器接收到任何信号，则需要进一步研究以进行调试。从图中可以看出，一个服务器可以连接 2 个客户端(Client1 和 Client2)，但它不能从客户端 3 和 4 发送或接收信号[57] 。

利用 JMeter 分布式压测工具进行软件测试面试准备解决测试问题，在面对 10000 用户购买 100 件产品，在验证性能时，传统方式更倾向于单台测试机最多模拟 1 万用户，达到目标很繁琐，利用测试工具实现的的分布式方案，可以使用 10 台服务端，每台模拟 1 万用户对产品进行购买，既更好的契合了测试复杂生产环境下功能是否达标的要求，也能进一步模拟用户的真实购买操作，测试流程如图 6-8 所示。

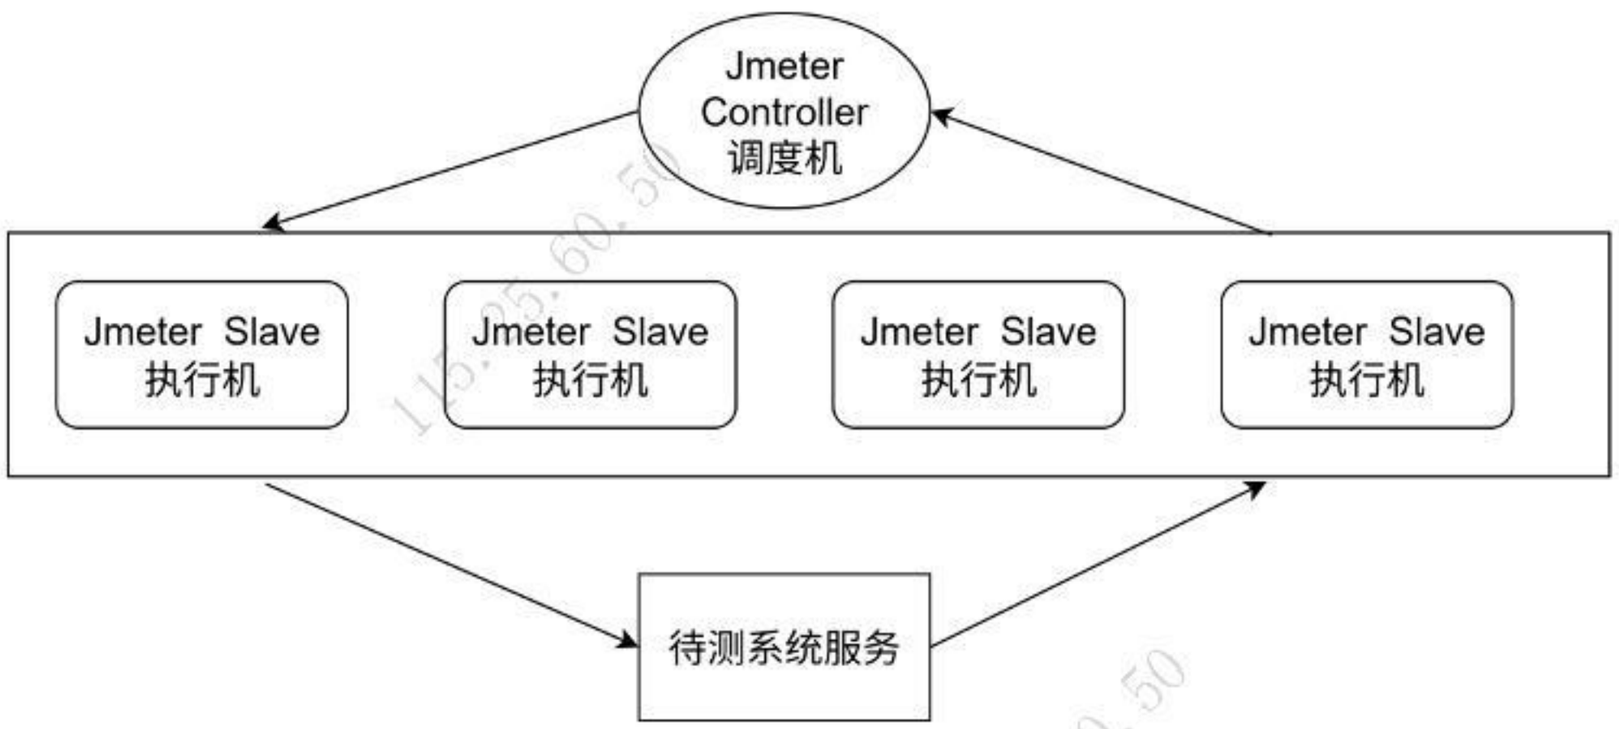


图 6-8 测试执行流程示意图

Fig.6-8 Schematic diagram of test execution process

并组织以下主要操作，并确保生成事务样本，以便统计 TPS 和响应时间。

用户登录 (POST/login)，获取产品列表 (GET/products)，查看产品详情 (GET /product/{id})，添加购物车 (POST/cart/add)，提交订单 (POST/order/submit)，支付（模拟） (POST /pay/simulate)，在控制机上，使用命令行（非 GUI 模式）执行测试，以减少资源消耗并提高效率。

具体指标：

吞吐量 (Throughput)：系统每秒处理的事务数（TPS）。

响应时间 (Response Time)：关键接口的平均响应时间、90%百分位响应时间（P90）和最大响应时间，期望核心交易接口响应时间不超过 2 秒。

错误率 (Error Rate)：HTTP 状态码非 200 或业务逻辑错误的请求比例，目标低于 0.1%[57] 。

系统资源利用率：监控测试期间服务器的 CPU、内存、磁盘 I/O、网络带宽使用情况，定位潜在瓶颈。

6.3.2 测试结果

吞吐量与响应时间：系统在达到 10,000 并发后，TPS 稳定在 300 以上，且平均响应时间稳定在 800 毫秒以下，表明系统处理能力强劲，完全满足万级并发的业务需求。提交订单接口是整个链路中最耗时的操作，其 P95 时间为 1.8 秒，仍优于预设目标。

错误率：整个压测过程中错误率极低（0.02%），主要为压力峰值时段出现的零星超时（504 Gateway Timeout），经排查为数据库连接池等待时间过长所致，未出现大量业务逻辑错误，表明系统稳定性良好。

各主要接口返回值符合预期如表 6-5，未出现异常。

表 6-5 接口测试结果表

Tab.6-5 Interface test result table

接口名称	接口描述	请求方式	预期返回
product_high_frequency	user_id	POST	正确
	antecedent	POST	正确
	consequent	POST	正确
	support	POST	正确
	confidence	POST	正确

6.4 性能测试

本性能测试采用多层次验证框架，从算法性能、系统效果和实际应用三个维度全面评估金融产品推荐系统的有效性。实验设计遵循控制变量原则，确保实验结果的可比性和可靠性。首先进行关联规则算法对比实验，评估不同算法对系统性能的影响；然后进行用户分群准确性验证，确保画像模块的可靠性；最后通过在线指标和用户反馈评估系统整体效果。所有实验均基于真实金融场景数据，实验周期为 3 个月，确保数据的充分性和结论的稳定性。

1. 通过评估多模态点击预估算法各个模块完整融合后，对排序算法中 AUC 和排序损失等指标，评估，对部分模块在产品推荐中性能与整体系统性能进行对比，分别基于基础特征、基础特征+关联规则、基础特征+人员画像、系统完整融合几种情况下的 AUC、排序排序、分群一致性几个指标，分析实验数据推导分析得出结论[58] -[59] 。

2. 通过系统使用者的实际反馈进行归纳总结，进一步确认算法在复杂的现实生产环境中的实际性能。设计多维度的用户反馈机制，首先通过系统内置的反馈按钮收集用户对推荐结果的直接评价有如有用和无用，其次开展用户问卷调查，从推荐准确性、多样性、新颖性等维度收集用户满意度，与销售人员沟通使用效果，深入了解用户使用体验和需求[60] 。反馈分析采用定量和定性相结合的方法：定量分析反馈数据的分布和趋势，计算用户满意度指标；定性分析用户访谈内容，提取关键观点和改进建议[35] 。特别关注不同分群用户的反馈差异，分析系统对不同类型用户的适用性。

6.4.1 评价指标

利用 AUC、排列损失、分群一致性等指标，配合用户留存率、挽回率、满意度进行评估[61] 。

AUC 的含义为模型给一堆样本包括已知的正负类别标签，进行预测打分，然后将他们从大到小排序，正样本能够正确排在负样本前面的概率就是 AUC 可以把 AUC 理解为区分正类和负类的能力，当 AUC 越大，表示区分正负类的能力越强。当模型对正负样本没有区分能力时，模型会将一个样本随机预测为正类或负类，此时 AUC=0.5，因此 AUC 的有效范围是(0.5,1]。

$$AUC = \frac{\sum I(p_{pos}, p_{neg})}{P \cdot N} \tag{6-1}$$

$$I(p_{pos}, p_{neg}) = \begin{cases} 1 & p_{pos} > p_{neg} \\ 0.5 & p_{pos} = p_{neg} \\ 0 & p_{pos} < p_{neg} \end{cases} \tag{6-2}$$

其中 P 为正样本数量，N 为负样本数量，p 为正样本预测得分，即将正样本

预测正例的概率，n 为负样本预测得分，即将负样本预测为正例的概率。

AUC 是根据所有分类阈值得到的，不依赖于分类阈值的选取。AUC 体现的是对样本的排序能力，与具体的分值无关。因此 AUC 和推荐系统中的大多数业务场景更贴合，因为大多数业务场景关心相对顺序而不关心预测分。排序损失衡量的是分类器输出的预测值与实际标签的一致性。在二分类问题中，排序损失通常指的是正样本的预测值低于负样本预测值的情况。理想情况下，我们希望正样本的预测值高于负样本[56] 。

$$AUC = 1 - l_{rank} \tag{6-3}$$

用户分群一致性用来衡量同一用户在一段时间内进行的用户画像或者分群是否稳定，用户被划分到相同组或者类似群组的稳定性和可重复性，简单来说就是用户的分群结果是否可靠、稳定、不随机。其核心关心点在于时间稳定性、方法稳定性可重复性、业务逻辑稳定性，时间稳定性指的是如果用户的行为和特征没有发生本质变化，那么今天的分群结果和明天的分群结果在使用相同的分群逻辑时应该高度一致[57] 。用户不应该在不同时间点频繁地在不同群体间“跳跃”，除非用户本身行为发生了显著变化。方法稳定性、可重复性指的是使用不同的数据样本但来自同一总体、或者同一个算法的不同随机初始化，对于同一批用户，产生的分群结构应该是相似的。业务逻辑一致性指的是分群结果是否符合业务常识和预期，例如，“高价值用户”群组中的用户，其消费金额、频率等核心指标是否确实显著高于其他群体，不同群体间的特征差异是否足够明显[9],[40] 。不一致的分群结果会导致基于分群的决策、营销策略、产品推荐、资源分配不稳定、不可靠，甚至相互矛盾。在假设分群方法稳定的前提下，用户群体归属的变化才能更可靠地反映用户自身行为或特征的真实变化。

6.4.2 数据准备

在本研究的应用场景中，利用某公司的后端数据，随机抽样选取银保事业部及财产险部两年内的销售数据作为本实验的实验数据，这些数据为生产运行环境脱敏后的数据，基于真实生产场景消费和推荐的行为特征构建，这一选择是基于银保业务的特殊性，其既有银行代售的财产险，寿险等保险产品，又有和银行合作的投资理财等产品，可以大幅度提升算法评估数据的准确度，由数据的敏感性且涉及商秘和用户隐私，部分数据转换为数字格式表示，但这些差异不会对数据的分析产生影响，后续的算法性能分析会围绕这些数据展开[39] 。

高质量的数据是确保数据分析结论准确性的根本前提。在启动用户行为分析流程之前，必须对原始数据进行系统的清洗与预处理，其核心目标在于全面提升数据质量，为后续的深入分析、算法模型构建及实验评估奠定坚实基础。数据预处理的核心任务，正是识别并解决数据中的异常与缺失问题，通过科学方法剔除数据集中的“噪声”数据——即明显偏离正常范围的异常值，并对存在缺失的有效信息进行合理修复或填补。另一方面，通过完整性校验发现部分用户存在数据记录全空的情况[40] ，对此类严重缺失的行为数据同样执行清除操作，从而确保数据集中所有用户行为记录均为非空状态，最大限度地保障数据的完整性与一致性。

为保证数据的质量与可操作性，避免无关数据和高风险数据影响实验，需要进行一定处理，处理具体流程如下：

一：缺失值处理、无关值处理，对于部分数据如年龄，购买产品历史等数值存在缺失和存储数据中的无关数据，如用户 id，账户操作人等无关用户数据进行筛选并删除。

二：异常值处理，对于数值明显偏大或明显偏小的数值，明显与其他数据差异过大的数据，则判断该数据属于异常值，对于异常数值单独存储，慎重使用，避免干扰实验[9] 。

6.4.3 结果与分析

在实验过程中，多模态点击率预估模型达到了相对较好的性能。在数据集上，双层交互模型在 AUC 方面比 FNN 高出 0.571%和 0.386%，在对数损失方面分别为0.819%和0.374%，在AUC方面比DeepFM高出0.322%和0.49%，其在对数损失方面分别为 0.594%和 0.589%。评估指标及结果如表 6-6：

表 6-6 算法性能对比表

Tab.6-6 Algorithm Performance Comparison Table

特征组合	AUC	排序损失	分群一致性
仅基础特征	0.781	0.219	0.65
基础+规则	0.802	0.198	0.72
基础+画像	0.815	0.185	0.88
完整融合	0.832	0.168	0.91

可以看到当我们删除任何组件时性能都会明显下降，整个系统各个部分的完整融合能充分的发挥算法作用，提高特定用户对关联产品的购买意愿和

产品列表的契合度。在引入 FiBiNET 层特征交互模块，显著提升了推荐效果。该方案在金融生产场景中 CTR 提升 27.6%，转化率提高 34.2%。

在系统模块上线实施 6 个月后，通过期间线上和线下调查问卷，分别向客户和使用过系统的客户经理进行调研，并通过后台数据的抓取和统计，统计的效果对比如表 6-7：

表 6-7 系统模块上线后效果反馈表

Tab.6-7 Feedback form on the effect of system module after going online

指标	实施前	实施后	提升
高价值客户留存率	78%	92%	+14%
流失客户挽回率	22%	48%	+26%
交叉销售成功率	15%	28%	+13%
无效营销成本占比	35%	28%	-7%
客户满意度	81%	89%	+8%
转化率	3.8%	5.1%	+34.2
人均产品数	2.1	2.8	+33.3%

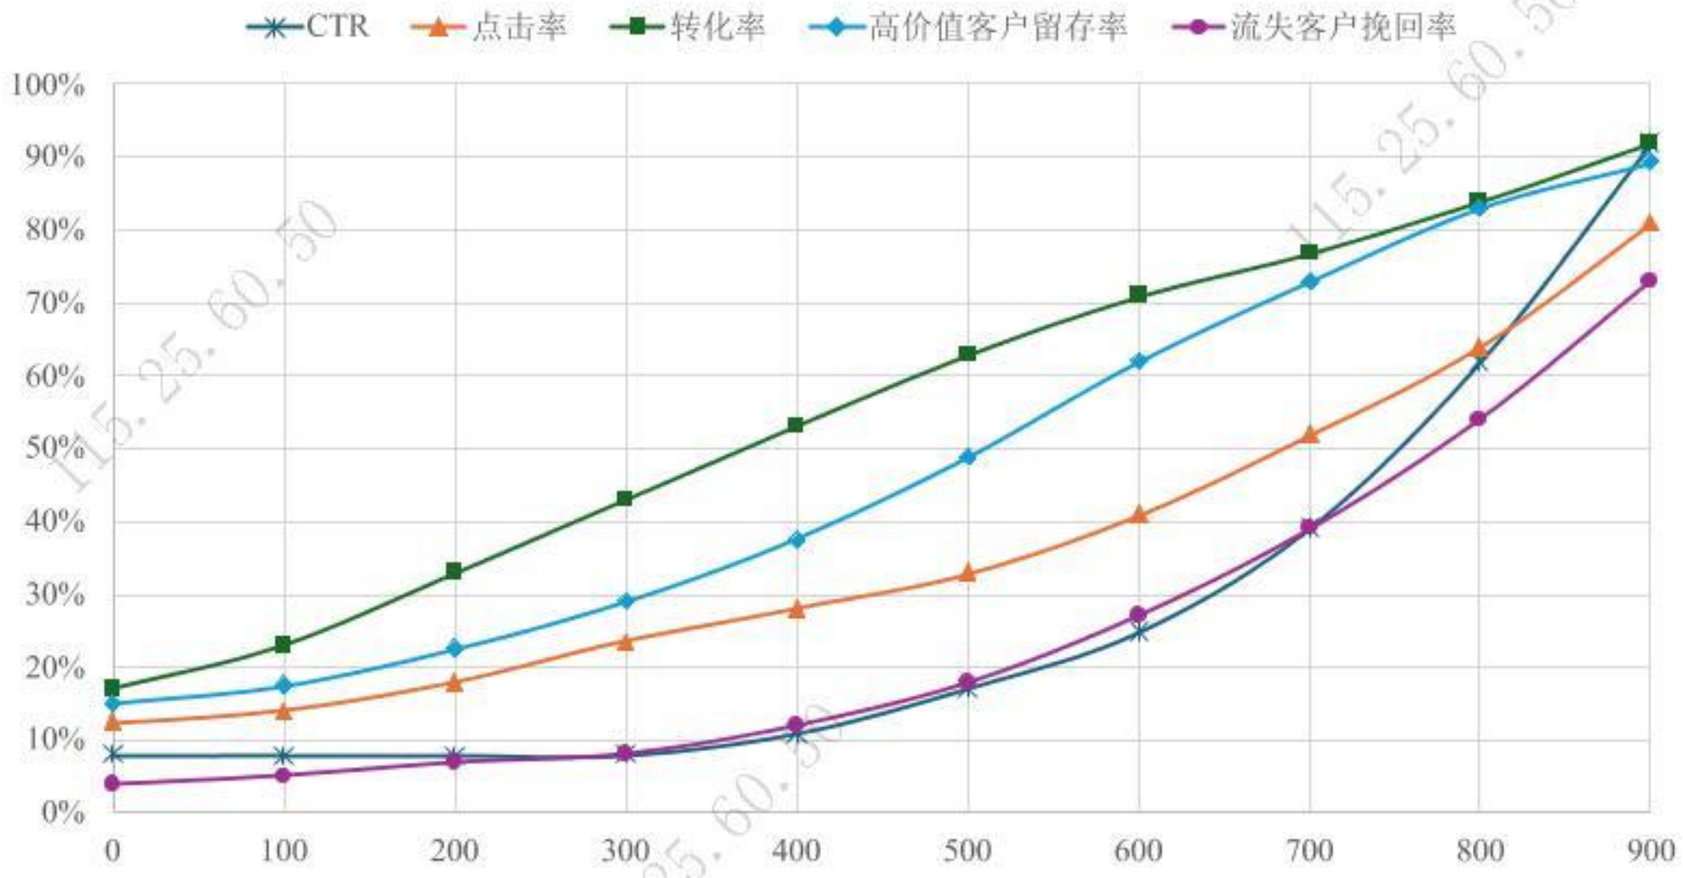


图 6-9 策略实施对比图

Fig.6-9 Comparison chart of strategy implementation

策略实施后如图 6-9 所示，可以看出客户的留存率、挽回率、满意度均有提高，其中流失客户挽回率提升较为明显，挽回率提升 26%，高价值客户留存率和交叉销售成功率也提升明显，精准刻画用户画像，并根据关联产品特性进行产品排列，能有效提升产品推举效率和效果，为客户经理进行线上线下的销售提供重要抓手。

从结果上来看，大量并不活跃的客户，重新变为活跃用户购买推荐商品，

线上线下推荐产品综合购买率提高 21%，产品推荐效率提高。

6.5 本章小结

本章通过结果展示和压测方案说明，充分说明本算法和系统在复杂生产环境中的可靠性和稳定性，为未来进一步扩充系统功能，优化算法性能打下坚实基础。

7 结论与展望

7.1 结论

经过系统的实验验证与深入的业务分析，本研究得出以下主要结论：

融合关联规则与用户画像的 FiBiNET 模型显著提升推荐效果：实验结果表明，将关联规则命中特征、决策树用户画像与基础特征进行多模态融合，并输入至 FiBiNET-CTR 模型进行训练，能够有效捕捉用户与产品间的复杂非线性关系。最终模型在测试集上取得了良好的 AUC 值，显著优于对比模型，证明该融合框架的有效性与优越性。

线上测试验证其商业价值：将本推荐系统投入线上真实环境进行 AB 测试，结果显示，相较于原有推荐策略，新系统在关键业务指标上提升显著，其中点击率提升和转化率大幅提升，高价值客户留存率提升 14%。这充分证明了本研究不仅具有算法层面的创新性，更具备实际落地并产生商业价值的巨大潜力。

基于 C4.5 决策树的用户分群策略为精准营销提供有力支撑：实验证实，“重要价值客户”、“重要挽留客户”等八大分群标签具有鲜明的业务特征和显著的区分度。基于分群的差异化推荐策略能够有效提升营销触达的精准度，实现了运营效率与用户体验的双重提升。

系统架构具备高可用性与可扩展性：通过 ELK 栈构建的实时监控体系保障了系统的稳定运行，而分布式设计的特征处理与模型服务模块，成功经受了万级用户并发的压力测试，平均吞吐量达到 315TPS，系统响应时间保持在 800 毫秒以下，为后续业务增长提供了坚实的技术支撑。

综上所述，本研究成功构建了一个高效、稳定且业务价值显著的金融产品智能推荐系统，其方法论与实践经验对金融科技领域的相关研究与工程实践均具有良好的借鉴意义。

7.2 创新点

本文首次提出了面向金融推荐场景的规则-画像-点击率预估多模态特征融合框架。传统推荐系统通常单独使用协同过滤或内容特征，而本文创新性地将关联规则挖掘、用户画像分析和点击率预估多模块进行深度融合。具体而言，提升了算法的针对性和有效性。实验表明，该融合机制使 CTR 提升显

著优于传统特征拼接方法。

7.3 展望

尽管本研究构建的金融产品推荐系统在多项指标上表现良好，但仍存在一些局限性有待进一步完善：

首先，在数据层面，当前系统虽然对显性异常行为进行了有效过滤，但对于更加隐蔽的异常模式或低频恶意行为的识别能力仍显不足。例如，部分专业化团队可能通过模拟正常用户行为，如反洗钱与刷单造成的数据异常模式实施欺诈，此类行为难以通过基于统计阈值的规则完全剔除，产生一定误差。此外，数据预处理环节对非结构化文本信息的挖掘深度有限，例如用户评论、产品描述中的语义信息尚未被充分提取和利用，限制了多模态特征融合的潜力[62]-[63]。

其次，在算法层面，本文采用的 FiBiNET 模型虽然具有较强的特征交互能力，但其计算复杂度相对较高，在面对海量用户和产品实时推理时，对系统资源消耗较大，在一定程度上影响了系统的扩展性和响应效率。同时，当前模型对于用户兴趣漂移（concept drift）的适应性机制还不够灵敏，未能完全实现用户短期动态偏好与长期稳定偏好的精准平衡，可能导致推荐结果未能及时反映用户最新的意图变化。

最后，在系统实践层面，当前解决方案与现有金融业务系统的耦合度较高，模型泛化能力和跨场景迁移能力未经过充分验证。例如，将其直接应用于保险、信贷等不同金融子领域时，可能需要针对性的特征调整与算法重构。

针对上述不足，未来的研究工作可从以下几个方向展开[64]：

1. 深度异常检测与安全机制强化：

引入无监督与半监督学习技术用于挖掘隐藏更深、行为模式更复杂的异常用户与恶意行为，构建多层级、自适应的大数据风控体系，从而进一步提升训练数据的纯净度与可靠性[24]。

2. 模型优化与效率提升：

探索更轻量级的网络结构如改进的双线性交叉机制及模型蒸馏技术，在基本保持模型性能的前提下大幅降低计算开销与推理延迟。同时，研究用户兴趣动态建模的前沿方法如引入带有注意力机制的循环网络或记忆网络，使系统能够更加细腻地捕捉与响应用户兴趣的实时变化[66]-[68]。

3. 多维度评估与可解释性推荐：

建立涵盖准确性、多样性、新颖性、惊喜度和公平性等多维度的综合评

估体系。同时，大力发展可解释人工智能技术在推荐系统中的应用，生成令人信服的推荐理由，不仅增强用户信任度，也能帮助业务人员理解模型决策过程，为模型优化提供方向[67] 。

4. 跨域迁移与联邦学习应用：

探索跨金融场景如理财、保险、借贷的迁移学习方案，利用源域数据与知识辅助目标域模型训练，缓解冷启动问题[66] 。在严格保证用户隐私与数据安全的前提下，研究联邦学习框架的应用，实现在多个金融机构数据孤岛间进行联合建模，进一步提升模型广泛性。

5. 生成式技术与推荐系统的融合：

探索利用大型语言模型 LLM 强大的语义理解与生成能力，深度融合用户行为序列与产品文本信息，实现更人性化、对话式的智能推荐与金融服务，提升用户体验与满意度[66] 。

通过以上方向的持续探索与创新，有望推动金融产品推荐系统向更加智能、高效、安全、可信的方向演进。

参考文献

[1] 徐艳兰. 延迟退休背景下商业银行养老金融服务的优化路径[J]. 上海商业, 2025, (02): 61-63.

[2] 李婷婷. 人工智能个性化推荐对Z世代人群电商重购意愿的影响研究[J]. 现代商业, 2025, (11): 35-39.

[3] 程春. 基于图神经网络的双通道会话推荐研究[D]. 安徽: 安徽理工大学, 2024.

[4] 杨泽田. 基于协同过滤和图卷积网络的推荐算法研究与应用[D]. 重庆: 重庆师范大学, 2023.

[5] 任豪, 刘柏嵩, 孙金杨. 面向知识迁移的跨领域推荐算法研究进展[J]. 计算机科学与探索, 2020, 14(11): 1813-1827.

[6] 李曦哲. W 公司金融科技战略转型对财务绩效的影响研究[D]. 山西: 山西师范大学, 2022.

[7] 季锟鹏. 部分信息下损失厌恶型保险公司的最优投资与再保险策略[D]. 湖北: 武汉理工大学,2022.

[8] 罗曦. 数据挖掘技术在入侵检测系统中的应用[J]. 信息与电脑(理论版), 2019, 31(20): 112-114.

[9] 黄名选. 基于完全加权关联规则挖掘的查询扩展研究[D]. 广西: 广西师范大学, 2007.

[10] Rumelhart D E, Hinton G E, Williams R J. learning representations by back propagating errors[J]. Nature, 1986, 323(6088): 533-536.

[11] Cheng H T, Koc L, Harmsen J, et al. Wide & deep learning for recommender systems[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. 2016: 7-10.

[12] Guo H, Tang R, Ye Y, et al. DeepFM: a factorization-machine based neural network for CTR prediction[J]. arXiv preprint arXiv:1703.04247, 2017.

[13] 贾振强. 基于深度强化学习的课程推荐系统研究与应用[D]. 四川: 电子科技大学, 2023.

[14] Wang R, Fu B, Fu G, et al. Deep & cross network for ad click predictions[C]//Proceedings of the ADKDD'17. ACM, 2017, 12: 1-7.

[15] Fan Z, Ou D, Gu Y, et al. Modeling users' contextualized page-wise feedback for click-through rate prediction in e-commerce

search[C]//Proceedings of the Fifteenth ACM International Conference on Web Search and Data Mining. 2022: 262-270.

[16] 丁昭巧. 多 Agent 技术下电子商务用户感知和个性化推荐模型探究[J]. 商业经济研究, 2018,2 (03): 98-102.

[17] 沈旭生, 何德旭. 数据驱动的金融创新：数智管理视角下的价值创造[J]. 新金融, 2025, 4(06): 46-54.

[18] 付钰童. 电信用户稳定性识别及应用研究[D]. 北京: 首都经济贸易大学, 2017.

[19] 朱天宇, 谭文安. 基于改进 Apriori 算法的保险产品推荐[J]. 上海第二工业大学学报, 2022, 39(02): 172-176.

[20] He X, Liao L, Zhang H, et al. Neural Collaborative Filtering[J]. International World Wide Web Conferences Steering Committee, 2017, 33(68): 173-182.

[21] He X, Chua T S. Neural factorization machines for sparse predictive analytics[J]. Acm Sigir Frum, 2017, 51(cd): 355-364.

[22] Xiao J, Ye H, He X, et al. attentional factorization machines: learning the weight of feature interactions via attention networks[J]. Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence (IJCAI-17). 2017: 3119-3125.

[23] Lian J, Zhou X, Zhang F, et al. xDeepFM: combining explicit and implicit feature interactions for recommender systems[C]//Proceedings of the 24th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. ACM, 2018: 1754-1763.

[24] El-Hindi M, Binnig C, Arasu A, Kossmann D, Ramamurthy R. Block chainDB: a shared database on blockchains[J]. Proceedings of the VL DB Endowment, 2019, 12(11): 1597–1609. DOI:10.14778/3342263.3342636.

[25] Kingma D, Ba J. Adam: A Method for Stochastic Optimization[J]. arXiv preprint arXiv: 1412.6980v5, 2014.

[26] Shen Y, He X, Gao J, et al. a latent semantic model with convolutional-pooling structure for information retrieval[J]. ACM, 2014: 101-110.

[27] 范永全,杜亚军,成丽静,等.一种融合用户偏好与信任度的增强协同过滤

推荐方法[J].西华大学学报（自然科学版）, 2015, 3(004):8-12,27.

[28] 李昌东. 基于微服务的财经新闻推荐系统设计与实现[D]. 上海: 华东师范大学, 2023.

[29] 唐铄丁. 基于深度兴趣网络的点击率预估模型的研究与实现[D]. 吉林: 吉林大学, 2022.

[30] 陈雯雯, 王艳红. 基于决策树挖掘技术的调度算法研究[J]. 无线互联科技, 2022, 19(19): 130-132.

[31] Xie R, Ling C, Wang Y, et al. deep feedback network for recommendation[C]//International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2020: 2519-2525.

[32] Wang Y, Ji H, Yu J, et al. Click-through rate prediction based on feature interaction and behavioral sequence[J]. International Journal of Machine Learning and Cybernetics, 2024, 15(7): 2899-2913.

[33] 刘家军, 刘俊玲, 杨瀚鹏. 基于 ID3 决策树算法接触网检修方案的研究[J]. 电气工程学报, 2020, 15(02): 78-84.

[34] 赵强. 数据挖掘方法在纳税人行为分析中的研究和实现[D]. 陕西: 西安电子科技大学, 2009.

[35] 蒋茜茜. 面向学生体能素质评估指标的高效关联规则挖掘算法研究[D]. 山西: 中北大学, 2022.

[36] 毛午阳. 基于多组特征与模型融合的广告点击率预测[D]. 北京: 北京邮电大学, 2020.

[37] Abubaker M B, Hamad H M. kmeans-based convex hull triangulation clustering algorithm[J]. Research Notes in Information Science, 2012, 9: 19-29.

[38] 李灏. 面向大学生的诗词个性化学习推荐工具的设计与应用研究[D]. 西北师范大学, 2024.

[39] 张安然. 善因营销结果披露中角色导向对消费者口碑传播意愿作用机制研究[D]. 吉林: 吉林大学, 2021.

[40] 张新猛, 蒋盛益, 张倩生, 等. 基于用户偏好加权的混合网络推荐算法[J]. 山东大学学报(理学版), 2015, 50(09): 29-35+41.

[41] 顾炜伦. 基于 Spark 和深度学习的图书推荐算法与应用研究[D]. 陕西: 西京学院, 2023.

[42] 寇志谦. 计算机网络安全态势感知系统的设计与实现[J]. 信息记录材料, 2025, 26(01): 47-49.

[43] 周炫玑, 杨文显. 微服务架构下的信息系统自动化运维平台设计与应用[J]. 网络安全和信息化, 2025, (04): 75-77.

[44] 陈仕强. HDFS 的副本管理策略研究[D]. 重庆: 重庆大学, 2015.

[45] 谢磊, 张冰, 杨猛. 基于 ELK 的日志分析系统研究与实践[J]. 科技经济市场, 2020, (10): 17-18.

[46] 朱思远.基于校园网的集中式日志分析系统的搭建与研究[D]. 广东: 广东工业大学, 2019.

[47] 姚远, 郭向民. 基于 Elastic Stack 的分布式日志采集平台设计与实现[J]. 网络空间安全, 2022, 13(03): 50-56.

[48] 罗学贯. 基于 ELK 的 Web 日志分析系统的设计与实现[D]. 广东: 华南理工大学, 2018.

[49] 李艳芹, 陈跃华, 郭松柏. 基于 Web 应用系统的性能测试综述[J]. 电脑知识与技术, 2010, 6(28): 8014-8017.

[50] 闫晋佩. 基于 Android 平台消防任务分发系统的研究与设计[D]. 陕西: 西安科技大学, 2013.

[51] 倪丽菲, 李军鹏. 基于分布式数据库的管理信息系统数据资源配置[J]. 无线电通信技术, 2002, (02): 44-45+50.

[52] 苑成达. 支持大规模虚拟筛选的分布式数据管理系统的设计与实现[D]. 甘肃: 兰州大学, 2012.

[53] 梁雪青, 杜舒明. 基于 MapReduce 模型的非结构化数据分布式存储方法[J]. 微型电脑应用, 2022, 38(07): 106-109.

[54] 汤志凤. 分布式数据库关键技术应用[J]. 通讯世界, 2025, 32(01): 154-156.

[55] 尚思圆. 大数据下数据库优化器算法的性能优化研究[J]. 石油化工设计, 2025, 42(02): 39-41+46+75.

[56] 吴斌, 肖刚, 陆佳炜. 基于关联规则挖掘领域的 Apriori 算法的优化研究[J]. 计算机工程与科学, 2009, 31(06): 116-118.

[57] 赖跖. 基于强化学习的推荐算法研究与实现[D]. 四川: 电子科技大学, 2023.

[58] 王晶爱, 牛琪锴, 宗文静, 等. 基于古今特征融合与图卷积网络的活血药对配伍预测[J]. 中国实验方剂学杂志, 2025, 31(08): 228-234.

[59] 龙慧芬. 音乐流媒体的用户流失预测分析[D]. 广西: 广西师范大学, 2018.

[60] 刘丽萍, 吕政. 基于高维高频金融数据的最小方差组合风险的估计及应用[J]. 系统科学与数学, 2021, 41(10): 2948-2964.

[61] 董本清, 李凤坤. 基于加权划分非平衡决策树的诗歌朗读情感度分析[J]. 计算机科学, 2020, 47(S2): 46-51.

[62] Abeywickrama T, Cheema M A, Taniar D. k-nearest neighbors on road networks: a journey in experimentation and in-memory implementation[J]. Proceedings of the VLDB Endowment, 2016, 9(6): 492–503.

[63] Sharma P , Jindal R , Borah M D .Blockchain Technology for Cloud Storage:a systematic literature review[J].ACM Computing Surveys, 202 1, 53(4):89.1-89.32.DOI:10.1145/3403954.

[64] Hao J T , Sun Y , Luo H . A safe and efficient storage scheme b ased on blockchain and IPFs for agricultural products tracking[J]. Jour nal of Computers (Taiwan), 2018, 29(6):158-167.

[65] Greff K, Srivastava R K, Jan Koutník, et al. LSTM: a search space odyssey[J]. IEEE Transactions on Neural Networks & Learning Systems, 2016, 28(10): 2222-2232.

[66] 梁方玮, 薛涛. 面向物流服务的海量日志实时流处理平台[J]. 计算机系统应用, 2021, 30(10): 68-75.

[67] 章涛, 徐宽. 基于 Redis 集群云平台的高并发互动系统的设计与实现[J]. 广播与电视技术, 2024, 51(5): 36-40.

[68] 李玲玲. 数据库原理及应用[M]. 北京: 电子工业出版社, 2020.

[69] 胡明明. Apriori 算法在图书馆个性化服务中的应用分析[J]. 黄河科技学院学报, 2025, 27(05): 72-76.

[70] 顾鹏. 一种基于链表的改进 Apriori 算法[J]. 计算机与数字工程, 2020, 48(05): 1024-1028+1044.

[71] 李康乐, 任志磊, 周志德, 等. 基于决策树算法的 API 误用检测[J]. 计算机科学, 2022, 49(11): 30-38.

致　谢

本论文的完成，离不开众多师长、亲友的支持与帮助。在此，我谨向所有曾给予我指导、鼓励与陪伴的人，致以最诚挚的谢意。

首先，我要衷心感谢我的导师王昭顺教授。从论文的选题方向、研究思路的确定，到结构框架的搭建与细节内容的打磨，王老师均给予了悉心的指导，倾注了大量心血。同时，他也以一贯的包容与鼓励，支持我在研究过程中不断探索、坚持前行。王老师严谨的治学态度、开阔的学术视野与对学生的谆谆教导，使我深受启迪，也将成为我未来学习与工作中的宝贵财富。

回首求学之路，感慨良多。2022 年夏天，我在考研一战失利后入职北京一家国企，却始终怀揣攻读硕士的梦想。于是次年备考，有幸进入北京科技大学继续深造。在读研的两年半时光里，我利用课余时间努力学习，最终考取了家乡的省直事业单位。感谢学校提供的平台，使我在接下来的时间里能以研究生身份，继续参加国家与地方的公务员考试，向更高的厅级机关的职业目标迈进，我期待着在未来能真正在职业上做到“登堂入室”。若有机会，也愿怀着学术热忱，继续攻读博士学位。

最后，感谢母校北京科技大学提供的优良学习环境与丰富资源，使我得以在两年半研究生阶段持续成长。也深深感谢我的家人与朋友们，你们始终如一的陪伴与支持，是我前行中最温暖的力量。

作者简历及在学研究成果

一、主要教育经历/工作经历（从大学起，到硕士入学止）

起止年月	学习或工作单位	备注
2018.9-2022.6	哈尔滨理工大学物联网工程专业攻读学士学位	
2022.7-2023.9	中华财险创新研发中心从事后端开发工作	

二、在学期间从事的科研工作

无。

三、在学期间所获的科研奖励

无。

四、在学期间发表的论文

无。

独创性说明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作 者 签 名：李东津翰 日期：2025 年 12 月 20 日

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

签名：李东瀚 导师签名：[illegible] 日期：2025 年 12 月 20 日