密　　级：公开

加密论文编号：

论文题目：基于知识库和知识图谱的鼻咽癌问答系统的设计与实现

学　　号：M202240088

作　　者：李天威

专 业 名 称：软件工程

2025 年 9 月 10 日

115.25.60.50

基于知识库和知识图谱的鼻咽癌问答系统的设计与实现

Design and Implementation of Nasopharyngeal Cancer Question and Answer System Based on Knowledge Base and Knowledge Graph

研究生：李天威

指导教师：张志超

北京科技大学数理学院

北京 100083，中国

Master Degree Candidate：Tianwei Li

Supervisor：Zhichao Zhang

School of Mathematics and Physics

University of Science and Technology Beijing

30 Xueyuan Road，Haidian District

Beijing 100083，P.R.CHINA

中图分类号：　　学校代码：10008
U　D　C：　　密　　级：公开

北京科技大学硕士学位论文

论文题目：基于知识库和知识图谱的鼻咽癌问答系统的设计与实现

研究生：李天威

指 导 教 师：张志超　单位：北京科技大学　职称：副教授

指导小组成员：　　单位：　　职称：

　　单位：　　职称：

论文提交日期：2025 年 9 月 10 日

学位授予单位：北 京 科 技 大 学

摘 要

鼻咽癌作为临床高发的恶性肿瘤类型，其早期诊断与规范治疗对提升患者生存率起着关键作用。但受限于医学知识的专业门槛与复杂体系，患者群体及基层医疗工作者在获取精准、全面的鼻咽癌相关信息时，往往面临信息零散、筛选困难等问题。鉴于此，本文设计并开发一套融合知识库与知识图谱技术的鼻咽癌智能问答系统，通过整合多渠道医学数据资源，建构结构化的知识框架，并结合大语言模型的优势，为用户提供高效且精准的问答服务，具体研究工作包含以下三方面：

首先是鼻咽癌知识图谱的搭建工作。以标注的数据集为基础，运用实体识别、关系抽取等核心技术，将疾病、症状、治疗方案等关键医学概念进行可视化关联展示，最终构建一套结构化的医学知识图谱，为后续问答功能的实现提供技术支撑。

其次是鼻咽癌知识库的构建。通过采集多源医学数据，包括学术文献、临床诊疗指南、权威医学数据库等，经过数据清洗、去重和结构化处理，将原本分散的非结构化信息转化为可高效检索的知识单元，为问答系统的稳定运行提供了可靠的数据基础。

最后是鼻咽癌问答系统的整体设计与开发。研究从用户实际需求出发，先明确系统的功能需求与非功能需求，随后设计出包含前端交互界面、后端数据处理模块、知识管理模块的完整系统架构。在技术实现上，系统以知识库和知识图谱为核心，融合生成式大语言模型，并采用向量检索与语义匹配技术，提升了问答结果的准确性与交互流畅度。经测试验证，该系统回答准确率达到 94%，在响应时效、功能覆盖度等方面均满足预设目标，可以有效满足用户对鼻咽癌知识的查询需求。

关键字：知识图谱；知识库；大语言模型；问答系统

Design and Implementation of Nasopharyngeal Cancer Question and Answer System Based on Knowledge Base and Knowledge Graph

ABSTRACT

As a clinically common type of malignant tumor, early diagnosis and standardized treatment of nasopharyngeal carcinoma play a crucial role in improving patients' survival rates. However, due to the professional threshold and complex system of medical knowledge, patients and primary medical workers often face problems such as scattered information and difficult screening when obtaining accurate and comprehensive information related to nasopharyngeal carcinoma. In view of this, this paper designs and develops an intelligent question-answering system for nasopharyngeal carcinoma that integrates knowledge base and knowledge graph technologies. By integrating multi-channel medical data resources, building a structured knowledge framework, and combining the advantages of large language models, the system provides users with efficient and accurate question-answering services. The specific research work includes the following three aspects:

First is the construction of the nasopharyngeal carcinoma knowledge graph. Based on the annotated dataset, core technologies such as entity recognition and relationship extraction are used to visually associate and present key medical concepts such as diseases, symptoms, and treatment plans. Finally, a structured medical knowledge graph is formed, which provides technical support for the subsequent realization of the question-answering function.

Second is the construction of the nasopharyngeal carcinoma knowledge base. By collecting multi-source medical data, including academic literature, clinical diagnosis and treatment guidelines, and authoritative medical databases, through data cleaning, deduplication, and structured processing, the originally scattered unstructured information is transformed into efficiently retrievable knowledge units, which provides a reliable data foundation for the stable operation of the question-answering system.

Third is the overall design and development of the nasopharyngeal carcinoma question-answering system. Starting from the actual needs of users, the research

first clarifies the functional and non-functional requirements of the system, and then designs a complete system architecture including a front-end interactive interface, a back-end data processing module, and a knowledge management module. In terms of technical implementation, the system takes the knowledge base and knowledge graph as the core, integrates a generative large language model, and adopts vector retrieval and semantic matching technologies to improve the accuracy of question-answering results and the smoothness of interaction. Through test verification, the answer accuracy rate of the system reaches 94%, and it meets the preset goals in terms of response time efficiency, function coverage, etc., which can effectively meet users' needs for querying nasopharyngeal carcinoma knowledge.

Key Words: Knowledge graph; Knowledge Base; Large Language Model; Question answering

目录

摘　要 I
ABSTRACT II
1 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 知识图谱发展与研究现状 2
1.2.2 问答系统发展与研究现状 4
1.3 文章结构 5
2 相关理论介绍 7
2.1 知识图谱 7
2.1.1 基础概念 7
2.1.2 知识图谱的关键技术 8
2.2 知识库 10
2.2.1 基础概念 10
2.2.2 嵌入向量模型 11
2.3 大语言模型 14
2.3.1 基础概念 14
2.3.2 Transformer 架构原理 15
2.3.3 主流大模型介绍 17
2.4 本章小结 20
3 知识库和知识图谱的构建 21
3.1 知识库的构建 21
3.1.1 数据采集 21
3.1.2 知识库的构建 22
3.2 知识图谱的构建 26
3.2.1 数据来源和处理 26
3.2.2 数据标注 26
3.2.3 知识图谱的构建 29
3.3 生成式模型 32
3.3.1 知识库和知识图谱与大模型的结合 32
3.4 本章小结 34

4 基于知识库和知识图谱的鼻咽癌问答系统.....35
4.1 需求分析.....35
4.1.1 总体需求分析.....35
4.1.2 功能需求分析.....36
4.1.3 非功能需求分析.....36
4.2 架构设计.....39
4.2.1 整体架构设计.....39
4.2.2 模块设计.....40
4.3 系统实现.....42
4.3.1 开发环境.....42
4.3.2 前端实现.....43
4.3.3 后端实现.....46
4.3.4 系统展示.....47
4.4 系统测试.....54
4.4.1 测试环境.....54
4.4.2 页面测试.....54
4.4.3 功能测试.....55
4.5 本章小结.....59
5 总结与展望.....60
5.1 总结.....60
5.2 展望.....61
参考文献.....62
附录 A 后端主要代码.....67
致　谢.....73
作者简历及在学研究成果.....74
独创性说明.....75
关于论文使用授权的说明.....76
学位论文数据集.....77

1 绪论

1.1 研究背景与意义

鼻咽癌（Nasopharyngeal Carcinoma, NPC）是一类原发于鼻咽部的恶性肿瘤，其最显著的特征之一便是鲜明的地域分布差异：在中国南方地区及东南亚沿海国家，该病的发病率远高于全球其他区域[1]。从全球癌症统计数据来看，鼻咽癌虽未进入全球高发癌症榜单，但在上述特定区域，它已成为威胁居民健康的重要疾病类型。探究其病因可知，这是一个多因素交织的复杂问题：既涉及遗传层面的易感性，也与环境因素（像饮食习惯、吸烟行为等）密切相关，同时 EB 病毒（Epstein-Barr virus, EB）病毒感染也是被广泛认可的关键诱因之一[2]。遗憾的是，鼻咽癌早期症状往往不明显，这导致不少患者确诊时病情已发展至中晚期，不仅治疗难度大幅增加，术后恢复效果也往往不理想。

近年来，随着精准医学理念的深化与大数据技术的飞速发展，医学研究模式正悄然转变，从过去依赖单一数据驱动的方式，逐步转向多源数据融合驱动。然而，患者和基层医生在获取准确、全面的鼻咽癌知识时面临诸多困难，如医学信息碎片化、专业门槛高、临床指南更新滞后等。传统的搜索引擎和信息获取方式容易导致误导，亟需一个权威、实时、易懂的鼻咽癌智能问答系统来填补知识获取的鸿沟，提升鼻咽癌的早期诊断率和治疗依从性。

从临床实践角度看，鼻咽癌智能问答系统的构建与应用具有不可忽视的现实意义。一方面，它能为临床医生提供全方位的疾病知识支持，助力其更精准地开展诊断与治疗工作。另一方面，依托鼻咽癌智能问答系统开发人工智能驱动的临床决策支持系统，还能为鼻咽癌的早期诊断与预后评估提供技术保障。此外，在医学教育与培训场景中，鼻咽癌智能问答系统也能发挥作用：帮助医学生与年轻医生快速掌握鼻咽癌的核心知识，缩短学习周期。

除了医学领域的价值，鼻咽癌智能问答系统的研究还具备广泛的社会意义。首先，鼻咽癌高发区域多为经济欠发达地区，这些地方医疗资源相对短缺。通过构建鼻咽癌智能问答系统，可将高质量的医学知识输送到这些区域，助力当地提升医疗服务水平，从而降低鼻咽癌的发病率与死亡率。其次，鼻咽癌智能问答系统的研究与应用能推动精准医学的进一步发展，促进医疗资源的合理分配，让整个医疗系统的运行效率得到提升。最后，鼻咽癌智能问答系统的研究经验，还可为其他癌症类型的问答系统构建提供参考，进而推

动癌症研究领域的整体进步。

本研究的核心目标是开发一套针对鼻咽癌诊疗场景的智能问答系统，在具体研发过程中，需要攻克一系列关键技术难题，主要可归纳为以下四点：

1） 鼻咽癌专科知识图谱建设的短板。现有的通用医学知识图谱，在面对鼻咽癌这类专科领域的深度需求时，往往显得“力不从心”，内容上过于宽泛，难以满足精准医疗对专科知识的细致要求；同时，这类通用图谱高昂的运维成本，也给其在专科场景的推广应用带来了阻碍。

2） 医学实体识别技术的现实瓶颈。鼻咽癌领域存在大量专业性强的术语，以及复杂的实体关联关系，典型例子如“下咽鳞状细胞癌 T2N1M0 分期”，这类表述中包含多个医学概念，解读难度较大。加之中文医学文本本身具有独特的表述习惯，进一步增加了实体识别的复杂度；更关键的是，专业医学标注数据的稀缺，直接限制了相关模型的训练效果，导致识别精度难以提升。

3） 知识更新机制的滞后性问题。鼻咽癌诊疗领域的临床指南、研究成果一直在动态更新，这就要求知识库系统必须具备同步跟进最新医学进展的能力。但医学知识的特殊性在于，它需要经过严格的专家评审与临床验证，才能被正式纳入体系，这使得知识更新周期普遍较长。如何在保证医学严谨性的前提下，提升知识更新的及时性，实现二者之间的平衡，成为当前系统研发面临的主要技术难题之一。

4） 医疗问答系统的优化需求。当前主流的医疗大模型，在鼻咽癌这类专科领域的回答中存在明显局限：对最新诊疗方案的了解不够全面，分析复杂病例时深度不足，解读专业术语时准确性也有待提升。因此，在系统设计中，需要重点解决三个问题：一是确保回答内容的权威性，二是优化医患之间的交互体验，三是搭建可扩展的技术架构，以支持多中心临床数据的整合应用。

1.2 国内外研究现状

1.2.1 知识图谱发展与研究现状

1955 年，Garfield[3]在其研究中首次提出“索引”的构想，这一理念的核心价值在于帮助科研人员快速建立不同研究工作间的关联，大幅提升文献查找效率。此后十年间，De Solla Price[4]持续深化这一思路，最终在个人发表的论文中正式提出“引证网络”概念，这一成果被学界普遍视为知识图谱技术萌芽的起点。到了 1968 年，Quillian[5]做出了开创性贡献：他提出“语义网络”

的理论框架，将有向图作为知识表达的基础范式。通过这种结构，自然语言语句可转化为可视化形式，原本错综复杂的信息得以清晰呈现；这一方法不仅为后续知识图谱的发展筑牢了基础，更成为技术演进过程中不可或缺的关键过渡阶段。从引文索引到引证网络，再到语义网络的逐步迭代，这些里程碑式的突破共同推动知识图谱技术向前迈进，为其后续的现代应用扫清了障碍。

1977 年，Feigenbaum[6]首次引入“知识工程”概念，该领域最具代表性的成果便是专家系统。专家系统的核心运作逻辑是：先收集特定领域的专业知识，再对这些知识进行分类与结构化处理，最终以规范格式存储于计算机中。研究人员通过编写程序代码，结合规则推理、知识表示等技术，将领域内的经验知识转化为可计算模型，进而实现对专业问题的智能化解答。同一时期，语义网络的相关理论也得到了深度研究与完善，它不仅能将复杂的知识体系转化为计算机可处理的形式，还进一步促进了知识的高效组织与利用，而专家系统在此阶段也实现了跨越式发展。

20 世纪 80 年代后期，语义网络的研究重点开始向“语义关系的深度探究”转移。其中，Bachman 及其团队[7]研发的 CLASSIC 语言成为该领域的标志性突破，极大地推动了语义网络理论的成熟与完善。进入 21 世纪前期，语义网络技术逐步向万维网（World Wide Web, Web）应用领域拓展，“语义 Web”作为万维网联盟（W3C）主导的网络扩展框架应运而生。其核心目标是提升数据在不同应用系统间的交互操作性与共享能力，通过建立标准化的数据描述机制，依托跨平台、跨系统的数据整合与知识发现能力，实现更高效的信息互联与交换[8]。

2012 年，Google [9]创新性地提出“知识图谱”的概念框架。从理论本质来看，知识图谱可视为语义网络的高级演进形态，其显著特征在于拥有更复杂的语义关系与更优化的结构设计[10]。在这一框架中，实体通过“节点”进行标注，实体间的关联则通过“边”来展现。

国内知识图谱的发展已从早期技术探索阶段，逐步深入到各行业的实际应用中，成为支撑智能化服务的重要基础。在落地场景上，垂直领域的应用最为突出，比如金融行业会构建企业知识图谱，整合企业工商、信贷、风险数据，辅助信贷审批和风险预警；医疗领域则围绕疾病、药物、症状等实体搭建知识网络，为临床诊断、药物推荐提供参考；政务领域也通过整合各部门数据，形成政务知识图谱，提升政策解读、民生服务的效率。技术层面，随着多源数据融合需求的增加，实体识别、关系抽取的精度不断提升，尤其

是在处理非结构化文本（如医疗文献、法律条文）时，结合预训练模型的技术方案，让知识图谱的构建效率和覆盖范围显著改善。不过当前发展仍有需要完善的地方，比如部分行业的知识图谱存在数据孤岛问题，不同机构间的数据标准不统一，导致知识难以互通；同时，动态知识的更新机制还不够灵活，面对快速变化的领域信息（如新兴技术术语、新上市药物），难以实现实时迭代，这些都需要行业进一步探索解决。

1.2.2 问答系统发展与研究现状

在上世纪中叶，被誉为“人工智能之父”的 Turing[11]提出了一种用于评估机器智能的方法，极大激发了自动问答系统的兴起，大量相关研究陆续开展，有人促进了深度学习[12]的大力发展，使得如今人工智能（Artificial Intelligence，AI）行业如火如荼。

早期问答的探索主要关注于特定的领域，也就是所谓的专家系统，这些系统的工作原理强依赖于固定的规则，需要事先准备好大量的模版，对问题进行规则筛选后去匹配对应的模版，从而回复问题，典型的例子有 Green 及其团队[13]开发的 BASEBALL 系统，其可通过事先存储的美国棒球联赛的知识回答问题，这是一次质的突破。但是该系统制造成本昂贵，而实际的效率偏低，始终无法大批量产生，为了减少系统开发过程中的繁杂费用，研究人员将目光转向了特定领域的数据集，小范围的验证。到了 20 世纪 90 年代，随着互联网技术的进一步发展，基于 Web 的问答平台陆续诞生，大大提高了民众获取信息的途径，尽管此时答案不一定准确。一些诸如苹果的 Siri 和微软的 Cortana 等个人助手的问世，大大简化了问题的方式[14]。

目前有两种形式的问答系统，分别是检索式的问答系统和生成式的问答系统，这两类系统的区别在于设计理念、技术实现以及应用场景上。具体来说，前者的关注点在于拥有一个丰富的知识库，该知识库事先涵盖了大量的问题及其对应的答案，通常也是经过自然语言处理等技术手段从文档中抽取出来的片段。当用户发起提问时，系统将根据设定的匹配算法去寻找最合适的问题模版，并由此提取出对应的答案返回给用户，可是当问题首次出现或知识库未及时更新的情况下，系统极大概率无法给出满意的答复；后者采取了一种全新的范式，以端到端的形式直接对问题进行处理，该类系统以 ChatGPT 在 2022 年底的推出作为标志，一经推出迅速火爆全网，在全球范围能掀起了大模型的热潮[15]。生成式问答大幅降低的人工设置模版的成本，而是通过对海量文本信息的学习，以获得强大的泛化能力，拥有了对语言文本

的理解能力，以至于当接收到新问题时可自行推导出恰当的答案。但也会遇到生成虚假信息的难题，信息的及时性和专业性无法得到保障，现阶段问答系统的发展趋势是给大模型提供更多的上下文信息，结合如知识图谱、向量检索召回等方案提高生成质量，有助于增强性能的准确性和鲁棒性。

知识库问答（Knowledge Base Question Answering，KBQA）延续了 20 世纪七八十年代数据库的自然语言接口（Natural Language Interface to DataBases，NLIDB）的研究成果，主要采用统一的 RDF 格式来表示知识图谱，并将语义解析的结果映射到图谱的本体结构，从而形成 SPARQL 查询以回答问题[8]。其核心技术挑战在于如何有效地将用户的提问转换成针对知识图谱的查询请求。

国内问答系统的发展已从早期简单的关键词匹配阶段，逐步迈向融合知识图谱、大语言模型等技术的智能化阶段。在技术层面，越来越多的研究与应用开始注重多源数据的整合能力，比如医疗领域会结合临床指南、文献数据库构建专业知识库，教育领域则整合课程资源与题库形成个性化问答支持，这种“技术+垂直领域知识”的融合模式，让问答系统的准确性和实用性显著提升。从应用场景来看，除了常见的客服咨询、智能助手等通用场景，垂直领域的落地案例不断增加，像金融行业的智能投顾问答、政务领域的政策解读系统、医疗领域的疾病知识查询工具等，都在逐步渗透到日常生产生活中，为不同群体提供针对性服务。不过当前发展也存在一些待突破的方向，比如部分系统在处理复杂语义理解、多轮对话连贯性上仍有提升空间，且垂直领域的知识更新速度与实际需求间的匹配度，以及数据隐私保护与系统性能平衡等问题，仍是行业持续探索的重点。

1.3 文章结构

本论文研究旨在开发一套基于知识库和知识图谱的鼻咽癌智能问答系统。论文总共包含五个章节，各章节之间的组织结构和研究内容如下：

第一章为绪论部分。首先介绍了基于知识图谱和知识库的鼻咽癌问答系统的研究背景与意义，然后概述了知识图谱和问答系统的发展与研究现状，最后介绍了本文的文章结构。

第二章为相关理论介绍。首先介绍了知识图谱和知识库的理论基础，然后阐述了 Transformer 架构的原理，为后续问答系统的开发奠定理论基础。

第三章为知识图谱和知识库的构建。首先收集和预处理了数据，然后完成了基于鼻咽癌的知识库和知识图谱的构建，最后实现了将知识库、知识图

谱和大模型技术相互融合。

第四章构建了基于知识图谱的鼻咽癌问答系统，首先进行了需求调研和需求分析，然后对系统整体架构进行设计，对各模块功能进行详细设计，从数据层面对系统底层进行设计，对系统的界面进行了相应的介绍和展示，最后对整个系统具体功能进行实现和测试。

第五章为总结与展望。对基于知识图谱的鼻咽癌问答系统的设计与实现进了总结，突出了本研究的重点工作内容，以及对后续系统优化做出了展望。

2 相关理论介绍

本文主要构造一个基于知识库和知识图谱的鼻咽癌问答系统，本章将对该问答系统所涉及的核心理论与关键技术进行详细介绍，具体包括：对知识库、知识图谱及大模型技术基本概念的阐释，以及对相关经典算法的理论分析，从而为后续系统的开发实践奠定坚实的理论基础。

2.1 知识图谱

2.1.1 基础概念

2012 年谷歌为了提高搜索引擎的能力，正式提出了知识图谱的概念。知识图谱的核心功能是描述现实世界中存在的概念、实体、事件及其之间的关系，能够对现实世界中的各类对象及其关联进行可视化表征，同时也能从互联网的海量数据中提取实体间的联系，并以结构化的方式进行知识存储，本质上构成一个结构化的海量知识数据库。

知识图谱是一种以语义为基础的结构化知识表示体系，其核心构成要素包括对象、关联及特征描述，用于系统化地表达现实世界中各类概念间复杂的联系与特性[16]。在该体系中，对象指代具体的实例或抽象概念（例如个人、区域、活动等），关联表征对象间的相互作用（如亲属关系、空间位置等），特征描述则用于界定对象的性质（包括名称、时间信息、坐标等）。通过将这些基本单元组织为三元组形式（对象-关联-对象或对象-特征-特征值），知识图谱可以直观地呈现不同对象间的关联网络与特征数据。

按照功能和应用场景的不同，知识图谱可以分为通用知识图谱和垂直领域知识图谱。通用知识图谱面向的是通用领域，来源广泛，以常识性知识为主，构建过程成熟，面向大众，致力于构建跨学科的综合性知识体系，注重知识的广度与全面性，针对的使用者主要为普通用户；领域知识图谱则面向某一特定领域，聚焦于垂直领域的专业化知识建构，追求特定领域的深度与精度，知识获取难以自动化，通常需要基于该行业的数据库进行构建，要求质量，受众为相关专业人士。本文建立的基于知识图谱的鼻咽癌问答系统的设计与实现属于垂直领域知识图谱范畴。

2.1.2 知识图谱的关键技术

知识图谱的完整构建流程，需从多源数据的获取与清洗环节起步，这一步要先收集分散在不同渠道的原始数据，再通过去重、纠错、格式统一等清洗操作，确保数据质量；随后依次推进本体构建、信息抽取、知识表示、知识融合与储存等关键步骤，最终形成能够支持高效查询与逻辑推理的语义网络，为后续应用提供结构化知识支撑。

本体构建的核心目标，是搭建一套标准化的知识体系框架，其价值不仅在于推动领域内知识的共享与复用，还能有效减少知识冗余问题。在具体构建领域本体时，需严格遵循以下几项核心原则：其一为术语规范化，要求采用统一且规范的术语体系，确保同一概念在整个知识体系中表述一致，避免因术语混乱导致的理解偏差；其二是语义一致性，需通过精准定义概念边界，尽量缩小同类概念间的语义差异，消除歧义；其三是结构稳定性，在后续扩展新术语、补充新知识时，必须保持原有本体结构的逻辑完整性，避免破坏整体知识框架；其四是约束最小化，即减少对实体建模对象的不必要限制条件，以此增强本体的灵活性与不同场景下的适应性；最后是语义充分性，要求准确界定每个术语的内涵与外延，确保其能完整表达所描述概念的核心特征。

知识抽取指的是利用各类技术手段，从非结构化数据（如医学文献、临床病历文本等）中自动识别、提取关键信息，并对这些信息进行整理归类，最终转化为结构化知识形式的过程。这一环节的主要目标有三个：一是大幅降低人工标注数据的工作量，提升知识获取效率；二是确保提取出的信息具备较高精准度，为后续知识图谱质量奠定基础；三是能够灵活适配不同领域的特性，满足多样化的知识需求。在知识抽取的具体技术中，实体抽取是最基础也最典型的一类，它能从文本内容里精准提取出特定类型的实体标识（如医学领域的“鼻咽癌”“EB 病毒”等），而命名实体识别（Named Entity Recognition, NER）技术正是专门解决这类问题的核心方法[17]。实体作为文本信息中最核心的单元，是自然语言处理流程中的基础性环节，其识别的准确程度直接影响后续关系抽取、事件抽取等环节的处理效果。关系抽取的核心任务，则是在已识别出的不同实体之间建立起明确的关联关系（如“鼻咽癌—致病因素—EB 病毒”），通过这种方式逐步构建出网状的知识体系。事件抽取聚焦于从文本中提取特定事件的相关信息（如“鼻咽癌手术治疗”的时间、流程、效果等），通常会采用预先定义的模板来规范信息提取格式。属性抽取用于获取实体所具备的特征信息（如“鼻咽癌—高发区域—中国南

方”），由于属性本质上属于名词性关联，因此在技术逻辑上可将其视为关系抽取的一种特殊形态。这些不同的抽取技术相互配合，共同构成了知识获取过程中的核心步骤，为知识图谱的构建提供了关键的数据支撑。

知识表示作为人工智能领域的核心技术之一，其核心议题是如何在计算机系统中，以形式化、结构化的方式对现实世界的知识进行呈现，这种呈现方式需同时满足计算机的存储需求、逻辑推理需求，以及后续的应用开发需求。一套优质的知识表示方法，不仅能帮助机器更深入地理解复杂的现实世界规律，还能在此基础上支持机器作出合理的决策判断。从本质来看，知识表示是通过特定的编码规则对知识进行转化，使其能够被计算机识别、理解并处理的过程。这一技术的应用场景十分广泛：在自动推理领域，它可支持计算机依据已有的知识储备进行逻辑推断（如根据 “EB 病毒感染与鼻咽癌相关”“患者感染 EB 病毒”，推断患者患鼻咽癌的风险）；在信息检索领域，能大幅提升从海量数据中精准定位目标信息的效率，减少无关信息干扰；在知识共享层面，可打破不同系统间的知识壁垒，促进跨系统的知识交互与复用；同时，它还为智能问答系统、专家决策系统等高级智能应用提供了底层的知识支撑框架。在知识图谱的实际构建中，应用最为广泛的知识表示方法是三元组表示法。这种方法将每一条知识都规范为 $<h, r, t>$ 的统一形式，其中 h 代表头实体，t 代表尾实体，r 则用于精确描述这两个实体之间存在的特定关系（例如 <鼻咽癌，高发于，中国南方> 这一三元组，就清晰表达了三者的关联）。

表 2-1 常用的CQL 命令

Tab.2-1 Commonly used CQL commands

CQL 命令	作用	举例
CREATE	创建节点、关系和属性	CREATE （n:NasopharyngealCancer {name:'鼻咽癌', type:'恶性肿瘤'}）-[r:has_symptom]->（m:Symptom {name:'鼻塞'}） RETURN r
MATCH	检索有关节点、关系属性	MATCH （n:NPC_Research） RETURN n LIMIT 25
WHERE	筛选条件、过滤检索数据	MATCH （n:Symptom） WHERE n.name='涕血' OR n.name='耳鸣' RETURN n
DELETE	移除节点、关系	MATCH （n:Symptom {name:'虚假症状'}） DELETE n
REMOVE	移除节点、关系的属性	MATCH（n:NPC_Research {name:'某旧研究'}）REMOVE n.outdated_info

当前，图数据库已在知识图谱领域得到广泛应用。它凭借专属的图结构查询语言，能够实现快速检索，不仅支持复杂的多层级关联查询，还可通过图形界面呈现查询结果。目前主流的图数据库包括 Neo4j、JanusGraph 和 TigerGraph 等。其中，Neo4j 因功能完善且具备丰富的实际应用案例，在知识图谱存储场景中占据着最大的市场份额。该数据库拥有活跃的用户社区和丰富的周边工具，其内置的可视化功能进一步简化了数据的查看与展示流程，常用的 CQL 命令如表 2-1 所示。

2.2 知识库

2.2.1 基础概念

知识库（Knowledge Base, KB）作为人工智能领域的核心基础设施，是指采用结构化方式对领域知识进行系统化组织、存储和管理的计算机系统[18]。知识库本质上是一套系统化存储与组织信息的集合，它不像零散的文件夹那样随意堆放内容，而是会按照特定的逻辑框架对信息进行分类、关联和标注。比如企业里常用的产品知识库，会把产品参数、使用教程、常见问题等内容，按照 “产品系列 - 功能模块 - 问题类型” 的层级整理，方便员工或客户快速找到需要的内容；再比如学术研究用的知识库，可能会按学科领域、研究方向、文献类型来组织，让研究者能高效追溯相关成果。这种结构化的特点，是知识库区别于普通信息集合的关键。

构建知识库时，对信息的筛选和验证是核心环节。不是所有信息都能进入知识库，通常需要经过“真实性核查-价值判断-格式规范” 三个步骤。比如整理行业知识库时，首先要确认信息来源是否可靠，优先选择权威机构发布的数据、经过综述论文或长期实践验证的经验总结；接着判断这些信息对目标用户是否有实际价值，像过时的技术参数、与核心需求无关的边缘内容会被排除；最后还要统一信息的格式，比如术语的一致性、图表的规范标注等，确保用户在阅读时不会产生理解偏差。

从价值来看，知识库最核心的作用是实现信息的高效复用与知识传承。对个人而言，一个整理得当的学习知识库，能把分散在笔记、课件、文档里的知识点串联起来，复习时不用再翻找多个文件，还能通过关联内容发现知识间的逻辑关系；对组织来说，知识库更是重要的 “知识资产容器”，老员工的经验技巧、项目中的成功案例和避坑指南，都能通过知识库沉淀下来，新员工入职时不用再依赖 “口口相传”，通过查阅知识库就能快速上手工作，

避免因人员流动导致的知识流失。

2.2.2 嵌入向量模型

嵌入向量模型（Embedding Model）是将文本、图像、音频等非结构化数据转换为低维稠密向量的模型，其核心作用是通过向量空间的距离或相似度来表征原始数据的语义关联，让计算机能够“理解”非结构化数据的含义，是知识库技术的核心。

嵌入向量模型的核心作用包括以下 4 点：

1）语义关联量化：将文本、图像等数据转换为向量后，向量之间的余弦相似度、欧氏距离等可以直接反映原始数据的语义相似度。例如，“鼻炎”和“咽喉炎”的向量距离比“鼻炎”和“汽车”更近，因为它们同属病症。

2）跨模态关联：支持不同类型数据的关联（如文本与图像）。例如，“日落”的文本向量可以与一张日落照片的向量匹配，实现“以文搜图”或 “以图搜文”。

3）降维与高效计算：将高维稀疏数据（如文本的 One-Hot 编码）转换为低维稠密向量，大幅减少存储和计算成本，同时保留关键语义信息，适合用于检索、分类、聚类等任务。

4）作为下游任务的基础：生成的嵌入向量可直接作为机器学习或深度学习模型的输入，用于文本分类、推荐系统、问答系统、知识图谱构建等任务，提升模型性能。

常用的文本嵌入模型包括：BERT、MiniLM、Word2Vec、Bge 等。Bge 是由北京智源人工智能研究院提出的新的 embedding 模型，Bge-m3 支持超过 100 种语言的检索，既能在同一语言内部进行检索，也能实现跨语言的检索功能，能在全球化语境中处理复杂的语言需求；同时通过知识蒸馏来增强模型的学习效果，利用不同检索功能的异质性进行集成，提升了模型的整体性能。Bge-m3 通过多语言对比学习、混合检索公式、长文本分块技术、自我知识蒸馏和优化批处理策略，实现了多模态检索的高效统一。其核心公式（如混合检索加权、多向量交互）和训练机制（如梯度检查点、跨 GPU 负样本广播）为复杂信息检索场景提供了坚实的技术基础[19]。

Bge-m3 能够在多种不同的语言之间相互检索，通过翻译后的句子作为正样本，模型学习将不同语言的词嵌入映射到同一空间。例如，中文“鼻炎”和英文“rhinitis”的嵌入向量在空间中接近，实现跨语言检索。对于同一语

义的不同语言句子对（x_i, x_j）正样本得分$s_{pos} = e_i, e_j$，负样本为批次内其他句子的得分s_{neg_k}。损失函数采用 InfoNCE 形式，其定义如下：

$$L_{\mathrm{multi}} = -\log\left(\frac{\exp(s_{pos}/\tau)}{\exp(s_{pos}/\tau)+\sum_{k=1}^{k}\exp\left(s_{neg_k}/\tau\right)}\right), \quad (2\text{-}1)$$

其中τ是温度参数，控制得分的平滑度。

Bge-m3 单次推理即可生成多模态结果，因为其内部共集成三种检索功能，这三种检索方式分别是：

1）密集检索（Dense Retrieval）

密集检索通过将查询和文档转换为高维向量（嵌入向量），并通过向量之间的距离，如余弦相似度来进行相似度计算。

向量生成：取 Transformer 输出的 CLS 标记，归一化后作为语义向量：

$$e_q = \mathrm{norm}\left(H_q(0)\right), e_p = \mathrm{norm}\left(H_p(0)\right), \quad (2\text{-}2)$$

其中$H_q(0)$是查询的 CLS 隐藏状态，$H_p(0)$是段落的 CLS 隐藏状态。

相关性得分：

$$s_{dense} = e_q \cdot e_p . \quad (2\text{-}3)$$

2）稀疏检索（Sparse Retrieval）

稀疏检索通常将文档和查询表示为词袋模型或通过倒排索引进行处理，通过词频（TF）或逆文档频率（IDF）进行度量。

词项权重计算：通过线性层和 ReLU 激活函数生成每个 token 的重要性：

$$w_{qt} = \mathrm{relu}\left(W_{lex}^{T} h_q(i)\right), \quad (2\text{-}4)$$

其中W_{lex}是可学习的权重矩阵，$h_q(i)$是查询第 i 个 token 的隐藏状态。

联合重要度得分：

$$s_{lex} = \sum_{t\in q\cap p}\left(w_{qt} \cdot w_{pt}\right) . \quad (2\text{-}5)$$

3）多向量检索（Multi-Vector Retrieval）

多向量检索将文档或查询表示为多个向量，而不是单个向量，以更全面地捕捉其特征和语义信息。

一般通过投影矩阵转换进行实现：

$$e_q = \text{norm}(W_{mul}^T h_q), e_p = \text{norm}(W_{mul}^T h_p) \ , \quad (2\text{-}6)$$

其中W_{mul}是可学习的投影矩阵，将整个嵌入转换为多向量形式。

细粒度交互得分：

$$s_{mul} = \frac{1}{n}\sum_{i=1}^{n} \max_{j=1}^{m} e_q(i) \cdot e_p(j) \ , \quad (2\text{-}7)$$

通过上述三种检索方式，可计算其综合得分：

$$s_{rank} = w_1 \cdot s_{dense} + w_2 \cdot s_{lex} + w_3 \cdot s_{mul} \ , \quad (2\text{-}8)$$

其中权重w_1, w_2, w_3根据任务动态调整，例如在法律检索中可增大稀疏检索权重以捕捉关键词。

Bge-m3 训练过程使用了自我知识蒸馏的训练机制，自我知识蒸馏是知识蒸馏的一种特殊形式，其训练机制是让模型自身充当教师模型，将自身的中间层特征或输出作为“软目标”来指导模型的训练，以提升模型性能。其过程主要分为以下两步：

1）教师信号生成

集成三种检索方法的得分作为软标签：

$$y_{teacher} = \text{softmax}(s_{rank}) \ , \quad (2\text{-}9)$$

其中s_{rank}是混合检索得分。

2）学生模型训练

最小化交叉熵损失：

$$L_{distill} = -\sum y_{teacher} \log p_{student} \ , \quad (2\text{-}10)$$

同时保留原始任务损失L_{task}，总损失为：

$$L_{total} = L_{task} + \lambda L_{distill} \ , \quad (2\text{-}11)$$

其中λ是蒸馏权重，通常取 0.5。

Bge-m3 多阶段训练流程如下：

预训练阶段使用掩码自编码器（RetroMAE）在多语言语料上学习基础语义表示，掩码率设为 30%，学习率 1E-4。

通用微调阶段在 C-MTP 无监督语料上进行对比学习，批次大小 19200，采用 InfoNCE 损失，训练 10 万步。

任务微调阶段在标注数据上进行多任务学习，引入硬负样本（ANCE 方法），优化器为 Adafactor，学习率线性衰减至 0。

通过上述技术，使得 Bge-m3 在 MLDR 评测中跨语言平均准确率高达 0.62，显著高于 XLM-R（0.51）。在 NarrativeQA（平均长度 4000 tokens）中，

混合检索的召回率达 0.78，比单一密集检索提升 12%[20]。在 RAG 系统中，Bge-m3 的检索延迟比 BM25+DPR 组合降低 30%，同时精度提升 15%。

2.3 大语言模型

2.3.1 基础概念

大语言模型（Large Language Models, LLM）作为当前人工智能领域的核心技术范式，是指通过海量参数（通常达亿级以上）和超大规模训练数据（TB 级语料）构建的深度学习模型。其区别于传统语言模型的本质特征主要体现在三个相互关联的维度：首先是规模性，即模型参数量与训练数据规模的量级突破，根据 DeepMind 提出的 Scaling Laws 研究框架，当模型参数量超过 1E8 阈值时，模型开始呈现区别于小规模模型的特殊性质；其次是涌现性，指当模型规模超过临界点后，会非线性地产生如上下文推理、多语言翻译等未显式训练的能力；最后是通用性，表现为单一模型通过预训练即可处理跨领域、跨模态的多样化任务。

在技术实现层面，现代典型大模型如 OpenAI 的 GPT-3（1750 亿参数）、Google 的 PaLM（5400 亿参数）等，均基于 Transformer 神经网络架构。该架构通过自注意力机制（Self-Attention）实现高效的跨模态表征学习，其核心优势在于：1）并行化处理能力，允许模型在超大规模数据上高效训练；2）长距离依赖建模，使模型能够捕捉文本中跨度较大的语义关联；3）层次化特征提取，通过多层 Transformer block 逐步构建从词法到语义的抽象表征。这些特性共同促使大模型展现出传统小模型难以企及的零样本学习（Zero-shot Learning）、少样本迁移（Few-shot Transfer）以及复杂上下文推理（Contextual Reasoning）等高级认知能力。

从发展历程来看，大模型的规模扩展遵循近似指数增长规律。2018 年 BERT（1.1 亿参数）的问世首次验证了大规模预训练的有效性，2020 年 GPT-3 将参数量提升两个数量级并证实了涌现现象的存在，而 2022 年发布的 PaLM 等模型则进一步探索了万亿参数级别的可行性。值得注意的是，这种规模扩展并非简单的参数堆砌，而是需要算法-硬件-数据的协同创新：一方面需要改进模型架构（如稀疏注意力、混合专家系统），另一方面依赖分布式训练技术（如 3D 并行、梯度优化）和专用计算硬件（如 TPU 集群）的支持。

2.3.2 Transformer 架构原理

Transformer 模型是基于自注意力机制的序列建模架构，由 Vaswani 等人提出[21]，其核心突破在于摆脱了循环神经网络（Recurrent Neural Network，RNN）对序列顺序处理的依赖，通过并行计算的注意力机制实现了对长距离依赖关系的高效捕捉，成为自然语言处理等领域的基础模型。

Transformer 由编码器（Encoder）和解码器（Decoder）两部分组成。其结构如图 2-1 所示，编码器接收输入序列并生成上下文感知的特征表示，解码器则基于编码器输出和自身历史输出生成目标序列。两者均由N个（原论文中$N = 6$）相同的层堆叠而成。

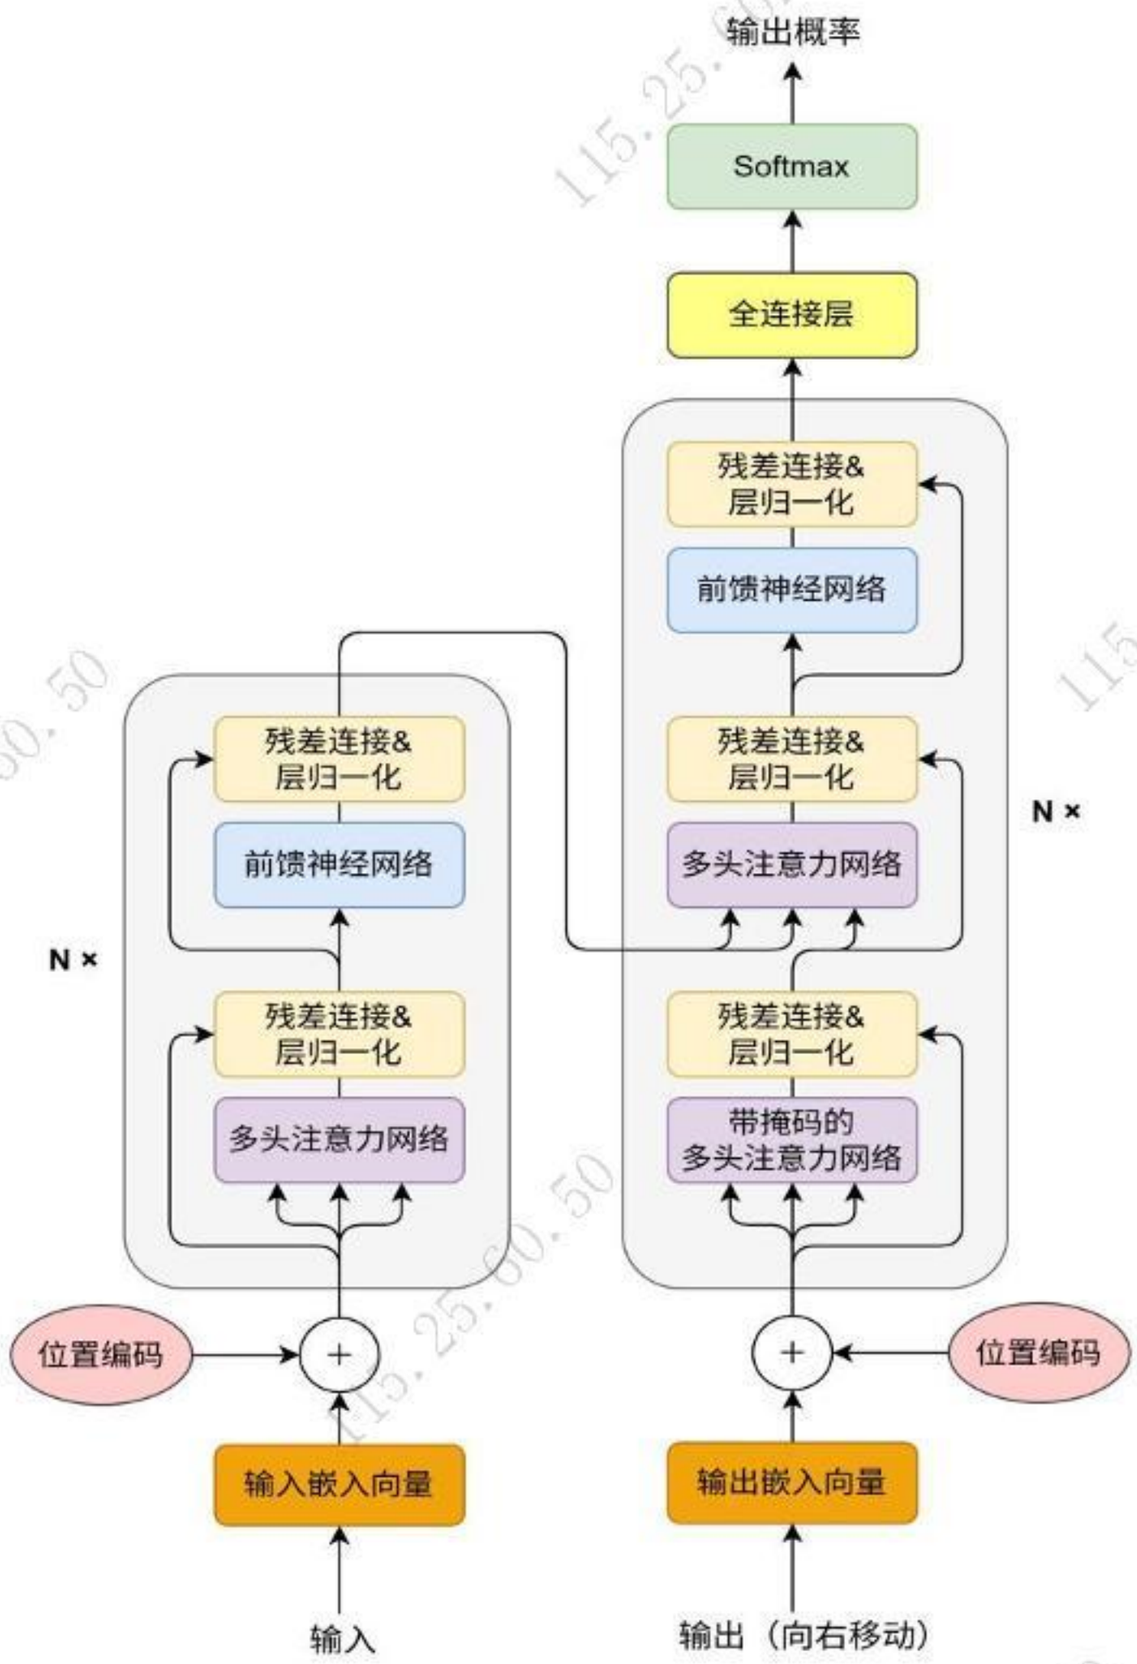


图 2-1 Transformer 架构图

Fig.2-1 Transformer architecture diagram

编码器层包含两个子层：多头自注意力机制（Multi-Head Self-Attention）和前馈神经网络（Feed-Forward Network），每个子层后均采用残差连接（Residual Connection）和层归一化（Layer Normalization）。

解码器层在编码器层的基础上增加了一个编码器-解码器注意力子层，用于关联编码器输出与解码器当前状态。

自注意力机制是 Transformer 的核心，其作用是通过计算序列中每个位置与其他位置的关联权重，生成包含全局上下文信息的特征表示。具体过程如下：

1）Query、Key、Value 向量的生成

对于输入序列的嵌入矩阵$X \in \mathbb{R}^{L\times d_{\text{model}}}$（$L$ 为序列长度，d_{model}为特征维度），通过三个可学习的权重矩阵$W^Q, W^K, W^V \in \mathbb{R}^{d_{model}\times d_k}$生成查询（Query）、键（Key）和值（Value）向量：

$$Q = XW^Q, K = XW^K, V = XW^V \quad , \tag{2-12}$$

其中d_k为Q、K、V的维度。

2）注意力分数的计算

每个位置的 Query 与所有位置的 Key 通过点积计算关联分数，再除以$\sqrt{d_k}$进行缩放（避免梯度消失）：

$$scores = \frac{QK^T}{\sqrt{d_k}} \quad . \tag{2-13}$$

3）注意力权重归一化

对分数应用 Softmax 函数，得到归一化的注意力权重，反映每个位置对当前位置的影响程度：

$$attention\ weights = \text{Softmax}(scores) \ . \tag{2-14}$$

4）上下文特征生成

用注意力权重对 Value 向量进行加权求和，得到自注意力输出：

$$\text{Attention}(Q, K, V) = attention\ weights \cdot V \ , \tag{2-15}$$

为捕捉不同维度的关联模式，Transformer 采用多头注意力机制：将 Q、K、V 分割为 h 个并行的子空间（每个子空间维度为d_k），分别计算注意力后拼接结果，再通过线性变换输出：

$$\text{MultiHea}(Q, K, V) = [head_1; head_2; \ldots; head_h]W^O \ , \tag{2-16}$$

其中$head_i = \text{Attention}(Q_i, K_i, V_i)$，$W^O \in \mathbb{R}^{h\cdot d_k\times d_{model}}$为输出权重矩阵。

前馈网络为每个位置提供非线性变换，由两个线性层和 ReLU 激活函数

组成：

$$FFN(x) = \max(0, W_1 x + b_1)W_2 + b_2 \quad , \tag{2-17}$$

其中$W_1 \in \mathbb{R}^{d_{model} \times d_{ff}}, W_2 \in \mathbb{R}^{d_{ff} \times d_{model}}$,其中$d_{ff} = 2048.$

由于 Transformer 无循环结构，需通过位置编码注入序列顺序信息。原论文采用正弦余弦函数生成位置编码：

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/\mathrm{d}_{model}}}\right), PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/\mathrm{d}_{model}}}\right) \quad , \tag{2-18}$$

其中pos为位置索引，i为维度索引。位置编码与输入嵌入相加后作为编码器和解码器的输入。

Transformer 通过上述机制实现了并行化计算与长距离依赖建模，其设计思想为后续预训练语言模型（如 BERT、GPT）奠定了基础，至今仍是序列建模任务的核心架构之一。如今混合专家模型 MOE[22]结合 Transformer 又一次推动了 LLM 的发展，使 LLM 具备了初步思考和推理的能力。

2.3.3 主流大模型介绍

从 GPT 系列引发行业关注，到 LLaMA[23]、Deepseek[24]、Qwen[25]等开源大模型相继涌现，LLM 的发展经历了从参数规模的不断突破到训练技术革新的历程。早期模型聚焦于语言理解与生成，如今通过持续优化，已具备多轮对话、代码编写、复杂推理等能力。在应用层面，LLM 深度融入教育、医疗、金融等领域，如辅助教师个性化设计教案、助力医生分析病例、为投资者提供市场趋势预判等，极大提高了各行业的工作效率，推动了智能交互的变革与创新。

本文基于 LLM 实现问答系统，LLM 是系统质量的核心因素，直接影响了最终的用户体验，因此，LLM 的选型也至关重要。本文从两个大的方面进行选型，分别是：通用大语言模型和医学专业模型，首先介绍一下选择对比的模型。

1）通用大语言模型

GPT 系列是 OpenAI 公司开发的闭源大语言模型，也是 LLM 现在爆火的引路人，其主要包含两个产品线：一是在 2025 年 2 月 27 日发布的 GPT-4.5，拥有约 1750B（billion）参数，在复杂推理、专业知识问答和长上下文理解上优势显著。它通过大规模互联网文本、学术文献等多样化数据训练，对各类知识理解深入。在代码生成任务中，能高效编写复杂程序代码；在多模态方

面，可理解输入图像并结合文本生成相关解释[26]。但其闭源性质限制了深度定制，调用成本也较高。二是在 2024 年 12 月 20 日发布的 GPT-o3，此版本在速度和成本上做了优化，同时增强了多模态交互。采用优化的 Transformer 架构，减少推理时间，适用于对响应速度要求高的场景。在处理图像与文本结合的任务时，能快速给出连贯输出，不过在专业领域知识细节上，相较于 GPT-4.5 可能稍逊一筹。

Grok 系列是 xAI 公司开发的一款闭源模型，其在 2025 年 7 月 10 日发布了最新的 Grok 4，具备强大的知识检索与整合能力。训练数据包含大量实时网络信息，使其能紧跟知识更新，在回答时效性问题上表现突出[27]。模型自身附带了联网搜索能力，例如能快速提供最新的科技动态、政策解读等。然而，在医学等专业性强的领域，若无针对性优化，可能出现知识准确性问题。

Claude 系列是 Anthropic 公司开发的一款闭源模型，其 2025 年 5 月 22 日最新发布的 Claude4 opus，参数规模达数千亿级别。采用“Constitutional AI”训练方法，保障回答安全可靠，减少有害输出。拥有超长上下文窗口（200K tokens），利于处理长文档分析、复杂对话。在金融分析、法律文档审阅、程序编码等领域表现出色，能准确理解复杂条款并进行解读，但多模态原生能力相比部分模型稍弱[28]。

Gemini 系列是 Google 公司和 DeepMind 公司联合开发的一款闭源模型，其 2025 年 6 月 5 日最新发布了原生多模态模型 Gemini2.5Pro，可无缝处理不同类型信息。其架构专为多模态设计，能同时理解图像、文本和音频输入。在图像识别结合文本描述任务中表现优异，能精准描述图像中的医学场景，并给出相关解释。在知识更新及时性上，借助 Google 强大的数据资源有一定优势，但在特定领域深度知识挖掘上需进一步优化[29]。

Qwen 是阿里巴巴公司开发的开源模型，其最新 2025 年 4 月 29 日发布的 qwen3 支持多模态、代码生成和结构化输出。具备 128K 长文本解析能力，拥有多个不同参数版本（0.6B 至 480B）可适应多样硬件环境。在跨语言知识管理、自动化流程任务（如金融建模）中表现良好，中文语言理解与生成能力优秀，但在国际医学知识通用性上，可能需结合国际数据微调[25]。

Kimi 是月之暗面公司开发的大模型，最新的 Kimi-K2 于 2025 年 7 月 11 日推出并开源，总参数为 1000B，激活参数 32B，采用“混合专家”（Mixture-of-Experts，MOE）架构，每次推理时动态激活 320 亿参数，支持最长 128K 上下文，具备更强通用性与工具调用能力，全新升级的 ToolCall 能力可严格保障格式正确性，适用于复杂 Agent 任务[30]。

GLM 是清华大学联合智普公司开发的开源模型，其最新 2025 年 7 月 28 号发布了 GLM4.5，中文对话流畅自然，支持多轮交互。在长文本摘要和情感分析方面表现出色，适用于轻量级交互场景。不过在医学专业知识问答的深度和广度上，需结合医学知识图谱和专业数据增强。

DeepSeek 是深度求索公司开发的开源模型，其最新 2025 年 1 月 20 日发布的 DeepSeek-R1 深受大家的好评，采用 671B 参数的 MoE 和 Transformer 架构，经大规模强化学习优化推理能力。在科技、工程专业领域表现精准，支持 128K 长上下文，中文处理能力突出。但在医学领域知识覆盖和准确性上，需通过医学数据微调提升[24]。

豆包是字节跳动公司开发的一款闭源模型，其最新 2025 年 6 月 11 日发布的 Doubao-Seed-1.6-thinking，在思考能力上得到强化，能更准确地理解和处理复杂任务，在代码生成、数学、逻辑推理、指令遵循等方面均有进一步提升，支持 256K 上下文和多模态推理。在高考全国新一卷数学测试中，豆包大模型取得 144 分，在大模型中居全国第一；在海淀模拟全卷考试中，理科得分 706 分，文科得分 712 分，较前代模型均有大幅提升。表现出起强大的逻辑思维能力。

2）医学专业模型

医学专业模型专门针对医学领域数据训练，对医学知识理解和应用更精准，相比于通用大模型，在医学相关知识储备上更加丰富，对医学相关名词也有着更好的理解。

Med-PaLM 2 是 Google 和 DeepMind 联合于 2023 年 3 月 14 日基于 PaLM 优化的开源大模型，通过 MIMIC-III 临床数据库（13 万份病历）、Cochrane 系统评价（超 10 万篇）、PubMed 摘要（2000 万篇）等海量数据训练，在疾病诊断、治疗方案推荐上严格遵循医学规范。在鼻咽癌诊断中，能准确依据症状、检查结果给出诊断建议和治疗方案，但知识更新速度相对较慢，且对罕见鼻咽癌病例的处理可能存在局限性。

灵医大模型是百度于 2023 年 9 月发布的一款闭源模型，结合了 2 亿用户搜索数据、5 亿健康科普内容、1000 万问答对和国际权威知识库：爱思唯尔医学指南、UpToDate 临床决策支持系统。在中文医疗 LLM 评测榜单 promptCBLUE 中位列 A 榜第一。但对罕见病和复杂病例的处理能力仍待提升。

2.4 本章小结

本章主要对基于知识图谱的鼻咽癌问答系统的相关理论和技术进行介绍。首先介绍了知识图谱基础概念，以及在构建流程中所涉及到的本体构建、知识抽取、知识表示与知识存储等关键技术。然后重点介绍知识库的基础理论及其在智能问答系统中的作用，阐述了知识库的定义与内涵、构成要素、知识表示方法及知识库的类型划分；接着深入分析嵌入向量模型（Embedding Model）的基本原理。最后介绍大语言模型的基础知识以及介绍了 Transformer 模型原理和目前主流的大模型。

3 知识库和知识图谱的构建

在鼻咽癌问答系统的构建中，知识库、知识图谱与大语言模型的融合是提升系统性能与实用性的关键。知识库能结构化存储鼻咽癌诊断标准、治疗方案等权威医学知识，确保回答内容的准确性与专业性；知识图谱则通过实体与关系网络，通过依赖关系呈现疾病症状、病理机制、药物关联等复杂医学逻辑，实现知识的深度关联，有助于大模型的推理；而大模型凭借强大的自然语言理解和生成能力，能够精准解析用户提问意图，输出通俗易懂的回答。三者相结合，既能利用知识库与知识图谱保证回答的科学性，又能借助大模型提升交互体验，为用户提供高效、准确且人性化的鼻咽癌知识解答，助力疾病科普、辅助临床决策。接下来将对知识库的构建、知识图谱的构建、生成式模型的选型进行详细的介绍。

3.1 知识库的构建

知识库可以看做为一个“结构化的知识集合”，一个专门存储特定领域知识的“数字图书馆”。其包含的内容通常是经过整理、分类的专业信息。检索增强生成（Retrieval-Augmented Generation，RAG）是一种结合了“知识库检索”和“AI 生成”的技术[31]。比如在鼻咽癌问答系统中，问“早期鼻咽癌有哪些症状？”如果没有 RAG，LLM 可能只凭自己训练过的通用知识回答，可能会遗漏某些最新发现的症状。当有了 RAG，系统会先去知识库中找到关于“早期症状”的相关描述，再让 LLM 基于这些内容参考生成回答，使回答更专业、更贴合知识库中的信息。

3.1.1 数据采集

知识库的构建需要大量的专业权威数据（本文中是鼻咽癌相关数据），通过这些专业数据来提升大模型的专业知识储备，本文主要通过学术论文数据采集和专业网站数据采集两种方法进行知识库构建数据的准备。

1）在开展鼻咽癌相关研究时，学术文献与数据的主要来源包括以下几个重要数据库。PubMed 作为全球最大的医学文献数据库，涵盖了海量的国际研究论文，尤其在鼻咽癌领域积累了海量的高质量英文文献[32]。对于中文文献，则可依托中国知网（CNKI）这一国内最具权威性的学术资源平台，获取丰富的鼻咽癌临床研究、病例分析及医药相关成果。此外，万方数据也提供了大量医学期刊论文与博硕士学位论文，尤其在鼻咽癌诊疗实践经验的总结与分析方面文献资源尤为丰富。

学术文献和论文数据的采集方法：先在上述数据库的搜索栏中输入“鼻咽癌”、“鼻咽癌诊疗”、“nasopharyngeal carcinoma”等关键词，筛选出近10年（保证时效性）高质量期刊（影响因子大于2，保证质量）的相关文献。对于可以免费下载的文献，直接下载保存全文；对于需要权限的，可通过学校图书馆有权限的数据库进行下载。

2）专业医学网站数据采集的主要来源包括多个权威且实用的平台。其中，国家癌症中心官网会定期发布涵盖全国癌症统计数据的重要报告，其中包括鼻咽癌的发病率、死亡率及地域分布等权威信息，为研究提供宏观流行病学依据。丁香园等专业医生社区则汇聚了大量临床医生分享的真实病例与诊疗经验，例如常可见到“一例晚期鼻咽癌患者的靶向治疗案例”这类具有实践参考价值的内容。此外，如“医学百科”等结构化医学知识网站也设有鼻咽癌专题板块，其内容组织清晰、系统性强，非常适合进行规范化、批量的信息采集与整理。

专业医学网站数据采集的采集方法：使用Python爬虫获取相关数据，爬取过程中严格遵守网站的版权协议和robots.txt文件[33]。本文使用的爬虫详细步骤如下：

（1）确定要爬取的网页范围，比如“医学百科”里所有包含“鼻咽癌”的文章链接。

（2）通过将网站URL替换为“域名URL/robots.txt”查看网站允许爬虫的范围和规则，若需要爬取的内容包含在禁止爬取列表中，则跳过该网页。

（3）通过requests库请求相应的URL，获取该URL的HTML源码。

（4）通过beautifulsoup库解析爬取的HTML[34]，只保留正文内容，删除广告、评论、源代码等无关信息，并将爬取的数据保存为txt文件。

（5）循环执行上述（1）-（4）过程，直至需要爬取的URL全部爬取完毕。

通过上述两种数据采集方法，最终得到采集文献390篇，爬取网页1790个，共计约83万字。作为后续知识库构建、知识图谱构建的主要数据来源。

3.1.2 知识库的构建

LLM是在海量数据上训练的，但并未在鼻咽癌相关数据上训练，因此单一LLM回答鼻咽癌相关问题会有偏差，甚至是错误。RAG通过将鼻咽癌数据添加到LLM能够访问的知识库中来解决此类问题，伴随着知识库的更新，使LLM的知识储备也能够不断更新。

在 RAG 中，采集的鼻咽癌相关数据被加载并向量化储存，用于查询或索引。通过用户提问的关键字进行索引，得到知识库中最相关的上下文。此上下文和用户的问题会一起发送给 LLM，LLM 会提供相应的参考并做出响应，其大致的工作流程如图 3-1 所示。本文使用 LlamaIndex[35]框架作为构建知识库的工具，LlamaIndex（曾用名 GPT Index）是一个专为连接外部知识与 LLM 设计的开源框架。它核心作用是帮助开发者更高效地构建基于专属知识库的问答系统、智能检索工具等应用，简化从数据处理到问答生成的全流程。

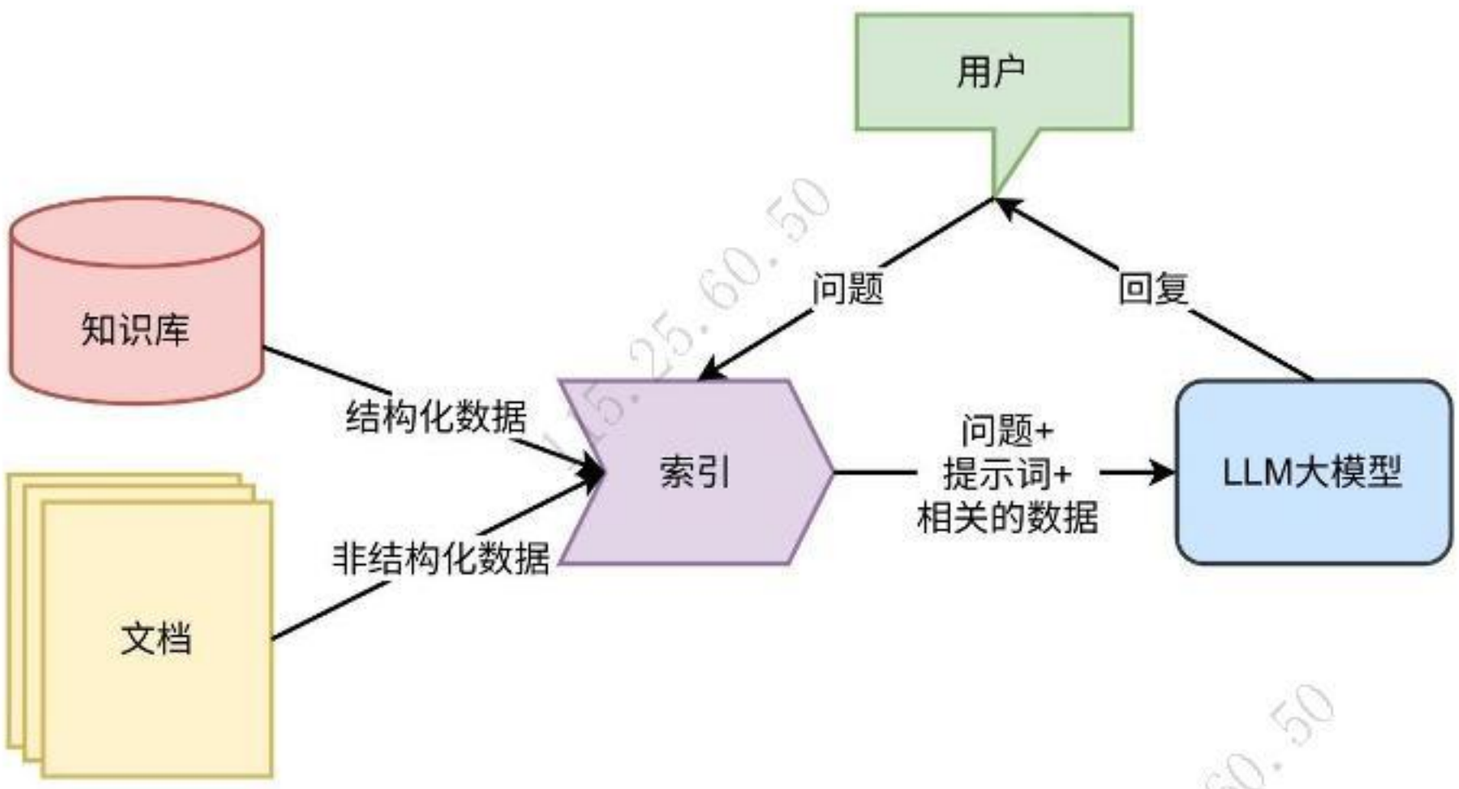


图 3-1 知识库的工作流程

Fig.3-1 Workflow of Knowledge Base

RAG 的构建和使用包括四个关键阶段：加载、索引、存储、查询[36]，如图 3-2 所示，每个阶段都有着不同的任务和功能：

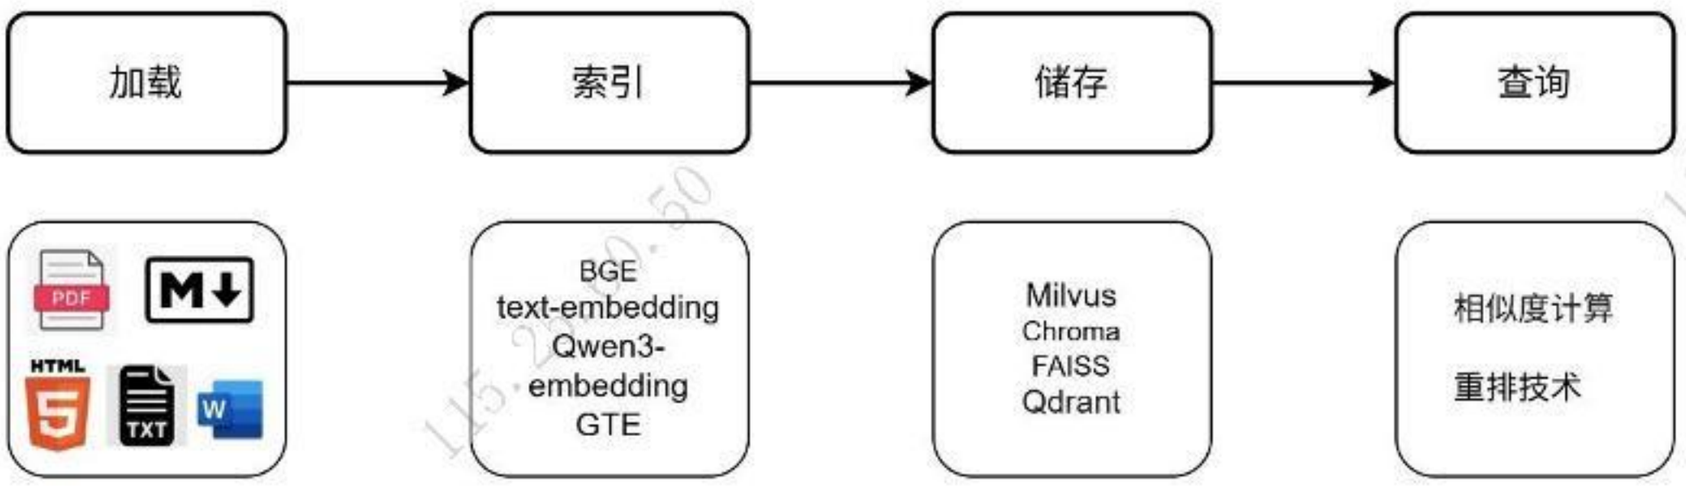


图 3-2 RAG 构建的四个阶段

Fig.3-2 The Four Stages of RAG Construction

1）加载

在 RAG 处理鼻咽癌的相关数据之前，需要先加载数据。LlamaIndex 提供了相关的接口，也称为 Reader 数据连接器，能够从不同的数据源、数据格式中读取数据，并将其格式化为 Document 对象。最常用的读取器是

SimpleDirectoryReader，它支持读取多种格式，包括 Markdown、PDF、txt 文档、图像等[37]。对于扫描的 pdf、图像等数据，需首先利用光学字符识别（Optical Character Recognition, OCR）技术将其转换为文本，再进行文档的加载，本文集成 MinerU 工具作为 OCR 识别工具。

加载完文档后，需要对文档进行预处理，第一步是将其分割成“Node”对象（子块）。即将鼻咽癌数据处理成适合检索的小片段，当需要检索时能够通过小片段和用户问题进行对比，得到其之间的相似度，通过相似度找出最相关的片段，从而获得对应的上下文信息以供 LLM 参考。

LlamaIndex 支持多种文本分割器，包括基于段落/句子/token/文件的分割器，本文使用固定长度为 200 token 作为分割器。在 LlamaIndex 中，索引（Index）是一个由 Document 对象构成的数据结构，该结构便于 LLM 查询。

Index 的核心是向量嵌入，是文本语义的数值表示，简单来说就是将上述分割的 200 token 小片段转换为一组向量，通过计算机能够识别的数字来表示自然语言。两段语义相似的文本会拥有相似的嵌入，即两段文本向量嵌入之间的距离较小，即使两段文本实际差异很大，只要语义相似，向量嵌入距离依旧很小。这种数学关系实现了语义搜索，用户提供查询词后，LlamaIndex 可以定位与查询词语义相关的文本，而不仅仅是简单的关键词匹配。

2）索引

向量嵌入有多种类型和方式，它们在效率、效果和计算成本上有所不同。常用的嵌入模型包括：Word2Vec[38]、FastText[39]、BERT[40]、text-embedding、Gte[41]、Bge[19]；此外，还包括 2025 年 6 月 6 日刚发布的 Qwen3-embedding[42] 等，虽然嵌入模型较多，但并不都适合做为 RAG 的嵌入模型，较早的 Word2Vec、FastText、BERT 在嵌入精度上有一定的劣势，通常用于词嵌入，即单个单词的嵌入表示，而最新发布的 Qwen3-embedding 等模型，虽然性能较高，但没有经过时间的验证。OpenAI 使用 text-embedding-ada-002 作为默认嵌入模型，但是该嵌入模型对中文的嵌入性能一般，因此本文选用 Bge-m3 作为嵌入模型，Bge-m3 支持超过 100 种语言的检索，既能在同一语言内部进行检索，也能实现跨语言的检索功能，能在全球化语境中处理复杂的语言需求；同时通过知识蒸馏来增强模型的学习效果，利用不同检索功能的异质性进行集成，提升了模型的整体性能。

3）存储

嵌入向量通常是高维向量（维度从几十到几千不等），其核心价值在于通过语义相似度（如余弦相似度、欧氏距离）实现跨模态匹配、模糊检索等

功能。将其存储在向量数据库中，本质是解决传统数据库无法满足的高维数据计算的需求。

表 3-1 不同向量库之间的比较

Tab.3-1 Comparison between different vector libraries

向量数据库	特点
Milvus	专为大规模向量检索设计，支持亿级数据量，开源且分布式部署友好。[43]
FAISS	纯算法库（非完整数据库），专注超高维向量快速相似度搜索；适合科研、小规模工程快速集成[44]。
Weaviate	轻量级开源数据库，支持向量+元数据过滤；适合中小规模 RAG、推荐系统。
Chroma	部署简单，一行代码启动；适合个人项目、RAG 原型验证。
Pinecone	全托管云服务，无需运维，自动优化索引，与大模型生态（OpenAI 等）深度集成；适合企业快速上线。

向量数据库有很多种，它们各自有各自的优势和特点，其如表 3-1 所示。Milvus 是目前主流的开源向量数据库之一，相比 FAISS、Weaviate、Chroma、Pinecone 等同类工具，Milvus 的底层设计为原生分布式架构，而非从单机工具扩展而来（如 FAISS 是算法库，需额外开发分布式能力），支持百亿级向量存储。Milvus 支持几乎所有主流 ANN 索引，可根据业务对“速度-精度”进行权衡。Milvus 不仅支持文本向量，还能支持处理图像、音频、视频等多模态向量，且支持多向量存储（如本文使用的嵌入模型 Bge-m3 的“多向量检索”功能，可将一篇长文档拆分为多个子向量存储，提升检索精度），相比之下，Weaviate 虽然也支持多模态，但在长文档多向量处理上灵活性较低；适配 GPU 加速，进一步提升大规模数据的检索速度[45]。基于上述优点，本文选择 Milvus 作为向量数据库。LlamaIndex 可以通过 VectorStoreIndex 接口将文档数据转换为嵌入向量，并通过 MilvusVectorStore 接口持久化储存到 Milvus 中。

4）查询

LlamaIndex 从 Milvus 中加载和使用索引的过程，本质是通过 Milvus 向量数据库读取已存储的向量数据，并基于这些数据构建可查询的索引对象。LlamaIndex 会将用户提问转换为向量，通过 Milvus 进行相似度搜索，返回最相关的文档片段。最常见的检索类型是“top-k”语义检索，即返回相似度排

名最高的 k 个结果，这也是本文使用的方法。一般还包含后处理阶段，是对检索到的 Node 对象进行重排、转换或过滤，例如要求它们具有特定的元数据（如关键词）。最终将查询到的上下文发送给 LLM 进行参考。

3.2 知识图谱的构建

知识图谱在问答系统里就像一张精细的关系网，把各种信息按“谁和谁有什么联系”梳理清楚。比如问“鼻咽癌有哪些早期症状？”，它能快速从“疾病-症状”的关联中找出相应的关系，而不是去知识库中匹配相关内容。它能够为 LLM 提供更多的逻辑思维支持，减少 LLM 的幻觉，使 LLM 的回答更有逻辑性。

3.2.1 数据来源和处理

构建知识图谱的数据，一部分来自于章节 3.1.1 中构建知识库的数据，主要包括：一是从 PubMed、CNKI 等筛选的 379 篇鼻咽癌相关文献，优先选择近 10 年发表、影响因子大于 2 的期刊论文，重点关注临床研究、诊疗指南类文献；二是权威医学专著，包括《耳鼻咽头颈外科学（第 9 版）》[46]、《鼻咽喉癌诊疗规范手册》[47]、《鼻咽癌放疗后的中医康复与调养》[48]等 11 本电子书籍，截取其中涉及鼻咽癌的章节；三是通过爬虫获取的专业医疗网站内容，如 39 健康网的鼻咽癌专区、丁香园社区的相关页面，有效文本约 43 万字。对扫描 PDF 格式的文献和图书内容进行 OCR 识别与校对，确保文本准确率；将网页 HTML 标签去除，保留正文纯文本内容。

另一部分是使用开源医疗数据集，提取 TCGA 数据库[49]中鼻咽癌临床数据子集及中文医学知识图谱（CMeKG）[50]中的相关子集。对其中的结构化字段（如“病理类型”“治疗方案”）进行文本化转换，统一数据格式。

通过上述两部分数据来源，最终形成约 83 万字的原始文本语料，将其按照 8:2 比例划分为训练集和验证集。

3.2.2 数据标注

通过对专用数据标注方法的了解，形成了数据标注的规则体系，对于实体标注体系，本文定义 9 类核心实体，涵盖疾病诊疗全流程，具体核心实体类别和示例如表 3-2 所示：

表 3-2 核心实体和示例

Tab.3-2 Core entities and examples

核心实体	示例
疾病实体	包括具体病理类型（如“鼻咽鳞状细胞癌”）、亚型（如“角化型鳞状细胞癌”）
症状实体	如“回吸性涕血”“颈部肿块”等临床表现
治疗实体	含治疗方式（如“调强放射治疗”）、手术名称（如“鼻内镜下鼻咽部活检术”）
药物实体	包括化学药物（如“顺铂”）、靶向药物（如“尼妥珠单抗”）
检查实体	如“鼻咽部增强 MRI”“EB 病毒抗体检测”
解剖实体	如“鼻咽顶壁”“咽隐窝”等部位
分期实体	如“TNM 分期Ⅳ期”“临床Ⅰ期”
并发症实体	如“放射性中耳炎”“吞咽困难”
人群实体	如“EB 病毒感染者”“华南地区居民”

对于关系标注体系，本文基于临床逻辑定义了 11 种核心关系，体现实体间的语义关联，具体核心关系和示例如表 3-3 所示：

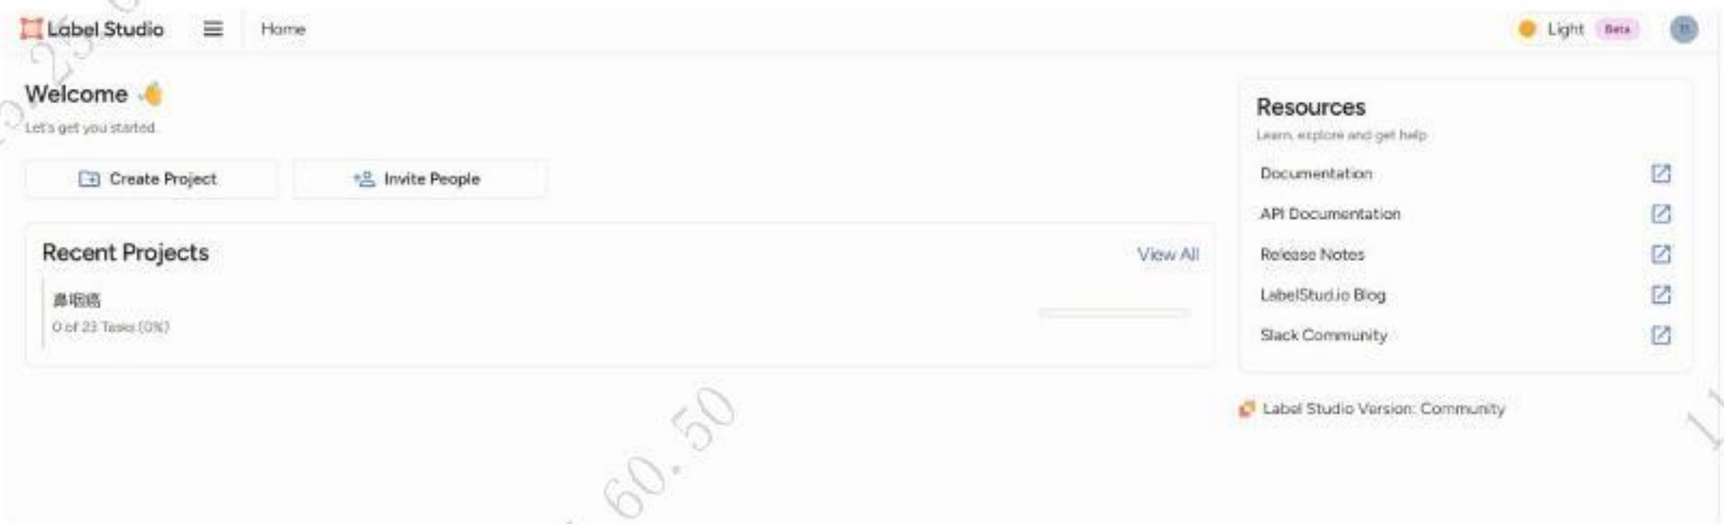


图 3-3 Label Studio 界面

Fig.3-3 Label Studio interface

选用章节 3.2.1 所提及的数据，从中抽取 2000 条作为本次标记的数据对象，使用 Label Studio 工具[51]辅助进行标注，该工具界面如图 3-3 所示。具体步骤如下：

在 Label Studio 中创建新项目，选择“Natural Language Processing”模板，重点配置标注要素：预设实体类型需覆盖医学专业术语，如“疾病”（含

鼻咽癌及亚型）、“症状”（如鼻塞、耳鸣）、“治疗方法”（如放疗、化疗）、“药物”（如顺铂）、“检查手段”（如鼻咽镜）等；关系类型需体现医学逻辑，如“疾病-有症状”“疾病-需检查”“疾病-可治疗”“治疗-使用药物”等。

表 3-3 核心关系和示例

Tab.3-3 Core relationships and examples

核心关系	示例
疾病 - 伴随症状	如“鼻咽癌-伴随-颈部淋巴结肿大”
疾病 - 需要检查	如“鼻咽癌-需要-鼻咽镜检查”
检查 - 用于诊断	如“病理活检-用于-确诊鼻咽癌”
疾病 - 适用治疗	如“早期鼻咽癌-适用-单纯放射治疗”
治疗 - 包含药物	如“化疗-包含-顺铂”
治疗 - 可能引发	如“放射治疗-引发-放射性皮炎”
疾病 - 高发人群	如“鼻咽癌-高发于-40-60 岁男性”
疾病 - 有分期	如“鼻咽癌-分为-TNM 分期”
分期 - 对应治疗	如“III期鼻咽癌-对应-同步放化疗”
药物 - 给药方式	如“紫杉醇-通过-静脉滴注给药”
症状 - 常见于	如“耳鸣-常见于-鼻咽癌患者”

进入标注环节后，逐句处理文本。先标注实体：选中“鼻咽癌”文本段，选择“疾病”标签；遇到“颈部淋巴结肿大”，标记为“症状”；看到“调强放疗”，归类为“治疗方法”。实体标注完成后，通过界面中的“关系工具”连接相关实体：例如，用“有症状”关系连接“鼻咽癌”与“回吸性涕血”，用“可治疗”关系连接“鼻咽癌”与“同步放化疗”，用“使用药物”关系连接“化疗”与“紫杉醇”，形成“鼻咽癌-有症状-回吸性涕血”“化疗-使用药物-紫杉醇”等三元组。对于复杂句子（如“鼻咽癌患者常需通过鼻咽镜检查确诊”），需同时标注“鼻咽癌”（疾病）、“鼻咽镜检查”（检查手段），并建立“需检查”关系。

全部文本标注完成后，导出 JSON 格式数据，文件中会包含每个实体的位置、类型及关系详情，导出的数据可直接用于构建鼻咽癌知识图谱，或作为训练数据输入三元组抽取模型（如 BERT-based 模型），后续可根据标注结果优化实体和关系类型，提升标注体系的专业性。

特殊情况处理：遇到缩写词（如“IMRT”对应“调强放射治疗”）时，先标注全称再括号注明缩写；对存在争议的医学概念（如某症状是否属于鼻咽癌典型表现），标注时附上参考文献依据。

邀请 1 名从事鼻咽癌临床工作 10 年以上的副主任医师作为审核专家，随机抽取 20%的标注数据进行审核。重点检查实体类型错误（如将“颈部淋巴结转移”误标为“症状”）、关系逻辑错误（如“治疗-引发”关系颠倒为“引发-治疗”），对错误标注进行修正并记录错误类型。

3.2.3 知识图谱的构建

在基于知识图谱的问答系统中，实体与关系构成了提升 LLM 逻辑能力的核心骨架。实体作为知识图谱的基本单元，为 LLM 提供了精确的语义锚点，确保模型在理解问题时能准确定位核心概念；而实体间的关系（如从属、因果、时空关联等）则构建了结构化的推理路径，为 LLM 提供了可追溯的逻辑链条。

当 LLM 结合知识图谱的实体与关系时，无需依赖模糊的上下文联想，而是能沿着明确的实体关联进行多步推理——例如从“张三是李四的父亲”“李四是王五的妻子”中，直接推导出“张三是王五的岳父”。这种基于实体与关系的结构化知识，不仅能约束 LLM 的“幻觉”输出，更能引导其按照客观规律展开逻辑演绎，显著提升在复杂问答场景中（如多实体关联、长链条推理）的回答准确性与逻辑性。因此，本文只需要提取出，实体之间的依赖关系三元组，即可满足提升 LLM 的逻辑能力，至于实体的基本信息，在知识库中有着更加详细的介绍。

实体抽取的目标是从文本中自动识别预定义的 9 类核心实体，为知识图谱提供节点数据。本文采用 BERT+CRF 模型实现实体抽取，该模型结合了 BERT 对语义的深层理解能力和 CRF 对序列标注边界的约束作用，适合处理鼻咽癌数据文本中实体边界模糊、嵌套复杂的问题。

模型训练分为三个步骤：首先进行领域预训练，使用 5000 篇未标注的鼻咽癌文本对通用 BERT-base 模型进行继续训练，通过调整模型参数使其适应鼻咽癌术语的语义特征；然后利用 3.2.2 标注的 2000 条语料数据集进行微调，

将文本按字分割后输入 BERT，得到每个字的上下文语义向量，再通过全连接层映射为 9 类实体标签的概率分布；最后通过 CRF 层对输出概率进行解码，利用转移矩阵约束标签序列的合理性（如“分期”实体不能直接跟随“药物”实体的起始标签），输出最优标注结果。

实体抽取的输出为结构化实体列表，每条记录包含实体文本、类型及在原文中的位置，例如：{"text": "紫杉醇", "type": "药物", "start": 32, "end": 35}，为后续关系抽取提供基础实体数据。

关系抽取是识别实体间语义关联并生成三元组的关键步骤，本研究采用“实体对分类法”实现关系抽取：先从文本中提取实体对，再判断其所属关系类型，最终形成“头实体-关系-尾实体”三元组。


```
{"h": "鼻咽癌", "t": "鼻咽镜检查", "r": "需要检查"}
{"h": "鼻咽鳞状细胞癌", "t": "病理活检", "r": "需要检查"}
{"h": "病理活检", "t": "确诊鼻咽鳞状细胞癌", "r": "用于诊断"}
{"h": "EB 病毒抗体检测", "t": "确诊鼻咽癌", "r": "用于诊断"}
{"h": "早期鼻咽癌", "t": "单纯放射治疗", "r": "适用治疗"}
{"h": "晚期鼻咽癌", "t": "同步放化疗", "r": "适用治疗"}
{"h": "化疗", "t": "顺铂", "r": "包含药物"}
{"h": "靶向治疗", "t": "尼妥珠单抗", "r": "包含药物"}
{"h": "放射治疗", "t": "放射性皮炎", "r": "可能引发"}
{"h": "化疗", "t": "恶心呕吐", "r": "可能引发"}
{"h": "鼻咽癌", "t": "40-60 岁男性", "r": "高发人群"}
{"h": "鼻咽鳞状细胞癌", "t": "华南地区居民", "r": "高发人群"}
{"h": "鼻咽癌", "t": "TNM 分期", "r": "有分期"}
{"h": "角化型鳞状细胞癌", "t": "临床分期", "r": "有分期"}
{"h": "Ⅰ 期鼻咽癌", "t": "单纯放射治疗", "r": "对应治疗"}
{"h": "Ⅲ 期鼻咽癌", "t": "同步放化疗", "r": "对应治疗"}
{"h": "顺铂", "t": "静脉滴注", "r": "给药方式"}
{"h": "尼妥珠单抗", "t": "静脉注射", "r": "给药方式"}
```


图 3-4 提取出的三元组示例

Fig.3-4 Extracted triplets

具体实现是，以 BERT-base 模型为基础编码器，对包含目标实体对的文本片段进行编码。为增强模型对实体位置的感知，在输入文本中对头实体和尾实体分别添加特殊标记（如"[H]"和"[T]"），例如将“放射治疗可导致鼻咽癌患者出现放射性皮炎”处理为“[H] 放射治疗 [H] 可导致鼻咽癌患者出现 [T] 放射性皮炎 [T]”。模型通过[CLS] token 的隐藏向量捕捉句子整体语义，经全连接层和 softmax 函数输出 11 种关系类型的概率分布，概率最高的类型即为该实体对的关系。

模型在 2000 组标注的实体对样本上训练。最终提取出的三元组如图 3-4

所示：

对于多源数据中出现的冲突三元组（如不同文献对同一治疗方法的适用分期描述不一致），采用“权威优先+多数表决”原则处理：优先采纳指南数据，若无指南依据则以多数文献支持的表述为准。经处理后，共得到高质量三元组 3236 条，其中实体 1931 个，关系 2087 个，涵盖鼻咽癌诊疗全流程的核心知识关联。

将生成的三元组数据导入 Neo4j 图数据库，完成知识图谱的构建与可视化展示。导入前需进行知识融合处理：实体层面，对同义实体（如“鼻咽癌”与“鼻咽恶性肿瘤”）进行归一化，关系层面，通过领域规则库（如“化疗”与“化学治疗”视为同一关系）进行标准化，确保关系表述的一致性。

在 Neo4j 中，每个实体作为独立节点存在，实体间的关系作为有向边存储，记录关系类型[52]。例如“放射治疗”节点与“口腔黏膜炎”节点通过“可能引发”边连接。通过 Neo4j 的可视化界面，可直观展示实体间的关联关系（如以“鼻咽癌”为中心节点，辐射出症状、治疗、并发症等关联节点），如图 3-5 是通过“辅助化疗”检索到的实体依赖关系。



图 3-5 “辅助化疗”实体依赖关系

Fig.3-5 Entity dependency relationship in adjuvant chemotherapy

3.3 生成式模型

3.3.1 知识库和知识图谱与大模型的结合

为了挑选出适合鼻咽癌问答系统的 LLM，首先对鼻咽癌知识问答系统模型选型过程进行了需求分析，确保挑选的 LLM 大模型符合本文的需求，主要包括以下 6 个方面：1）鼻咽癌知识问答系统需准确理解专业术语，如“咽隐窝活检”“调强放射治疗”，严格遵循临床诊疗规范，如“NCCN 指南”等；2）能结合最新研究成果更新知识，支持本地化治疗经验融入，即能够使用知识库；3）同时要高效调用医学知识库和知识图谱，快速准确回答患者和医护人员问题；4）知识理解和生成能力强，能够进行长文本的对话和记忆等；5）能够使用网络搜索，及时搜索网络上相关知识的动态，获取最新信息；6）安全性，能够保障用户的数据安全，保证用户隐私不会泄露等。

基于以上 6 个维度，综合考量了 2.3.3 中介绍的大模型，其中 Med-PaLM2 是在专业的医学数据上训练并微调的模型，在专业知识维度展现了优势，但该模型未提供应用程序编程接口（Application Programming Interface, API）调用服务，若需本地部署则需投入大量硬件资源；GPT-4.5、Gemini2.5Pro、Grok4、Claude4 opus 训练数据中英文数据较多，而且都属于闭源大模型，因此暂不考虑。Kimi-K2、DeepSeek-R1、Seed-1.6-thinking、Qwen3 等模型各维度均衡，但是 DeepSeek-R1 经过大众的考验，思考能力出众。

综合考虑，选择 DeepSeek-R1 作为基础模型，通过注入大量鼻咽癌医学文献、病例数据，增强医学知识理解。利用其出色的推理能力，结合知识图谱，梳理鼻咽癌知识逻辑关系。接入医学知识库，保障知识调用准确。对于最新知识，可结合网络搜索接口或定期更新知识数据实现。医学专业模型提供专业医学知识校验，确保回答符合医学规范，从而构建高效、准确的鼻咽癌知识问答系统。

前面章节，介绍了基于鼻咽癌数据的知识库的构建、知识图谱的构建和 LLM 大模型的选型，要使它们发挥出最佳的效果，还需要对它们的流程进行编排，保证各司其职，本文使用的框架整体工作流程如图 3-6 所示。

当用户发起提问时后，系统会通过意图识别，识别出用户想要了解的主要问题或关键字，然后通过并行三类检索：其一，向量检索基于 Milvus 向量数据库从非结构化文档中查找语义匹配的内容，并附带上下文信息，有效缓解大模型因训练知识滞后和专业知识不足所导致的局限；其二，图谱检索依

托 Neo4j 图数据库，从结构化三元组中挖掘实体间的深层关联，用于增强知识的相关性与逻辑推理能力，典型如疾病诊断路径和药物相互作用分析；其三，网络搜索通过 Tavily 搜索 API 实时获取互联网公开信息，包括最新医学指南和行业动态，以弥补本地知识库在更新延迟和覆盖范围方面的不足，确保响应的时效性与全面性。

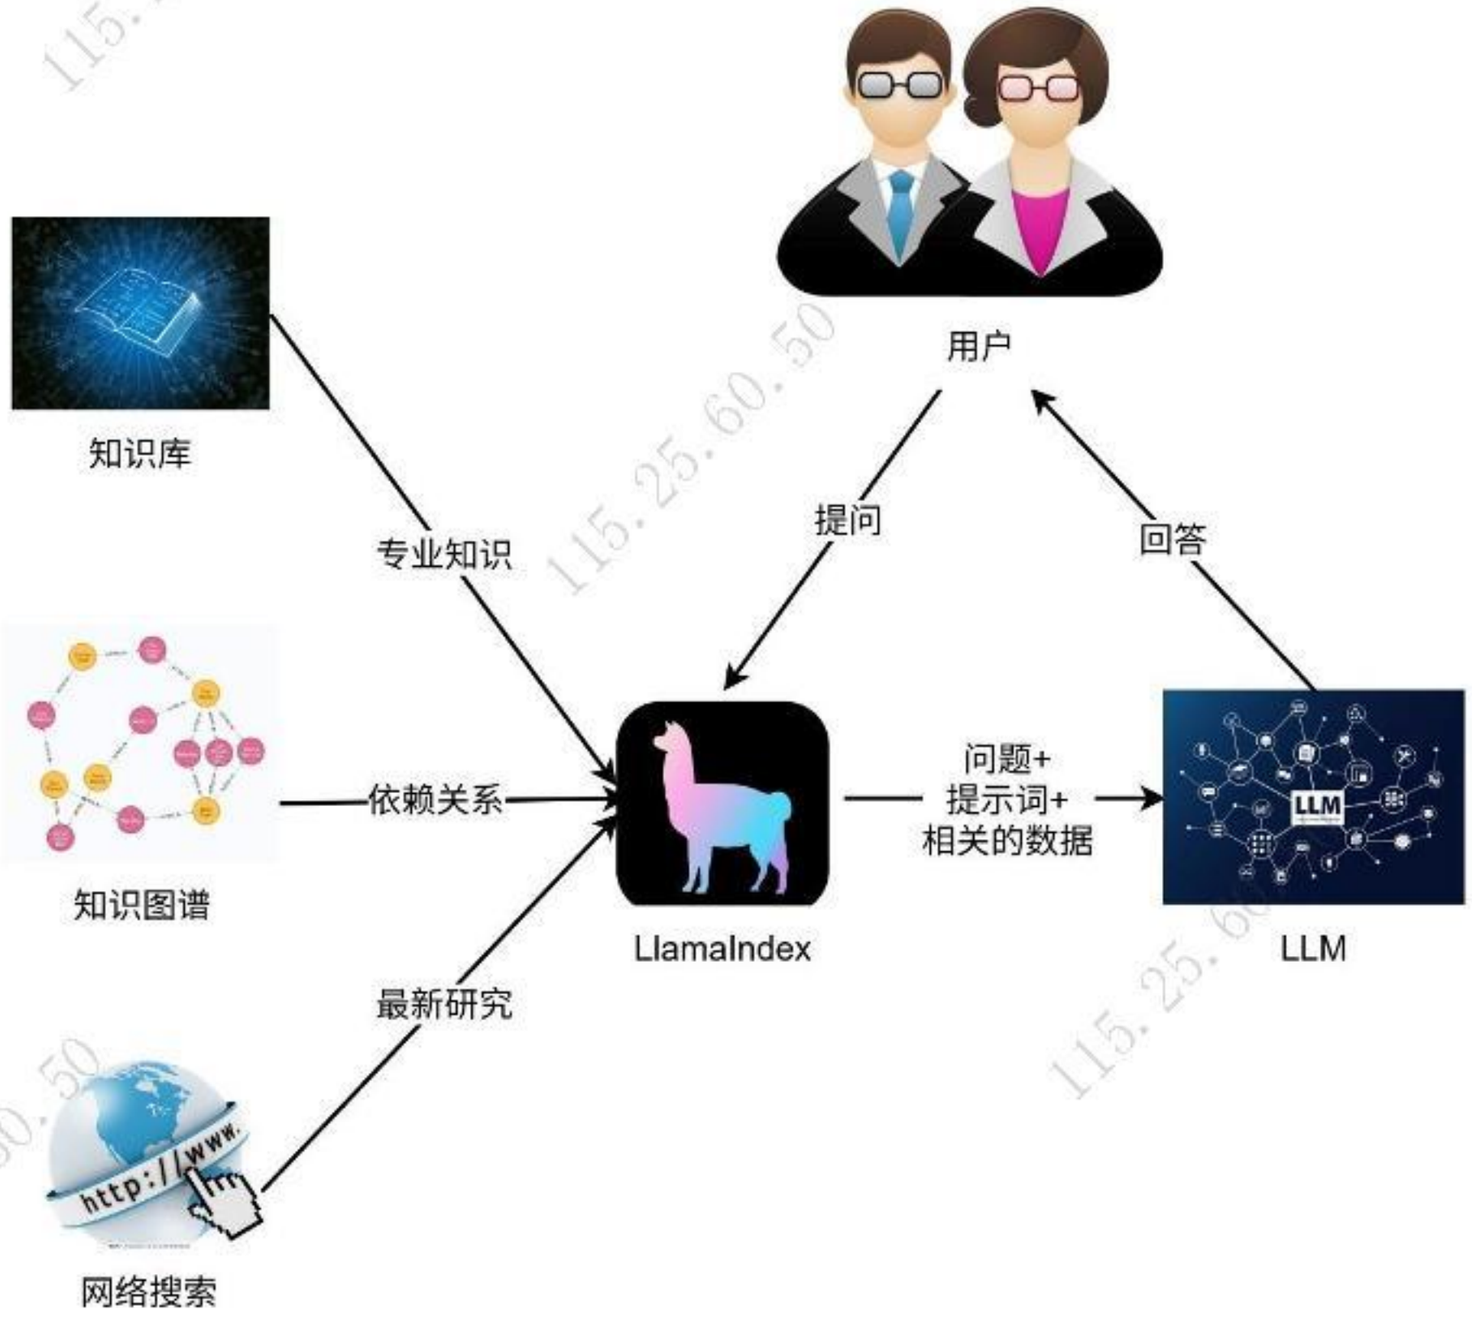


图 3-6 基于知识库和知识图谱的问答系统工作流程

Fig.3-6 Workflow of Question Answering System Based on Knowledge Base and Knowledge Graph

本文使用 DeepSeek-R1 作为 LLM 大模型，共接收三部分输入：（1）通过向量检索得到的文档语义片段+通过关系检索得到的实体关联图谱+通过网络搜索得到的实时网络信息；（2）用户提出的原始问题;（3）系统提示词工程。

模型首先理解提示词工程，了解主要的任务，其次理解用户提出的问题，最后会对多源信息做融合与校验：比如检查文档片段与图谱结论是否冲突，过滤网络信息的低质量内容。然后基于 LLM 的“语义理解+逻辑推理”能力，整合多源知识，用自然语言生成回答。

这套流程本质是“大模型+多源知识工程”的结合，用数据库解决“知识

存储与精准检索”，用大模型解决“自然语言理解与生成”，最终实现“专业、精准、实时”的问答系统。

3.4 本章小结

本章介绍了构建基于鼻咽的问答系统所必备的数据、工具及其流程。首先介绍了知识库的数据来源和构建过程；然后介绍了知识图谱的数据来源、数据标注和构建过程；最后介绍了大模型相关的知识和本文大模型选型的过程，同时系统的介绍了基于知识库、知识图谱、网络搜索和大模型构建问答系统的整体框架和流程，为后续系统开发奠定基础。

4 基于知识库和知识图谱的鼻咽癌问答系统

本文研究的基于知识图谱和知识库的鼻咽癌问答系统，旨在为用户提供更加专业的医疗指导，为医生提供专业的医疗辅助，既能提升患者的获取知识途径，帮助患者决策和康复，也能辅助医生快速诊断，提升医生工作效率。接下来将对系统搭建的整体过程进行详细的介绍。

4.1 需求分析

4.1.1 总体需求分析

鼻咽癌知识问答系统的核心目标是构建一个集成多源医学知识、具备智能交互能力的专业工具，为三类核心用户提供精准、便捷的信息服务：一是鼻咽癌患者及家属，需获取疾病认知、治疗方案解读、康复护理等实用知识；二是基层医务人员，需快速查询诊疗规范、鉴别诊断要点等临床参考信息；三是医学科研人员，需整合最新研究成果、统计数据等学术资源[53]。

从实际应用场景结合调查和相关数据分析来看，鼻咽癌患者需要的基于鼻咽癌的问答系统，主要看重其核心能力包括以下五点，这也是现阶段鼻咽患者获取知识的痛点。

1）信息获取的精准性与专业性需求：鼻咽癌属于头颈部恶性肿瘤，其病因、症状、治疗方案（如放疗、化疗、靶向治疗等）及康复护理具有较强专业性。患者通过通用搜索引擎（百度、谷歌等）获取的信息可能存在片面性、滞后性或错误（如混淆鼻咽癌与其他鼻咽疾病），而专业问答系统能整合权威医学资源（专业医学网站、学术期刊、权威书籍等），提供针对鼻咽癌的精准解答，能够避免误导。

2）缓解就医过程中的信息差：患者在诊断、治疗阶段常面临复杂医学术语（如“EB 病毒相关鼻咽癌”“调强放疗”）和治疗方案选择难题，与医生沟通时间有限。问答系统可作为补充工具，帮助患者提前了解关键信息，提升与医护人员沟通的效率，减少因信息不足导致的决策焦虑或选择错误[54]。

3）个性化需求的快速响应：不同患者的病情分期、身体状况、治疗阶段（如术后康复、复发监测）存在差异，需求各不相同（如“放疗后口干如何缓解”“晚期鼻咽癌的姑息治疗方案”）。网络搜索很难有针对性的给出个性化的分析和解答，而问答系统能根据患者具体情况提供针对性建议，填补大众化健康知识与个体需求之间的间隙。

4）心理支持与康复指导的补充：鼻咽癌治疗周期长，患者易出现心理压力、社交障碍及术后功能恢复（如吞咽、发声）问题。问答系统可纳入心理疏导技巧、康复训练方法、饮食营养建议等内容，帮助患者应对治疗副作用，提升生活质量，增强治疗信心。

5）时效性与便捷性需求：医学研究不断进展，鼻咽癌的治疗指南（如NCCN 指南）可能更新，患者需要及时获取最新信息。问答系统可通过定期更新内容，让患者随时便捷查询，无需依赖线下咨询或等待复诊，尤其对偏远地区就医不便的患者更具价值[55]。

因此，系统需实现“知识精准化、决策智能化、服务个性化、加强心理康复、信息时效性高”的总体要求：通过知识库与知识图谱整合权威医学资源，确保信息的专业性和一致性；借助知识图谱的逻辑链能力结合 LLM 推理能力，为用户提供更好的建议，实现决策智能化；针对不同用户需求提供差异化服务，如为患者生成通俗解读，为医生提供指南原文引用，为科研人员推送文献关联分析，为用户提供个性化服务。借助 LLM 的自然语言处理能力，和心理健康相关知识库，为用户提供良好的心理健康恢复平台，加速病情康复；通过网络搜索和知识库定期更新，为用户提供高时效性的回答信息，保证用户能够用最新的技术进行选择和治疗。

4.1.2 功能需求分析

通过上述需求调研和分析，得出鼻咽癌知识问答系统的主要功能包括：

1）知识查询功能旨在为用户提供全面的信息服务。该功能首先实现了对鼻咽癌全流程知识的多维度覆盖，包括病因（如 EB 病毒感染机制）、临床表现（如回吸性涕血与普通鼻炎鉴别）、诊断方法（如鼻咽镜活检的适应症）、治疗方案（如调强放疗的剂量分割模式）以及康复护理（如放射性皮炎的标准护理措施）等重要环节。系统还能够自动进行关联知识推荐，例如当用户询问“化疗药物顺铂的副作用”时，不仅提供直接答案，还会同步推送“副作用应对方法”和“替代药物选择”等实用信息。对于结构复杂或易混淆的知识内容，功能还支持以可视化形式进行直观展示，例如通过流程图展示“鼻咽癌 TNM 分期的判断步骤”，或借助对比表格展示“不同放疗技术的优缺点”，来辅助用户理解。。

2）智能交互功能旨在为用户提供高效、精准且人性化的问答体验。该功能首先通过自然语言理解技术，同时支持包含口语化描述的模糊查询（例如“脖子肿是不是得癌了”）和专业性较强的术语查询（如“T3N2M0 期的标

准治疗策略”），并能够准确识别同义词（如“NPC”与“鼻咽癌”）和标准简称（如“IMRT”对应“调强放射治疗”）。在此基础上，系统具备多轮对话能力，允许用户基于前序回答进一步追问，例如在回答“放疗周期多长”之后，可继续响应“中间中断治疗会怎样”的疑问，始终保持上下文的连贯性与语义一致性。此外，系统还能够根据用户类型调整回答风格，提供个性化反馈：面向患者群体时，使用通俗易懂的表述方式，避免直接使用“五年生存率”等可能引起误解的专业术语；而面向专业用户时，则提供详实的数据来源标注（如“参考 NCCN 指南[56]第 3 章”），以满足专业研判的需求。

3）知识更新功能旨在确保系统信息时效性与准确性。该功能首先通过网络搜索增强模块，对时效性要求较高的问题（例如“2024 年鼻咽癌新药获批情况”）自动调用网络搜索接口，实时获取最新公开信息，并与系统本地知识库内容进行交叉验证，以保障信息的真实性与完整性。对于新纳入系统的知识，如最新临床研究结果等专业内容，需经过耳鼻喉科专家的审核后方可生效，从而避免错误信息进入系统。此外，功能还支持管理员通过上传结构化文件（如 Excel 表格）实现数据的批量更新，例如高效添加诸如“某医院最新放疗设备参数”等本地化信息，显著提升知识库的维护效率与扩展灵活性。

4）系统基础功能主要包括登录注册与模型设置两大核心模块。登录注册功能允许用户创建个人账户并安全登录，实现用户数据的相互隔离，有效保障隐私与数据安全；同时，该功能可持续记录用户历史提问，支持基于对话上下文的更深层次交互与连续性思考。模型设置功能则使用户能够灵活配置 LLM 的 API，用户可选择自己常用的 LLM 服务，系统也提供默认 API 选项，确保用户无需配置即可直接使用基础模型服务。

4.1.3 非功能需求分析

除了上述功能性需求，还需要对系统的非功能性需求进行分析，功能性需求保证了系统的正常运行和功能符合用户需求，但是系统是否好用，是否能让用户使用的满意，主要是看非功能需求，本文经过分析，得出的非功能性需求包括：

1）回答准确性是系统核心能力的体现，具体包括以下三方面要求：首先，知识准确率必须达到高标准，所有核心诊疗知识需与权威来源（如 NCCN 指南、国家卫健委诊疗规范）保持 100%一致；对目前存在学术争议的内容（如某治疗方案的适用人群范围），系统需明确标注不同观点并附上相应的支持证据。其次，须确保 LLM 生成回答时的推理可靠性，要求其严格基于结构化

知识库进行内容生成，杜绝虚构信息（例如不存在的药物用法或剂量），并对推理实现过程可追溯，例如在回答中标注“该结论综合自文献 A 与临床研究 B”。最后，系统应保持术语使用的一致性，例如统一使用“放射治疗”而非混用“放疗”，对专业表述如“颈部淋巴结转移”需严格遵循分期标准并明确其对应的解剖区域定义，以避免歧义。

2）良好的系统可用性主要体现在快速响应和广泛兼容两个方面。对于用户提出的问题，系统能够迅速反馈答案：像“鼻咽癌早期症状”这类简单问题，一秒内即可返回结果；针对“晚期患者综合治疗方案”等复杂询问，响应时间控制在三秒以内；而对于需要联网获取最新信息的增强搜索，响应时间也严格保持在五秒以内。在兼容性方面，系统同时支持电脑和手机访问，可在 Chrome、Edge、微信等主流浏览器上顺畅使用。特别针对手机用户，系统优化了触控体验，所有重要按钮尺寸都经过专门设计，确保点击区域不小于 8 毫米见方，让操作更加准确便捷。

3）数据安全是系统设计中优先保障的环节，涵盖用户隐私、权限管理与内容防护三个关键方面。在数据隐私上，所有用户查询记录均经过匿名化处理，系统不收集也不存储任何可识别个人身份的信息（例如真实姓名、病历号码等），严格遵循《医疗数据安全指南》的相关规范。在权限控制方面，管理员必须通过双因素认证方可登录系统后台，所有对知识内容的审核与删除操作均全程记录，确保每项变更都可追溯至具体责任人。在内容安全层面，系统具备识别和过滤有害信息的能力，能够拦截诸如“如何自制化疗药物”等危险提问，并对检测到含有自杀倾向或极端情绪的表达（如“治疗太痛苦，不想活了”），自动触发心理援助机制，向用户推送安慰性语言。

4）系统的可扩展性体现在功能、知识与性能三个层面。在功能扩展方面，系统预留标准化接口以支持未来新增模块，例如实现医患精准匹配的问答系统或基于病例数据的预后分析工具。知识扩容方面，系统支持灵活新增内容类型，如引入“鼻咽癌遗传咨询”等专题时无需重构底层架构。性能扩展方面，采用分布式部署设计，当用户规模增长至万级时，可通过横向增加服务器节点快速提升系统处理能力。

4.2 架构设计

4.2.1 整体架构设计

本系统采用分层式架构设计，通过“前端交互层-后端服务层-数据存储层”的三级架构实现功能解耦，各层通过标准化接口通信，保障系统的可扩展性和维护性。

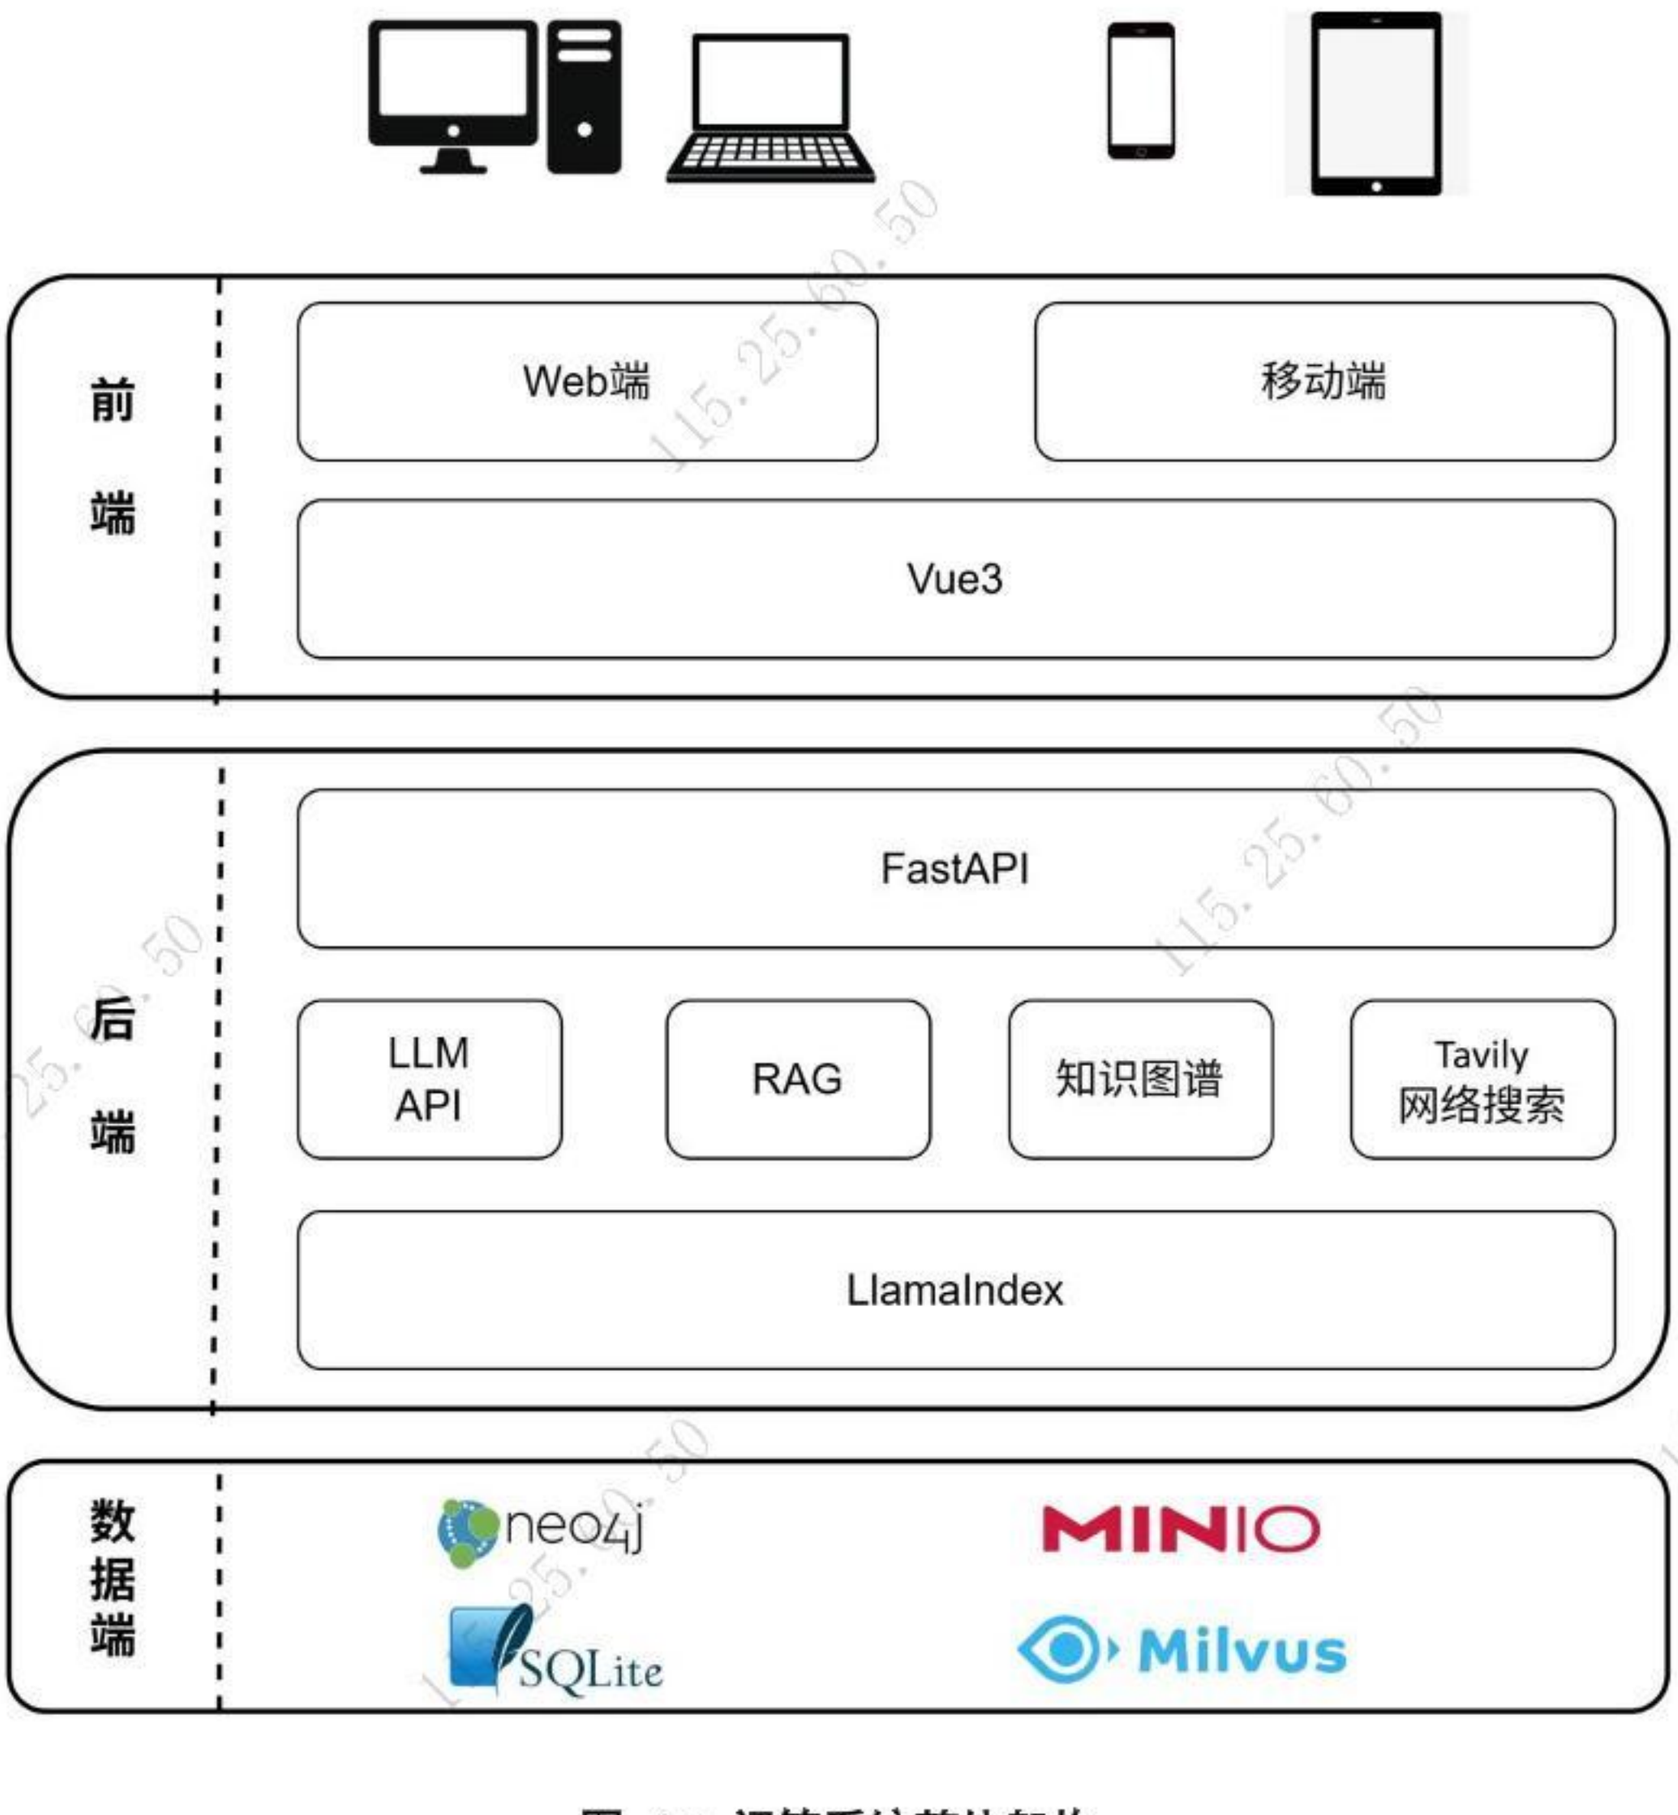


图 4-1 问答系统整体架构

Fig.4-1 Overall architecture of Q&A system

前端交互层基于 Vue3 框架构建，负责用户界面展示和交互逻辑处理，通过 HTTP/HTTPS 协议与后端服务层通信。为适配不同终端用户（如 PC 端医生工作站、移动端患者查询），采用响应式设计原则，通过媒体查询动态调整组件布局，确保在 1024×768 及以上分辨率的设备上均能正常显示。该层与

后端的交互严格遵循 RESTful 规范，所有请求携带 JSON 格式参数，响应数据包含状态码（如 200 表示成功、400 表示参数错误、500 表示服务器错误）、消息提示和业务数据三部分，便于前端统一处理。

后端服务层是系统的核心处理中枢，基于 FastAPI 构建异步服务，采用模块化设计实现业务逻辑的封装。该层向上对接前端交互层的请求，向下调用数据存储层的资源，中间通过 Llama-Index 实现多源知识的整合与调度。为提升并发处理能力，采用 Uvicorn 作为 ASGI 服务器，配置 4 个工作进程（worker=4），支持每秒 500+次的查询请求。服务层内部通过事件驱动机制实现模块间通信，例如当知识检索模块完成任务后，触发事件通知 LLM 融合模块进行下一步处理，避免同步调用导致的性能瓶颈。

数据存储层采用多组件协同的存储方案，根据数据类型选择适配的存储介质：结构化的用户配置和操作日志采用 SQLite 数据库（由于实际表和结构化数据并不多，因此采用轻量化数据库即可满足要求），利用其轻量级特性实现本地文件存储，无需额外服务端；非结构化的文档资源（如 PDF 格式的诊疗指南）通过 MinIO 对象存储管理，支持断点续传和版本控制，单文件最大支持 500MB；知识图谱的实体与关系数据存储于 Neo4j 图数据库，通过节点-边模型高效表达“疾病-症状-治疗”的关联关系，单节点属性支持动态扩展（如为“放疗”节点新增“最新研究”字段）；文本向量数据则由 Milvus 向量库管理，采用 1024 维向量空间存储，通过 IVF_FLAT 索引实现毫秒级相似度检索。各存储组件通过 Docker 容器化部署，通过内部虚拟网络实现数据互通，对外仅暴露必要的访问端口（如 Neo4j 的 7474 端口、Milvus 的 19530 端口）。

此外，系统设计了跨层的安全机制：前端与后端之间通过 HTTPS 加密传输，防止数据在传输过程中被篡改；后端服务层采用 JWT 令牌进行身份验证，不同用户角色（普通用户/超级管理员）分配不同的访问操作权限。

4.2.2 模块设计

本文的问答系统是基于前后端分离架构进行搭建的，因此需要分别对前端模块和后端模块分开设计，下面对前后端的模块设计进行详细的介绍。

1）前端模块

用户交互模块：包含功能菜单、对话列表和输入面板三个核心组件。功能菜单是在不同功能之间切换的选项，本文设计的鼻咽癌知识问答系统主要包括：对话、智能体、知识图谱、知识库、用户、设置等菜单；对话列表时

用户和系统的交互界面，采用时间线布局，左侧显示系统回复和参考信息（带“知识库”“网络搜索”等来源标签），右侧显示用户提问；输入面板除基础文本输入外，还提供选择知识来源的按钮，知识来源包括：知识库、网络搜索、知识图谱。

知识展示模块：根据后端返回的知识类型自动选择展示方式。文本类知识使用富文本组件渲染；支持列排序和筛选；知识图谱关系通过 ECharts 绘制交互式力导向图，通过检索按钮可以对其中的实体进行检索和筛选。

系统配置模块：实现用户个性化设置，包括 LLM 和嵌入莫模型的 API 切换、默认回答长度（短/中/长）、知识库和知识图谱的开关等。设置项通过 Pinia 状态管理库存储于 localStorage，用户下次登录时自动加载，其中角色信息会同步至后端，作为知识检索的过滤条件。

2）后端模块

请求处理模块：作为后端服务的入口，负责请求参数的校验与预处理。通过 Pydantic 模型定义请求格式，例如 QueryRequest 模型包含 question（str 类型，最小长度 2）、user_type（枚举类型，值为 patient/doctor/researcher）、history（列表类型，存储前序对话）三个字段，不符合格式的请求直接返回 400 错误。对于有效请求，调用会话管理工具生成唯一会话 ID（UUID 格式），并将上下文信息存储于内存缓存（默认保留 30 分钟），确保多轮对话的连贯性（如用户问“副作用多久消失”时，系统能关联上一轮提到的“放疗”）。

知识检索模块：通过 Llama-Index 协调多源知识的检索任务，采用并行计算提升效率。首先从 SQLite 读取用户历史偏好（如医生用户近 3 次查询均涉及“分期诊断”），生成个性化检索条件；然后同时触发三个子任务：

知识库检索：调用 Llama-Index 的 SQLiteReader，通过 IVF_FLAT 索引匹配结构化数据中的关键词，返回相关度 TOP10 的诊疗条目；

知识图谱检索：执行 Cypher 查询语句获取实体关联（如 MATCH （d: 疾病）-[r: 采用治疗]->（t） WHERE d.name='鼻咽癌' RETURN t.name, r.evidence）；

网络搜索：当本地知识匹配度低于阈值（默认 60%）时，调用 Tavily 的 API 接口获取实时信息（如“2024 鼻咽癌靶向药进展”），结果经清洗后（去除 HTML 标签和广告内容）转换为纯文本。

结果排序模块：接收知识检索模块返回的多源结果，通过 Llama-Index 的 Rerank 组件进行二次排序。排序算法综合考虑三个维度：相关性（权重 60%，基于 BAAI/bge-reranker-large 模型的评分）、时效性（近 3 年文献加 20%权重）、权威性（指南/教科书加 30%权重），最终返回 TOP5 的知识片段。对

于存在冲突的信息（如 A 文献称某药物有效率 70%，B 文献称 65%），自动标注差异点并提示“存在研究争议”。

LLM 融合模块：以 DeepSeek-R1 为基础模型，结合用户角色生成差异化回答。通过 LangChain 构建动态提示词，例如对患者用户的提示词为用小学文化能理解的语言解释，避免“5 年生存率”等术语；对医生用户则提示“引用最新指南（2024 版），列出具体化疗方案的剂量和周期”。模型输出后，调用术语转换工具进行适配处理（如将“客观缓解率”转换为“肿瘤缩小的患者比例”），最后通过 StreamingResponse 实现逐句输出，首句响应时间控制在 1 秒内。

数据存储模块：负责各存储组件的协同管理，提供统一的数据访问接口。知识图谱数据通过 Neo4j 工具批量导入，向量数据通过 Milvus SDK 批量插入，每批处理 1000 条文本片段，编码后向量维度为 1024；用户上传的文档通过 MinIO 实现安全上传，元数据（如文件名、上传时间）存入 SQLite 的 documents 表，支持按上传日期和文件类型查询。

4.3 系统实现

上一章节主要介绍了系统的主要架构和相关模块，接下来，会对这些模块进行详细的展开，介绍开发过程中详细的系统实现。

4.3.1 开发环境

本系统的开发环境围绕兼容性和性能需求搭建，硬件配置如下表所示。使用多核 CPU 加大内存，满足知识库、知识图谱存储及多用户并发请求的计算需求；存储采用 1TB NVMe 固态硬盘作为系统盘，2TB 7200 转机械硬盘保障 Milvus 向量库和 MinIO 对象存储的高速读写。

软件环境方面，操作系统选用 Ubuntu 22.04 LTS，依托其稳定的服务端支持和对开源工具的良好兼容性。前端开发基于 Node.js 24.4.0 环境，使用 npm 11.4.2 构建工具；后端采用 Python 3.10.12 作为编程语言，依赖包管理工具使用 uv 0.7.2，核心依赖包括 FastAPI 0.116.0（后端框架）、langchain 0.3.26（大模型融合）、Llama-Index 0.12.42（知识库）、PyMilvus 2.5.12（向量数据库）、neo4j 5.28.1（图数据库）等。

表 4-1 开发环境硬件配置表

Tab.4-1 Hardware Configuration Table for Development Environment

硬件名称	配置
CPU	Intel Core i7-12700H 处理器（20 核 32 线程）
内存	40GB DDR5
显卡	NVIDIA RTX 3060 显卡（6GB 显存）
硬盘	1TB NVMe + 2TB 7200 转 HDD
网卡	1000M 有线网卡

数据库及中间件方面，部署 Neo4j 5.26（知识图谱存储），配置 4GB 堆内存以优化节点关系查询；Milvus 2.5.6 作为向量数据库，采用单机部署模式，设置 IVF_FLAT 索引（nlist=1024）提升相似度检索效率；MinIO RELEASE.2023-03-20T20-16-18Z 用于文档存储，通过 Docker 容器化部署确保跨平台一致性；SQLite 3.42.0 用于存储用户配置和系统日志，无需额外服务端降低部署复杂度。

开发过程中采用 Apifox 2.7.27 测试 API 接口，通过 PyCharm 2025.1 进行开发调试，便于追踪系统运行状态和排查问题。

4.3.2 前端实现

前端基于 Vue 3 框架开发，采用组件化设计思想，核心依赖包括 Vue Router 4.5.1（路由管理）、Pinia3.0.2（状态管理）、Axios 1.9.0（HTTP 请求）、ECharts 5.6.0（知识图谱绘制）和 Element Plus 2.3.14（UI 组件库），确保界面风格统一且交互流畅。前端主要布局页面代码如下所示。

```
<template>
<div class="chat-container">
  <div class="conversations" :class="{ 'is-open': state.isSidebarOpen }">
    <div class="actions">
      <!-- <div class="action new" @click="addNewConv"><FormOutlined /></div>
-->
        <span class="header-title">鼻咽癌知识问答系统</span>
        <div class="action close" @click="state.isSidebarOpen = false">
          <PanelLeftClose size="20" color="var(--gray-800)"/>
```

```
    </div>
  </div>
  <div class="conversation-list">
    <div class="conversation"
      v-for="(state, index) in convs"
      :key="index"
      :class="{ active: curConvId === index }"
      @click="goToConversation(index)">
      <div class="conversation__title">{{ state.title }}</div>
      <div                                    class="conversation__delete"
@click.stop="delConv(index)"><DeleteOutlined /></div>
    </div>
  </div>
  <ChatComponent
    :conv="convs[curConvId]"
    :state="state"
    @rename-title="renameTitle"
    @newconv="addNewConv"/>
</div>
</template>

<script setup>
import { reactive, ref, watch, onMounted } from 'vue'
import { DeleteOutlined } from '@ant-design/icons-vue'
import ChatComponent from '@/components/ChatComponent.vue'
import { MessageSquareMore, PanelLeftClose } from 'lucide-vue-next'

const convs = reactive(JSON.parse(localStorage.getItem('chat-convs')) || [
  {
    id: 0,
    title: '新对话',
    history: [],
    messages: [],
    inputText: ''
  },
])

const state = reactive({
  isSidebarOpen: JSON.parse(localStorage.getItem('chat-sidebar-open') || 'true'),
```

```
})

// Watch isSidebarOpen and save to localStorage
watch(
  () => state.isSidebarOpen,
  (newValue) => {
    localStorage.setItem('chat-sidebar-open', JSON.stringify(newValue))
  }
)
const curConvId = ref(0)

const generateRandomHash = (length) => {
    let chars =
  'abcdefghijklmnopqrstuvwxyzABCDEFGHIJKLMNOPQRSTUVWXYZ0123456789';
    let hash = '';
    for (let i = 0; i < length; i++) {
        hash += chars.charAt(Math.floor(Math.random() * chars.length));
    }
    return hash;
}
</script>
```

页面结构分为三大模块：功能菜单、对话列表和输入面板。功能菜单时在不同功能之间切换的选项，本文设计的鼻咽癌知识问答系统主要包括：对话、智能体、知识图谱、知识库、用户、设置等菜单；对话列表时用户和系统的交互界面，采用时间线布局，左侧显示系统回复和参考信息（带“知识库”“网络搜索”等来源标签），右侧显示用户提问；输入面板除基础文本输入外，还提供选择知识来源的按钮，知识来源包括：知识库、网络搜索、知识图谱。

知识展示区针对不同内容类型采用差异化呈现：文本知识使用富文本编辑器渲染，支持排序和筛选；知识图谱关联关系通过 ECharts 绘制力导向图，节点颜色区分实体类型，节点间关系标注在节点和节点之间边的箭头之上。

系统设置区实现不同模型之间的切换、知识库和知识图谱的开启和关闭功能，通过 Pinia 存储用户偏好设置，刷新页面后保持状态一致。针对移动端适配，采用媒体查询（@media）动态调整组件尺寸，输入框高度在小屏设备上增加 20%，按钮间距扩大至 12px，确保触控操作便捷性。

前端与后端的通信通过 Axios 封装的 API 接口实现，采用 RESTful 风格设计，主要接口包括 /user/query（提交问题）、/knowledge/related（获取关联

知识）、/system/log（上传操作日志）等，请求头中携带 JWT 令牌防止跨站攻击，响应超时设置为 10 秒，超时后显示重试按钮。

4.3.3 后端实现

后端采用 FastAPI 构建异步服务，通过模块化设计实现功能解耦，核心模块包括请求处理、知识检索、LLM 融合和数据存储。

请求处理模块负责接收前端请求，首先进行参数校验（使用 Pydantic 模型 QueryRequest，包含 question、user_type、history 等字段），过滤无效请求（如长度＜2 的空问题），然后调用会话管理工具记录对话上下文（默认保留最近 10 轮），确保多轮对话的连贯性。其主要后端代码详见附录 A。

知识检索模块是系统的核心，通过 Llama-Index 实现多源知识整合：首先调用 SQLite 查询用户历史交互数据（如医生用户偏好指南类内容），作为检索过滤条件；然后并行触发三个检索任务：

知识库检索：通过 Llama-Index 的 SQLiteReader 读取结构化诊疗数据，使用 IVF_FLAT 索引匹配关键词（如“放疗剂量”）；

知识图谱检索：调用 Neo4j 驱动执行 Cypher 查询（如 MATCH （d: 疾病）-[r: 有症状]->（s） WHERE d.name=‘鼻咽癌’RETURN s.name），获取实体关联关系；

网络搜索：当本地知识匹配度＜60%时，调用 Tavily 的 API 接口获取最新信息（如 2024 年新药获批情况），结果经清洗后（去除广告和重复内容）存入 MinIO。

检索结果由 Llama-Index 的 Rerank 模块（基于 BAAI/bge-reranker-large 模型）进行排序，综合考虑相关性（权重 60%）、时效性（近 3 年文献权重+20%）和权威性（指南/教科书权重+30%），最终返回 Top5 条知识片段。

LLM 融合模块采用 DeepSeek-R1 作为基础模型，通过 LangChain 封装的 PromptTemplate 构建提示词（包含问题、检索结果和用户类型），结合知识库、知识图谱和网络搜索结果一起提交给 LLM。模型输出后，调用自定义的医学术语检查工具，将表达术语标准化后通过 FastAPI 的 StreamingResponse 实现流式输出，提升用户体验。

数据存储模块实现各组件的协同：知识图谱数据通过 Neo4j 的批量导入工具（neo4j-admin import）初始化；向量数据由 Milvus 的 Python SDK 导入，每批处理 1000 条文本片段（经 BGE-m3 编码为 1024 维向量）；用户上传的

参考文档（如文献 pdf）通过 MinIO 的 Presigned URL 实现安全储存，元数据存储于 SQLite 的 documents 表。

系统部署采用 Docker Compose 编排，定义 6 个服务（前端、后端 API、Neo4j、Milvus、MinIO、Etcd），通过内部网络实现组件通信，对外暴露 80 端口（前端）和 8000 端口（API），支持 HTTPS 加密（配置 Nginx 反向代理）和水平扩展（通过增加后端 API 服务实例应对高并发）。

4.3.4 系统展示

注册登录模块采用简单的账户注册登录，采用简易化设计，背景采用绿色树叶作为衬托，给鼻咽癌患者一种清新的感觉，登录界面设计如图 4-2 所示。用户输入用户名密码，即可登录。



图 4-2 登录界面

Fig.4-2 Login interface

对话模块界面如图 4-3 所示，通过用户输入相关问题，选择是否启用知识库和知识图谱进行联合搜索，进入对话页面后，用户可以在下方输入区输入相关的问题，同时上方回答区也预置了几个常用的问题，帮助用户一键获取相关回答。

用户可以根据自己的需求，选择启用知识图谱、知识库、网络搜索相关功能。启用相关功能后，在回答中，会将涉及的知识进行可视化展示，为回答提供权威的知识来源。



图 4-3 对话界面

Fig.4-3 conversational interfaces

智能体界面如图 4-4 所示，为用户提供了个性化服务。用户可以通过提示词和选择相应的工具，为自己量身打造一个属于自己的私有化鼻咽癌知识助手。比如：若用户希望系统回答问题时增加一些感情色彩，只需在智能体提示词区域输入相应的指令：

你是一个专注于鼻咽癌相关问题的问答助手，你的核心使命是用温柔、耐心且专业的态度为用户提供帮助。无论用户提出的是关于病因、症状、治疗方案、康复护理还是心理疏导等方面的问题，你都需要做到：

语言温和亲切，避免使用生硬的医学术语堆砌，必要时用通俗比喻解释专业概念，让用户感受到被理解和关怀。

回答内容详尽全面，针对用户的问题从多个角度展开说明，比如解释某种治疗方式时，既说明原理、优势，也客观提及可能的副作用及应对方法，让用户获得充分信息。

面对用户的焦虑或担忧，先给予情感上的安抚，再提供专业解答，例如：“我能理解你现在的担心，这种情况确实会让人有些不安，但请放心，目前医学上对于这类问题已经有了成熟的应对方案……”

若遇到不确定的问题，坦诚告知用户，并建议咨询专业医师，同时可以提供一些获取权威医疗资源的方向，避免给出不准确信息。



图 4-4 智能体界面展示

Fig.4-4 Intelligent agent interface display

本系统通过优化自然语言生成策略，输出内容在保证科学准确性的基础上，倾向于使用支持性、鼓励性的措辞，旨在降低用户的心理负担，并改善其信息获取体验。



图 4-5 智能体回答结果展示

Fig.4-5 Intelligent agent response result display



图 4-6 知识图谱展示

Fig.4-6 Knowledge Graph Display

还是以问题：鼻炎会发展为鼻癌吗？为例。从图 4-5 结果显示，通过上述提示词构建的系统，回答问题就会根据提示词的要求回答的预期更加温柔，问题细节更加细致，也没有令人难懂的晦涩语言。能够使用户体验到个性化服务。

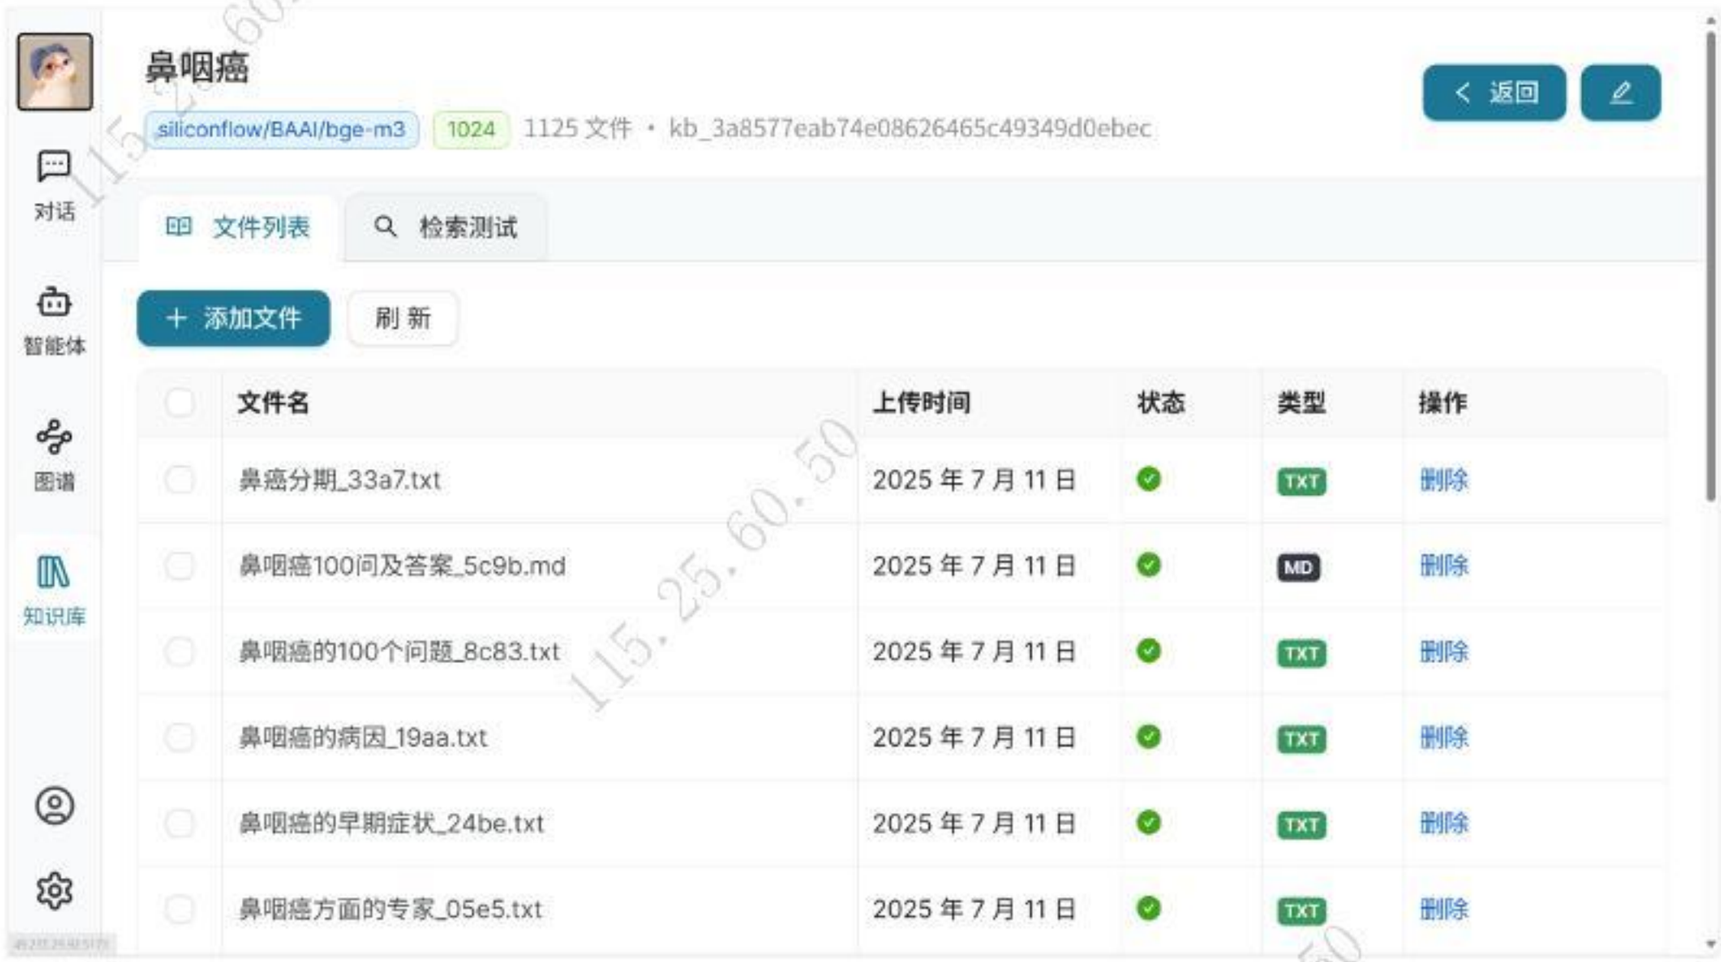


图 4-7 知识库展示

Fig.4-7 Knowledge Base Display

知识图谱展示如图 4-6 所示，展示了知识图谱中现有的各个实体之间的关系，以供用户查询和查看。

知识库展示如图 4-7 所示，展示了构建知识库的相关文件和索引，以供用户查询和查看。



图 4-8 设置界面展示

Fig.4-8 Set interface display

设置模块如图 4-8 所示，用户可以通过自己的习惯，选择相应的模型以及 API，甚至可以关闭知识库知识图谱等相关功能，为用户提供更多选择。

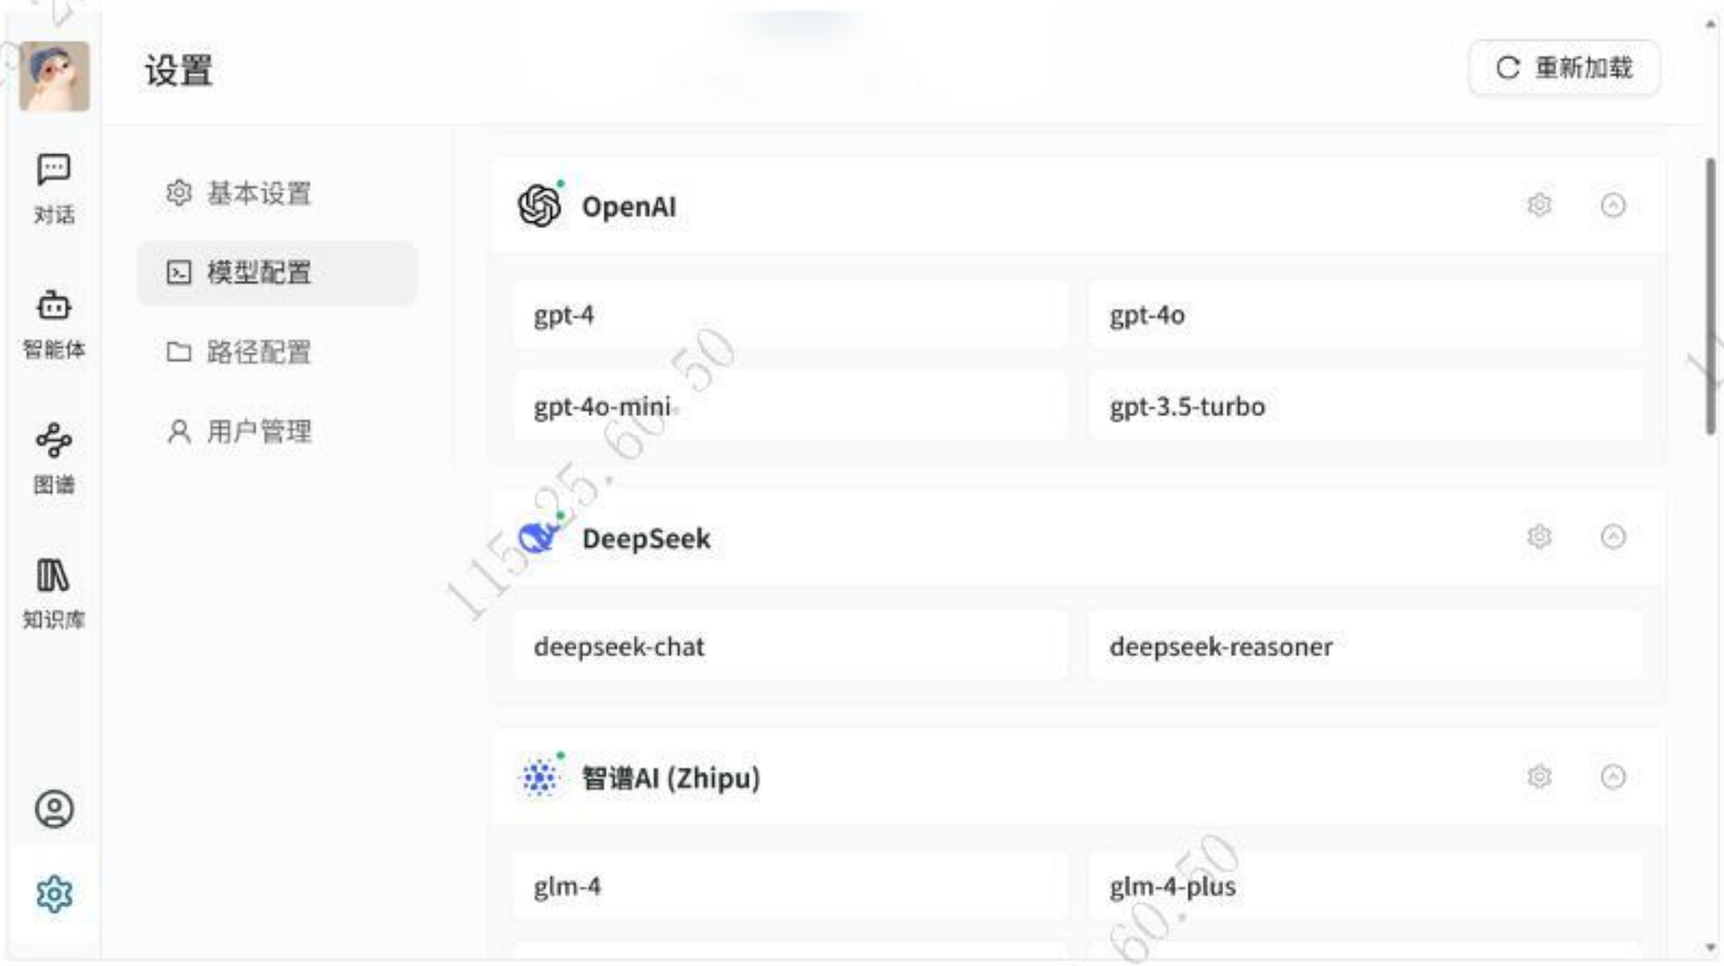


图 4-9 模型配置界面展示

Fig.4-9 Model configuration interface display

本文的问答系统以内置了各大厂商的 LLM 模型以供用户选择，如图 4-9 所示，并且用户也能自己通过配置，配置清单中没有的模型。

同时，超级管理员可以对用户进行管理，修改、删除用户相关信息。其相关操作界面如图 4-10 所示。



图 4-10 用户管理界面展示

Fig.4-10 User management interface display

同样 Web 端的功能，在移动端也都给予实现，只是在页面布局上发生了变化，由于移动端屏幕比较小，因此需要将比较重要的界面或按钮进行放大，保证操作正常，以下图 4-11 是移动端的相关页面展示。



图 4-11 移动端界面展示

Fig.4-11 Mobile interface display

4.4 系统测试

4.4.1 测试环境

本系统的测试环境与开发环境保持硬件一致性，以确保测试结果的可靠性。客户端测试覆盖 PC 端和移动端，PC 端包括搭载 Windows 11（Chrome 118.0、Edge 117.0 浏览器）和 macOS Ventura（Safari 16.1 浏览器）的设备，移动端选用 iPhone 15（iOS 18.5）和小米 15（HyperOS 2.0），分别模拟不同操作系统和屏幕尺寸下的使用场景。

软件环境方面，后端服务通过 Docker Compose 部署，包含前端应用、FastAPI 服务、Neo4j、Milvus、MinIO 等组件，各服务间通过虚拟网络通信，端口映射与生产环境保持一致（前端 80 端口、API 服务 8000 端口）。测试工具采用 Apifox 2.7.27 进行 API 接口自动化测试，JMeter 5.6 模拟并发请求，Selenium 4.14.0 实现前端页面交互测试。

页面测试：主要考虑页面布局和点击相应等相关可视化，各种浏览器兼容问题，着重测试 Web 端和移动端有差异的地方。功能测试分为三类：一是结构化的鼻咽癌知识数据（含 100 条标准问答对），用于验证知识检索准确性；二是模拟用户交互数据（50 条患者提问、50 条医生提问），涵盖常见问题（如“鼻咽癌早期症状”）和复杂问题（如 “IV 期鼻咽癌的综合治疗方案”）；三是压力测试数据，通过 JMeter 生成 1000 条/秒的并发请求，测试系统响应稳定性。

4.4.2 页面测试

页面测试聚焦前端交互的完整性和兼容性，采用人工测试与自动化脚本结合的方式进行。

布局适配测试中，在 PC 端（1440×2560 分辨率）验证页面组件排列，确认搜索框、对话列表和知识展示区的比例分配合理（分别占顶部 15%、中部 60%、底部 25%），且无元素重叠现象。通过浏览器开发者工具模拟不同分辨率（2160×3840、1080×1920、768×1024、768×1366 等），检查响应式布局是否生效，如 1024×768 分辨率下输入框高度自动增加至 60px，确保触控区域充足。移动端测试中，重点验证竖屏状态下对话气泡是否完整显示，知识图谱力导向图是否自动缩小以适配屏幕宽度（iPhone 15 上节点直径压缩至 12px）。

功能按钮测试覆盖所有可交互元素：移动端的输入框在点击后应弹出键盘；“上传报告”按钮在选择超过 500MB 的文件时，需弹出“文件过大”提示并禁止上传。通过 Selenium 脚本模拟 100 次连续点击操作，未发现按钮无响应或重复提交问题。

兼容性测试中，在 Chrome、Edge、Safari 浏览器上验证核心功能：富文本展示是否正常，知识图谱图表是否能正确渲染。测试发现 Safari 浏览器中 ECharts 图表初始化较慢（约 2 秒），通过优化图表数据加载方式（延迟 100ms 加载非核心节点），将渲染时间缩短至 1 秒内，确保各浏览器体验一致。

4.4.3 功能测试

功能测试围绕系统核心模块展开，通过设计测试用例验证功能实现的准确性和稳定性。

知识检索功能测试中，选取 100 条标准问题验证多源知识整合效果。对于“鼻咽癌的治疗方法”，系统应从知识库返回 3 条指南推荐方案、从知识图谱返回“放疗-适用分期”关系、从网络搜索补充 2024 年靶向药进展，经 Llama-Index 排序后，TOP3 结果需包含指南内容（权重最高）。测试结果显示，92%的问题能准确召回相关知识，其中医生用户关注的“化疗剂量调整”类问题召回率达 96%，患者用户的“副作用缓解”类问题召回率 88%，主要因部分网络信息清洗不彻底导致排序偏差，经优化过滤规则后提升至 93%。



图 4-12 知识图谱检索结果展示

Fig.4-12 Display of Knowledge Graph Retrieval Results

通过“检索实体”按钮，可以检索出需要查询的实体，比如通过实体：鼻塞，检索出的知识图谱关系如下图 4-12 所示。

通过“检索”按钮，可以检索出需要查询的知识文献，比如通过语句：鼻炎会发展成鼻癌吗，检索出的相关知识文献如下图 4-13 所示。



图 4-13 知识库检索结果展示

Fig.4-13 Display of Knowledge Base Retrieval Results

LLM 融合功能测试重点验证差异化回答效果，对同一问题“鼻咽癌 5 年生存率”，智能体自定义角色应返回“约 60%的患者能存活 5 年以上”（通俗表述），默认角色应返回“I期约 90%、IV期约 30%，数据来源 2024 版 NCCN 指南”（含具体分期和来源）。通过 50 组对比测试，模型均能正确区分用户角色并调整回答风格，术语转换准确率达 95%（仅 2 处出现“客观缓解率”未转换为通俗表述）。多轮对话测试中，用户连续提问“放疗多少次？”“每次多长时间？”，系统能关联上下文，正确理解“放疗”指前序对话中的“调强放射治疗”，回答连贯性评分达 92 分（满分 100 分）；针对测试选择的问题，通过人工进行评判（与标准答案差距在 5%以内即为正确），最终系统整体回答准确率达到 94%。



图 4-14 网络搜索结果展示

Fig.4-14 Display of online search results



图 4-15 知识库检索结果展示

Fig.4-15 Display of Knowledge Base Search Results

以问题：鼻炎会发展为鼻癌吗？为例。网络搜索结果如图 4-14 所示，知识库搜索结果如图 4-15 所示。整体相关性很高，证明知识库、知识图谱、网络搜索能够起到辅助作用。

API 接口测试针对 12 个核心接口（如/user/query、/knowledge/related），采用 Apifox 批量发送请求并验证响应。例如调用/user/query 接口时，传入参数{"question": "鼻咽癌放疗后口干怎么办"}，预期返回包含状态码 200、回答

文本（如“可通过多喝水、使用人工唾液缓解”）及 3 条关联知识（如“放疗副作用护理指南”）的 JSON 数据，最终结果如图 4-16 所示。测试 500 次接口调用，成功率达 100%，平均响应时间 0.8 秒，其中涉及网络搜索的请求（如“2024 年鼻咽癌新药”）响应时间较长（约 3 秒），但均在 10 秒超时阈值内。

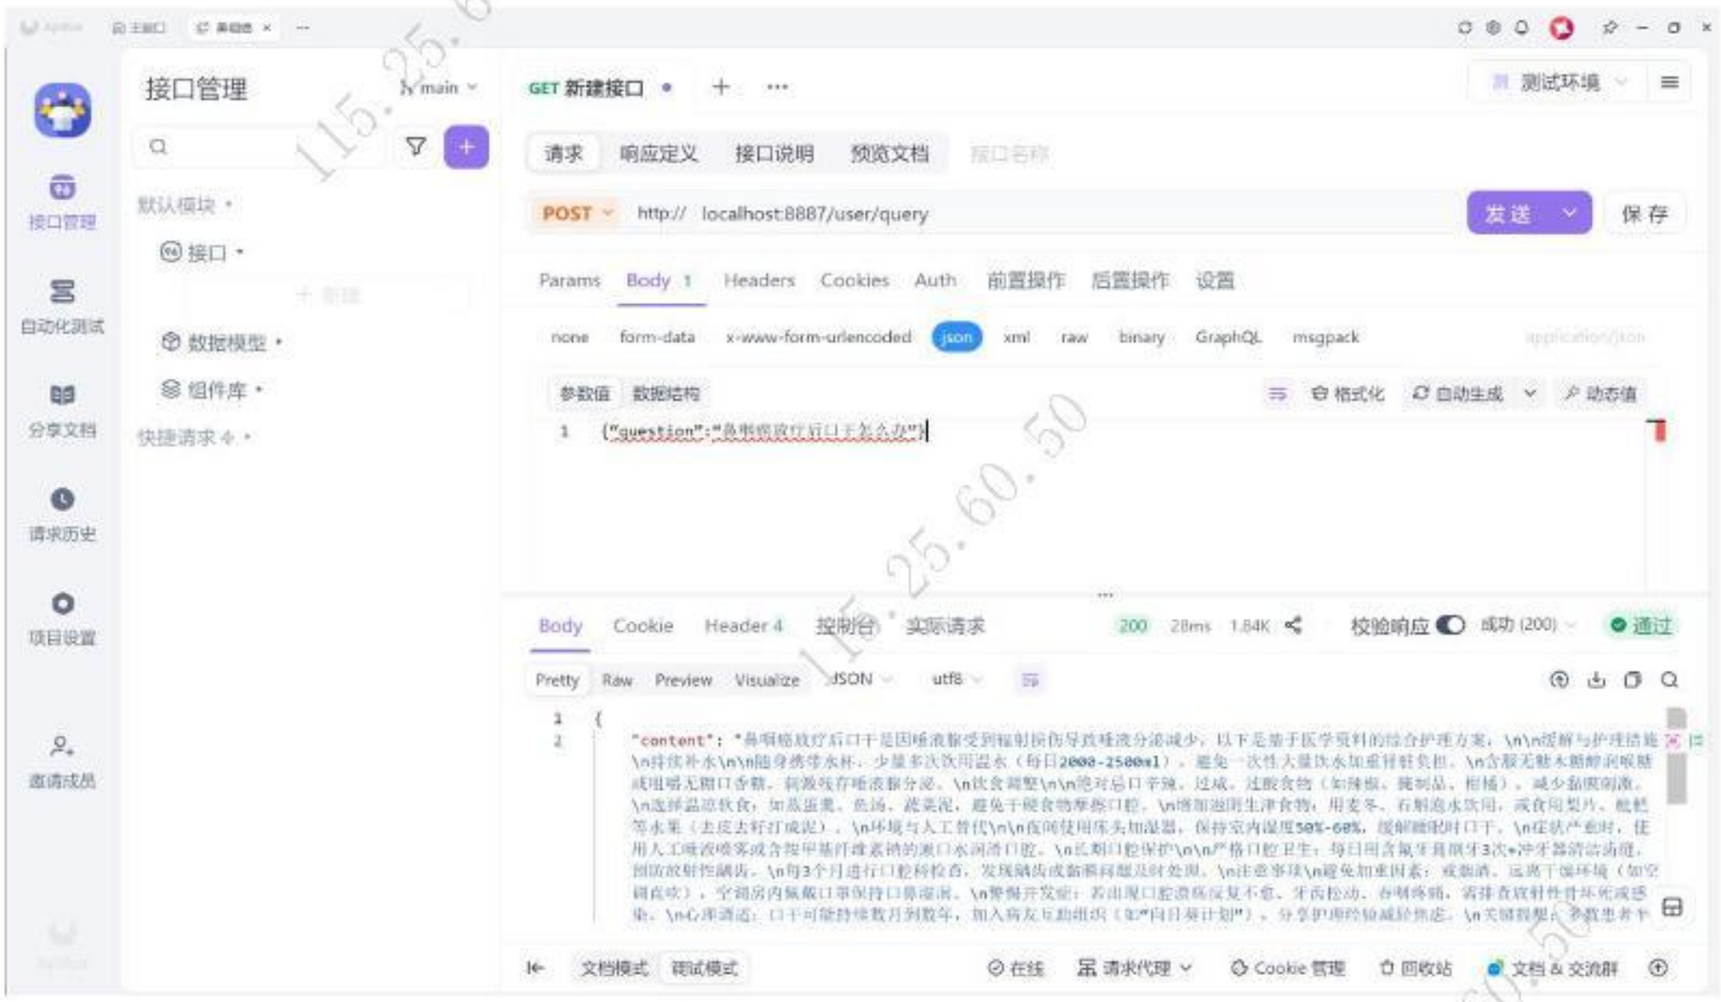


图 4-16 接口回复测试

Fig.4-16 Interface response test

压力测试通过 JMeter[57]模拟 50、100、200 用户并发请求，监测系统响应时间和错误率。50 用户并发时，平均响应时间 1.2 秒，错误率 0%；100 用户并发时，测试结果如图 4-17 所示，响应时间增至 2.5 秒，错误率 1.0%（主要为网络搜索超时）；200 用户并发时，响应时间达 5.8 秒，错误率 2.3%，但核心的知识库和知识图谱检索仍保持稳定。测试结束后检查各组件状态，Neo4j 和 Milvus 未出现数据丢失，MinIO 文件存储完整，系统整体表现满足预期的 100 用户并发需求。

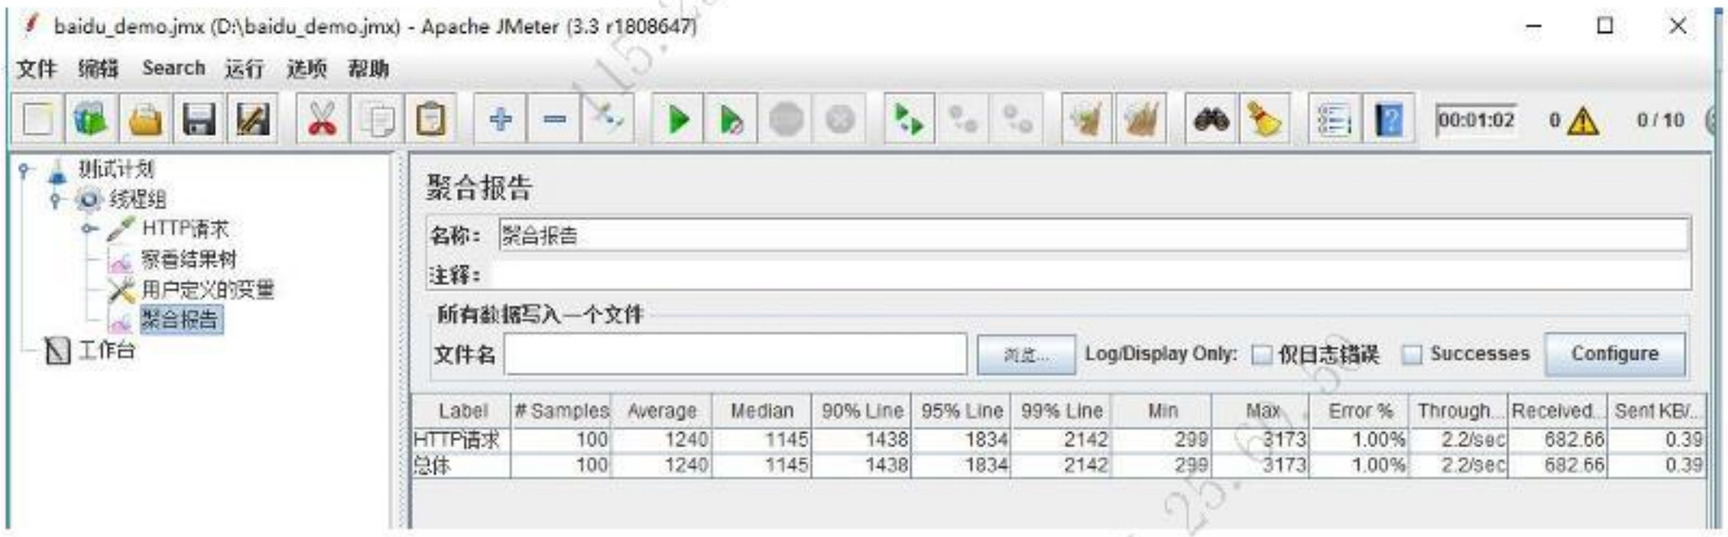


图 4-17 100 并发压力测试结果

Fig.4-17 100 concurrent stress test results

4.5 本章小结

本章结合鼻咽癌知识问答系统的需求分析，从需求的角度出发，对系统进行了整体的设计。首先对用户的需求进行了充分的调研和分析，了解了相关系统的难点；然后对系统整体采用什么架构，选用什么开发技术，以及各层级之间的关联关系进行了概要设计；其次从功能实现的角度，对鼻咽癌知识问答系统的实现过程进行了详细的介绍，并对系统内的交互进行了相关的展示；最后对系统进行了充分的测试，保证系统可用性和稳定性。通过本章的实现和验证，实现了一个好用并且稳定的鼻咽癌知识问答系统。

5 总结与展望

5.1 总结

本文围绕基于知识库和知识图谱的鼻咽癌问答系统的设计与实现展开研究，通过数据采集、知识库构建、知识图谱构建到系统集成的全流程设计，完成了一套从信息获取到智能问答的完整解决方案，为医疗从业者、患者及研究者提供精准、高效的鼻咽癌相关知识查询服务。主要工作如下：

1）多源数据采集与预处理：针对鼻咽癌领域知识分散的特点，设计了多渠道数据采集方案：通过网络爬虫获取权威医疗网站（如梅奥诊所、丁香园）的科普文章、诊疗指南；批量下载 PubMed、CNKI 等学术数据库中的相关文献；整理公开的临床病例报告与医患问答数据。对采集的非结构化文本进行清洗、标准化（统一医学术语）和格式转换，为后续知识提取奠定数据基础。

2）领域知识库构建：基于预处理后的数据集，构建了鼻咽癌领域结构化知识库。该知识库涵盖疾病基础（病因、分型、症状）、诊断方法（影像学检查、病理检测）、治疗方案（手术、放化疗、靶向治疗）及预后护理等维度，采用关系型数据库存储结构化知识，并通过本体模型定义概念层级（如“鼻咽癌”属于“头颈部恶性肿瘤”），以确保知识的逻辑性和一致性。

3）知识图谱构建与实体关系提取：针对领域知识的关联性需求，设计了“实体-关系”标注体系，标注了包括“疾病实体”“关系实体”等 9 种核心实体，“疾病-伴随症状”“疾病-需要检查”等 11 类核心关系。基于标注数据，训练了 BERT+CRF 模型用于实体识别和关系抽取，最终构建了包含 1931 个实体、2087 条关系的鼻咽癌知识图谱，实现了知识的可视化关联与高效检索。

4）问答系统集成与实现：提出“知识库+知识图谱+ LLM”的融合问答框架，以知识库为基础提供结构化事实性答案，以知识图谱支撑多实体关联查询，通过 LLM 实现自然语言理解与生成。系统支持多样化查询类型，包括事实问答（如“鼻咽癌的早期症状有哪些？”）、关联推理（如“放疗对鼻咽癌患者听力有何影响？”）及治疗方案对比（如“手术与化疗在鼻咽癌治疗中的优劣？”），并通过多轮对话功能提升交互体验。

5）系统评估与验证：采用人工评估与自动评测结合的方式验证系统性能：在测试集上，针对 50 条真实测试问题，系统回答准确率为 94%，证明了方案的有效性。

5.2 展望

尽管本文构建的问答系统在鼻咽癌领域知识服务中表现出较好的性能，但仍存在以下不足，需在未来研究中进一步优化：

1)实时性与动态更新机制缺失：知识图谱和知识库的更新依赖人工干预，无法自动同步最新研究成果（如期刊论文、临床试验数据），导致系统回答可能滞后于医学进展。例如，2025 年 7 月以后的最新文献尚未纳入系统知识库。

通过分析上述不足，本文未来改进方向有以下几点：

1）拓展知识来源与动态更新机制：接入临床试验数据库（如 ClinicalTrials.gov）和实时医学文献 API，通过文本挖掘自动提取最新研究结论，实现知识库每周增量更新。引入联邦学习框架，与医院合作构建隐私保护下的多中心病例库，补充个体化诊疗知识，提升系统对罕见病例的支持能力。

2）提升模型推理与鲁棒性：采用 Prompt Tuning[58]或 LoRA[59]技术微调 LLM，结合知识图谱的三元组约束减少“幻觉”，例如在生成答案时引用知识图谱中的实体关系作为依据。引入知识蒸馏，将专业领域模型（如医疗领域的 BioBERT[60]）的知识迁移至基础模型，提升对模糊术语和长距离关系的识别能力。

未来研究将聚焦于“知识实时化、推理可解释化、交互多模态化”，推动系统从“信息查询工具”向“辅助诊疗决策支持系统”升级，为鼻咽癌的精准防治提供更智能的技术支撑。

参考文献

[1] 梁锌, 杨剑, 高婷, 等. 中国鼻咽癌流行概况[J]. 中国肿瘤, 2016, 25(11): 835-840.

[2] 赫捷, 李进, 马军, 等. 中国临床肿瘤学会(CSCO)常见恶性肿瘤诊疗指南[M]. 人民卫生出版社, 2021.

[3] GARFIELD E. Citation indexes for science: a new dimension in documentation through association of ideas[J]. Science, 1955, 122(3159): 108-111.

[4] PRICE D J D S. Networks of scientific papers: The pattern of bibliographic references indicates the nature of the scientific research front.[J]. Science, 1965, 149(3683): 510-515.

[5] MINSKY M L. Semantic information processing[M]. The MIT Press, 1969.

[6] FEIGENBAUM E. The art of artificial intelligence-Themes and case studies of knowledge engineering[C]//Managing Requirements Knowledge, International Workshop on. IEEE Computer Society, 1978: 227-227.

[7] BORGIDA A, BRACHMAN R J, MCGUINNESS D L, et al. CLASSIC: A structural data model for objects[J]. ACM Sigmod Record, 1989, 18(2): 58-67.

[8] 论兵, 王月春, 郝晓慧, 等. 知识图谱问答研究进展[J]. 软件导刊, 2022, 21(3): 226-236.

[9] AMIT SINGHAL. Introducing the Knowledge Graph: things, not strings[EB/OL]. (2012-05-16)[2025-08-23]. https://blog.google/products/search/introducing-knowledge-graph-things-not.

[10] 郑泳智, 朱定局, 吴惠粦, 等. 知识图谱问答领域综述[J]. 计算机系统应用, 2022, 31(4): 1-13.

[11] TURING A M. Computing machinery and intelligence[M]. Springer, 2007.

[12] GOODFELLOW I, BENGIO Y, COURVILLE A, et al. Deep learning[M]. MIT Press Cambridge, 2016.

[13] GREEN JR B F, WOLF A K, CHOMSKY C, et al. Baseball: an automatic question-answerer[C]//Papers Presented at the May 9-11, 1961, Western Joint IRE-AIEE-ACM Computer Conference. 1961: 219-224.

[14] ZAIB M, ZHANG W E, SHENG Q Z, et al. Conversational question answering: A survey[J]. Knowledge and Information Systems, 2022, 64(12): 3151-3195.

[15] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[J].

Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.

[16] 刘峤, 李杨, 段宏, 等. 知识图谱构建技术综述[J]. 计算机研究与发展, 2016, 53(3): 582-600.

[17] CURRAN J R, CLARK S. Language independent NER using a maximum entropy tagger[C]//Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003. 2003: 164-167.

[18] FAGERBERG J, FOSAAS M, SAPPRASERT K. Innovation: Exploring the knowledge base[J]. Research Policy, 2012, 41(7): 1132-1153.

[19] GUJJAR J P, KUMAR H P. Text Similarity Technique Using BGE-M3[C]//2025 International Conference on Advances in Modern Age Technologies for Health and Engineering Science (AMATHE). IEEE, 2025: 1-7.

[20] KOČISKỲ T, SCHWARZ J, BLUNSOM P, et al. The narrativeqa reading comprehension challenge[J]. Transactions of the Association for Computational Linguistics, 2018, 6: 317-328.

[21] HAN K, WANG Y, CHEN H, et al. A survey on vision transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(1): 87-110.

[22] DAI D, DENG C, ZHAO C, et al. DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. 2024: 1280-1297.

[23] JAYASEELAN N. LLaMA 2: The New Open Source Language Model[J]. Journal of Machine Learning Research, 2023, 24(1): 1-15.

[24] MIKHAIL D, FARAH A, MILAD J, et al. Performance of DeepSeek-R1 in ophthalmology: an evaluation of clinical decision-making and cost-effectiveness[J]. British Journal of Ophthalmology, 2025, 109(9): 976-981.

[25] LI Z, LIANG S, YANG Y, et al. Fault Knowledge Graph for QUAV Construction Based on Qwen Large Model[C]//International Conference on Guidance, Navigation and Control. Springer, 2024: 538-548.

[26] MAO R, CHEN G, ZHANG X, et al. GPTEval: A Survey on Assessments of ChatGPT and GPT-4[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). 2024: 7844-7866.

[27] MOHAMMED A A, MUDHSH B A, BIN-HADY W R A, et al. DeepSeek and

Grok in the spotlight after ChatGPT in English education: A review study[J]. Journal of English Studies in Arabia Felix, 2025, 4(1): 13-22.

[28] BISWAS S S. Role of chat gpt in public health[J]. Annals of Biomedical Engineering, 2023, 51(5): 868-869.

[29] RANE N, CHOUDHARY S, RANE J. Gemini versus ChatGPT: applications, performance, architecture, capabilities, and implementation[J]. Journal of Applied Artificial Intelligence, 2024, 5(1): 69-93.

[30] BAI X, REN J, FAN Y, et al. KIMI: Knockoff Inference for Motif Identification from molecular sequences with controlled false discovery rate[J]. Bioinformatics, 2021, 37(6): 759-766.

[31] ARSLAN M, GHANEM H, MUNAWAR S, et al. A Survey on RAG with LLMs[J]. Procedia Computer Science, 2024, 246: 3781-3790.

[32] WHITE J. PubMed 2.0[J]. Medical Reference Services Quarterly, 2020, 39(4): 382-387.

[33] 肖千凯. 数据爬虫侵权责任认定问题研究[D]. 贵州师范大学, 2025.

[34] DIKILITAŞ Y, ÇAKAL Ç, OKUMUŞ A C, et al. Performance analysis for web scraping tools: case studies on beautifulsoup, scrapy, htmlunit and jsoup[C]//International Conference on Emerging Trends and Applications in Artificial Intelligence. Springer, 2023: 471-480.

[35] LI C, LIU Z, XIAO S, et al. Llama2vec: Unsupervised adaptation of large language models for dense retrieval[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 3490-3500.

[36] 刘雪颖, 云静, 李博, 等. 基于大型语言模型的检索增强生成综述[J]. 计算机工程与应用, 2025, 61(13): 1-25.

[37] LIU J. LlamaIndex[EB/OL]. (2022-11). https://docs.llamaindex.org.cn/en/stable.

[38] WANG L, YANG N, HUANG X, et al. Improving Text Embeddings with Large Language Models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. 2024: 11897-11916.

[39] YAO T, ZHAI Z, GAO B. Text classification model based on fasttext[C]//2020 IEEE International Conference on Artificial Intelligence and Information Systems (ICAIIS). IEEE, 2020: 154-157.

[40] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional

transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (long and short papers). 2019: 4171-4186.

[41] ZHENG X, BURDICK D, POPA L, et al. Global table extractor (gte): A framework for joint table identification and cell structure recognition using visual context[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2021: 697-706.

[42] WANG J, CHEN K, CHEN Z, et al. Winning ClimateCheck: A multi-stage system with BM25, BGE-reranker ensembles, and LLM-based analysis for scientific abstract retrieval[C]//Proceedings of the Fifth Workshop on Scholarly Document Processing (SDP 2025). 2025: 276-280.

[43] WANG J, YI X, GUO R, et al. Milvus: A purpose-built vector data management system[C]//Proceedings of the 2021 International Conference on Management of Data. 2021: 2614-2627.

[44] DANOPOULOS D, KACHRIS C, SOUDRIS D. Approximate similarity search with faiss framework using fpgas on the cloud[C]//International Conference on Embedded Computer Systems. Springer, 2019: 373-386.

[45] SINGH P N, TALASILA S, BANAKAR S V. Analyzing embedding models for embedding vectors in vector databases[C]//2023 IEEE International Conference on ICT in Business Industry & Government (ICTBIG). IEEE, 2023: 1-7.

[46] 孙虹, 张罗. 耳鼻咽喉头颈外科学（第 9 版）[M]. 人民卫生出版社, 2018.

[47] 韩德民, 陈明远. 鼻咽癌诊疗规范手册[M]. 人民卫生出版社, 2022.

[48] 彭桂原. 鼻咽癌放化疗后的中医康复与调养[M]. 人民卫生出版社, 2020.

[49] TOMCZAK K, CZERWIŃSKA P, WIZNEROWICZ M. Review The Cancer Genome Atlas (TCGA): an immeasurable source of knowledge[J]. Contemporary Oncology/Współczesna Onkologia, 2015, 19(1A): 68-77.

[50] 奥德玛, 杨云飞, 穗志方, 等. 中文医学知识图谱 CMeKG 构建初探[J]. 中文信息学报, 2019, 33(10): 1-9.

[51] SAMBETBAYEVA M, NEKESSOVA A, YERIMBETOVA A, et al. A Multi-Level Annotation Model for Fake News Detection: Implementing Kazakh-Russian Corpus via Label Studio[J]. Big Data and Cognitive Computing, 2025, 9(8): 215-228.

[52] MILLER J J. Graph database applications and concepts with Neo4j[C]//Proceedings of the Southern Association for Information Systems Conference. 2013: 141-147.

[53] 张仕娜. 基于领域本体的中医急诊诊疗知识库构建和知识发现研究[D]. 湖南中医药大学, 2024.

[54] 郑寿东. 基于强化学习的医疗知识图谱问答系统关键技术研究与应用[D]. 电子科技大学, 2025.

[55] 梁津. 基于循证临床实践指南系统评价的痛风本体知识库构建研究[D]. 南方医科大学, 2024.

[56] TELLI M L, GRADISHAR W J, WARD J H. NCCN guidelines updates: breast cancer[J]. Journal of the National Comprehensive Cancer Network, 2019, 17(5.5): 552-555.

[57] HALILI E H. Apache JMeter[M]. Springer, 2008.

[58] LESTER B, AL-RFOU R, CONSTANT N. The Power of Scale for Parameter-Efficient Prompt Tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 3045-3059.

[59] DEVALAL S, KARTHIKEYAN A. LoRa technology-an overview[C]//2018 Second International Conference on Electronics, Communication and Aerospace Technology (ICECA). IEEE, 2018: 284-290.

[60] LEE J, YOON W, KIM S, et al. BioBERT: a pre-trained biomedical language representation model for biomedical text mining[J]. Bioinformatics, 2020, 36(4): 1234-1240.

附录 A 后端主要代码

```
import json
import uuid
import asyncio
import traceback
from typing import List, Dict, Optional, Any
from fastapi.responses import StreamingResponse
from fastapi import APIRouter, Depends, Body, HTTPException
from langchain_core.messages import AIMessageChunk, HumanMessage


from src.core import HistoryManager
from src.agents import agent_manager
from src.models import select_model
from server.models.user_model import User
from src import executor, config, retriever
from src.utils.logging_config import logger
from server.models.thread_model import Thread
from src.agents.tools_factory import get_all_tools
from server.routers.auth_router import get_admin_user
from server.utils.auth_middleware import get_required_user, get_db


# 初始化聊天相关路由，前缀为"/chat"
chat_router = APIRouter(prefix="/chat")


@chat_router.get("/default_agent")
async def fetch_default_agent(current_user: User = Depends(get_required_user)):
    """
    获取默认智能体 ID(需登录)

    优先返回配置中设置的默认智能体 ID，若未设置则返回首个可用智能体
的 ID
    """
    try:
        default_id = config.default_agent_id
        # 若配置中无默认值，尝试从可用智能体中取第一个
        if not default_id:
```

```
            available_agents = await agent_manager.get_agents_info()
            if available_agents:
                default_id = available_agents[0].get("name", "")

        return {"default_agent_id": default_id}
    except Exception as e:
        logger.error(f"获取默认智能体失败: {str(e)}")
        raise HTTPException(
            status_code=500,
            detail=f"获取默认智能体时发生错误: {str(e)}"
        )


@chat_router.post("/set_default_agent")
async def configure_default_agent(
        agent_id: str = Body(..., embed=True),
        current_user: User = Depends(get_admin_user)
):
    """
    设置默认智能体 ID(仅管理员可用)

    验证智能体 ID 是否存在，通过后更新配置并保存
    """
    try:
        # 验证智能体是否存在
        available_agents = await agent_manager.get_agents_info()
        valid_agent_ids = [agent.get("name", "") for agent in available_agents]

        if agent_id not in valid_agent_ids:
            raise HTTPException(
                status_code=404,
                detail=f"智能体 {agent_id} 不存在"
            )

        # 更新并保存默认智能体配置
        config.default_agent_id = agent_id
        config.save()

        return {"success": True, "default_agent_id": agent_id}
    except HTTPException as he:
```

```
        raise he
    except Exception as e:
        logger.error(f"设置默认智能体失败: {str(e)}")
        raise HTTPException(
            status_code=500,
            detail=f"设置默认智能体时发生错误: {str(e)}"
        )

@chat_router.get("/")
async def check_chat_service(current_user: User = Depends(get_required_user)):
    """
    聊天服务健康检查(需登录)

    用于验证聊天服务是否正常响应
    """
    return "Chat Service is running"


@chat_router.post("/")
async def handle_chat_request(
        query: str = Body(...),
        extra_info: Optional[Dict] = Body(None),
        chat_history: Optional[List[Dict]] = Body(None),
        thread_id: Optional[str] = Body(None),
        current_user: User = Depends(get_required_user)
    ):
    """
    处理聊天请求主接口(需登录)

    接收用户查询，根据附加信息处理检索逻辑，调用模型生成响应并以流形式返回
    """
    # 选择合适的模型(根据配置或请求参数)
    selected_model = select_model()
    # 补充模型名称到附加信息中
    if extra_info:
        extra_info["server_model_name"] = selected_model.model_name
    else:
        extra_info = {"server_model_name": selected_model.model_name}
```

```
# 初始化历史记录管理器
history_handler = HistoryManager(
    chat_history,
    system_prompt=extra_info.get("system_prompt") if extra_info else None
)
logger.debug(f"收到聊天请求: 查询内容={query}, 附加信息={extra_info}")

def build_stream_chunk(content: Optional[str] = None, **kwargs) -> bytes:
    """构建流式响应的 Chunk(JSON 格式)"""
    chunk_data = {
        "response": content,
        "meta": extra_info, **kwargs
    }
    return json.dumps(chunk_data, ensure_ascii=False).encode('utf-8') + b"\n"

def need_knowledge_retrieval(info: Optional[Dict]) -> bool:
    """判断是否需要执行知识库检索"""
    if not info:
        return False
    return info.get("use_web") or info.get("use_graph") or info.get("db_id")

def generate_chat_response():
    """生成聊天响应的生成器函数(用于流式输出)"""
    processed_query = query
    reference_info = None

    # 处理知识库检索逻辑(若需要)
    if extra_info and need_knowledge_retrieval(extra_info):
        # 发送检索中状态
        yield build_stream_chunk(status="searching")

try:
    # 调用检索器处理查询
    processed_query, reference_info = retriever(
        processed_query,
        history_handler.messages,
        extra_info
    )
except Exception as e:
```

```
                    logger.error(f"检索器错误:
{str(e)}\n{traceback.format_exc()}")
                    yield build_stream_chunk(
                        message=f"检索处理失败: {str(e)}",
                        status="error"
                    )
                    return

                # 发送生成中状态
                yield build_stream_chunk(status="generating")

            # 构建包含历史的消息列表
            messages = history_handler.get_history_with_msg(
                processed_query,
                max_rounds=extra_info.get('history_round') if extra_info else None
            )
            # 将原始查询添加到历史记录
            history_handler.add_user(query)

            full_response = ""
            reasoning_process = ""

            try:
                # 调用模型生成响应(流式输出)
                for delta in selected_model.predict(messages, stream=True):
                    # 处理推理过程内容(若模型支持)
                    if not delta.content and hasattr(delta, 'reasoning_content'):
                        reasoning_process += delta.reasoning_content or ""
                        yield build_stream_chunk(
                            reasoning_content=reasoning_process,
                            status="reasoning"
                        )
                        continue

                    # 处理完整响应(部分模型支持)
                    if hasattr(delta, 'is_full') and delta.is_full:
                        full_response = delta.content
                    else:
                        full_response += delta.content or ""
```

```
                # 发送当前生成的内容片段
                yield build_stream_chunk(
                    content=delta.content,
                    status="loading"
                )

            logger.debug(f"最终响应内容: {full_response}")
            logger.debug(f"推理过程内容: {reasoning_process}")

            # 发送完成状态及最终信息
            yield build_stream_chunk(
                status="finished",
                history=history_handler.update_ai(full_response),
                refs=reference_info
            )

        except Exception as e:
            logger.error(f"模型调用错误: {str(e)}\n{traceback.format_exc()}")
            yield build_stream_chunk(
                message=f"模型处理失败: {str(e)}",
                status="error"
            )
            return

    # 返回流式响应
    return StreamingResponse(
        generate_chat_response(),
        media_type='application/json'
    )
```

致　谢

时光荏苒，转眼间这段在职攻读硕士学位的旅程即将画上句号。回首这段兼顾工作与学习的岁月，既有挑战与艰辛，也有成长与收获。在此，我怀着最真挚的感激之情，向所有给予我支持与帮助的人表达谢意。

首先，衷心感谢我的导师张志超教授。感谢您在我求学期间的悉心指导和耐心包容。作为在职研究生，我时常面临时间与精力的双重压力，但您始终以严谨的治学态度和灵活的教学方式引导我，帮助我在繁忙的工作之余完成科研任务。无论是深夜的邮件回复，还是周末的线上讨论，您都给予我莫大的支持与鼓励。您的学术视野和敬业精神深深影响着我，让我在学术与职业发展的道路上更加坚定。

感谢实验室的学长学姐们，你们无私地分享经验、提供建议，帮助我快速适应科研节奏。你们在文献梳理、理论框架构建和学术规范方面的建议，让我少走许多弯路。你们的榜样力量让我明白，坚持与协作是科研路上不可或缺的品质。

感谢课题组的每一位同学，与你们的每一次讨论、每一次合作都让我受益匪浅。在职学习的特殊性让我无法像全日制同学那样全程参与组会与实验，但你们始终包容我的时间安排，并在关键时刻伸出援手。那些深夜的线上交流、周末的实验室加班，都成为我求学路上最珍贵的回忆。

最后，谨以最深切的感恩献给我的家人。感谢父母数十年如一日的无私付出，你们始终是我最坚实的后盾。在职求学的日子里，是你们默默承担了更多家庭事务，在我熬夜赶论文时端来的一杯热茶，在我工作学业双重压力下给予的宽慰鼓励，这些细微之处的温暖让我得以心无旁骛地坚持至今。感谢兄弟姐妹的体谅与支持，你们主动分担照顾父母的责任，替我弥补了因忙碌而缺失的陪伴。寸草春晖，无以为报，唯愿以今后的成长反哺这份沉甸甸的爱。

这段求学经历让我深刻体会到“学无止境”的真谛。尽管过程充满不易，但正是这些挑战让我更加坚韧。未来，我将带着这段经历中的收获与感动，继续在学术与职业道路上砥砺前行。

再次向所有帮助过我的人致以最诚挚的谢意！

作者简历及在学研究成果

一、主要教育经历/工作经历（从大学起，到硕士入学止）

起止年月	学习或工作单位	备注
2008 年 09 月至 2012 年 07 月	在曲阜师范大学计算机科学与技术专业攻读学士学位	
2012 年 09 月至 2016 年 07 月	在聊城文轩中学从事教师工作	
2016 年 08 月至 2025 年 08 月	在山师二附中从事教师工作	

二、在学期间从事的科研工作

无

三、在学期间所获的科研奖励

无

四、在学期间发表的论文

无

独创性说明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作 者 签 名：李天威 日期：2025 年 9 月 10 日

备注：提交时须有作者亲笔签名！

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：李天威　导师签名：张志超　日期：2025年9月10日

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
知识图谱； 知识库； 大语言模型； 问答系统	公开	TP319	004	
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京科技大学		10008	工程硕士	硕士
论文题名*		并列题名		论文语种*
基于知识库和知识图谱的鼻咽癌问答系统的设计与实现				中文
作者姓名*	李天威		学号*	M202240088
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京科技大学		10008	北京市海淀区学院路 30 号	100083
学科专业*		研究方向*	学制*	学位授予年*
软件工程		深度学习	2.5	2025
论文提交日期*	2025 年 9 月 10 日			
导师姓名*	张志超		职称*	副教授
评阅人	答辩委员会主席*		答辩委员会成员	
	艾冬梅		司新辉，刘林，齐悦	
1 电子版论文提交格式　文本（√）　图像（ ）　视频（ ）　音频（ ）　多媒体（ ）　其他（ ） 2 推荐格式：application/msword; application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*	74			
共 33 项，其中带*为必填数据，为 22 项。				