密　　级：公开

加密论文编号：

论文题目：基于图对比学习的乳腺癌空间异质性研究

学　　号：M202340090

作　　者：梁冬娟

专 业 名 称：软件工程

2025 年 12 月 25 日

115.25.60.50

基于图对比学习的乳腺癌空间异质性研究

Research on Spatial Heterogeneity of Breast Cancer Based on Graph Contrastive Learning

研究生：梁冬娟

指导教师：艾冬梅

北京科技大学数理学院

北京 100083，中国

Master Degree Candidate：Liang Dongjuan

Supervisor：Ai Dongmei

School of Mathematics and Physics

University of Science and Technology Beijing

30 Xueyuan Road，Haidian District

Beijing 100083，P.R.CHINA

115.25.60.50

中图分类号：　　学校代码：10008
U　D　C：　　密　　级：公开

北京科技大学硕士学位论文

论文题目：基于图对比学习的乳腺癌空间异质性研究

作者：梁冬娟

指　导　教　师：艾冬梅　单位：数理学院　职称：教授

指导小组成员：　　单位：　　职称：

　　单位：　　职称：

论文提交日期：2025 年 12 月 25 日

学位授予单位：北 京 科 技 大 学

摘 要

乳腺癌的空间异质性是影响治疗耐药和疾病复发的关键因素。空间转录组技术的出现为解析乳腺癌组织结构与微环境提供了新的视角，它有效弥补了单细胞转录组学技术在空间信息缺失上的局限。空间域识别是空间转录组数据分析中的关键任务，其通过将组织切片划分为空间连续且具有相似分子特征的功能区域，为理解肿瘤异质性提供了基础。但是，现有算法多依赖基因表达数据，未能有效整合组织形态学信息，限制了识别精度和生物学解释性。

为解决这一挑战，本论文提出了一种基于图对比学习的多模态空间域识别算法 SpaGCL（Spatial Domain Identification via Graph Contrastive Learning）。该算法在图对比学习框架下，分别对基因表达信息和组织形态学特征进行表征，并通过引入交叉注意力机制实现两种模态特征的有效融合，从而提升空间域边界的识别精度。此外，针对现有数据增强策略可能破坏生物学关系的问题，本论文提出基于基因表达余弦相似度的增强策略，在保持生物学语义一致性的同时提升了算法的稳定性。

为了全面评估算法性能，本论文在 10x Visium、Stereo-seq 以及 Slide-seqV2 三个平台的五个真实数据集上开展实验。结果表明，SpaGCL 算法在空间域识别方面优于六种现有算法；进一步联合单细胞分析了人类乳腺癌的空间异质性，揭示了肿瘤核心、侵袭前沿及免疫富集区域在细胞类型分布和生物功能上的异质性；最后，通过整合临床信息，构建了基于三级淋巴结构的预后模型，为精准医疗提供了新的见解与工具支持。

关键词：空间域识别；图对比学习；多模态；交叉注意力；乳腺癌

Research on Spatial Heterogeneity of Breast Cancer Based on Graph Contrastive Learning

ABSTRACT

Spatial heterogeneity in breast cancer is a key factor contributing to treatment resistance and disease recurrence. The emergence of spatial transcriptomics provides a new perspective for in-depth analysis of breast cancer tissue structure and microenvironment, effectively compensating for the limitations of single-cell transcriptomics in terms of spatial information loss. In spatial transcriptomics data analysis, accurate identification of spatial domains, by dividing tissues into different functional regions, lays the foundation for understanding tumor heterogeneity and intercellular interactions. However, existing spatial domain identification algorithms typically rely solely on gene expression data, failing to effectively integrate morphological information from tissue sections, thus limiting identification accuracy and biological relevance.

To address this challenge, this dissertation proposes a graph contrastive learning–based multimodal spatial domain identification algorithm, termed SpaGCL (Spatial Domain Identification via Graph Contrastive Learning). Within the graph contrastive learning framework, SpaGCL separately represents gene expression information and histomorphological features, and integrates the two modalities through a cross-attention mechanism, thereby improving the accuracy of spatial domain boundary identification. In addition, to mitigate the risk that existing data augmentation strategies may disrupt biological relationships, this study introduces a gene expression cosine similarity–based augmentation strategy, which enhances algorithmic stability while preserving biological semantic consistency.

To comprehensively evaluate the algorithm's performance, this paper conducted experiments on five real-world datasets across three platforms: 10x Visium, Stereo-seq, and Slide-seqV2. The results show that SpaGCL outperforms six existing methods in spatial domain recognition tasks. Further analysis using single-cell data revealed the spatial heterogeneity of human breast cancer, showcasing the significant spatial specificity of the tumor core, invasion front, and immune-enriched regions in terms of cellular composition and molecular

characteristics. Finally, by integrating clinical information, the functional characteristics and prognostic value of the tertiary lymphoid structures in the breast cancer microenvironment were systematically analyzed, providing new insights and methodological support for precision medicine.

Key Words: Spatial Transcriptomics; Spatial Domain Identification; Graph Contrastive Learning; Multimodal; Breast Cancer

目 录

摘 要 I
ABSTRACT II
1 引言 1
1.1 研究背景 1
1.2 主要研究内容 2
1.3 技术路线 3
1.4 论文的组织结构 4
2 文献综述及相关理论基础 5
2.1 基于概率统计的空间域识别算法 5
2.2 基于图神经网络的空间域识别算法 5
2.3 基于图对比学习的空间域识别算法 6
2.4 图注意力 GAT 7
2.5 图对比学习 GCL 9
2.6 无负样本的图对比学习 Barlow Twins 13
2.7 空间域识别算法的评估指标 14
2.8 本章小结 17
3 基于图对比学习的空间域识别算法研究 18
3.1 组织学图像特征提取 18
3.2 基于图对比学习的基因表达特征提取 19
3.2.1 基于基因表达相似性的数据增强 21
3.3 基于交叉注意力的特征融合 22
3.4 聚类和可视化 22
3.5 实验结果与模型对比 23
3.5.1 数据来源 23
3.5.2 SpaGCL 在 DLPFC 数据集上的定量评估 24
3.5.3 SpaGCL 提升小鼠冠状脑切片的细微结构识别能力 28
3.5.4 SpaGCL 在小鼠嗅球数据集上的大尺度空间解析 31
3.5.5 SpaGCL 在小鼠海马体数据集上的亚细胞分辨率解析 32
3.5.6 SpaGCL 精细刻画癌组织的空间域 33
3.6 关键模块评估 34

3.7 本章小结 35
4 基于空间转录组与单细胞的乳腺癌空间异质性研究 36
4.1 联合单细胞数据解析乳腺癌细胞组成与空间分布 36
4.2 肿瘤区域细胞组成及功能异质性 38
4.3 肿瘤边缘细胞组成与功能异质性 41
4.4 基于免疫细胞空间聚集识别 TLS 微环境 43
4.5 本章小结 46
5 构建乳腺癌预后模型 47
5.1 TLS 特征基因的筛选与功能分析 47
5.2 基于 TLS 特征基因构建预后模型 48
5.3 预后模型的统计学评估与验证 51
5.4 本章小结 53
6 结论与展望 54
参考文献 55
致　谢 63
作者简历及在学研究成果 64
独创性说明 65
关于论文使用授权的说明 66
学位论文数据集 67

1 引言

1.1 研究背景

乳腺癌是全球女性中发病率最高的恶性肿瘤[1]，其生物学行为呈现高度异质性，涉及分子分型、细胞组成、空间结构及微环境状态等多层面差异[2]。这种多维度的异质性不仅影响肿瘤的发生发展过程，还直接关联治疗响应差异与预后不一致性[3]。近年来，空间转录组技术的发展，使得在组织原位解析细胞类型、空间组织结构及其相互作用成为可能，从而为研究肿瘤空间生态系统及异质性提供了新的视角[4,5]。

空间域识别作为空间转录组数据分析中关键的基础分析任务之一，其目标是根据空间邻域与基因表达相似将组织划分为具有生物学意义的区域[6]。空间域的精确识别对揭示细胞互作[7]、解析空间组织结构及理解疾病发生机制[8]具有重要价值，在疾病早期诊断、预后评估[9]及精准治疗方面等方面具有潜在的价值。为此，研究者提出了多种空间域识别方法。这些方法大体可分为两类：基于统计模型的方法和基于图神经网络的方法。基于统计模型的算法如：BayesSpace[10]和 Seurat[11]使用马尔可夫随机场对相邻细胞中的相关基因表达进行建模进行空间域识别。随着深度学习的兴起，深度学习成为空间域识别分析的有力工具[12]。SpaGCN[13]是一种采用图卷积模型进行空间域识别算法。该算法将基因表达、空间信息和组织学图像相结合，通过图卷积模型实现空间域的识别。STAGATE[14]算法在图卷积模型的基础上引入了注意力机制进一步提高了空间域识别的性能。GraphST[15]算法将图神经网络与自监督对比学习相结合来提高空间域识别能力。这些方法的发展为从原始数据中提取生物信号提供了重要工具。CCST [16]利用最大化互信息原理通过随机构建损坏的图并采用对比学习技术进行表示学习。SpaceFlow[17]采用图卷积模型作为编码器集成基因表达谱和空间位置信息，使用对比学习和正则化技术进行优化。尽管空间域识别方法在分析空间转录组数据结构特征方面取得了一定进展，但多依赖基因表达数据，未能有效整合组织形态学信息，限制了识别精度和生物学解释性。

针对上述问题，本论文提出一种空间域识别算法 SpaGCL。该算法在图对比学习框架下分别学习基因表达特征和组织形态学特征，并通过引入交叉注意力机制对两类特征进行自适应融合，从而提升算法对空间域的识别准确

性。并结合单细胞转录组数据与临床生存数据系统分析乳腺癌的空间异质性及其潜在预后意义。

1.2 主要研究内容

具体而言，本论文旨在开发和验证一种新的空间域识别算法，以准确表征和解析空间转录组中的组织结构域。本论文共分三个研究内容。

1) 基于图对比学习的空间域识别算法研究

本论文提出了一种基于图对比学习的空间域识别算法 SpaGCL。该算法采用图对比学习框架提取基因表达特征，以基因表达余弦相似度作为边权重，实现图对比学习的自适应增强：通过为高相似度边赋予更高的保留概率，同时优先丢弃低相似度边，在有效扩大对比学习视图差异的同时，保持了转录组空间拓扑结构的一致性。在此基础上，采用 Barlow Twins 对组织图像进行特征提取。并且引入交叉注意力机制，实现组织学图像特征与基因表达特征的自适应权重分配。

2) 乳腺癌空间异质性研究

本论文旨在系统解析乳腺癌的空间异质性，整合单细胞转录组（Single-cell RNA sequencing，scRNA-seq）数据，通过细胞类型反卷积算法，精确解析了 ST 样本中每个空间域的细胞类型组成；依据细胞类型的空间分布模式，鉴定 ST 样本中不同的功能区域。进一步，通过区域间的基因表达差异分析，识别出每个区域特异性高表达的基因集合；通过对这些区域特征基因集进行基因本体论（Gene Ontology annotation，GO）[18]与京都基因与基因组百科全书（Kyoto Encyclopedia of Genes and Genomes，KEGG）[19]功能富集分析，最终从功能学层面揭示了乳腺癌不同空间区域的生物学功能。

3) 构建乳腺癌预后模型

本论文基于乳腺癌数据，通过细胞空间共定位分析识别出 T 细胞与 B 细胞聚集的三级淋巴结构（Tertiary Lymphoid Structures，TLS）区域。通过比较 TLS 与非 TLS 区域的差异表达基因，筛选出 TLS 核心特征基因，并进一步结合单因素 Cox 和 LASSO-Cox 构建基因风险评分模型。随后，采用 Kaplan-Meier 生存分析、时间依赖性 ROC 曲线以及多因素 Cox 分析对模型进行验证。不仅揭示了乳腺癌 TLS 的关键分子特征，同时为临床生存风险评估提供潜在工具。

1.3 技术路线

本论文的技术路线如下图 1-1 所示。

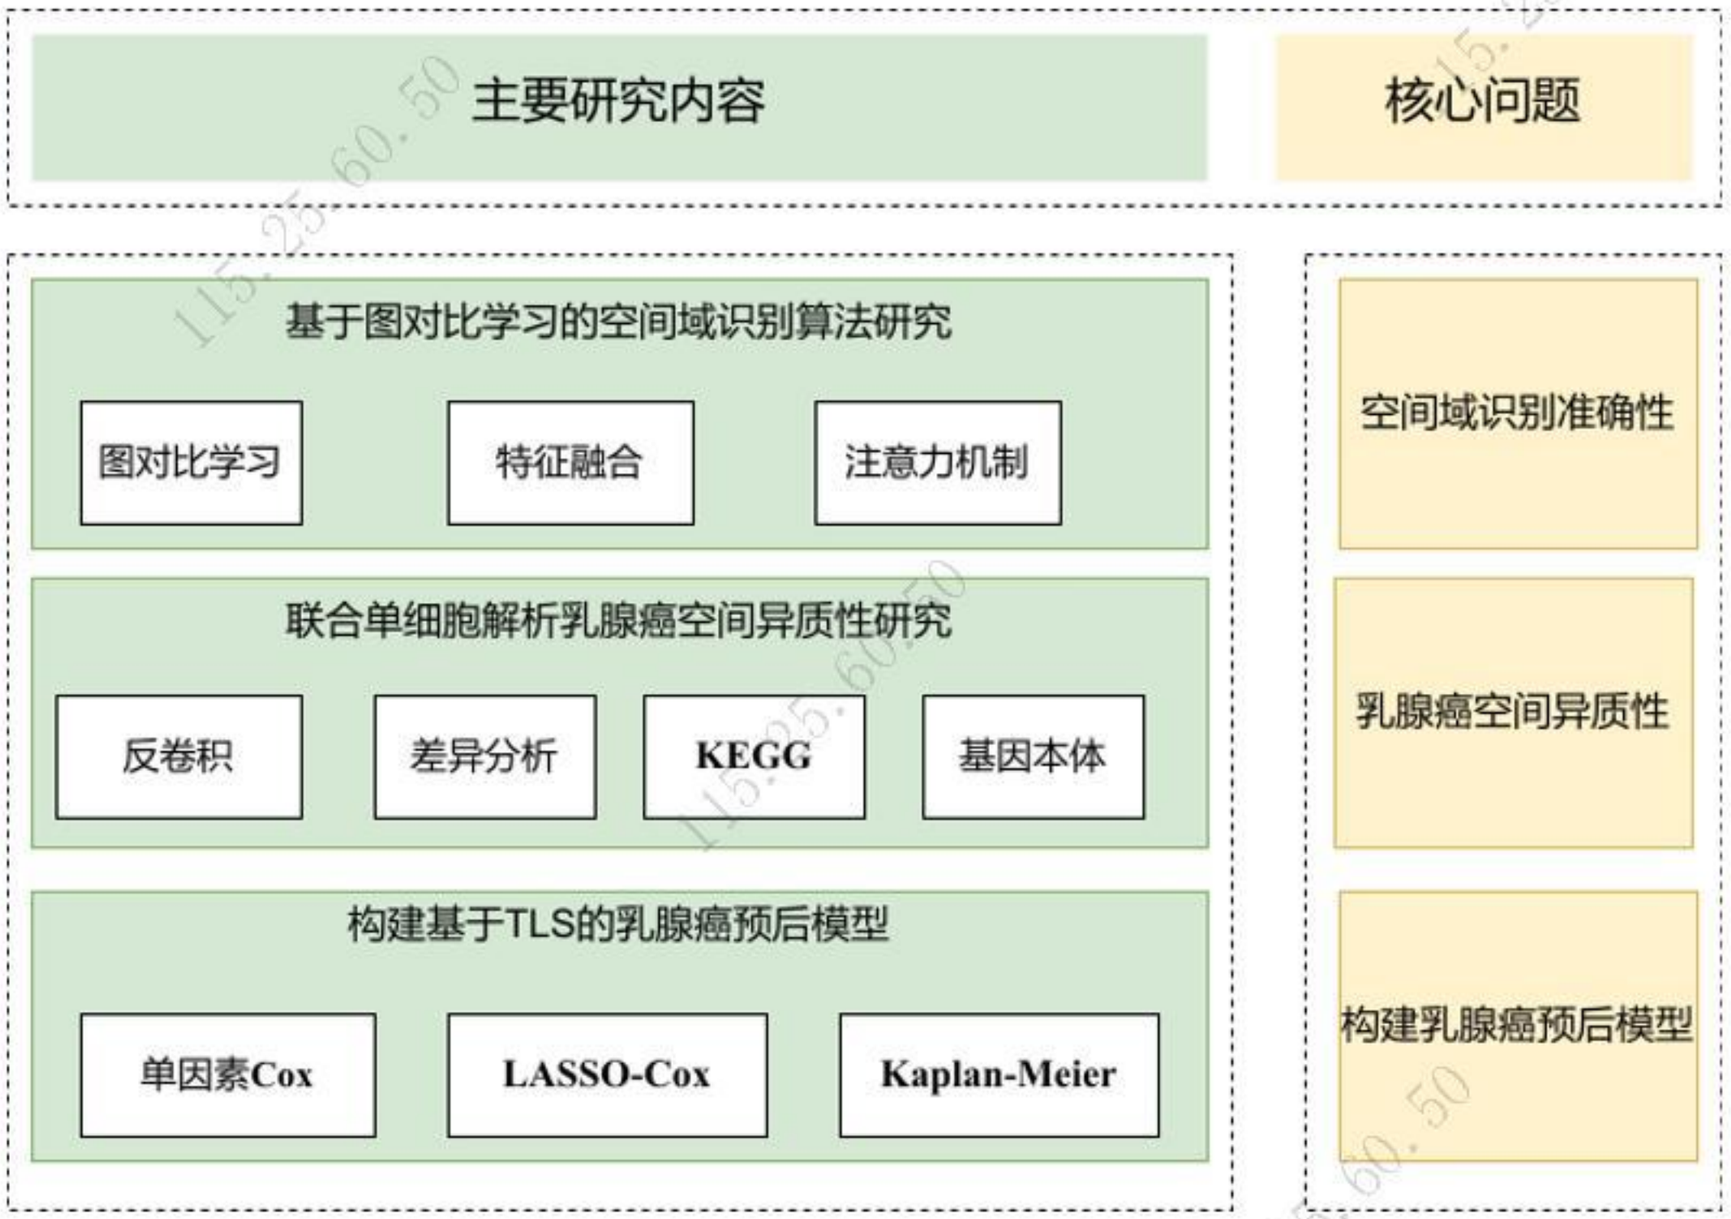


图 1-1 技术路线

Fig.1-1 Experimental Design and Workflow

本论文首提出了一种基于图对比学习的空间域识别算法 SpaGCL，在基因表达特征提取上，通过构建以基因表达余弦相似度作为边权重，实现了图对比学习的自适应增强。同时，采用 Barlow Twins 自监督学习模型从组织切片图像中提取形态学特征，并引入交叉注意力机制，实现了基因表达特征与组织学图像特征的双模态自适应融合。为验证算法的有效性，在三个空间转录组平台（10x Visium、Stereo-seq 和 Slide-seqV2）共五个真实数据集上进行了系统评估，这些数据集涵盖了健康组织与肿瘤组织等多种组织类型。与 SCANPY[20]、SpaGCN、SEDR、DeepST、STAGATE 和 GraphST 六种现有空间域识别算法的比较结果表明，该方法在空间域识别准确性方面具有显著优势，充分证明了其有效性和先进性。

接下来，在精确识别乳腺癌组织空间域的基础上，本论文进一步联合单细胞转录组数据集 GSE176078，以深入解析其空间异质性。本论文首先运用 Cell2location 算法对空间转录组数据进行细胞群体反卷积，精确量化了每个 spot 点的细胞组成。随后，结合病理学注释将已识别的空间域划分为肿瘤核

心区域与肿瘤边缘区域，并分别对这两个功能区域的不同分区进行基因表达差异分析。通过对区域差异表达基因进行 KEGG 通路与基因本体（GO） 富集分析，系统揭示了肿瘤核心与边缘区域各自独特的关键生物学功能，从细胞组成和分子功能两个层面深化了对乳腺癌空间异质性的理解。

最后，本论文基于识别的 TLS 区域进行基因差异分析。共获得 184 个 TLS 特征基因，经过 KEGG 和 GO 功能注释证实其显著富集于免疫相关通路。利用 GSE1456 乳腺癌队列，通过单因素 Cox 回归和 LASSO-Cox 回归从中筛选出 13 个与总生存期显著相关的关键基因，有 6 个基因在既往研究中已被证实与乳腺癌预后密切相关。基于这些基因构建的风险评分模型，经 Kaplan-Meier 分析、时间依赖性 ROC 曲线和 C-index 验证表现出良好的预后预测效能，多因素 Cox 回归分析进一步证实，该风险评分模型是独立于其他临床因素的预后标志物。

1.4 论文的组织结构

本论文共包含七个章节，具体内容如下：

第一章是绪论部分。该部分介绍了空间域识别的研究背景和意义。

第二章介绍了现有空间域识别算法的基本原理，分析了不同方法的优势与局限性，并进一步阐述了 SpaGCL 算法所涉及的相关理论基础及评价指标。

第三章重点介绍 SpaGCL 算法的整体框架与具体实现过程，同时对实验设计与评估方案进行了详细说明。

第四章联合运用单细胞与空间转录组技术系统性地揭示了乳腺癌的空间异质性。通过 Cell2location 工具对乳腺癌数据集进行细胞类型反卷积，构建了细胞在组织原位的精准分布图谱，并结合细胞标志基因表达及 KEGG 和 GO 功能富集分析,阐明不同空间域细胞群体的生物学功能，系统揭示了乳腺癌的空间异质性。

第五章围绕构建乳腺癌预后模型展开。首先通过基因表达差异分析从 TLS 区域获得候选基因，随后结合单因素 Cox 分析初筛潜在预后因素，采用 LASSO 回归构建风险评分模型。模型性能通过 Kaplan-Meier 生存分析和时间依赖性 ROC 曲线验证，确定模型在患者风险分层与预后的有效性。

第六章是总结与展望。

2 文献综述及相关理论基础

目前，空间域识别算法大致可分为两种类型：非空间感知空间域识别算法和空间感知空间域识别算法。非空间感知识别算法，如 SCANPY[20]和 Seurat[11]等算法仅利用基因表达谱，未使用空间坐标约束，导致识别出的空间域边界模糊、连续性差。检测到的空间域与组织解剖结构之间存在差异，不能准确地反映真实的组织结构。为了更好地利用 ST 数据中的空间位置信息，研究人员开发了多种空间感知空间域识别算法。空间感知空间域识别算法根据技术的不同又分为基于概率统计、图神经网络以及图对比学习的空间域识别算法。

2.1 基于概率统计的空间域识别算法

该类算法基于概率统计框架，通过统计空间位置上相邻 spot 点之间的基因表达相关性，对具有空间连续性的组织区域进行推断和识别。以 BayesSpace 为代表，该方法是一种贝叶斯统计方法，它基于“空间相邻 spot 在基因表达上更为相似”的先验假设，在模型中为邻近 spot 分配更高的先验概率，在聚类时往往将空间上相邻的 spot 分到同一类，以保证空间区域的连续性。该方法在一定程度上提升了基因表达谱的分辨率，但其适用范围主要局限于 10X Visium 平台的数据集。另一类方法如 Giotto[21]，使用隐马尔可夫随机场模型，通过在目标函数中引入相邻 spot 之间的一致性约束，使得空间上相邻 spot 更倾向于被划分到同一空间域，从而实现对 spot 之间空间依赖关系的刻画。这很好地反映了基因的空间连续性。然而，这类算法的性能有限且无法捕获基因表达在高维特征空间中的复杂非线性模式。此外，这些方法在处理大规模 ST 数据时的性能仍然受到限制。

2.2 基于图神经网络的空间域识别算法

尽管基于概率统计的方法可以将 spot 划分为不同的空间域，但这些方法通常依赖于预先设定的统计规则和相似性计算方式，当基因表达模式或空间结构较为复杂时，这些固定规则往往难以灵活应对，从而影响方法的适用范围和效果。相比之下，基于图神经网络(Graph Neural Networks, GNN)的算法能够在保留局部数据结构的同时，有效学习空间邻近关系，更能准确地捕获和解析组织中复杂的空间特征，在空间域识别方面表现出色。

基于 GNN 技术的空间域识别算法将 ST 中的 spot 看作图数据结构中的节点，通过构建图的边来表示 spot 点之间的空间关系。常用的图构建方法包括基于距离的方法、基于相似性的方法和基于生物学知识的方法等。该方法考虑 ST 中的空间信息，可以更好地解释 spot 点间的空间依赖性。stLearn[22]提出了一种空间形态基因表达归一化算法。该算法从组织学图像中提取纹理、形状和结构特征计算形态距离，并将其与空间位置信息融合，用于调整基因表达水平。这种方法能够增强相邻 spot 的表达一致性。但其固定的融合策略对不同平台或组织类型的适应性有限。SEDR[23] 通过深度自动编码器和变分图自动编码器联合学习基因表达与空间位置信息，在刻画复杂空间模式方面表现优于统计模型，但其参数规模较大，对数据量和噪声较为敏感。DeepST[24]通过整合组织形态特征、基因表达谱和空间位置三种数据类型构建增强型特征向量，并利用变分图自编码器引入空间约束生成高维嵌入表示，增强了细胞特性及相互关系的精确表达。与 SEDR 相比，DeepST 在多模态信息整合上更具优势，但其模型复杂度较高，训练成本较大。SpaGCN[25] 是一种通过图卷积模型识别空间域的算法。该算法通过构建加权的无向子图来解释空间依赖性，然后将子图和基因表达输入图卷积模型生成 spot 的嵌入表示从而实现空间域的识别。SpaGCN 提高了空间域识别的准确性，并能够直观解释空间依赖关系，但其性能在数据稀疏或空间分辨率较低的情况下可能下降。

STAGATE 通过将基因表达数据与 spot 的空间邻接关系同时纳入图注意力自编码器中，学习能够反映空间结构的低维表示。注意力机制使模型能够自动为不同邻近 spot 的赋予不同的重要性，从而更准确地描述 spot 之间的依赖关系。结合针对 10x Visium 数据设计的预聚类模块，STAGATE 在低分辨率空间转录组数据的空间域识别中表现出较好的效果。尽管上述方法在空间域识别方面取得了一定进展，但如何在充分利用空间信息的同时，引入更强的判别约束以增强不同空间域之间的区分能力，仍是空间域识别方法需要进一步解决的问题。

2.3 基于图对比学习的空间域识别算法

近年来，对比学习（Contrastive Learning，CL）提高了计算机视觉技术中自监督学习的性能[26-28]。图对比学习（Graph Contrastive Learning，GCL）是 CL 在图数据上的扩展，其针对图数据的特点设计了正负样本构建和相似度度量策略。，GCL 将图的拓扑结构融入样本构建和编码器训练，使得学习得到的节点或子图表示同时保留了特征信息和图结构信息。

目前，在空间转录组分析中，已有多种基于 GCL 的方法，CCST 利用最大化互信息原理，通过对原始图进行随机扰动生成损坏图，并采用对比学习优化编码器，使节点嵌入在面对噪声和缺失数据时保持鲁棒性，同时提升下游空间聚类任务的性能。SpaceFlow[29]将深度图神经网络与对比学习结合，通过在编码器训练过程中随机置换空间表达图生成负样本，有效捕获局部和非局部的空间依赖关系。GraphST 则将对比学习与图神经网络联合应用，通过结合节点的空间位置信息与基因表达相似性构建图，利用对比学习增强嵌入表示，从而生成信息量更丰富、空间关系更准确的 spot 表示，实现高精度的空间聚类。

然而，在分析非局部空间基因共表达模式的复杂组织时，上述方法存在局限。为此，Zhang 等人提出 MuCoST，一种基于多视图图对比学习的框架，用于解析复杂的空间转录组数据。MuCoST 通过共享的多视图 GCN 自动编码器结合对比学习损失，整合基因表达相关性与空间邻近性，有效捕获非局部共表达依赖，实现高精度的空间域识别。

stCluste[30]通过图对比学习和多任务策略相结合的方式提高空间域识别的准确性。它首先使用图对比学习来获取 spot 的低维嵌入，然后采用多任务协作模型同时优化基因表达重建、空间邻接图重建和深度嵌入聚类任务来进一步优化生成的低维，以此来更好地结合基因表达和空间位置信息。另外这个算法还通过降低空间基因表达数据中的噪声来提高空间轨迹分析的精度。

然而，这些方法在数据增强过程中通常采用随机删除边或节点、掩盖节点嵌入或依赖预设规则来扰动图结构。对于空间转录组数据而言，图中的边代表 spot 之间的实际生物关系，随机操作会破坏这些生物关系，因此需要设计能够保留生物信息的增强策略。

2.4 图注意力 GAT

与传统图卷积网络（Graph Convolutional Network，GCN）使用固定权重进行邻居聚合不同，图注意力网络（Graph Attention Network，GAT）通过引入可学习的自注意力机制，为每个邻居动态分配可学习的权重，实现差异化、自适应性聚合[31]。这些注意力系数的计算不依赖于图的全局结构信息，而是通过一个可训练的线性变换和激活函数来实现，使得模型能够根据节点特征本身的内容，动态地分配聚合权重。在介绍注意力网络前，本论文先补充下图卷积网络相关知识。

GCN 模型包含输入层、多个隐藏层与输入层，模型结构如图 2-1 所示。

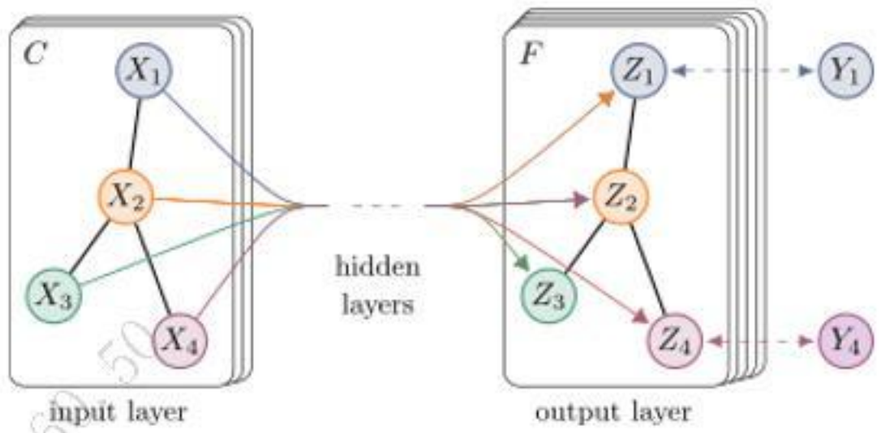


图 2-1 GCN 模型示意图

Fig.2-1 GCN Model Schematic Diagram

GCN 通过聚合节点自身特征与邻居特征完成更新。具体而言，各层节点特征按当前自身特征加邻居加权平均规则同步更新，以生成下一层的新特征表示。GCN 的传递函数如公式(2-1)所示：

$$X^{l+1}=\sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}X^{l}W^{l}\right)=\sigma\left(\hat{A}X^{l}W^{l}\right) \tag{2-1}$$

其中，X^{l+1} 表示 $l+1$ 层的节点特征表示。X^{l} 表示第 l 层的节点特征表示。σ 是非线性激活函数。$\tilde{A}=A+I$ 表示每个节点都添加自环后的图邻接矩阵。$\tilde{D}$ 是 $\tilde{A}$ 的度矩阵。其中，$\hat{A}=\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}$ 表示对 $\tilde{A}$ 进行对称归一化操作，$\hat{A}$ 表示了特征如何在每一层上进行混合以得到下一层的表示。GAT 的模型架构则如图 2-2 所示。

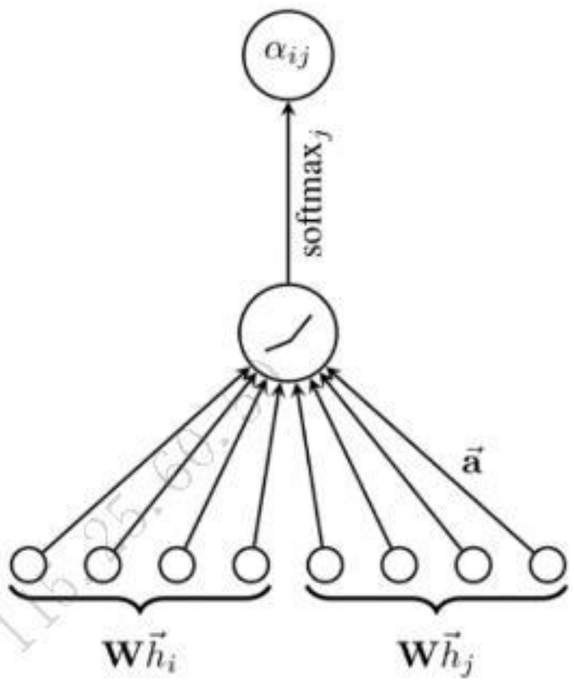


图 2-2 GAT 模型示意图

Fig.2-2 GAT Model Schematic Diagram

接下来，介绍下如何计算注意力系数，节点对 (i,j) 之间的注意力值 e_{ij} 如公式(2-2)所示：

$$e_{ij} = a\left(W\vec{h}_i, W\vec{h}_j\right) \tag{2-2}$$

其中，$\vec{h}_i, \vec{h}_j$ 分别表示节点 i 和节点 j 的特征表示，$W \in R^{F' \times F}$ 是一个共享的线性变换。该操作对所有节点的特征向量施加一个共享的线性变换，其功能在于将特征映射到更高维度的空间，这属于一种常见的特征增强手段，旨在提升模型的表达能力。$a()$ 是一个映射函数，负责把增强后的两个特征向量映射到一个实数。e_{ij} 则表示特征的重要性。通过 LeakyReLU 函数进行计算，具体计算如公式(2-3)所示：

$$e_{ij} = \text{LeakyReLU}\left(\vec{a}^T \left[W\vec{h}_i W\vec{h}_j\right]\right) \tag{2-3}$$

其中，||表示拼接操作。完成拼接操作得到两个样本之间的系数之后，就需要对邻居样本信息进行融合。再对融合后数值进行归一化操作。其中，k 表示节点 i 的所有邻居节点。如公式(2-4)所示：

$$a_{ij} = \text{softmax}_j\left(e_{ij}\right) = \frac{\exp\left(e_{ij}\right)}{\sum_{k \in N_i} \exp\left(e_{ik}\right)} \tag{2-4}$$

最后，完整的注意力如公式(2-5)所示：

$$a_{ij} = \frac{\exp\left(\text{LeakyReLU}\left(\vec{a}^T \left[W\vec{h}_i W\vec{h}_j\right]\right)\right)}{\sum_{k \in N_i} \exp\left(\text{LeakyReLU}\left(\vec{a}^T \left[W\vec{h}_i W\vec{h}_j\right]\right)\right)} \tag{2-5}$$

在获得所有节点的注意力系数后，将其与对应的节点特征进行加权组合，随后通过非线性激活函数处理，从而生成节点的新特征表示。新特征表示如公式(2-6)所示：

$$\vec{h}_i' = \sigma\left(\sum_{j \in N_i} a_{ij} W\vec{h}_j\right) \tag{2-6}$$

2.5 图对比学习 GCL

近年来，图对比学习（Graph Contrastive Learning，GCL）作为一种自监督表示学习范式引起人们广泛关注，作为一种无需标签的学习方法，它能够直接利用样本自身的信息来指导模型，从而学习到区分度较高的特征表示。其核心目标是训练一个或多个编码器，使来自相同图或子图的表示尽可能接

近，而来自不同图实例的表示保持较大差异。在实践中，模型通过构建正样本对和负样本对，并使用互信息或其他度量指标来衡量表示之间的一致性，从而优化编码器的参数。通过这种方式，GCL 能够在无需人工标注的情况下，生成鲁棒且判别性强的图表示，为图数据的下游任务提供可靠特征。

在图对比学习框架中，模型的核心目标并非捕捉样本的细粒度细节，而是学习能够区分不同样本的判别性特征。在图对比学习模型所构建的特征空间中，属于同一类别的样本其特征表示趋于相近，而不同类别的样本其特征表示则具有明显的差异性。

图对比学习算法有三个关键步骤：第一，正负样本的选择。传统的对比学习算法将样本自身通过数据增强来得到一对正样本，并将其他样本作为负样本。数据增强旨在保持语义标签不变的前提下，通过施加特定转换来生成合理且多样化的新数据样本。对于图像和文本来说，数据增强有很多种方式，然而对于图数据来说，图数据的非欧几里得特性使得在图上进行数据增强并不容易。第二，编码器的构建。根据数据类型的不同，可以采用不同深度神经网络结构作为对比学习的编码器。第三，对比损失的选择。对比损失的目的是增强正样本嵌入之间的相似性，降低负样本间的相似性。对比学习的损失函数的目的主要在于使得模型可以更好地区分正负样本，常用的对比损失有三元组损失、边际对比损失、中心损失、InfoNCE 损失等。

在图对比学习中，数据增强可以分为基于启发式和基于学习两大类。GraphCL[32]论文中提出了四种启发式数据增强方法，如下图 2-3 所示。

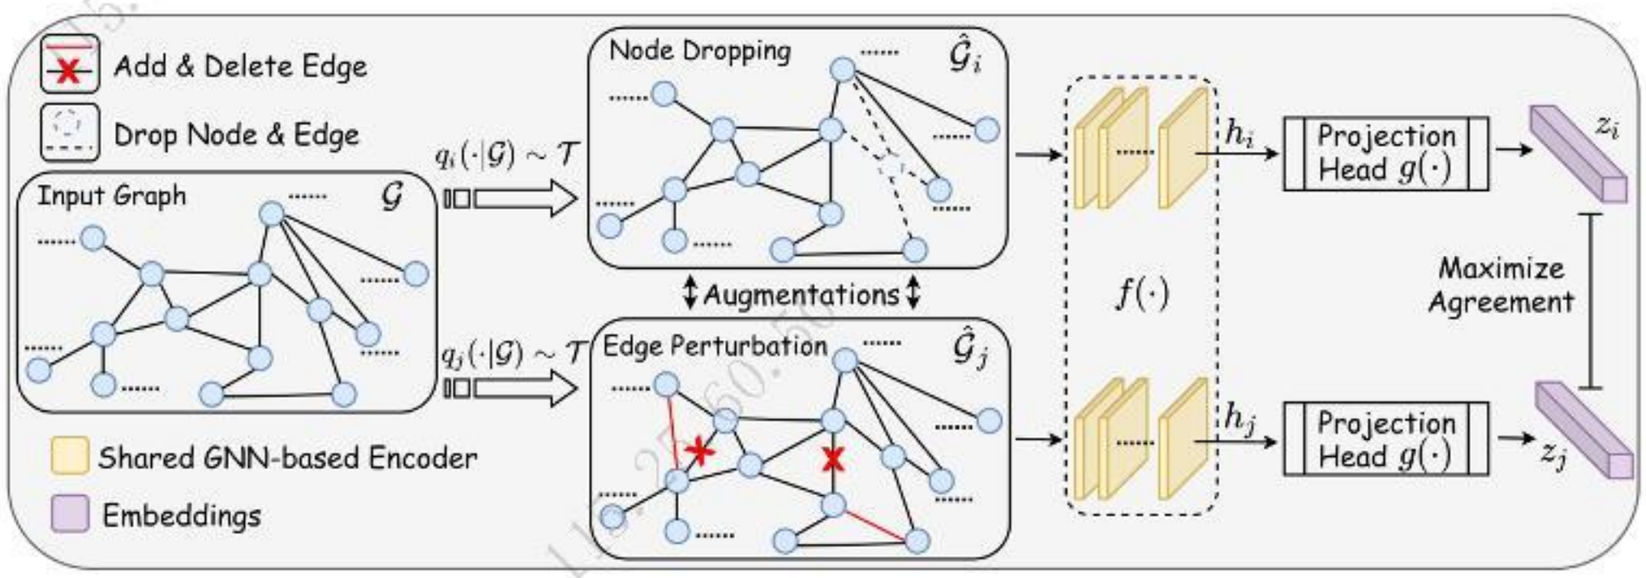


图 2-3 GraphCL 模型框架示意图

Fig.2-3 GraphCL model framework diagram

节点属性掩码(Node feature masking，NFM)：该方法通过随机地按一定比例将部分节点的特征置成零或随机值。具体来说，给定输入的节点属性矩阵 X，节点属性掩码表示如公式(2-7)所示：

$$T_X^{(mask)}(X) = X*(1-I_m)+M*I_m \tag{2-7}$$

其中，符号*表示逐元素相乘运算，M 表示掩码矩阵，I_{m} 表示掩码位置矩阵。给定掩码比例参数 γ，I_{m} 中的元素以概率 γ 设置为 1，以概率 $1-\gamma$ 设置为 0。

节点丢弃：对于给定图 G，遵循某种分布概率随机丢失一定比例的节点及边。这背后的假设是认为丢弃部分节点并不会影响图 G 的语义。

随机边扰动（Edge modification，EM）该方法作用于邻接矩阵，属于结构增强。通过在给定的图上随机增加或删除一定比例的边来实现拓扑结构增广。

子图采样：使用均匀采样、基于随机游走或基于 top-k 重要性等方法从给定的图中提取子图，要求提取的子图最大程度上保留了原图的语义特征。

给定一个输入图 $\mathsf{G}=(\mathsf{A},\mathsf{X})$，基于采样的增强同时对邻接矩阵 A 和特征矩阵 X 进行增强。

均匀采样：默认所有节点具有同等的重要程度，给每个节点分配了相同的丢弃概率。

重要性采样：对于给定结点，按照其邻居的重要性进行采样一个子图，重要性得分矩阵记作：

随机游走采样则从图中选择一个起始节点，随后开始在图上进行随机游走。游走以与边权重成正比的概率迭代地前往其邻域。此外，在每一步以正概率 α 返回到起始节点。最后，被访问的节点则被纳入一个节点子集中。

启发式图数据增强往往需要经过大量的实验，才能针对给定的数据集挑选出合适的数据增强方法。Zhu 等人在此基础上进一步提出自适应数据增强算法 GCA[33]，根据节点的中心性指标为每个节点分配了相应的重要度。如度中心性、特征向量中心性和 PageRank 中心性，这一过程确保了关键节点的特征得到保留，不会被随机掩码。同时，对于那些重要性相对较低的节点，算法赋予了更高的掩码概率，以促进模型对关键信息的学习和提取而避免了过多的人工干预。针对这些问题，学者们设计了多种不同的图数据增强。

负样本曾一直被认为是对比学习中不可或缺的，如果没有负样本就会引起模型的坍塌，即所有样本都学习到相同的表示。近年来，研究者提出了一类无需显式构建负样本对的模型，从而摆脱了对负样本的依赖。

图对比视图按粒度从粗到细可以分为全局、子图级和节点级。相应地，对比学习模式可以分为同尺度对比和跨尺度对比两类。同尺度对比分为全局、子图和节点三类。跨尺度对比分为节点-全局、节点-子图和子图-全局三类。

最后是损失函数，下面介绍下对比学习中常用的损失函数。

信息论对比损失 InfoNCELoss[34]是比较常用的损失函数，具体如公式(2-8)所示：

$$L=-\frac{1}{2N}\sum_{i=1}^{N}\log\frac{\exp\left(\mathrm{sim}\left(z_i,z_{i+}\right)/\tau\right)}{\exp\left(\mathrm{sim}\left(z_i,z_{i+}\right)/\tau\right)+\sum_{j=1}^{K}\exp\left(\mathrm{sim}\left(z_i,z_{j-}\right)/\tau\right)} \tag{2-8}$$

其中，z_i 表示第 i 个样本的特征表示，z_+ 代表正样本，z_- 代表负样本。sim(x，y)表示样本 x 和 y 之间的相似性得分，τ 表示温度系数，是一个用于调节模型对正负样本判别强度的超参数。如果温度系数τ 过大，模型对样本间差异的敏感度会降低，导致难以有效区分负样本，从而削弱其表征学习能力；若τ 取值过小，模型会过度聚焦于难以区分的困难负样本，导致泛化性能下降与训练过程不稳定。因此，设合适的温度系数对模型的性能是至关重要的。

在空间转录组学研究中，InfoNCE 损失函数通过对比学习策略引导模型识别细胞微环境的结构特征。其核心机制是：当空间点位 spot 的基因表达特征与相邻同类型点位不相似，且与不同功能区域 spot 点高度相似时，损失函数值显著增大，从而驱动模型参数优化。这一过程促使模型学会区分具有生物学意义的空间域——通过强化正样本对，即相邻同类型点位的特征一致性，同时扩大其与不同功能区域 spot 点的表征差异，最终获得能精准反映组织功能分区的高判别性特征表示。

除了基于互信息的损失函数之外，传统的损失函数同样可以应用于对比学习任务。例如，均方误差（Mean Squared Error，MSE） 损失函数能够在不依赖负样本的情况下，通过直接缩小正样本对在特征空间中的距离，实现同类样本的特征对齐，从而在避免构建负样本可能引入偏差的同时，有效提升类内特征的相似性。MES 损失函数的定义如下列公式(2-9)所示：

$$L_{MSE}=\frac{1}{2}\left(D\left(p_1,z_2\right)+D\left(p_2,z_1\right)\right) \tag{2-9}$$

其中， D 的表达式如公式(2-10)所示：

$$D\left(p_1,z_2\right)=-\frac{p_1}{\|p_1\|_2}\cdot\frac{z_2}{\|z_2\|_2} \tag{2-10}$$

上述计算过程对不同的正样本特征进行 L2 正则化处理后，再计算其特征间的距离，通过最小化特征间距离以实现模型优化。

此外，在某些复杂场景下，仅依赖 InfoNCE 损失函数可能难以获得理想的学习效果。因此，实践中常采用多种损失函数混合的策略来提升模型性能。

例如，将交叉熵损失学习和 InfoNCE 损失学习结合、对抗损失和 InfoNCE 损失相结合，均被证明能有效增强对比学习的表达能力和鲁棒性。

2.6 无负样本的图对比学习 Barlow Twins

大多的图对比学习模型都需要负样本，负样本的质量和数量对图对比学习结果影响很大。为了解决这一问题，研究者提出了无负样本的图对比学习。本节将介绍一种经典的无负样本的图对比学习方法。

Barlow Twins 是一种基于信息论的自监督学习方法[35]。样本图片 X 经过两个不同的数据增强分别得到增强视图 Y^A 和 Y^B，然后将增强视图输入到两个权重共享的神经网络 f_θ，得到对应的特征表示 Z^A 和 Z^B，然后计算特征表示 Z^A 和 Z^B 的交叉相关矩阵 C。模型框架图如图 2-4 所示。

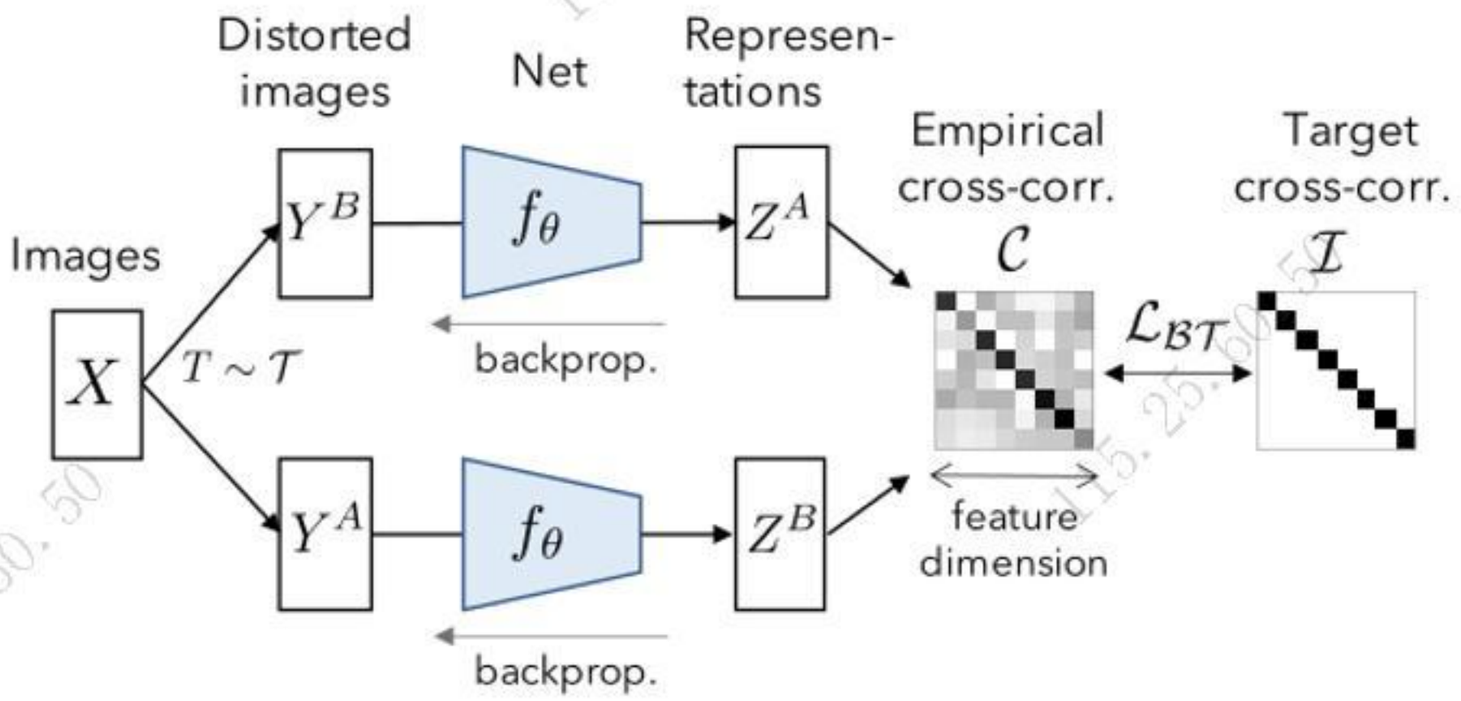


图 2-4 Barlow Twins 模型框架图

Fig.2-4 Barlow Twins Model Architecture Diagram

Barlow Twins 的损失函数 L_{BT} 表示如公式(2-11)所示：

$$L_{BT} \triangleq \sum_i (1-C_{ii})^2 + \lambda \sum_i \sum_{j \neq i} C_{ij}^2 \tag{2-11}$$

其中，$\sum_i (1-C_{ii})^2$ 表示不变性项，C_{ii} 越接近 1 损失值越小，代表相同位置的特征表示在不同的增强视图下高度相关。$\lambda \sum_i \sum_{j \neq i} C_{ij}^2$ 则表示冗余减少项，C_{ij} 越接近 0 损失值越小，代表不同位置的特征表示经过不同的增强视图没有冗余。C_{ij} 被称为交叉相关矩阵，用于衡量不同增强视图下神经元之间的相关性。其公式(2-12)表示如下：

$$C_{ij} = \frac{\sum_b z_{b,i}^A z_{b,j}^B}{\sqrt{\sum_b \left(z_{b,i}^A\right)^2} \sqrt{\sum_b \left(z_{b,j}^B\right)^2}} \tag{2-12}$$

其中，$z_{b,i}^A$ 表示样本 b 在增强视图 A 中第 i 个特征表示，$z_{b,j}^B$ 则表示样本 b 在增强视图 B 第 j 个特征表示。

2.7 空间域识别算法的评估指标

调整兰德指数（Adjusted Rand Index，ARI）是评估空间域识别准确性的常用的外部指标。ARI 通过衡量样本在算法聚类与人工标注两种划分中归属的一致性，对聚类效果进行客观评价。a 为在真实组织标注和算法预测中均属于同一空间域的点位对数量，b 为在真实组织标注和算法预测中均属于不同空间域的点位对数量，则兰德指数（Rand Index，RI）计算如公式(2-13)所示：

$$RI = \frac{a+b}{L_2^{n_{samples}}} \tag{2-13}$$

其中，$L_2^{n_{samples}}$ 是数据集中可能的样本对的总数。

然而，当聚类结构中的空间域数量接近样本总量时，随机聚类所产生的兰德指数可能无法趋近于零，从而影响其作为评估指标的判别能力。为克服此局限性，调整兰德指数（ARI）被指出，它通过引入随机模型下的期望值对 RI 进行校正，从而有效降低随机因素的影响，提升对聚类结果的区分度。ARI 的计算公式如(2-14)所示：

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]} \tag{2-14}$$

其中，RI 是兰德指数，max(RI)、E[RI]分别是兰德指数 RI 的最大值和期望值。

假设 n 是 ST 数据集中的位点个数。$U = \{u_1, u_2, \ldots u_R\} \epsilon \mathbb{R}^n$ 和 $V = \{v_1, v_2, \ldots v_C\} \epsilon \mathbb{R}^n$ 分别表示 n 个位点的两个聚类标签，其中 R,C 分别为 U,V 的聚类数目。将同时属于类 u_i 和 v_j 的位点个数分别记作 n_i 和 n_j

ARI 的取值范围介于-1 到 1 之间。该指标为 0 作为随机划分的基准：负值意味着聚类结果比随机分配更差，即聚类结果与真实标签不相似；正值则

意味着优于随机分配，数据越接近 1 表明聚类效果越高。此外，调整兰德指数的计算不受比较的结果中簇顺序的影响。

归一化互消息[36]（Normalized Mutual Information，NMI）是另一种空间域识别算法评价指标。NMI 以信息论为基础，通过归一化的互信息评分消除类别数量偏差。NMI 的取值范围在$[0,1]$，数值越高，聚类效果越好。其具体计算公式表示如(2-15)所示：

$$NMI = \frac{2*I(A;B)}{H(A)+H(B)} \tag{2-15}$$

其中，A 为算法聚类结果，B 为真实标签划分，$I(A;B)$ 表示二者之间的互信息，计算方法如公式(2-16)所示：

$$I(A,B) = H(A)+H(B)-H(A,B) \tag{2-16}$$

此处 $I(A,B)$ 表示 A 与 B 的交叉熵，具体表示如公式(2-17)所示：

$$\begin{aligned} H(A) &= -\sum_{a} P_A(a)\log P_A(a) \\ H(B) &= -\sum_{b} P_B(b)\log P_B(b) \\ H(A,B) &= -\sum_{a,b} P_{AB}(a,b)\log P_{AB}(a,b) \end{aligned} \tag{2-17}$$

其中，$P_A(a)$、$P_B(b)$分别为 A 与 B 的概率分布，$P_{AB}(a,b)$为其联合概率分布。

轮廓系数（Silhouette Coefficient，SC）是一种内部指标，与 ARI、MNI 等外部指标不同，内部指标的计算不依赖于真实聚类标签，而是完全基于数据集自身的结构特征对聚类质量进行评估。轮廓系数 SC 通过评估 ST 数据集中 spot 点与其所属簇的紧密程度，以及与其他簇的分离度来评估聚类效果。该指标的取值范围为$[-1,1]$，数值越大，表示聚类结构越清晰，效果越好。具体计算公式(2-18)如下：

$$SC(i) = \frac{b(i)-a(i)}{\max\{a(i),b(i)\}} \tag{2-18}$$

其中，$a(i)$表示样本点i的内聚度，计算样本点i与标记为同一个聚类结果的其它样本点的平均聚类。具体计算方式如下(2-19)所示：

$$a(i)=\frac{1}{n-1}\sum_{j\neq i}^{n}distance(i,j) \tag{2-19}$$

其中，n表示同一簇中样本数据，j表示样本点i同一簇内其它样本点。$distance(\ )$函数则用来计算样本点之间的距离。所以$a(i)$值越小代表该聚类结果中的样本点之间越紧密。$b(i)$表示样本点i的最小跨簇距离，即$mix(b_1(i),b_2(i),\ldots,b_n(i))$。如果$a(i)<b(i)$表明簇内距离小于簇间距离，样本点被正确划分，聚类效果良好，此时$S(i)$接近1；反之，若$a(i)>b(i)$，则说明簇内结构松散，聚类效果不佳，$S(i)$为负值。根据$a(i)$与$b(i)$之间的大小，公式(2-20)则变为：

$$S(i)=\begin{cases}1-\dfrac{a(i)}{b(i)} & a(i)<b(i)\\ 0 & a(i)=b(i)\\ \dfrac{b(i)}{a(i)}-1 & a(i)>b(i)\end{cases} \tag{2-20}$$

最终聚类结果的轮廓系数表示如公式(2-21)所示。

$$s=\frac{1}{n}\sum_{i=1}^{n}S(i) \tag{2-21}$$

戴维森堡丁指数（Davies-Bouldin Index，DB）是另一种内部指数，它则通过计算聚类结果之间的距离来评估算法的聚类性能。如公式(2-22)所示：

$$DB=\frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\left(\frac{avg(C_i)+avg(C_j)}{d_{cen}(C_i,C_j)}\right) \tag{2-22}$$

其中，$avg(C_i)$表示属于同一个簇内的样本点之间平均距离，如公式(2-23)所示：

$$avg(C_i)=\frac{2}{|C_i|(|C_i|-1)}\sum_{1\le m\le n\le|C_i|}dist(x_m,x_n),x_m,x_n\in C_i \tag{2-23}$$

其中，$d(C_i,C_j)$表示不同簇中心点之间的距离，u_i和u_j则表示簇的中心。如公式(2-24)所示：

$$d_{cen}\left(C_i, C_j\right) = \text{distance}\left(u_i, u_j\right) \tag{2-24}$$

2.8 本章小结

本章主要介绍了关于图对比学习相关理论知识、相关技术以及实验验证所要使用的评价指标，为下文的展开做铺垫。首先，本章介绍了图的相关定义、图表示学习及以图对比学习等概念。接着重点介绍了图对比学习所涉及的关键组件，如数据增强策略、负样本选择以及损失函数等。其次，还介绍了与本论文工作相关的无负样本的图对比学习方法。最后简要地介绍了实验中所使用的评价指标。

3 基于图对比学习的空间域识别算法研究

空间域识别是空间组学数据分析的核心基础步骤，不仅用于划分组织的结构与功能区域，也是开展细胞组成解析、微环境重构及空间互作研究的前提条件。高质量的空间域划分能够更真实地呈现组织内部的生物学差异，为后续分析提供可靠的空间框架。然而，现有空间域识别算法在空间连续性及多模态信息整合等方面仍存在局限，导致空间域划分的准确性受到影响。

为了解决上述问题，本论文开发了 SpaGCL 算法。该算法首先采用 Barlow Twins 对组织学图像进行特征提取，同时利用图对比学习获取基因表达特征；并以基因表达的余弦相似度作为边权重，从而实现图对比学习过程中的自适应增强。此外，引入交叉注意力机制，以实现图像特征与基因表达特征的自适应权重分配，从而更充分地整合多模态空间信息。为验证模型性能，本论文在来自三个空间转录组平台的五个真实 ST 数据集上对 SpaGCL 进行了系统评估，并与六种现有的空间域识别算法开展对比分析。

3.1 组织学图像特征提取

为了解决上述空间域识别准确性有限的问题，本论文提出了多模态空间域识别算法 SpaGCL。如图 3-1 所示，SpaGCL 由组织图像形态特征提取、基因表达特征提取以及模态特征融合三大模块构成，旨在单一模型中同时建模组织学形态信息与基因表达模式，从而提升空间域识别的鲁棒性与准确性。

在组织图像特征提取模块（图 3-1（a））中，本论文首先根据 spot 的空间坐标将整张组织切片分割为 n 个局部图像块。为了消除组织学图像中的噪声并获得稳定的 spot 级形态表征，本论文引入了 Barlow Twins 自监督学习框架，通过最大化同一 spot 图像不同增强视图之间的一致性来进行特征学习。具体而言，对每个图像块随机施加两次数据增强，包括水平翻转、颜色扰动、高斯模糊与曝光度调整，生成两个正样本视图。随后，使用 ResNet-50[37] 作为编码器提取深度特征，并利用两层感知机（Multi-Layer Perceptron，MLP）投影头获得潜在空间中的表示向量 Z^A 和 Z^B，通过冗余抑制损失鼓励特征解耦与共享信息最大化。最终，每个 spot 获得 2048 维特征，经 PCA 降维至 64 维形成形态特征矩阵 Z_j。

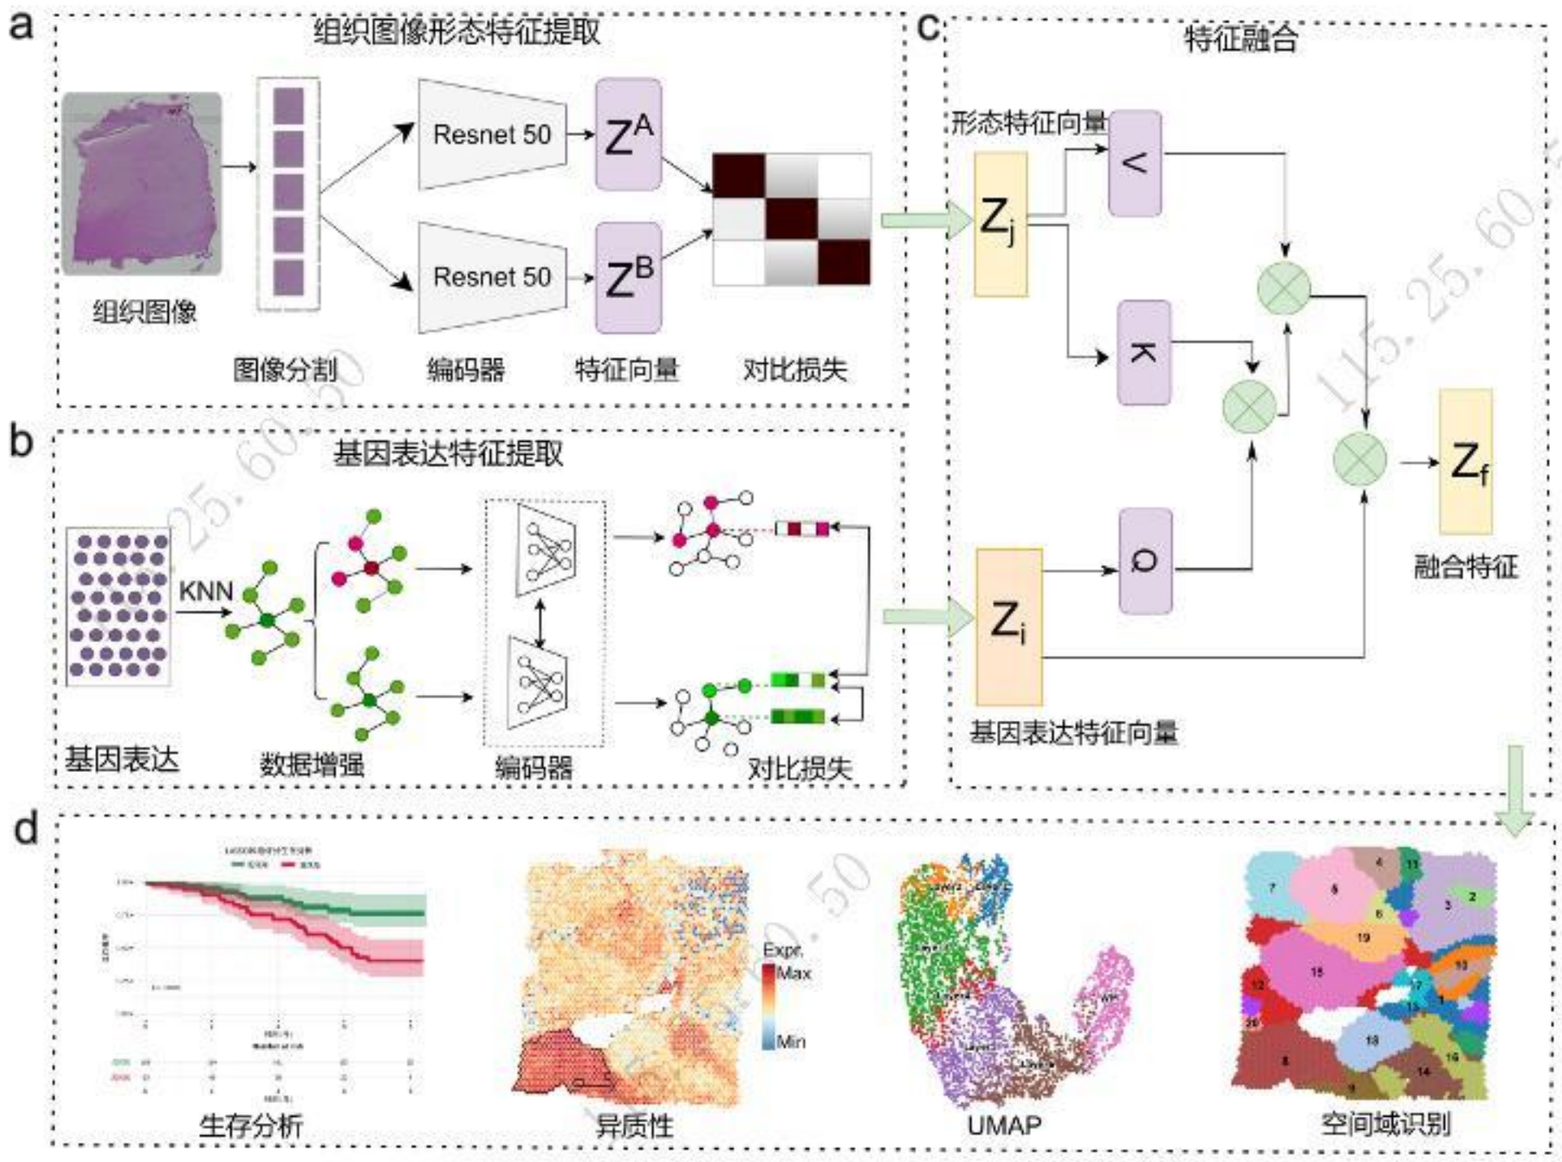


图 3-1 SpaGCL 整体框架流程图

Fig.3-1 Overview of SpaGCL

3.2 基于图对比学习的基因表达特征提取

在进行邻域图构建之前，本论文使用 SCANPY 软件包筛选出 3000 个高可变基因，并对这些高可变基因进行标准化处理，随后采用对数变换以进一步降低基因表达值之间的差异。

为了有效地整合 ST 数据中的基因表达信息和空间位置信息，同时抑制基因表达信息中的噪声干扰，本论文提出一种基于自注意力机制的自编码器框架学习特征嵌入并重建基因表达矩阵。该自编码器包括两部分：编码器 E_w 和解码器 $D_{w'}$。在构建自动编码器时，针对空间转录组数据通常包含多种细胞类型或具有局部结构差异的基因表达特征，本论文采用 GAT 来构建编码器。GAT 能够为不同的相邻节点分配不同的权重，从而有效克服噪声对基因表达特征的干扰，并有效地捕获节点之间的长距离依赖关系。

本论文采用两层 GAT 作为编码器 E_w。GAT 网络可以利用注意力机制为输入数据分配权重，这使模型能够提高关键特征的权重并减少不相关特征的权重。编码器 E_w 采用正则化邻接矩阵 $\tilde{A}$ 和预处理后的基因表达矩阵 X 作为

输入，并输出低维潜在嵌入表示 $Z=E_{\omega}\left(X,\tilde{A}\right),Z=\left\{z_1,z_2,\cdots z_N\right\}\subseteq R^{N\times F'}$，其中 N 表示 spot 节点个数， F' 表示 spot 节点的潜在嵌入表示维度,公式如(3-1)所示：

$$Z=E_{\omega}\left(X,\tilde{A}\right) \tag{3-1}$$

GAT 图层在获取 spot 节点之间的空间依赖关系和交互方面起着至关重要的作用。GAT 首先计算第 i 个 spot 节点的特征向量 h_i 通过线性变换 W，其次，GAT 通过注意力向量计算每个 spot 对的聚合权重，如公式(3-2)所示：

$$e_{ij}=\delta\left(\vec{a}^{T}W_{GAT}h_i\left\|W_{GAT}h_j\right.\right) \tag{3-2}$$

其中，e_{ij} 是 spot 对 (i,j) 的注意力分数，$\delta(\cdot)$ 是激活函数，而 $(\cdot\|\cdot)$ 是串联运算符。根据经验，选取 Sigmoid 函数作为激活函数。$\vec{a}$ 是图中每个 spot 点共享的可训练注意力向量，并且 W_{GAT} 是 GAT 的可训练特征提取矩阵。为避免过大的聚合权重，GAT 会按如下公式(3-3)对每个 spot 的聚合权重进行标准化：

$$a_{ij}=soft\max\left(e_{ij}\right)=\frac{\exp\left(e_{ij}\right)}{\sum_{k\in N(i)}\exp\left(e_{ik}\right)} \tag{3-3}$$

a_{ij} 是 spot 对 (i,j) 的注意力权重。最后，GAT 聚合邻接点和中心点的特征，如下公式(3-4)所示：

$$h_i^{(GAT)}=\delta\left(\sum_{j\in N(i)}a_{ij}W_{GAT}h_j\right) \tag{3-4}$$

其中，$h_i^{(GAT)}$ 是 spot 节点 i 的潜在表示，$N(i)$ 是 spot 节点 i 的相邻节点集合，a_{ij} 则是标准化的聚合权重。

解码器 $D_{W'}$ 以 Z 为输入，输出重建的基因表达矩阵 $H=D_{W'}(Z)$，$H=\left\{h_1,h_2,\cdots h_N\right\}\subseteq R^{N\times F}$。由于解码器的主要目标 $D_{W'}$ 是对原始数据进行重构，并不关注数据中的特征选择和提取，因此，本论文在解码器中直接使用两个全连接层，这与编码器结构中使用的 GAT 结构不同。在 $D_{W'}$，ELU 激活函数和批量归一化应用于除瓶颈层之外的所有隐藏层。

最后，在自编码器模块中，本论文采用均方误差损失函数 L_{RECON} 来计算

重建损失基因表达矩阵，可表示如下公式(3-5)：

$$L_{RECON} = \sum_{i=1}^{N} \| x_i - h_i \| \tag{3-5}$$

其中，x_i 和 h_i 分别表示 spot 的原始基因表达向量和重建基因表达向量。

本论文采用 InfoNCE 损失作为对比损失，如公式(3-6)所示：

$$L_{CON} = \frac{1}{N} \sum_{i=1}^{N} -\log \frac{\exp\left(\frac{\cos(h_i, pos_i)}{\tau}\right)}{\exp\left(\frac{\cos(h_i, pos_i)}{\tau}\right) + \sum_{j \in C_i^N} \exp\left(\frac{\cos(h_i, h_j)}{\tau}\right)} \tag{3-6}$$

其中，N 表示 spot 的数量，h_i 表示 spot 点的特征向量。pos_i 表示正样本的特征向量，C_i^N 是负样本的集合。

同时，SpaGCL 还考虑了重构损失，旨在重建。最后，SpaGCL 的损失函数定义如公式(3-7)所示：

$$L = L_{RECON} + \alpha L_{CON} \tag{3-7}$$

其中，α 是一个超参数，用于平衡重建损失和对比损失，本论文将其设置为 0.2。

3.2.1 基于基因表达相似性的数据增强

数据增强作为图对比学习中的一个关键步骤，其目的是在不影响样本语义的情况，通过一些方法来扩充样本数量。现有的随机删除边和节点或属性的数据增强策略往往会破坏基因间的语义。本文提出了一种基于 spot 基因表达余弦相似性的数据增强策略，具体计算如公式(3-8)所示：

$$a_{i,j} = \cos\left(h_i, h_j\right) \tag{3-8}$$

本论文使用不同的修剪概率修剪边缘来构建两个增强基因表达。超参数 c_k 表示修剪概率分别设置为 0.05 和 0.1。边修剪概率 c_{ij} 定义如公式(3-9)所示：

$$c_{ij} = \min\left(\frac{a_{max} - a_{ij}}{a_{max} - a_{mean}} \cdot c_k, r \right) \tag{3-9}$$

在此上下文中，a_{ij} 表示 spot 对之间的余弦相似度，而 a_{max} 和 a_{mean} 表示所有点对之间的最大和平均余弦相似度值。此外 r 是用于限制修剪速率的截断概率，采用默认值 0.7。根据不同的修剪概率，SpaGCL 生成两个损坏的图形，称为 viewU 和 viewV。

3.3 基于交叉注意力的特征融合

在特征融合模块（图 3-1（c））中，本论文提出了基于交叉注意力的多模态融合机制，实现形态特征与基因表达特征的自适应权重分配。具体而言，首先输入两种不同模态数据的特征 Z_i 和 Z_j，其中 Z_i 表示 H&E 图像特征，Z_j 表示基因表达特征，根据特征图计算 Q（Query 查询）、K（Key，键）和 V（value，值）三个矩阵。

$$M(Q,K)=\sigma\left(\frac{Q\cdot K^{T}}{\sqrt{d_k}}\right)^{T} \tag{3-10}$$

$$Z^{'}=\gamma\left(V\cdot M(Q,K)\right) \tag{3-11}$$

$$Z_f=Z^{'}+Z_i \tag{3-12}$$

其中，$\sqrt{d_k}$ 是根据 k 的维度的平方根，它是一个缩放因子，用于保持数字稳定性，γ 是一个可学习的参数，用于平衡注意力机制输出和原始输入的贡献，从而确保模型在信息融合时的灵活性和有效性。$\sigma(\cdot)$ 表示 softmax 函数，$M(\cdot)$ 是计算注意力权重的函数。

融合得到的特征 $Z^{'}$ 的每个位置不仅包含信息，还融合了 Z_j 的特征信息。$Z^{'}$ 通过一个可学习的缩放参数调整后，与 H&E 图像的特征 Z_i 相加，得到融合后的特征 Z_f。

3.4 聚类和可视化

在构建邻接矩阵时，邻居个数 k=5。编码器的输入、隐藏和输出维数分别设置为 3000，256 和 64。解码器的这些参数则分别为 64、256 和 3000。在对比数据学习模块中，τ 设置为 0.5。在训练过程中，采用 Adam 优化器，初始

学习率为 0.0001，最大训练次数为 100。

本论文采用聚类算法 mclust[38]将 spot 分配到不同的空间域中。mclust 是一种基于最大期望算法的聚类方法。它假设数据来自混合高斯分布，并通过最大似然函数确定最佳模型和聚类结果。聚类结果中的每个聚类都被视为一个空间域，包括表现出相似基因表达谱和空间接近性的点。具体而言，采用带有“EEE”方法的 mclust 版本 5.4.10 对低维潜在表示进行聚类。本论文采用工具 sklearn 来计算 ARI 和 NMI 两个外部指标。本论文中的箱形图由 Python 包 matplotlib 绘制。用于轨迹推理的均匀流形近似和投影（Uniform Manifold Approximation and Projection，UMAP）可视化图[39]和 PAGA[40]由 Python 包 SCANPY 生成。

3.5 实验结果与模型对比

3.5.1 数据来源

为了全面地评估算法 SpaGCL 的空间域识别效果，本论文选取了来自 10x Visium、Stereo-seq 和 Slide-seqV2 三个平台的五个真实数据集。

第一个 ST 数据集是人类背外侧前额叶皮层（dorsolateral prefrontal cortex ，DLPFC），该数据集来源于 10x Visium，分辨率为 55μm。该数据集由 12 个切片组成，每个切片的 spot 数量从 3460 个到 4789 个不等，基因数为 33538 个。Maynard 等人根据细胞学结构和遗传标记将切片划分为 5-7 个区域[41]。数据集下载地址：http://spatial.libd.org/spatialLIBD

第二个 ST 数据集为了评估具有更复杂空间结构的数据集中的空间聚类方法，本论文选取了来自小鼠脑组织的空间转录组数据。该数据集由 10x Visium 平台产生。冠状切片包含 2698 个 spot，具有 31053 个基因的表达数据。将来自 Allen Mouse Brain Atlas 的脑解剖参考注释 (https://mouse.brain-map.org/static/atlas）作为评估空间域识别结果的标准[42]。

第三个 ST 数据集是来自 Stereo-seq 平台的小鼠嗅球数据集。Stereo-seq 是一种基于 DNA 纳米球图案陈列的新型空间组学技术，可以实现亚细胞分辨率（～220nm）[43]。该数据集由 19109 个 spot 和 14367 个基因组成。以研究层状结构的鉴定。该数据集被注释为七个不同的皮质层。数据集下载地址：https://github.com/JinmiaoChenLab/SEDR_analyses/。

第四个是 Slide-seqV2 小鼠海马体数据集。Slide-seqV2 是一种高分辨率

空间转录组技术，可以在组织切片上同时捕获成千上万个基因的表达，并提供精准的空间位置信息[44]。该数据集包含 41786 个 spot 和 4000 个基因表达数据，是小鼠海马体样本的空间基因组数据，旨在揭示大脑中不同区域的基因表达谱与空间分布特征。可以通过命令 squidpy.datasets.slideseqv2()获取该数据集，该数据集包含了空间域的注释信息[45]。

第五个是人类乳腺癌数据集。该数据集在 10x Genomics Visium 平台上发布，对应于组织下检测到 3798 个点，每个点发现 6026 个中位基因。数据集下载地址 https://www.10xgenomics.com/resources/datasets/human-breast-cancer-block-a-section-1-1-standard-1-1-0。SEDR 的作者根据 H&E 图像和已知乳腺癌标志物基因的空间表达谱手动注释数据。本论文以该注释为标准。注释文件下载地址：https://github.com/JinmiaoChenLab/SEDR_analyses/blob/master/data/BRCA1/metadata.tsv。

3.5.2 SpaGCL 在 DLPFC 数据集上的定量评估

为了评估 SpaGCL 算法在空间域识别方面的准确性，本论文在 10x Visium 平台的 DLPFC 数据集上与六种空间域识别算法 SCANPY、SpaGCN、SEDR、DeepST、STAGATE 和 GraphST 进行比较。

如图 3-2 所示，在 DLPFC 数据集的 12 个切片上，SpaGCL 算法在 ARI 和 NMI 两个指标上均表现最佳，获得了最高的平均数。

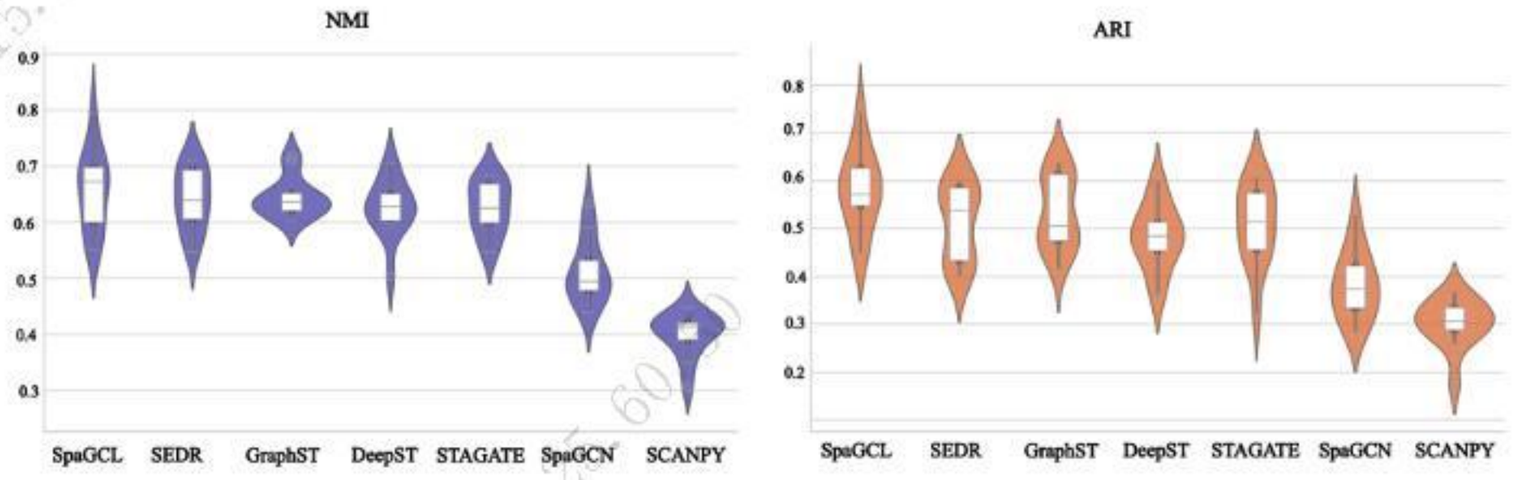


图 3-2 SpaGCL 和其他六种算法在 DLPFC 数据集上的 NMI 值和 ARI 箱线图

Fig.3-2 Boxplots of NMI and ARI for SpaGCL and Six Algorithms

这表明 SpaGCL 算法在识别 DLPFC 数据集中的空间域方面具有卓越的能力，能够有效地进行空间结构的捕捉和聚类。最值得注意的是，SCANPY 在两个指标上的表现最差，其 ARI 和 NMI 均为最低，表明其空间域识别效果不佳。SCANPY 是唯一未使用空间位置信息的算法，这可能是其表现不佳

的主要原因。

表 3-1 描述了七种算法在 DLPFC 数据集 12 个切片上的 ARI 值。在 12 个切片中，SpaGCL 算法获得了最高的 ARI 平均值为 0.581。

表 3-1 七种算法在 DLPFC 数据集上的 ARI 结果

Tab. 3-1 ARI Results of Seven Algorithms on the DLPFC Dataset

切片	SCANPY	SpaGCN	STAGATE	SEDR	GraphST	DeepST	SpaGCL
15507	0.365	0.388	0.520	0.561	0.475	0.511	0.557
15508	0.303	0.369	0.456	0.442	0.486	0.480	0.452
15509	0.309	0.449	0.325	0.420	0.417	0.449	0.576
15510	0.334	0.338	0.471	0.434	0.472	0.456	0.519
15669	0.174	0.287	0.454	0.401	0.590	0.381	0.625
15670	0.259	0.286	0.440	0.593	0.524	0.364	0.451
15671	0.290	0.525	0.596	0.598	0.613	0.522	0.576
15672	0.354	0.455	0.597	0.541	0.611	0.508	0.738
15673	0.338	0.451	0.597	0.583	0.636	0.573	0.566
15674	0.227	0.413	0.567	0.600	0.619	0.455	0.612
15675	0.318	0.379	0.508	0.534	0.488	0.488	0.631
15676	0.296	0.319	0.565	0.429	0.468	0.596	0.671
平均值	0.297	0.388	0.508	0.511	0.533	0.482	0.581

如表 3-2 所示，在所有 12 个切片中，SpaGCL 算法同样获得了最高的 NMI 平均值为 0.656，GraphST 紧随其后为 0.645，而 SCANPY 算法则未超过 0.5。

表 3-2 七种算法在 DLPFC 数据集的 NMI 结果

Tab. 3-2 NMI Results of Seven Algorithms on the DLPFC Dataset

切片	SCANPY	SpaGCN	STAGATE	SEDR	GraphST	DeepST	SpaGCL
15507	0.412	0.512	0.684	0.712	0.654	0.635	0.679
15508	0.411	0.479	0.634	0.628	0.643	0.597	0.673
15509	0.418	0.573	0.553	0.633	0.601	0.627	0.796
15510	0.421	0.498	0.601	0.615	0.639	0.605	0.58
15669	0.306	0.453	0.595	0.548	0.651	0.599	0.697
15670	0.35	0.493	0.548	0.576	0.618	0.504	0.552
15671	0.425	0.633	0.68	0.691	0.709	0.654	0.673
15672	0.421	0.491	0.601	0.666	0.619	0.629	0.717
15673	0.448	0.59	0.618	0.702	0.635	0.705	0.703
15674	0.375	0.519	0.671	0.708	0.718	0.614	0.607
15675	0.42	0.478	0.657	0.646	0.622	0.65	0.633
15676	0.396	0.439	0.668	0.58	0.629	0.696	0.566
平均值	0.400	0.513	0.626	0.642	0.645	0.626	0.656

此外，本论文在 DLPFC 数据集 ID：151672 切片上生成了 SpaGCL 和其他六种算法聚类结果的可视化。如下图 3-3 所示。SpaGCL 算法获得了 ARI=0.738 和 NMI=0.717 的最高值。其中，SCANPY 和 SpaGCL 算法无法清晰分离五层，边界显得模糊，并且存在明显的噪声干扰。GraphST 和 STAGATE 虽然可以清晰地分离五层，但分离的 Layer3 层在整个图像中占据的面积较小，与图 3-3（a）给出的手动注释不符。相比之下，SpaGCL 识别的所有层除了 Layer4 之外都可以与手动注释有很好地对应。

实验结果表明，与最先进基准的空间域识别算法（SCANPY、SpaCGN、DeepST、GraphST、STAGATE 和 SEDR）相比，SpaGCL 的空间域识别结果与手动注释的结果更加一致，并且在识别 DLPFC 组织中的层结构方面取得了显著改进。

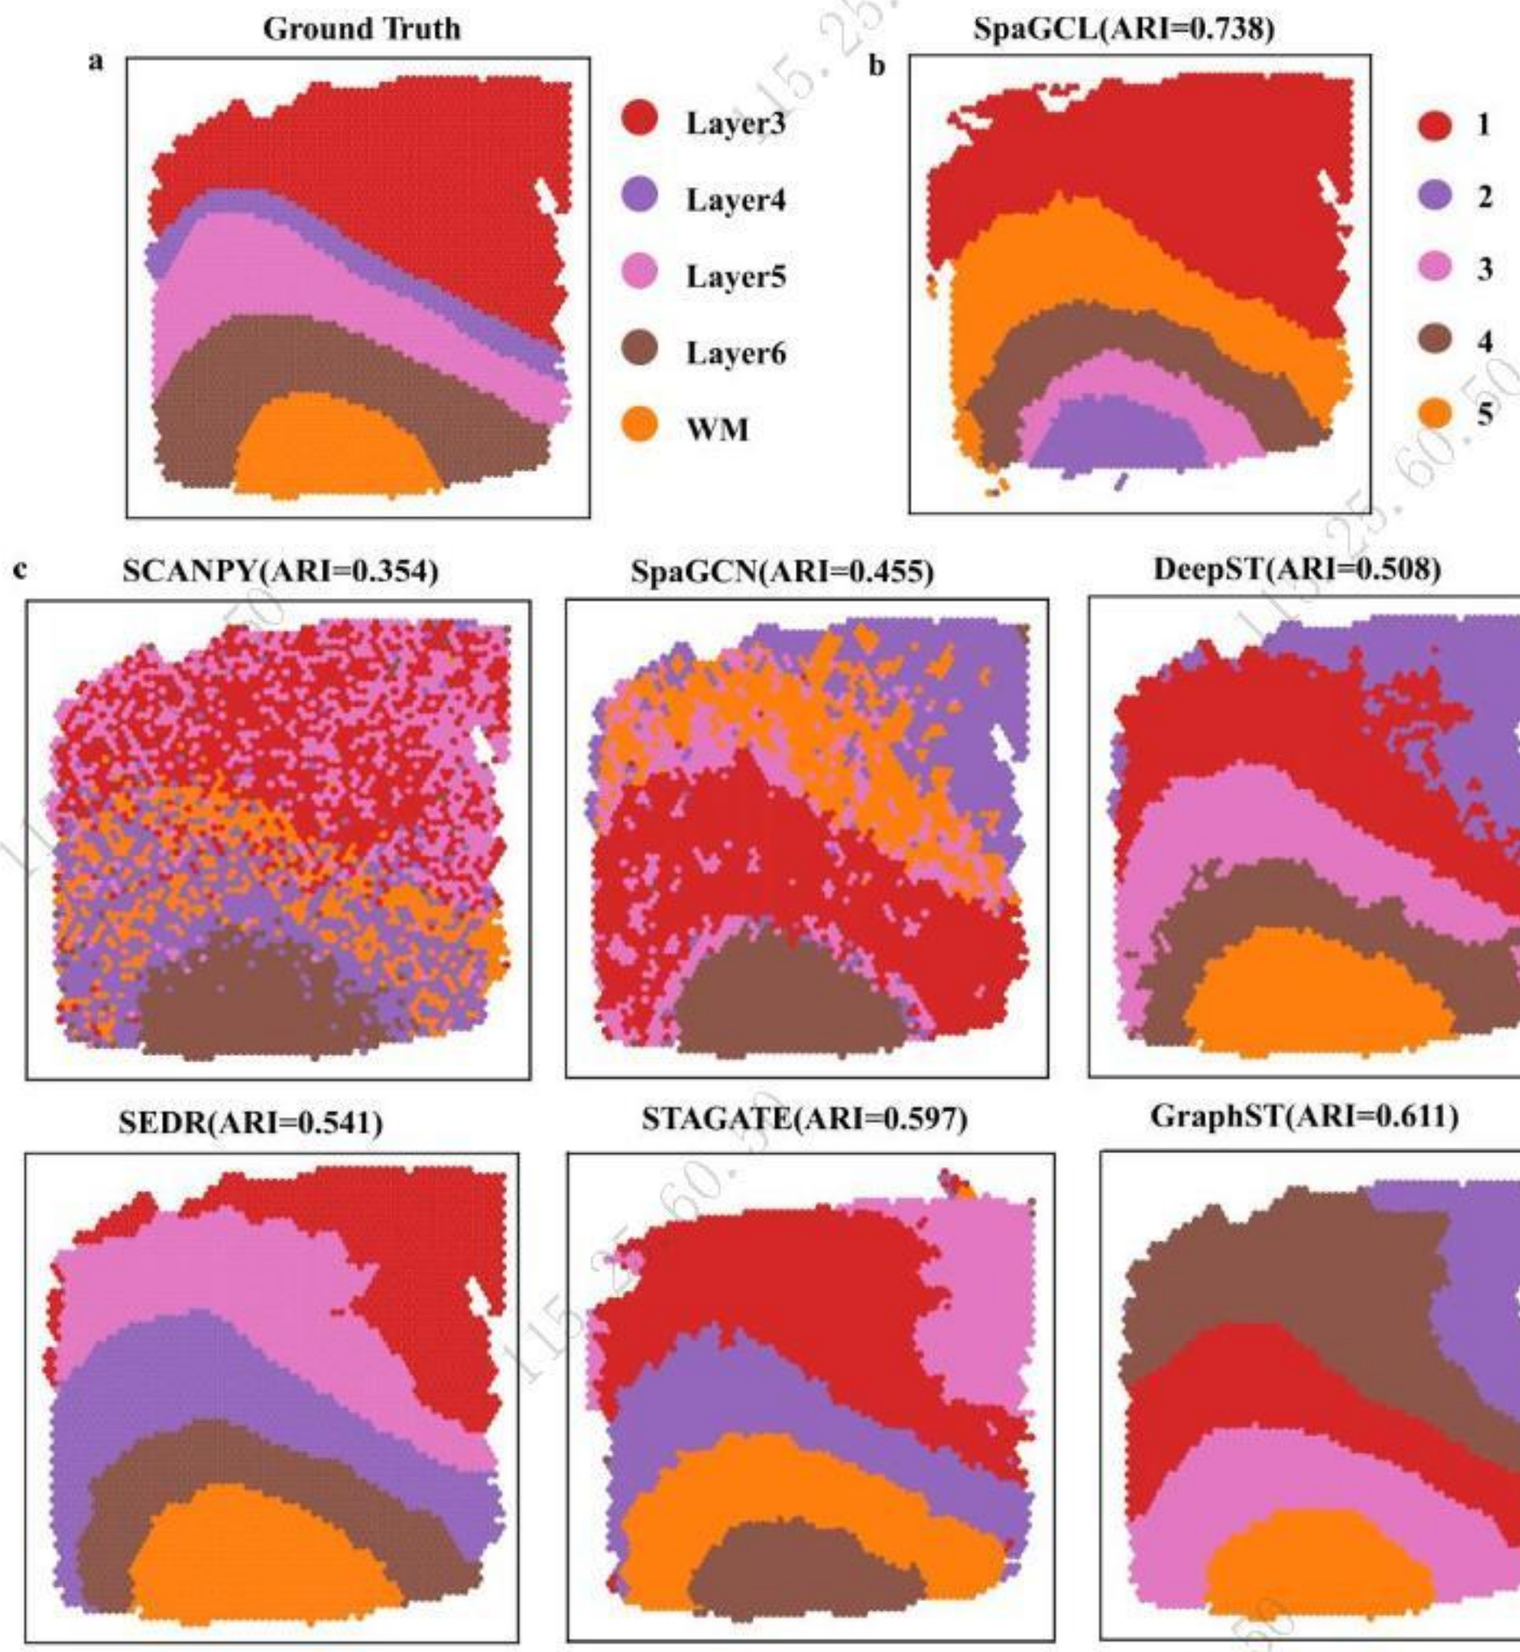


图 3-3 七种算法在 DLPFC 数据集 ID:151672 上的空间域识别结果

Fig.3-3 Spatial Domain Identification Results of Seven Algorithms on Dataset 151672

空间域的轨迹是揭示生物进化机制的基础[46]，PAGA 用于推算各种算法

识别的空间域之间的关系。为了证明 SpaGCL 算法学习到的特征可以很好地推广到其他下游任务中，本论文进一步地执行了 UMAP 来可视化集群的 PAGA 之间的距离以推断空间轨迹。如下图 3-4 所示，在 SpaGCL 和 SEDR 的 UMAP 图中，Layer3、Layer4 和 Layer5 层的 spot 点混合。SpaGCL 和 STAGATE 很好地分离了所有簇，并且 PAGA 轨迹从 3 层到 WM 近似呈线性。

综上所述，这些结果验证了 SpaGCL 采用交叉注意力的特征融合机制，确保了高质量的嵌入，并有效捕捉了空间信息和域间边界的特征表示。

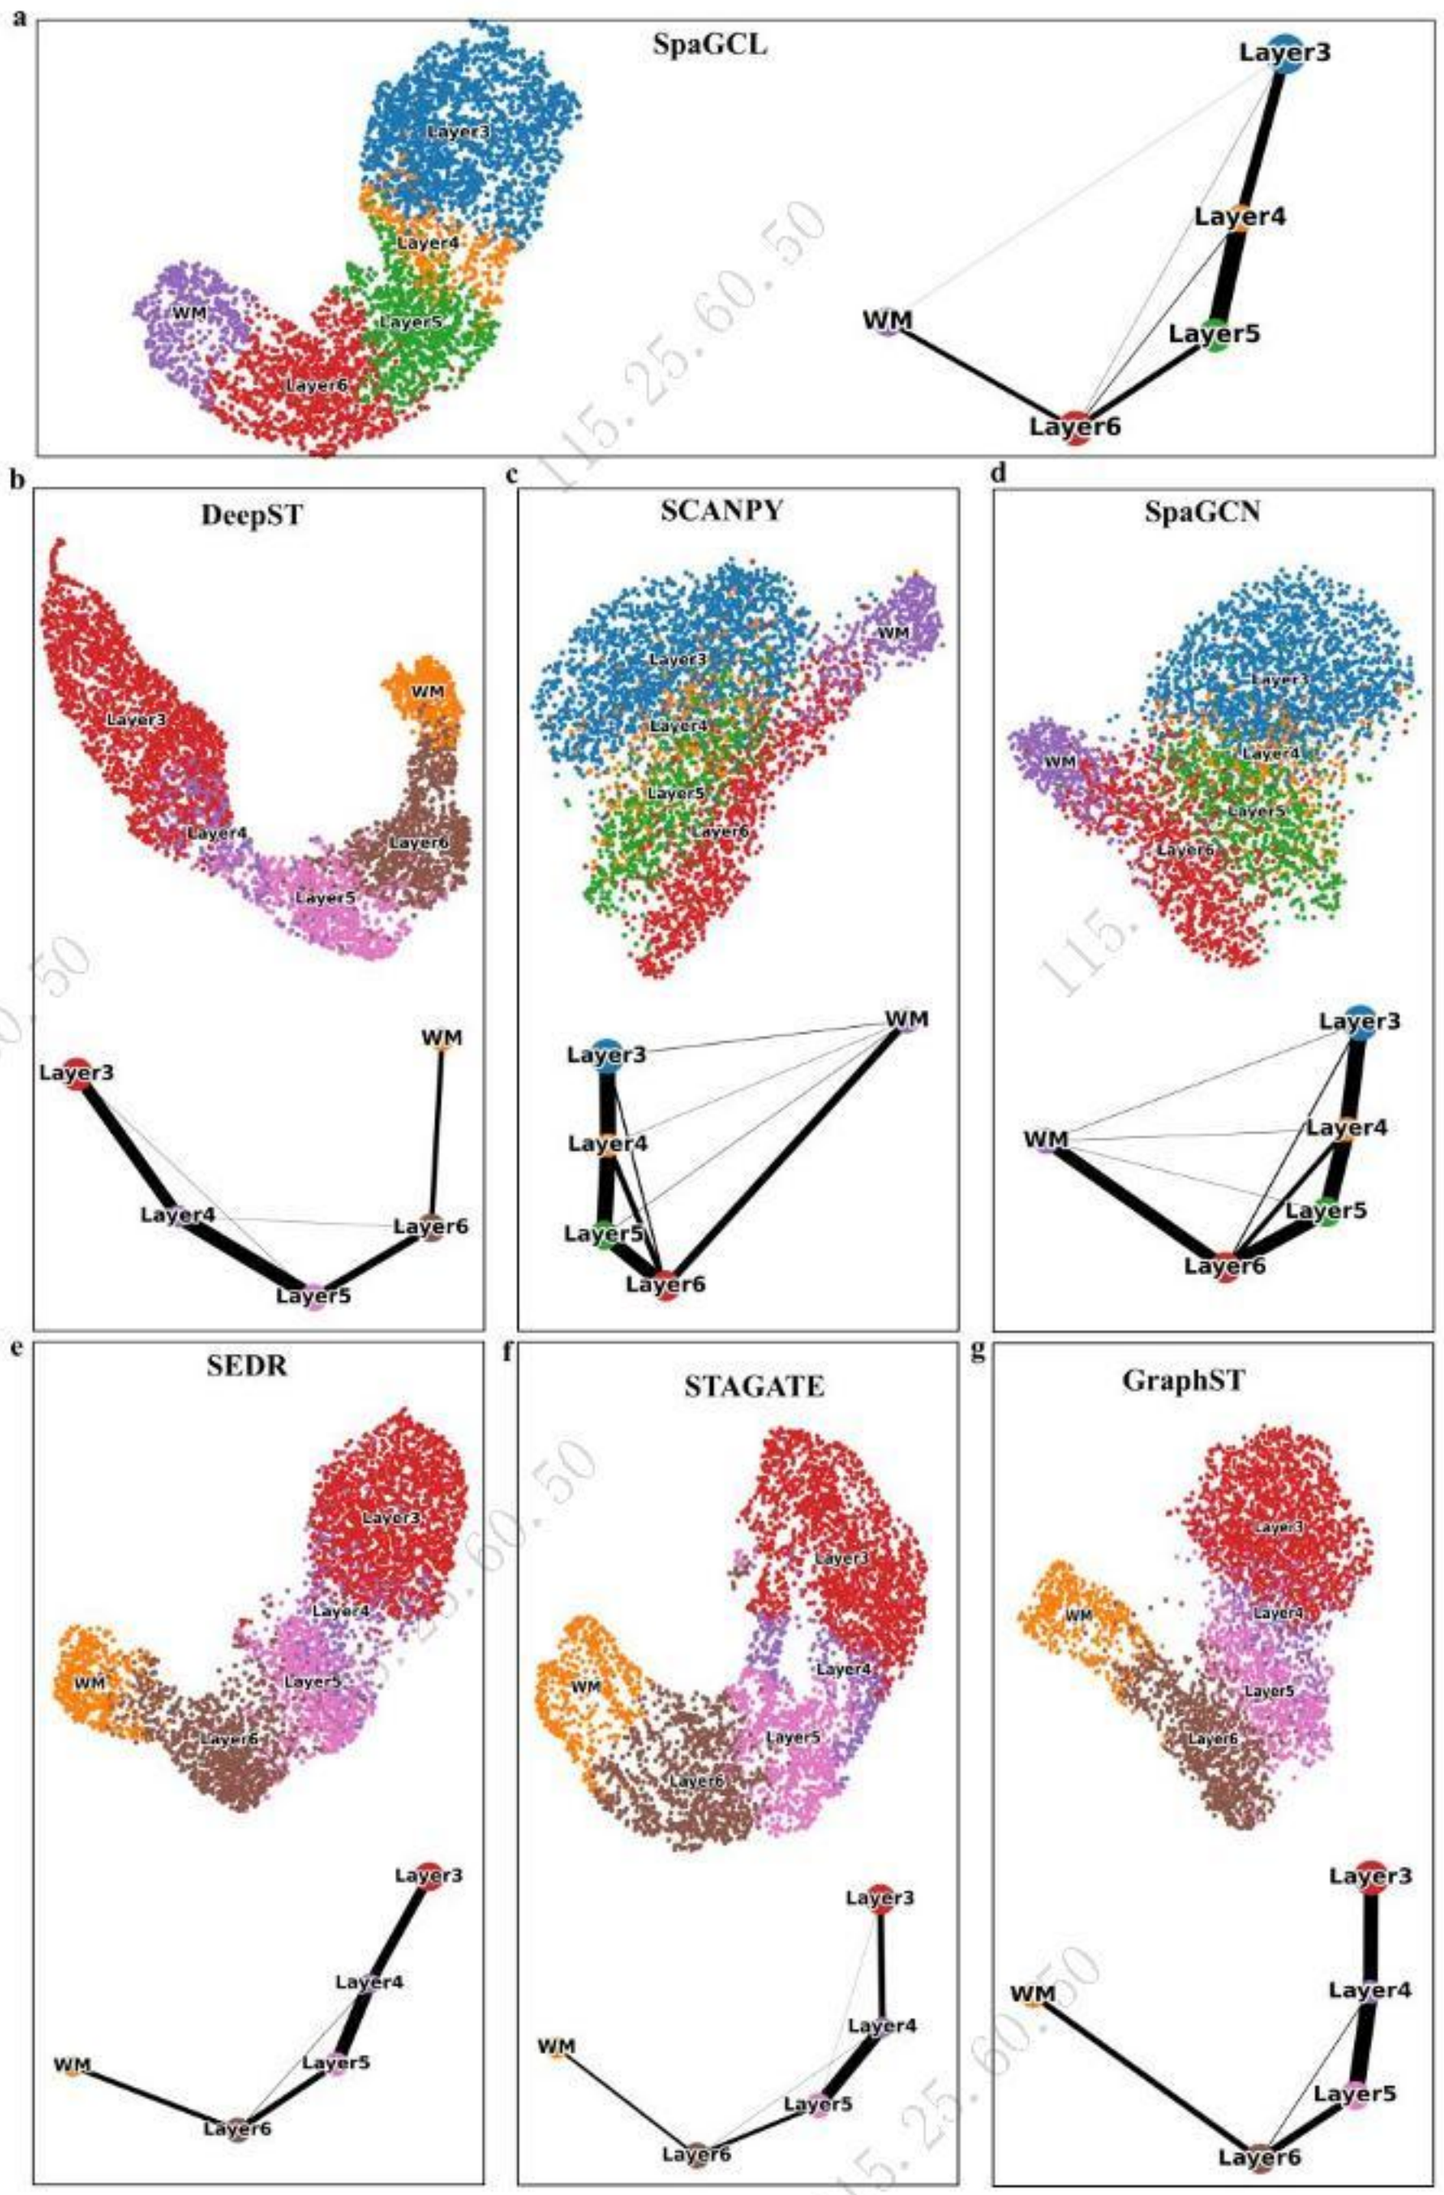


图 3-4 七种算法在 ID:151672 上的 UMAP 和 PAGA 图

Fig.3-4 UMAP and PAGA Visualization by Seven Algorithms on Dataset 151672

此外，为了进一步证实了 SpaGCL 在嵌入空间的有效性，本论文生成了基于 UMAP 的密度热图。如下图 3-5 所示，SpaGCL 模型生成的不同团簇的密度分布是连续的，在高密度区域观察到良好的类内紧凑性和清楚地展示了层次结构，这表明，SpaGCL 算法在特征表示方面能够准确反映聚类的内部一致性。密度热图还显示，空间域的层次结构不仅保留在局部密度分布中，而且保留在不同集群之间边界的清晰度和分离性中。密度热图中的层次结构与空间域的识别结果一致，表明该算法在特征嵌入中保留了空间域之间的拓扑关系。

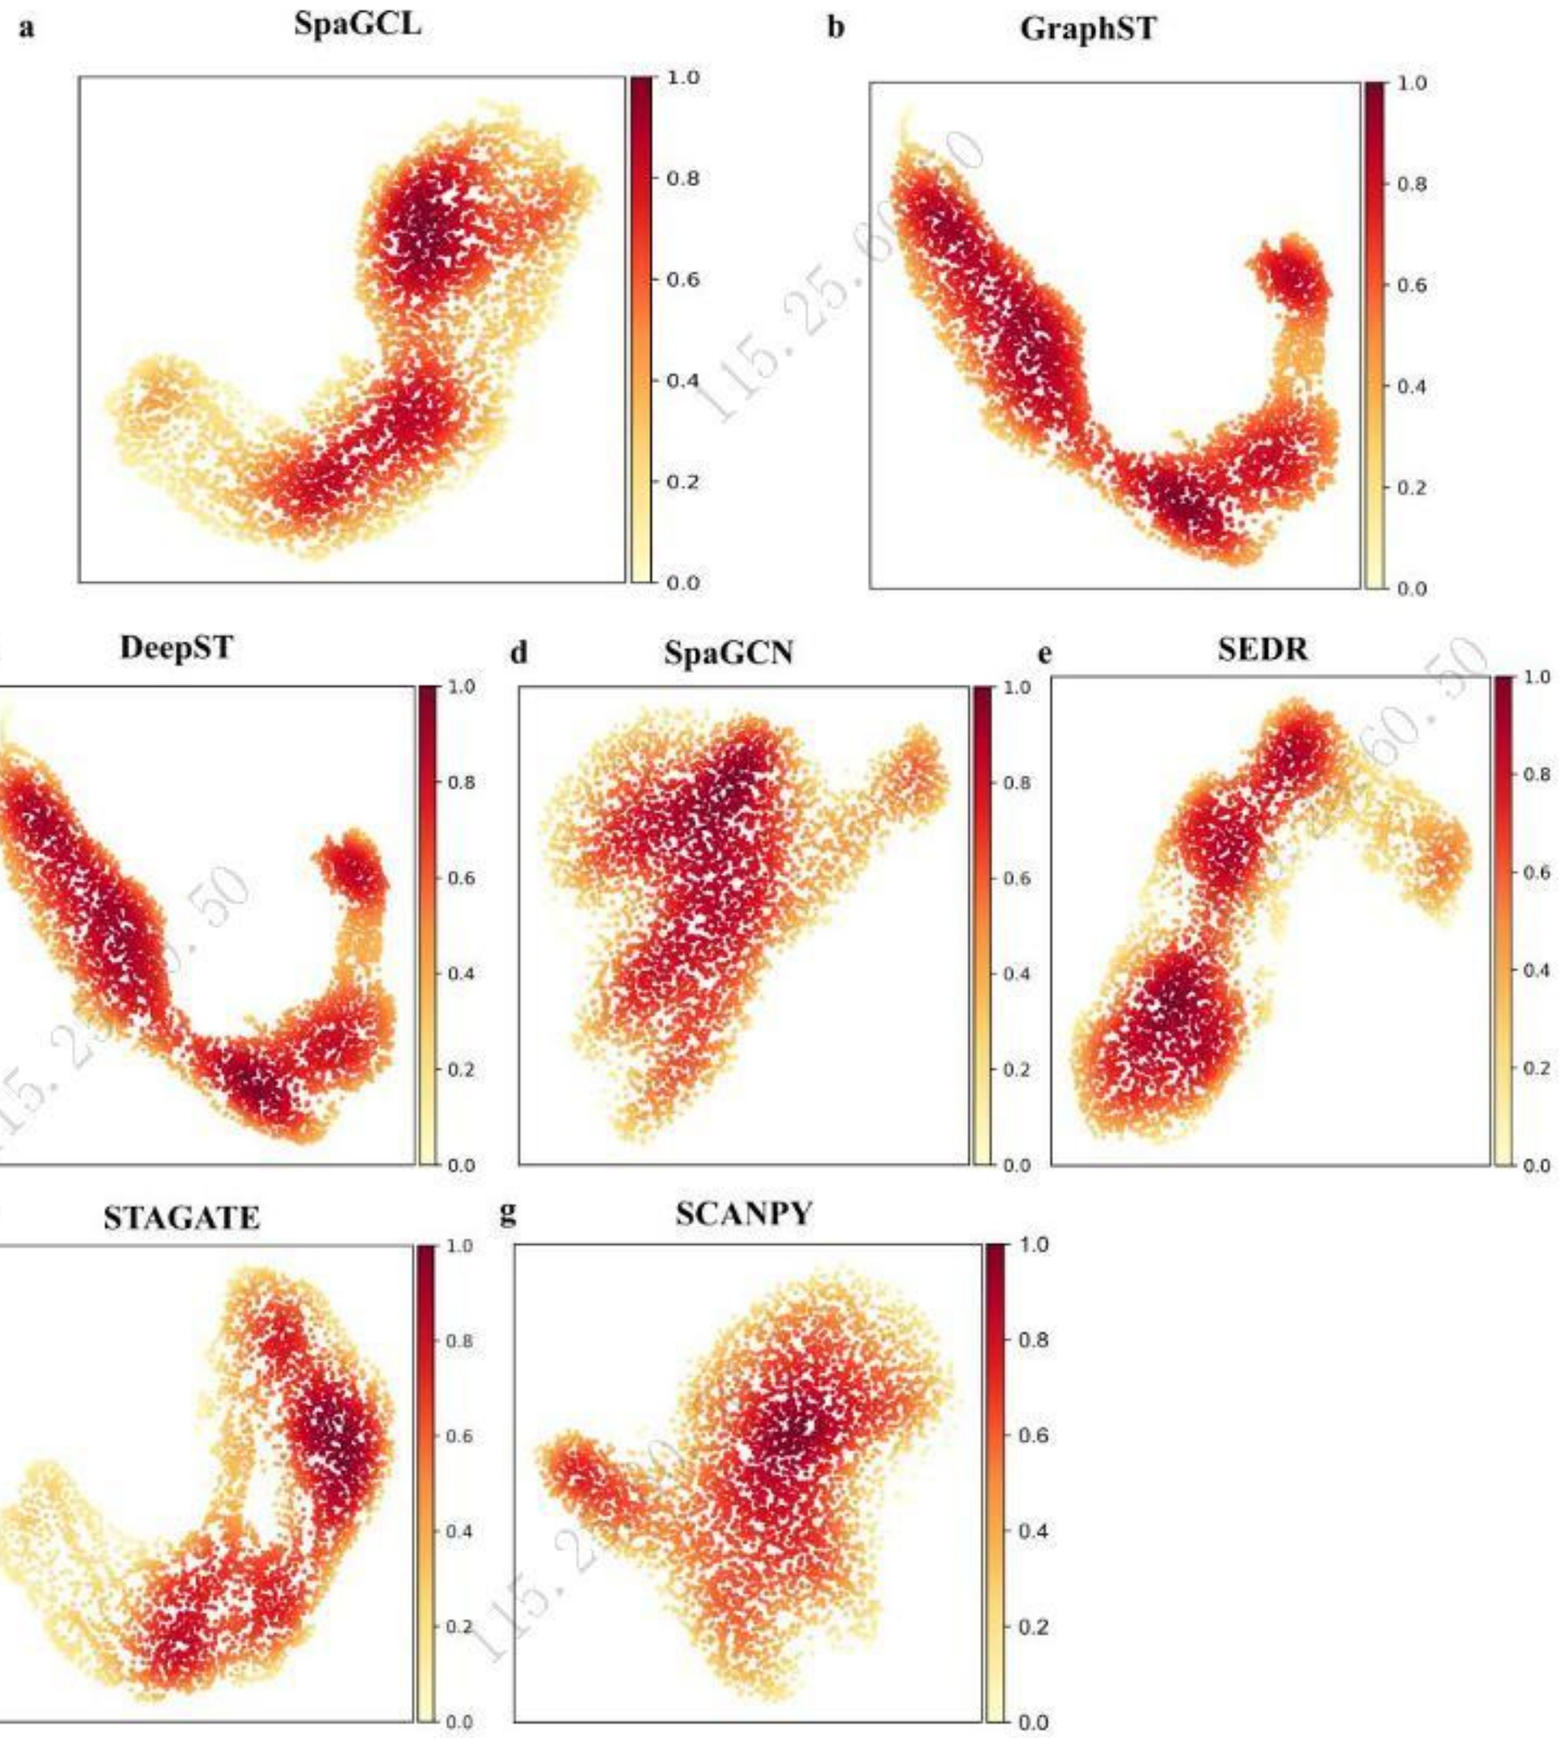


图 3-5 七种算法切边 ID:151672 上的密度热图

Fig.3-5 Density Heatmaps from Seven Algorithms on Dataset 151672

3.5.3 SpaGCL 提升小鼠冠状脑切片的细微结构识别能力

为了进一步验证 SpaGCL 在细微生物纹理的识别能力。本论文选取了

10X Visium ST 数据集中的小鼠冠状脑切片。该数据集由 Squidpy 中的 Allen Brain Atlas 和 Mouse Brain 基因表达图谱注释作为基准。

实验结果（图 3-6）发现 SpaGCL 识别的空间域与 Squidpy 中手动注释的空间域高度一致，获得了较高的识别精度。本论文发现，仅使用基因表达信息而不使用空间信息的 SCANPY 比其他使用空间信息的竞争算法具有更高的识别精度，但其对细微生物纹理的捕获能力并不比使用空间信息更好。

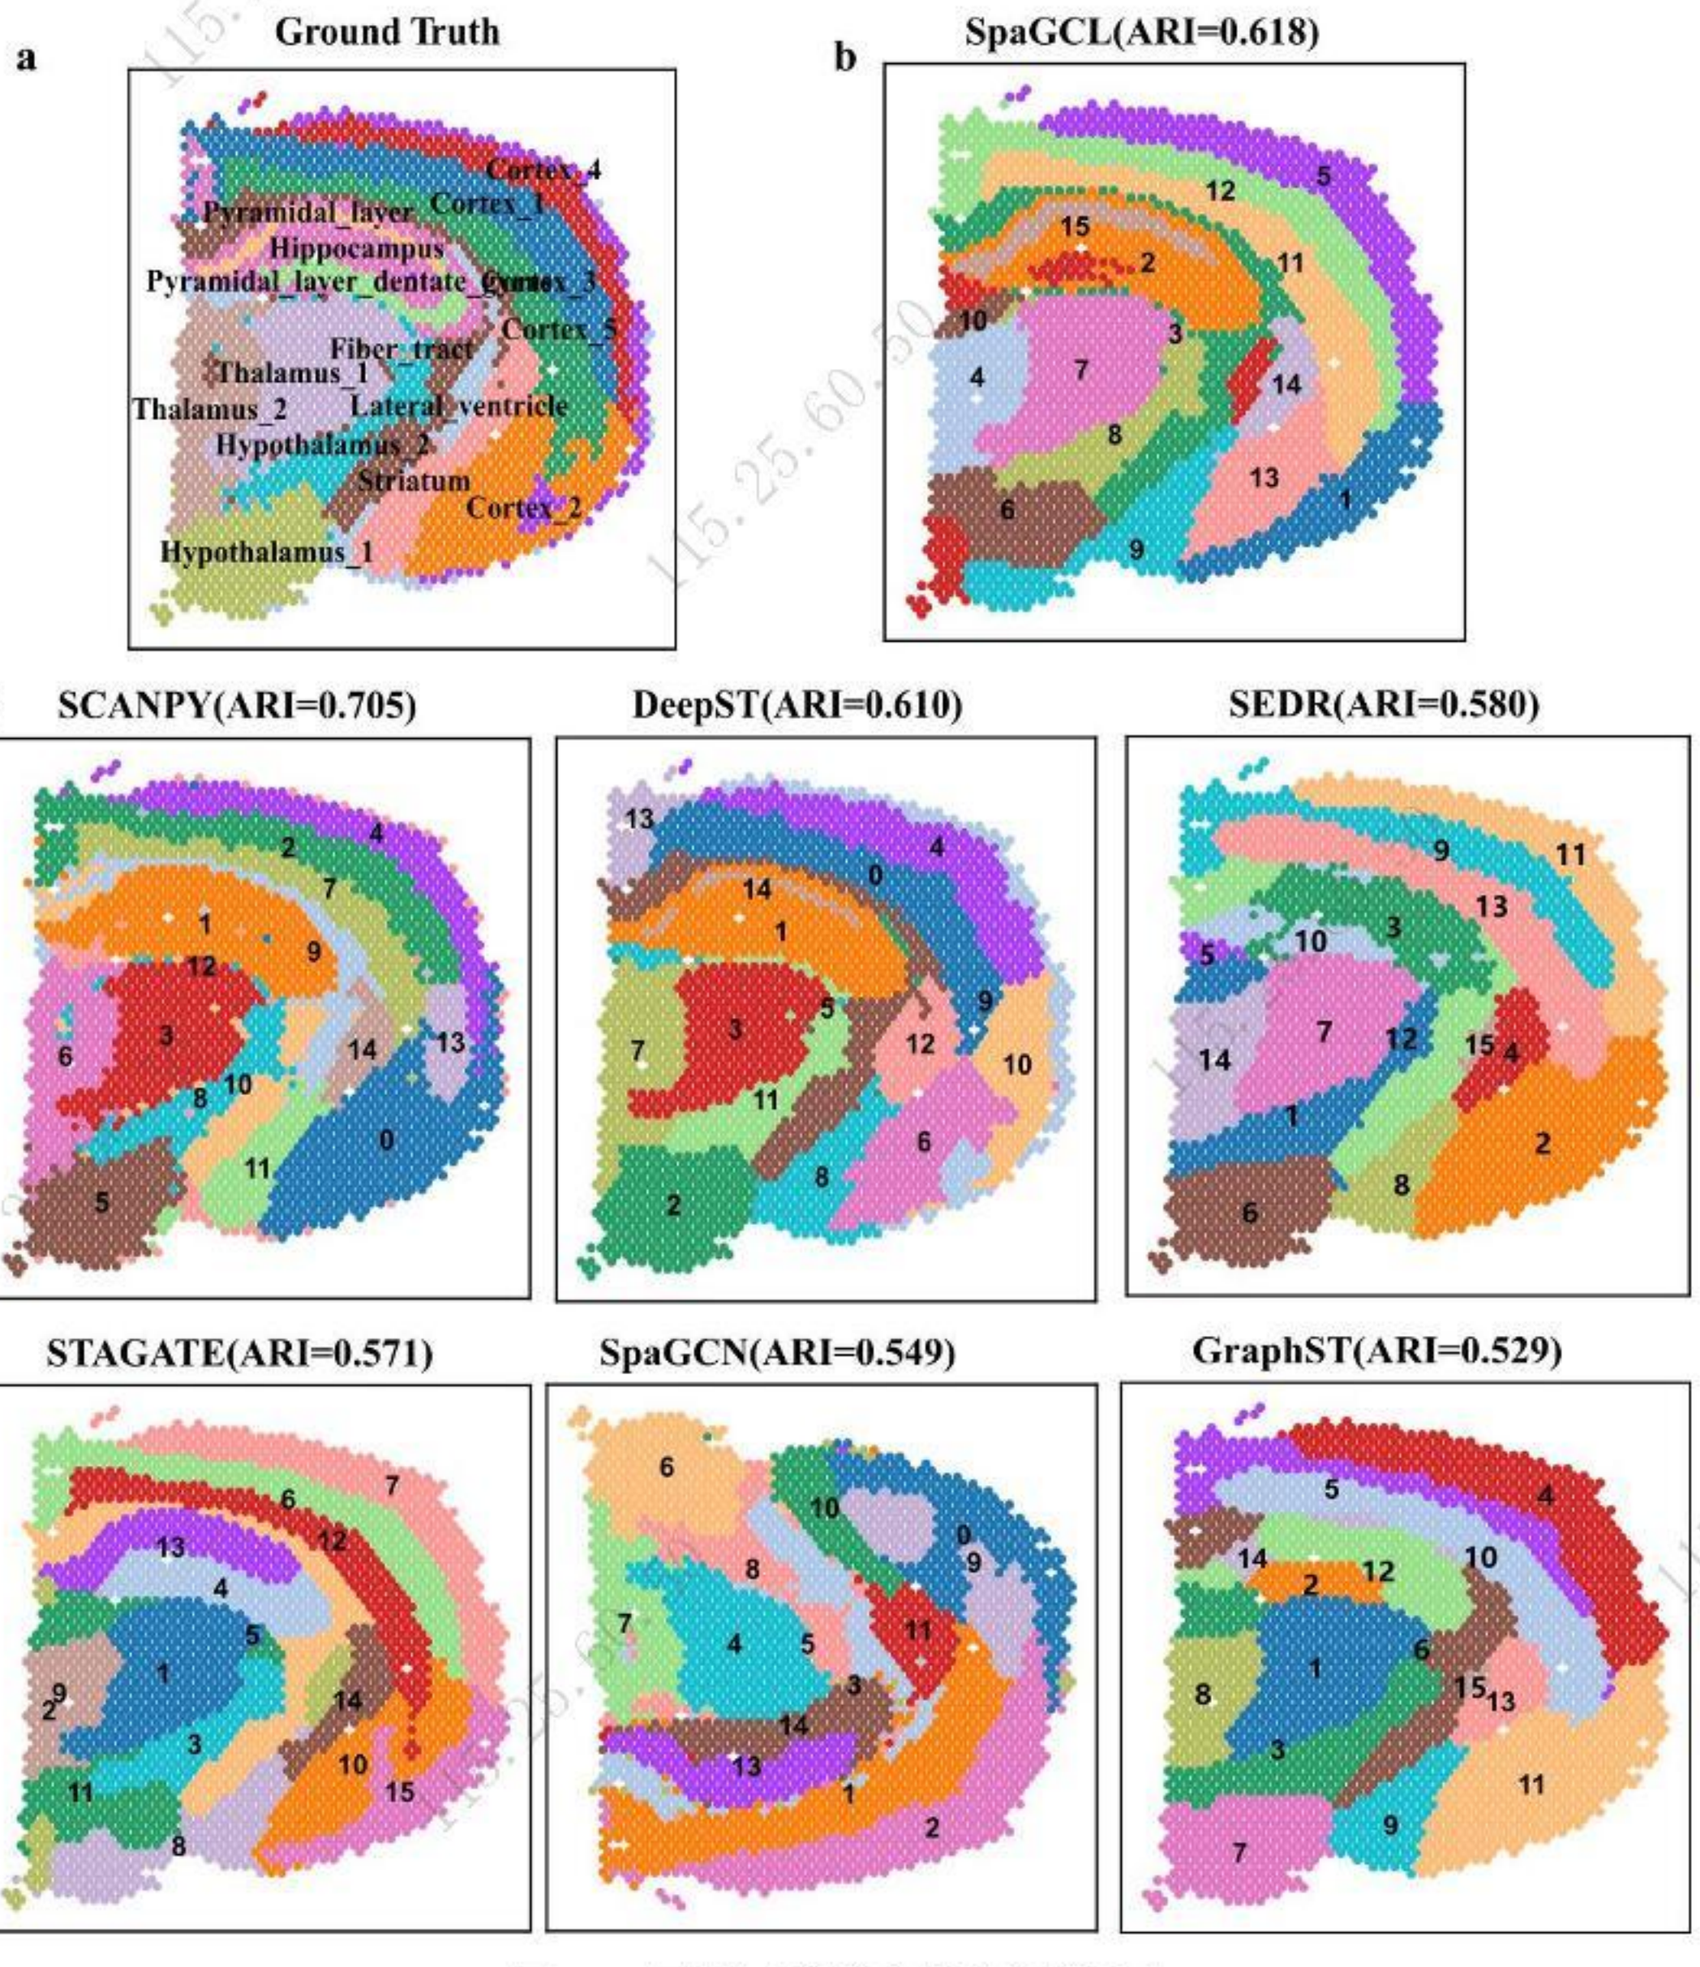


图 3-6 冠状小鼠脑切片识别结果

Fig.3-6 Identification Results in the Coronal Mouse Brain Slice

最后，为了消除不同聚类算法的影响，本论文使用真实空间域分析了潜在表示。如图 3-7 所示，通过 UMAP 可视化和 PAGA 轨迹分析，可以看出 SpaGCL 区分了不同空间域中的 spot。并将每个空间域中的点聚合，从 PAGA

中找到了清晰的轨迹。然而，STAGATE 和 SEDR 的 spot 在 UMAP 可视化中被混淆，没有显示出清晰的轨迹。综上所述，SpaGCL 可以有效地利用基因表达和 H&E 组织图像特征来实现最佳的识别精度和微妙的生物纹理识别。

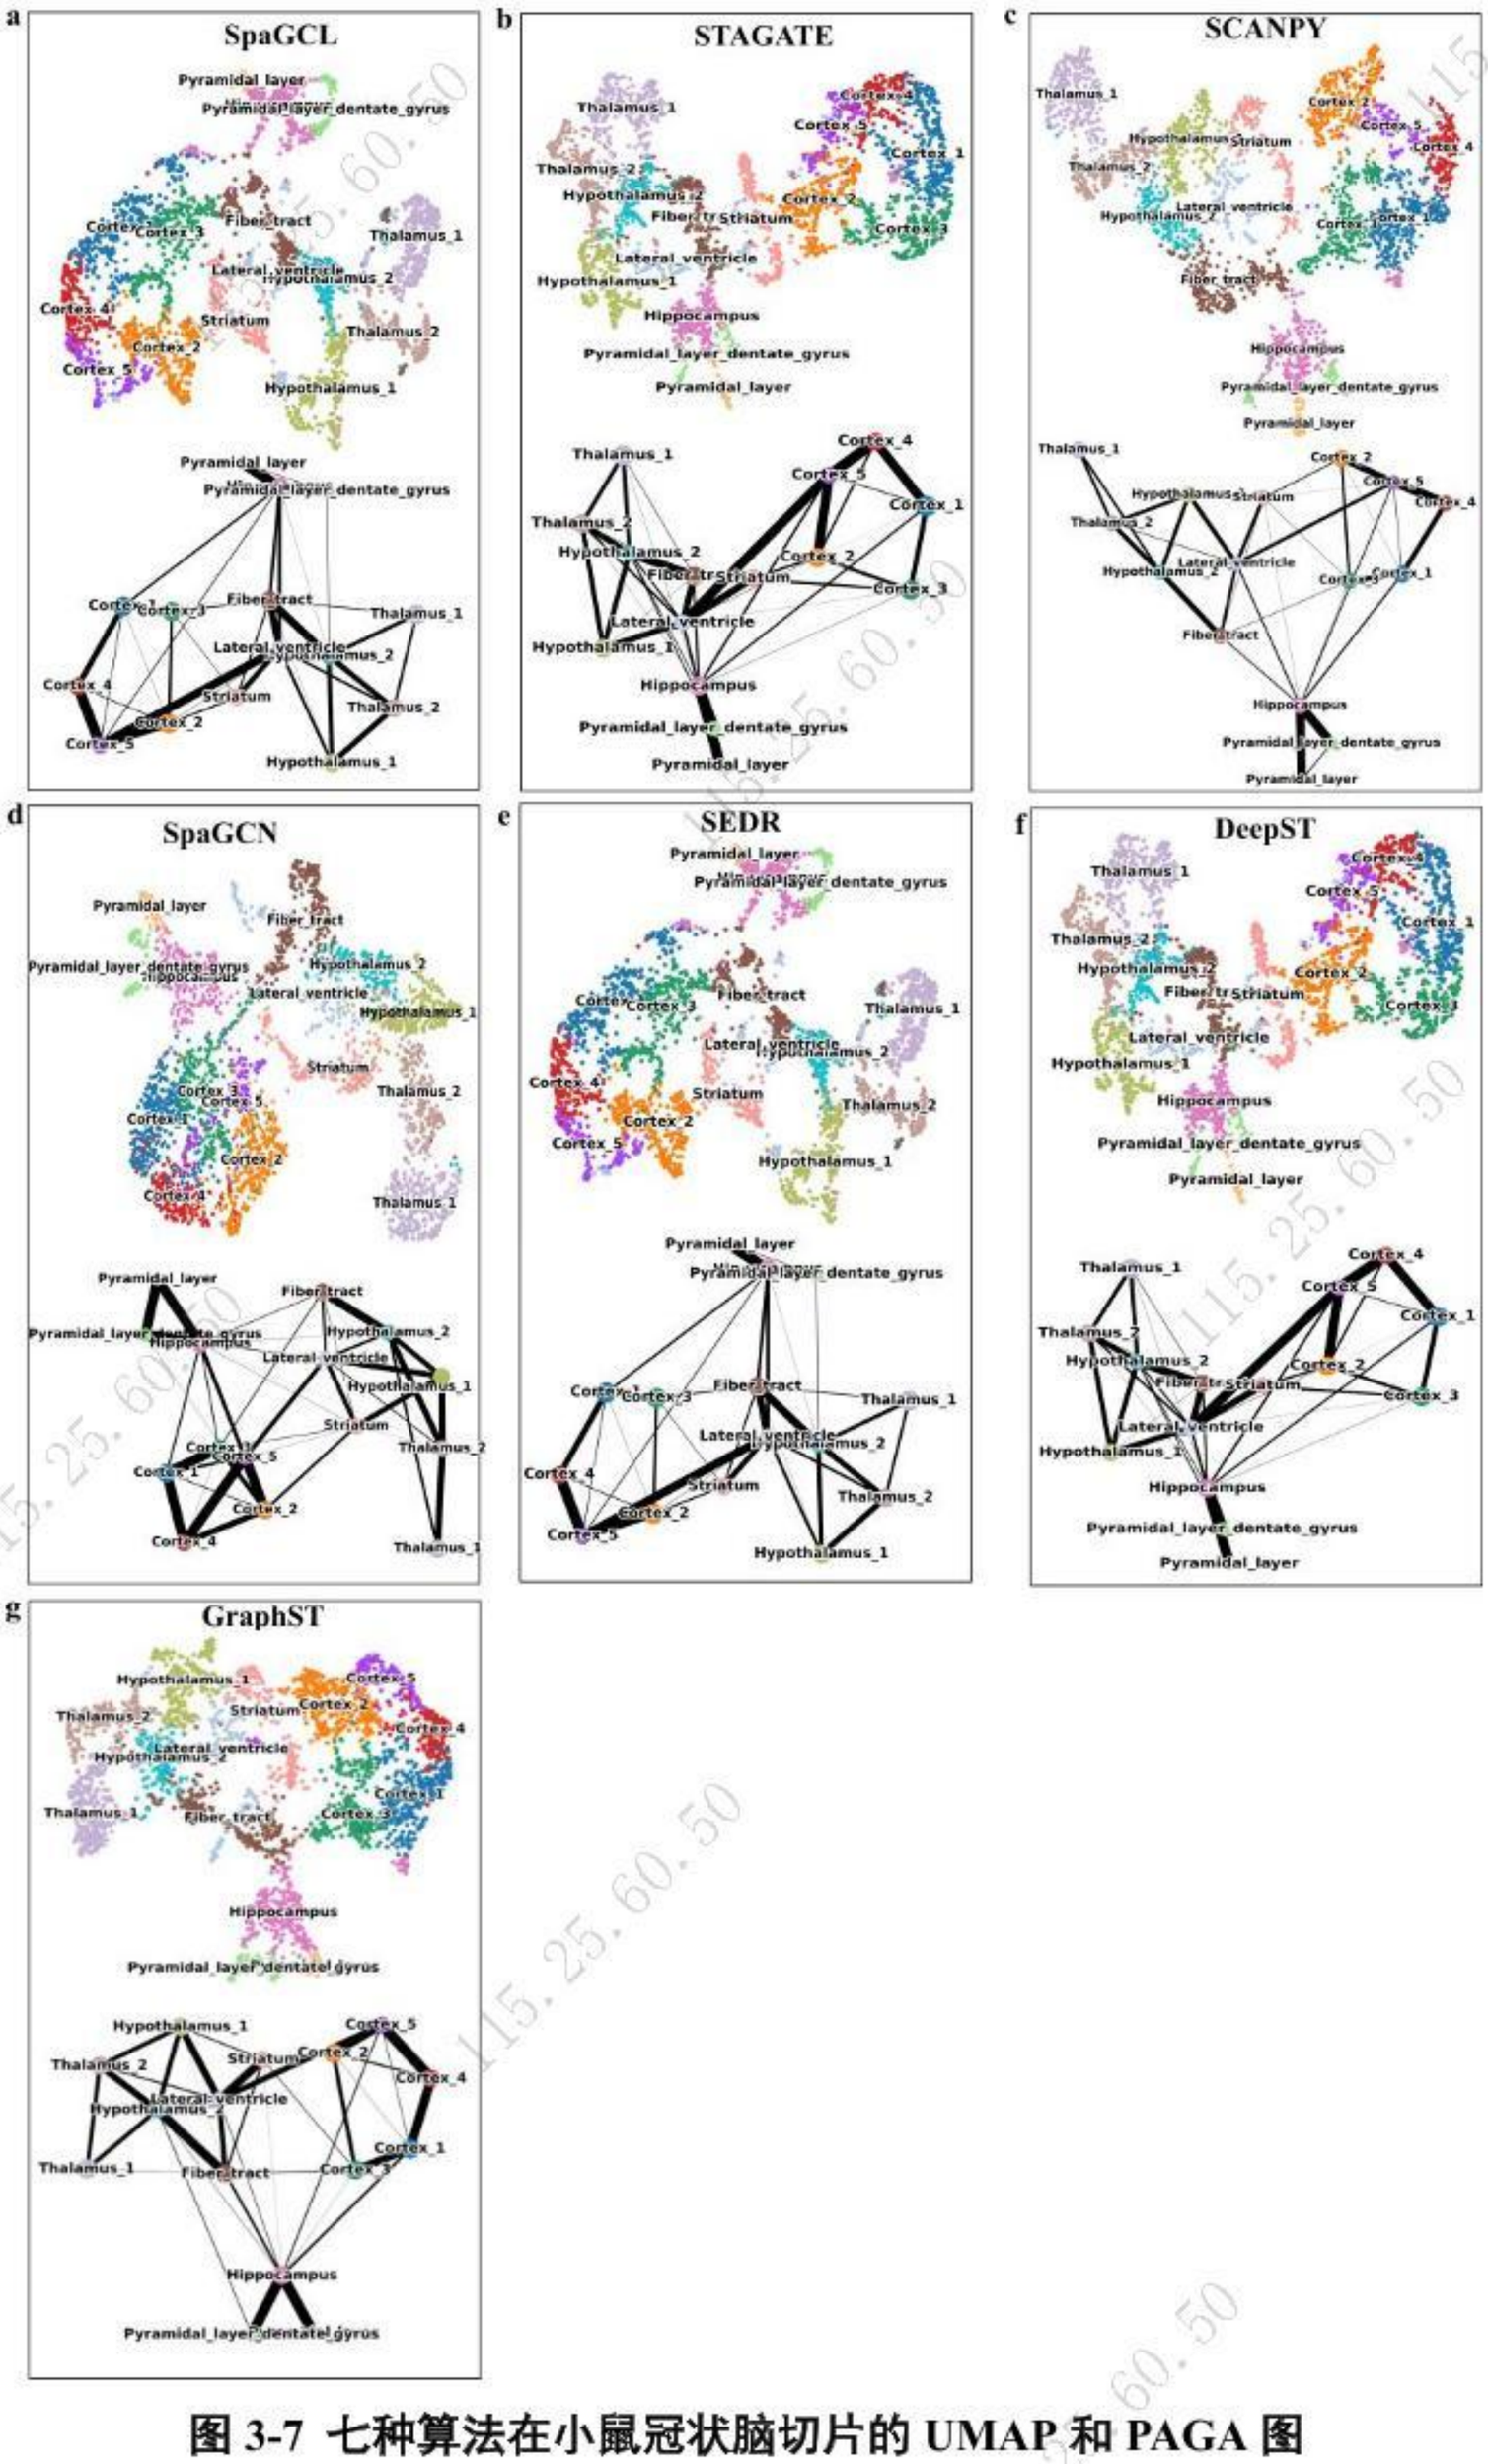


图 3-7 七种算法在小鼠冠状脑切片的 UMAP 和 PAGA 图

Fig.3-7 UMAP and PAGA Plots from Seven Algorithms

3.5.4 SpaGCL 在小鼠嗅球数据集上的大尺度空间解析

接下来，为了验证 SpaGCL 是否可以应用于具有更多 spot 的高分辨率 ST 数据集，本论文将 SpaGCL 应用于 Stereo-seq 平台的小鼠嗅球组织数据集。

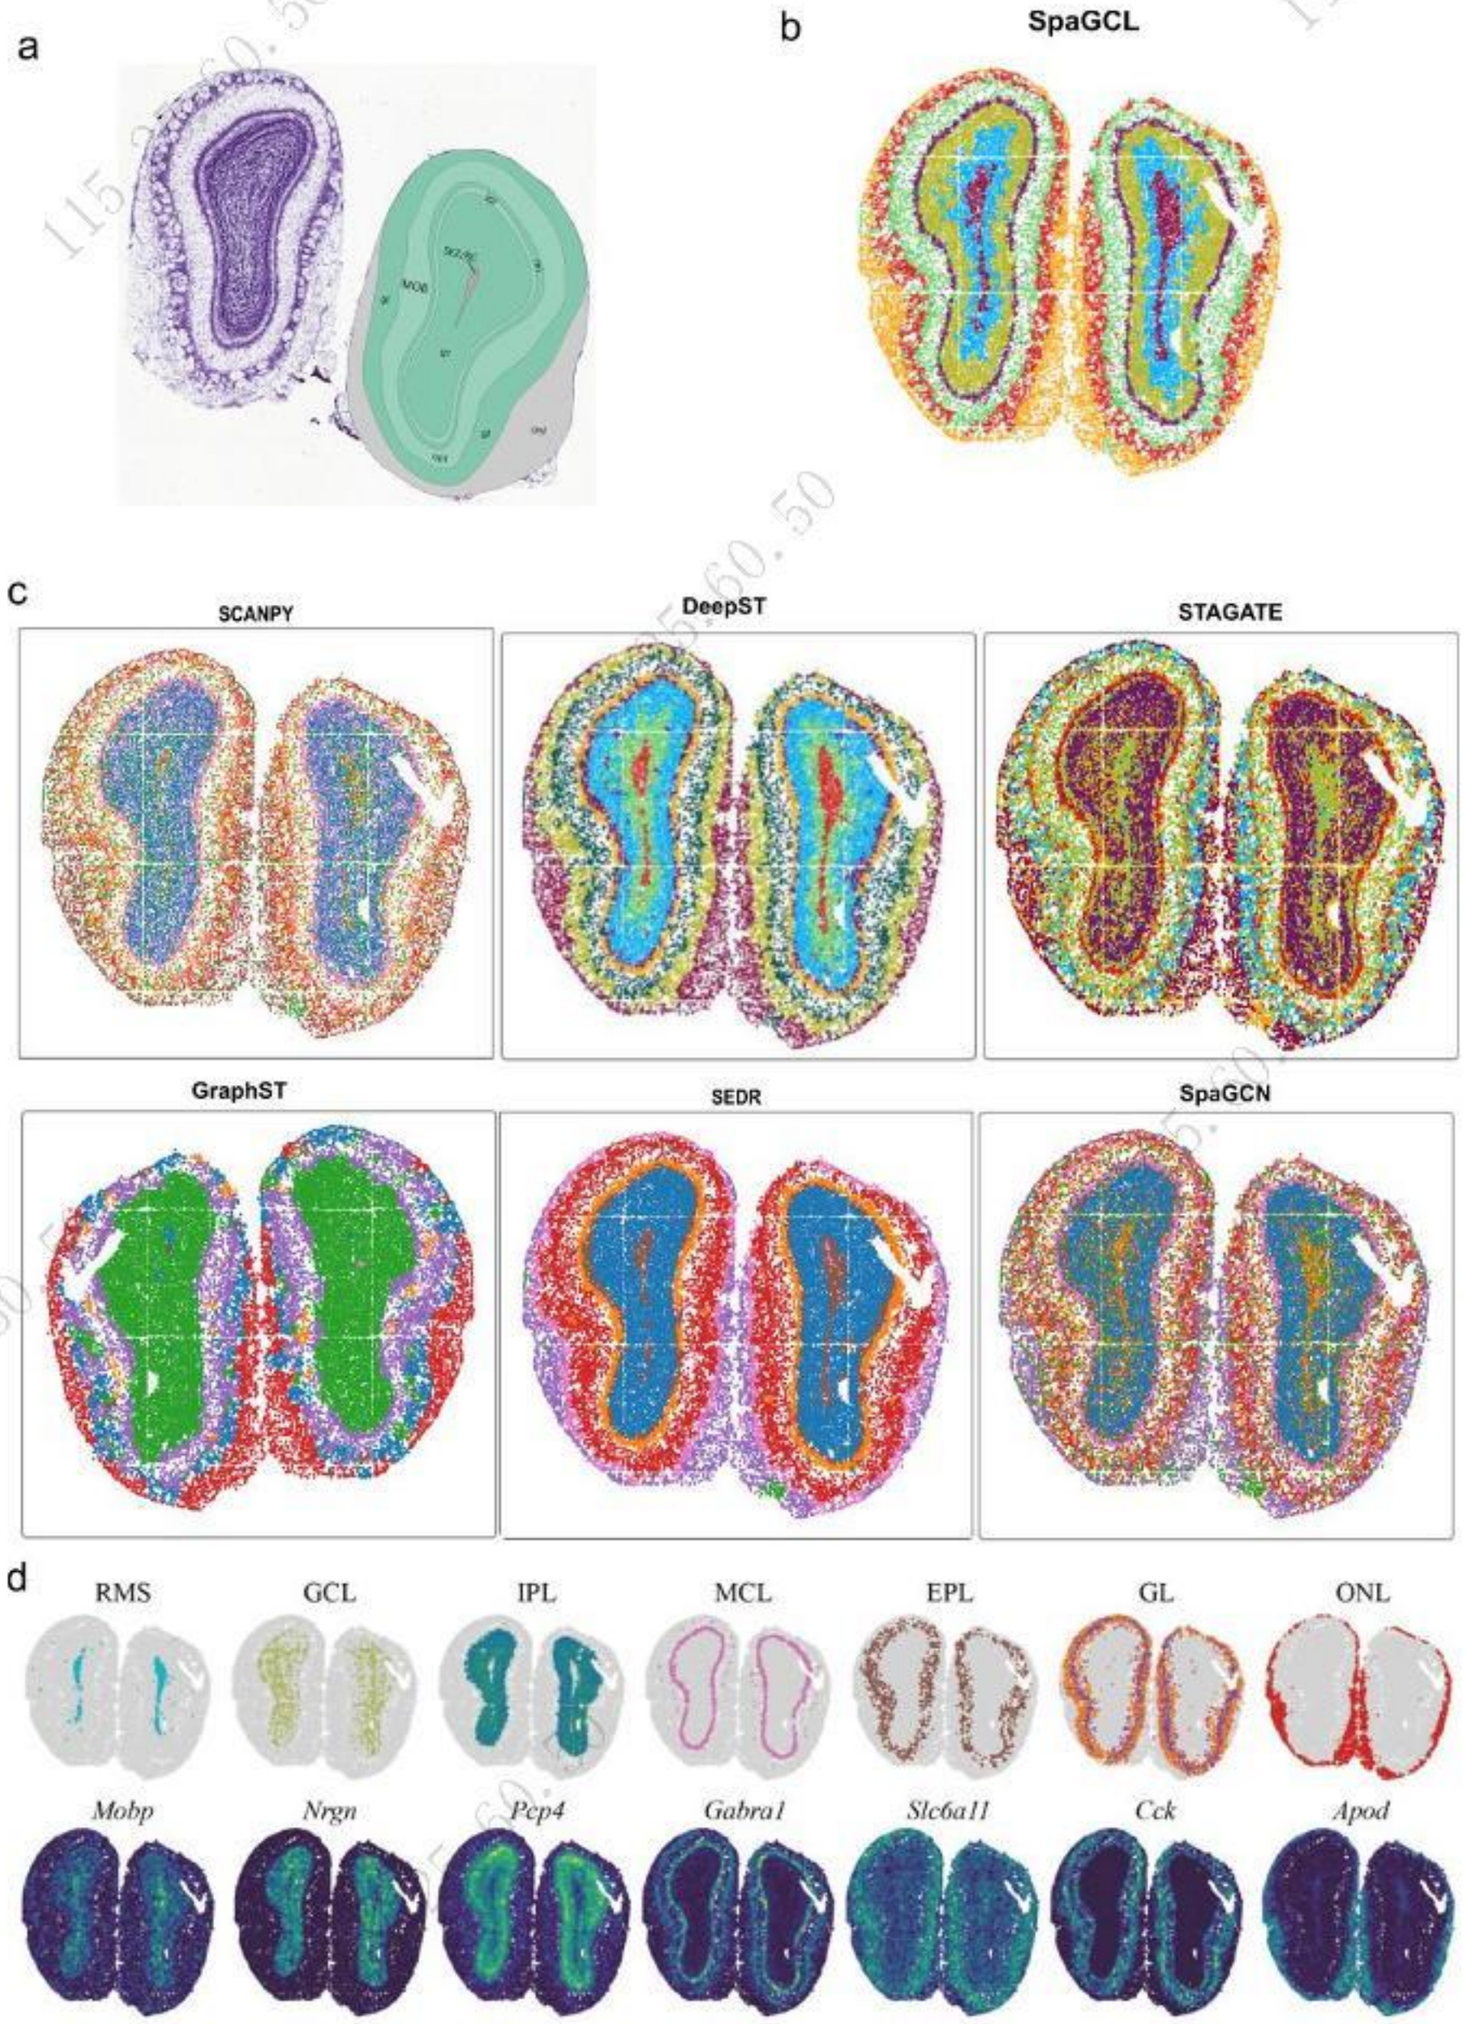


图 3-8 小鼠嗅球空间域识别结果

Fig.3-8 Spatial Domain Identification Results in the Mouse Olfactory Bulb

图 3-8（a）小鼠嗅球的结构注释。（b）SpaGCL 算法的空间域识别结果。（c）六种对比算法的空间域识别结果。（d）识别的嗅球层和相应的标记基因。

为了定量分析层状生物纹理的聚类质量。本论文计算了每种算法的 SC 评

分和 DB 评分。图 3-9 结果表明，SpaGCL 获得了最高的 SC 和较低的 DB 值（SC=0.231,DB=2.514），SpaGCN 紧随其后得分（SC=0.214,DB=3.679），SCANPY 得分最差（SC=0.038,DB=4.549）。

结果表明，SpaGCL 能够在细胞分辨率下刻画脑组织的细粒度空间域，从而实现对 ST 数据中细微生物纹理的最佳识别能力。

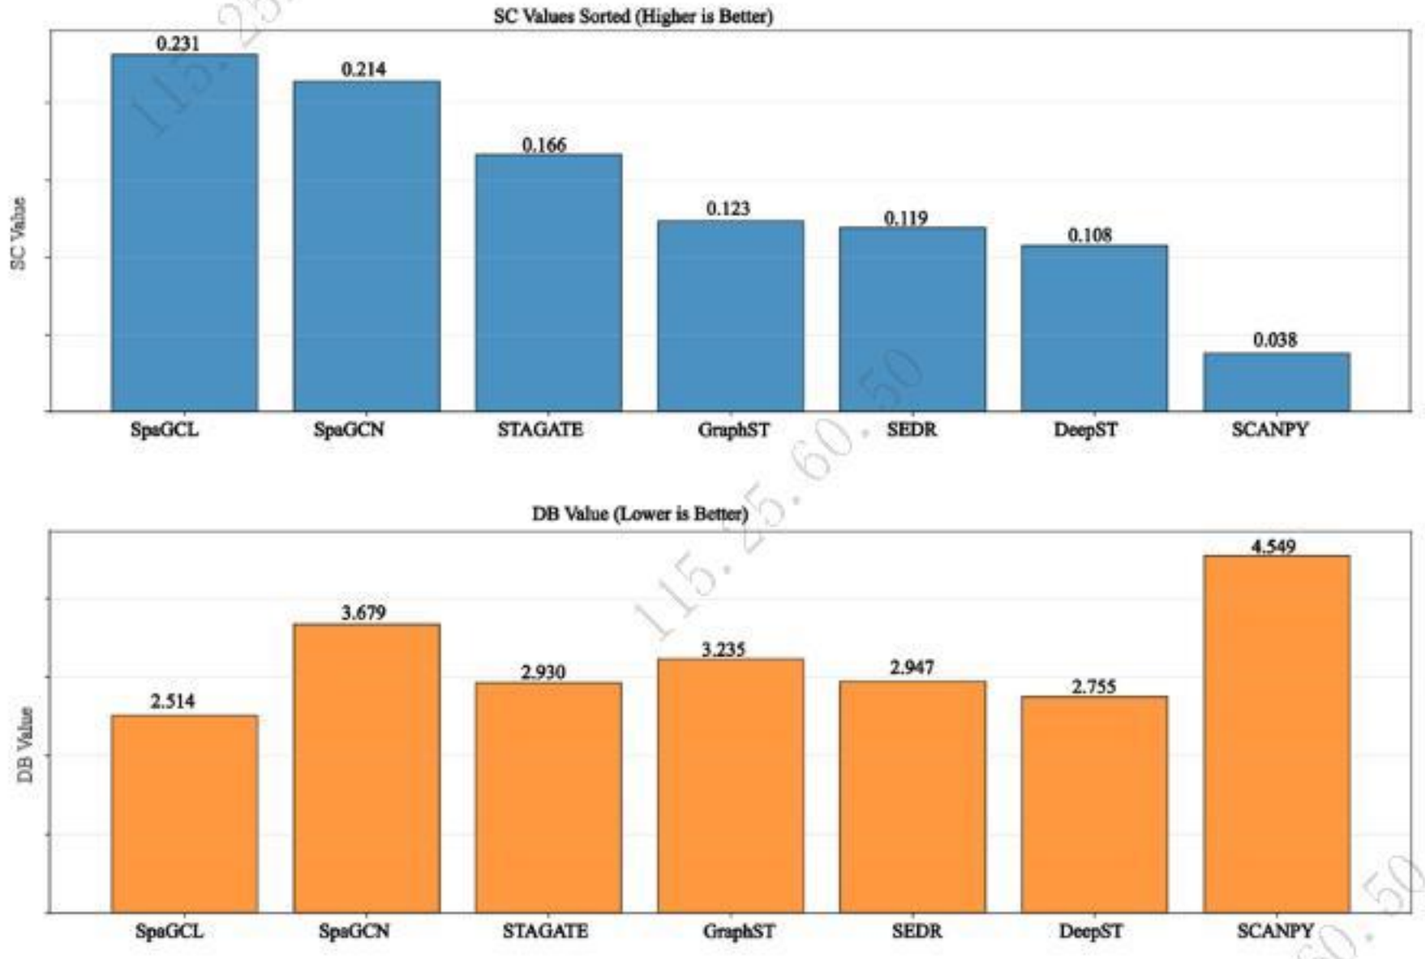


图 3-9 DB 和 SC 值柱状图

Fig.3-9 Bar Plots of Davies-Bouldin Index (DB) and Silhouette Coefficient (SC)

3.5.5 SpaGCL 在小鼠海马体数据集上的亚细胞分辨率解析

在本节中，本论文将 SpaGCL 应用于 Slide-seqV2 平台的小鼠海马体。如图 3-10 所示，SpaGCL 成功识别了带注释的空间结构域，包括齿状回和阿蒙角内的锥体层，并进一步分为 CA1、CA2 和 CA3 区域，而且它在 CA3 和齿状回的描绘方面优于 DeepST。然而，SCANPY 和 SEDR 未能区分 CA 和 DG 结构，错误地将它们识别为单个集群。尽管 STAGATE 和 SpaGCN 可以确定 CA1、CA3 和齿状回结构，但其余识别的结构域包含噪声且边界不明确。相比之下，SpaGCL 描绘的结构域表现出清晰的空间分离，并且更类似于解剖注释。此外，已知基因标记的表达证实了 SpaGCL 的空间聚类结果，CA1 基因标记基因 Wsf1 在已鉴定的 CA1 结构域中特异性表达[47]。分泌的突触组织分子 C1q12 在 DG 结构中显示出高表达[48,49]。

实验结果表明，SpaGCL 可以更好地描绘海马组织的细粒度结构及其空间表达模式。

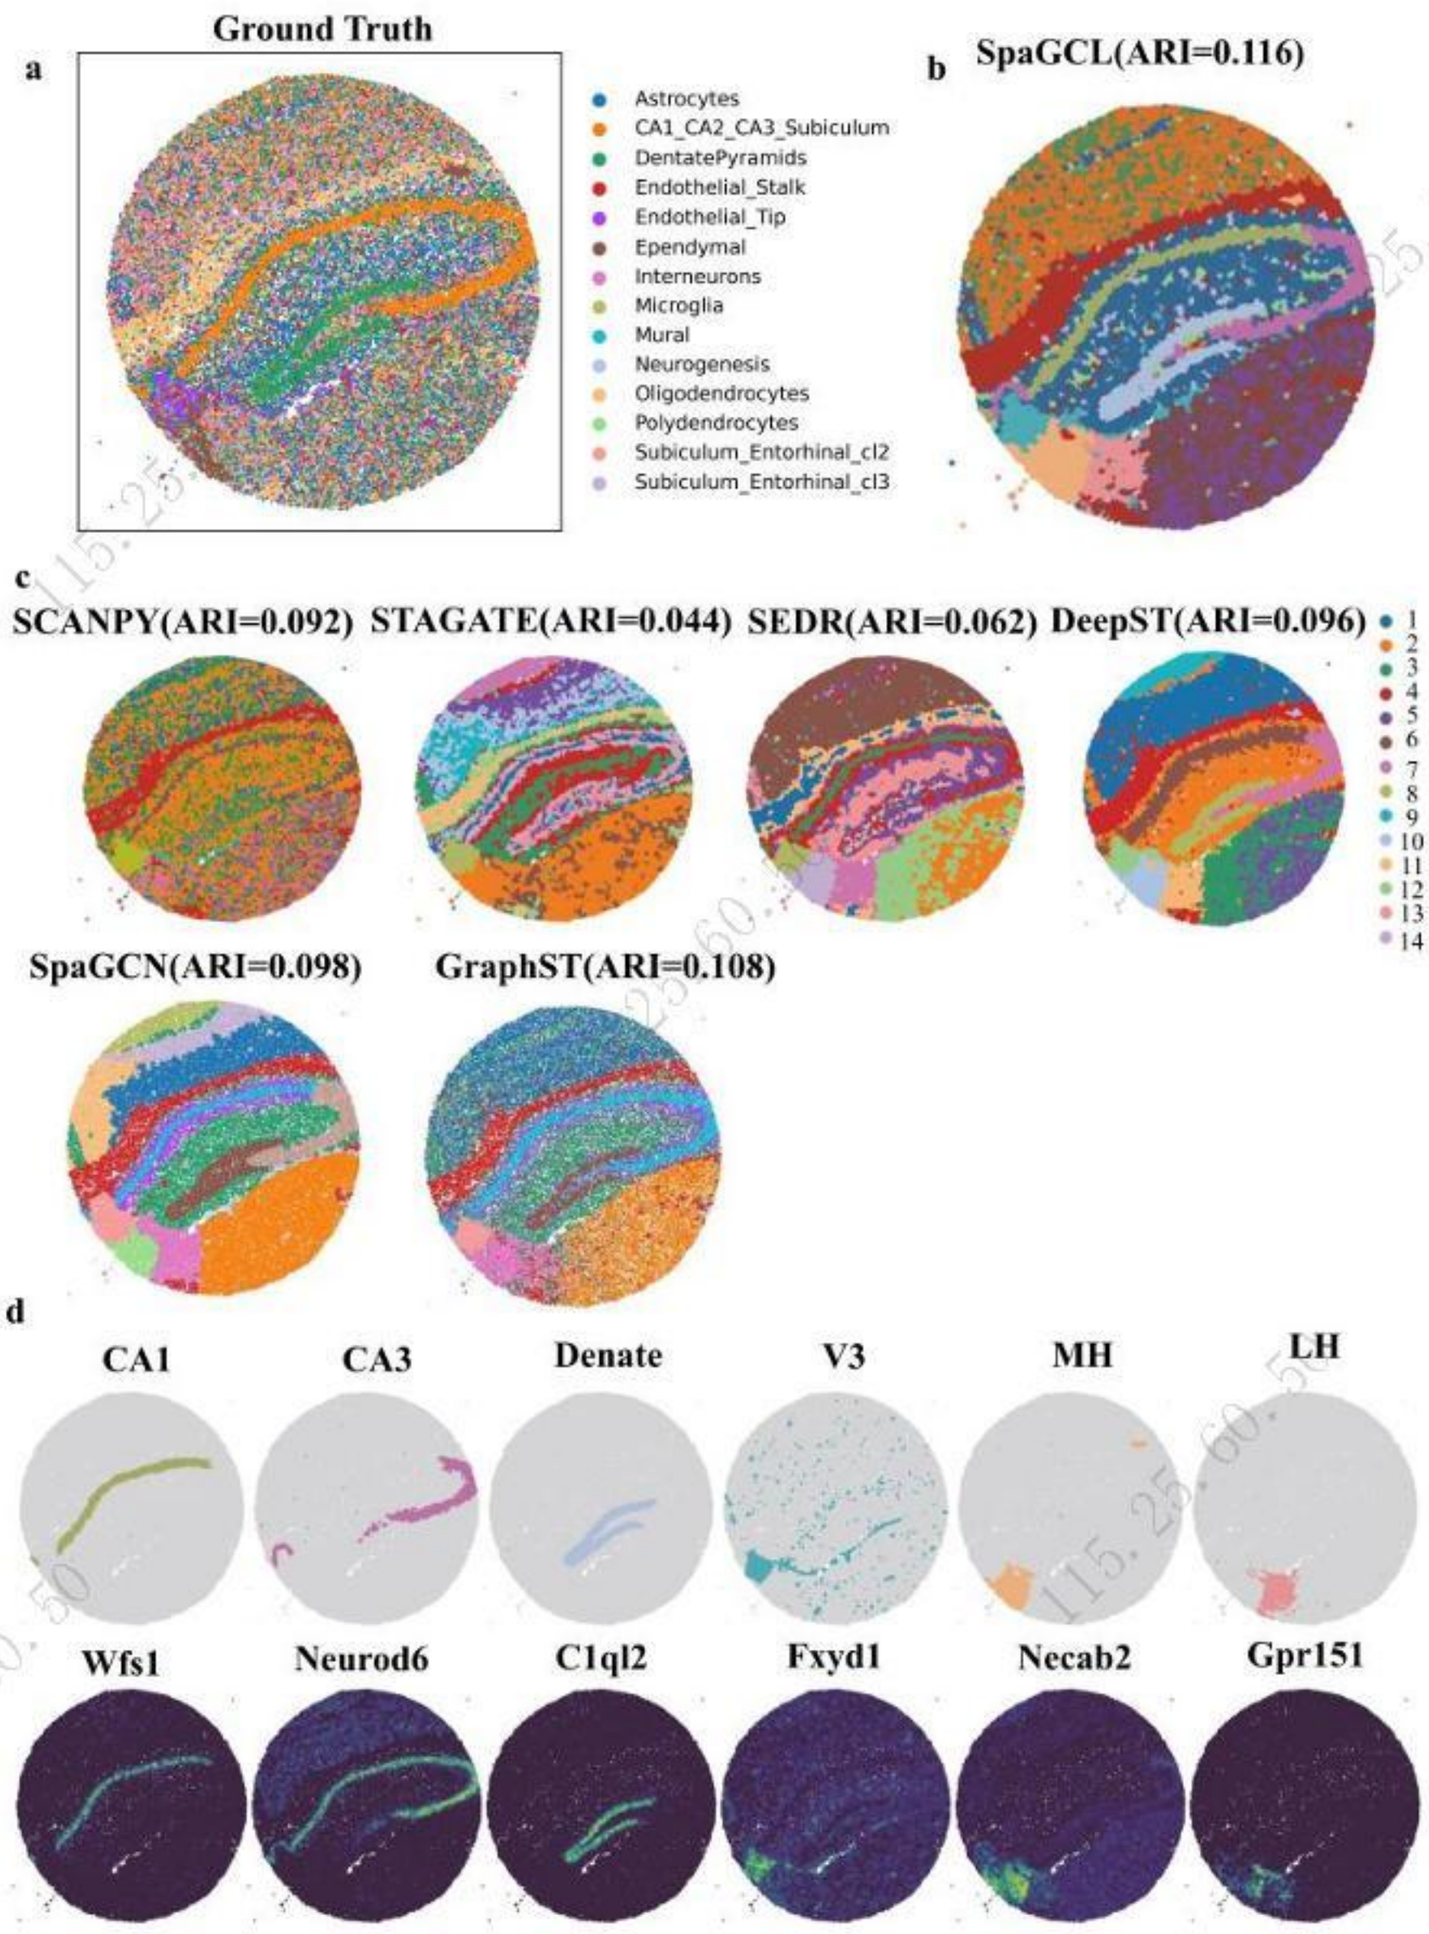


图 3-10 小鼠海马体识别结果

Fig.3-10 Identification Results in the Mouse Hippocampus

图 3-10（a）Slide-seq V2 生成的小鼠海马数据集基于 Allen Mouse Brain Atlas 进行注释。（b）SpaGCL 算法识别的空间域，（c）其他算法识别的空间域。（d）SpaGCL 识别的空间域与艾伦小鼠脑图谱的海马体区域对齐以及相应的标记基因空间表达。

3.5.6 SpaGCL 精细刻画癌组织的空间域

为了验证算法在具有复杂空间模式和异质基因表达的癌症组织中的泛化能力，本论文选取了人类乳腺癌样本进行实验。实验结果如下图 3-11 所示，

SpaGCL 能够有效识别乳腺癌组织中的空间域结构,并在性能上优于其他方法，其 ARI 值为 0.601，较次优算法 SpaGCN（ARI=0.558）提升了 7.71%。

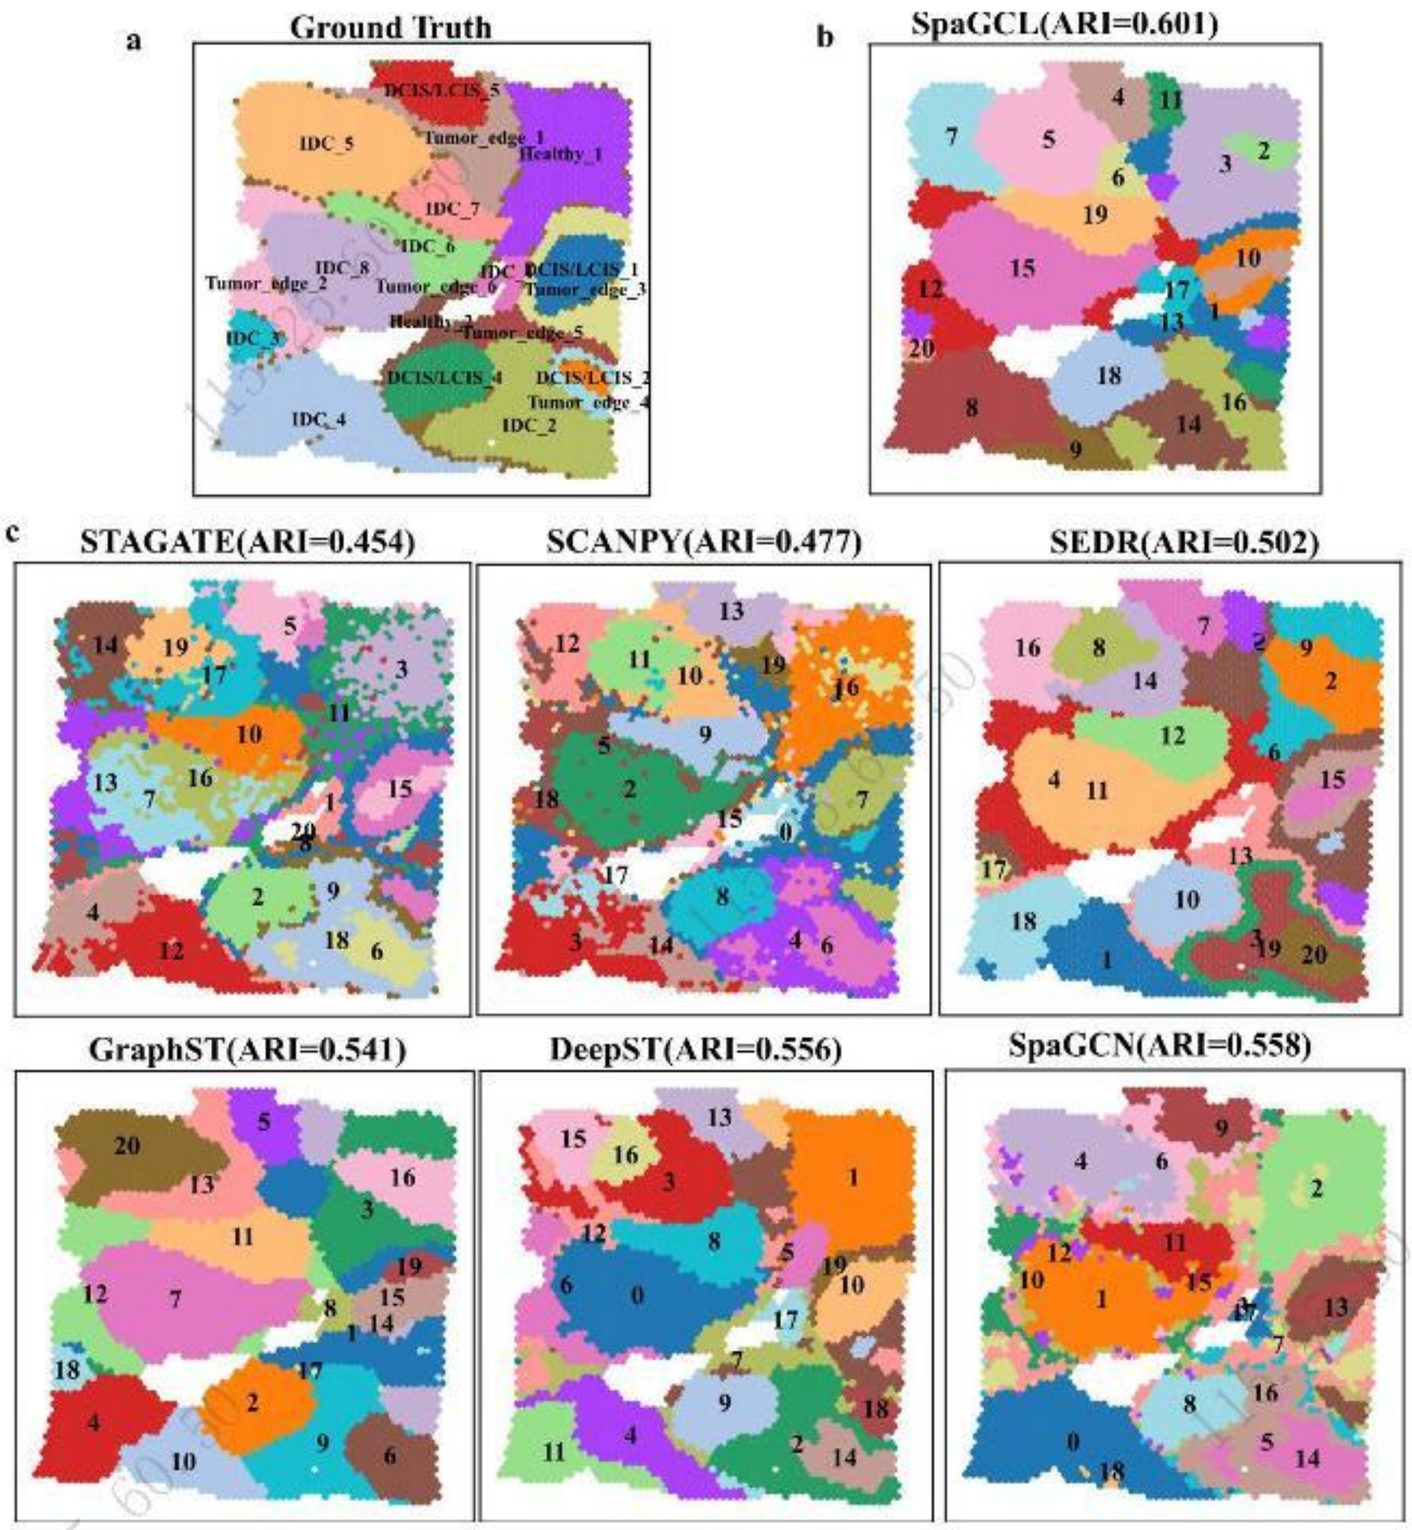


图 3-11 七种算法在人类乳腺癌数据集上的空间域识别结果

Fig.3-11 Spatial Domain Identification Results of Seven Algorithms

图 3-11（a）基于 H&E 染色图像的人类乳腺癌数据集的手动注释。（b）在聚类数量为 20 的情况下，SpaGCL 算法识别的空间域。（c）其他六种算法识别的空间域。

从视觉上来看，所有算法都获得了跟手动注释一致的分类。但 SCANPY 作为一种非空间感知的算法，该算法的聚类结果呈现明显的碎片化。尽管 STAGATE 可以识别主要组织区域,但仍存在明显的聚类混合和大量异常值。同时，SEDR 产生更平滑的结果，但它无法准确识别健康组织并将其分为小簇。

3.6 关键模块评估

为了证明 SpaGCL 算法中关键模块的必要性和有效性，本论文对 DLPFC

数据集进行了消融研究。SpaGCL-w/o-1 表示使用图对比学习框架，将基于基因表达相似性的增强策略改为随机删边策略。SpaGCL-w/o-2 表示不使用组织图特征。SpaGCL-w/o-all 表示两个优化组件都移除，只保留图对比学习框架。

如图 3-12 所示，SpaGCL-w/o-1 的 ARI 平均值为 0.568，SpaGCL-w/o-2ARI 平均值为 0.541。同时去掉两个优化策略的 SpaGCL-w/o-all 性能有明显的下降，ARI 平均值为 0.534。结果表明，删除任何一个优化组件都会导致 SpaGCL 算法的性能下降。

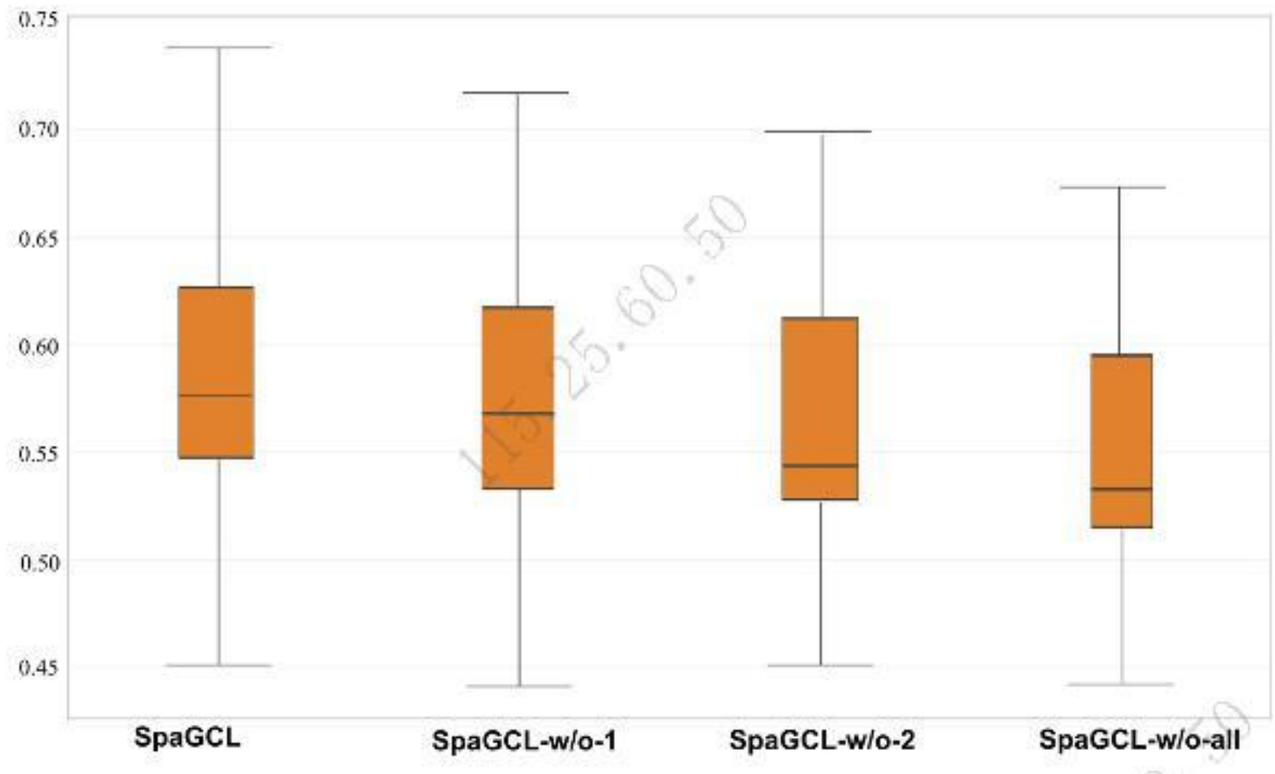


图 3-12 SpaGCL 及其变体在 DLPFC 数据集上的消融实验结果

Fig.3-12 Ablation Study Results of SpaGCL and Its Variants on the DLPFC Dataset

3.7 本章小结

本章针对现有算法的缺陷提出了一种基于图对比学习的空间域识别模型 SpaGCL。它在基因表达特征提取阶段，首先构建 spot 邻接图，并以基因表达余弦相似度作为边权，实现图对比学习中的自适应增强：高相似边赋予高保留概率，低相似边被优先丢弃，在扩大视图差异的同时维护了生物学一致性。随后，引入交叉注意力实现组织形态特征与基因表达特征权重自适应分配。为验证模型性能，本论文在三个 ST 平台的五个真实数据集上对 SpaGCL 进行评估，与六种其他算法相比，SpaGCL 在空间域识别精度和紧凑性和可分离性的聚类表示方面优于其他的方法。

4 基于空间转录组与单细胞的乳腺癌空间异质性研究

乳腺癌作为高度异质性的实体瘤，其组织内部在分子特征、细胞组成及微环境状态上呈现显著的空间差异。这种空间异质性不仅体现在肿瘤核心、侵袭边缘及免疫浸润区域之间的细胞构成与功能差异，也深刻影响着肿瘤的生长动力学、免疫逃逸方式以及治疗响应模式。因此，解析乳腺癌内部的空间组织结构对于理解肿瘤发生发展机制及发现新的治疗靶点至关重要[50]。空间转录组学在解析乳腺癌微环境与空间结构方面具有独特优势，但其分辨率上存在一定局限。相比之下，scRNA-seq 能够在单细胞水平实现高通量基因表达定量，精确刻画细胞群体的异质特征，但无法保留原有的空间位置信息。将 ST 与 scRNA-seq 技术整合，可在高分辨率识别细胞类型的同时恢复其空间背景，从而实现技术互补。

为了深入探索乳腺癌的空间异质性，本论文联合应用 ST 与 scRNA-seq，对第四章识别的乳腺癌空间域进行系统分析，通过构建具备空间分辨能力的基因表达图谱，旨在从结构层面解析其异质特征，为理解肿瘤生物学提供新的视角。

4.1 联合单细胞数据解析乳腺癌细胞组成与空间分布

为了阐明人类乳腺癌的肿瘤微环境，本论文从基因表达综合数据库（Gene Expression Omnibus，GEO）选择了 scRNA-seq 数据集 GSE176078，数据集下载地址：https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE176078。该数据集包含 26 例原发性乳腺癌患者样本，其中包含 11 例雌激素受体阳性（Estrogen Receptor Positive，ER+）样本，5 例人表皮生长因子受体 2 阳性（Human Epidermal Growth Factor Receptor 2 Positive，HER2+）样本和 10 例三阴性乳腺癌（Triple-Negative Breast Cancer，TNBC）样本[51] 。

该数据集涵盖了 9 种主要细胞类型、29 种次要细胞类型和 49 种子集细胞类型的注释。鉴于乳腺癌空间转录组样本的分子分型是 ER+、孕酮受体阴性（Progesterone Receptor Negative，PR-）和 HER+，本论文仅选择 11 名 ER+和 5 名 HER2+患者。本论文还对数据集进行了质量控制，排除表达低于 5 个细胞或占总细胞 3%的基因。质量控制后的 scRNA-seq 数据集如图 4-1 所示。

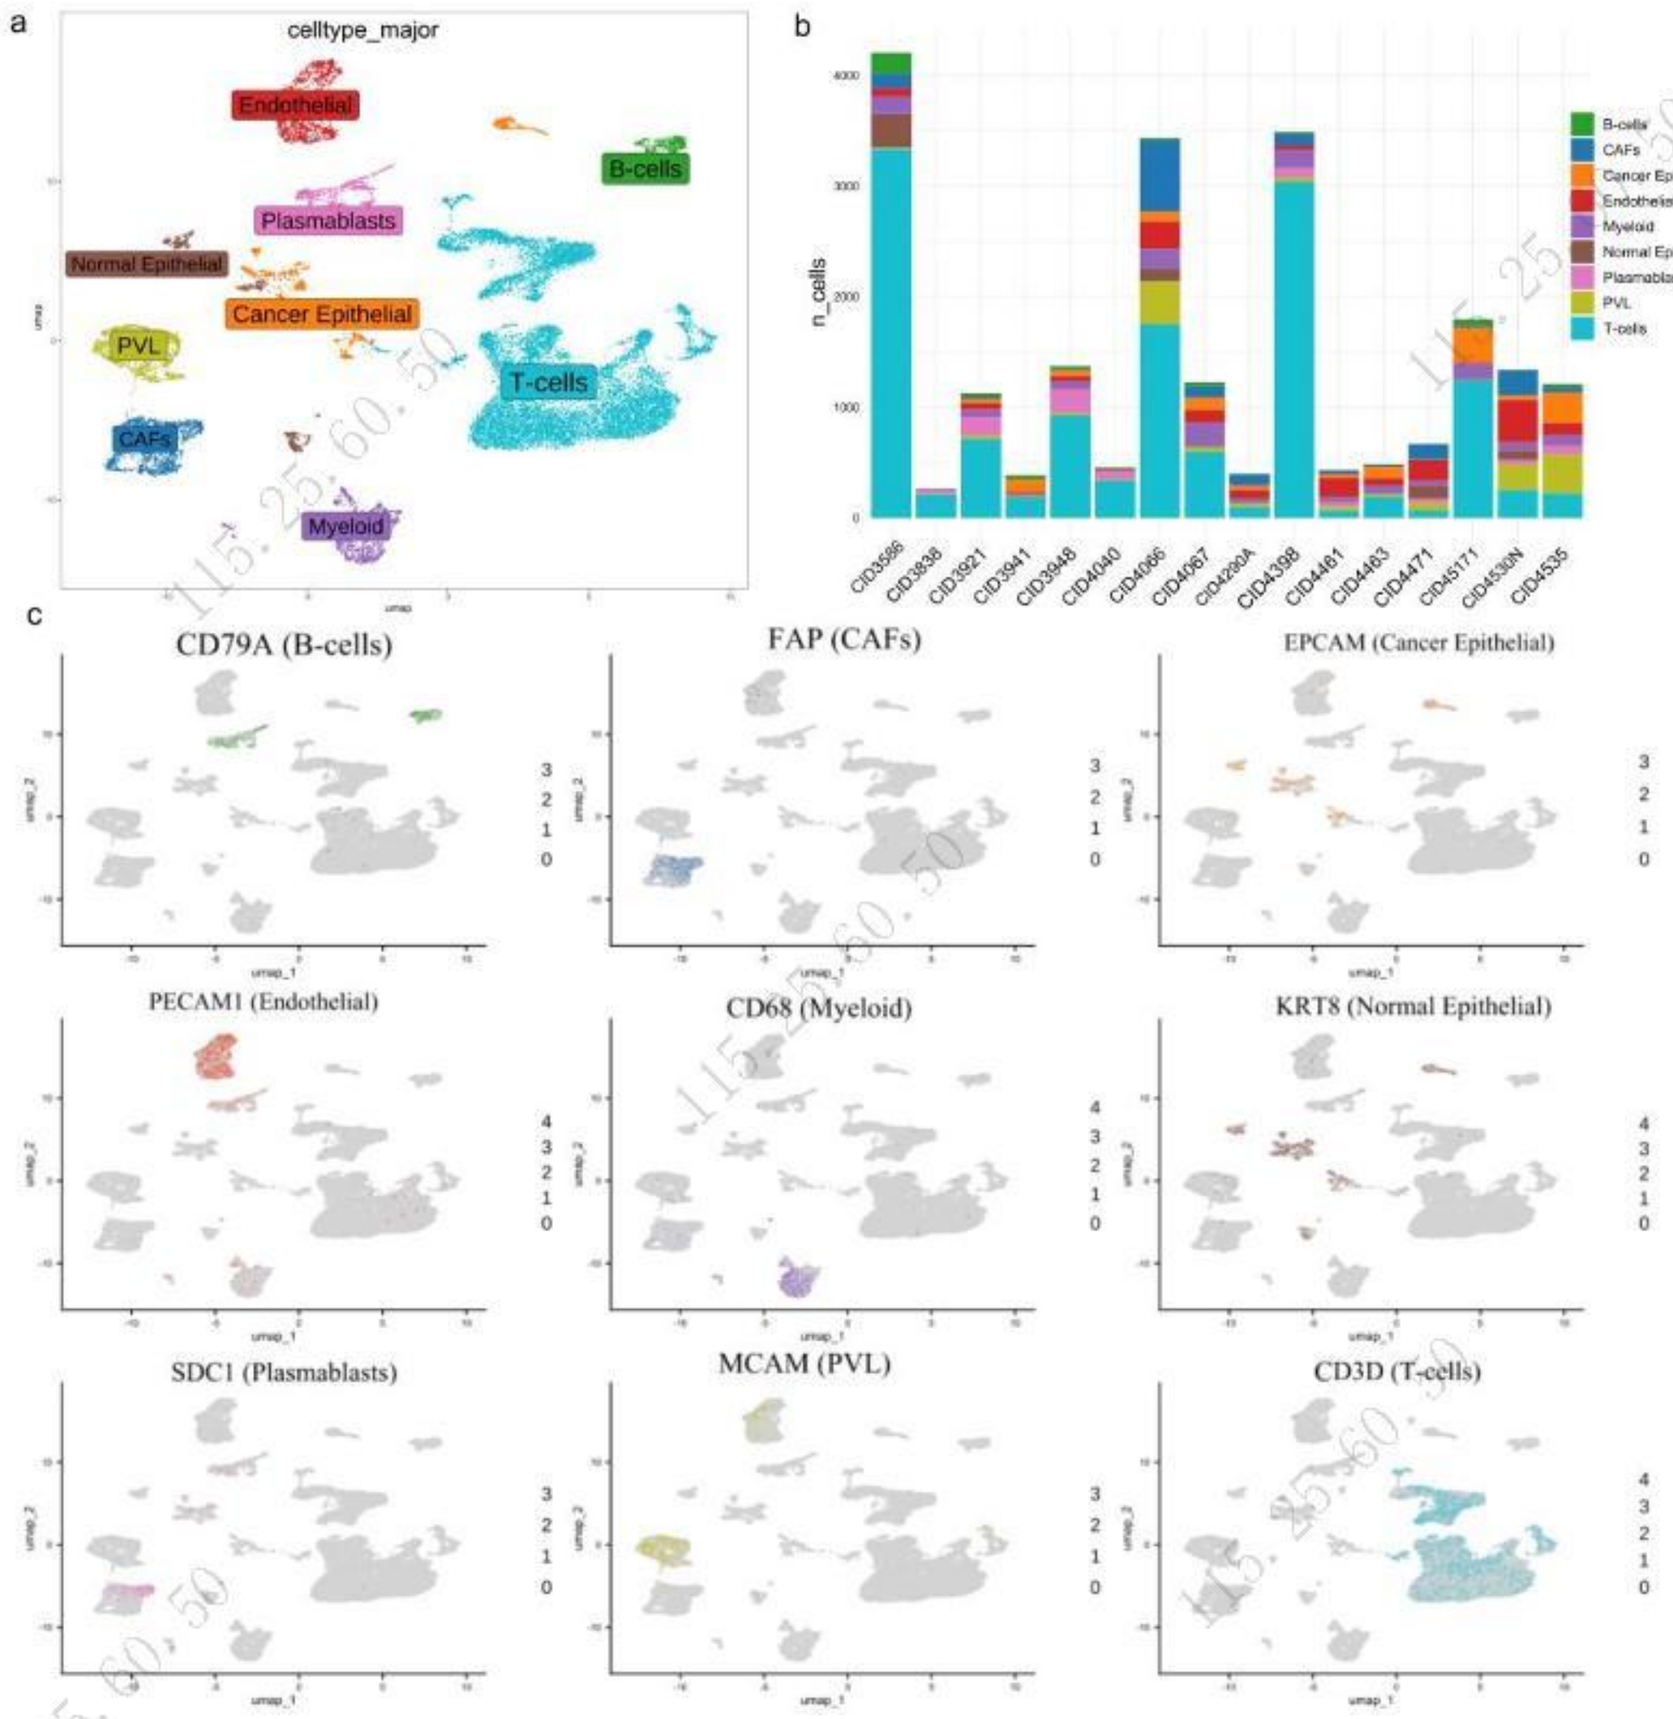


图 4-1 单细胞数据集主要细胞类型及标志基因

Fig.4-1 Overview of major cell types and their marker genes in scRAN-seq dataset

（a）九种主要细胞类型的 UMAP 图，（b）16 名患者的细胞类型组成，（c）细胞类型的标志基因 UMAP 图。

在乳腺癌研究中，组织内不同细胞类型的空间分布对疾病进展和治疗反应有重要影响。由于空间转录组数据无法达到单细胞分辨率，每个 spot 实际上包含多种细胞类型。为此，本论文采用 Cell2location 算法[52]对 spot 进行反卷积，得到各细胞类型的丰度，即每种细胞在 spot 中所占比例。采用后验分布的 5%分数，以获取高置信度的细胞丰度估计结果。图 4-2 展示了各空间域的细胞类型组成，其中空间域 20 内不存在癌细胞，而显著富集了大量的免疫细胞。图 4-3 描述了不同细胞类型的空间分布，其中绿色区域富集免疫细胞，粉色与紫色区域为癌细胞富集区。

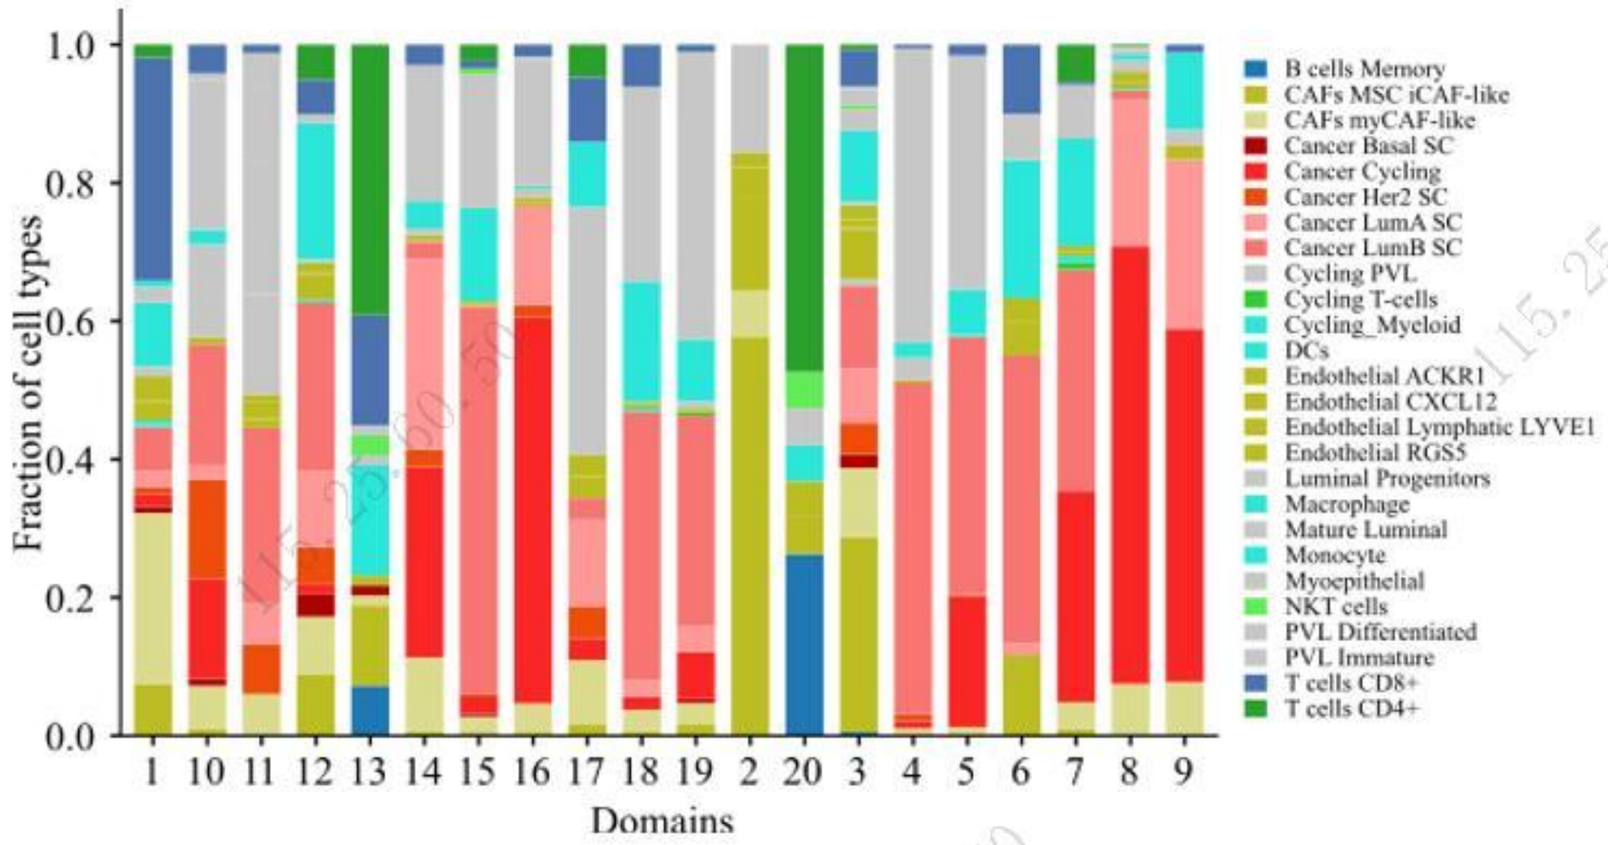


图 4-2 乳腺癌样本中不同空间域的细胞类型占比

Fig.4-2 Cell Type Proportions in Different Spatial Domains of Breast Cancer Samples

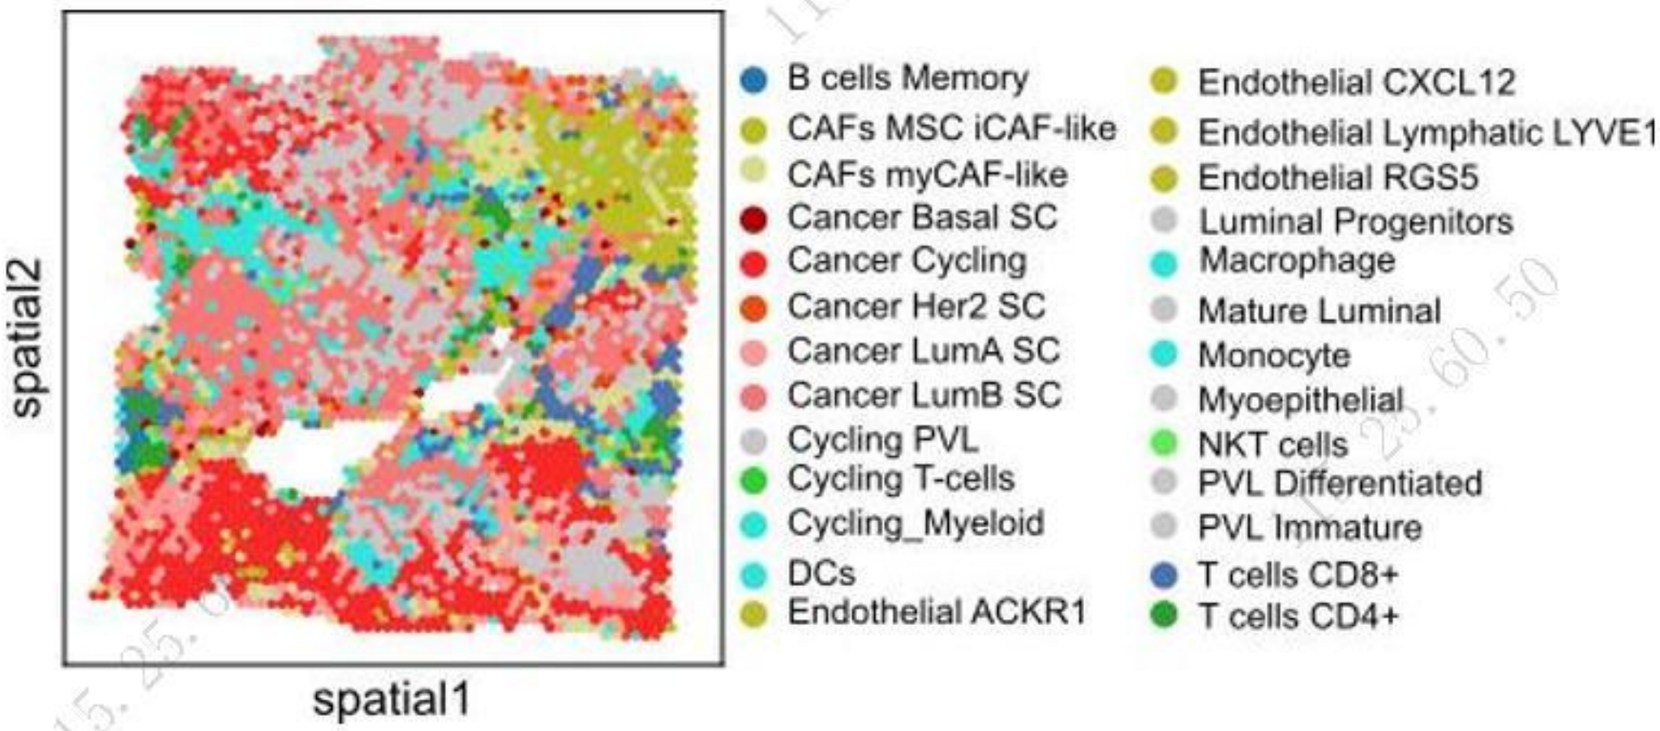


图 4-3 细胞类型的空间分布

Fig.4-3 Spatial distribution of cell types

4.2 肿瘤区域细胞组成及功能异质性

通过上述分析可以发现乳腺癌样本里存在不同的乳腺癌细胞，本论文进一步构建了肿瘤区域的细胞空间分布空间，如下图 4-4 所示。从图中可清晰观察到，乳腺癌样本中存在多种癌细胞亚型，且细胞分布呈现明显的空间聚集特征，表明肿瘤区域是由高度异质性的细胞生态系统构成。癌症基底干细胞（Cancer Basal SC）作为一种驱动肿瘤发生、具有高度侵袭性与治疗抵抗性的关键细胞亚群，主要富集于空间域 7 和空间域 8 中。值得注意的是，空间域 8 同时聚集了大量处于活跃繁殖状态的 Cancer Cycling 细胞和 Cancer LumA SC，表明这个区域不仅是干细胞巢，也是肿瘤增殖的核心区。Cancer Her2 SC

在空间域 10 中特异性高表达，管腔 B 型癌症干细胞（Cancer LumB SC）则主要富集于空间域 15 中。除癌细胞亚群外，肿瘤区域还存在免疫细胞和上皮细胞，其中增殖态髓系细胞（Cycling_Myeloid）和树突状细胞（DCs）主要分布于癌细胞聚集的外缘，这提示外缘区域可能是免疫细胞活跃募集与抗原呈递的重要场所。

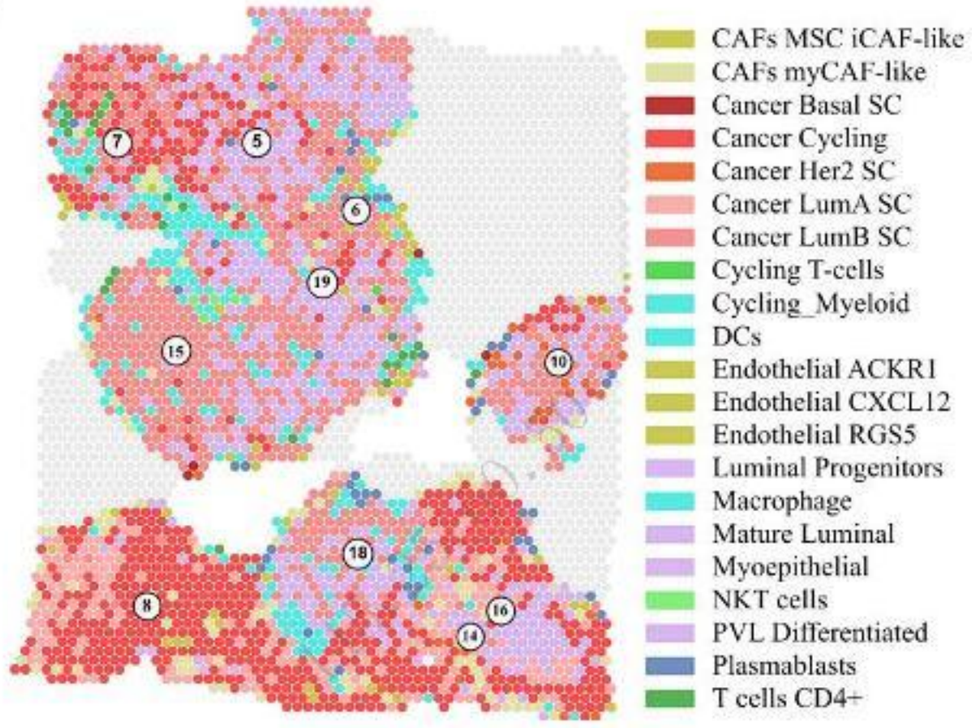


图 4-4 肿瘤区域的空间分布

Fig.4-4 Spatial Distribution of Distinct Cancer Cell Types

为了探究肿瘤区域间的异质性，本论文选取了在空间分布和细胞组成上具有显著差异的空间域 15 和空间域 8 进行对比分析。通过基因表达差异分析，共检测到 213 个显著差异表达基因，其中上调基因 141 个，下调基因 72 个，其分布见火山图（图 4-5）所示，横坐标表示基因表达差异倍数log2FC，其绝对值越大代表表达差异越大；纵坐标表示差异表达的显著性（$-\mathrm{Log}_{10}(\mathrm{AdjustedP-value})$），数值越大表明差异越显著，结果可信度越高。

在空间域 8 中显著表达的基因（CXCL14、CCND1、KRT8、AGR2 和 TCEAL4）参与了肿瘤的形成、侵袭和转移的过程、肿瘤抑制（CXCL14）。在这些重要的 DEGs,已发现 CXCL14 在乳腺癌中具有预后意义，表明其作为重要生存预测因子的潜力[53]。此外，CCND1 已被证实可驱动原发性乳腺肿瘤的扩增，进一步确立了其在乳腺癌发展中的关键作用[54]。本论文进一步分析了关键基因的空间表达模式。如图 4-6 所示，CCND1 基因在空间域 8 中呈现特异性高表达，而 HLA-C 基因则显著富集于空间域 15。这一发现从基因层面揭示了不同肿瘤区域间的异质性。

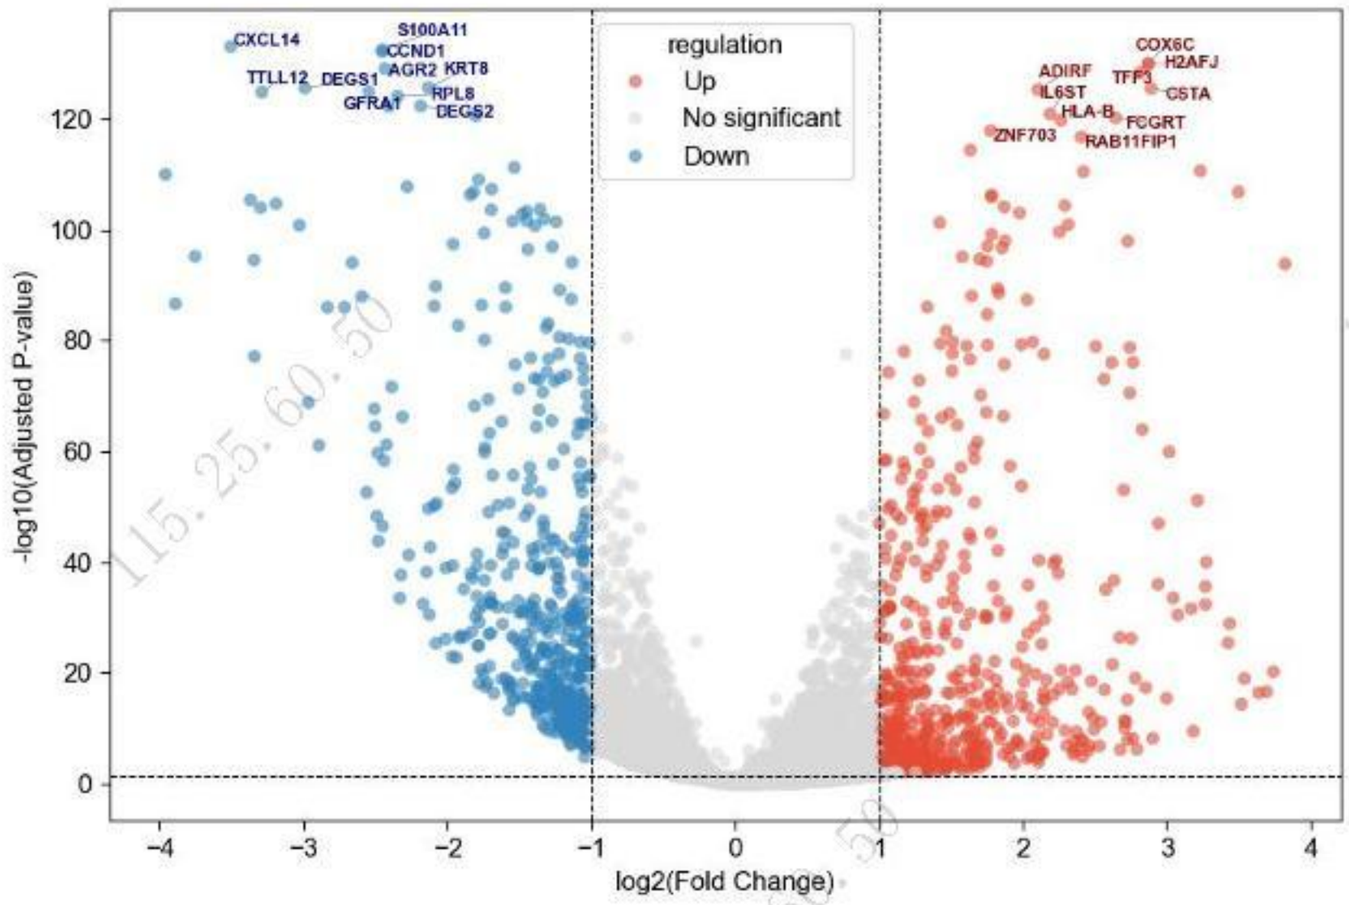


图 4-5 两个肿瘤区域间的差异基因表达分析

Fig.4-5 Differential Gene Expression Analysis Between the Two Spatial Domains

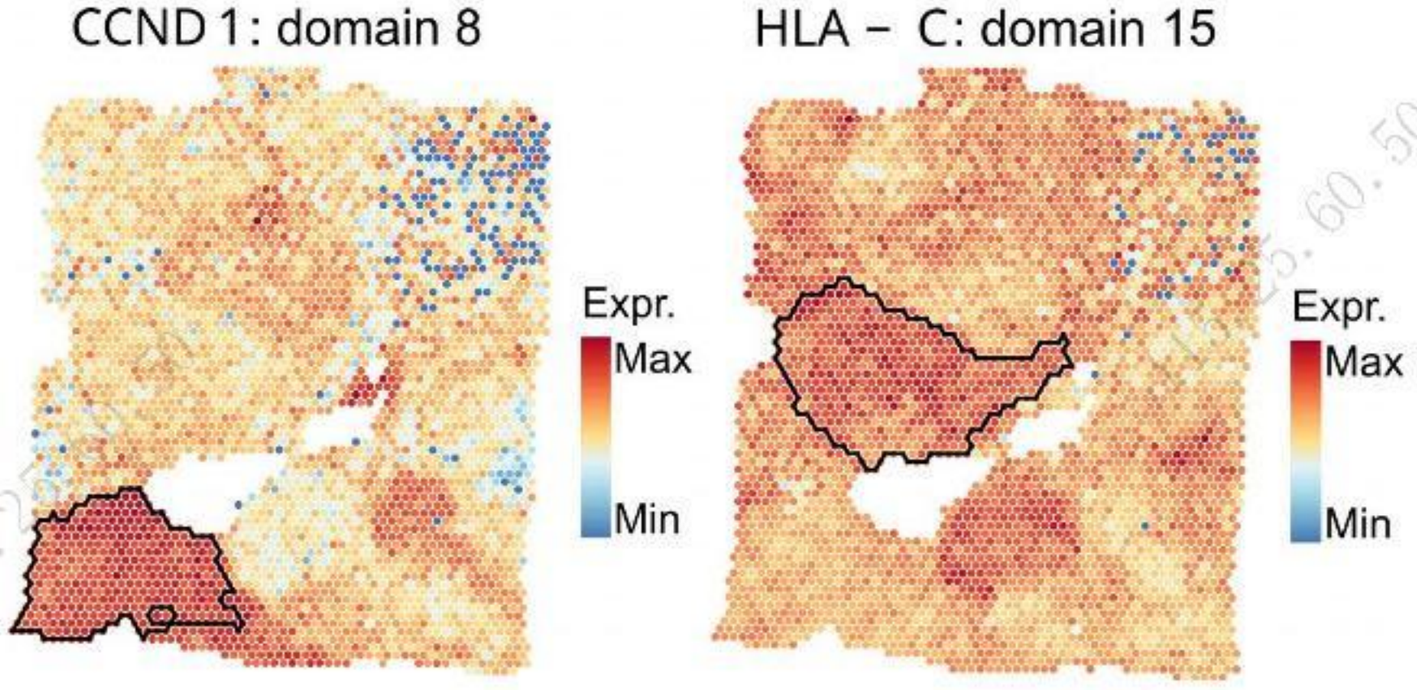


图 4-6 空间的高可变基因

Fig.4-6 Spatially Variable Genes (SVGs) in the Spatial Domain

为了解析上述空间区域的特异性生物学功能，本论文基于 213 个差异基因，采用 clusterProfiler 包[55]进行 KEGG 通路富集分析。分析设定校正后 P 值<0.05 且 FDR<0.25 为显著性阈值，结果以柱状图展示（图 4-7）。分析结果与已有研究一致：空间域 15 富集于免疫细胞杀伤与粘附等相关通路，显示出免疫反应和细胞修复的趋势，而空间域 8 则主要富集于细胞周期与氧化应激通路，表明该区域以细胞增殖及应激适应为主导功能。该发现从通路层面进一步证实了肿瘤内部存在功能异质性的空间区域[56]。

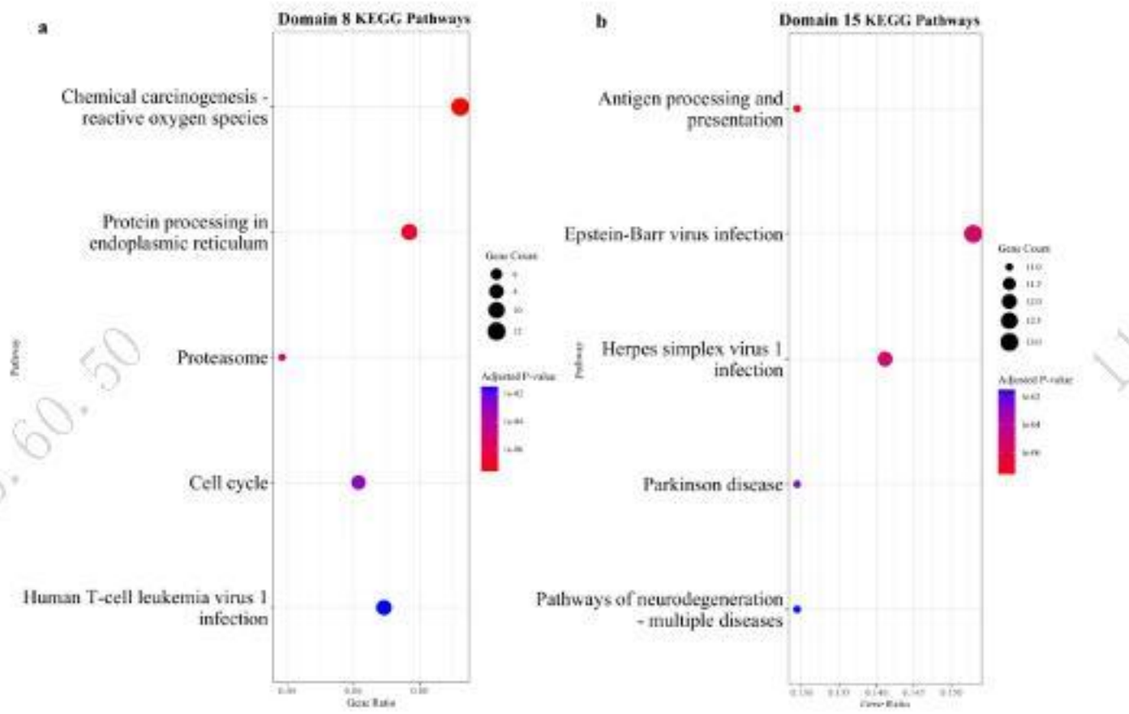


图 4-7 空间域 8 和空间域 15 的 KEGG 通路富集分析

Fig.4-7 KEGG Enrichment Analysis for Spatial Domains 8 and 15

4.3 肿瘤边缘细胞组成与功能异质性

为探究肿瘤发生与发展过程中的空间细胞特征，本论文对肿瘤边缘区域进行了精细的空间域分层与细胞空间分布。如下图 4-8 所示，与肿瘤核心区域细胞组成不同，肿瘤边缘主要由免疫细胞、成纤维细胞、上皮细胞以及少量癌细胞组成，提示该区域是免疫浸润与基质重塑的重要界面。进一步的细胞标志基因空间表达分析（图 4-9）与上述细胞组成一致：免疫相关基因 IGHG1 和 IGLC2 在肿瘤边缘（空间域 1）显著富集，表明大量活化的 B 细胞和浆细胞浸润。同时，基质相关基因 COL1A2 也主要分布于肿瘤边缘，表明该区域存在明显的胶原沉积与成纤维细胞活化。综合而言，肿瘤边缘呈现免疫活跃与基质重塑并存的特征，是肿瘤–宿主相互作用的关键功能区域。

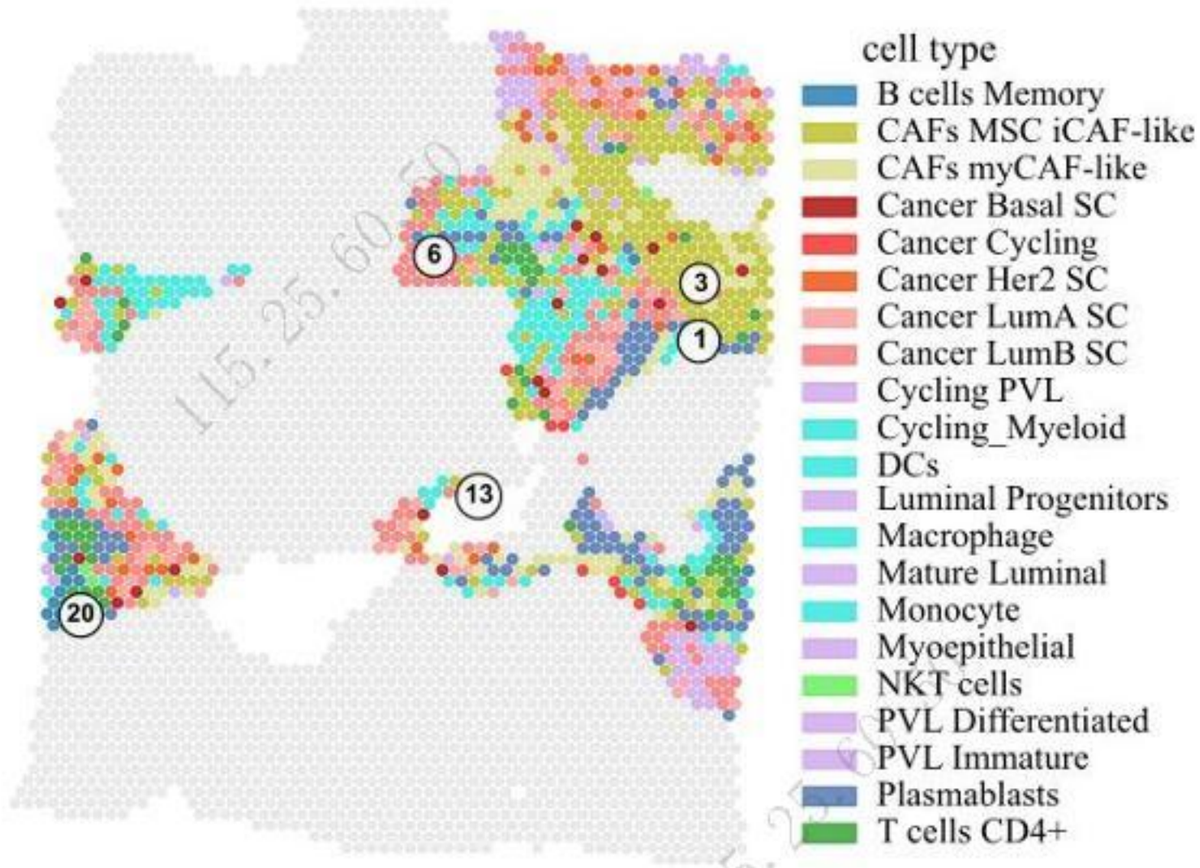


图 4-8 肿瘤边缘细胞空间分布

Fig.4-8 Cellular Spatial Distribution at the Tumor Margin

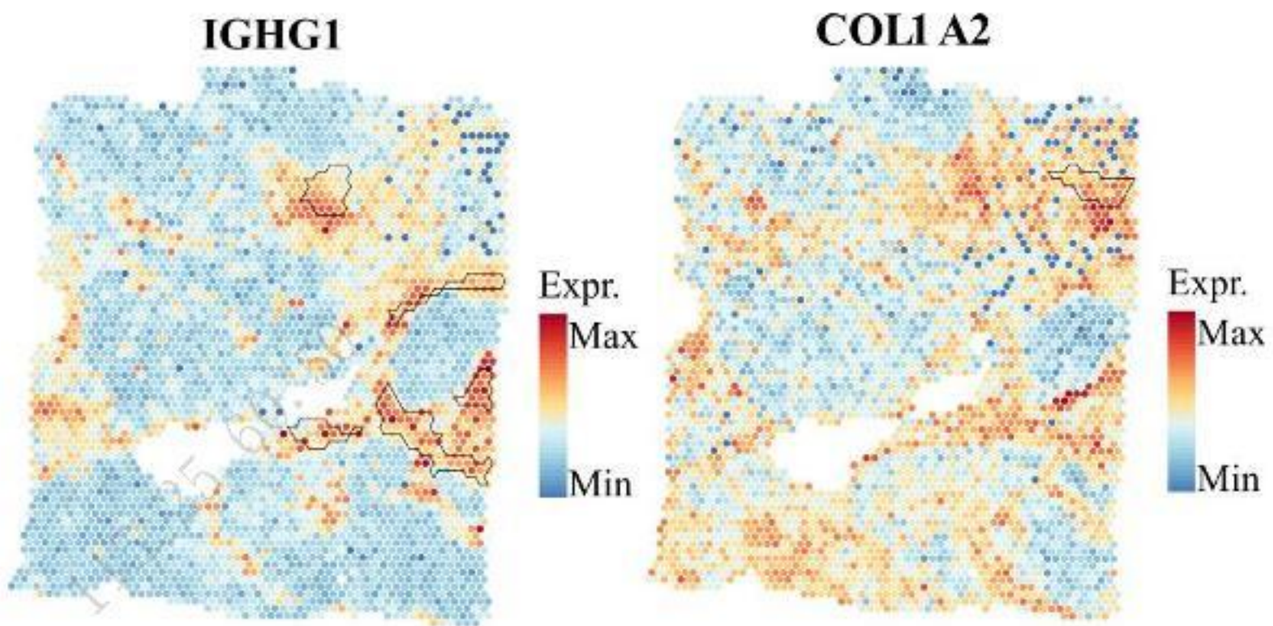


图 4-9 细胞标志基因的空间分布

Fig.4-9 Spatial Distribution of Marker Genes

空间分析显示，CAFs 呈现功能亚型的分区化富集：CAFs MSC iCAF-like 细胞主要定位于邻近正常组织的区域（空间 3），相比之下，靠近肿瘤前沿的空间域 1 则以 CAFs myCAF-like 细胞为主。该空间分布模式与既往关于 CAFs 异质性及其空间定位的研究报道相一致，进一步支持了本论文对肿瘤边缘微环境结构的解析[57]。作为肿瘤基质的重要组成部分，CAFs 在肿瘤进展和转移中发挥着重要作用。包括促进癌症血管促进生成和转移、诱导耐药性、重塑细胞外基质和发展免疫抑制微环境。同时，一些研究表明，CAFs 在特定癌症类型中可以抑制肿瘤[58]。

为更直观地呈现不同 CAFs 亚型的空间定位特征，本论文分别绘制了 CAFs MSC iCAF-like 与 CAFs myCAF-like 在组织中的空间分布图谱。如下图 4-10 成纤维细胞主要分布在肿瘤边缘区域所示，结果显示，AFs MSC iCAF-like 主要聚集于靠近正常组织的空间域 3，CAFs myCAF-like 则富集于邻近肿瘤前沿的边缘区域。

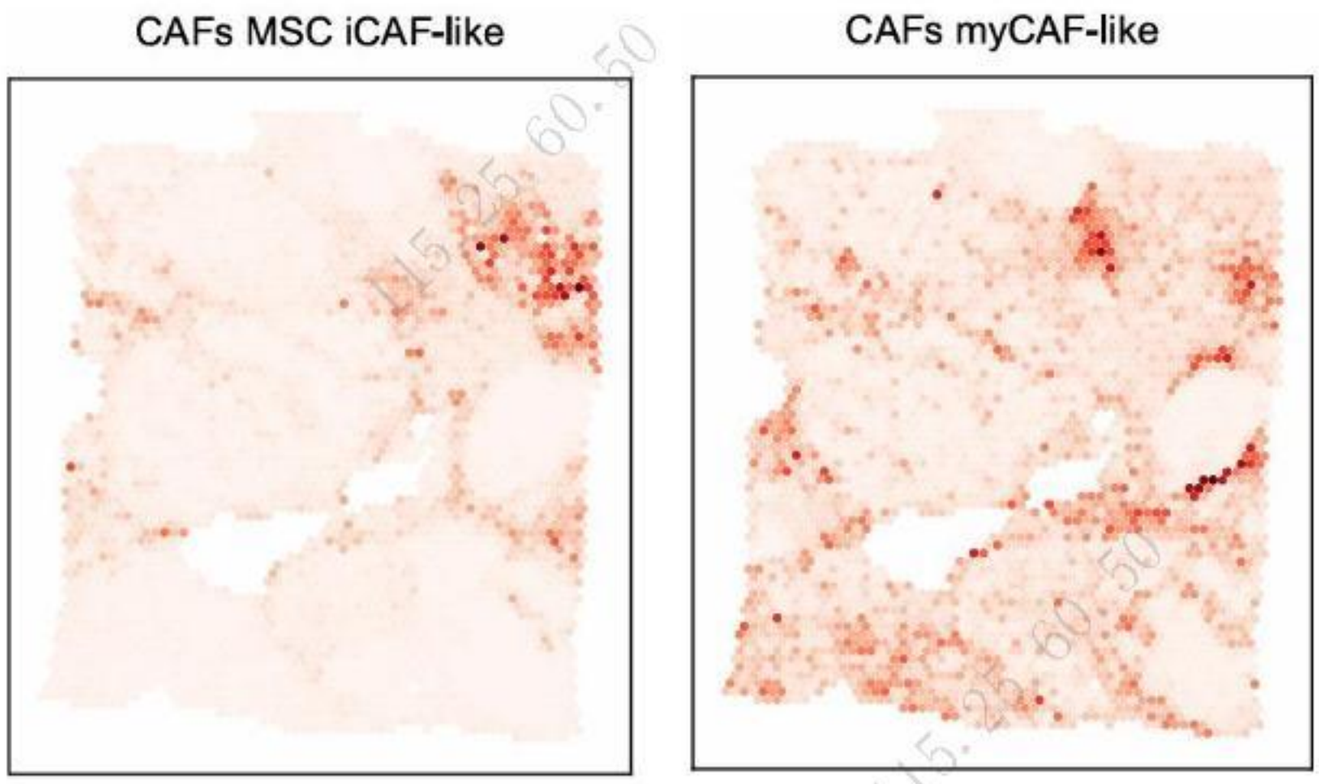


图 4-10 成纤维细胞主要分布在肿瘤边缘区域

Fig.4-10 Fibroblasts are predominantly distributed in the tumor marginal region

为进一步阐明空间域 1 与空间域 3 在生物学功能上的差异，本文采用 GO 功能注释对两个区域的差异基因进行生物过程（Biological Process，BP）分子功能（Molecular Function、MF）和细胞组分（Cellular Component、CC）层面的功能注释。如下图 4-11 所示，分析表明，空间域 1 的基因显著富集于细胞外基质组织、胶原纤维形成及 TGF-β 受体信号通路，表明该区域细胞外基质重塑活跃并受到 TGF-β 信号调控，其基因特征以胶原相关基质及纤维结构成分为主[59]。相比之下，空间域 3 富集于组织再生过程和血管生成调控等过程，显示修复及血管生成特征。其分子功能主要涉及糖胺聚糖结合和肝素结合，提示细胞与基质分子相互作用及分泌活动增强[60]。

总体而言，肿瘤边缘区域呈现由外向内的功能梯度：空间域 1 强化细胞外基质重塑与侵袭支持，空间域 3 则偏向炎症与组织反应。这一差异强调了肿瘤边缘的功能异质性及其在肿瘤扩张过程中的重要作用。

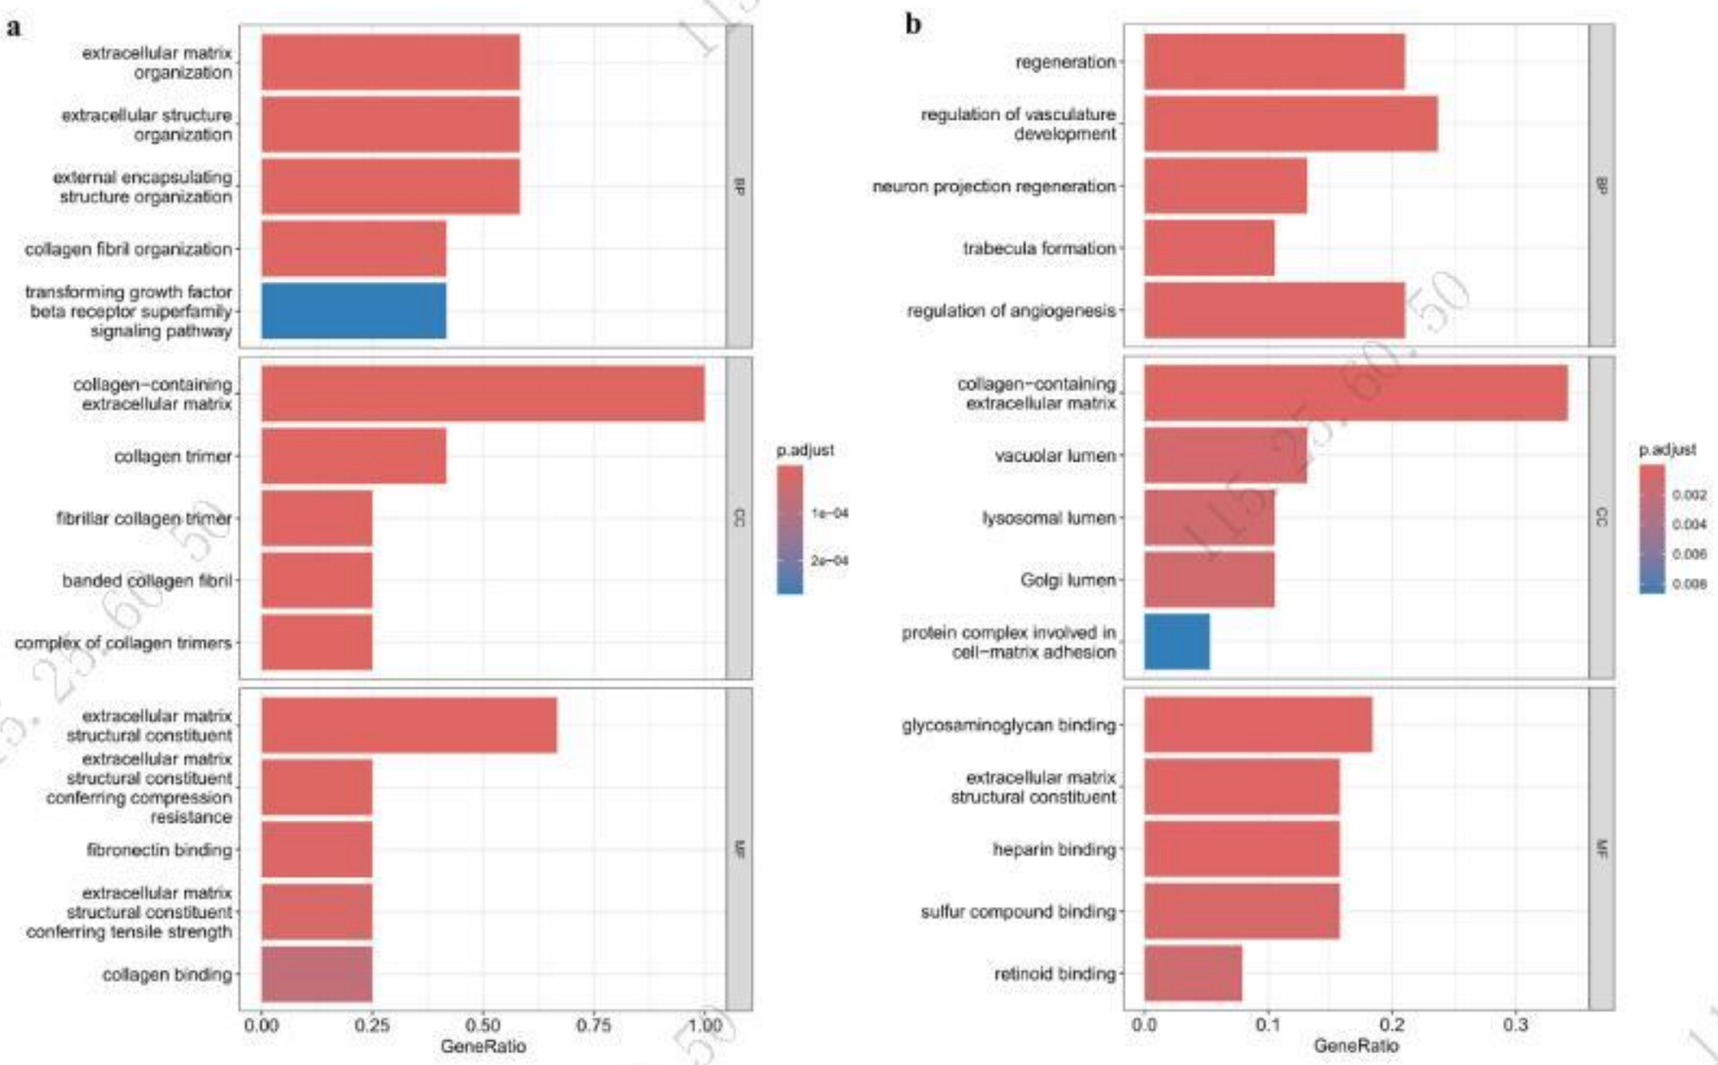


图 4-11 肿瘤边缘区域的功能分析

Fig.4-11 Functional analysis of the tumor edge region

（a）空间域 1 的 GO 富集分析，（b）空间域 3 的 GO 富集分析。

4.4 基于免疫细胞空间聚集识别 TLS 微环境

通过的细胞类型空间分析，本论文观察到空间域 20 显示为绿色，表示该区域富集大量免疫细胞。随后，针对免疫细胞进行空间定位分析，如下图 4-12 所示，图中的红色越深表示该区域免疫细胞的富集程度越高。具体来看，

图 4-12（a）显示了 T 细胞的空间分布，T cells 4+、T cells 8+ 和 NKT cells 主要分布于肿瘤边缘区域，其中空间域 20 的颜色呈现黑红色，反映该区域 T 细胞的高富集程度。图 4-12（b）显示了 B cells Naïve 和 B cells Memory 也富集于空间域 20。通过对免疫细胞的空间分布的综合分析，可以观察到 B 细胞与 T 细胞在空间域 20 内显著共同富集，这种协同的聚集的模式符合 TLS 的典型组织特征[61-63]。

TLS 是在慢性炎症或肿瘤微环境中形成的一个免疫激活中心[64]。在肿瘤微环境中，TLS 的存在标志着局部免疫反应的加强，并促进癌细胞抗原识别和呈递以及促进抗肿瘤免疫反应[65]。因此，TLS 被视为肿瘤免疫微环境中重要的预后标志[66]。

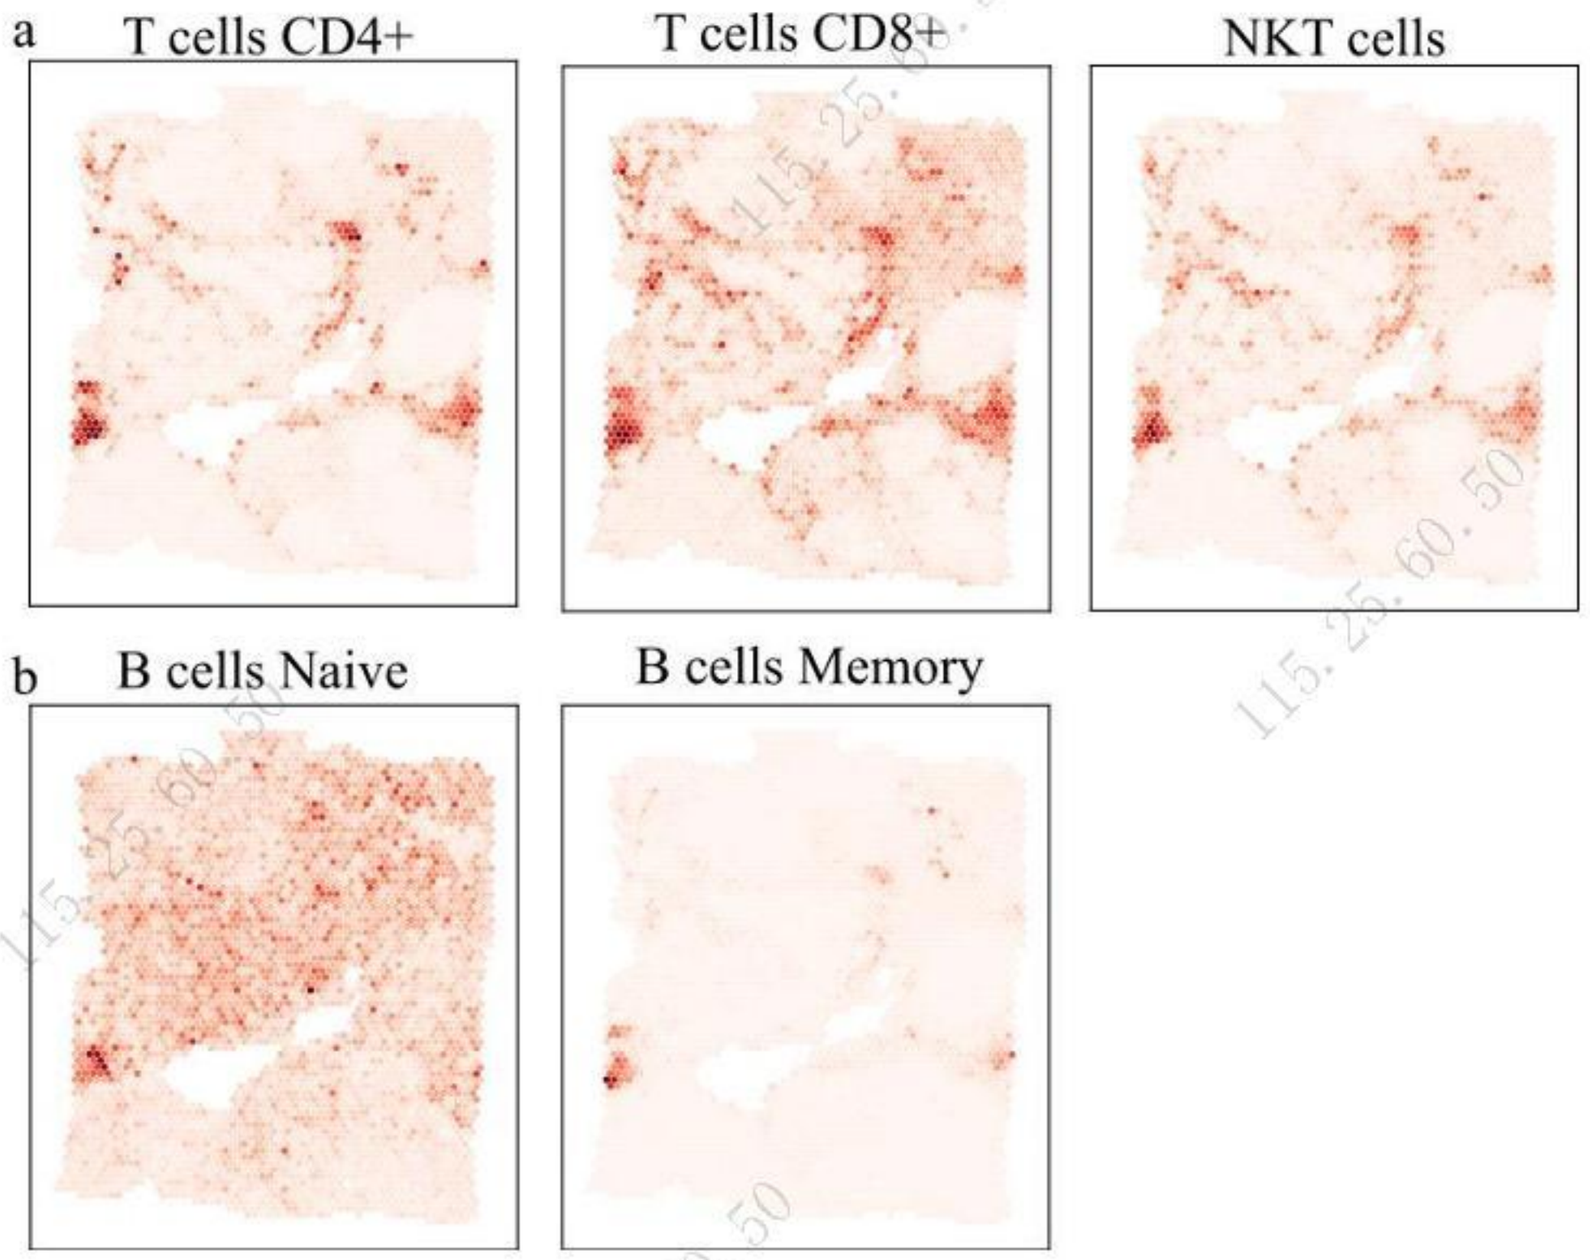


图 4-12 B 细胞和 T 细胞富集于空间域 20

Fig.4-12 B cells and T cells are enriched in spatial domain 20

随后，为了定量评估细胞类型之间的空间共定位关系，本论文采用 Spearman 相关系数（Spearman's Rank Correlation Coefficient，SCC）对各细胞类型在组织内不同 spot 上的丰度进行相关性分析。假设 S_K 是细胞类型的丰度载体 K 在组织内的所有 spot 中，两种细胞类型之间的 K 和 M 定义如(4-1)所示：

$$SCC_{K,M} = \frac{cov\left(R\left(S_K\right), R\left(S_M\right)\right)}{\sigma R\left(S_k\right)\sigma R\left(S_M\right)} \tag{4-1}$$

其中，$R\left(S_K\right)$和$R\left(S_M\right)$表示细胞类型的等级丰度 K 和 M，$cov\left(R\left(S_K\right), R\left(S_M\right)\right)$是它们的协方差，而$\sigma R\left(S_k\right)$和$\sigma R\left(S_M\right)$是它们的标准差。SCC 的值范围为-1 至 1，其中接近 1 表示高度共定位，接近-1 表示强负相关，而接近 0 表示共定位关系较弱。

下图 4-13 显示了细胞类型之间空间共定位的 SCC 热图。颜色越深表示相关性越强。分析结果表明，细胞毒性 T 细胞（T cells CD8+）与记忆 B 细胞（B cells Memory）之间呈现最显著的共定位特征，其 SCC 值在所有细胞类型对中居于最高水平。此高度共定位的空间结构与 TLS 的典型免疫组成高度一致，进一步支持了空间域中 TLS 的免疫微环境特征。

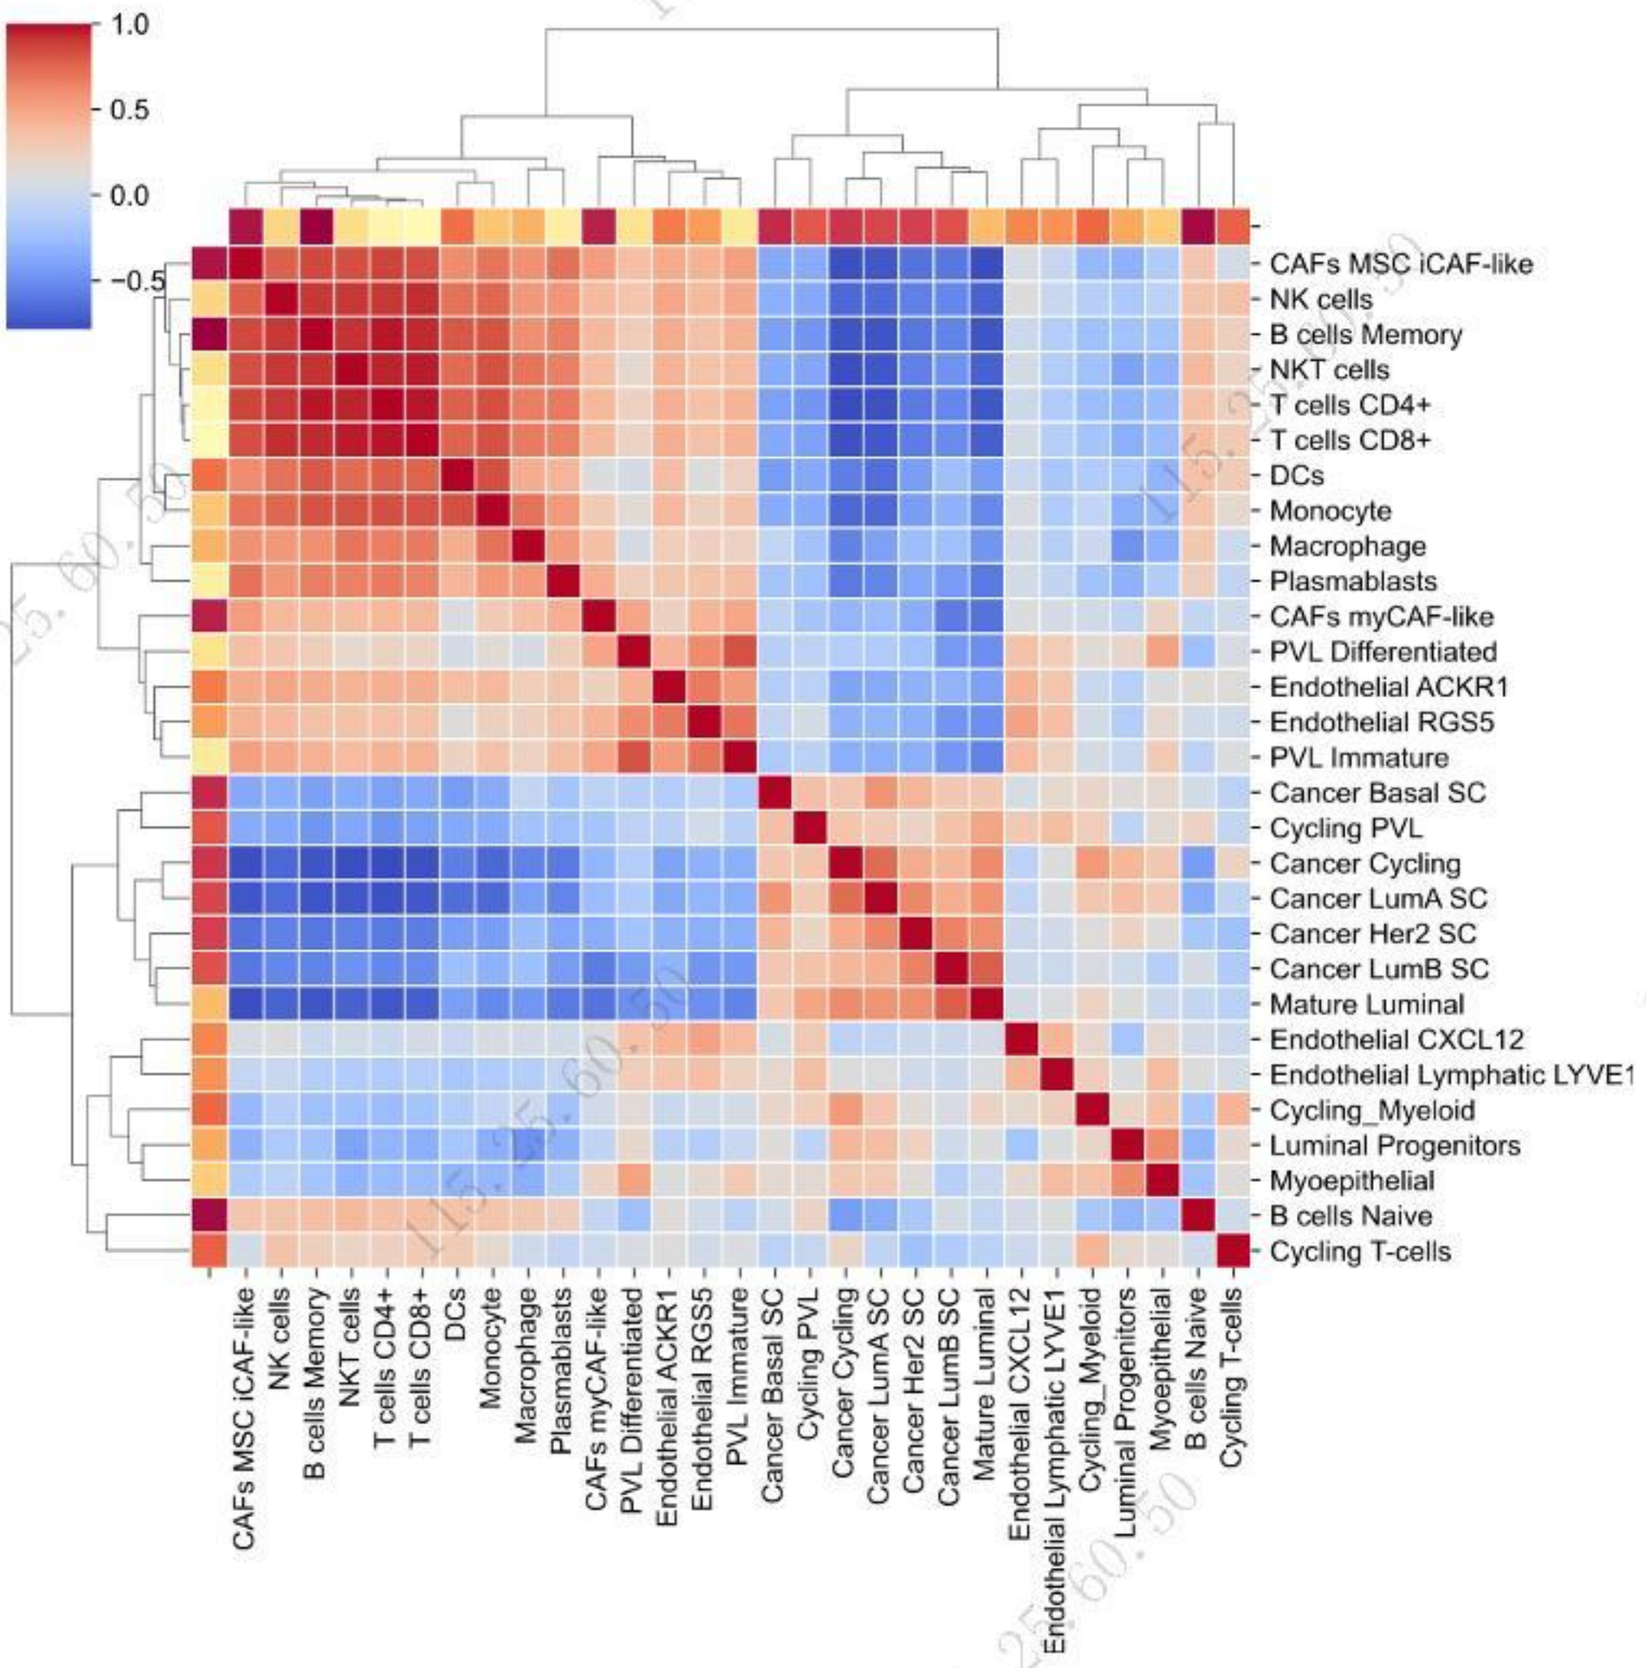


图 4-13 细胞类型间的 SCC 值

Fig.4-13 SCC Matrix across Cell Types

4.5 本章小结

本论文通过整合单细胞与空间转录组数据，系统揭示了人类乳腺癌的高度空间异质性。首先，利用 Cell2location 进行细胞类型解卷积，精确绘制了多种细胞在组织原位的空间分布图谱。结果显示，单个肿瘤内部存在显著的细胞组成差异，Cancer Basal SC、Cancer LumA SC、Cancer Her2 SC 等多种癌细胞亚群共存，从细胞层面证实了肿瘤异质性。

基于空间定位信息，研究进一步解析了不同功能区域的生物学特征。通过标志基因与通路富集分析，揭示了肿瘤核心区、侵袭前沿等空间域特有的功能。值得注意的是，基于 T 细胞与 B 细胞的空间共定位，识别出三级淋巴结构。

综上，本章从细胞分布与功能区划等多维度，构建了乳腺癌空间异质性图谱，为理解肿瘤生物学提供了新视角。

5 构建乳腺癌预后模型

乳腺癌呈现显著的分子与细胞层面的异质性，这种高度异质性不仅影响肿瘤的生物学行为，也导致临床治疗差异与预后不一致[67]。因此，准确识别能够反映患者生存差异的关键分子标志，对于风险分层与精准治疗具有重要意义。在前一章中，本论文对乳腺癌组织的空间异质性进行了系统解析，明确了不同空间区域在细胞组成和功能特征上的差异并识别了具有显著免疫组织化特征的 TLS。已有研究表明，TLS 作为肿瘤局部抗肿瘤免疫反应的重要组织形式，其存在与患者临床预后密切相关。在此基础上，本章进一步聚焦于 TLS 区域所体现的免疫活性差异，提取其关键分子特征，并探索其与患者预后的关系，为乳腺癌的个体化预后评估提供决策依据。

5.1 TLS 特征基因的筛选与功能分析

为解析 TLS 的特征基因并为后续预后模型构建奠定基础，本论文基于空间转录组数据将 spot 划分为 TLS 区域与非 TLS 区域，并展开差异表达分析。结果共鉴定出 184 个在 TLS 区域显著上调的 DEGs，如图 5-1。这些基因构成 TLS 的初始特征基因集，用以支撑后续的特征筛选与预后模型开发。

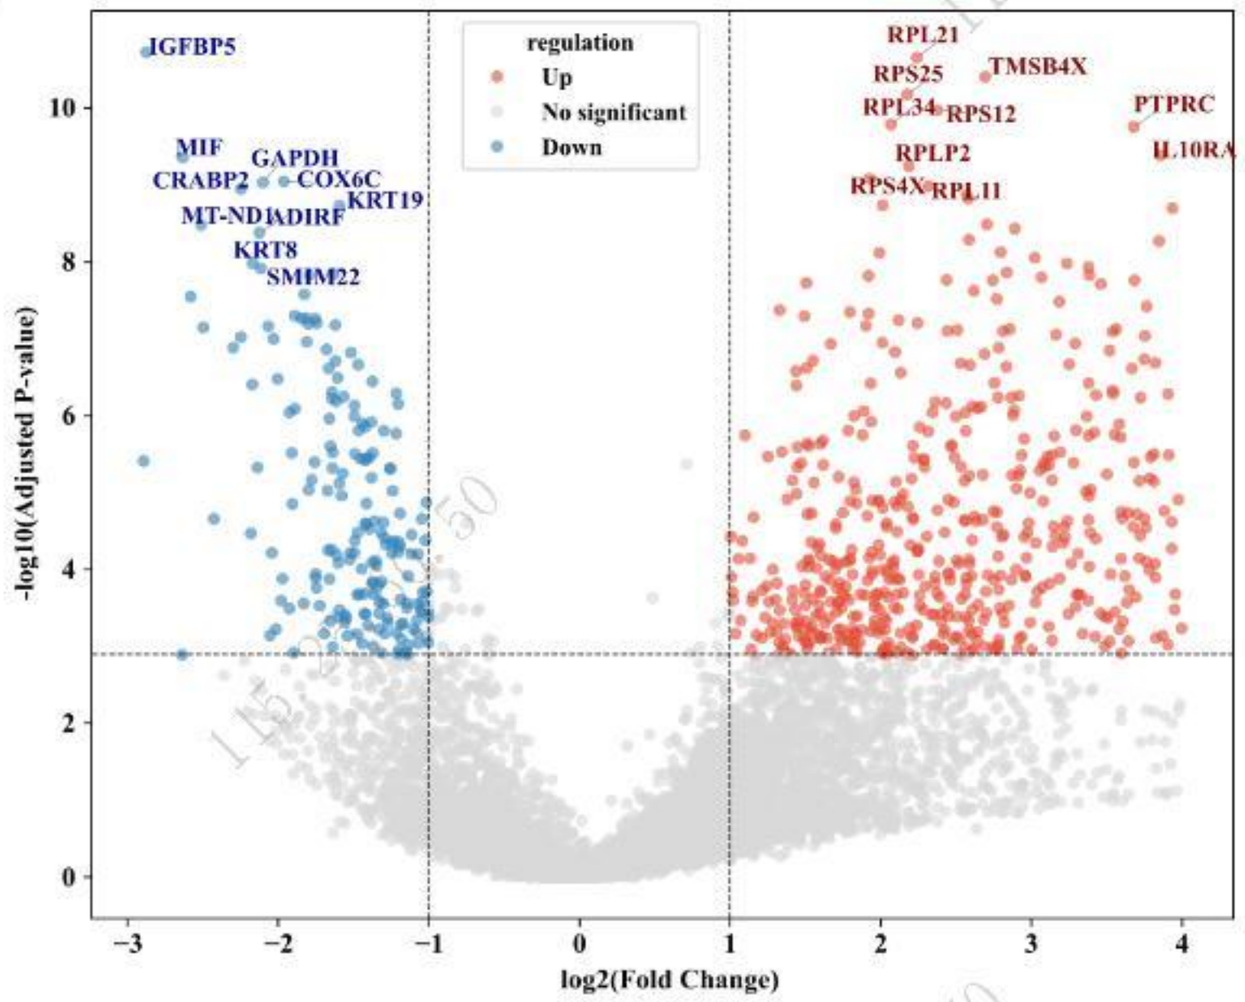


图 5-1 TLS 与非 TLS 的差异基因火山图

Fig.5-1 Volcano plot of differentially expressed genes between TLS and non-TLS

随后，对在 TLS 区域上调的 184 个 DEGs 进行 GO 功能注释和 KEGG 通路富集分析，以识别其相关的生物过程及信号通路。图 5-2（a）的 GO 富集

分析结果表明，差异基因的功能主要富集在两个层面。在生物过程层面，它们显著地参与免疫细胞相互作用与活化及相关黏附过程的调控，提示其在细胞间通讯与免疫应答中发挥关键作用。在分子功能与细胞组分层面，这些基因则关联于蛋白质合成与细胞结构维持，包括核糖体构成及细胞连接等。这为免疫活动的执行提供了必要的物质与结构基础[68]。

图 5-2（b）的 KEGG 通路富集分析显示，TLS 区域的主要生物功能表现为免疫细胞活化、细胞间通讯以及免疫调控等相关的生物学功能富集。这一结果与 GO 富集分析中免疫活化的结论相一致。

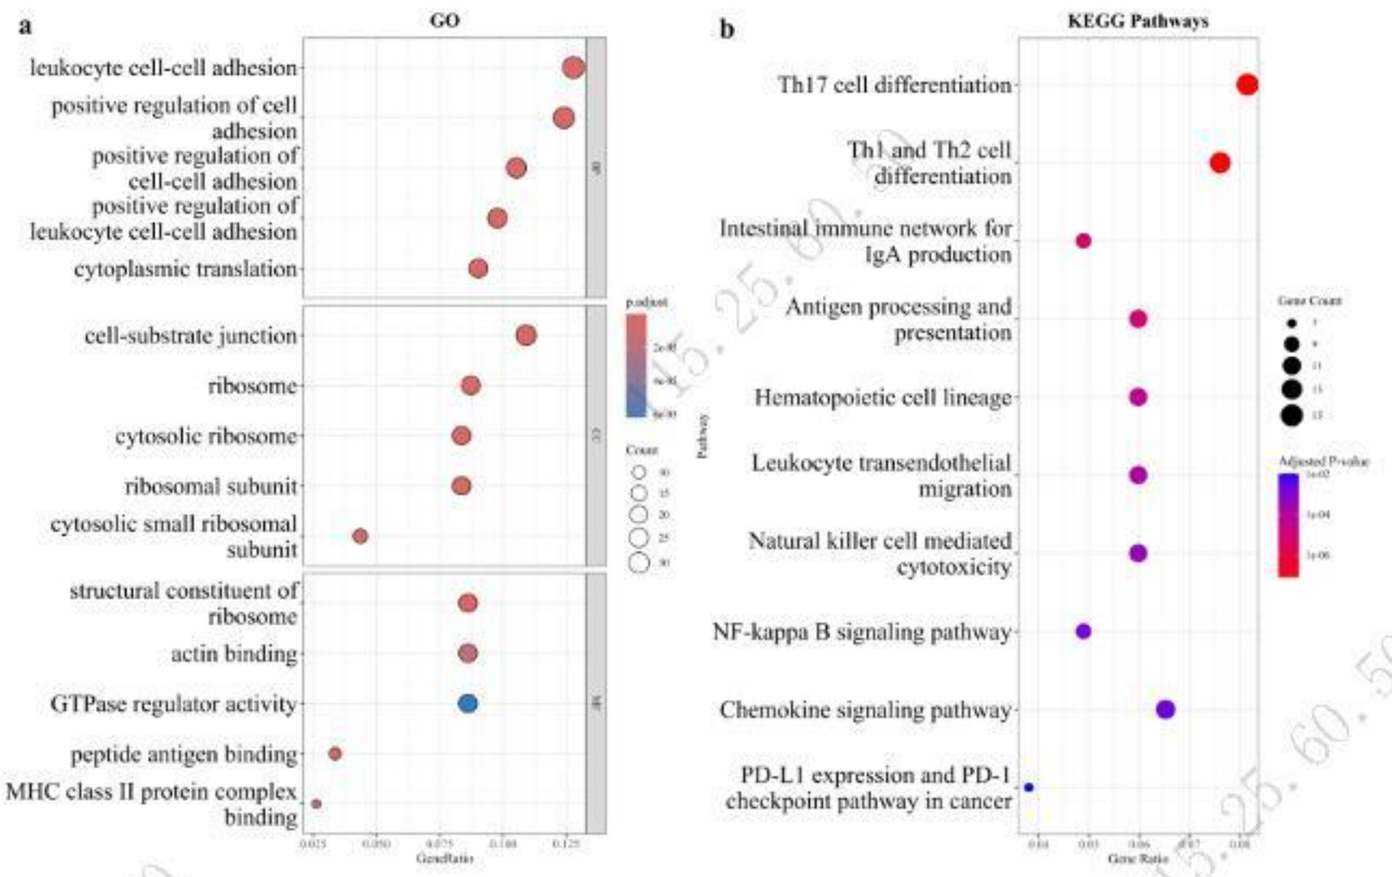


图 5-2 GO 和 KEGG 富集分析

Fig.5-2 GO and KEGG pathway analysis

5.2 基于 TLS 特征基因构建预后模型

本论文通过 TLS 与非 TLS 区域的差异表达分析获得了一组能够代表 TLS 免疫活性特征的特征基因，并结合患者的生存数据系统评估其临床预后意义，从而筛选出与生存相关的关键基因并构建 TLS 相关的预后模型。

本论文使用的数据来源于 GEO 数据库中的 GSE1456 数据集（登录号：GSE1456）。该数据集包含 159 例淋巴结阴性、未接受新辅助治疗的乳腺癌患者的基因表达谱及完整临床随访信息，随访终点包括无远处转移生存期（Distant Metastasis-Free Survival，DMFS）和总生存期（Overall Survival，OS）[69]。数据集的原始 CEL 文件及处理后的表达矩阵均可通过 GEO 数据库公开获取。

在 GSE1456 队列中，对差异分析获得的 184 个上调 DEGs 进行单因素 Cox 回归分析，将基因表达量作为连续变量纳入模型，计算 HR、95%置信区

间及 P 值（显著性阈值设为 P<0.05）。

如下图 5-3 所示，蓝色方框表示保护基因，在包含 159 例乳腺癌患者的队列中，共观察到 40 个终点事件。模型整体具有显著统计学意义（Log-Rank p＝0.000239），且展现出良好的预测效能（C-index＝0.73）。分析结果显示，共有 50 个基因与患者预后显著相关，其中 24 个为风险基因（HR>1），26 个为保护基因（HR<1），构成后续研究的核心基因子集。代表性保护基因包括 FNBP1、FYN 和 CCND2 HR<1 且置信区间不包含 1 为保护基因，其高表达与较好的预后有关。而 DDX39A、DNM2 和 MAGK 的 HR>1 且置信区间不包含 1 为风险基因，其高表达与不良预后相关。

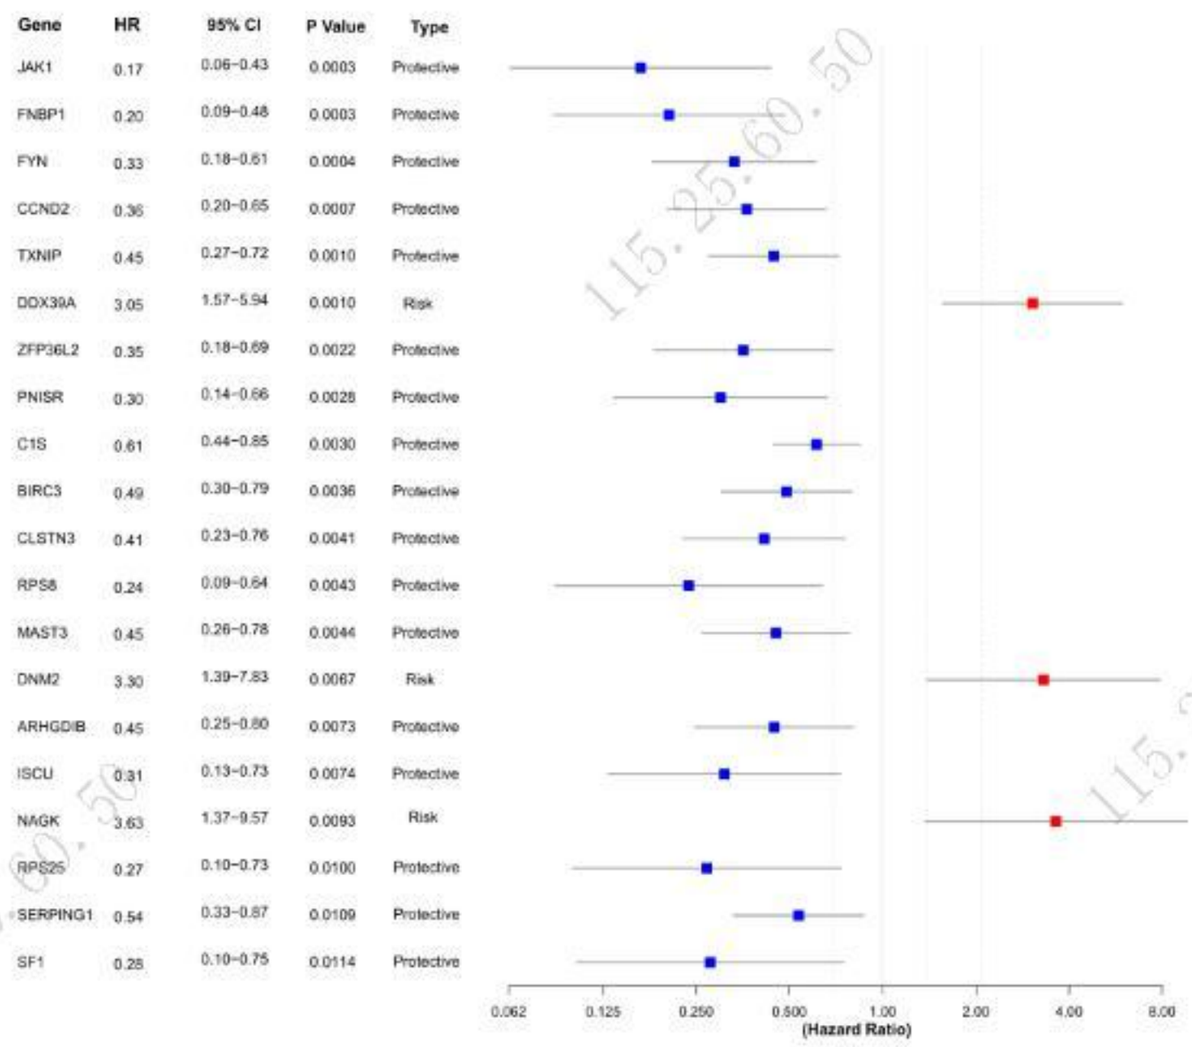


图 5-3 单因素 Cox 回归分析排名前 20 基因

Fig.5-3 Top 20 genes from univariate Cox regression analysis

随后，本论文进行了最小绝对收缩和选择算子（Least Absolute Shrinkage and Selection Operator，LASSO）Cox 回归分析，从 50 个基因中识别出与总生存期高度相关的 13 个基因（JAK1, FNBP1, FYN, CCND2, DDX39A, ZFP36L2, BIRC3, CLSTN3, RPS8, MAST3, DNM2, NAGK, CLASRP）。并通过 10 倍交叉验证，构建了 13 个基因的预后预测模型，如下图 5-4 所示。

风险评分如下所示：

Risk Score = -0.4895 × JAK1 + -0.3919 × FNBP1 + -0.3023 × FYN + -0.1296 × CCND2 + 0.1465 × DDX39A + -0.0844 × ZFP36L2 + -0.0371 × BIRC3 + -0.3289 × CLSTN3 + -0.1278 × RPS8 + -0.1041 × MAST3 + 0.0689 × DNM2 + 0.3709 × NAGK + -0.1231 × CLASRP

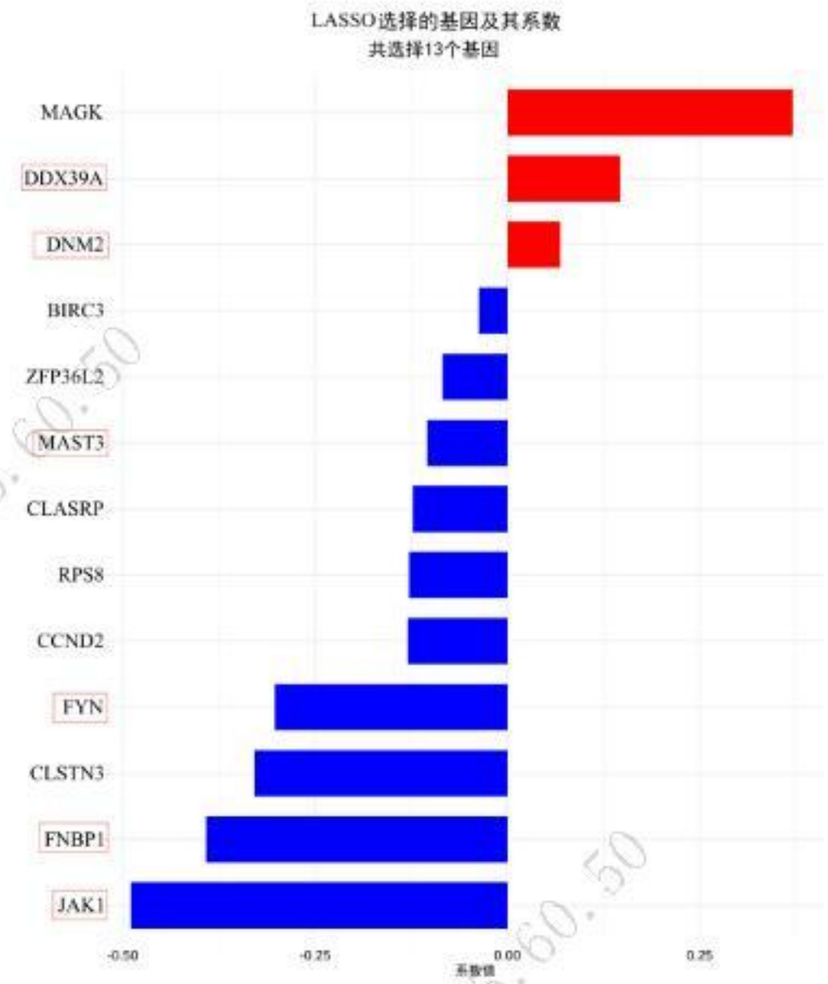


图 5-4 13 个基因及其系数

Fig.5-4 13 genes and their coefficients

已有研究表明，JAK1 与肿瘤体积小、淋巴结转移少、免疫浸润丰富及长期生存率升高显著相关是乳腺癌预后有利指标[70]。FNBP1 的高表达则与乳腺癌患者的不良预后有关[71]。而 FYN 是乳腺癌中一个关键的促癌基因，其高表达与肿瘤侵袭、转移、耐药以及不良预后密切相关[72]。CCND2 是一种以诱导衰老表型和抑制细胞生长而闻名的细胞周期蛋白，在许多乳腺癌样本中观察到缺失或突变。此外，发现 CCND2 表达在细胞生长停滞期间增加，表明其对乳腺癌的发展有抑制作用[73]。DDX39A 在乳腺癌中普遍高表达，主要作为 ER^+亚型不良预后的独立预测因子，DDX39A 的高表达意味着较好的预后[74]。DNM2 在乳腺癌组织中普遍呈高表达状态，是乳腺癌不良预后的重要分子标志物和潜在的抗转移治疗新靶点[75]。全基因组测序研究已将 ZFP36L2 确定为乳腺癌的驱动基因[76]。BRIC3 在原发性乳腺癌组织中普遍上调，且与腋窝淋巴结转移正相关[77,78]。DNM2 在乳腺癌组织中普遍高表达，且其表达水平与肿瘤侵袭、转移及化疗耐受密切相关，是不良预后的独立分子标志物和潜在治疗靶点[79]。CLASRP 的异常表达与某些类型的癌症相关。特别是在乳腺癌和肺癌中，CLASRP 的表达水平显著升高，提示其在肿瘤发生和发展中的潜在作用。MAST3 在乳腺癌中普遍高表达，可促进 TNBC 细胞增殖、侵袭和体内成瘤，是不良预后的独立预测因子[80]。

其中 JAK1、 FNBP1[81]、FYN、DNM2、DDX39A[82]、MAST3 均有文献报道与乳腺癌预后相关。

5.3 预后模型的统计学评估与验证

为了评估模型的预测有效性，本论文采用了 Kaplan-Meier 生存分析。如下图 5-5 所示， Kaplan-Meier 生存分析结果表明基于 LASSO 算法构建的风险评分模型能够非常有效地区分乳腺癌患者的预后。高风险组患者（n=53）的生存期显著短于低风险组（n=106）。随着时间推移，两组生存差异逐渐扩大。至随访末期，低风险组仍保持较高的生存概率，而高风险组生存率显著下降。风险分层表进一步证实了这一趋势，随着时间延长，高风险组患者数量急剧减少（从 53 例降至 4 例），显著快于低风险组（从 106 例降至 25 例）。基于模型划分的高、低风险组在生存率上差异极显著（$p < 0.0001$）。高风险组中位生存时间约为 2.5 年，而低风险组 5 年生存率仍保持在 75% 以上。分析结果表明，依据模型划分的高、低风险组间，其生存曲线呈现出具有高度统计学意义的分离，且 Log-rank 检验结果显著。这一发现有力地证实了本模型在患者风险分层与预后评估方面的卓越性能与临床实用性。

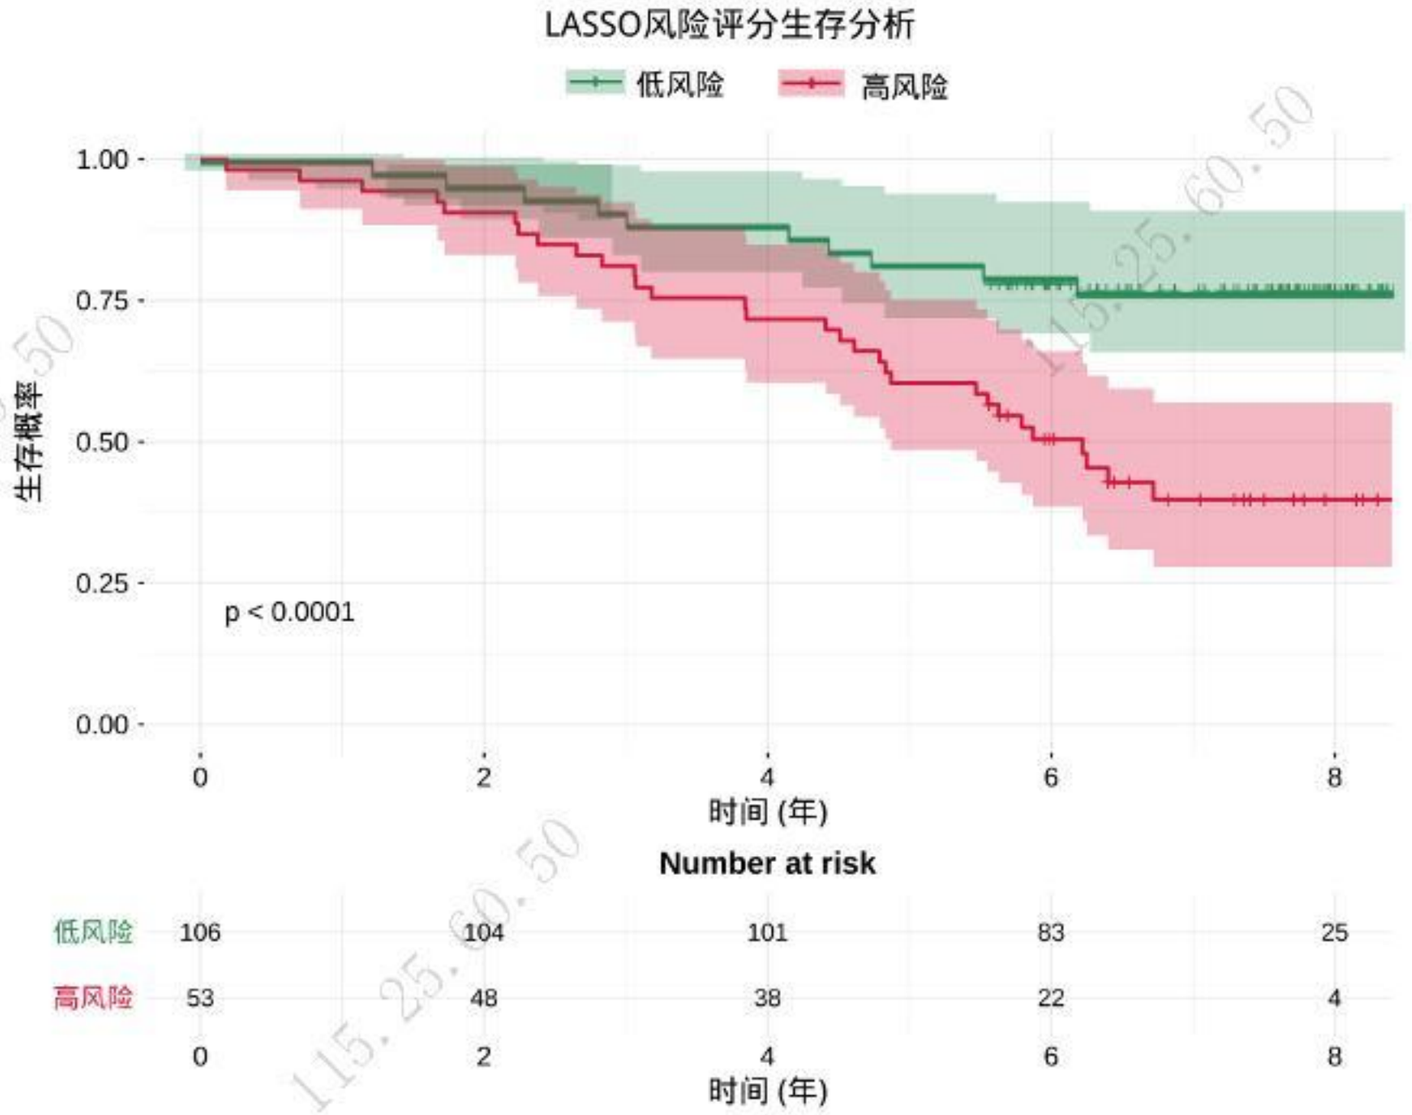


图 5-5 KM 生存分析图

Fig.5-5 KM survival curve

图 5-6 的时间依赖性 ROC 分析显示，基于 13 个基因的风险评分模型在 1 年、3 年和 5 年的 AUC 分别达到 0.822、0.779 和 0.807，均显著优于传统 TNM 分期（5 年 AUC ≈ 0.64），证实该模型具有稳健且持久的预测能力，可作为一种可靠的预后工具用于乳腺癌患者的个体化风险评估。

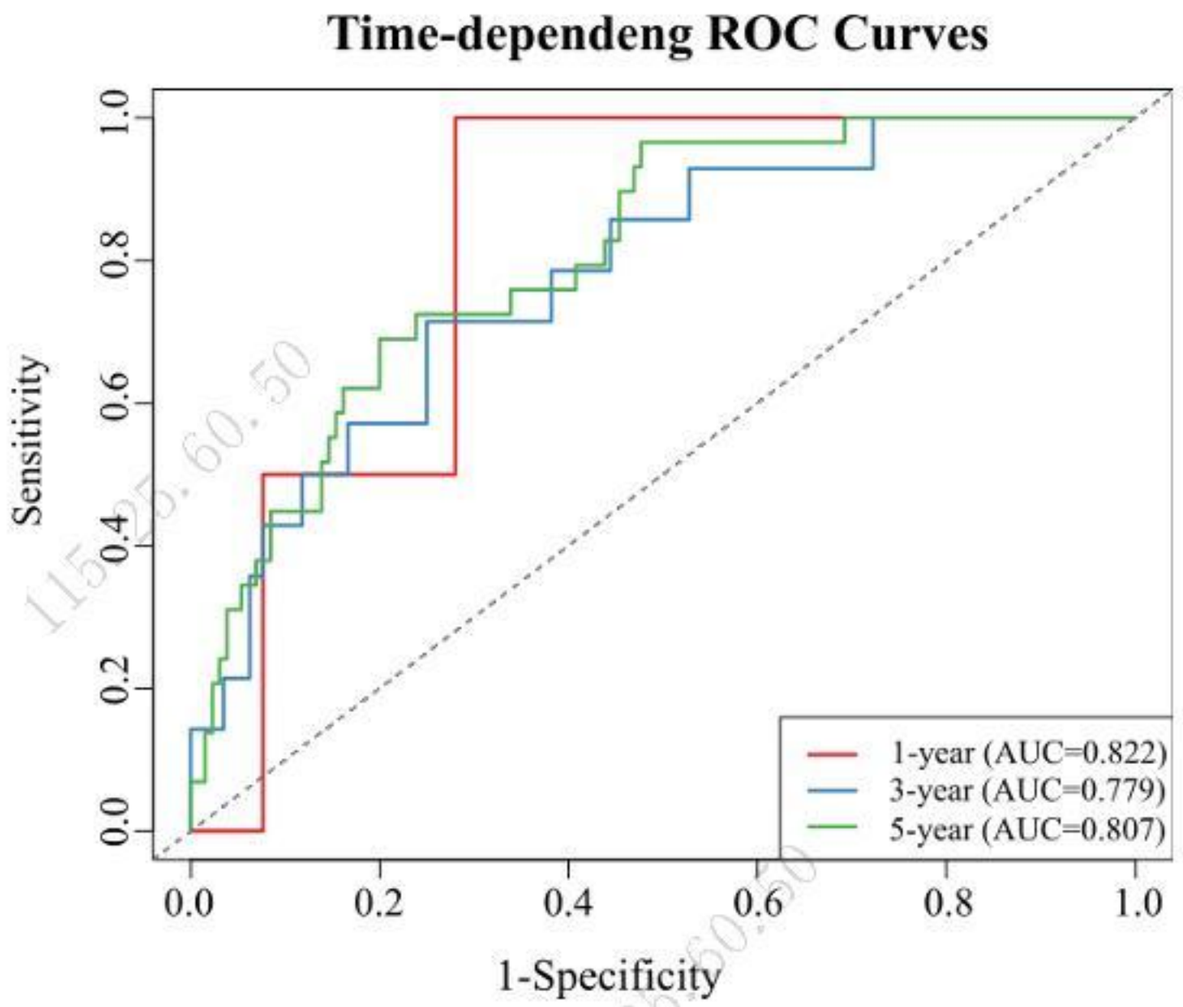


图 5-6 ROC 曲线

Fig.5-6 ROC curve

为了评估风险评分模型在乳腺癌预后预测中的独立价值，将其与 Elston 分级和分子分型一同纳入多因素 Cox 比例风险模型。图 5-7 的结果显示，LASSO 风险评分显著与患者预后相关，风险比为 12.27（$p < 0.001$），表明 LASSO 风险评分越高，患者的死亡风险越大。相较之下，其他因素如 Elston 等级和亚型的影响较小，部分没有显著性。总的来说，Lasso 风险评分是乳腺癌预后中的重要预测因子，而其他因素的影响则较小。

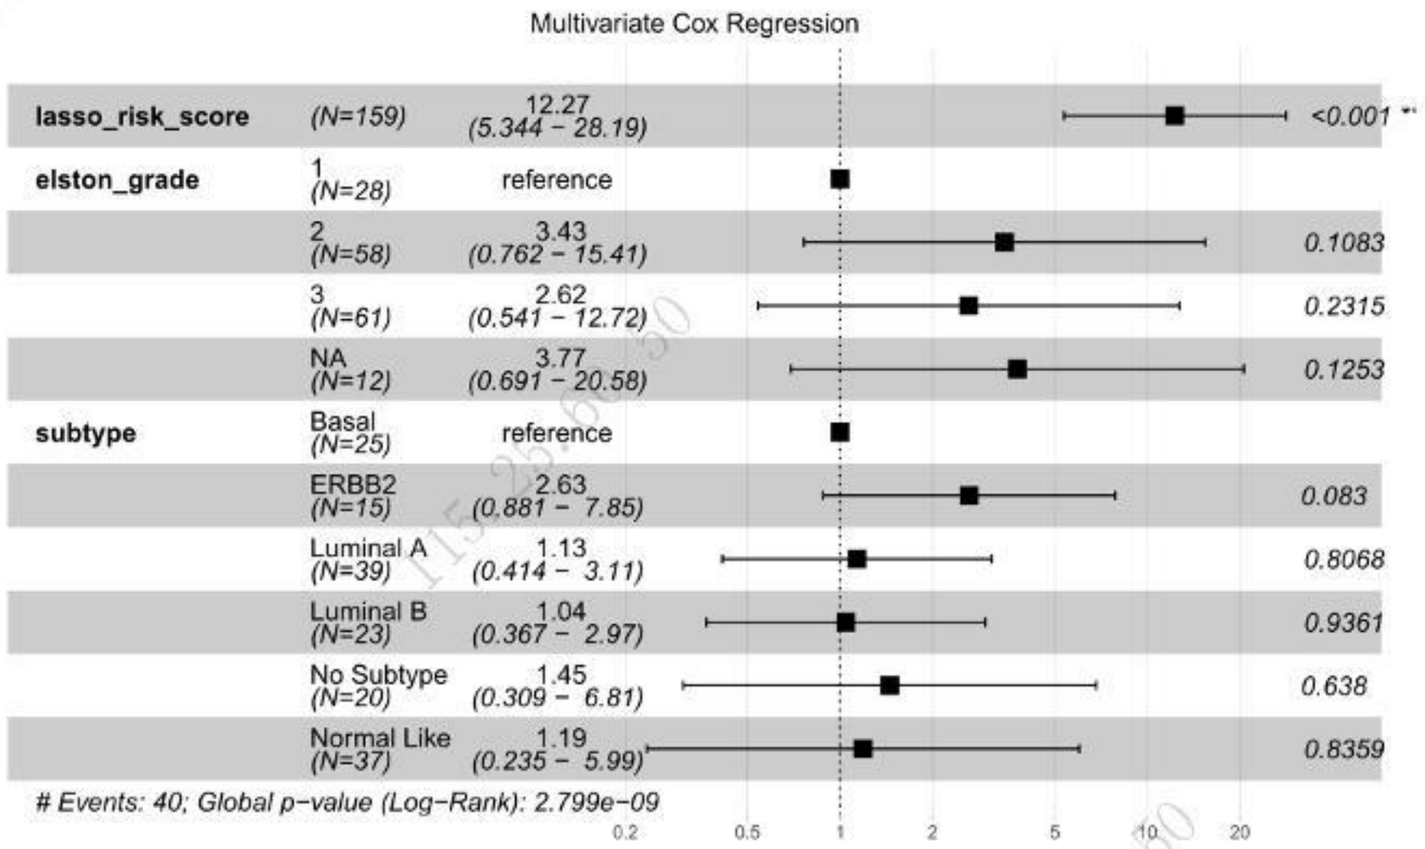


图 5-7 乳腺癌预后因素的多因素 Cox 回归分析

Fig.5-7 Multivariate Cox regression analysis of prognostic factors in breast cancer

5.4 本章小结

在乳腺癌中。TLS 的存在是强大的抗肿瘤免疫力的标志[68]。它们通常位于肿瘤侵袭边缘，是原位启动 T 细胞和产生高亲和力抗体的关键场所。本章首先通过提取 TLS 特征基因并进行功能解析，结果表明这些基因显著富集于免疫应答、淋巴细胞活化等通路，从分子层面证实了 TLS 在调控抗肿瘤免疫反应中的关键。接着，采用单因素 Cox 回归和 LASSO-Cox 回归分析构建风险评分模型。最后，本章识别了与乳腺癌患者总生存期显著相关的 13 个关键基因（JAK1, FNBP1, FYN, CCND2, DDX39A, ZFP36L2, BIRC3, CLSTN3, RPS8, MAST3, DNM2, NAGK, CLASRP），其中 6 个基因（JAK1、FNBP1、FYN、CCND2、DDX39A、MAST3）在相关文献验证了其在乳腺癌预后的重要性。Kaplan-Meier 生存分析显示，TLS 签名基因高表达与更长的总生存期显著相关（log-rank $p<0.001$）。进一步的多因素 Cox 回归分析证实，TLS 特征基因风险评分是独立的预后标志物。

6 结论与展望

乳腺癌具有显著的空间异质性，不同区域呈现出差异化的细胞组成和功能状态，这种区域性差异在疾病进展及患者预后中发挥着重要作用。空间转录组技术为从空间维度解析肿瘤微环境提供了重要手段，但如何在复杂空间背景下准确刻画组织内部的空间结构，仍是理解空间异质性的关键问题。本论文围绕空间域识别问题，提出了基于图对比学习的多模态融合算法SpaGCL，并结合单细胞转录组与临床生存数据，系统分析了乳腺癌的空间异质性及其潜在预后意义。

SpaGCL 算法在图对比学习框架下分别提取基因表达和组织形态学特征，并通过交叉注意力机制实现上述两种特征的有效融合，从而提升了空间域边界的识别精度。同时，对于基因表达数据，算法提出了基于余弦相似度的数据增强策略，保留了生物学相关的基因间关系，增强了模型训练的稳定性和鲁棒性。实验结果表明，SpaGCL 算法在多个基准数据集上均优于现有方法，并能够在不同分辨率的空间转录组数据中准确识别空间域。在人类乳腺癌数据集上，SpaGCL 算法能够有效区分肿瘤的不同功能区域，为深入研究乳腺癌的空间异质性提供了可靠的分析工具。

基于空间域识别结果，结合单细胞数据对人类乳腺癌进行空间异质性分析。结果显示，肿瘤核心、边缘以及免疫相关区域在细胞组成和功能特征上存在显著差异，体现了肿瘤微环境在空间上的组织化特征。同时，通过免疫细胞空间共定位分析，识别出乳腺癌组织中的三级淋巴结构区域，并基于相关特征基因构建了预后风险评分模型。生存分析结果表明，该模型能够在一定程度上区分不同预后风险患者，提示 TLS 相关分子特征与乳腺癌预后存在联系。

总体来看，本论文结合方法学与生物学分析，从空间域识别出发，揭示了乳腺癌的空间异质性。空间域划分有助于理解肿瘤微环境的组织结构，而随后的空间异质性分析与预后建模加深了对 TLS 的认识。需要指出的是，本研究仍受样本量和实验验证条件的限制，未来可考虑增加更多临床队列和实验验证，以进一步探讨空间结构解析在乳腺癌免疫研究中的生物学意义和潜在价值。

参考文献

[1] KIM J, HARPER A, MCCORMACK V, et al. Global patterns and trends in breast cancer incidence and mortality across 185 countries[J]. Nature Medicine, 2025, 31(4): 1154-1162.

[2] TURNER K M, YEO S K, HOLM T M, et al. Heterogeneity within molecular subtypes of breast cancer[J]. American Journal of Physiology-Cell Physiology, 2021, 321(2): 343-354.

[3] GUO L, KONG D, LIU J, et al. Breast cancer heterogeneity and its implication in personalized precision therapy[J]. Experimental Hematology & Oncology, 2023, 12(1): 3-29.

[4] 危莹, 张小丹, 胡苗苗, 等. 空间转录组技术研究进展[J]. 生物化学与生物物理进展, 2022, 49(3): 561-571.

[5] ZHU Z, JIANG L, DING X. Advancing Breast Cancer Heterogeneity Analysis: Insights from Genomics, Transcriptomics and Proteomics at Bulk and Single-Cell Levels[J]. Cancers, 2023, 15(16): 4164-4195.

[6] STÅHL P L, SALMÉN F, VICKOVIC S, et al. Visualization and analysis of gene expression in tissue sections by spatial transcriptomics[J]. Science, 2016, 353(6294): 78-82.

[7] 李润泽, 陈旭, 杨雪瑞. 空间转录组的解读与探究: 数据分析方法学研究现状与展望[J]. 科学通报, 2024, 69(30): 4415-4431.

[8] HUNTER M V, MONCADA R, WEISS J M, et al. Spatially resolved transcriptomics reveals the architecture of the tumor-microenvironment interface[J]. Nature Communications, 2021, 12(1): 6278-6293.

[9] MANIATIS S, PETRESCU J, PHATNANI H. Spatially resolved transcriptomics and its applications in cancer[J]. Current Opinion in Genetics & Development, 2021, 66: 70-77.

[10] ZHAO E, STONE M R, REN X, et al. Spatial transcriptomics at subspot resolution with BayesSpace[J]. Nature Biotechnology, 2021, 39(11): 1375-1384.

[11] HAO Y, HAO S, ANDERSEN-NISSEN E, et al. Integrated analysis of multimodal single-cell data[J]. Cell, 2021, 184(13): 3573-3587.

[12] ZAHEDI R, GHAMSARI R, ARGHA A, et al. Deep learning in spatially

resolved transcriptomics: a comprehensive technical view[J]. Briefings in Bioinformatics, 2024, 25(2): bbae082.

[13] HU J, LI X, COLEMAN K, et al. SpaGCN: Integrating gene expression, spatial location and histology to identify spatial domains and spatially variable genes by graph convolutional network[J]. Nature Methods, 2021, 18(11): 1342-1351.

[14] DONG K, ZHANG S. Deciphering spatial domains from spatially resolved transcriptomics with an adaptive graph attention auto-encoder[J]. Nature Communications, 2022, 13(1): 1739-1750.

[15] LONG Y, ANG K S, LI M, et al. Spatially informed clustering integration and deconvolution of spatial transcriptomics with GraphST[J]. Nature Communications, 2023, 14(1): 1155-1168.

[16] LI J, CHEN S, PAN X, et al. Cell clustering for spatial transcriptomics data with graph neural networks[J]. Nature Computational Science, 2022, 2(6): 399-408.

[17] REN H, WALKER B L, CANG Z, et al. Identifying multicellular spatiotemporal organization of cells with SpaceFlow[J]. Nature Communications, 2022, 13(1): 4076-4089.

[18] The Gene Ontology Consortium, CARBON S, DOUGLASS E, et al. The Gene Ontology resource: enriching a GOld mine[J]. Nucleic Acids Research, 2021, 49(1): 325-334.

[19] KANEHISA M. KEGG: Kyoto Encyclopedia of Genes and Genomes[J]. Nucleic Acids Research, 2000, 28(1): 27-30.

[20] WOLF F A, ANGERER P, THEIS F J. SCANPY: large-scale single-cell gene expression data analysis[J]. Genome Biology, 2018, 19(1): 15-19.

[21] DRIES R, ZHU Q, DONG R, et al. Giotto: a toolbox for integrative analysis and visualization of spatial expression data[J]. Genome Biology, 2021, 22(1): 78-108.

[22] PHAM D, TAN X, BALDERSON B, et al. Robust mapping of spatiotemporal trajectories and cell–cell interactions in healthy and diseased tissues[J]. Nature Communications, 2023, 14(1): 7739-7763.

[23] XU H, FU H, LONG Y, et al. Unsupervised spatially embedded deep representation of spatial transcriptomics[J]. Genome Medicine, 2024, 16(1):

12-41.

[24] XU C, JIN X, WEI S, et al. DeepST: Identifying spatial domains in spatial transcriptomics by deep learning[J]. Nucleic Acids Research, 2022, 50(22): e131.

[25] HU J, LI X, COLEMAN K, et al. SpaGCN: Integrating gene expression, spatial location and histology to identify spatial domains and spatially variable genes by graph convolutional network[J]. Nature Methods, 2021, 18(11): 1342-1351.

[26] CHEN T, KORNBLITH S, NOROUZI M, et al. A Simple Framework for Contrastive Learning of Visual Representations[C]//Proceedings of the 37th International Conference on Machine Learning: PMLR, 2020: 1597-1607.

[27] GRILL J B, STRUB F, ALTCHÉ F, et al. Bootstrap Your Own Latent A New Approach to Self-Supervised Learning[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems. Vancouver,BC,Canada: MIT Press, 2020: 21271-21284.

[28] VELIČKOVIĆ P, FEDUS W, HAMILTON W L, et al. Deep Graph Infomax[C]//The Seventh International Conference on Learning Representations. New Orleans,Louisiana,United States: PMLR, 2019: 1-17.

[29] REN H, WALKER B L, CANG Z, et al. Identifying multicellular spatiotemporal organization of cells with SpaceFlow[J]. Nature Communications, 2022, 13(1): 4076.

[30] WANG T, SHU H, HU J, et al. Accurately deciphering spatial domains for spatially resolved transcriptomics with stCluster[J]. Briefings in Bioinformatics, 2024, 25(4): bbae329.

[31] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph Attention Networks[C]//International Conference on Learning Representations. Vancouver, Canada: PMLR, 2018.

[32] ZHU Y, XU Y, YU F, et al. Graph Contrastive Learning with Adaptive Augmentation[C]//Proceedings of the Web Conference 2021. Ljubljana, Slovenia: Association for Computing Machinery, 2021: 2069-2080.

[33] YOU Y, CHEN T, SHEN Y, et al. Graph Contrastive Learning Automated[C]//Proceedings of the 38th International Conference on Machine Learning: PMLR, 2021: 12121-12132.

[34] HE K, FAN H, WU Y, et al. Momentum Contrast for Unsupervised Visual Representation Learning[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE Computer Society, 2020: 9726-9735.

[35] ZBONTAR J, JING L, MISRA I, et al. Barlow Twins: Self-Supervised Learning via Redundancy Reduction[C]//Proceedings of the International Conference on Machine Learning (ICML 2021): PMLR: 12310-12320.

[36] GATES A J, AHN Y Y. The Impact of Random Models on Clustering Similarity[J]. The Journal of Machine Learning Research, 2017, 18(1): 3049-3076.

[37] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas,NV,USA: IEEE, 2016: 770-778.

[38] SCRUCCA L, FOP M, MURPHY T Brendan, et al. mclust 5: Clustering, Classification and Density Estimation Using Gaussian Finite Mixture Models[J]. The R Journal, 2016, 8(1): 289-317.

[39] HEALY J, MCINNES L. Uniform manifold approximation and projection[J]. Nature Reviews Methods Primers, 2024, 4(1): 82-92.

[40] WOLF F A, HAMEY F K, PLASS M, et al. PAGA: graph abstraction reconciles clustering with trajectory inference through a topology preserving map of single cells[J]. Genome Biology, 2019, 20(1): 59-67.

[41] MAYNARD K R, COLLADO-TORRES L, WEBER L M, et al. Transcriptome-scale spatial gene expression in the human dorsolateral prefrontal cortex[J]. Nature Neuroscience, 2021, 24(3): 425-436.

[42] LEIN E S, HAWRYLYCZ M J, AO N, et al. Genome-wide atlas of gene expression in the adult mouse brain[J]. Nature, 2007, 445(7124): 168-176.

[43] CHEN A, LIAO S, CHENG M, et al. Spatiotemporal transcriptomic atlas of mouse organogenesis using DNA nanoball-patterned arrays[J]. Cell, 2022, 185(10): 1777-1792.

[44] RODRIQUES S G, STICKELS R R, GOEVA A, et al. Slide-seq: A scalable technology for measuring genome-wide expression at high spatial resolution[J]. Science, 2019, 363(6434): 1463-1467.

[45] PALLA G, SPITZER H, KLEIN M, et al. Squidpy: a scalable framework for

spatial omics analysis[J]. Nature Methods, 2022, 19(2): 171-178.

[46] SAELENS W, CANNOODT R, TODOROV H, et al. A comparison of single-cell trajectory inference methods[J]. Nature Biotechnology, 2019, 37(5): 547-554.

[47] TAKEDA K. WFS1 (Wolfram syndrome 1) gene product: predominant subcellular localization to endoplasmic reticulum in cultured cells and neuronal expression in rat brain[J]. Human Molecular Genetics, 2001, 10(5): 477-484.

[48] IIJIMA T, MIURA E, WATANABE M, et al. Distinct expression of C1q-like family mRNAs in mouse brain and biochemical characterization of their encoded proteins[J]. European Journal of Neuroscience, 2010, 31(9): 1606-1615.

[49] NEWRZELLA D, PAHLAVAN P S, KRÜGER C, et al. The functional genome of CA1 and CA3 neurons under native conditions and in response to ischemia[J]. BMC Genomics, 2007, 8(1): 370-387.

[50] SUNG H, FERLAY J, SIEGEL R L, et al. Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries[J]. CA: A Cancer Journal for Clinicians, 2021, 71(3): 209-249.

[51] WU S Z, AL-ERYANI G, RODEN D L, et al. A single-cell and spatially resolved atlas of human breast cancers[J]. Nature Genetics, 2021, 53(9): 1334-1347.

[52] KLESHCHEVNIKOV V, SHMATKO A, DANN E, et al. Cell2location maps fine-grained cell types in spatial transcriptomics[J]. Nature Biotechnology, 2022, 40(5): 661-671.

[53] WALDEMER-STREYER R J, REYES-ORDOÑEZ A, KIM D, et al. Cxcl14 depletion accelerates skeletal myogenesis by promoting cell cycle withdrawal[J]. npj Regenerative Medicine, 2017, 2(1): 16017-16026.

[54] VALLA M, KLÆSTAD E, YTTERHUS B, et al. CCND1 Amplification in Breast Cancer -associations With Proliferation, Histopathological Grade, Molecular Subtype and Prognosis[J]. Journal of Mammary Gland Biology and Neoplasia, 2022, 27(1): 67-77.

[55] YU G, WANG L G, HAN Y, et al. clusterProfiler: an R Package for Comparing

Biological Themes Among Gene Clusters[J]. OMICS: A Journal of Integrative Biology, 2012, 16(5): 284-287.

[56] ZHANG L, LIANG S, WAN L. A multi-view graph contrastive learning framework for deciphering spatially resolved transcriptomics data[J]. Briefings in Bioinformatics, 2024, 25(4): bbae255.

[57] CROIZER H, MHAIDLY R, KIEFFER Y, et al. Deciphering the spatial landscape and plasticity of immunosuppressive fibroblasts in breast cancer[J]. Nature Communications, 2024, 15(1): 2806-2833.

[58] AFFO S, NAIR A, BRUNDU F, et al. Promotion of cholangiocarcinoma growth by diverse cancer-associated fibroblast subpopulations[J]. Cancer Cell, 2021, 39(6): 866-882.e11.

[59] CHEN Y, MCANDREWS K M, KALLURI R. Clinical and therapeutic relevance of cancer-associated fibroblasts[J]. Nature Reviews Clinical Oncology, 2021, 18(12): 792-804.

[60] BOCKSTAL M V, LAMBEIN K, GELE M V, et al. Differential regulation of extracellular matrix protein expression in carcinoma-associated fibroblasts by TGF-β1 regulates cancer cell spreading but not adhesion[J]. Oncoscience, 2014, 1(10): 634-648.

[61] N J, J T, SL N, et al. Tertiary lymphoid structures and B lymphocytes in cancer prognosis and response to immunotherapies[J]. OncoImmunology, 2021, 10(1): 1900508-1900524.

[62] NARVAEZ D, NADAL J, NERVO A, et al. The Emerging Role of Tertiary Lymphoid Structures in Breast Cancer: A Narrative Review[J]. Cancers, 2024, 16(2): 396-409.

[63] ANDERSSON A, LARSSON L, STENBECK L, et al. Spatial deconvolution of HER2-positive breast cancer delineates tumor-associated cell type interactions[J]. Nature Communications, 2021, 12(1): 6012-6025.

[64] SAUTÈS-FRIDMAN C, PETITPREZ F, CALDERARO J, et al. Tertiary lymphoid structures in the era of cancer immunotherapy[J]. Nature Reviews Cancer, 2019, 19(6): 307-325.

[65] SCHUMACHER T N, THOMMEN D S. Tertiary lymphoid structures in cancer[J]. Science, 2022, 375(6576): eabf9419.

[66] WANG Q, ZHONG W, SHEN X, et al. Tertiary lymphoid structures predict

survival and response to neoadjuvant therapy in locally advanced rectal cancer[J]. npj Precision Oncology, 2024, 8(1): 61-70.

[67] SAEKI S, KUMEGAWA K, TAKAHASHI Y, et al. Transcriptomic intratumor heterogeneity of breast cancer patient-derived organoids may reflect the unique biological features of the tumor of origin[J]. Breast Cancer Research, 2023, 25(1): 21-32.

[68] WANG X, VENET D, LIFRANGE F, et al. Spatial transcriptomics reveals substantial heterogeneity in triple-negative breast cancer with potential clinical implications[J]. Nature Communications, 2024, 15(1): 10232-10253.

[69] MIECZNIKOWSKI J C, WANG D, LIU S, et al. Comparative survival analysis of breast cancer microarray studies identifies important prognostic genetic pathways[J]. BMC Cancer, 2010, 10(1): 573-579.

[70] CHEN B, LAI J, DAI D, et al. JAK1 as a prognostic marker and its correlation with immune infiltrates in breast cancer[J]. Aging, 2019, 11(23): 11124-11135.

[71] FUKAI K, KOJIMAHARA N, HOSHI K, et al. Combined effects of occupational exposure to hazardous operations and lifestyle-related factors on cancer incidence[J]. Cancer Science, 2020, 111(12): 4581-4593.

[72] QI D, LU Y, QU H, et al. CLDN6 triggers NRF2-mediated ferroptosis through recruiting DLG1/PBK complex in breast cancer[J]. Cell Death & Disease, 2025, 16(1): 122-132.

[73] HOU Q, LI C, CHONG Y, et al. Comprehensive single-cell and bulk transcriptomic analyses to develop an NK cell-derived gene signature for prognostic assessment and precision medicine in breast cancer[J]. Frontiers in Immunology, 2024, 15: 1460607.

[74] LI Z, LIU F, LI F, et al. DHX9-mediated epigenetic silencing of BECN1 contributes to impaired autophagy and tumor progression in breast cancer via recruitment of HDAC5[J]. Cell Death & Disease, 2025, 16(1): 524-535.

[75] TROCHET D, BITOUN M. A review of Dynamin 2 involvement in cancers highlights a promising therapeutic target[J]. Journal of Experimental & Clinical Cancer Research, 2021, 40(1): 238-249.

[76] NIK-ZAINAL S, DAVIES H, STAAF J, et al. Landscape of somatic mutations in 560 breast cancer whole-genome sequences[J]. Nature, 2016, 534(7605): 47-54.

[77] MAKUCH-KOCKA A, KOCKI J, BRZOZOWSKA A, et al. The BIRC Family Genes Expression in Patients with Triple Negative Breast Cancer[J]. International Journal of Molecular Sciences, 2021, 22(4): 1820-1843.

[78] XIA Z A, LU C, PAN C, et al. The expression profiles of signature genes from CD103+LAG3+ tumour-infiltrating lymphocyte subsets predict breast cancer survival[J]. BMC Medicine, 2023, 21(1): 268-285.

[79] SAJED R, SAEEDNEJAD ZANJANI L, RAHIMI M, et al. Overexpression and translocation of dynamin 2 promotes tumor aggressiveness in breast carcinomas[J]. EXCLI Journal, 2020, 19: 1423-1435.

[80] DENG N, KANG W, DU J, et al. Microtubule associated serine/threonine kinase-3 inhibits the malignant phenotype of breast cancer by promoting phosphorylation-mediated ubiquitination degradation of yes-associated protein[J]. Breast Cancer Research, 2025, 27(1): 63-79.

[81] WANG Z, TIAN Z, SONG X, et al. Membrane tension sensing molecule-FNBP1 is a prognostic biomarker related to immune infiltration in BRCA, LUAD and STAD[J]. BMC Immunology, 2022, 23(1): 1-15.

[82] CHANG Y T, HONG Z J, TSAI H H, et al. Hub metastatic gene signature and risk score of breast cancer patients with small tumor sizes using WGCNA[J]. Breast Cancer, 2024, 31(6): 1114-1129.

致　谢

回首两年半的研究生涯，岁月在忙碌与充实间流转，艰辛与成长交织，终是收获满怀。

衷心感谢我的导师艾冬梅老师。她严谨的治学态度让我既敬且畏——对论文质量的极致追求曾让我倍感压力，却在无形中锤炼了我的科研能力。每当我陷入自我怀疑想要放弃时，她坚定的信任总能重新点燃我的信心。而她始终如一的学术热忱，更在潜移默化中重塑了我对科研的认知。这份亦师亦友的陪伴，让我在砥砺前行的路上始终看得见曙光。感谢我的同窗，彼此鼓励，度过了这段岁月，让我在科研的道路上不孤单。

作者简历及在学研究成果

一、主要教育经历/工作经历（从大学起，到硕士入学止）

起止年月	学习或工作单位	备注
2002 年 9 月至 2005 年 7 月	在河北理工大学计算机及应用专业就读	
2005 年 9 月至 2016 年 6 月	在北京国舜科技股份有限公司从事软件测试的工作	
2016 年 9 月至 2019 年 11 月	在奇安信科技集团股份有限公司从事软件测试的工作	
2019 年 12 月至 2021 年 7 月	在北京理工大学计算机科学与技术攻读学士学位	
2019 年 11 月至今	在云盾智慧安全科技有限公司从事软件测试的工作	

二、在学期间从事的科研工作

无

三、在学期间获得的科研奖励

（1）荣获北京科技大学 2026 届优秀毕业生

四、在学期间发表的论文

无

独创性说明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作者签名：梁冬娟 日期：2025年12月25日

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：梁冬娟　　导师签名：史冬梅　　日期：2025.12.25