密　　级：公开

加密论文编号：

论文题目：基于知识图谱与协同过滤的新能源汽车推荐算法研究与系统设计

学　　号：M202240120

作　　者：赵紫微

专 业 名 称：软件工程

2024 年 12 月 14 日

115.25.60.50

基于知识图谱与协同过滤的新能源汽车推荐算法研究与系统设计

Research and System Design of New Energy Vehicle Recommendation Algorithm Based on Knowledge Graph and Collaborative Filtering

研究生：赵紫微

指导教师：万初斌

北京科技大学数理学院

北京 100083，中国

Master Degree Candidate：Ziwei Zhao

Supervisor：Chubin Wan

School of Mathematical

University of Science and Technology Beijing

30 Xueyuan Road，Haidian District

Beijing 100083，P.R.CHINA

中图分类号：　　学校代码：10008
U　D　C：　　密　　级：公开

北京科技大学硕士学位论文

论文题目：基于知识图谱与协同过滤的新能源汽车推荐算法研究与系统设计

作者：赵紫微

指　导　教　师：万初斌　**单位：**数理学院　**职称：**教授

指导小组成员：　　**单位：**　　**职称：**

　　单位：　　**职称：**

论文提交日期：2024 年 12 月 14 日

学位授予单位：北 京 科 技 大 学

摘 要

传统汽车已无法满足人们的理想需求，越来越多的人倾向于选择新能源汽车。但是随着人们的需求量的增加，一时间市面及网络上出现了海量级别的新能源汽车数据，用户如何在众多品牌车型里最优选到自己所需的便成了首页问题。

随着时代发展，推荐算法和个性化推荐在生活中各个领域已被广泛使用，例如国内外许多短视频平台的随机推荐。尽管许多系统推荐的物品不同，但是基本机制都是在原有基础上为用户提供最可能喜欢的项目。而针对向用户推荐新能源领域数据时便稍有差别，既要保证系统所推荐的新能源车辆品牌用户倾心，还要着重把不同品牌的差异化考虑进去。在这种情况下，通过融合协同过滤算法来兼顾用户喜好，并将新能源车辆的重要特征作为重要的推荐标准，最后实现新能源汽车的个性化推荐。基于上述所讲，本文的主要内容如下:

1.本文通过爬虫技术从相关网站获取数据,采用 Dic-CTR 模型对文本数据进行命名实体识别，因存在多个数据源里，同一个实体会以不一样的方式展现这种情况，所以需要将获取到的实体采用实体对齐的方法来统一。最后完成新能源汽车知识图谱的存储与构建。

2.构建新能源汽车领域知识图谱,在经过数据预处理，实体对齐一系列步骤后，分别对新能源汽车领域中的实体与关系进行定义;通过对文本数据进行实体抽取、知识融合、知识加工等过程，并将知识以三元组的形式存储，拟实现知识图谱的构建。

3.推荐算法将使用协同过滤算法进行过滤，根据用户在推荐项目上的过去行为，以及海量用户间的接近度，推测出用户未来的行为，也就是喜欢某商品。此方法的核心理念在于，当两件商品被同一用户给予评价，或两位用户对其他商品展现出高度一致的评分模式时，可以预期这两件商品在该用户的评分上也会表现出显著的相似性。在对用户进行新能源汽车推荐上能够提高准确性，并且覆盖率也可提高。

4.新能源汽车推荐系统的设计与实现。从用户需求与系统需求两方面进行分析设计；主要核心功能有主页推荐模块，个人中心模块，汽车信息模块以及系统后台管理模块等，完成了系统的可应用性。

关键词：知识图谱；个性化推荐；协同过滤；实体识别

Research and System Design of New Energy Vehicle Recommendation Algorithm Based on Knowledge Graph and Collaborative Filtering

ABSTRACT

Traditional cars can no longer meet people's ideal needs, and more and more people tend to choose new energy vehicles. However, with the increasing demand from people, a massive amount of new energy vehicle data has emerged on the market and the internet. How users can select the best brand models they need has become a problem on the homepage.

With the development of the times, recommendation algorithms and personalized recommendations have been widely used in various fields of life, such as random recommendations on many short video platforms at home and abroad. Although many systems recommend different items, the basic mechanism is to provide users with the most likely favorite items based on the existing ones. However, there is a slight difference when recommending data in the field of new energy to users. It is necessary to ensure that the new energy vehicle brands recommended by the system are appealing to users, while also emphasizing the differentiation of different brands. In this case, by integrating collaborative filtering algorithms to take into account user preferences and using important features of new energy vehicles as important recommendation criteria, personalized recommendations for new energy vehicles can be achieved. Based on the above, the main content of this article is as follows:

1.This article uses web crawling technology to obtain data from relevant websites and adopts the Dic CTR model for named entity recognition of text data. As there are multiple data sources, the same entity will be presented in different ways, so it is necessary to use entity alignment method to unify the obtained entities. Finally, complete the storage and construction of the knowledge graph for new energy vehicles.

2.Constructing a knowledge graph in the field of new energy vehicles, defining entities and relationships in the field after a series of steps including data preprocessing and entity alignment; By extracting entities from the textual content, integrating and processing the knowledge, and using the triple method to preserve the knowledge, a visual representation of the knowledge has been further formed.

3.Recommendation algorithms use collaborative filtering algorithms to filter, based on the user's past behavior on recommended items and the proximity

between a large number of users, to infer the user's future behavior, that is, liking a certain product. The core concept of this method is that when two products are rated by the same user, or when two users exhibit highly consistent rating patterns for other products, it can be expected that these two products will also show significant similarity in the user's rating. It can improve the accuracy and coverage of recommending new energy vehicles to users.

4.Design and implementation of a new energy vehicle recommendation system, analyzing and designing from two aspects: user requirements and system requirements; The main core functions include homepage recommendation module, personal center module, car information module, and system backend management module, which have completed the system's applicability.

Key Words: Knowledge graph; personalized recommendation; collaborative filtering; entity recognition

目　录

摘　要 I
ABSTRACT II
目　录 IV
1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 2
1.2.1 推荐系统研究现状 2
1.2.2 知识图谱研究现状 4
1.2.3 新能源汽车研究现状 6
1.3 本文研究内容 7
1.4 论文组织结构 7
2 相关理论基础 9
2.1 知识图谱 9
2.1.1 知识图谱基本定义 9
2.1.2 知识建模 10
2.1.3 知识表示 11
2.1.4 信息抽取 12
2.2 协同过滤算法 14
2.3 相似度相关计算方法 15
2.3.1 余弦相似度 15
2.3.2 欧式相似度 15
2.3.3 皮尔系相关系数 16
2.4 模型介绍 16
2.4.1 条件随机场模型 16
2.4.2 双向长短时记忆模型 17
2.4 本章小结 19
3 新能源汽车领域知识图谱构建 20
3.1 数据获取与预处理 20
3.2 知识图谱模式层定义 21
3.2.1 相关实体定义 21

3.2.2 实体间关系定义 21
3.3 实体识别 22
3.3.1 数据集标注 23
3.3.2 基于 Dic-CTR 模型的命名实体识别 23
3.3.3 实验结果与分析 24
3.4 关系分类 25
3.4.1 基于 BiLSTM 的关系分类 25
3.5 知识存储 26
3.6 导入知识图谱可视化 27
3.7 本章小结 28
4 基于知识图谱的新能源汽车语义表示 29
4.1 传统的知识图谱嵌入模型 29
4.2 基于 TransHR 的知识图谱嵌入模型 30
4.3 模型训练过程 31
4.4 实验与分析 31
4.4.1 数据集 31
4.4.2 实体链接预测 31
4.4.3 三元组分类 32
4.4.4 超参数设置 32
4.4.5 实验结果与分析 32
4.5 本章小结 33
5 基于知识图谱与协同过滤的推荐算法 34
5.1 算法介绍 34
5.1.1 基于用户-新能源汽车评分的汽车相似度 35
5.1.2 基于知识图谱的新能源汽车语义相似度 35
5.1.3 两种相似度融合 36
5.1.4 推荐列表生成 36
5.2 算法实验 36
5.2.1 数据集 36
5.2.2 实验标准 37
5.2.3 实验结果及分析 37
5.3 本章小结 40
6 新能源汽车推荐系统的设计与实现 41
6.1 系统分析 41

6.1.1 系统可行性分析 41
6.1.2 系统需求分析 41
6.2 系统设计 42
6.2.1 系统框架设计 42
6.2.2 系统功能设计 42
6.3 系统实现 43
6.3.1 首页推荐模块的实现 43
6.3.2 个人中心模块的实现 44
6.3.3 后台管理模块模块的实现 46
6.4 系统测试 47
6.4.1 用户功能测试 47
6.4.2 管理员功能测试 48
6.5 本章小结 49
7 总结与展望 50
7.1 本文总结 50
7.2 未来展望 51
参考文献 52
致　谢 57
独创性说明 59
关于论文使用授权的说明 60
学位论文数据集 61

1 绪论

1.1 研究背景及意义

世界新能源加快增长的时期已经开始到来,中国新能源消费的绝对规模、占比以及效率都已开始逐步降低,而围绕再生能源市场所进行的争夺也将逐渐转至新能源发电领域。近年来,中国的可再生能源市场取得了跨越式增长[1],数量已稳居全球首位。鉴于资源逐渐减少和环境问题的加剧，促进新能源汽车的进步已经被确定为国家的策略方向。中国新能源汽车产业链在多年的持续研究和实际应用后，已经逐渐走向成熟。这个流程包括了关键原材料的提供、高质量电池和核心组件（例如整车控制器）的研发创新、车辆的设计和生产的全面推进，以及充电网络和其他基础设施的建设，从而形成了一个从上游到下游的完整供应链体系。这一系列的努力共同为中国新能源汽车行业的规模化增长奠定了稳固的基石。

2012 年指出新能源汽车产业化发展方向的文件《节能与新能源汽车产业发展规划（2012-2020 年）》发布，根据现有的规划数据，预计到 2020 年，纯电动和混动新能源汽车的产量将接近 2000 万辆[2]，同时预计总产量也将达到 600 万辆。接下来，在购车的相关政策上，国家为众多品牌推出了一系列的经济补助和优惠方案。在这之中，车辆购置补助政策占据了核心地位，此政策不仅涉及全国各地的汽车采购税务减免措施，还囊括了政府及各公共机关在购买时的环保导向、为降低运营成本而设定的合适电价，以及为充电设备建设提供的经济补偿等多方面的策略，整体上为新能源汽车行业提供了坚实的支撑体系。得益于国家和各个地方政府的全方位的政策扶持和引导，我国的新能源汽车行业不仅成功实现了从零开始的产业化突破，而且在极短的时间里快速加速进入了规模化发展的轨道，呈现飞跃式增长。截止 2011 年的总产出量仅达到 8000 辆，相对于全国汽车产量的整体表现来说，这一比例显得相对偏低；然而，随着时间的流逝，到 2017 年时，中国新能源汽车的总产量已经上升到 80 万辆,这一数字在国内汽车总产量里已占超过了两个百分点的比例。在 2018 年的上一个季度中，我国的新能源汽车生产总量达到了 13 万辆,而销售量为13.3 万辆,与上一个季度相比,分别实现了 146.9%和 144.3%的增长[3]。到 2024 年今年为止，我国新能源汽车年产量已经达到了 1000 万辆。

新能源汽车的产量在逐年提升，用户对于新能源汽车的需求也在日愈增

长。且随着智能时代的到来，海量新能源汽车数据便涌现出来。对于用户来说，如何在庞大的新能源汽车数据量里选择出适合自己需求的车辆便成为问题。推荐系统是目前最为流行的物品检索系统，它作为基于知识图谱构造的一个完整体系，能利用知识图谱对数据结构强大的描述能力，来理解推测用户与物品之间的关系与属性，从而帮助用户来筛选检索适配的物品。目前现有的新能源汽车推荐系统，大部分只关注了用户与车辆之间的关系，忽视了车辆之间的语义关联。因此，本文便引出了在新能源汽车数据域上基于知识图谱与协同过滤的推荐算法[4]，来解决物品与物品之前挖掘度不够的问题，将新能源车辆之间的关系考虑进去，为用户在检索过程中提供个性化推荐。

1.2 国内外研究现状

1.2.1 推荐系统研究现状

在确定项目时，推荐步骤显得尤为重要，特别是在面临项目繁多、种类丰富且持续变动的情况下。基于此特定工作区域，在缺乏对某些项目认知或对项目属性不甚了解的情况下，用户可能会错失符合其喜好的项目契机。在互联网诞生之前，推荐活动主要依赖于口耳相传的方式。然而，随着推荐系统的兴起与演进，它们已经成功地适应并满足了用户对在线推荐的多样化需求。

推荐系统是一个能够实时在线搜索信息的在线平台，它的主要设计初衷是使搜索出来的信息能够与用户的兴趣爱好相契合，从而辅助用户找到和推介他们觉得适当的项目。现阶段的推荐系统利用特定的技术手段和模型来探索和捕捉用户的喜好，这些方式可以大体上归纳为三大类：协同过滤、基于内容的方法、混合方法。以内容为核心的预测方法是根据项目的特殊属性来设计[5]，比如向热爱动作片的人推荐一部分类动作片。协同过滤系统将根据系统中其他用户的评估，向目标用户推荐最合适项目。实际上，混合方法是前面提到的两种技术的结合。

在近年的研究领域内，众多科学家们为提升推荐系统的性能，设计了各种不同的策略。Liu 等研究者采纳了一种结合项目预测和用户协助过滤的重叠回归策略，以便进行高效的推荐，Lian 及其团队推出了一套融合了显式与隐式特质互动的 xdeepfm 推荐系统的算法[6]。此算法不但揭示了如何学习特定类型的特征交互性，还能通过隐式学习的方法来掌握多种高级和低级特征交互。由 Wagavkar 等人[7]设计出来的一款加权混合推荐方案，其核心意图是创建一个个性化且综合多样的推荐列表。

鉴于此，传统协同过滤方法主要基于评分信息来进行推荐，却忽视了时间这一重要因素的影响。明显地，积极地利用时间数据能够提升推荐的精确性。借助于采用时间序列数据的推荐策略，此模型有能力察觉用户喜好的持续演变，从而对推荐算法的决策机制实施精细化调整[8]。Guo 等人[9]为适应不同时间权重的项目，建议采用定制化算法进行优化设计。鉴于用户购买习惯会随时间演变，模型因此减少过往数据权重。Koren 等人[10]用户特性向量构造过程中已经集成了时间有关信息。这种模型可以对整个周期内的数据变化进行全程跟踪，以有效应对兴趣偏移。

深度学习方法的广泛应用，随着时间的推移，更多的学者开始探索如何在推荐系统中更深入地分析文本评论和项目描述。针对该问题，提出了一种基于深度学习网络的用户-评分矩阵生成方法。目前存在的这些技术主要是依赖于卷积神经网络或者循环神经网络进行构建的。如 Kom 等[11]指出结合卷积网络与概率矩阵分解技术的卷积矩阵分解模型。Zhang 等人[12]指出一种融合深度学习的解决方案，该方案采用了两个并行的卷积神经网络结构，旨在从消费者的评价与商品的描述中汲取文本信息。此方法借助于一个整合模块辨识使用者与物件的属性，并将之关联起来，最后将这些数据输送至因子分解机模型，以进行评判与预测。Wu 等人[13]借助集成的深度神经元网络技术，成功推出融合双重正则化技术的深度学习推荐策略。这一模型的目的是实现卷积神经网络理论与循环神经网络理论结合，以便掌握与词汇相关的依赖度和排序规则。接下来，将采用矩阵分解方法进行预测分析，以便能够产生有关评级的预期数值。

相较于国外，中国对推荐系统理论的研究和开发起步较晚，和国际领先规范差距明显。我国学术界对推荐系统范畴的探究主要集中在对传统推荐算法固有局限性的完善和提炼上，我国商业环境下推荐系统应用也正在显示出明显加速的迹象。在 2009 年，百分点公司应运而生，作为中国首家中专精于个性化推荐技术的专业企业。通过集成基于用户听歌经验的个性化推荐功能，并加入私人 FM 这一创新性模块，网站的云音乐显著地改进了用户的使用体验，并成功地吸引了大量年轻用户的关注。这也促成了该业务业务的迅速壮大以及在市场上地位的稳步提升。电商比如淘宝、京东等利用推荐系统来促进销量，腾讯、爱奇艺等视频推荐系统来提高用户忠诚度并增加网络流量。

1.2.2 知识图谱研究现状

2012 年，某搜索引擎发布了一个称为知识图谱的独特技术，它在文本实体识别和消除歧义方面显示出了其重要性。首先，该工具会根据词汇的构造来增加搜索的多样性，并在探索性搜索的阶段分享与特定实体关联的语义资料，旨在强化搜索引擎的功能，从而优化用户的搜索体验。从那一时刻开始，许多公司也开始打造属于他们的知识线。比方说，微软推出的 Bing 搜索引擎整合了与 Satori 相似的知识框架。现阶段，诸如 DBpedia YAGo Wikidata 和 Freebase 这样的知识图谱也正在被认为是语义网络的知识存储手段[14]等。

整合知识已然变成了人工智能领域内发展的一个关键路径和方向。在人类问题解决方式的激励下，对知识的展示与推理不仅仅是把知识建构成智能系统中的一个核心组成部分，更通过仿真人类的思考模式，赋予系统处理复杂任务的技巧，这在人工智能领域为系统带来了创新突破。近几年，由于知识库的独特性和结构化结构，它在学术和产业领域已经获得了空前的重视。知识图谱采用一套结构化的数据呈现手法，它依赖于实体、相互之间的联系和相关的意义描述来呈现和整合知识。当尝试将知识图谱形象化时，这可以被看作是一个复杂的图形结构。在研究形式语义这一领域时，这个概念可以被认为是基于知识的一种工具，它旨在深刻地解释和逻辑推断事实真相。在资源描述框架(RDF)这一框架中，知识被精确地定义为一组事实的三个元组合，也就是(head relation tail)，这直接揭示了实体之间的相互关系。此外，这种知识的构成还可以被视为有向关系图，在该图中，节点代表着不同的结构，而边象征着这些实体之间的互动，共同构成了一个结构复杂且有序的网络体系。

在知识图谱研究的核心领域中，知识图谱嵌入[15]扮演着至关重要的角色。这一技术通过将实体和关系高效地转化为低维向量，成功地捕捉和表述了它们的深层次语义，从而为后续的自然语言处理任务提供了强有力的基础。核心研究领域在于知识图谱构建技术中知识的高效获取、多数据来源的整合以及复杂推断规则的实施与改进。在非结构化文本中精准识别实体及其相互间的关系，并将这些信息精确地融入到知识图谱中。其后，借助知识图谱的丰富联系性，能够进一步挖掘并推断出文本中隐含的新知识和事实。此流程不仅深化了对信息的理解，还显著提升了知识的使用效率与价值。研究知识图谱的应用主要聚焦于探索如何有效集成知识图谱技术，并将其融入到各类实际应用系统及特定行业场景中，以实现智能化、高效的信息处理与知识挖掘。目前，学术研究领域对于知识图谱的应用探索主要集中在推荐系统、信息检

索系统、问答系统等方面，突出其在新闻传媒、网络安全、社交网络、教育、医疗、金融、等诸多领域的广泛适用性和巨大潜力。

知识图谱概念的引入与普及，其在众多领域中的研究与应用已达到前所未有的高潮。语义网络结构在推荐系统中的应用不仅开拓了其发展的新维度，还极大地提升了个性化推荐的准确性和用户体验，通过构建丰富多维的知识图谱，实现深层次的理解与关联，从而在复杂多变的用户需求中精准定位，显著增强推荐效果。目前，基于知识图谱的推荐系统主要分为三大类：一是利用开放链接数据（Linked Open Data LOD）来生成推荐，二是通过图嵌入技术来生成推荐，三是基于实体的推荐生成方式。这种分类方法依据为，知识图谱在推荐算法中的辅助功能可以通过其多种应用场景来体现。

(1)基于实体[16]的推荐生成策略。实体与现实世界准确存在的事物或概念是相对应的，每一个实体都在这个图谱中保证了其独特性。实体之间存在着多样化关联实体和连接，它们共同织就着知识图谱语义网络。以实体为中心的推荐机制以挖掘实体间内在联系为目标，借助于用户与具体实体间以往的交互，并通过发现多个关联拓展用户可能关注的客体，进而达到深度解析实体范畴的效果。将知识图谱的实体特征融入到基于上下文信息生成推荐[17]、基于内容的推荐[18]、基于协同过滤的推荐[19]等方法中。Niaraki 等[20]通过整合用户交互的历史与上下文信息，成功构建物理数据库，并将该方法看作是前期实体导向推荐系统中核心策略的重要一环。在构建实体概念层次上的关系上，遵循以用户需求为核心的路径计划模型策略并将其与多标准决策机制相结合，显著增强模型可靠性。这一创新不仅弥补了传统建模方法的局限性，而且极大地提升了系统推荐路径的精确度和适用性。Dodwad 等[21]的算法原理更类似于前一种算法，但是对用户喜好的分析更细粒度。Saraswathib 等[22]的该模型以求职者群体为研究对象，目的是为了解决求职者浏览招聘平台上大量岗位空缺时由于信息过载而难以抉择的难题。这种方法通过对简历实体的动态生成和语义特征的评估来自定义求职者的推荐方案。Moreno 等人开发的 SigTur/E-Destination 混合推荐系统融合了协同过滤技术和实体特性，从而显著提高了推荐的准确性，这是一个以实体为导向的推荐系统的综合应用实例。

(2)基于开放链接数据的推荐生成策略。知识图谱领域中，包含了海量语义信息，虽然这些语义信息主要是通过数据库方式存储，但是当不需要图谱可视化时，探讨如何把这类语义元素融合到既有策略中就成了目前的一个研究热点。提出应制定战略，重点使用开放链接数据挖掘用户个性化偏好构建和项目之间相关性形成。通过内部语义信息提高项目相似度评价，更好地洞

察用户偏好，这是语义相似度计算的挑战。Passant 等[23]在推荐系统中使用 DBpedia 计算音乐推荐中的语义距离。Noia 等[24]利用开放连接数据的便捷性和多样性，通过 SPARQL 从 DBpedia、Freebase 等抽取与 ROF 相关的电影信息，并用向量空间模型分析相似性，制定推荐流程。

(3)基于图嵌入的推荐生成策略。从 Deepwalk[25]被提出的起，图嵌入技术便开始作为一种推荐手段。通过采用截断随机游走技术，我们可以深入了解网络的社交属性（socialrepresentation），即便在网络标记节点较少的场景下，也能够获得令人满意的成果。这种方法还拥有扩展性，可以灵活应对网络中的各种变动。Lászl[26]等为率先引入图嵌入理念的研究者，其提议的方法侧重于将电影及用户在 movielens 数据集内置于同一向量空间，同时，将知识图谱中的所有实体整合至相同维度的表示中。通过度量这些元素之间的空间距离，从而实现推荐生成。

1.2.3 新能源汽车研究现状

新世纪以来，新一轮科技革命和产业变革逐步走向纵深，前沿技术和颠覆性变革不断涌现，在数字经济、新能源和低碳经济、生物经济等领域涌现出一批高速增长的新兴产业。在全球低碳转型和碳达峰碳中和目标驱动下，新能源产业是增长最迅速、前景最广阔的产业新赛道之一。我国新能源产业经历了一个从无到有、从小到大再到强的发展过程，不仅成为国内经济的亮点和经济增长的重要推动力，也在国际上展现出强大的竞争力。根据国家统计局的数据，2023 年，与中国的“新三样”相关的产品，如太阳能电池、新能源汽车以及汽车用锂离子动力电池等，与上一年相比，它们的产出量分别有 30.3%、54.0%和 22.8%的上升，“新三样”出口增幅高达 29.9%，出口额首次超过万亿元大关。我国新能源汽车产销量自 2015 年以来连续九年世界第一，2023 年汽车出口量超越日本成为全球第一。以新能源汽车为代表的我国新能源产业的快速发展展现出我国产业升级的良好态势和经济的强劲韧性。新能源汽车是全球汽车产业的发展方向，国内外都在积极推进相关研究和技术创新。以下是一些国内外新能源汽车的研究现状：

一是电池技术：电池技术是新能源汽车的关键技术之一。目前，锂离子电池是主流的电池技术，具有高能量密度、长寿命、低自放电率等优点。除此之外，研究人员还在探索新型电池技术，如固态电池、氢燃料电池等。二是燃料电池技术：燃料电池是新能源汽车的另一项重要技术。燃料电池通过氢气与氧气的反应产生电能，不仅能够提供零排放的驱动力，还具有高能量密度、短时间充电等优势。但目前燃料电池技术仍面临着成本高、存储和输

送氢气的难题。三是快充技术：快充技术是解决新能源汽车续航里程和充电时间的重要途径。目前，一些新能源汽车已经实现了快速充电，使得充电时间大幅缩短。此外，还出现了无线充电技术，可以通过在地面或停车场安装电磁感应装置，使车辆在行驶过程中无需停车即可充电。四是智能化技术：智能化技术是新能源汽车发展的趋势之一。通过车联网技术和人工智能等手段，实现车辆与网络的互联，提供智能导航、自动驾驶等功能，优化能源利用、提高安全性和舒适性。

且在政策支持方面，中国政府高度重视新能源汽车的发展，出台了一系列政策以推动其产业化进程。国际上，欧洲联盟和美国政府也推出了相应的政策支持新能源汽车的发展。预计未来几年，随着技术进步和政策支持的不断加强，中国新能源汽车市场将继续保持快速增长。

1.3 本文研究内容

提出了基于知识图谱在新能源汽车推荐领域上的应用，能够一定程度上解决了用户无法在有限时间内找到适合自己需求的车辆的问题，本文的主要工作包括:

(1)数据收集与处理。通过互联网和移动应用等渠道收集和整合新能源汽车相关数据，也包括兴趣偏好数据、地理位置数据、用户历史行为数据等。清洗并预处理这些数据，确保其准确可用。

(2)构建知识图谱。知识图谱可以把各种知识集成到协同体系中去，从而推动知识共享和循环利用。就新能源汽车而言，通过实施合适的数据预处理步骤来清晰地划分实体和关系类别。然后应用本文所描述的 Dic-CTR 模型来达到从文本资料辨识实体之目的。另外还介绍了基于 BiLSTM 的分类策略，重点在于详细分类和分析核心实体之间相互依存关系;处理了所有实体之后，利用 OWL 本体语言来储存在新能源汽车领域内的知识图谱，从而成功地构建了一个全新的知识图谱。

(3)融合知识图谱与协同过滤的推荐算法。推荐算法是新能源汽车推荐系统的核心部分。计划使用整合了知识图谱与协同过滤推荐算法的方法[27]，该方法既可算出新能源汽车之间的语义关联度，又可算出用户对车辆偏好度。将该方法应用在新能源汽车数据集上，并最后进行验证分析。

1.4 论文组织结构

本文主要分为七个章节。

第一章是对研究背景及研究现状进行了详细描述。主要介绍当前新能源汽车推荐系统的研究背景及意义，阐述了国内外推荐系统的研究现状以及目前大环境下新能源汽车的用户量日愈增长，引出本课题研究的重点内容。

第二章全面介绍了相关理论和方法。包括协同过滤算法、多种相似度评估方法、知识图谱核心技术，以及两个模型的解释。

第三章为知识图谱的构建过程。首先收集和预处理了数据，确立了实体及其间关联的具体界定。继而，阐述了本研究中选用的命名实体识别及关系分类技术。随后，深入探讨了在新能源汽车行业构建知识图谱的存储策略。

第四章致力于以翻译模型为驱动，构建知识图谱，对新能源汽车进行语义表述。在知识图谱嵌入技术的支持下，已经成功地将与车辆相关的信息集成到紧密而维度较小的特征集合中，在这个低维空间上对实体向量之间的语义关联进行量化。对模型的学习过程进行深入分析，借助经验证明特征抽取准确。

第五章为推荐算法的详细介绍。利用协同过滤技术，描述了用户新能源汽车偏好一致性。接着，通过运用关联领域的知识图谱与知识表征学习策略，已有效地将新能源汽车的数据嵌入到低维度的向量空间内，并据此评估其与其它实体的语义近似程度。然后将两种相像度进行融合，利用融合后的相像度估算出用户对于车辆的预测评分，进而依此将推荐列表输出。最后通过新能源汽车方面试验对上述数据进行了检验。

第六章首先分析了新能源汽车推荐系统的可行性、系统功能需求跟技术框架，然后进行了系统框架设计与系统功能设计，最后对系统开展用户与管理员功能调试测试，展示并介绍了新能源汽车推荐相关核心模块页面图。

第七章对本文的研究进行了总结并说明了存在的不足之处，以及对未来的展望。

2 相关理论基础

本章主要对基于知识图谱的新能源汽车推荐的理论基础与关键技术进行介绍。

2.1 知识图谱

知识图谱建构过程中的挑战性问题主要体现在图谱内资讯抽取、知识图谱的向量化表示、知识整合以及逻辑推断等方面。而在基本步骤中，信息提取扮演着核心角色，涉及依据特定应用环境挑选合适的策略以识别实体与关联。知识图谱内嵌系指将知识图谱内所蕴含的概念性内容转化为低维度的向量形式，旨在提升捕捉实体间语义关联的效率。

2.1.1 知识图谱基本定义

知识图谱其实就是一种语义网络，它体现了客观世界的多样性[28]，这一表达对现实世界进行了简明扼要的描绘。此数据呈现的是图为核心的数据结构方式，也可以被诠释为一个融合了实体（节点）以及关系（有向边）的网络关系。使用 $G=(V, E)$作为表示工具，其中 G 是知识图谱的实体组合，而 E 则是边的集合。而且，节点也蕴含了众多的属性信息。在节点 V 与关系 E 分别存在各自独立类型的情境下，我们有可能将此网络定义为异构网络，而相对于它来说，则是同构网络的存在。

三元组结构在知识图谱的表达中是一种常见的方法，它通常采用<头部实体、关系型实体、尾部实体>或者<实体、特性、属性值>这类表达进行详细描述[29]，实体不仅是一个独立的实体，而且是唯一可以用来区分的事物。例如一个具体的物品、某种特定的水果或一个电影明星等，这些具体的事物共同构成了这个世界的一切。每一个物品都是一个实体，而不同的实体都拥有其独特的属性。实体是知识图谱中最根本的组成部分，而连接实体和实体的是两种截然不同的联系方式。

三元组里面明确了 $\mathcal{E}$ 作为知识体系内的一个实体集合，并且该集合由多个不同的实体组成 $|E|$ 个；r 代表知识结构内多种关系的集合，它内部涵盖了不同的相互关系 $|R|$ 个。如图 2.1 所示，以<苹果品牌 创造者 乔布斯>或者<苹果公司，其创办年份为 1976 年>为研究实例。在首个三元组里，第一个实体被命名为“苹果品牌”，而最后一个实体则是“乔布斯”。“创造人”是

关系的定义”；在第二个三元组中，该实体被命名为“苹果公司”，其标志是“成立时间”，而其具体数值则是“1976 年”。

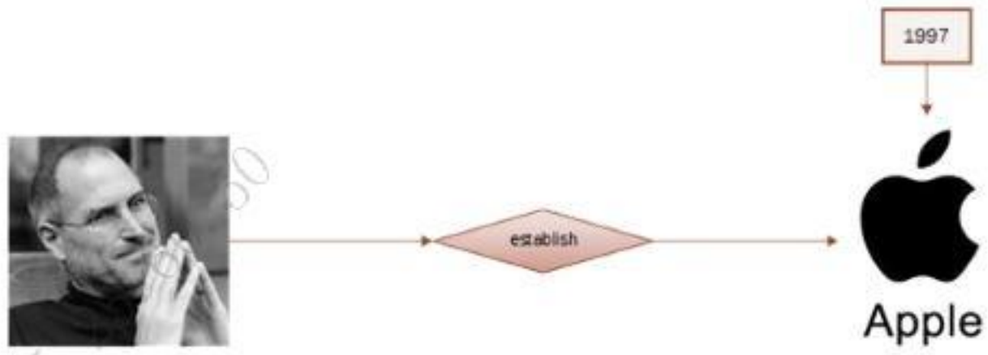


图 2.1 知识图谱示例图

Fig.2.1 Example diagram of knowledge graph

要真正掌握知识图谱在推荐工具中的价值，我们必须细心观察知识图谱与物品的属性之间存在的差别。在知识图谱里，物品的特性可被看做是某一实体的一个核心节点，与它形成了紧密的联系，而属性在知识图谱中被视为一个简洁的例子。社交媒体网络可以被视为一个仅仅包括了用户和社交关系的知识脆弱式图谱。一个完美的知识结构图能够为算法提供更精确、更多元化和更有解释力的推荐成果。知识图谱不只为推荐方法提供了更深层的语义联系以进行资料增补，该方法也有助于解决传统推荐技术在推荐结果解释方面存在的不足。如图 2.2， $_2$→《星际穿越》→类型→《致命魔术》这一系列的路径为推荐平台提供了一种易于理解和接受的推荐方式。

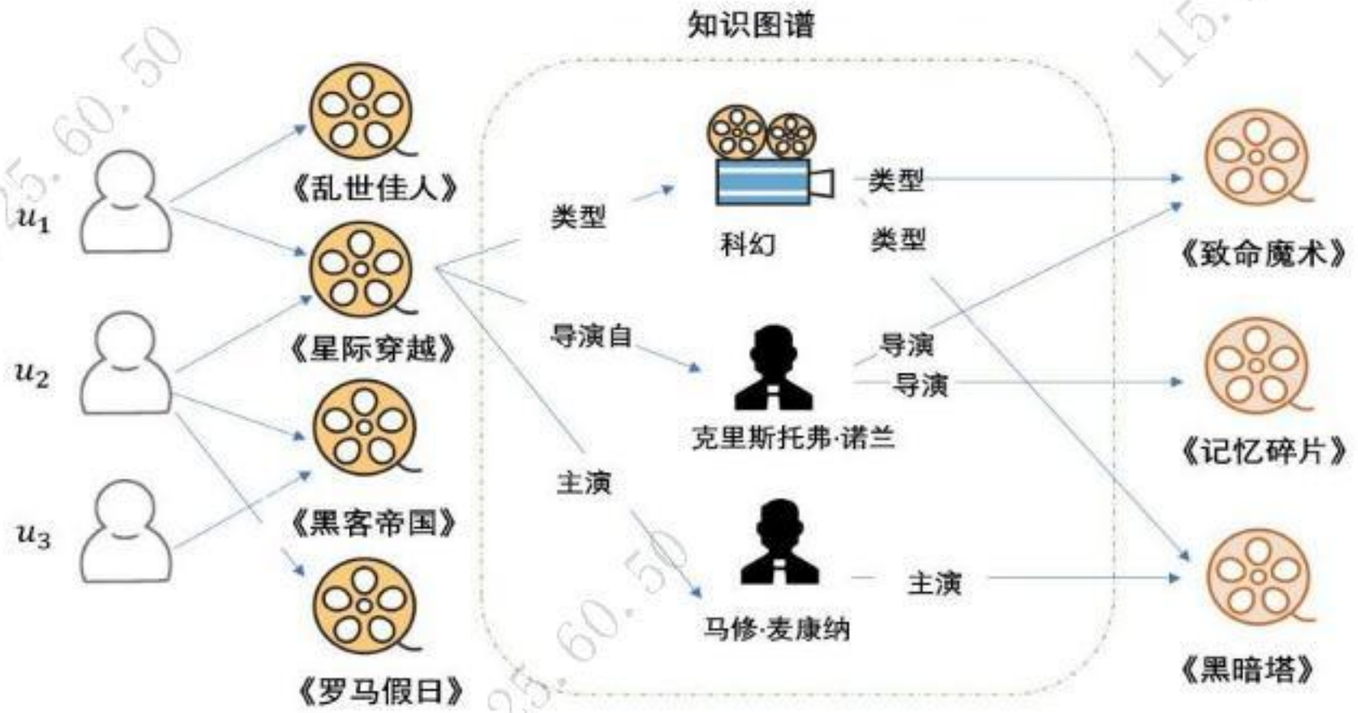


图 2.2 基于知识图谱推荐系统示例图

Fig.2.2 Example diagram of a knowledge graph based recommendation system

2.1.2 知识建模

知识图谱揭示了不同概念间的相互关联原则[30]，知识图谱揭示了不同概念间的相互联系原则，并包含了与这些原则相关的众多信息，这也涵盖了该领域内的专家的经验和研究者之间的合作状况。借助节点、边结合方法来建立模型，目的是深化对数据局限的认识。从两个维度—理论以及实际应用，

本体不仅是一项至关重要的信息资产，还有助于人们更深刻地洞察复杂系统内部隐藏的规律和理念，并从中汲取有价值的见解与知识。本体库建模的根本含义是为已有的知识进行模型化。本体库为一种依据规则以及语义相似性进行计算的形式化展示，它可以有效地描述人的思考过程中的逻辑推断[31]。本体库的形成主要借助综合自上而下与自下而上的策略。对于这两种本体库的建立方法，我们进行了详细的对比和解析，进而提出了一个融合自上而下与自下而上的综合设计，促进本体库内各种数据类别的对应与共用。采用由下至上的设计方法，初始阶段从个体实体出发，经过选择与聚合，从而构建出一个相对大规模的概念，接着再进行进一步的抽象处理。利用分层结构来划分数据，这样既加强了数据维度上的高效，又能确保各级数据之间能保持较高连续性。该研究采用机器学习和统计学等策略，以基础实体为视角，针对标准数据来源展开基础分析，优化标准数据组织构架。

2.1.3 知识表示

知识图谱不仅包括本体论、认知学和社会学等多个领域的关键内容，而且还囊括了众多实际应用案例。一个能高效地识别和分析属性名称的方法。所谓关系抽取的概念就是在没有考虑到物体之间语义联系的情况下，将其与数据库内其他物体进行相似性比较，从而得到对应的信息或者回答[32]。实现基于既定规则和模板的方法，领域内的专家需要制定和建立相应的关系规则和模板。虽然这些建议和模板在准确性上表现出色，但鉴于研究的巨大工作量和它们在其他领域的应用困难，对它们进行深入的学术探索和研究是非常必要的。为了解决此问题，推出了一个依赖于知识图谱技术的关系抽取方法[33]。伴随机器学习领域的持续发展，已集成一种融合监督与轻监督策略的关系提取手段，旨在增强其实效性与精确度。本篇论文介绍了一种创新的、具有特征的关系标注方法。与实体识别相似[34]，我们首先利用基于特性的关系提取技术来识别具有辨识能力的词汇、实体属性、依存意义以及语法构造等。接着，利用这些属性来对训练与分类模型进行深入研究，最终使用训练完成的模型进行文本的关系提取和依存语义深入分析，从而产生完整的三元组关系。

实际上，知识的展示方式是通过计算机符号的模拟推断来实现的[35]，此方法既适用于机器也适用于人类，其目标是模仿人类大脑所承载的知识。图模型作为一种高效的关系表达工具，不仅能够清晰地描绘实体间的联系，还为计算机提供了理解与解析的途径，其应用范围广泛，特别是对于模仿人类大脑进行知识推理过程具有重要意义。这一模型采纳了基于标志与向量的呈

现技巧，非常适合知识的建模工作。图 2.3 为知识的抽取和表示之间的关系图。

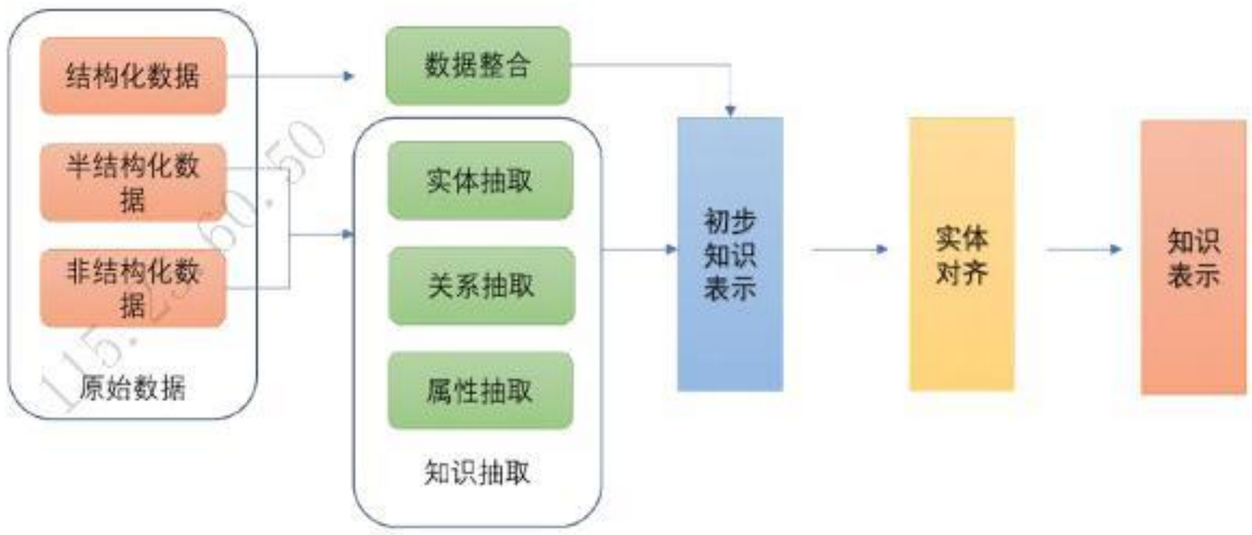


图 2.3 知识抽取与表示关系图

Fig.2.3 Knowledge Extraction and Representation Relationship Diagram

2.1.4 信息抽取

目标在于自动化地从非结构化数据集合中提取关键信息，该信息通常呈现出有序结构，具备为问答系统、检索系统等后续自然语言处理任务提供支撑的能力。此外，提取的此类信息还能强化现有的知识库。信息提取的技术路径主要涵盖了知识工程技术和基于统计学原理的方法。知识工程的方法分为两大类：其一是基于知识的策略，另一方面则基于规则，这两个策略融合了人类的专业知识和计算机系统，特别是在需要专业知识的环境中表现得较为出色。与传统的知识工程方法相对照，统计驱动技术不需要手动设定规则，更加强调系统的分类和功能特性。我们可以将统计方法划分为几个不同的类别：有监督学习、半监督学习和无监督学习的几种。信息抽取的主要职责涵盖了实体的辨识、指定的解析、联系的建设和事件的提取。这一节详细回顾了实体提取与关系提取方面的工作进展。

(1)实体抽取

实体提取，也被称为实体的识别，是在自然语言处理过程中常用的一种技术，如信息问答系统[36]、检索提取[37]、机器翻译[38]等。

在特定领域的文献里，对实体的名称进行自动化的辨识和分类，即为所谓的实体提取。实体提取是涵盖了两个核心工作领域：一是命名实体的确定，特指分辨单个词汇或者词汇组群是组成命名实体的过程；二是标注实体类别，明确所识别命名实体的具体性质或范畴。在实体抽取技术的众多方法中，最初被提出的通常是基于规则的方法。这一方法的优势在于其易于理解的特性以及便于逻辑推断的过程。从语言、专业领域以及文本风格的角度考量，基于规则的方法在应用性和泛化能力上表现出明显的局限性。此外，规则驱动

的实体提取过程通常涉及复杂且耗时的手动规则设计。机器学习技术的执行涉及在文本中识别模式与关联以构建模型，此模型旨在辨识并归类名词性实体，包括人物、地点及时间等。机器学习技术展现出优越的弹性和稳定性，其独特之处在于无需依赖语言专家，从而使其具备跨语言应用的潜力。然而，这一优势也伴随着显著的挑战，即实现模型的有效训练通常需要庞大的数据集作为支撑。

(2) 关系抽取

在自然语言处理领域，关系抽取被视为一项至关重要的任务。目前，关系抽取技术已经在信息抽取、自然语言的理解以及知识库的补充方面得到了广泛的应用。关系抽取的目的是将文本中两两相互独立的实体之间的语义关联归类并加以处理。现有技术有几个独特的分类：

基于规则的策略：应设定关系提取的特定准则，然而，此类自动化形成的规则可能存在误判，此策略的适用迁移性通常受限于领域内专家的投入。

无监督策略：该方法先将实体的单词串抽取出来，然后再将这些单词串归类并化繁为简，最后得到关系串[39]。该策略对已标定数据没有依赖性，可以直接对海量数据进行处理，确定其相互联系。但是关系格式没有标准化造成抽取的准确性不高。

半监督方法：bootstrapping 为该方法核心概念。这一方法最初是在 DIPRE[40]文献中提出的，然后对 Snowball,KnowltAll,TextRunner 等人的文献进行进一步优化与改进。bootstrapping 技术经常会遇到语义发生偏移，精度不够等问题。

监督方法：视关系识别任务是一个涉及多类的复杂任务，因此需要在清楚关系的两个子领域里独立地利用不同的分类器来完成该任务。采用监督手段对优质的标注语料库提出更严格的标准，不过在关系抽取标注的应用中，通常规模会偏小。在没有必要数据支持的前提下，监督学习方法可能面临若干问题。

远程监控技术：以避免人工构建关系和抽取数据集的麻烦工作，Mintz 等[41]提出远程监督。他们利用知识图谱为各个句子提供深入的解释，以明确不同实体之间的关系。每一句话都明确了这些联系，并通过远程监控工具将其整合为实体关系的示例。考虑到存在一组由多句描述构成并与之紧密关联的实体，远程监控关系提取任务的主要目的便是从这批监控集合中识别并提取其独特性质，进而对实体对间的实体关联类型进行分类。

2.2 协同过滤算法

协同过滤这一方法依托于集体智慧的原理运作。协同过滤推荐并不能充分地继承物品或者用户的具体属性，它的灵活性与用户中心性才是它吸引人的地方。它是根据对用户行为数据的分析来产生推荐的，不需要用户另外的输入，比如填问卷等。协同过滤推荐机制有效地探索并揭示用户可能感兴趣但尚未被发现的偏好。协同过滤技术现在不再仅基于商品与用户之间的标签，而是采用系统内其他用户提供的评分信息来实施推荐。核心主张在于：若两位用户曾相互给予过反馈评价，或在评估同类物品时采取了相同比例的评价策略，那么他们对于任一特定物品的评分表现可能会呈现出高度的一致性。

(1)基于用户的协同过滤

根据与预定用户较为接近的人群，用户协同过滤技术能够生成对应的推荐列表。当有一些用户给某个特定物品的评分与其他人持平时，这个特定群体对另一商品的评价或许也与其他用户的评价接近。首先鉴定目标用户的最近邻，然后基于该用户为某一物品的评级来预测可能的物品效果。

步骤 1：通过用户评分向量的皮尔逊相关性，我们可以量化用户间的相似度，并据此为用户分配权重。

步骤 2：从多个中选取那些和目标用户相似度最高的 n 个用户。

步骤 3：采用近似度作为评价标准后，对邻近用户的评分进行了加权平均分析，从而预测了目标用户对给定物品的评分，并根据这一数据构建了推荐表。

(2)基于物品的协同过滤

采用商品协同过滤策略为与用户所钟情的商品相匹配的物品做推荐，由于这些商品的相似度显示出静态特质，这使得它可以先行离线估算其相似度，并在一定时期内再次对其进行计算，这种方式赋予了该方法出色的可扩充性。另外，在不损害预测效果的前提下，只能挑选与每种物品最为匹配的 n 项物品来评估其性能。接下来，可以通过查找活跃用户对每件物品的相似度列表，并评估它们的预期偏好，这样能够实现在线、高效的预测功能。该算法步骤如下：

步骤 1：先得到目标用户过去喜爱的商品。

步骤 2：接着评估物件间的关联性，随后基于特定使用者偏好的物件与其他物件的关联强度对其进行量化，进而估算各个待估物件的评价分数。

步骤 3：基于目标用户过去所偏好的物品记录以及每个物品的评分生成推荐列表。

(3)基于记忆的协同过滤

实时处理用户与物品评分数据的基于记忆的协同过滤推荐系统实现起来，充满挑战，尤其是当数据规模庞大且持续增长时。这一情境下，确保系统能够实时响应并提供个性化推荐变得异常困难。该协同过滤模型在经过训练后，利用预先训练好的模型进行预测，无需重复调用或分析完整数据集，此特性极大地增强了推荐系统在处理效率与预测准确性方面的表现。

矩阵分解时评分矩阵用两个特征矩阵之和来表示。将用户与对象映射在维度 f 潜在因子空间中，以内积方式表达其互动。各项目 i 和每个用户 u 分别与向量 $\in R^f$ 和向量 $\in R^f$ 相关联。给定的用户 u， 中的元素衡量用户对相应因素较高的项目的兴趣程度，为积极或消极，点积 可捕捉用户 u 和项目 i 之间的交互信息。

= (2-1)

2.3 相似度相关计算方法

在多数推荐算法里，用户或物体间的相似度评估方法经常出现。这些相似性评估方法的科学准确性是决定推荐质量高低的决定性因素，一个高质量的度量技术能够让推荐结果更加精准，其中应用最广为欧式距离相似度、皮尔逊相似度、余弦相似度[42]。

2.3.1 余弦相似度

余弦相似度通过计算两个物体向量夹角的余弦值来评估它们之间的相似度差异。当这些值的大小为[0,1]，数值越高意味着两个样本之间的相似性越高。设 $X=(x_1,x_2,\cdots,x_n)$ 和 $Y=(y_1,y_2,\cdots,y_n)$ 是 n 维向量。

$$(,)_{\cos}= \frac{\cdot}{\| \| \cdot \| \|} = \frac{\sum_{=1}}{\sqrt{\sum_{=1}^{2}}\sqrt{\sum_{=1}^{2}}} \tag{2-2}$$

2.3.2 欧式相似度

在数学领域，欧式距离作为一种基本的距离度量方法，在向量空间中得到了广泛的应用，目的是为了准确地计算两点间的直线距离。欧式距离的计算严格依赖于两点间固定的一致性度量单位，这意味着它实际衡量的是两点在绝对空间距离。设 $X=(x_1,x_2,\cdots,x_n)$ 和 $Y=(y_1,y_2,\cdots,y_n)$，则 X 和 Y 的欧式距离计算方法如下所示：

$$(,) = \sqrt{\ _{=1}(\ - \ )^2} \tag{2-3}$$

则欧式距离相似度的计算公式如(2-4)所示:

$$(,) = \frac{1}{1+\sqrt{\ _{=1}(\ - \ )^2}} \tag{2-4}$$

当目标间距离越小，计算结果越接近 1，表示目标相似度越高。

2.3.3 皮尔系相关系数

皮尔逊相关系数通过标准化两个向量（减去均值）来衡量关系，适用于矩阵有缺失值时，比余弦相似度更优越，因此，可以说在处理数据缺失问题上，皮尔逊相关系数是对余弦相似度的一种有效提升和改进。相较于余弦相似度，皮尔逊相关系数在衡量样本间相似性方面更为精确，它被视为协同过滤技术中在处理评分尺度不一致问题时最为常见的评估手段。若用户 *b* 对相同车辆的评分为(8，6，4)，用户 *a* 对车辆 1、车辆 2 和车辆 3 的评分为(10，8，6)，为强相关，设 $X=(x_1,x_2,\cdots,x_n)$和 $Y=(y_1,y_2,\cdots,y_n)$为 *n* 维向量。

$$\text{sim}(,) \quad = \frac{\ _{=1}(\ - \bar{\ })(\ - \bar{\ })}{\sqrt{\ _{=1}(\ - \bar{\ })^2}\sqrt{(\ - \bar{\ })^2}} \tag{2-5}$$

2.4 模型介绍

2.4.1 条件随机场模型

条件随机场(CRF)[43]该模型是一种基于概率的方式来进行序列数据的标记与划分。此方法作为一种受控的机械学习手段，在众多的编程语言中，在命名以及实体识别方面，都已被广大领域采用，并已经展现出卓越性能[44,45]。它一般处理三大核心问题：特征的挑选、训练的参数设定以及解码过程。在特定条件概率分布模型的背景下，条件随机场展现出一种特殊的特征。

其 *X* 的长度是 *n*，输入序列 *Y* 中，公式(2-6)所描述为其定义。

$$(|)=\frac{1}{( )}exp\Big(\qquad (, | ,)+ \qquad (, | ,)\Big) \tag{2-6}$$

( )为标准化分布函数，主要目的在于将全部输出序列概率归并为 1。

$$( )= \ \Big(\ \Big(\qquad (, | ,)+ \qquad (, | ,)\Big)\Big) \tag{2-7}$$

和 为节点和边某一特征的权值， 为边的传递特征函数， | 和 | 分别表示注释序列构成的无向图的边和节点， 为节点 *v* 的状态特征函数，

将特征函数和它的有关参数一起统一显示，这种表达方式既涉及那些刻

画系统传递特性又涉及揭示系统状态特征的功能，由 （ $_{-1}$，，，）的两个特征函数统一表示为公式(2-8)。

$$(y,x)= \quad (\ _{-1},\ ,\ ,\ ) \tag{2-8}$$

故条件概率可以改为:

$$(\mid)=\frac{1}{( )}\exp(\qquad (\ , \ )) \tag{2-9}$$

其中 ( )是归一化因子:

$$( )= \qquad (\qquad (\ , \ )) \tag{2-10}$$

2.4.2 双向长短时记忆模型

长短期记忆网络、递归神经网络[46][47]对处理长度各异时间序列数据具有较高适用性，每一个句子都有可能被解读为由字符拼接而成的逻辑排列，这使得 RNN 和 LSTM 成为了在多种自然语言处理任务中的理想选择。典型的 RNN 布局在图 2.4 中有描述。

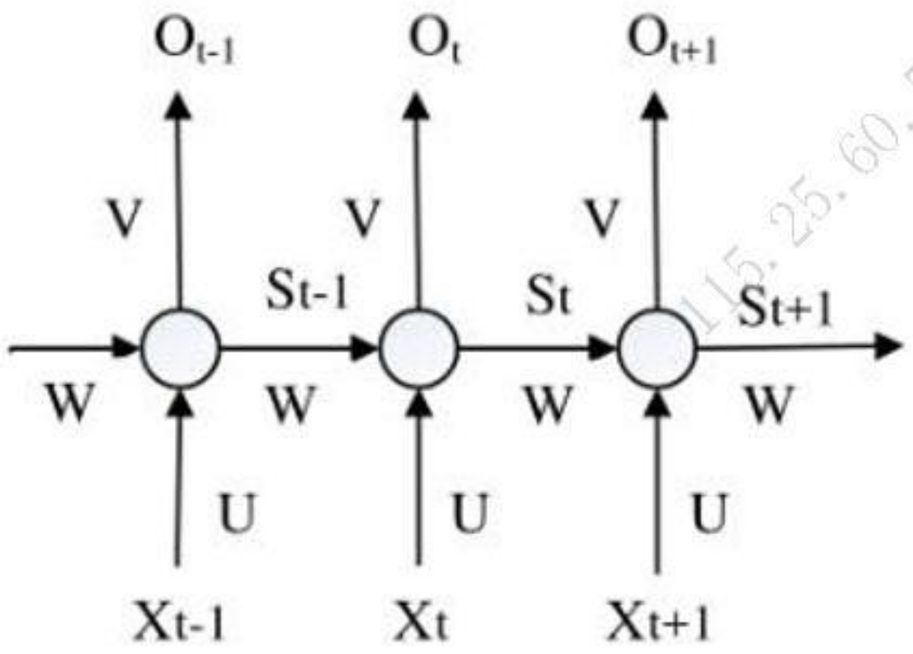


图 2.4 RNN 结构

Fig.2.4 RNN structure

当前隐含层 的输出由输入层 x_i 和前一隐含层 $_{-1}$的输出决定。

$$= \tanh(\ \times \ _{-1}+ \ \times \ ) \tag{2-11}$$

在此结构里,W 代表的是权重矩阵，U 是转移矩阵的代表，而 tanh 则是激活函数的代表[48]。在网络应用中长步长会引起梯度爆炸甚至消失。Hochreiter 给出了一种与长短时记忆相结合的神经网络模型，较好地解决了这一难题。[49]。LSTM 模型作为 RNN 的一种进阶版本，能以极其简化的手法来处理梯度的消失问题。LSTM 模型在其核心上增加了 RNN 模型的内存，从而让其有能力维护并学习输入的持久依赖性。LSTM 存储器也被人们称作“门”组件，其内部的“门”这个词是基于一个选择，即保持或忽略已经存储的信息进行记忆。与 RNN 系统相比，LSTM 系统新增了三个控制接口，它们是遗忘门、

输门的入口以及输门出口。LSTM 的监测模块的主要职责是引导细胞选择性地丢弃和更新特定的数据，以应对可能源自 RNN 的问题。标准的 LSTM 架构在图 2.5 中呈现。一个用于描述细胞遗忘与信息更新的数学表达式(2-12)已被用来表示。

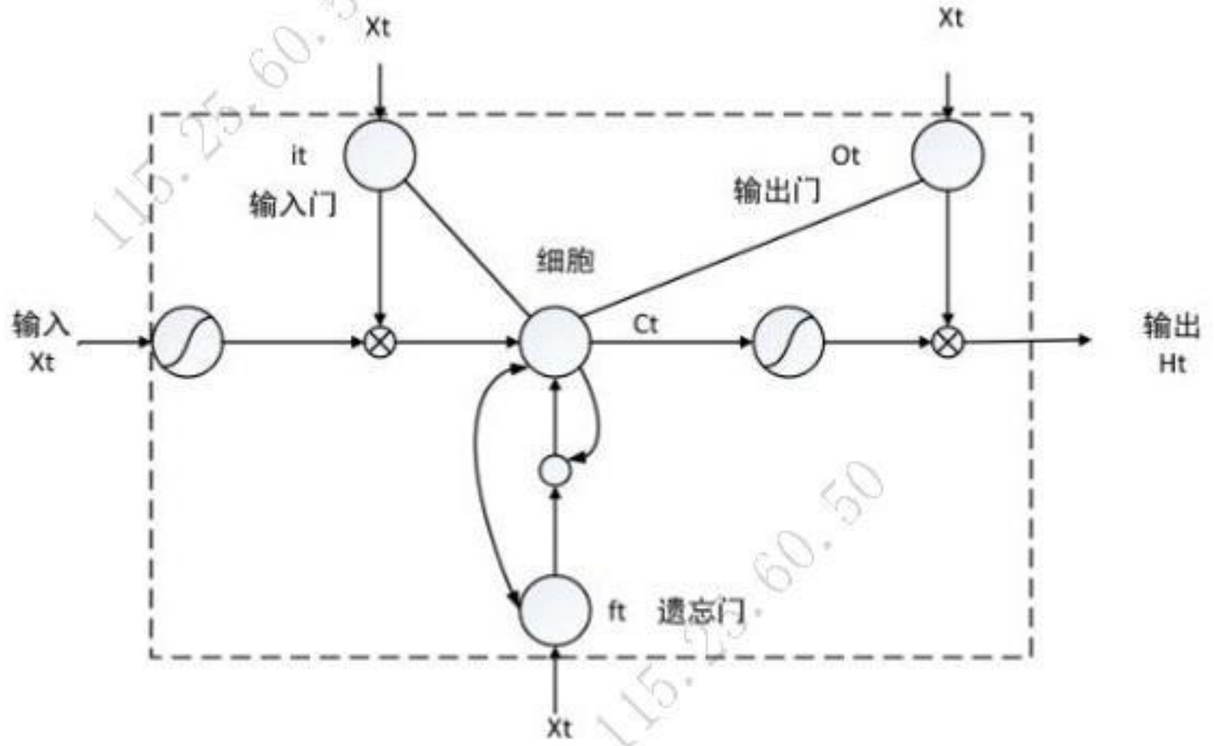


图 2.5 LSTM 结构

Fig.2.5 LSTM structure

$$\begin{cases} i_t = \sigma\left(W_i\left[x_t, h_{t-1}\right] + b_i\right) \\ f_t = \sigma\left(W_f\left[x_t, h_{t-1}\right] + b_f\right) \\ o_t = \sigma\left(W_o\left[x_t, h_{t-1}\right] + b_o\right) \\ c_t = f_t \times C_{t-1} + i_t \times \overline{c_t} \\ h_t = o_t \times \tanh\left(c_t\right) \end{cases} \tag{2-12}$$

神经网络设计中，隐藏层数据可直接输出，h 为隐藏层数。门控机制中，b 是偏置向量，w 是权重矩阵。网络节点记录的数据和过去甚至将来网络节点的数据是有联系的。在处理序列标记任务的信息时，我们建议使用 BiLSTM68%的模型。该模型具有良好的前后期信息整合的性能，适合这类工作。BiLSTM 模型的输出性能是由 LSTM 模型的两个相反方向和六个特定权重参数共同作用和影响所决定的[50]。

图 2.6 展示了 BiLSTM 关系分类模型，其中 C_1-C_n 是汉字向量，h0 和 S 是句子向量，O 是输出向量。分类器输入 C_1-C_n 和 h0，输出二维向量 O，00 和 01 分别代表满足和不满足关系的可能性。神经网络有能力在训练阶段确定最合适的参数组合，并据此进行数据分类。

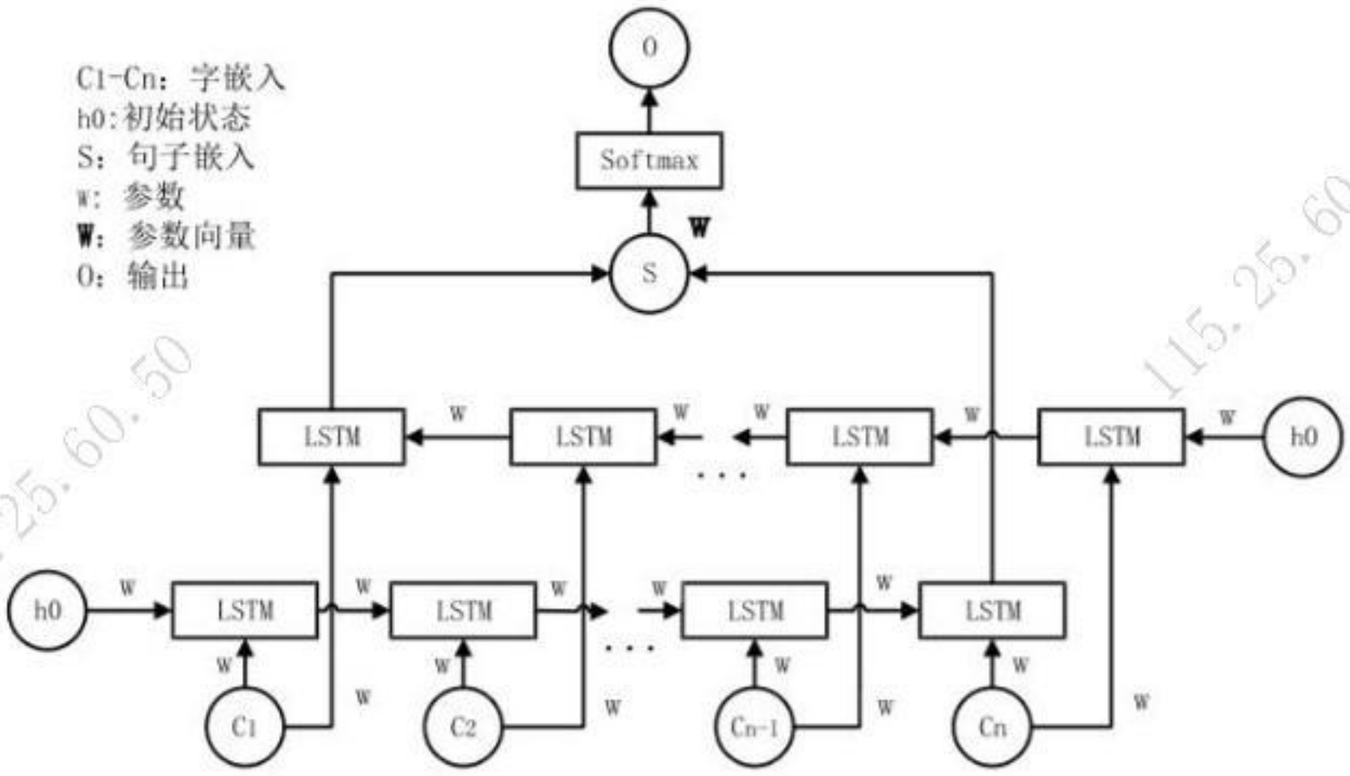


图 2.6 文本分类处理中的双向长短期记忆结构

Fig.2.6 Bidirectional Long Short Term Memory Structure in Text Classification Processing

2.4 本章小结

这一章节主要聚焦于介绍新能源汽车推荐算法相关的理论框架，对多种协同过滤技巧作了深入探讨，分析了常用的相似度评定方法，接着对知识图谱中的信息提取与嵌入式的核心思想与技巧进行了详尽的解读，最终涉及到用于命名实体识别的 CTR 模型，以及在实体分类时所依赖的 BiLSTM 模型。

3 新能源汽车领域知识图谱构建

本文设计了一种基于知识图谱的解决方案，该图谱在新能源汽车领域构建，旨在为寻求新能源汽车推荐的用户提供决策支持。首先概述了数据采集及预处理流程，随后详细阐述了针对新能源汽车的知识图谱模式层设计，明确界定了其内的概念与关联关系。接下来，采用了创新的实体抽取与关系分类策略，有效识别并分离出数据集中的关键实体与连接关系。此外，实施了实体对齐技术以确保信息的一致性和准确性。最后，运用 OWL[51]本体语言，成功地将构建的知识图谱进行存储与整合。整个过程系统而有序，最终实现了新能源汽车领域知识图谱的全面构建。

3.1 数据获取与预处理

在这一部分中，详细描述了怎样得到试验中的数据。新能源汽车知识图谱数据由具体爬虫软件在对应站点上收集而来，并根据数据类型进行合适预处理。研究资料主要来自于网站相关的数据，这其中涵盖了大量的结构化、半结构化和非结构化信息。Jena 展示了一个应用程序的接口，它允许从 RDF 图中提取数据，并在图中记录所需的信息。然后这些影像被转换成可在文件，数据库和网站上进行数据检索的概念模型。Jena 支持 OWL 接口的 API 接口,Jena API 顺利满足 RDF 规范。

本文构建电池质量、车辆性能、品牌与售后、经济考量、个人需求五个词典。使用规则公式处理了半结构化数据，将所有从其上提取的实体都保存在了对应的词汇列表里。针对非结构化数据，采用多重模式字符串匹配策略实现数据配准，并将与此相匹配的实体整合进词典内。如表 3-1 所示，列出了词典的实例。

表 3-1 词典实例

Tab.3-1 Dictionary Example

词典名称	实例
电池质量	能量密度、安全性、循环寿命等
车辆性能	续航里程、动力性能、充电效率、安全性能等
品牌与售后	品牌信誉、售后服务网络、质保政策等
经济考量	购车成本、使用成本、保值率等
个人需求	出行需求、载人载物需求、地理条件、性能偏好等

3.2 知识图谱模式层定义

3.2.1 相关实体定义

通过整理与分析新能源汽车相关数据，最后，选择在新能源汽车的知识图中将实体概念划分为五个主要种类，其中包括电池质量、车辆性能、品牌与售后、经济考量、个人需求。各类实体的描述与实例如表 3-2 所示。

表 3-2 新能源汽车实体定义

Tab.3-2 Definition of New Energy Vehicle Entity

实体	描述	实例
电池质量	新能源汽车所需要重要部分	能量密度、安全性、循环寿命等
车辆性能	新能源汽车所拥有的性能指标	续航里程、动力性能、充电效率、安全性能等
品牌与售后	与新能源汽车紧密联系且相互影响	品牌信誉、售后服务网络、质保政策等
经济考量	影响用户购买的原因之一	购车成本、使用成本、保值率等
个人需求	用户购买车辆时的需求	出行需求、载人载物需求、地理条件、性能偏好、品牌与售后、政策环境等

3.2.2 实体间关系定义

基于 3.2.1 节取得的数据，如表 3-3 与图 3.1 本文定义了五种实体间关系。分别包括电池质量、车辆性能、品牌与售后与经济考量、个人需求之间的满足、不满足关系，电池质量与品牌与售后、车辆性能之间的直接影响、间接影响关系。

表 3-3 新能源汽车知识图谱中实体间关系

Tab.3-3 Entity relationships in the knowledge graph of new energy vehicles

关系	主体	客体	描述	实例
直接影响	电池质量	车辆性能	电池质量在某方面上直接影响了车辆性能	能量密度直接影响了续航里程

表 3-3 续

Tab.3-3 Cont

关系	主体	客体	描述	实例
间接影响	电池质量	车辆性能	电池质量也间接保证了车辆某方面的性能	质量好的电池能间接影响到汽车安全性方面的热稳定性与抗冲击性
满足	电池质量、性能、品牌售后	经济考量、个人需求	电池质量，车辆质量及品牌售后方面满足某经济考量与需求合适的用户	电池寿命长，安全性高，比亚迪满足经济型，日常通勤用户
不满足	电池质量、性能、品牌售后	经济考量、个人需求	电池质量，车辆质量及品牌售后方面不满足某经济考量与需求合适的用户	能量密度一般，动力性能一般，比亚迪不满足经济型，激情驾驶用户

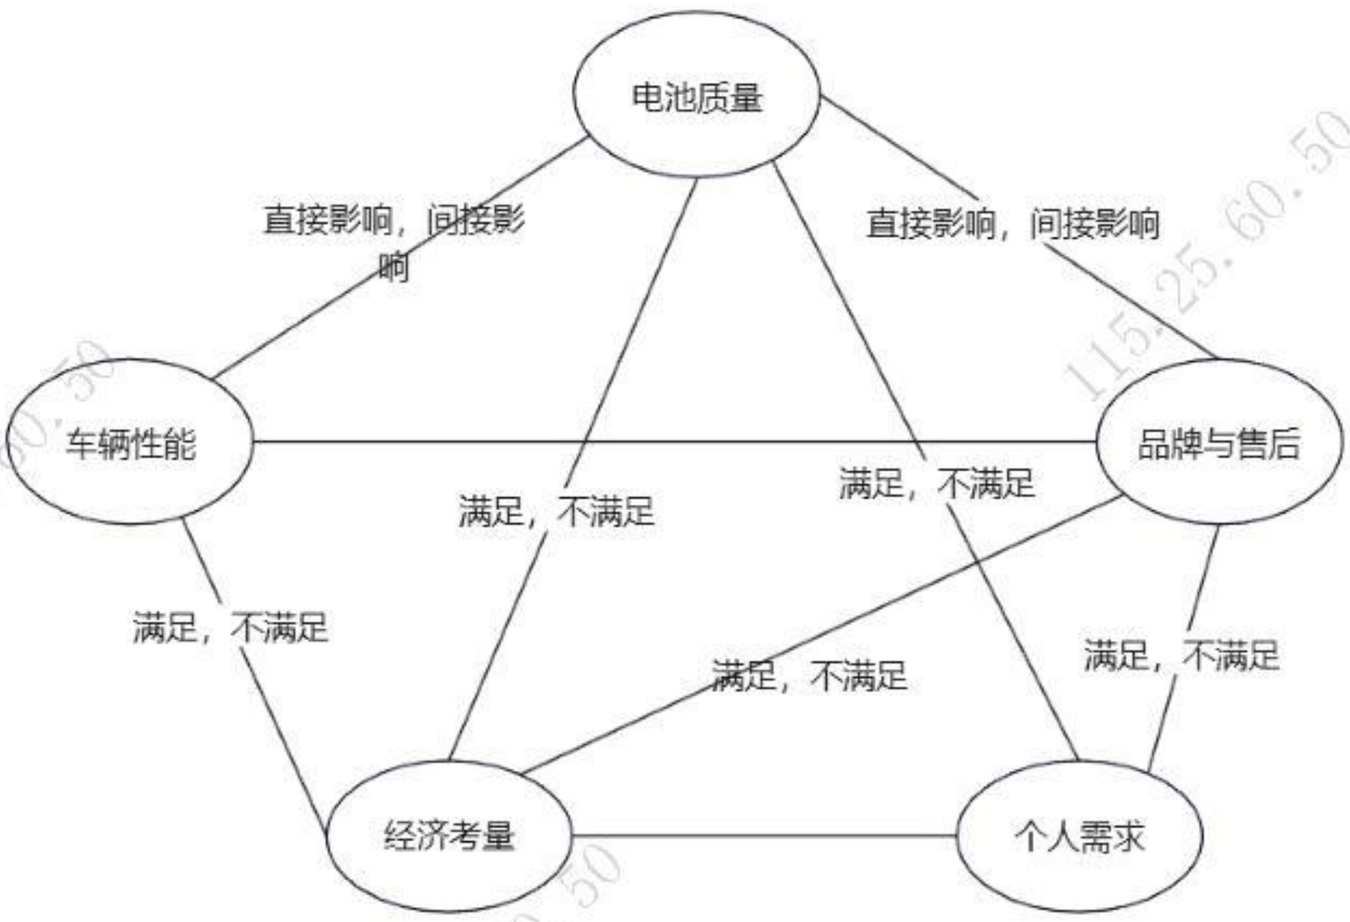


图 3.1 新能源汽车知识图谱模式层

Fig.3.1 New Energy Vehicle Knowledge Graph Pattern Layer

3.3 实体识别

在非结构化的文本数据里，仍存在大量数据未被完全提取。本节将详细解释如何采用一种融合词典和条件随机场的方法来对文本数据进行命名和实体识别。

3.3.1 数据集标注

在执行命名实体识别之前需要在数据集上标记。自然语言处理的预处理步骤通常是通过序列标注来辅助机器对文本结构与组成的理解。

文章采纳了目前使用最广的 BIO 编码方式[52]，对从数据源中提取的文本信息进行了序列性的标注。如图 3.2 展示的 BIO 编码模式中，B 代表实体的起始点，I 代表实体的内部结构，其中包含了结束词，而 O 是指非实体部分。见图 3.2，“能”是电池质量实体的初始词，并用 B-Quality（Begin-Quality）进行标识。在电池质量实体中，“量”、“密”和“度”是其内部的词汇，并用 I-Quality（Inside-Quality）来进行标识。“直接影响”这个字并不是任何实体的一部分，因此采用 O（Outside）来进行标识。由于“续”是车辆性能实体的初始词，因此采用了 B-property 作为标识。而“航”、“里”和“程”则是车辆性能的内部词汇，因此选择了 I-property 作为标记。

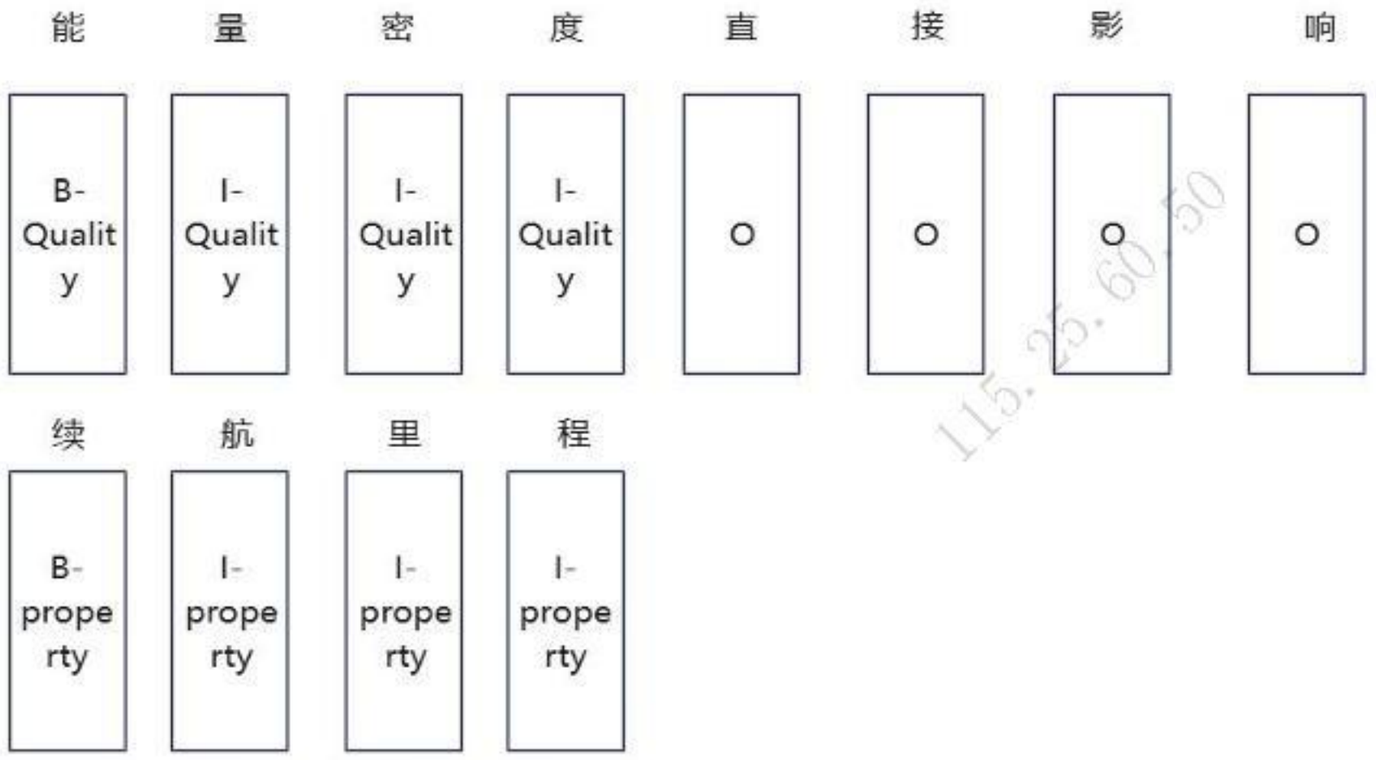


图 3.2 标注实例图

Fig.3.2 Annotate example diagram

3.3.2 基于 Dic-CTR 模型的命名实体识别

该研究针对上述数据识别命名实体，命名实体识别实例详见表 3-4。以“能量密度对续航里程有着直接的影响”这一主题为例，进行了深入的实体分析，识别出的实体为能量密度、续航里程，并分别将能量密度对应到模式层中的电池质量，续航里程对应到车辆性能。

表 3-4 实体命名识别实例

Tab.3-4 Entity Naming Recognition Instance

非结构化文本	命名实体识别
能量密度直接影响了续航里程	能量密度（电池质量） 能量密度（车辆性能）
品牌为中等水平满足经济型 动力性能一般，比亚迪满足追求预算低， 但不满足激情驾驶用户	比亚迪（品牌与售后） 经济型（经济考量） 动力性能（车辆性能） 比亚迪（品牌与售后） 预算低（经济考量） 激情驾驶用户（个人需求）

虽然在非结构化文本数据处理中，多模字符串匹配算法已被广泛应用于实体提取，但由于单词语义的复杂性和多样性问题仍然存在，这一方法在非结构化数据的实体提取方面表现得并不是特别准确和高效。为进一步提高新能源汽车领域命名实体识别能力，文中使用 2.4 节所述 CTR 模型与基于词典技术相结合完成命名实体识别工作，如图 3.3。

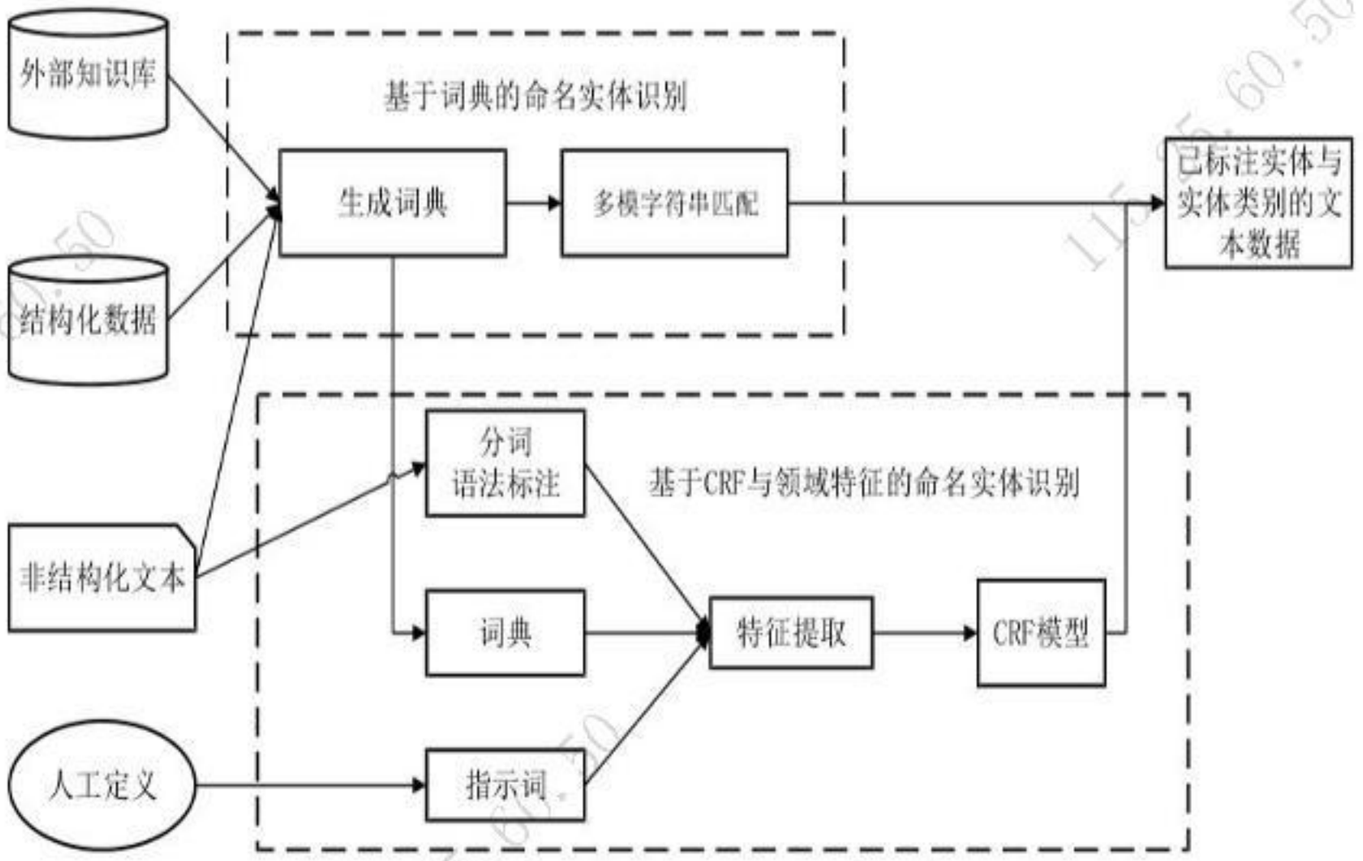


图 3.3 命名实体识别流程图

Fig.3.3 Named Entity Recognition Flowchart

在此过程中，通过利用文本资料完成了词的分类和语法注释的加工，生成了如边界词、词类、字典和指代词等独特的描述特征。

3.3.3 实验结果与分析

为了验证 Dic-CTR 模型的命名实体识别效果，对 5600 段新能源汽车数据进行了 BIO 标注，随机抽取 4480 段作为训练集，1120 段作为测试集通过

召回率[53]、准确率[54]和 F1 值比较本方法与现有基准方法的性能。

$$\text{Recall} = \frac{\text{正确识别出的实体数量}}{\text{识别出的总实体数量}} \tag{3-1}$$

$$\text{Precision} = \frac{\text{正确识别出的实体数量}}{\text{人工标注的总实体数量}} \tag{3-2}$$

$$\text{F1} = \frac{2\text{Recall Precision}}{\text{Recall+Precision}} \tag{3-3}$$

在实验性的研究过程中，我们运用了 Dic 算法以及 LSTM 模型，首先根据词性、词汇库和指令词来展开特征识别，然后采用条件随机场技术来确定所被命名的目标。具体各模型表现如表 3-5。

表 3-5 各模型表现

Tab.3-5 Performance of each model

模型	Precision	Recall	F1
Dic	0.853	0.730	0.746
Dic-Ctr	0.834	0.766	0.806
LSTM	0.851	0.820	0.835

研究成果显示，通过使用字典和条件随机场技术，能够更有效地识别新能源汽车命名实体，这也印证了这篇文章中提出模型的可靠性。在各种不同的实体下，该模型展示的性能如表 3-6。

表 3-6 各类实体下的 F1 值

Tab.3-6 F1 values under various entities

实体种类	Dic	LSTM	Dic-Ctr
电池质量	0.756	0.802	0.903
车辆性能	0.748	0.793	0.852
品牌与售后	0.722	0.835	0.826
经济考量	0.693	0.806	0.804
个人需求	0.682	0.778	0.812

3.4 关系分类

3.4.1 基于 BiLSTM 的关系分类

电池质量、车辆性能、品牌与售后与经济考量、个人需求之间的关系可以分为满足与不满足，电池质量、车辆性能与品牌与售后之间的关系为直接影响与间接影响。

表 3-7 实体关系分类案例

Tab.3-7 Example of Entity Relationship Classification

例句	关系
网约车司机应该选择续航能力强的新能源汽车	续航里程强-满足-职业个人需求
经济预算低的不适合选择第一梯队品牌的车	第一梯队品牌车-不满足-经济预算低
品牌对电池质量有一定影响	品牌售后-间接影响-电池质量

表 3-7 展示了一些关系抽取的例子。例如可以从“网约车司机应该选择续航能力强的新能源汽车”中提取出续航里程强和职业个人需求之间为满足关系。从“经济预算低的不适合选择第一梯队品牌的车”中可以提取出第一梯队品牌车和经济预算低之间的不满足关系。从“品牌对电池质量有一定影响”中可以提取出品牌售后和电池质量的间接影响关系。本研究先借助 TF-IDF[55]算法将 3.3 节所得到的句子进行分词处理。

$$= \frac{\text{词 在文本中出现的次数}}{\text{文本分词后的总次数}} \tag{3-4}$$

$$= \log\left(\frac{\text{文本分词总数}}{\text{包含词 的文本数}+1}\right) \tag{3-5}$$

$$= \tag{3-6}$$

表示词 i 在文档中的频率，　　是衡量词 i 在文档集合中分布的方法。选取 SVM 算法、K 近邻、贝叶斯算法[56]在进行满足或不满足关系的分类实验时，BiLSTM 被选为主要的分类器。BiLSTM 接受的是一个随机词向量作为输入，而其他分类器的输入都是　　，其输出关系是“满足”和“不满足”两种可能性，最后可能性大的类别被确定为实体之间的关系。

3.5 知识存储

知识图谱的存储方式可以被分类为 RDF RDFS/OWL 方式以及图形数据库方式。RDF 的存储方式采用了(head，relation，tail)三元组的形式，在此模式中，每一个三元组都被视为事实存在。三元组主要集中在探讨实体之间的相互关联性，而并不能区别不同实体的具体分类。在现有的基础上，RDFS 进一步明确了类型、关联性和特征。相较于 RDFS，OWL 不仅扩充了术语库，更具备优越的语义阐述能力。图形数据库主要以属性图为核心，其中图中的节点与边皆可携载属性信息。RDF 供应标准化的推论指导，然而，多数图形数据库并未配备标准化的推论引擎。RDF 类存储结构遵循 W3C 规范，因此特别适于数据的传播与交流，与此相对，图数据库并非基于标准化的存储架

构。RDF 广泛应用于学界，而图数据库则主要在产业领域得到应用。如表 3-8 实体统计与表 3-9 关系统计，本文确定了 61282 个三元组、47885 个关系、8693 个实体。

表 3-8 实体统计

Tab.3-8 Entity statistics

实体	数量
电池质量	1665
车辆性能	6420
品牌与售后	268
经济考量	211
个人需求	129

表 3-9 关系统计

Tab.3-9 Relationship statistics

实体	数量
直接影响	1250
间接影响	2266
满足	17268
不满足	8896

3.6 导入知识图谱可视化

NoSQL 数据库是一种基于图论的数据库，它将数据和它们之间的关系存储在节点和边上，这些节点“关系”(Relation)和“节点”(Nodes)分别代表了现实世界中的各种实体以及实体间的关系。众多的图数据库中，Neo4i 是频繁使用的图形数据库，可以将实体之间的相互关系直观地展示出来,它能够清晰地展示实体之间的关联，而且采用 Cypher 查询语言，可以有效地检索和管理图形数据库。从 2013 年开始，DB-Engines 每月都会对图数据库管理系统进行全面的评估，以确保其优秀表现。

本文采用图数据库 Neo4j 通过 load csv 导入数据，用于 csv 文件的多批次数据导入选择 Cypher CREATE 语句和 load csv 的方式来构建初始的知识库。分别将节点、关系和属性信息批量的导入图数据库。导入 csv 的方式速度较快方便灵活且如果需要修改相关实体只需修改采集到的相关数据，然后在 neo4j 浏览窗口执行 load csv 相关文件命令即可，如图 3.4 展示了知识图谱可

视化。

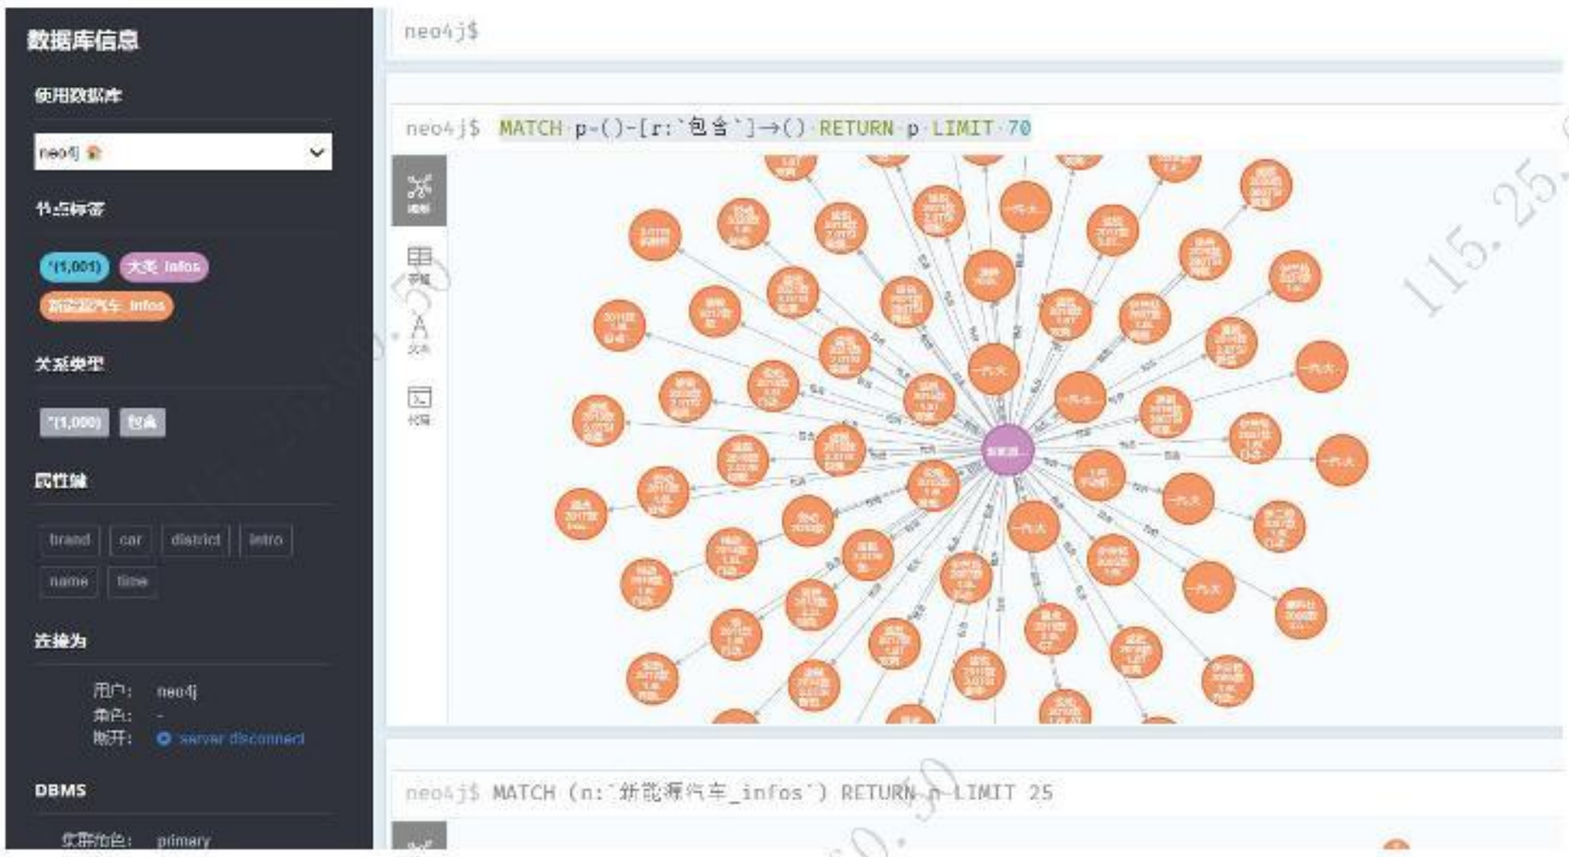


图 3.4 知识图谱可视化

Fig.3.4 Visualization of Knowledge Graph

3.7 本章小结

本章介绍了新能源汽车知识图谱的构建过程。首先说明了数据获取方式，接着深入描述了相关的实体及其之间的联系，使用 Dic-CTR 模型来识别文字数据中的命名实体。最后介绍了图数据 Neo4j，对新能源汽车领域知识图谱进行了存储，完成了新能源汽车领域知识图谱的构建和可视化。

4 基于知识图谱的新能源汽车语义表示

为了把新能源汽车知识图谱体系更好地推向给市场，首先需要对知识图谱进行深入和全面的向量化分析与展示。在知识谱图谱向量的描述方法中，传统的度量方法过于偏重于符号和逻辑，这使得对实体之间的语义关联进行精确评估变得困难。而知识图谱的嵌入是通过分布式表示法来实现的，其核心是将实体和关系转化为高密度、精确且维度较低的向量。该方法的目的是在向量上保留知识图谱结构与语义信息，从而突破了传统向量化的限制。在知识图谱的嵌入模型中，像 TransR、TransE 和 TransH[57,58]这样以翻译为中心的模型得到了广泛的应用。

4.1 传统的知识图谱嵌入模型

知识图谱含有尾实体 t、头实体 h 以及关系 r，其中嵌入技术实现了实体与关系向低维数值表示的转换，从而有效地度量了实体之间语义相关性，其本质目的是在于掌握一种将关联转换为线性实体序列以实现翻译的技术内嵌方法。在各类模型中，Bordes 等人所研发的 TransE 模型最为精炼且最具代表性。这个模型提出，一个准确的三元组必须符合公式（4-1）的要求

$$\| \quad + \quad \| \approx \tag{4-1}$$

在 L1 或 L2 范数的限制条件下，得分函数的定义可以参考公式（4-2）。

$$(h,t)= \| \quad + \quad - \quad \|_{L1/L2} \tag{4-2}$$

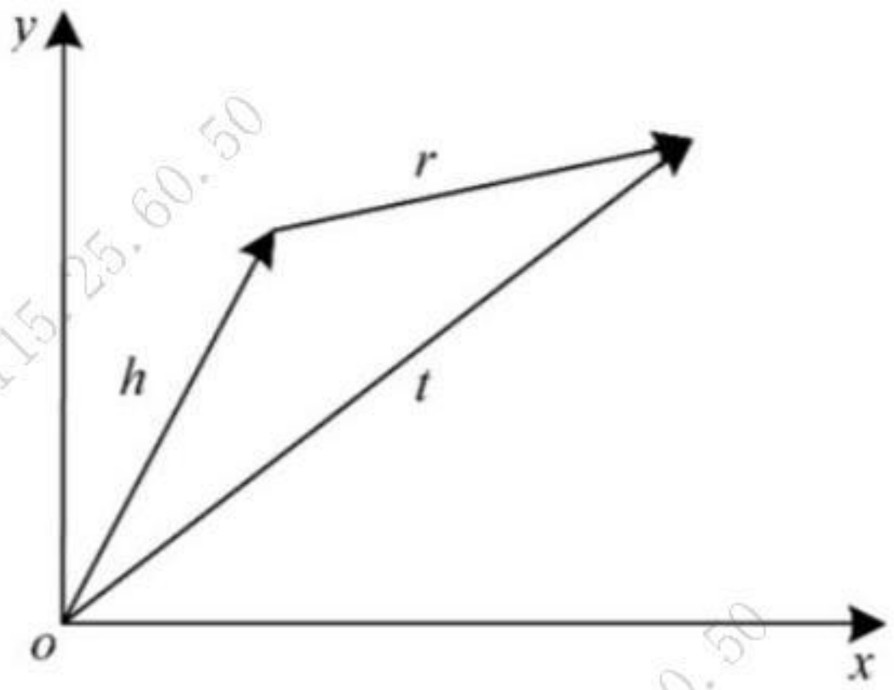


图 4.1 TranE 模型

Fig.4.1 TranE model

如图 4.1 展示的那样，尽管 TransE 模型既简洁又高效，但它主要适用于处理 1 对 1 的类型关系，并在处理 1 对多或多对多的关系时存在明显的不足。

如果一辆新能源汽车能够满足多个不同的需求，而其中一个需求又能匹配多种类型的车辆，那么使用 TransE 模型可能会导致相似度的计算出现偏差。

4.2 基于 TransHR 的知识图谱嵌入模型

对于各三元组*(h,r,t)*，TransHR 在 k 维空间中，实体向量 h 和 t 分别代表头尾实体，d 维空间中的关系向量 r 表示它们间的联系，k 和 d 可能不同。假设实体对有 n 种关系，第 i 种关系的投影向量　是关系向量在实体空间的投影，每个关系向量对应一个转移矩阵。

$$(,) = \quad , \quad = 1,2..... \tag{4-3}$$

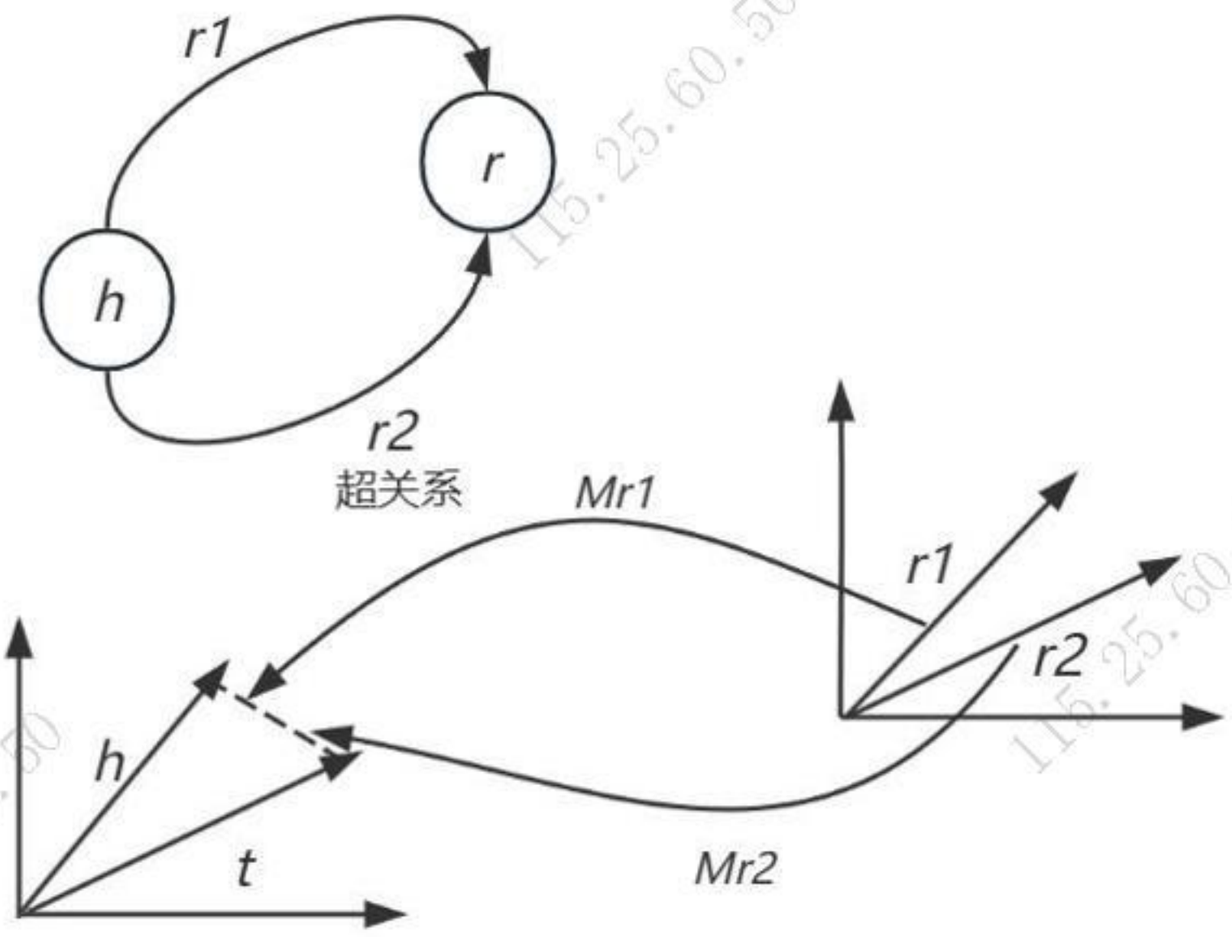


图 4.2 TransHR 模型

Fig.4.2 TranHR model

故各具体 d 维向量　将其对应的 r_i 转换成 k 维向量 $r_{(h,t)}$，可观察到头部实体向量 h 和尾部实体向量 t 之间的平移关系，相关损失函数如下:

$$(h,t) = \| \quad + \ (\ , \ ) - \ \|_2^2 \tag{4-4}$$

(h,t)则表示　+ (,)、t 间的差别。

TransHR 模型能够标识各个实体，且能够描绘实体之间复杂多重的关联，有着强大描述能力。通过利用新能源汽车知识图谱间复杂多维的关系，可更为精确和合理地计算出新能源汽车相似度。在两个新能源汽车间，存在可能共享同一电池资源或基于相似经济效益考量的关联关系。若多辆新能源汽车关联更多，则相似度在相关车辆之间也会提高。

4.3 模型训练过程

为训练得分函数 *(h,t)*参数，以最小化区间为训练目标的损失函数公式如下：

$$L= \quad (\ ,\ ) \quad (\ ',\ ,\ ') \quad , \quad (0, \quad (h,t)+ \quad - \quad (\ ',\ ')) \tag{4-5}$$

max(0,*x*)取 0 与 *x* 间最大值。 >0 为分隔正负三元组的超参数，通常为 1。实体和其关联在标准化过程中的嵌入，以及间距 对目标的具体规定，有助于防止权重出现崩溃或偏移。损失函数比分数多的负三元组倾向于比分数少的正三元组。Adam 优化器优化整个学习流程。若 *(h,t)*> (', ')- ，因此，将采用 Adam 算法来实现目标函数的最小化。

4.4 实验与分析

该实验任务涵盖了实体链路预警和三元组的分类方法。关于实体链路的预测，是针对三元组而进行的，以准确预测缺少的头实体 *h* 或者尾实体 *t* 的情况。对三元组的分类目的在于验证三元组的准确性。

4.4.1 数据集

在本次实验中，我们所使用的数据集是根据本项研究所设计的知识图谱，涵盖 61282 个三元组、47885 个关系、15669 个实体、依据 8:2 的比例来确定训练数据集和验证。

4.4.2 实体链接预测

实体链接的预测旨在完整地补全头实体和尾实体的缺失，并创造出合适的三元组*(h,r,t)*。借助于分数函数可以将三元组测试分数排序并依此获得最佳选择。为了评估该模型，选取 MeanRank 平均排名与 Hits@10 为两大评估标准。

MeanRank:通过多轮测试，得出每次准确结果出现的概率位置。

Hits@10:在开始进行的十个中进行估测，得出正确实体能够出现的机率。

移除测试三元组*(h,r,t)*中的 *h*、*t*，同时在知识图谱内进行调整以来达到各个实体适配的序列，并以此为基础，来生成了一系列可能存在损害准确性的三元组备选方案。通过根据评分能力计算损坏三元组分数，按降序将分数排序，最终确定 MeanRank 与 Hits@10 这两个预期的数值。鉴于新能源汽车的知识图谱中可能含有误导性的三元组，这些误导性的信息有可能对预测结果

产生负面影响，因此，本研究决定将这些被预先排除的错误三元组的测试集命名为“Filter”，那些没有经过筛选并包含所有原始三元组的测试集仍然被称作“Raw”。在这两种配置之中，MeanRank 展示的相对较低的数值以及 Hits@10 展现出的相对较高数值则表现出这两种模式有更为优秀的实体连接性能。

4.4.3 三元组分类

鉴于新能源汽车知识的图谱仅展示了正三元组结构，分类评定因此需要使用负标签，所以依据现有的学术文献来建构出一个负三元组合。针对每一个黄金实体，都会存在替换合适序列来生成为负实体的情况，通过设置边界值 [59]。若测试集中的特定案例在差异性分数上得分不足，没有超过边界值 ，则这个案例会被视为正，反之则被视为负。

4.4.4 超参数设置

构建此模型选择了 Pytorch 和 Adam 作为优化策略，并采用网格方式进行分析，以确定最合适的超额参数设置。我们可以观察到网格搜索的设置：学习率 的值设于（0.002，0.006，0.02)，间距 γ 是位于(0.2，0.6，2，3)，而嵌入维度 d 的值则是设定在(20，40，60，80，100)，L1 或 L2 范数。对新能源汽车领域的知识图谱数据集实施了五百轮的训练迭代，经过多轮的实验研究，确定了最佳的参数配置为 =2， =0.02，d=60。

4.4.5 实验结果与分析

正如在表 4-1 中展现的链接预测结果，文中介绍的计算方式在评估新能源知识图表的总体性能时，明显地超越了其他多种基线方法。在 Hits@10 这一平台上的研究结果呈现出 85.1%的准确率，与 TransH 技术相比，准确性上升了 3.2%，与 TransE 技术进行了对照后，准确度也提高了 4.6%。此项研究结果表明，在处理超级关系的数据时，采用多种空间的建模方法已经超过了单纯基于单一空间的建模技术。

表 4-1 预测任务结果

Tab.4-1 Predict task results

模型	MeanRank		Hits@10	
	Filter	Raw	Filter	Raw
TransHR	37	39	85.1	74.2
CTransR	45	46	83.2	73.6
TransH	47	51	81.9	72.5

表 4-1 续

Tab.4-1 Cont

模型	MeanRank		Hits@10	
	Filter	Raw	Filter	Raw
TransR	41	44	82.5	71.8
TransE	49	56	80.5	70.6

表 4-2 呈现了三元组分类的评价数据，从中可以观察到 TransHR 在性能上超越了其他所有技术，相比 TransE，其分类精度提升了 11 个百分点。经由双组实验数据检验，TransHR 在链路预估与三元组分类作业中均展现出胜过基准算法的性能，此结果更强化了 TransHR 于新能源汽车领域知识图谱嵌入应用之效用。

表 4-2 三元组分类结果

Tab.4-2 Triple classification results

模型	Classification (%)
CTransR	74.8
TransR	81.6
TransE	71.5
TransH	75.3
TransHR	82.5

4.5 本章小结

在本章节中，深入探讨并应用了 TransHR 模型，旨在对其在新能源汽车知识图谱领域的知识表示学习能力进行详细分析与实践。借助于将车辆间语义信息投射到低维向量空间的技术手段，能够有效地在其语义相似度的度量上进行计算。在新能源汽车知识地图中存在的实体间复杂关系上，传统的知识呈现框架往往表现出其局限性，本研究采纳了增强型的超关系学习模型 TransHR，旨在提升知识表示的准确性和有效性。通过实证研究，在链接预测和三元组分类的任务上，TransHR 模型表现出明显的优势，比所有基线模型都获得更好的结果。

5 基于知识图谱与协同过滤的推荐算法

5.1 算法介绍

本文设计并建立了新能源汽车的知识图谱，通过将图谱中的汽车元素转化为向量形式，计算不同汽车之间的语义相似度。此过程不仅考量了基于用户行为的相似度指标，还综合考虑了外部评分因素和内在知识价值，以形成最终的相似度评估。基于这一评估结果，系统能够生成个性化的推荐列表，从而实现对外部数据评价与深度知识理解的有机结合。本研究建议的算法成功地克服了协同过滤（CF）方法忽视内在数据这一局限性，显著提升了针对新能源汽车的推荐系统的精确度和适用性。

采用将知识图谱与协同过滤技术相结合[60]的推荐算法 TranHR-CF。首先构建了新能源汽车知识图谱，随后引入并应用了先进的 TransHR 模型，成功生成了与新能源汽车领域紧密相关的低维向量表示。进一步地，通过精确计算这些向量之间的语义相似性度量，能够有效地识别和定义在概念层面上的紧密关联或近邻关系，依据预设的融合算法，我们综合考量了语义一致性与外部评估指标，以此为基础计算出协同过滤的相关性系数，并在此基础上进行了数据的深度整合。最终，通过这一综合性的相似度指标，成功构建了精准且具有针对性的推荐列表。

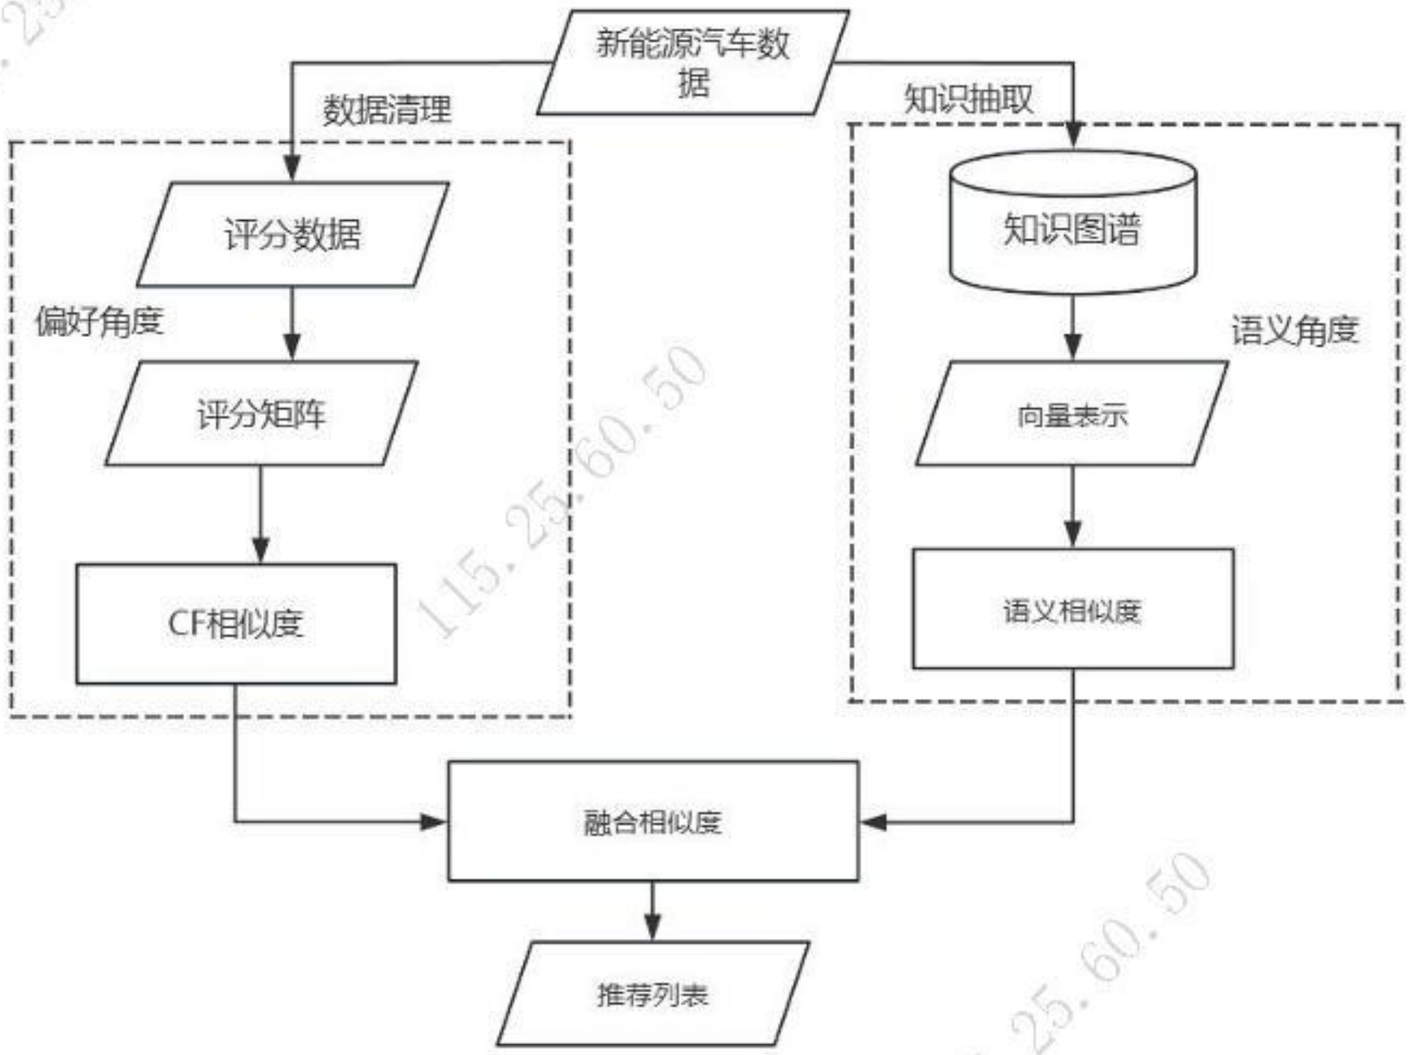


图 5.1 TransHR-CF 算法流程图

Fig.5.1 TransHR CF algorithm flowchart

5.1.1 基于用户-新能源汽车评分的汽车相似度

协同过滤算法是公认为最受欢迎且应用领域最为广泛的推荐系统策略之一。该技术并未直接侧重于推荐特定内容，其焦点更多在于分析用户对各类项目给出的评价。其核心理论基础在于假设用户倾向于偏好与其已有兴趣或行为相类似的新项目。设 $I=(I_1,I_2,\cdots,I_n)$为所有车辆的集合，其个数为 n，现设 $U=(U_1,U_2,\cdots,U_m)$为所有用户的集合，其个数为 m。

$$\times=\begin{bmatrix} 11 & 12\cdots & 1 \\ 21 & 22\cdots & 2 \\ \cdot & \cdot\cdot & \cdot \\ 1 & 2 & \end{bmatrix} \tag{5-1}$$

在这之中，s_{ij}代表了用户 i 对车辆 j 的评价，而这个评分的高低则反映了他们的喜好水平。

文中把用户给某款车打分看作 m 维，而用户给该车 i 打分向量是 $I_i=(s_{1i},s_{2i},\cdots,s_{mi})$，则车辆 I_i 和车辆 I_j 之间的余弦相似度为：

$$(i,j)=\cos(\ ,\ )=\frac{\cdot}{\|\ \|\cdot\|\ \|}=\frac{\sum_{=1}\ \times}{\sqrt{\sum_{=1}(\ ^2)}\times\sqrt{\sum_{=1}(\ ^2)}} \tag{5-2}$$

(i,j)的值介于 0 到 1 之间，值越高，表示车辆 i 和车辆 j 越相似。为了提高推荐质量，使用余弦相似度前需要进行标准化处理，即从全局评分中减去平均评分 s_u。也可以考虑调整余弦相似度的计算方式：

$$(i,j)=\frac{\sum_{=1}(\ \ -\bar{\ })\times(\ \ -\bar{\ })}{\sqrt{\sum_{=1}(\ ^2-\bar{\ })}\times\sqrt{\sum_{=1}(\ ^2-\bar{\ })}} \tag{5-3}$$

5.1.2 基于知识图谱的新能源汽车语义相似度

本研究用欧氏距离衡量新能源汽车 i 和 j 的相似度，并将具体的计算手法描述在公式(5-4)中：

$$(i,j)=1-\frac{\|\ -\ \|_2^2}{\|\ -\ \|_2^2+1}=\frac{1}{\|\ -\ \|_2^2+1} \tag{5-4}$$

在存在的情况下，两个实体向量之间的关系向量并非唯一，其联系形式既包括直接关联也涵盖间接关联。基于车辆i和j之间存在明显的语义相似性，远超其通过其他车辆形成的间接联系，在此研究中，我们明确将其量化为一个评价指标：

$$(i,j)=\frac{[\ \ (\ ,\ )+\ ^2(\ ,\ )]}{\|\ -\ \|_2^2+1} \tag{5-5}$$

取值范围(0,1)，$N(I_i,I_j)$、$M(I_i,I_j)$为车辆 i 与 j 之间直接关系数和间接关系

数。

利用公式（5-5）进行语义相似度计算可获得车辆相似度矩阵见表 5-1。

表 5-1 车辆相似性矩阵

Tab.5-1 Vehicle similarity matrix

车辆	车辆 1	车辆 2	车辆 j	...	车辆 n
车辆 1	1	...	a_{1j}	...	a_{1n}
车辆 2	...	1	...	...	a_{2n}
车辆 i	a_{i1}	...	...	...	a_{in}
...	...	...	...	...	...
车辆 n	a_{n1}	...	a_{nj}	...	1

5.1.3 两种相似度融合

在知识图谱嵌入算法中，首先计算车辆之间的语义相似性　，并与协同过滤算法计算出的　结合，之后通过线性加权的方法进行数据融合，具体融入方式如所给公式展示：

(,) = · (,)+(1-) (,) (5-6)

其中 为权重系数，且 0< <1。

5.1.4 推荐列表生成

在本文中，采用 来描述用户 u 对车辆 i 的预期评分，而预测评分的具体计算方法如下所示:

$$= \frac{( )\cap (,) \quad (,)\times}{( )\cap (,) \quad (,)} \tag{5-7}$$

其中 (,)为与车辆 i 最为相似 k 个车辆， ( ) ∩ (,)表示两个车辆集合的交集， ( )表示用户 u 已经评分的车辆。 是使用者 u 给汽车 j 的评分。

(,)是指物品 i 与 j 的融合相似度。

5.2 算法实验

5.2.1 数据集

将深入剖析这两大关键数据集的内容与特性，图谱源于本研究所构建的新能源车的知识库。涉及到的组织中，该体系内包括 15669 个具体的实体、47385 个相互关联的关系以及 61282 个三元组合形式，有关用户行为信息是

从“大搜车智云”和“易车”获取，并通过收集的用户数据、存储的新能源汽车信息以及用户的搜索纪录来进行数据构建。最终，我们整理了 3698 条关于用户的有效记录,92348 条记录了用户对新能源汽车的评价，这些评价涵盖了多个方面[0，5]。目前已经按照时间序列把评分数据集合进行了有序排列，而最初的 80%被挑选为训练数据集，紧随其后的 20%被选为测试数据集。

5.2.2 实验标准

为了与传统方法做对照，我们选取了 Recall（召回率）与 AUC 这两种评价准则来对不同的算法表现进行鉴定。下面明确列出了两项评估标准的具体定义:

$$\text{Recall} = \frac{\text{正确推荐项目数}}{\text{总喜欢的项目总数}} \tag{5-8}$$

AUC：ROC 曲线和其交叉坐标轴所组成的表面区域面积在[0.5，1]之间。当其值接近 1 时，推荐给用户的结果便会更为准确。

5.2.3 实验结果及分析

(1)融合权重因子确定

TransHR-CF 算法在协同过滤和知识图谱相似性间通过调节融合权重因子α进行比例融合来调节相似度，知识图谱嵌入维度 100，近邻数 k 为 50，同时 的值域被定在了[0，1]以内。在实验操作里， 值从 0 上升至 1，每次递增 0.1，这涉及到 11 个不同的实验分组。每个组别都要重复 10 次实验，并对这些实验进行平均处理。至于最终的实验数据，请参考图 5.2 进行展示。

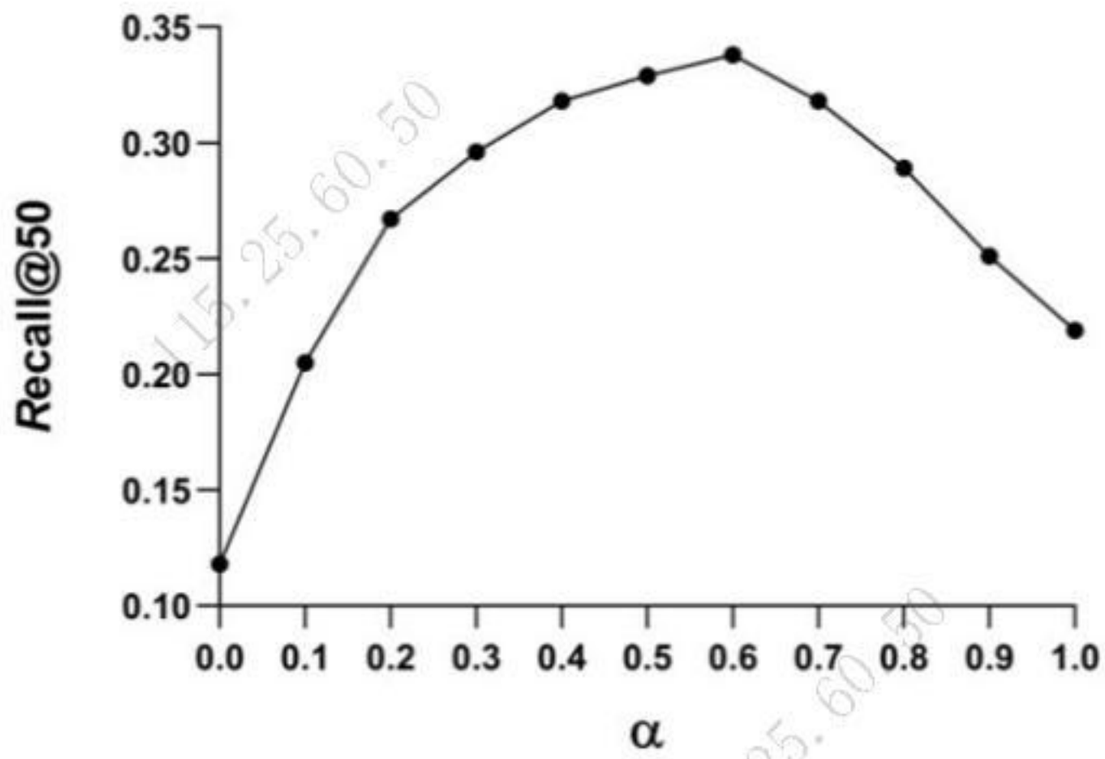


图 5.2 不同权重下的实验结果

Fig.5.2 Experimental results under different weights

从图 5.3 可以看出，随着融合因子的逐步增加，TransHR-CF 算法的召回

效率显著提高，特别是在 =0.6 的情况下效果最佳，但当 >06 时，召回率开始下降，因此本研究选择了 0.6 作为融合因子α。

(2)嵌入维度确定

当知识图谱融入低维向量空间内时，各种不同的嵌入层次可能会产生各异的推荐结果。在试验设计阶段，我们选定了几个关键的融合元素：融合因子α为 0.6，相邻数量为 50，并且维度被分别设置为 20、40、60、80 和 100。依据图 5-3 所呈现的实验数据，提升嵌入维度能够为推荐系统引入更为丰富且具有价值的数据，进而显著增强推荐效果。然而，一旦维度攀升至逾六十之时，过拟合问题便可能侵袭，从而引发推荐效能的下滑。鉴于在实验过程中发现，将知识图谱的嵌入维度设定为 60 能实现最佳推荐性能，基于此发现，本研究决定采用嵌入维度为 60 的知识图谱作为核心工具。

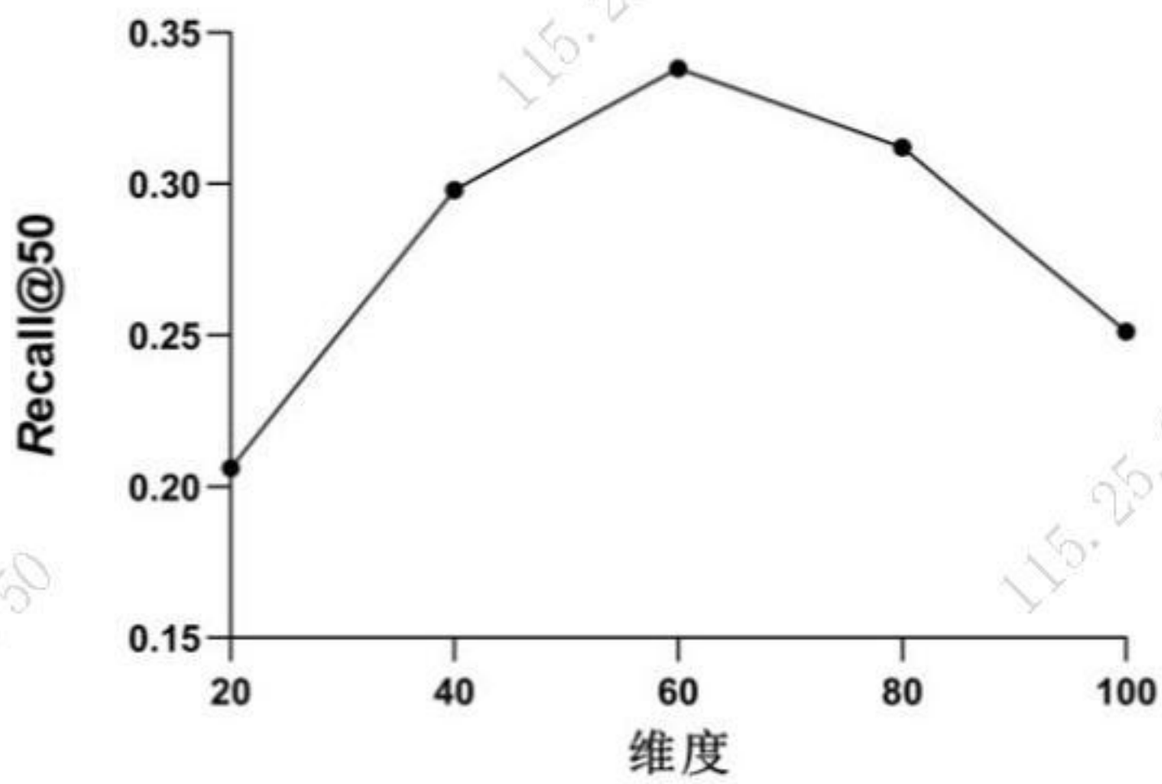


图 5.3 不同嵌入维度下的 Recall

Fig.5.3 Recall under different embedding dimensions

(3)算法对比

为了验证本研究提出的 TransHR-CF 算法的效用，我们进行了一系列的对比实验，将其与几个基准算法进行了深入的分析。这些基准算法涵盖 RippleNet、TransE-CF、NCF。以下是对这些基准算法的详尽说明:

CF:传统的协同过滤技术依赖于相似性矩阵来工作，并借助与自己相似用户及其关联物品的打分数据来构建预测倾向。

TransE-CF:此算法利用 TransE 提供的语义嵌入技术，旨在提高传统协同过滤方法的执行效率。

RippleNet:此算法综合了正则化与路径技术，通过在每一条以用户为中心的路线增加新的项目，进而增强了用户的表示体验。

NCF:联合过滤方法基于神经网络，融合了矩阵分解和多重感知机技术。

DeepFM:融合“wide&deep”的观点到因子分解机的设计中，使用“wide”阶段对一级和二级特征的互动进行建模，同时“deep”部分用于高级特征的互动模型构建。

知识图谱被确定为一个嵌入维度，其数值范围定为 0.6，并选用了 2 10 50 100 作为其中的近邻数字。每组试验都经历了十轮循环，在这些十轮的实验活动中，都获得了相应结果的平均数值。表格 5-2 和图表 5.4 展示了在召回率和 AUC 评价准则方面，不同算法显示出了各自的性能特点。实验数据显示，当近邻数 k 逐步上升时，各种算法的召回率也随之增长。总体而言，与基准算法相比，本研究提出的基于 TransHR 模型的新能源汽车推荐算法在召回率和 AUC 两个关键指标上都表现得更为出色，这证明了本研究的算法能更好地满足用户的推荐需求。

表 5-2 不同 k 值下的回召率

Tab.5-2 Recall rate under different k values

R@50	R@10	R@100	R@2	算法
0.348	0.170	0.492	0.055	TransHR-CF
0.336	0.164	0.430	0.048	RippleNet
0.312	0.156	0.416	0.041	NCF
0.265	0.111	0.363	0.033	TransE-CF
0.427	0.159	0.324	0.043	DeepFM
0.128	0.061	0.186	0.024	CF

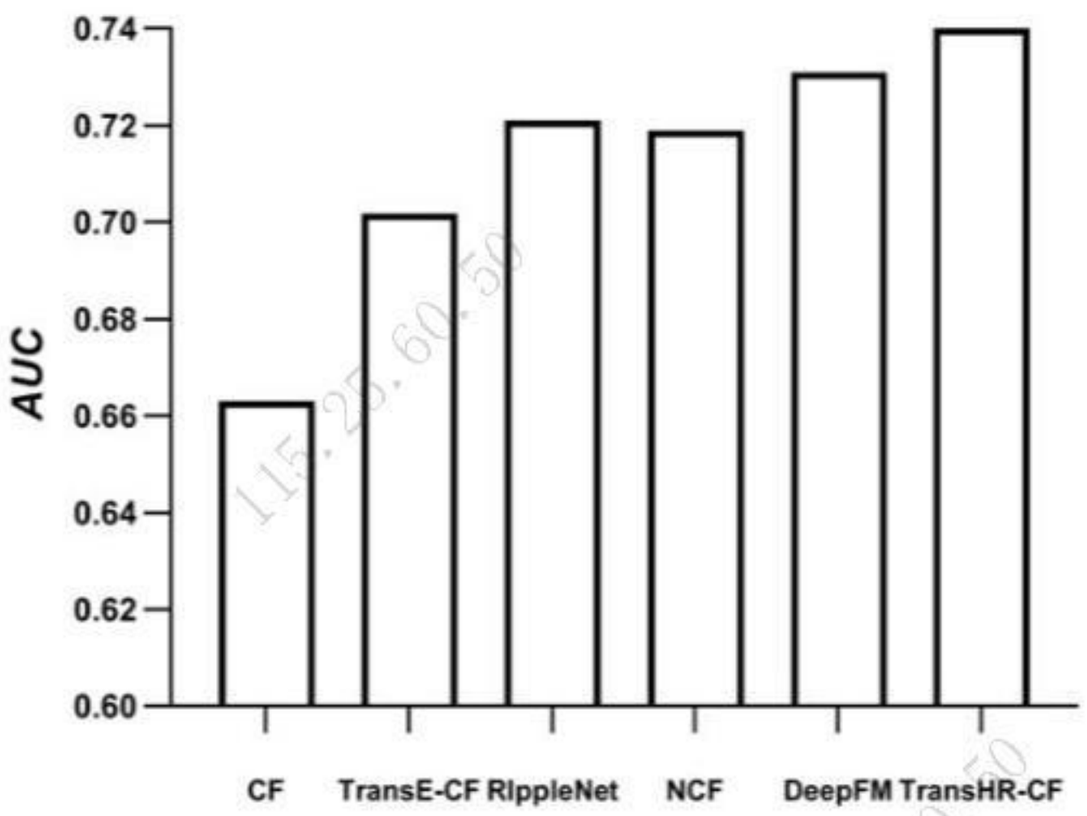


图 5.4 AUC 值

Fig.5.4 AUC value

5.3 本章小结

传统协同过滤方法主要依据用户对车辆的评分进行决策，忽视了车辆间的语义关联，这常常导致数据稀疏性和冷启动难题。鉴于此现象的出现，本章节采用了知识图谱与协同过滤技术相结合的推荐算法，通过协同过滤技术，我们能够精准地计算出基于用户反馈的车辆匹配程度。通过将车辆相关数据投射到低维向量空间，借助知识图谱嵌入模型，进而量化并评估不同车辆间的语义相似性。采用融合相似度的方法，综合考量两种不同的相似度指标，以此为基础构建用户对车辆的预测评分体系。基于此评分，系统能够自动生成个性化的推荐列表，为用户提供更精准、符合其需求的车辆选择建议。通过实证研究发现，本文所采用的推荐技术，即结合知识图谱与协同过滤的TransHR-CF 方法，在性能评估指标上显著超越了对照算法，这有力地证实了该算法的优越性和实用性。

6 新能源汽车推荐系统的设计与实现

6.1 系统分析

6.1.1 系统可行性分析

在系统建设阶段，可行性评估系启动系统建设之先决要素，因其能全面审视在规划与构建进程中可能遭遇的技术挑战或财务难题，从而确保系统建设得以成功开发。

考虑到技术的实施性，通过 Vue 框架在系统的前端进行了开发，这 Vue 是前端 JavaScript 领域的热门框架，专为搭建用户界面所设计。该平台实施了双向的数据绑定方式。譬如，数据发生改变的情况下，相应的 DOM 元素会自行进行升级；同样，用户在表单等元素中输入内容，相关的数据也会随之改变。Vue 框架可以把页面拆分成一个个可复用的组件。像一个网页的导航栏、侧边栏、内容展示区等都能作为单独的组件开发，组件内部有自己的逻辑和样式，方便维护和复用。并且 Vue 会先在内存中构建一个虚拟 DOM 树，通过比较新旧虚拟 DOM 树的差异，以最优化的方式更新真实 DOM，提高性能，减少不必要的 DOM 操作。并且开发速度快。后端开发采用 Diango 框架作为基础，这个 Diango 框架内部综合了 Web 开发的多种功能，并利用 Python 语言中简明的语法规则与丰富的库资源，能够迅速地完成整个系统的开发过程。

在经济可行性层面，开发新能源推荐系统的硬件和软件成本相对较低。服务器、存储设备等硬件可以根据需求逐步扩展，降低初期投资风险。另外我国政府对新能源的发展给予了大力支持，因此，新能源汽车吸引了大量的用户，并在市场上有着广泛的应用潜力。由于其低成本、快速的上线速度和远低于预期收益的特点，这使得它成为一个非常适合开发的产品。

6.1.2 系统需求分析

本文主要从两个方面进行需求分析，一是从用户功能需求，二是系统功能需求。

用户功能需求：用户功能需求主要包括用户登录、用户检索汽车信息和用户对汽车评分评论收藏等。用户登录主页面之后，将会通过算法计算出与用户相似度高的用户的历史行为，为其生成相应的推荐列表，用户可点击推

荐列表的汽车信息进行车辆信息的查看；用户还可通过登录主页后按照自己需要的汽车类型或者标签，亦或者根据评分、评论、收藏来进行检索。在此过程中用户可对汽车进行评论、评分或者收藏，与此同时用户的历史行为也会被记录在后台。

系统功能需求：系统功能需求便是后台管理相关功能，管理员登录后台后可查看并对用户产生的历史行为进行管理，以及管理用户及新能源汽车信息等。

6.2 系统设计

6.2.1 系统框架设计

如图 6.1 展示的新能源汽车推荐系统架构，其浏览器页面能够接收用户输入的请求上下文进行 request，随后发送给内部服务器以接收数据的请求，并通过计算逻辑来检索和处理数据库中的信息。

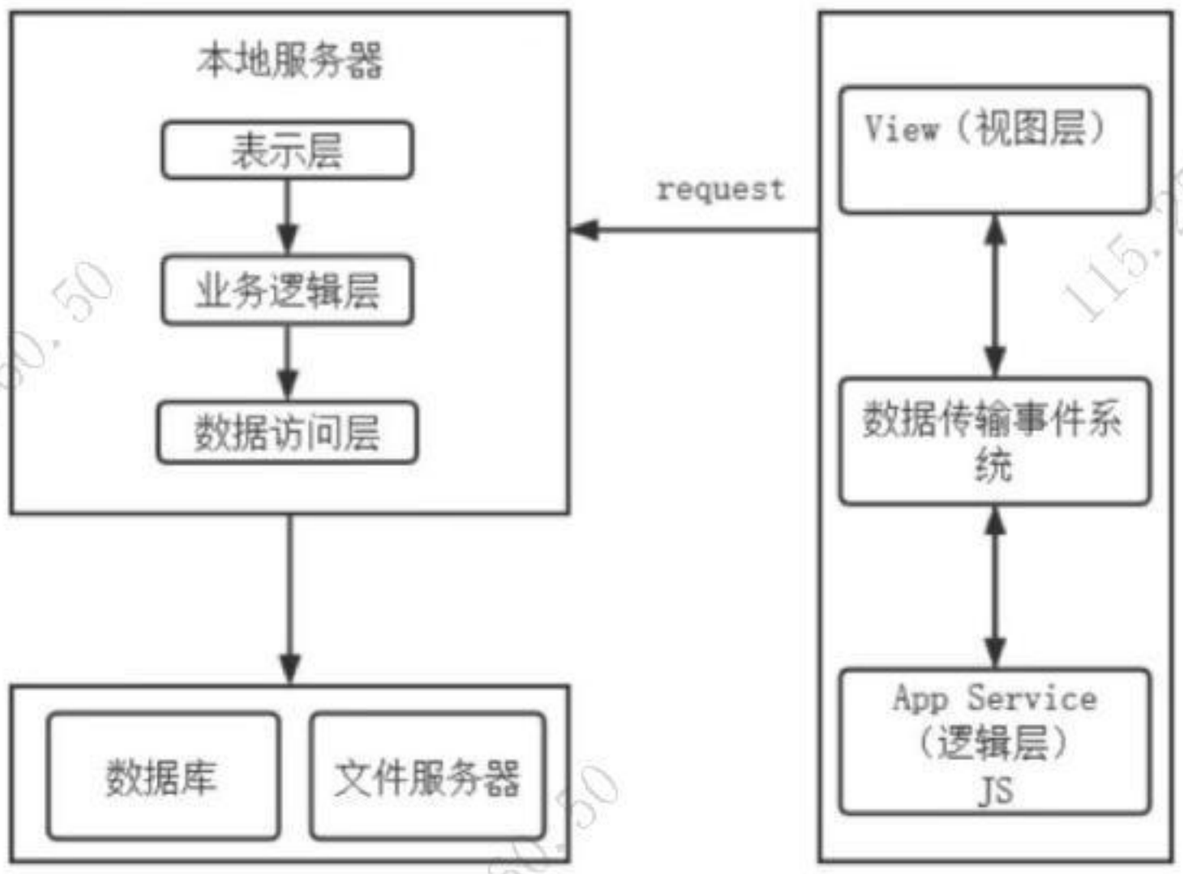


图 6.1 系统总体框架图

Fig.6.1 Overall System Framework Diagram

6.2.2 系统功能设计

基于 6.1.2 小节对新能源汽车推荐系统进行需求分析后，本系统的功能设计如图 6.2 所示。

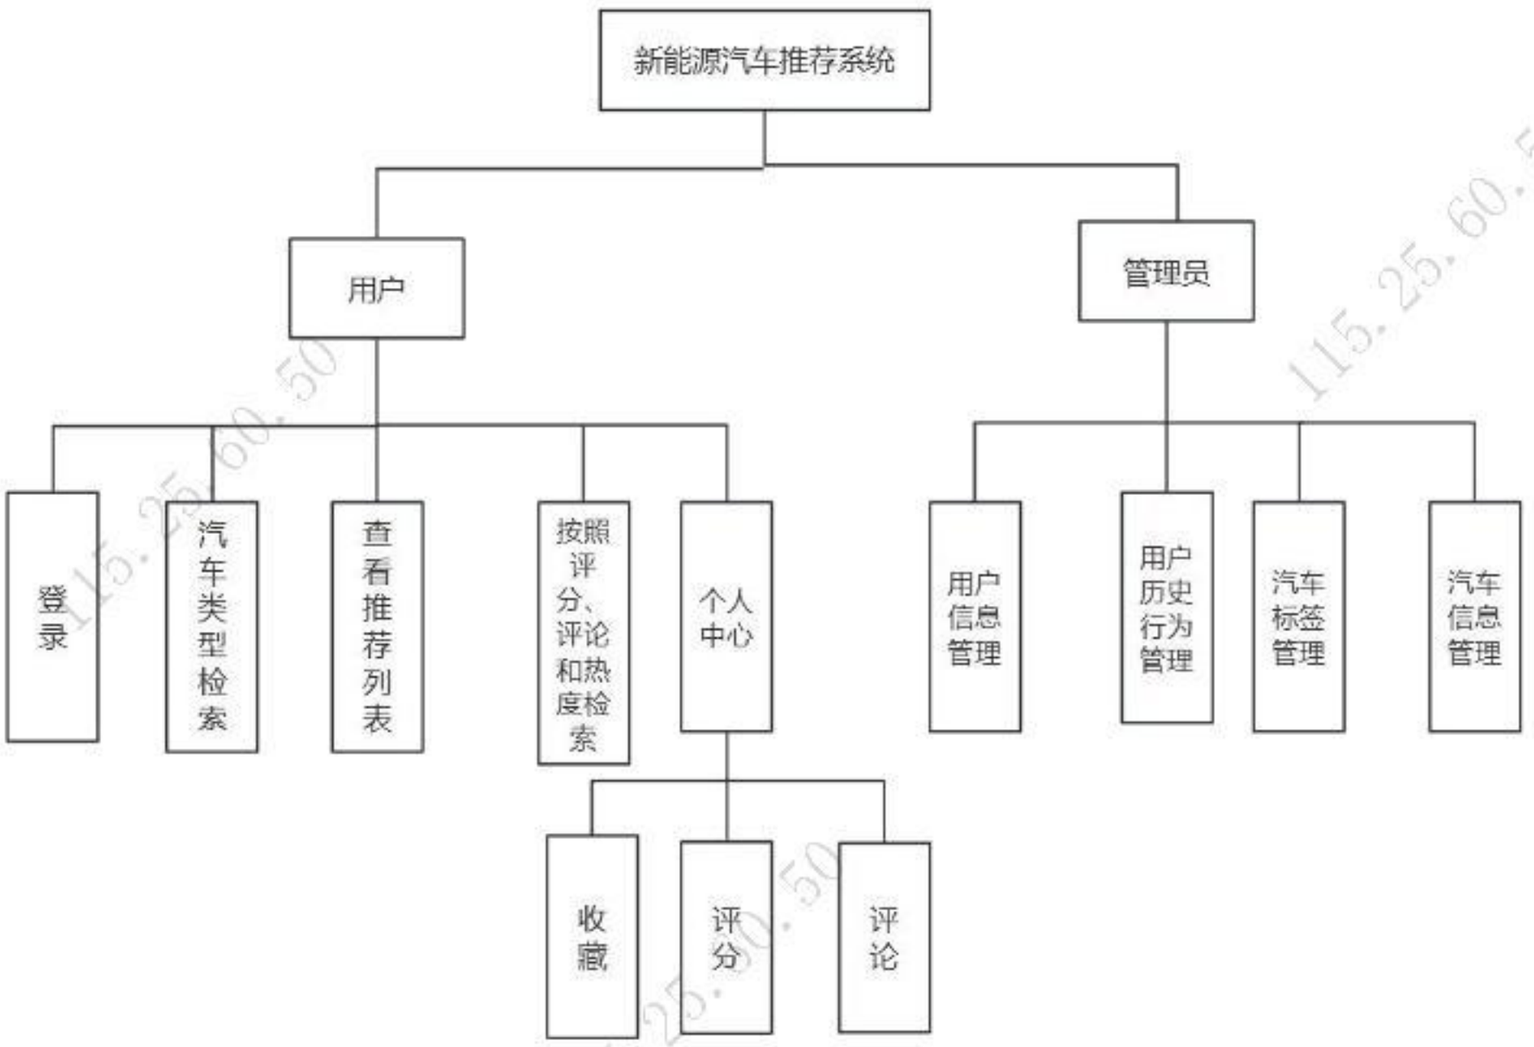


图 6.2 系统功能设计图

Fig.6.2 System Function Design Diagram

6.3 系统实现

依托于先前章节中所开展的理论工作，包括准备阶段、数据搜集与算法分析，以及细致规划的系统架构设计，通过持续的编码调优，最终成功地将系统付诸实践。以下各节将详细阐述本系统各项功能的具体实施方案。

6.3.1 首页推荐模块的实现

如图 6.2 所示，用户登录之后会显示新能源汽车排列组，默认按照热度排序展示，有效解决了用户登录之后冷启动问题。用户可通过自己喜好来通过标签选择筛选喜欢汽车种类。在浏览相关新能源汽车信息后，登录用户可对相关新能源汽车进行收藏，评分与评论，如图 6.3 所示。与此同时后台会将用户对汽车做出的相关动作记录下来以便用户在再次登录及其他用户登录时，首页能再次更新汽车推荐列表。

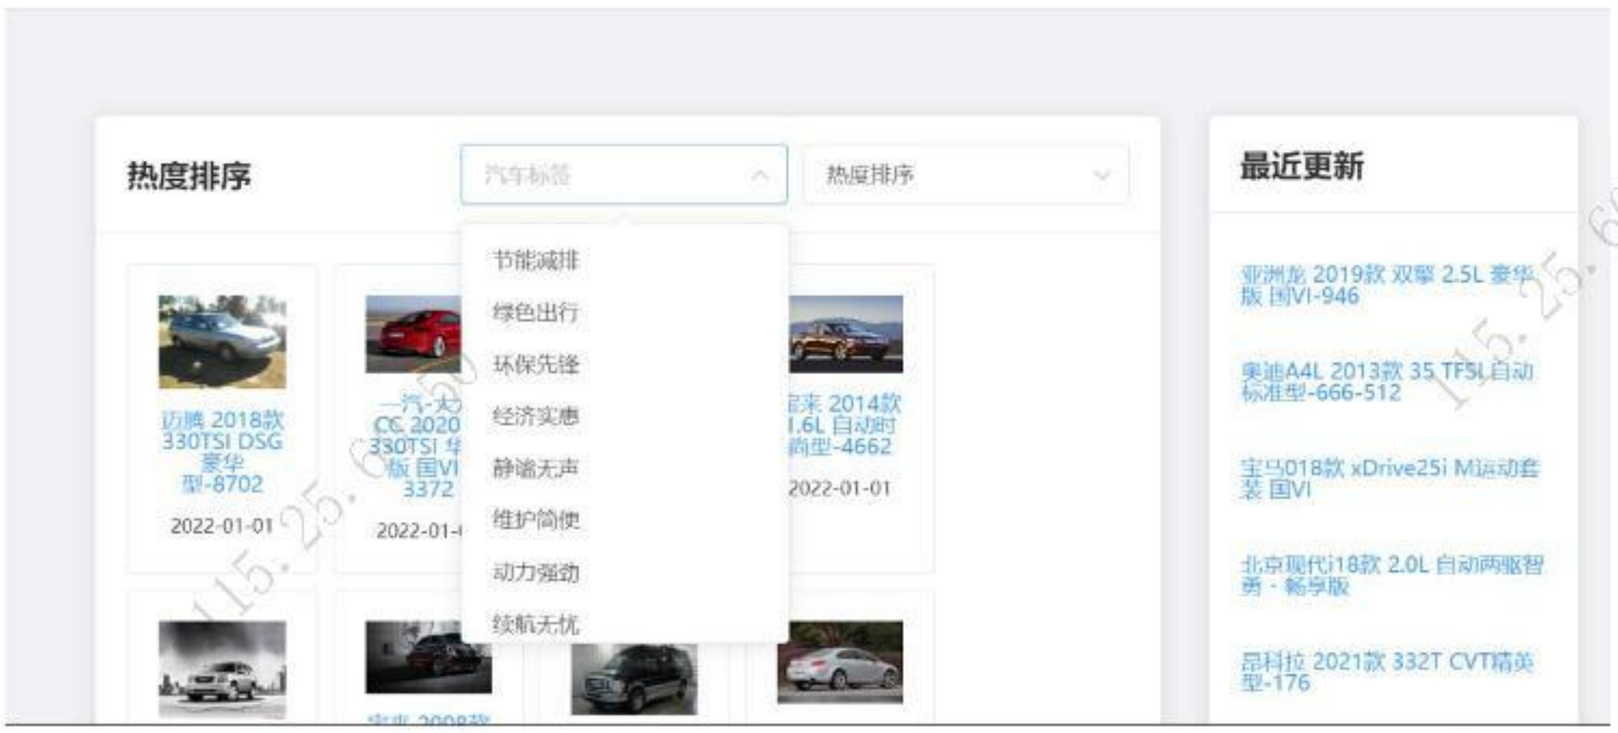


图 6.3 首页推荐模块图

Fig.6.3 Homepage Recommended Module Diagram



图 6.4 汽车详情界面图

Fig.6.4 Car Details Interface Diagram

6.3.2 个人中心模块的实现

如图 6.4 所示。用户在首页浏览了选定标签或选定排序的新能源汽车资料之后，并且在新能源汽车详情页对选定车辆进行评分、收藏或者评论等动作。用户可在个人中心查看自己的操作记录。



图 6.5 个人中心界面图

Fig.6.5 Personal Center Interface Diagram

点击我的收藏之后，便会显示用户所收藏过的所有车辆列表，如图 6.5

所示。



图 6.6 我的收藏界面图

Fig.6.6 My collection interface diagram

如图 6.6 所示，点击我的评论之后，便会显示用户评论过的新能源汽车列表，用户可对评论进行删除处理。同样点击我的评分之后，页面也将显示用户评分过的所有新能源汽车信息列表，也会显示用户给新能源汽车评分多少。用户也可对评分进行删除，如图 6.7 所示。



图 6.7 我的评论界面图

Fig.6.7 My comment interface diagram

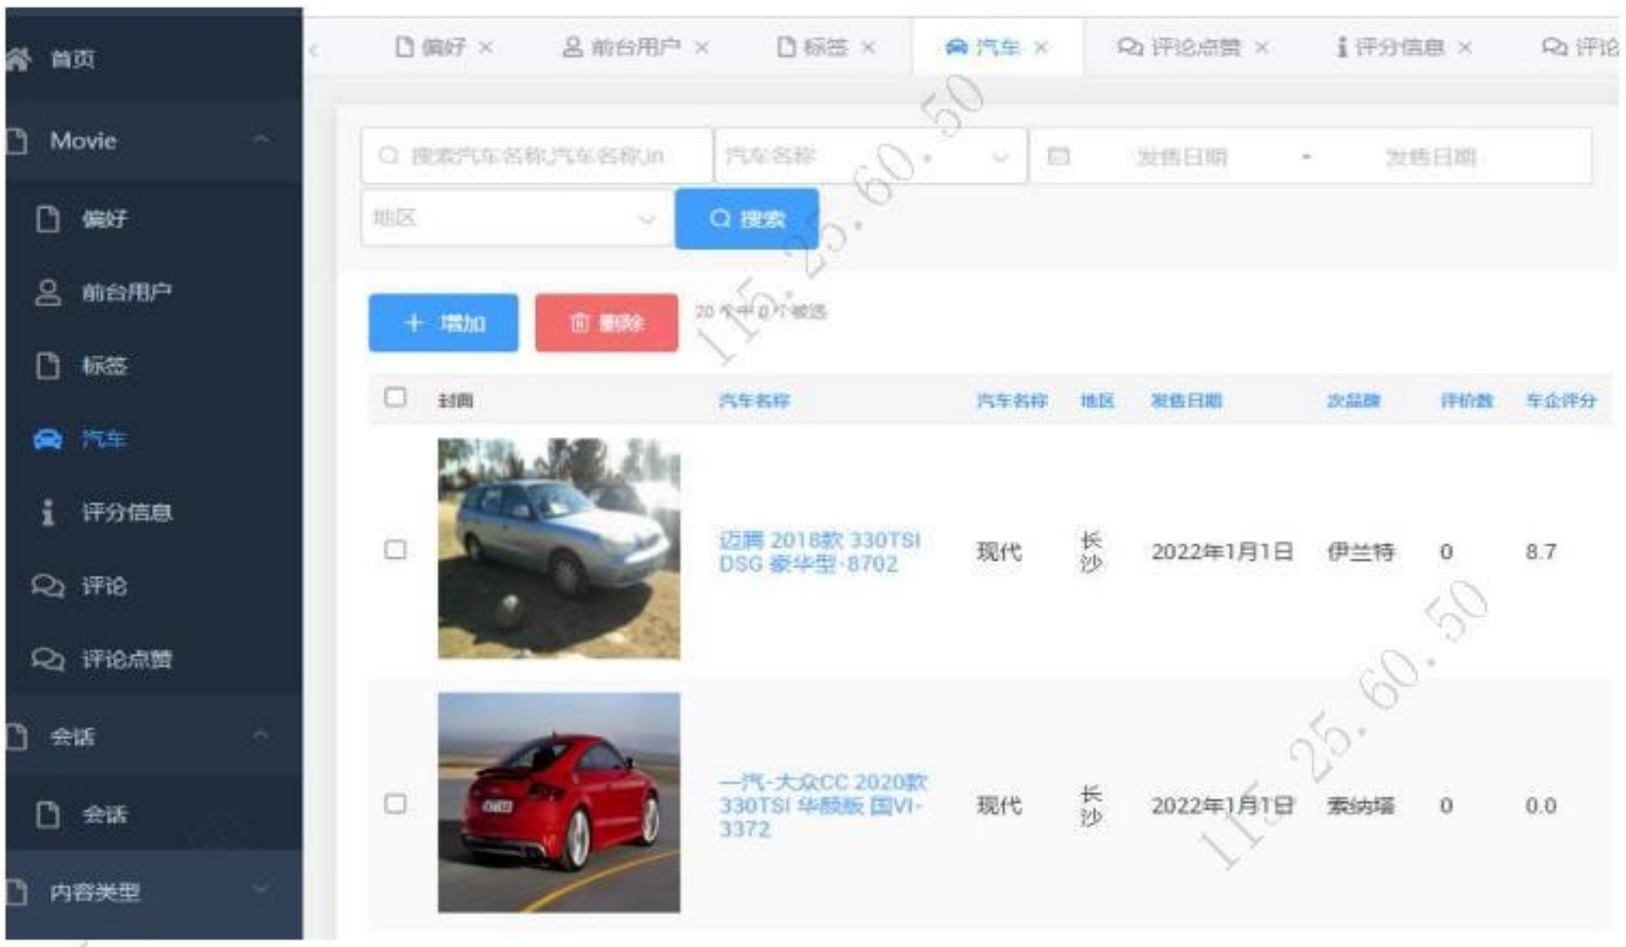


图 6.8 我的评分界面图

Fig.6.8 My rating interface diagram

6.3.3 后台管理模块模块的实现

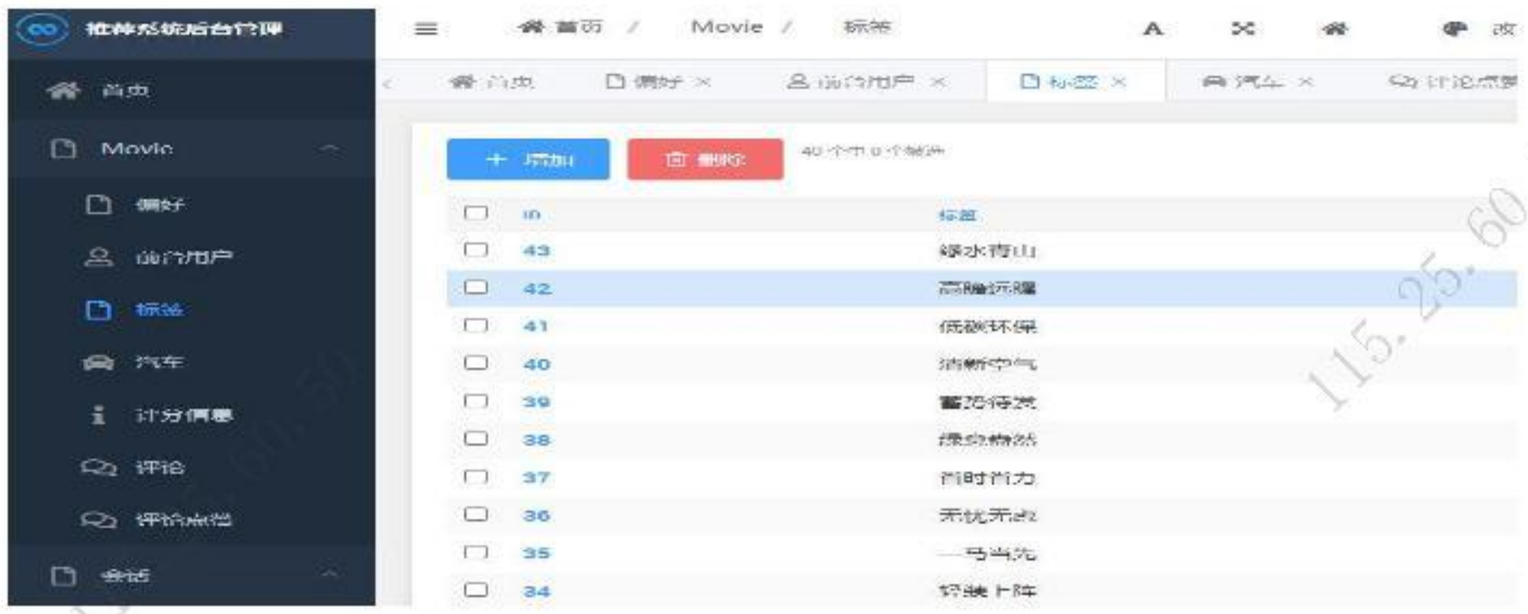
如图 6.8 所示，后端管理模块也是为新能源汽车推荐设计的关键部件之一。当使用管理员的身份登录到推荐系统的后台时，可以增加删除新能源汽车列表的操作，也可对新能源汽车标签进行删除增加操作；并且还可查看登录该网站的所有用户信息，以及用户对于新能源汽车标签的分类偏好，以及他们对新能源汽车的评价和点赞情况等。后台的管理员有能力管理用户在首页上对新能源汽车信息所做的操作，这样用户登录后就可以创建一个新的推荐列表。



(a) 后台管理界面 1



(b) 后台管理界面 2



(c) 后台管理界面 3



(d) 后台管理界面 4

图 6.9 管理员后台管理界面图

Fig.6.9 Administrator backend management interface diagram

6.4 系统测试

为保证推荐新能源汽车推荐系统的可靠性与安全性，需要对系统的各个模块进行测试调试，以避免投入使用时错误的出现为用户带来不舒适的体验感。本系统将采用黑盒测试的方式，从用户需求、系统管理员需求两个角度对系统功能进行测试。

6.4.1 用户功能测试

新能源汽车推荐系统主页推荐模块，个人中心模块中用户功能相关测试用例如表 6-1 所示。

表 6-1 用户功能测试用例

Tab.6-1 User Function Test Cases

功能	功能步骤	预置条件	预期结果	测试结果
用户登录	用户输入账号与密码后点击登录	用户账号与密码均正确	成功登录	成功登录
用户查看推荐列表	用户登陆后查看右侧新能源汽车推荐列表	后台计算出与用户相似度搞得用户，并生成推荐列表	成功查看	成功查看
按照汽车标签检索	用户点击标签下拉框，选择标签进行检索	用户选择相应标签	成功检索	成功检索
按照收藏、评分热度检索	用户点击下拉框，选择想检索的类型进行检索	用户选择相应类型	成功检索	成功检索
用户评论	用户点击相应的新能汽车信息跳转至详情页，进行评论	用户选择相关车辆	成功评论	成功评论
用户收藏和评分	用户点击相应的新能汽车信息跳转至详情页，进行评分和收藏	用户选择相关车辆	成功收藏和评分	成功收藏和评分

6.4.2 管理员功能测试

新能源汽车推荐系统后台管理模块中管理员功能相关测试用例如表 6-2 所示。

表 6-2 管理员功能测试用例

Tab.6-2 Administrator Function Test Cases

功能	功能步骤	预置条件	预期结果	测试结果
管理员登录	管理员输入账号与密码后点击登录	账号与密码均正确	成功登录	成功登录
管理用户偏好	点击用户偏好栏，对用户对汽车类型的偏好打分进行增加或删除	用户有过历史行为	成功增加或删除	成功增加或删除
管理前台用户	点击前台用户栏，对前台用户进行增加或删除	有一定的用户数据源	成功增加或删除	成功增加或删除

表 6-2 续

Tab.6-2 Cont

功能	功能步骤	预置条件	预期结果	测试结果
管理汽车标签	点击标签栏，对标签增加或删除	标签与相应车辆关系一一对应	成功增加或删除	成功增加或删除
管理车辆信息	点击汽车栏，对车辆信息进行增加或删除	有一定的车俩数据源	成功增加或删除	成功增加或删除
管理用户评论信息	点击评论栏，对用户在车辆信息上产生的评论进行增加或删除	用户有过评论行为	成功增加或删除	成功增加或删除
管理用户评分信息	点击评分信息栏，对用户在车辆信息上产生的评分进行增加或删除	用户有过评分行为	成功增加或删除	成功增加或删除

6.5 本章小结

本章主要对新能源汽车推荐系统进行了详细介绍，首先对系统的可行性及需求功能进行了分析；其次在系统总体设计过程中，分别介绍了系统框架设计和系统功能设计；然后截取了系统实现的相关核心模块进行了截图展示；结尾便是从用户角度和管理员角度对新能源汽车推荐系统相关核心功能进行了全方面的测试。

7 总结与展望

7.1 本文总结

在当前人工智能驱动的时代背景下，伴随 5G 网络与 8K 超高清视频技术的兴起，显著地提升了人们的休闲娱乐体验。伴随用户基数及视频类型日益膨胀，这不仅引发了显著的网络负担，还造成了困扰性的信息泛滥现象。人工智能的演进顺应时代诉求，已深入人类日常生活的各个角落，并正驱动推荐系统朝更为智能的路径进化。推荐系统被视为应对信息泛滥挑战的有力工具。鉴于此前提及的情境，本论文重点探讨了新能源汽车范畴内的推荐系统相关议题。

本篇文章呈现了以知识图谱和协同滤波为基础的新能源汽车推荐算法，主要研究工作如下：

(1)构建了新能源汽车知识图谱。首先需要对新能源汽车有关试验的初级数据做初步的处理；在明确实体与其相关的边界后，我们采用了本篇介绍的 Dic-CTR，鉴别命名的实体从文本数据；通过 OWL 语义网络，有效地存贮新能源汽车领域的知识图谱，从而构建起新能源汽车的知识图谱体系。

(2)利用 TransHR 模型对知识图谱进行了深入的知识呈现。通过在低维度向量空间中对车辆间承载的语义信息进行编码，实现了对不同车辆语义相似度的定量和计算。考虑到传统的知识表示模型在处理新能源汽车领域的复杂知识图谱时存在的限制，研究选择了经过优化的超关系模型 TransHR,目的是为了更高效地嵌入，且其在链接预测和三元组分类时展现出了显著的优越性，其表现甚至超越了所有的对比基线模型。

(3)采用了一种名为 TransHR-CF 的推荐算法。该算法是将知识图谱与协同过滤技术相结合。协同过滤驱动的新能源汽车推荐系统主要依赖于用户-物品评分矩阵来运作，忽视了物品固有的语义信息。此外，用户给出的评分往往并非理想的评价标准。本研究以创新的方式应用了知识图谱技术，并以车辆之间的语义信息作为主要的推荐参数。将实体和关系巧妙地将其映射到所构造的新能源汽车知识图谱上，并将其映射到 2 个彼此独立的低维连续向量空间上，从而实现了对车辆语义相似性的量化。随后，融合了基于协同过滤的相似度评估方法，以全面考量用户偏好与历史行为。通过综合上述两种相似度指标，能够精确计算出预测评分，从而高效生成个性化的推荐列表。

（4）新能源汽车推荐系统的设计与实现。完成了主页推荐模块，个人中

心用户功能模块及汽车信息模块等；以及系统的后台对用户、用户历史行为数据和新能源车辆的一系列管理功能，实现了本系统的高可用性。

本文构造了新能源汽车数据域的知识图谱，有效描述了用户与车辆之间的关系；通过采用 TransHR-CF 的推荐算法，强化了车辆间隐匿信息的挖掘，有效解决了数据匮乏与初次使用场景的挑战，从而为用户产出更为公允的推荐反馈。

7.2 未来展望

当前，知识图谱在工业领域的应用普及程度有限，主要障碍在于其构建过程显著依赖于人工介入，并且耗时较长。多数现有实践仅能生成特定子领域的知识图谱，未能实现广泛覆盖。研究推荐系统的历史源远流长，鉴于其作为应对信息过载问题的有力工具，在工业领域的应用已发展至相对成熟的阶段。将知识图谱与推荐系统相融合，不仅能够开拓推荐系统分析问题的全新维度，而且能为其发展提供前所未有的推动力。本项研究仅是对基于知识图谱的推荐系统领域的初步探索，即使已经获得了一些研究进展，但仍存在大量的提升潜力。计划在接下来的几个领域进一步深化研究。

(1)知识图谱的构建问题。在本研究构建知识图谱的时候，我们从新能源汽车的相关网站爬取了数据，并避开了反爬虫的策略，这种做法为知识图谱的构建带来了很大的困扰，尤其是那些需要大量人工处理的部分，而这一构建方法并不够明智。知识图谱的构建方法在未来有望走向更精确和更自动化的方向。

(2)对于知识图谱，在数据模式层的定义上进行优化，并对用户社会关系、薪资水平等方面进行改进；深入探索车辆与这些观念间的更深层次联系；为了更好地为用户提供知识，拟整合大量的数据，将涵盖了众多的专业书目和百科全书。

(3)依据本文采用的推荐算法，开发一款新能源汽车推荐应用程序，并深入探讨用户对购买车辆不满的各种原因。在功能设计上，将更多地关注用户使用的便捷性。

(4)努力将时间的影响因素融入推荐流程，并借助动态时间模型来更好地满足用户在时间敏感区域的动态需要。

参考文献

[1] 张娜，米倩玉，邓嘉纬，等. 新能源崛起对中国新能源产业战略的影响[J]. 中国软科学，2024，20(2)：1-8.

[2] 李媛媛. 中国科学院院士欧阳明高：氢能储能智能协同发力 推动新能源产业变革[N]. 中国证券报，2023-11-24(T02).

[3] 高红. 基于知识图谱的新能源汽车咨询系统研究与实现[D]. 西安：西安石油大学，2023：5-40.

[4] 孙进强，肖银宝. 基于协同过滤-知识图谱的图书推荐[J]. 科技风，2023，52(36)：70-72.

[5] Bollacker K, Evans C, Paritosh P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the 2008 ACM SIGMOD international conference on Management of data. Vancouver, BC, Canada: ACM, 2008: 1247-1250.

[6] 程诚. 基于知识图谱的推荐系统的研究与应用[D]. 南京：南京邮电大学，2023：16-30.

[7] 金宇，陈红梅，罗川. 基于知识图谱的兴趣捕捉推荐算法[J]. 计算机科学，2024，51(1)：133-142.

[8] Dara S, Chowdary C R, Kumar C. A survey on group recommender systems[J]. Journal of Intelligent Information Systems, 2020, 54(2): 271-295.

[9] 徐海文，谭台哲. 基于知识图谱的个性化推荐系统构建[J]. 数字技术与应用，2022，40(3)：152-154+164.

[10] Koren Y. Collaborative filtering with temporal dynamics[C]//Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining. Paris, France: ACM, 2009: 447-456.

[11] 刘峤，李杨，段宏，等. 知识图谱构建技术综述[J]. 计算机研究与发展，2016，53(3)：582-600.

[12] Kim D, Park C, Oh J, et al. Convolutional matrix factorization for document context-aware recommendation[C]//Proceedings of the 10th ACM Conference on Recommender Systems. Boston, MA, USA: ACM, 2016: 233-240.

[13] Zheng L, Noroozi V, Yu P S. Joint deep modeling of users and items using reviews for recommendation[C]//Proceedings of the Tenth ACM

International Conference on Web Search and Data Mining. Cambridge, UK: ACM, 2017: 425-434.

[14] Wu H, Zhang Z, Yue K, et al. Dual-regularized matrix factorization with deep neural networks for recommender systems[J]. Knowledge-Based Systems, 2018, 145(17): 46-58.

[15] 李学超，张文德，曾金晶，等. 推荐系统领域研究现状分析[J]. 情报探索，2019，30(1)：112-119.

[16] 田萱，陈杭雪. 推荐任务中知识图谱嵌入应用研究综述[J]. 计算机科学与探索，2022，16(8)：1681-1705.

[17] 唐晓波，魏巍. 基于本体的推荐系统研究综述[J]. 图书馆学研究，2016，40(18)：7-12.

[18] Li D, Lv Q, Xie X, et al. Interest-based real-time content recommendation in online social communities[J]. Knowledge-Based Systems, 2012, 28(4): 1-12.

[19] 印鉴，王智圣，李琪，等. 基于大规模隐式反馈的个性化推荐[J]. 软件学报，2014，25(9)：1953-1966.

[20] 王立才，孟祥武，张玉洁. 上下文感知推荐系统[J]. 软件学报，2012，23(1)：1-20.

[21] Niaraki A S, Kim K. Ontology based personalized route planning system using a multi-criteria decision making approach[J]. Expert Systems with Applications, 2009, 36(2): 2250-2259.

[22] Dodwad P R, Lobo L M R J. A context-aware recommender system using ontology based approach for travel applications[J]. International Journal of Advanced Engineering and Nano Technology (IJAENT), 2014, 1(10): 8-12.

[23] Kethavarapu U P K, Saraswathi S. Concept based dynamic ontology creation for job recommendation system[J]. Procedia Computer Science, 2016, 85: 915-921.

[24] Di Noia T, Mirizzi R, Ostuni V C, et al. Linked open data to support content-based recommender systems[C]//Proceedings of the 8th International Conference on Semantic Systems. Graz, Austria: ACM, 2012: 1-8.

[25] Ting K M, Witten I H. Issues in stacked generalization[J]. Journal of Artificial Intelligence Research, 1999, 10(8): 271-289.

[26] Perozzi B, Al-Rfou R, Skiena S. DeepWalk: online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. New York, NY, USA: ACM, 2014: 701-710.

[27] 李涛，王次臣，李华康．知识图谱的发展与构建[J]．南京理工大学学报，2017，41(1)：22-34.

[28] 王卓岚，张雨琦，陈鸣宇，等．基于 neo4j 图数据库的电影知识图谱构建与电影推荐研究[J]．现代电影技术，2022，20(3)：29-36.

[29] Xu B, Xu Y, Liang J, et al. CN-DBpedia: a never-ending Chinese knowledge extraction system[C]//Benferhat S, Tabia K, Ali M. Advances in Artificial Intelligence: From Theory to Practice: Vol. 10351. Cham, Switzerland: Springer International Publishing, 2017: 428-438.

[30] Miller G A. WordNet: a lexical database for English[J]. Communications of the ACM, 1995, 38(11): 39-41.

[31] Jin H, Hou L, Li J. Type hierarchy enhanced heterogeneous network embedding for fine-grained entity typing in knowledge bases[C]//Sun M, Liu T, Wang X, et al. Chinese Computational Linguistics and Natural Language Processing Based on Naturally Annotated Big Data: Vol. 11221. Cham, Sweden: Springer International Publishing, 2018: 170-182.

[32] 王智悦，于清，王楠，等．基于知识图谱的智能问答研究综述[J]．计算机工程与应用，2020，56(23)：1-11.

[33] 陈浩．基于动态知识图谱的推荐算法研究[D]．海口：海南大学，2023.

[34] Chen Q, Yao H, Li S, et al. Fact-condition statements and super relation extraction for geothermic knowledge graphs construction[J]. Geoscience Frontiers, 2023, 14(5): 101412-101830.

[35] 周雨晴．基于知识图谱的隐私保护推荐算法研究[D]．南宁：广西民族大学，2023: 19-60.

[36] Müller H M, Kenny E E, Sternberg P W. Textpresso: an ontology-based information retrieval and extraction system for biological literature[J]. PLoS Biology, 2004, 2(11): e309.

[37] Lehnert W G. The process of question answering: a computer simulation of cognition[M]. London, UK: Routledge, 1978: 500-875.

[38] Cho K, Van Merrienboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder - decoder for statistical machine translation[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: Association for Computational Linguistics, 2014: 1724-1734.

[39] Yan Y, Okazaki N, Matsuo Y, et al. Unsupervised relation extraction by mining Wikipedia texts using information from the web[C]//Proceedings of

the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing of the AFNLP: Volume 2 - ACL-IJCNLP ’09: Vol. 2. Suntec, Singapore: Association for Computational Linguistics, 2009: 1021-1578.

[40] Brin S. Extracting patterns and relations from the World Wide Web[C]//Atzeni P, Mendelzon A, Mecca G. The World Wide Web and Databases: Vol. 1590. Berlin, Heidelberg: Springer Berlin Heidelberg, 1999: 172-183.

[41] Mintz M, Bills S, Snow R, et al. Distant supervision for relation extraction without labeled data[C]//Proceedings of the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing of the AFNLP: Volume 2 - ACL-IJCNLP ’09: Vol. 2. Suntec, Singapore: Association for Computational Linguistics, 2009: 1003-1677.

[42] 刘知远，孙茂松，林衍凯，谢若冰:知识表示学习研究进展[J]. 计算机研究与发展，2016, 53(2):247-261.

[43] 苏湛，陈学谦，艾均，等. 基于用户相似性选择及标签距离的推荐算法[J]. 应用科学学报，2023，41(06)：940-957.

[44] 凌婷. 协同过滤推荐算法研究进展[J]. 信息记录材料，2023，24(11)：16-18.

[45] 付娟. 推动新能源汽车产业持续健康发展[N]. 中国政府采购报，2024-03-05(7).

[46] 万敏. 为新能源汽车提供源源动力[N]. 南昌日报，2024-03-04(1).

[47] 王思瑜. 新能源汽车发展现状研究综述[J]. 内燃机与配件，2024，60(5)：135-137.

[48] 马晓敏. 着力推动新能源高质量规模化发展[N]. 中国矿业报，2024-03-12(2).

[49] 吴喃. 基于知识图谱的个性化体检推荐方法研究与系统实现[D]. 海口：海南大学，2023: 26-48.

[50] 郭黄梅. 融合张量分解和知识图谱的推荐算法研究[D]. 武汉：华中农业大学，2023: 15-50.

[51] Ren H, Yang M, Jiang P. Improving attention network to realize joint extraction for the construction of equipment knowledge graph[J]. Engineering Applications of Artificial Intelligence, 2023, 125(30): 1723-2034.

[52] 郭雅静. 基于知识图谱和用户偏好的推荐方法研究[D]. 大连: 大连海事大学, 2023: 20-40.

[53] Liu C, Zhang H, Zhang J, et al. Design of a learning path recommendation system based on a knowledge graph[J]. International Journal of Information and Communication Technology Education, 2023, 19(1): 1-18.

[54] Fan H, Zhong Y, Zeng G, et al. Improving recommender system via knowledge graph based exploring user preference[J]. Applied Intelligence, 2022, 52(9): 10032-10044.

[55] Troussas C, Krouska A. Path-based recommender system for learning activities using knowledge graphs[J]. Information, 2022, 14(1): 9-16.

[56] Chen T, Wang X, Yue T, et al. Enhancing abstractive summarization with extracted knowledge graphs and multi-source transformers[J]. Applied Sciences, 2023, 13(13): 7753-7767.

[57] 张潇. 基于知识图谱的个性化推荐系统研究[D]. 无锡: 江南大学, 2022: 25-39.

[58] 谢世科. 基于知识图谱的论文推荐算法的研究与设计[D]. 北京: 北京邮电大学, 2023: 16-48.

[59] 牛雪磊, 杨军, 闫浩文. 融合知识图谱与协同过滤的微地图推荐[J]. 地球信息科学学报, 2024, 26(4): 967-977.

[60] 甄好. 基于知识图谱和协同过滤的推荐方法研究[D]. 天津: 天津理工大学, 2024: 20-50.

致　谢

时光荏苒，如白驹过隙，两年半的时间即将过去，意味着我的研究生生涯即将结束。在这两年的学习与研究过程中，因在职研究生的特殊性质，需要同时协调好自己的工作与学习，在这个过程中我经历了挫折、迷茫最终也坚持下来。此刻，我怀着无比感恩与崇敬的心情，写下这篇致谢，以表达我对那些在我求学道路上给予我支持和帮助的人们的深深敬意与感激。

我想对我的研究生导师万初斌老师表示深深的感谢，从选定研究论文的主题、构思阶段到最后的定稿，每一步均深受导师教诲。导师以其深厚的学识、严谨的学术态度、敏锐的学术洞见和高尚的人格品质，都为我树立了表率，激励着我不断追求卓越。在我遇到波折时，导师总是给予我鼓励和支持，引导我走出困境，让我重新找回勇气，使我受益终身。

一、 作者入学前简历

起止年月	学习或工作单位	备注
2017 年 9 月-2019 年 7 月	河南财经政法大学	专科
2019 年 9 月-2021 年 7 月	河南科技学院	本科

二、 在学期间从事的科研工作

三、 在学期间所获的科研奖励

四、 在学期间发表的论文

独创性说明

本人郑重声明：所呈交的论文是我个人在导师指导下进行的研究工作及取得研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写的研究成果，也不包含为获得北京科技大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

作 者 签 名：赵紫微 日期：2024 年 12 月 11 日

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：赵紫微　导师签名：[illegible]　日期：2024年12月14日

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
知识图谱；个性化推荐；协同过滤； 实体识别	公开	TP311	004	
学位授予单位名称*		**学位授予单位代码***	**学位类别***	**学位级别***
北京科技大学		10008	工学	硕士
论文题名*		**并列题名**		**论文语种***
基于知识图谱与协同过滤的新能源汽车推荐算法研究与系统设计				中文
作者姓名*	赵紫微		**学号***	M202240120
培养单位名称*		**培养单位代码***	**培养单位地址**	**邮编**
北京科技大学		10008	北京市海淀区学院路 30 号	100083
学科专业*		**研究方向***	**学制***	**学位授予年***
软件工程		知识图谱；神经网络	2.5 年	2025
论文提交日期*	2024 年 11 月 19 日			
导师姓名*	万初斌		**职称***	教授
评阅人	**答辩委员会主席***		**答辩委员会成员**	
	万初斌		周贤伟 李擎 林福宏 顾强	
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） **推荐格式：** application/msword；application/pdf				
电子版论文出版（发布）者		**电子版论文出版（发布）地**		**权限声明**
论文总页数*	51			
共 33 项，其中带*为必填数据，为 22 项。				